Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

Inhaltsverzeichnis

1. Grundlagen der Statistik
2. Regression
3. Expectation-Maximization (EM) Algorithmus
4. Independent Component Analysis

Kapitel

1 **Grundlagen der Statistik**

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Maximum-Likelihood Schätzer

Maximum-Aposteriori Schätzer

Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ω ist der **Ereignisraum**, also die Menge aller Elemantarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir $\Omega := \{1, 2, 3, 4, 5, 6\}$.
- Mit $\mathcal{A}$ bezeichnen wir die zugehörige **Sigma-Algebra**, einer Menge von Teilmengen von Ω. Im einfachsten Fall könnten wir $\mathcal{A} := \text{Pot}(\Omega)$ wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra $\mathbb{B}$ auf $\mathbb{R}$ heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \to [0, 1]$ ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus $\mathcal{A}$ eine Wahrscheinlichkeit zuordnet.

Zufallsvariablen

Im Folgenden sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{B})$ ein messbarer Raum.

1.1 Definition: Die Abbildung $x : \Omega \to \mathcal{X}$ heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : x^{-1}(B) := \{\omega \in \Omega : x(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von B unter x muss also eine messbare Menge in $\mathcal{A}$ sein, der durch $\mathbb{P}$ eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable $x : \Omega \to \mathcal{X}$ die Funktion

$$\mathbb{P}^x : \mathcal{B} \to [0, 1] \qquad \text{mit} \qquad B \mapsto \mathbb{P}(x^{-1}(B))$$

die **Verteilung** der Zufallsvariablen x. $\mathbb{P}^x$ ist das **Bildmaß** von $\mathbb{P}$ unter x.

Zufallsvariablen (Forts.)

Sei $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$ ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße $x : \Omega \to \mathcal{X}$ ist *verteilt gemäß* $\mathbb{Q}$ oder kurz $\mathbb{Q}$-*verteilt*, falls es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\mathbb{P}^x = \mathbb{Q}$ gilt.

Beispiele:

- x ist N_{μ,σ^2}-verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\forall B \in \mathbb{B} : \mathbb{P}(x \in B) = N_{\mu,\sigma^2}(B)$. Wir schreiben kurz $x \sim N_{\mu,\sigma^2}$.
-

Wahrscheinlichkeitsdichten

In der Regel wollen wir mit Dichten rechnen:

1.2 Definition: Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{B}, \mathbb{P}^x)$ Wahrscheinlichkeitsräume. Dabei ist $\mathbb{P}^x$ die Verteilung der Zufallsvariablen $x : \Omega \to \mathcal{X}$. Wir nennen eine nichtnegative Funktion

$$p_x : \mathbb{R} \to [0,\ 1]$$

eine **(Wahrscheinlichkeits-)Dichte** von $\mathbb{P}^x$, falls

$$\mathbb{P}^x(B) = \int_B p_x(\xi)\,\mathrm{d}\xi \qquad \forall B \in \mathcal{B}.$$

Die Wahrscheinlichkeiten der Mengen $B \in \mathcal{B}$ müssen sich also allesamt als Integral der Dichte p_x darstellen lassen können.

Erwartungswert von Zufallsvariablen

1.3 Definition: Sei $x \in \mathbb{R}$ eine Zufallsvariable. Wir definieren den **Erwartungswert** (erstes Moment) von x als

$$\mathbb{E}[x] := \int_{\mathbb{R}} \xi \cdot p_x(\xi) \, \mathrm{d}\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen x und y und eine beliebige aber feste Zahl $\alpha \in \mathbb{R}$ (keine Zufallsvariable!) gelten

$$\mathbb{E}[x + y] = \mathbb{E}[x] + \mathbb{E}[y] \qquad \text{und} \qquad \mathbb{E}[\alpha \cdot x] = \alpha \cdot \mathbb{E}[x].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)^\top$ als

$$\mathbb{E}[\boldsymbol{x}] := (\mathbb{E}[x_1], \mathbb{E}[x_2], \ldots, \mathbb{E}[x_n])^\top.$$

Varianz von Zufallsvariablen

1.4 Definition: Die Varianz einer Zufallsvariablen $x \in \mathbb{R}$ ist definiert als die erwartete quadratische Abweichung vom Erwartungswert (zweites zentriertes Moment), also

$$\mathbb{V}[x] := \mathbb{E}\big[(x - \mathbb{E}[x])^2\big] = \int_{\mathbb{R}} (\xi - \mathbb{E}[x])^2 \cdot p_x(\xi)\, \mathrm{d}\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[x] &= \mathbb{E}\big[(x - \mathbb{E}[x])^2\big] = \mathbb{E}\big[x^2 - 2x \cdot \mathbb{E}[x] + (\mathbb{E}[x])^2\big] \\ &= \mathbb{E}[x^2] - 2(\mathbb{E}[x])^2 + (\mathbb{E}[x])^2 \\ &= \mathbb{E}[x^2] - (\mathbb{E}[x])^2\end{aligned}$$

Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen. Seien dazu x und y reelle Zufallsvariablen und $\alpha \in \mathbb{R}$ beliebig aber fest.

- Die Varianz ist **nicht** linear:
  - Es gilt $\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$ nur, wenn x und y unkorreliert sind (Satz von Bienaymé).
  - $\mathbb{V}[\alpha \cdot x] = \alpha^2 \cdot \mathbb{V}[x]$
- Eine Verschiebung verändert die Varianz nicht, also $\mathbb{V}[x + \alpha] = \mathbb{V}[x]$

Kovarianz und Streuungsmatrix

tbd

Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

Name der Verteilung	$\mathbb{P}^x$	Zähldichte $p_x(k)$	$\mathbb{E}[x]$	$\mathbb{V}[x]$
Binomialverteilung	$B_{n,p}$	$\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Hypergeometrische Verteilung	$H_{n,K,N}$	$\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \cdot \frac{K}{N}$	$n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$
Poisson-Verteilung	P_λ	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	λ	λ

Absolutstetige Verteilungen

Name der Verteilung	$\mathbb{P}^x$	Lebesgue-Dichte $p_x(\xi)$	$\mathbb{E}[x]$	$\mathbb{V}[x]$
Normalverteilung	N_{μ,σ^2}	$\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gammaverteilung	$\Gamma_{\lambda,r}$	$\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0,\infty)}(\xi)$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$
Chiquadrat-Verteilung	χ^2_f	$\frac{1}{2^{\frac{f}{2}} \cdot \Gamma\left(\frac{f}{2}\right)} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0,\infty)}(\xi)$	f	$2 \cdot f$
Exponentialverteilung	Exp_λ	$\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0,\infty)}(\xi)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Betaverteilung	$\beta_{a,b}$	$\frac{\Gamma(a+b)}{\Gamma(a)\cdot\Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi)$	$\frac{a}{a+b}$	$\frac{a\cdot b}{(a+b)^2\cdot(a+b+1)}$
Gleichverteilung	$U_{(a,b)}$	$\frac{1}{b-a} \cdot \mathbf{1}_{(a,b)}(\xi)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

1.5 Definition: Es seien $x \in \mathbb{R}$ und $y \in \mathbb{R}$ reelle Zufallsvariablen mit den Verteilungen $\mathbb{P}^x$, $\mathbb{P}^y$ und den Dichten p_x bzw. p_y.

x und y heißen **stochastisch unabhängig** genau dann wenn $p_{x,y} := p_x \cdot p_y$ eine Produktdichte der Verteilung $\mathbb{P}^{x,y}$ ist, d. h. die gemeinsame Dichte von x und y ergibt sich als Produkt der Einzeldichten.

Bemerkung: Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. Die Umkehrung gilt im Allgemeinen nicht. Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als Unkorreliertheit.

Bedingte Wahrscheinlichkeiten

tbd

Satz von Bayes

tbd

Transformationssatz für Lebesgue-Dichten

1.6 Satz: Es seien $\boldsymbol{x}$ und $\boldsymbol{y}$ n-dimensionale Zufallsvektoren mit dem Zusammenhang

$$\boldsymbol{y} = \boldsymbol{T}(\boldsymbol{x}).$$

Die Abbildung $\boldsymbol{T} : \mathbb{R}^n \to \mathbb{R}^n$ sei *bijektiv*, sodass die Umkehrabbildung $\boldsymbol{x} = \boldsymbol{T}^{-1}(\boldsymbol{y})$ existiert und eindeutig ist. Dann gilt für die Dichte $p_{\boldsymbol{y}}$ der transformierten Zufallsvariablen $\boldsymbol{y}$

$$p_{\boldsymbol{y}}(\boldsymbol{y}) = p_{\boldsymbol{x}}(\boldsymbol{T}^{-1}(\boldsymbol{y})) \cdot \left|\det J\boldsymbol{T}^{-1}(\boldsymbol{y})\right|,$$

wobei $p_{\boldsymbol{x}}$ die Dichte von $\boldsymbol{x}$ und $J\boldsymbol{T}^{-1}$ die Jacobi-Matrix der Abbildung $\boldsymbol{T}^{-1}$ bezeichnet.

Beweis: Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

Beispiel I

Es sei $x \sim Exp_2$ eine reellwertige exponentialverteilte Zufallsvariable mit Ankunftsrate $\lambda = 2$. Gesucht ist die Dichte der Zufallsvariablen $y := 5x + 2$.

Lösung: Es ist $T(x) := 5x + 2$ eine bijektive Transformation mit der Umkehrabbildung $x = T^{-1}(y) = \frac{1}{5}(y - 2)$. Zusammen mit der Dichte $p_x(x) = 2 \cdot e^{-2x} \cdot \mathbf{1}_{[0,\infty)}(x)$ der Exp_2-Verteilung erhalten wir für die Dichte $p_y(y)$ der transformierten Zufallsvariablen y

$$
\begin{aligned}
p_y(y) &= p_x(T^{-1}(y)) \cdot (T^{-1})'(y) \\
&= 2 \cdot e^{-2\left(\frac{y}{5} - \frac{2}{5}\right)} \cdot \mathbf{1}_{[0,\infty)}\left(\frac{1}{5}y - \frac{2}{5}\right) \cdot \frac{1}{5} \\
&= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2y}{5}} \cdot \mathbf{1}_{[2,\infty)}(y).
\end{aligned}
$$

Beispiel II

Der Zufallsvektor $\boldsymbol{x} \in \mathbb{R}^n$ habe eine beliebige Lebesgue-Dichte $p_{\boldsymbol{x}}$. Die Transformation $\boldsymbol{T}$ sei linear und bijektiv, also von der Form $\boldsymbol{y} = \boldsymbol{T}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$. Insbesondere ist $\boldsymbol{A}$ in diesem Fall invertierbar. Dann existiert die Umkehrfunktion und ist gegeben durch $\boldsymbol{x} = \boldsymbol{T}^{-1}(\boldsymbol{y}) = \boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{b})$. Als Jacobi-Matrix erhält man $J\boldsymbol{T}^{-1}(\boldsymbol{y}) = \boldsymbol{A}^{-1}$.

Die Anwendung der Transformationsformel 1.6 ergibt daher für die Dichte $p_{\boldsymbol{y}}$ von $\boldsymbol{y}$ den Ausdruck

$$p_{\boldsymbol{y}}(\boldsymbol{y}) = \frac{1}{|\det \boldsymbol{A}|} \cdot p_{\boldsymbol{x}}(\boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{b})),$$

wobei wir den Zusammenhang $\det(\boldsymbol{A}^{-1}) = \frac{1}{\det \boldsymbol{A}}$ benutzt haben.

Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

1.7 Satz: Es sei $\boldsymbol{x} := (x_1, x_2, \ldots, x_n)^\top \in \mathbb{R}^n$ ein Zufallsvektor, dessen Komponenten $x_i \in \mathbb{R}$ unabhängig und identisch standardnormalverteilt sind, d. h. $x_i \sim N_{0,1}\ \forall i \in \{1, \ldots, n\}$.

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$p_{\boldsymbol{x}}(\boldsymbol{x}) := \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\boldsymbol{x}\|^2}{2}\right).$$

Beweis: Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$p_{\boldsymbol{x}}(\boldsymbol{x}) = \prod_{i=1}^{n} p_{x_i}(x_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^{n} x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\boldsymbol{x}^\top \boldsymbol{x}}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\boldsymbol{x}\|^2}{2}\right).$$

□

Multivariate Normalverteilung (Forts.)

Für die multivariate Standardnormalverteilung gilt $\mathbb{E}[\boldsymbol{x}] = \boldsymbol{0}$ und $\mathbb{D}[\boldsymbol{x}] = \boldsymbol{I}$.

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren $\boldsymbol{\mu} \in \mathbb{R}^n$ und Streuungsmatrizen $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$. Wir fordern lediglich, dass die Streuungsmatrix $\boldsymbol{\Sigma}$ *positiv definit* ist, dass also $z^\top \boldsymbol{\Sigma} z > 0 \, \forall z \in \mathbb{R}^n \backslash \{\boldsymbol{0}\}$ gilt.

1. Aufgrund der positiven Definitheit von $\boldsymbol{\Sigma}$ gibt es eine untere Dreiecksmatrix $\boldsymbol{A}$ mit $\boldsymbol{\Sigma} = \boldsymbol{A}\boldsymbol{A}^\top$ (Stichwort: **Cholesky-Zerlegung**).
2. Wir betrachten die Transformation $\boldsymbol{y} := \boldsymbol{A}\boldsymbol{x} + \boldsymbol{\mu}$. Es gilt

$$\mathbb{E}[\boldsymbol{y}] = \mathbb{E}[\boldsymbol{A}\boldsymbol{x} + \boldsymbol{\mu}] = \boldsymbol{A}\mathbb{E}[\boldsymbol{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \qquad \text{und} \qquad \mathbb{D}[\boldsymbol{y}] = \mathbb{D}[\boldsymbol{A}\boldsymbol{x} + \boldsymbol{\mu}] = \boldsymbol{A}\mathbb{D}[\boldsymbol{x}]\boldsymbol{A}^\top = \boldsymbol{A}\boldsymbol{A}^\top = \boldsymbol{\Sigma}.$$

3. Nun wenden wir die Transformationsformel 1.6 an.

Multivariate Normalverteilung (Forts.)

Es ist $\boldsymbol{T}^{-1}(\boldsymbol{x}) = \boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{\mu})$. Mit obigem Beispiel II zum Transformationssatz erhalten wir

$$\left|\det J\boldsymbol{T}^{-1}(\boldsymbol{y})\right| = \left|\det \boldsymbol{A}^{-1}\right| = \frac{1}{|\det \boldsymbol{A}|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz[1] die Identität $\det \boldsymbol{\Sigma} = \det(\boldsymbol{A}\boldsymbol{A}^\top) = \det \boldsymbol{A} \cdot \det \boldsymbol{A} = \det^2 \boldsymbol{A}$. Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also $|\det \boldsymbol{A}| = (\det \boldsymbol{\Sigma})^{\frac{1}{2}}$. Die Dichte $p_{\boldsymbol{y}}$ nimmt damit die Form

$$p_{\boldsymbol{y}}(\boldsymbol{y}) = \frac{1}{(\det \boldsymbol{\Sigma})^{\frac{1}{2}}} \cdot p_{\boldsymbol{x}}(\boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{\mu}))$$

an, wobei $p_{\boldsymbol{x}}$ die Dichte der Standardnormalverteilung aus Satz 1.7 ist. Wir setzen dort $\boldsymbol{x} := \boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{\mu})$, sodass $\|\boldsymbol{x}\|^2 = (\boldsymbol{y} - \boldsymbol{\mu})^\top (\boldsymbol{A}^{-1})^\top \boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{\mu}) = (\boldsymbol{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{y} - \boldsymbol{\mu})$ gilt.

[1] Für zwei $n \times n$ Matrizen $\boldsymbol{A}$ und $\boldsymbol{B}$ gilt $\det(\boldsymbol{A}\boldsymbol{B}) = \det \boldsymbol{A} \cdot \det \boldsymbol{B}$.

Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

1.8 Definition: Es sei $\boldsymbol{\mu} \in \mathbb{R}^n$ und $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ eine *positiv definite* Matrix.

Die Dichte der multivariaten Normalverteilung $N_{\boldsymbol{\mu}, \boldsymbol{\Sigma}}$ ist gegeben durch

$$p_{\boldsymbol{x}}(\boldsymbol{x}) := \frac{1}{(2\pi)^{\frac{n}{2}} \cdot (\det \boldsymbol{\Sigma})^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{x} - \boldsymbol{\mu})\right).$$

Bemerkung: Die positive Definitheit der Matrix $\boldsymbol{\Sigma}$ impliziert deren Invertierbarkeit.

Visualisierung: Multivariate Normalverteilung

tbd

Partitionierte Normalverteilung

1.9 Definition: Es seien $\boldsymbol{x} \in \mathbb{R}^d$ und $\boldsymbol{y} \in \mathbb{R}^{(n-d)}$ Zufallsvektoren. Wir fassen diese zu einem neuen Zufallsvektor $\boldsymbol{z} := (\boldsymbol{x}^\top, \boldsymbol{y}^\top)^\top \in \mathbb{R}^n$ mit $\boldsymbol{z} \sim N_{\boldsymbol{\mu},\boldsymbol{\Sigma}}$ zusammen. Hierbei seien

$$\boldsymbol{\mu} := \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix} \qquad \text{und} \qquad \boldsymbol{\Sigma} := \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}.$$

Wir nennen dieses Modell **partitionierte Normalverteilung**.

Bemerkungen:

- Aus der Symmetrie von $\boldsymbol{\Sigma}$ folgt die von $\boldsymbol{\Sigma}_{xx}$ und $\boldsymbol{\Sigma}_{yy}$. Außerdem gilt $\boldsymbol{\Sigma}_{xy} = \boldsymbol{\Sigma}_{yx}^\top$.
- Oft ist es einfacher mit der Inversen der Kovarianzmatrix zu arbeiten. Wir definieren daher $\boldsymbol{\Lambda} := \boldsymbol{\Sigma}^{-1}$. Man nennt diese Matrix **Präzisionsmatrix**.

Bedingte Normalverteilung

1.10 Satz: Wir betrachten die partitionierte Normalverteilung aus Definition 1.9. Dann ist die Verteilung von $\boldsymbol{x} \mid \boldsymbol{y}$ ebenfalls normalverteilt mit den Parametern

$$\boldsymbol{\mu}_{x|y} := \boldsymbol{\mu}_x + \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{yy}^{-1}(\boldsymbol{y} - \mu_y)$$

$$\boldsymbol{\Sigma}_{x|y} := \boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{yy}^{-1}\boldsymbol{\Sigma}_{yx}$$

Die Dichte dieser Verteilung bezeichnen wir mit $p_{x|y}$.

Beweis: Einen Beweis dieser Aussage finden Sie in Bishop (2006) auf den Seiten 85–87. □

Visualisierung: Bedingte Normalverteilung

tbd

Normale Randverteilung

1.11 Satz: Wieder betrachten wir die partitionierte Normalverteilung aus Definition 1.9. Dann sind auch die Randverteilungen von $\boldsymbol{x}$ und $\boldsymbol{y}$ normalverteilt. Es gilt

$$\boldsymbol{x} \sim N_{\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx}}$$

$$\boldsymbol{y} \sim N_{\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy}}$$

Die Dichten der Randverteilung bezeichnen wir mit $p_{\boldsymbol{x}}$ und $p_{\boldsymbol{y}}$.

Beweis: Man erhält dieses Ergebnis durch **Marginalisierung** der Verbunddichte, d. h. wir integrieren über alle Variablen, die uns nicht interessieren. Für die Randverteilung von $\boldsymbol{x}$ gilt zum Beispiel

$$p_{\boldsymbol{x}}(\boldsymbol{x}) = \int p_{\boldsymbol{x},\boldsymbol{y}}(\boldsymbol{x}, \boldsymbol{y})\, \mathrm{d}\boldsymbol{y}.$$

Einen ausführlichen Beweis finden Sie in Bishop (2006) auf den Seiten 88–89. □

Visualisierung: Normale Randverteilung

tbd

Satz von Bayes für Normalverteilungen

tbd

Maximum-Likelihood Methode

- Im Folgenden sei ein Beobachtungsvektor $\boldsymbol{x} := (x_1, x_2, \ldots, x_N)^\top$ bestehend aus N *unabhängig und identisch verteilten* (i. i. d.) Datenpunkten gegeben.
- Wir möchten Aussagen über die Parameter $\boldsymbol{\theta} := (\theta_1, \theta_2, \ldots, \theta_M)^\top$ der zugrundeliegenden Verteilung machen.
- Dies erledigen wir durch eine Punktschätzung des Parametervektors $\boldsymbol{\theta}$. Den Schätzer für $\boldsymbol{\theta}$ bezeichnen wir mit $\hat{\boldsymbol{\theta}}$.
- Eine der am häufigsten angewendete Methode ist die **Maximum-Likelihood Methode**, die wir im Folgenden näher beleuchten werden.

(Log-)Likelihood Funktion

Der Maximum-Likelihood Schätzer $\hat{\boldsymbol{\theta}}_{ML}$ für den Parametervektor $\boldsymbol{\theta}$ maximiert die Likelihood Funktion.

1.12 Definition: Es sei $p(\boldsymbol{x}; \boldsymbol{\theta})$ die Dichte eines Zufallsvektors $\boldsymbol{x} \in \mathbb{R}^n$, welche durch den Parametervektor $\boldsymbol{\theta} \in \Theta$ parametrisiert wird. Die **Likelihood Funktion** $L : \Theta \to \mathbb{R}$ ist dann definiert als

$$L(\boldsymbol{\theta}) := p(\boldsymbol{x}; \boldsymbol{\theta}) = p(x_1, x_2, \ldots, x_N; \boldsymbol{\theta}).$$

Häufig ist es einfacher, die **Log-Likelihood Funktion**

$$l(\boldsymbol{\theta}) := \ln p(\boldsymbol{x}; \boldsymbol{\theta})$$

zu betrachten. Es ist $\hat{\boldsymbol{\theta}}_{ML} := \arg\max_{\boldsymbol{\theta}} l(\boldsymbol{\theta})$.

Bemerkung: Der Schätzer $\hat{\boldsymbol{\theta}}_{ML}$ maximiert sowohl L als auch l. **(Warum?)**

(Log-)Likelihood Funktion (Forts.)

- Im Allgemeinen kann es schwer sein, die Liklihood Funktion zu bestimmen (vor allem wenn die Beobachtungen voneinander abhängen).
- Die Annahme der **Unabhängigkeit der Beobachtungen** vereinfacht dies maßgeblich, denn

$$L(\boldsymbol{\theta}) = p(x_1, x_2, \ldots, x_N; \boldsymbol{\theta}) = p(x_1; \boldsymbol{\theta}) \cdot p(x_2; \boldsymbol{\theta}) \cdot \ldots \cdot p(x_N; \boldsymbol{\theta})$$

$$= \prod_{n=1}^{N} p(x_n; \boldsymbol{\theta}).$$

- Für die Log-Likelihood Funktion ergibt sich durch Anwendung der Logarithmengesetze

$$l(\boldsymbol{\theta}) = \ln \prod_{n=1}^{N} p(x_n; \boldsymbol{\theta}) = \sum_{n=1}^{N} \ln p(x_n; \boldsymbol{\theta}).$$

Maximum-Likelihood Gleichung

- Falls die Likelihood Funktion differenzierbar ist, so erfüllt der Maximum-Likelihood Schätzer $\hat{\boldsymbol{\theta}}_{ML}$ notwendig die **Likelihood Gleichung**

$$\frac{\partial}{\partial \boldsymbol{\theta}} \ln p(\boldsymbol{x}; \boldsymbol{\theta}) \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}_{ML}} = \mathbf{0}.$$

- Diese sagt aus, dass $\hat{\boldsymbol{\theta}}_{ML}$ ein stationärer Punkt der (Log-)Likelihood Funktion sein muss.
- Es handelt sich dabei um ein System von M, im Allgemeinen nicht-linearen, Gleichungen der Form

$$\frac{\partial}{\partial \theta_j} \ln p(\boldsymbol{x}; \boldsymbol{\theta}) \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}_{ML}} = 0 \qquad j = 1, 2, \ldots, M.$$

- **Achtung:** Es muss noch überprüft werden, ob $\hat{\boldsymbol{\theta}}_{ML}$ tatsächlich ein Maximum darstellt.

Beispiel I: Binomialverteilung

1.13 Satz: Es sei die binomialverteilte Zufallsvariable x (beobachtete Anzahl der Erfolge) und der Stichprobenumfang N gegeben.

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für die unbekannte Erfolgswahrscheinlichkeit $\theta \in (0,\ 1)$ lautet $\hat{\theta}_{ML} = \frac{x}{N}$.

Beweis: Die Likelihood Funktion ist $L(\theta) = \binom{N}{x} \cdot \theta^x \cdot (1-\theta)^{N-x}$. Durch Anwendung des Logarithmus erhalten wir die Log-Likelihood Funktion

$$l(\theta) = \ln \binom{N}{x} + x \cdot \ln \theta + (N-x) \cdot \ln(1-\theta).$$

Diese leiten wir nach θ ab und setzen sie Null. Auflösen nach θ ergibt

$$\frac{\mathrm{d}}{\mathrm{d}\theta} l(\theta) = \frac{x}{\theta} + \frac{N-x}{1-\theta} \overset{!}{=} 0 \quad \Longleftrightarrow \quad \hat{\theta}_{ML} = \frac{x}{N}.$$

Zudem ist $\frac{\mathrm{d}^2}{\mathrm{d}\theta^2} l(\theta) = -\frac{x}{\theta^2} - \frac{N-x}{(1-\theta)^2} < 0 \ \forall \theta \in (0,\ 1)$, sodass $\hat{\theta}_{ML}$ tatsächlich ein Maximum ist. □

Beispiel II: Normalverteilung

1.14 Satz: Es seien

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_N)^\top$$

unabhängig und identisch normalverteilte Beobachtungen mit unbekanntem Erwartungswert $\mu \in \mathbb{R}$ und unbekannter Varianz $\sigma^2 > 0$. Der Parametervektor $\boldsymbol{\theta}$ ist in diesem Fall $\boldsymbol{\theta} := (\mu, \sigma^2)^\top$.

Die Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}^2_{ML}$ für die unbekannten Parameter μ und σ^2 sind gegeben durch

$$\hat{\mu}_{ML} = \frac{1}{N}\sum_{n=1}^{n} x_n \qquad \text{und} \qquad \hat{\sigma}^2_{ML} = \frac{1}{N}\sum_{n=1}^{N}(x_n - \hat{\mu}_{ML})^2.$$

Beweis: Die Dichte der Produktverteilung lautet aufgrund der Unabhängigkeit der Beobachtungen

$$p(\boldsymbol{x};\mu,\,\sigma^2) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x_n-\mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \frac{1}{\sigma^N} \cdot \exp\left(-\frac{\sum_{n=1}^{N}(x_i-\mu)^2}{2\sigma^2}\right).$$

Aufgrund der auftretenden Exponentialverteilung bietet sich die Betrachtung der Log-Likelihood Funktion an. Wir erhalten

$$l(\mu,\,\sigma^2) = -\frac{N}{2} \cdot \ln(2\pi) - N\ln(\sigma) - \frac{\sum_{n=1}^{N}(x_n-\mu)^2}{2\sigma^2}.$$

Nun berechnen wir die partiellen Ableitungen von l nach μ und σ^2. Es ist

$$\frac{\partial}{\partial\mu} l(\mu,\,\sigma^2) = \frac{1}{\sigma^2}\sum_{n=1}^{N}(x_n-\mu) \qquad \text{und} \qquad \frac{\partial}{\partial\sigma^2} l(\mu,\,\sigma^2) = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{n=1}^{N}(x_n-\mu).$$

Durch Nullsetzen und auflösen erhalten wir die im Satz angegebenen Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}^2_{ML}$. Es bleibt noch zu zeigen, dass es sich tatsächlich um ein Maximum handelt. Man rechnet nach, dass die Hesse-Matrix von $l(\mu,\,\sigma^2)$ and der Stelle $(\hat{\mu}_{ML},\,\hat{\sigma}^2_{ML})$ gegeben ist durch

$$\nabla^2 l(\mu,\,\sigma^2) = \begin{pmatrix} -\frac{N}{\hat{\sigma}^2_{ML}} & 0 \\ 0 & -\frac{N}{\left(\hat{\sigma}^2_{ML}\right)^2} \end{pmatrix}.$$

Diese Matrix ist negativ definit, weshalb wir tatsächlich ein Maximum gefunden haben. □

Erwartungstreue Schätzer

Wir definieren den Begriff der Erwartungstreue:

1.15 Definition: Wir nennen einen Schätzer $\hat{\boldsymbol{\theta}}$ **erwartungstreu**, falls $\mathbb{E}[\hat{\boldsymbol{\theta}}] = \boldsymbol{\theta}$ gilt.

- Der Schätzer $\hat{\mu}_{ML}$ ist erwartungstreu für den Erwartungswert μ im Normalverteilungsmodell

  Beweis: Es gilt

$$\mathbb{E}[\hat{\mu}_{ML}] = \mathbb{E}\left[\frac{1}{N}\sum_{n=1}^{N} x_n\right] = \frac{1}{N}\sum_{n=1}^{N}\mathbb{E}[x_n] = \frac{1}{N}\cdot N\cdot\mu = \mu.$$

□

- Demgegenüber ist $\hat{\sigma}^2_{ML}$ **nicht** erwartungstreu. Man kann diesen Schätzer jedoch durch eine geeignete Transformation zu einem erwartungstreuen Schätzer machen. Dies führt auf die **empirische Varianz** $\frac{n}{n-1}\hat{\sigma}^2_{ML} = \frac{1}{n-1}\sum_{n=1}^{N}(x_n - \hat{\mu}_{ML})^2$.

Aufgabe zur Maximum-Likelihood Schätzung

1.16 Aufgabe: Gegeben seien die N Beobachtungen $x_1, x_2, \ldots, x_N$, wobei $x_n \in \mathbb{N}$, $n = 1, 2, \ldots, N$. Sie legen den Daten eine Poisson-Verteilung zugrunde. Diese hat die Dichte

$$p(x) := e^{-\lambda} \cdot \frac{\lambda^x}{x!}.$$

1. Bestimmen Sie den Maximum-Likelihood Schätzer $\hat{\lambda}_{ML}$ für die Poisson-Verteilung. Vergessen Sie dabei nicht zu überprüfen, ob es sich tatsächlich um ein Maximum handelt.
2. Prüfen Sie den Schätzer auf Erwartungstreue.

Erwartete quadratische Abweichung (MSE)

Ein weiteres Qualitätsmerkmal eines Schätzers $\hat{\theta}$ ist seine erwartete quadratische Abweichung vom wahren Parameter θ.

1.17 Definition: Die **erwartete quadratische Abweichung** von $\hat{\theta}$ zu θ ist

$$\mathrm{MSE}[\hat{\theta}, \theta] = \mathbb{E}\left[(\hat{\theta} - \theta)^2\right].$$

Die $\mathrm{MSE}[\hat{\theta}, \theta]$ reduziert sich für erwartungstreue Schätzer $\hat{\theta}$ auf die Varianz $\mathbb{V}[\hat{\theta}]$.

Beweis: Man rechnet nach, dass $\mathrm{MSE}[\hat{\theta}, \theta] = \mathbb{V}[\hat{\theta}] + (\mathbb{E}[\hat{\theta}] - \theta)^2$ gilt (multipliziere hierzu aus und nutze die Linearität des Erwartungswerts). Der zweite Summand (Quadrat der Verzerrung/Bias) verschwindet aber für erwartungstreue Schätzer, da $\mathbb{E}[\hat{\theta}] = \theta$ gilt. Es folgt die Behauptung. □

Maximum-Aposteriori Schätzer (MAP)

- ML Schätzer laufen Gefahr, sich übermäßig stark an die Daten anzupassen (**Overfitting**).
- Wir erweitern daher das Konzept der ML Schätzung, indem wir zusätzlich eine *Apriori-Verteilung* für die zu schätzenden Parameter mit einbeziehen.
- Wir nutzen den Satz von Bayes, um damit zusammen mit der Likelihood eine *Aposteriori-Verteilung* über die Parameter zu erhalten.
- Ein Schätzer $\hat{\boldsymbol{\theta}}_{MAP}$ heißt **Maximum-Aposteriori Schätzer** für den Parameter $\boldsymbol{\theta}$, falls dieser die Aposteriori-Wahrscheinlichkeit maximiert.

Kapitel

2 Regression

Wiederholung: Lineare Regression

Lineare Regression

Wir wiederholen die wichtigsten Aussagen zur linearen Regression:

- Wir betrachten einen Datensatz bestehend aus N Featurevektoren $\boldsymbol{x}^n \in \mathbb{R}^m$, $n = 1, 2, \ldots, N$.
- Jeder Vektor $\boldsymbol{x}^n$ ist mit einem zugehörigen Label $y_n \in \mathbb{R}$, $n = 1, 2, \ldots, N$ versehen.
- Das lineare Regressionsmodell hat die Form

$$h(\boldsymbol{x}; \boldsymbol{\theta}) = \theta_0 + \sum_{m=1}^{M} \theta_m x_m.$$

- Im Folgenden bietet es sich an, die Dummy-Komponente $x_0 := 1$ einzuführen, sodass gilt

$$h(\boldsymbol{x}; \boldsymbol{\theta}) = \sum_{m=0}^{M} \theta_m x_m = \boldsymbol{\theta}^\top \boldsymbol{x}.$$

Design Matrix

Wir fassen die Featurevektoren $\boldsymbol{x}^n$ zeilenweise zu der Matrix

$$\boldsymbol{X} := \begin{pmatrix} — & \boldsymbol{x}^1 & — \\ — & \boldsymbol{x}^2 & — \\ \vdots & \vdots & \vdots \\ — & \boldsymbol{x}^N & — \end{pmatrix} \in \mathbb{R}^{N \times (M+1)}$$

zusammen. Die erste Spalte ist hierbei konstant 1 (wegen der Dummy-Komponente). Wir nennen diese Matrix **Design Matrix**.

Analog sammeln wir alle Labels in einem Vektor

$$\boldsymbol{y} := (y_1, y_2, \ldots, y_N)^\top \in \mathbb{R}^N.$$

Methode der kleinsten Quadrate

- Der Vektor $\boldsymbol{\theta} \in \mathbb{R}^{M+1}$ beinhaltet die Modellparameter.
- Diese möchten wir so wählen, dass unser Modell die Daten möglichst gut erklärt, d. h. die Abweichung der Regressionsfunktion zu den Trainingsdaten sollte möglichst klein sein.

2.1 Definition: Mit den obigen Definitionen ist der **Least-Squares-Fehler** gegeben durch

$$J_{\mathrm{LS}}(\boldsymbol{\theta}) := \frac{1}{2N} \|\boldsymbol{X}\boldsymbol{\theta} - \boldsymbol{y}\|^2.$$

Bemerkung: Der Vektor $\boldsymbol{X}\boldsymbol{\theta} \in \mathbb{R}^N$ beinhaltet die Modellvorhersagen, wenn man dem Modell die Parameter $\boldsymbol{\theta}$ zugrunde legt. J_{LS} misst also die mittlere quadratische Abweichung der Vorhersagen zu den wahren Werten.

Minimierung der Fehlerfunktion

Unser Ziel ist die Minimierung von J_{LS}. Hierzu schreiben J_{LS} unter Ausnutzung der Transpositionsregeln $(\boldsymbol{A}+\boldsymbol{B})^\top = \boldsymbol{A}^\top + \boldsymbol{B}^\top$ und $(\boldsymbol{AB})^\top = \boldsymbol{B}^\top\boldsymbol{A}^\top$ um:

$$
\begin{aligned}
J_{\text{LS}}(\boldsymbol{\theta}) &= \frac{1}{2N}\|\boldsymbol{X\theta}-\boldsymbol{y}\|^2 = \frac{1}{2N}(\boldsymbol{X\theta}-\boldsymbol{y})^\top(\boldsymbol{X\theta}-\boldsymbol{y}) \\
&= \frac{1}{2N}((\boldsymbol{X\theta})^\top - \boldsymbol{y}^\top)(\boldsymbol{X\theta}-\boldsymbol{y}) \\
&= \frac{1}{2N}((\boldsymbol{X\theta})^\top\boldsymbol{X\theta} - (\boldsymbol{X\theta})^\top\boldsymbol{y} - \boldsymbol{y}^\top(\boldsymbol{X\theta}) + \boldsymbol{y}^\top\boldsymbol{y}) \\
&= \frac{1}{2N}(\boldsymbol{\theta}^\top\boldsymbol{X}^\top\boldsymbol{X\theta} - 2(\boldsymbol{X\theta})^\top\boldsymbol{y} + \boldsymbol{y}^\top\boldsymbol{y}) \\
&= \frac{1}{2N}(\boldsymbol{\theta}^\top\boldsymbol{X}^\top\boldsymbol{X\theta} - 2\boldsymbol{\theta}^\top\boldsymbol{X}^\top\boldsymbol{y} + \boldsymbol{y}^\top\boldsymbol{y})
\end{aligned}
$$

Minimierung der Fehlerfunktion (Forts.)

Um einen stationären Punkt zu finden, müssen wir J_{LS} nach $\boldsymbol{\theta}$ ableiten und Null setzen.

- Es ist $\frac{\partial}{\partial \boldsymbol{\theta}} \boldsymbol{\theta}^\top \boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{\theta} = 2\boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{\theta}$, da $\boldsymbol{X}^\top \boldsymbol{X}$ symmetrisch ist.

  Beweis: Wir nutzen die Transpositionsregeln und erhalten $(\boldsymbol{X}^\top \boldsymbol{X})^\top = \boldsymbol{X}^\top (\boldsymbol{X}^\top)^\top = \boldsymbol{X}^\top \boldsymbol{X}$, woraus die Symmetrie folgt. □

- Es ist $\frac{\partial}{\partial \boldsymbol{\theta}}(-2\boldsymbol{\theta}^\top \boldsymbol{X}^\top \boldsymbol{y}) = -2\boldsymbol{X}^\top \boldsymbol{y}$ und $\frac{\partial}{\partial \boldsymbol{\theta}} \boldsymbol{y}^\top \boldsymbol{y} = \boldsymbol{0}$.
- Der Gradient der Fehlerfunktion J_{LS} ist damit gegeben durch

$$\begin{aligned}\frac{\partial}{\partial \boldsymbol{\theta}} J_{\text{LS}}(\boldsymbol{\theta}) &= \frac{1}{2N}(2\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\theta} - 2\boldsymbol{X}^\top \boldsymbol{y}) \propto \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\theta} - \boldsymbol{X}^\top \boldsymbol{y} \\ &= \boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{\theta} - \boldsymbol{y})\end{aligned}$$

Bemerkung: Man beachte den Zusammenhang zwischen dem Gradienten und dem Vorhersagefehler.

Minimierung der Fehlerfunktion (Forts.)

Wir setzen den Gradienten nun Null und lösen nach $\boldsymbol{\theta}$ auf:

$$\begin{aligned}
\frac{\partial}{\partial \boldsymbol{\theta}} J_{\mathsf{LS}}(\boldsymbol{\theta}) \stackrel{!}{=} \mathbf{0} \quad &\Longleftrightarrow \quad \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\theta} - \boldsymbol{X}^\top \boldsymbol{y} = \mathbf{0} \\
&\Longleftrightarrow \quad \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\theta} = \boldsymbol{X}^\top \boldsymbol{y} \\
&\Longleftrightarrow \quad \boldsymbol{\theta}^\star = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y}
\end{aligned}$$

Bemerkung: Wir haben damit einen stationären Punkt von J_{LS} gefunden. Allerdings wissen wir noch nicht, ob es sich tatsächlich um ein Minumum handelt. Außerdem sind wir hier etwas naiv von der Existenz der Inversen $(\boldsymbol{X}^\top \boldsymbol{X})^{-1}$ ausgegangen. Existiert diese Matrix immer?
Mit diesen Fragen beschäftigen wir uns im Folgenden.

Ein paar nützliche Aussagen

2.2 Satz: Für alle $\boldsymbol{A} \in \mathbb{R}^{N \times M}$ ist $\boldsymbol{A}^\top \boldsymbol{A}$ positiv semidefinit.

Beweis: Für alle $\boldsymbol{z} \in \mathbb{R}^M$ gitl $\boldsymbol{z}^\top(\boldsymbol{A}^\top \boldsymbol{A})\boldsymbol{z} = (\boldsymbol{A}\boldsymbol{z})^\top(\boldsymbol{A}\boldsymbol{z}) = \|\boldsymbol{A}\boldsymbol{z}\|^2 \geq 0$, die Behauptung. □

2.3 Satz: Für alle $\boldsymbol{A} \in \mathbb{R}^{N \times M}$ mit *vollem Spaltenrang* ist $\boldsymbol{A}^\top \boldsymbol{A}$ positiv definit.

Beweis: Da $\boldsymbol{A}$ vollen Spaltenrang hat, sind die Spaltenvektoren linear unabhängig. Daher ist $\boldsymbol{A}\boldsymbol{z}$ für alle $\boldsymbol{z} \in \mathbb{R}^M \setminus \{\boldsymbol{0}\}$ eine nicht-triviale Linearkombination der Spalten von $\boldsymbol{A}$. Folglich gilt $\boldsymbol{A}\boldsymbol{z} \neq \boldsymbol{0}$ und wir erhalten $\boldsymbol{z}^\top(\boldsymbol{A}^\top \boldsymbol{A})\boldsymbol{z} = (\boldsymbol{A}\boldsymbol{z})^\top(\boldsymbol{A}\boldsymbol{z}) = \|\boldsymbol{A}\boldsymbol{z}\|^2 > 0$. □

Ein paar nützliche Aussagen (Forts.)

2.4 Satz: Wenn $\boldsymbol{A}$ positiv definit ist, so ist $\boldsymbol{A}$ auch invertierbar.

Beweis: Wir nehmen an $\boldsymbol{A}$ sei nicht invertierbar. Dann sind die Spalten von $\boldsymbol{A}$ linear abhängig und es existiert ein $\boldsymbol{z} \in \mathbb{R}^M \setminus \{\boldsymbol{0}\}$ mit $\boldsymbol{A}\boldsymbol{z} = \boldsymbol{0}$. Daraus folgt aber

$$\boldsymbol{z}^\top \boldsymbol{A}\boldsymbol{z} = \boldsymbol{z}^\top \boldsymbol{0} = 0,$$

was der Definitheitseigenschaft von $\boldsymbol{A}$ widerspricht. □

Handelt es sich nun um ein Minimum?

Um diese Frage zu klären, berechnen wir die Hesse-Matrix von J_{LS} und untersuchen, ob die Matrix im stationären Punkt positiv definit ist.

- Man rechnet nach, dass die Hesse-Matrix gegeben ist durch

$$\frac{\partial^2}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}} J_{\mathrm{LS}}(\boldsymbol{\theta}) = \boldsymbol{X}^\top \boldsymbol{X}.$$

- Mit Satz 2.3 ist diese Matrix positiv definit für alle $\boldsymbol{\theta}$, falls $\boldsymbol{X}$ vollen Spaltenrang hat, d. h. die Features müssen linear unabhängig sein. In diesem Fall handelt es sich bei $\boldsymbol{\theta}^\star$ also tatsächlich um ein Minimum.
- Unter derselben Voraussetzung haben wir damit sogar die **Konvexität** von J_{LS} bewiesen, sodass das Mimimun global und eindeutig ist.

Und wie sieht es nun mit der Existenz der Inversen aus?

- Mit Satz 2.4 ist die Existenz der Inversen sichergestellt, wenn $\boldsymbol{X}^\top \boldsymbol{X}$ positiv definit ist, was wiederum aus der linearen Unabhängigkeit der Features folgt (Satz 2.3).
- **Achtung:** Bei der numerischen Berechnung der Inversen auf dem Computer kann es jedoch trotzdem zu Problemen kommen. Es ist ratsam, die Inverse nicht explizit zu berechnen, sondern stattdessen das lineare Gleichungssystem $\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\theta} = \boldsymbol{X}^\top \boldsymbol{y}$ nach $\boldsymbol{\theta}$ zu lösen. Dieses Vorgehen ist numerisch stabiler.
- Alternativ kann das Optimierungsproblem mit dem **Gradientenabstiegsverfahren** gelöst werden. Iteriere hierzu die Regel:

$$\boldsymbol{\theta}^{(t+1)} \longleftarrow \boldsymbol{\theta}^{(t)} - \alpha \boldsymbol{X}^\top (\boldsymbol{X}\boldsymbol{\theta} - \boldsymbol{y}). \tag{1}$$

Normalengleichungen

Wir fassen unsere Ergebnisse zusammen:

2.5 Satz: Die Design Matrix $\boldsymbol{X} \in \mathbb{R}^{N \times (M+1)}$ des Regressionsproblems habe vollen Spaltenrang, d. h. die Features sind linear unabhängig. Dann existiert die Inverse $(\boldsymbol{X}^\top \boldsymbol{X})^{-1}$ und

$$\boldsymbol{\theta}^\star = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y}$$

ist das eindeutige globale Minimum von J_{LS}. Die Gleichungen $\boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{\theta} = \boldsymbol{X}^\top \boldsymbol{y}$ bezeichnet man als **Normalengleichungen**.

Kapitel

3 **Expectation-Maximization (EM) Algorithmus**

Problemstellung

Ungleichung von Jensen

Bestimmung der unteren Schranke

Formulierung des EM-Algorithmus

Problemstellung

- Wir betrachten ein statistisches Modell mit Daten $\boldsymbol{X} = (\boldsymbol{x}^1, \boldsymbol{x}^2, \ldots, \boldsymbol{x}^N)^\top$, **latenten Variablen** $\boldsymbol{Z} = (z^1, z^2, \ldots, z^N)^\top$ und Modellparametern $\boldsymbol{\theta}$.
- Unser Ziel ist die Maximierung der Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$.
- Da wir die latenten Variablen nicht beobachten, könnten wir über sie summieren:

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \tag{2}$$

- In der Regel ist eine direkte Lösung hiervon jedoch zu kompliziert.
- Ein Lösungsansatz ist der **Expectation-Maximization (EM) Algorithmus**, welcher das Problem iterativ in zwei Phasen löst.
- Mit $\{\boldsymbol{X}, \boldsymbol{Z}\}$ bezeichnen wir den *vollständigen* Datensatz, $\boldsymbol{X}$ alleine nennen wir *unvollständig*.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

3.1 Satz: Es sei X eine Zufallsvariable mit endlichem ersten Moment (daraus folgt die Existenz des Erwartungswerts) und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen**

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für konkave Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Bestimmung der unteren Schranke

- Entscheidend ist, dass die Optimierung von $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ oftmals einfacher ist als die von $p(\boldsymbol{X}; \boldsymbol{\theta})$.
- Wir konstruieren daher mittels $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ eine untere Schranke $\mathcal{L}$ für $p(\boldsymbol{X}; \boldsymbol{\theta})$:

$$\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}) &= \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} \\
&= \ln \mathbb{E}_{\boldsymbol{Z} \sim q(\boldsymbol{Z})} \left[\frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} \right] \\
&\geq \mathbb{E}_{\boldsymbol{Z} \sim q(\boldsymbol{Z})} \left[\ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} \right] =: \mathcal{L}(q, \boldsymbol{\theta})
\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Jensensche Ungleichung**, Satz 3.1, mit $f := \ln$ (der Logarithmus ist strikt konkav) und $X := \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen umschreiben zu

$$\ln p(\boldsymbol{X};\boldsymbol{\theta}) \geq \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln p(\boldsymbol{X},\,\boldsymbol{Z};\boldsymbol{\theta})\right]}_{\text{Erw. vollst. Log-Likelihood}} - \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln q(\boldsymbol{Z})\right]}_{\text{Entropie von } q}. \tag{3}$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müsssen.
- Wir möchten q so wählen, dass $\mathcal{L}(q,\,\boldsymbol{\theta}) \stackrel{!}{=} \ln p(\boldsymbol{X};\boldsymbol{\theta})$ für das aktuelle $\boldsymbol{\theta}$ gilt.
- Die Ungleichung von Jensen (Satz 3.1) gilt mit Gleichheit, falls

$$\frac{p(\boldsymbol{X},\,\boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} = \text{const.}$$

- Wir müssen also $q(\boldsymbol{Z}) \propto p(\boldsymbol{X},\,\boldsymbol{Z};\boldsymbol{\theta})$ wählen!

Bestimmung der unteren Schranke (Forts.)

- Daraus erhalten wir

$$q(\boldsymbol{Z}) = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\boldsymbol{Z}}} p(\boldsymbol{X}, \tilde{\boldsymbol{Z}}; \boldsymbol{\theta})} = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{p(\boldsymbol{X}; \boldsymbol{\theta})}$$

$$= p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}).$$

- Dies setzen wir in (3) ein und erhalten die Identität

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \right].$$

Formulierung des EM-Algorithmus

- Zu jedem Zeitpunkt t haben wir eine Schätzung der Parameter $\boldsymbol{\theta}^t$, die der Algorithmus in der darauffolgenden Iteration verbessert.
- Für die Formulierung des Algorithmus führen wir einen Zeitindex ein

$$\begin{aligned}\ln p(\boldsymbol{X};\boldsymbol{\theta}) &= \mathbb{E}_{\boldsymbol{Z}\sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta}^t)}\left[\ln p(\boldsymbol{X},\boldsymbol{Z};\boldsymbol{\theta})\right] - \mathbb{E}_{\boldsymbol{Z}\sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta}^t)}\left[\ln p(\boldsymbol{Z}\mid\boldsymbol{X};\boldsymbol{\theta})\right]\\ &= Q(\boldsymbol{\theta};\boldsymbol{\theta}^t) + H(\boldsymbol{\theta};\boldsymbol{\theta}^t),\end{aligned}$$

  wobei $Q(\cdot)$ der erste Erwartungswert und $H(\cdot)$ der negierte zweite Erwartungswert ist.
- Den Ausdruck $H(\boldsymbol{\theta};\boldsymbol{\theta}^t)$ nennt man **Cross-Entropy** zwischen $\boldsymbol{\theta}$ und $\boldsymbol{\theta}^t$.

Formulierung des EM-Algorithmus (Forts.)

- Aufgrund der **Ungleichung von Gibbs** gilt

$$H(\boldsymbol{\theta}; \boldsymbol{\theta}^t) \geq H(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t). \tag{4}$$

- Daraus folgt

$$\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln p(\boldsymbol{X}; \boldsymbol{\theta}^t) &= Q(\boldsymbol{\theta}; \boldsymbol{\theta}^t) - Q(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t) + H(\boldsymbol{\theta}; \boldsymbol{\theta}^t) - H(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t) \\
&\overset{(4)}{\geq} Q(\boldsymbol{\theta}; \boldsymbol{\theta}^t) - Q(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t) + H(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t) - H(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t) \\
&= Q(\boldsymbol{\theta}; \boldsymbol{\theta}^t) - Q(\boldsymbol{\theta}^t; \boldsymbol{\theta}^t).
\end{aligned}$$

- Diese Ungleichung zeigt: Wenn wir $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^t)$ um einen Betrag δ verbessern, dann verbessern wir damit auch $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ *um mindestens denselben Betrag*.

Der EM-Algorithmus

Wir erhalten damit den folgenden iterativen Algorithmus:

1. Setze $t := 0$ und initialisiere den Parametervektor $\boldsymbol{\theta}^t$.
2. **E-Schritt (Expectation):**
$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^t) := \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta}^t)} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right]$$
3. **M-Schritt (Maximization):**
$$\boldsymbol{\theta}^{t+1} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}; \boldsymbol{\theta}^t)$$
4. Setze $t := t + 1$
5. Wenn der Algorithmus noch nicht konvergiert ist, gehe zu Schritt 2.

Der EM-Algorithmus (Forts.)

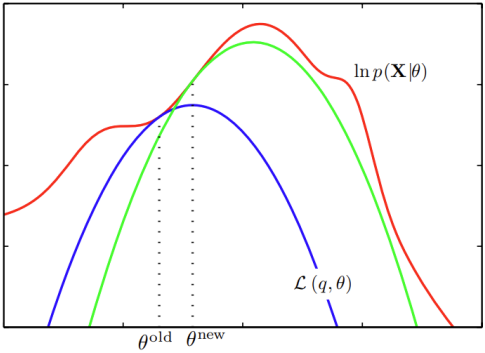

Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [1], Seite 453.

Kapitel

4 **Independent Component Analysis**

Motivation: Cocktail Party Problem

Formalisierung des Problems

Annahmen und Limitationen von ICA

Whitening

ICA durch Maximum Likelihood Schätzung

Cocktail Party Problem

Zur Motivation betrachten wir das folgende Problem:

- Auf einer Party sprechen N Personen gleichzeitig.
- Im Raum werden Mikrofone aufgestellt, welche *überlappende Kombinationen* der Stimmen der Sprecher aufzeichnen.
- Der Einfachheit halber nehmen wir an, dass sich ebenfalls N Mikrofone im Raum befinden.
- Da die Entfernung der Sprecher zu den einzelnen Mikrofonen verschieden ist, handelt es sich hierbei um leicht *verschiedene Kombinationen*.

Können wir die Stimmen der N Sprecher aus den N Aufzeichnungen isolieren?

Beispiel: Cocktail Party Problem

tbd

Mathematische Formulierung des Problems

- Es seien die Signale $\boldsymbol{s}(t) \in \mathbb{R}^N$ gegeben, welche von N *unabhängigen* (!) Quellen zum Zeitpunkt $t = 1, 2, \ldots, T$ erzeugt werden (die Sprecher im Cocktail Party Problem).
- Allerdings beobachten wir nur die gemischten Daten $\boldsymbol{x}(t)$ zum Zeitpunkt t (die Aufnahmen der Mikrofone).
- Das ICA-Modell nimmt an, dass es sich hierbei um *Linearkombinationen* der Quellsignale handelt.
- Wir betrachten also das Modell

$$\boldsymbol{x}(t) = \boldsymbol{A}\boldsymbol{s}(t), \tag{5}$$

wobei $\boldsymbol{A}$ die **Mixing Matrix** ist.

Mathematische Formulierung des Problems (Forts.)

- Unser Ziel ist es, die Quellsignale $\boldsymbol{s}$ aus den beobachteten Mischsignalen $\boldsymbol{x}$ zu rekonstruieren.
- Wäre $\boldsymbol{A}$ bekannt, so könnten wir in den meisten Fällen

$$\boldsymbol{s} = \boldsymbol{A}^{-1}\boldsymbol{x}$$

  berechnen und wären fertig.
- In der Regel ist $\boldsymbol{A}$ unbekannt, wodurch das Problem deutlich schwerer wird.
- Wir definieren die **Unmixing Matrix** $\boldsymbol{W} := \boldsymbol{A}^{-1}$.
- Mithilfe des ICA-Verfahrens werden wir diese Matrix approximieren. Mit ihr können wir dann die Quellsignale bestimmen, indem wir $\boldsymbol{s} = \boldsymbol{W}\boldsymbol{x}$ berechnen.

Annahmen des Verfahrens

Die folgenden Annahmen sind wesentlich für das ICA-Verfahren:

1. **Zentrale Annahme:** Die Quellsignale (ICs: Independent Components) sind *stochastisch unabhängig*.
2. Die ICs sind *nicht normalverteilt* (dazu später mehr).
3. Die Mixing Matrix A ist quadratisch. Es gibt allerdings Verallgemeinerungen der ICA, die auch rechteckige Matrizen erlauben. Wir machen diese Annahme hier, da das Problem selbst in diesem vereinfachten Fall schon schwer genug ist.

Limitationen des Verfahrens

Es gibt eine Reihe von Einschränkungen bei der Rekonstruktion der Quellsignale:

1. Die ursprüngliche *Reihenfolge* der Signale kann nicht rekonstruiert werden. Sei dazu $\boldsymbol{P}$ eine *Permutationsmatrix*. Dann ist $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s} = \boldsymbol{A}\boldsymbol{P}^{-1}\boldsymbol{P}\boldsymbol{s}$, wobei $\boldsymbol{P}\boldsymbol{s}$ die permutierten Quellsignale sind. $\boldsymbol{A}\boldsymbol{P}^{-1}$ ist lediglich eine neue zu schätzende Mixing Matrix. Wir können folglich kein Signal *das erste* Quellsignal nennen.
2. Die *Skalierung* der Quellsignale kann nicht wiederhergestellt werden (im Cocktail Party Problem entspricht dies der Lautstärke/Amplitude der Signale), wie man sich leicht überlegt:
   Sei dazu $\alpha \in \mathbb{R}$, dann gilt
   $$\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s} = \alpha\boldsymbol{A} \cdot \frac{1}{\alpha}\boldsymbol{s}.$$
3. Normalverteilte Signale können nicht aufgetrennt werden.

Warum sind Normalverteilungen verboten?

- Wir betrachten ein Beispiel mit $N = 2$ und $\boldsymbol{s} \sim N_{\boldsymbol{0}, \boldsymbol{I}}$.
- Die Konturlinien der Standardnormalverteilung sind perfekte Kreise, die auf dem Koordinatenursprung zentriert sind.
- Insbesondere ist die Dichte **rotationsinvariant**.
- Für $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s}$ gilt damit: $\boldsymbol{x} \sim N_{\boldsymbol{0}, \boldsymbol{A}\boldsymbol{A}^\top}$.

Beweis: Mit der Linearität des Erwartungswerts gilt $\mathbb{E}_{\boldsymbol{s}}[\boldsymbol{x}] = \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{A}\boldsymbol{s}] = \boldsymbol{A}\mathbb{E}_{\boldsymbol{s}}[s] = \boldsymbol{0}$. Die Streuungsmatrix ist

$$\begin{aligned}\mathbb{D}[\boldsymbol{x}] &= \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{x}\boldsymbol{x}^\top] = \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{A}\boldsymbol{s}\boldsymbol{s}^\top\boldsymbol{A}^\top] = \boldsymbol{A}\mathbb{E}[\boldsymbol{s}\boldsymbol{s}^\top]\boldsymbol{A}^\top = \boldsymbol{A} \cdot \mathbb{D}[\boldsymbol{s}] \cdot \boldsymbol{A}^\top \\ &= \boldsymbol{A}\boldsymbol{A}^\top.\end{aligned}$$

Also gilt die Behauptung. □

Warum sind Normalverteilungen verboten? (Forts.)

- Sei nun $\boldsymbol{R} \in \mathbb{R}^{N \times N}$ eine beliebige *orthogonale Matrix*.

  Eigenschaften orthogonaler Matrizen:

  - Orthogonale Matrizen beschreiben eine Drehung/Spiegelung im Raum.
  - Es gilt stets $\boldsymbol{R}\boldsymbol{R}^\top = \boldsymbol{R}^\top\boldsymbol{R} = \boldsymbol{I}$. Es ist also $\boldsymbol{R}^{-1} = \boldsymbol{R}^\top$.
  - Es ist $\det \boldsymbol{R} = 1$ für alle orthogonalen Matrizen $\boldsymbol{R}$.
  - Da $\boldsymbol{R}$ nur eine Drehung beschreibt, gilt für alle $\boldsymbol{x} \in \mathbb{R}^N$ die Identität $\|\boldsymbol{R}\boldsymbol{x}\| = \|\boldsymbol{x}\|$.
- Sei ferner $\tilde{\boldsymbol{A}} := \boldsymbol{A}\boldsymbol{R}$ die Matrix, welche mit der von $\boldsymbol{R}$ beschriebenen Drehung aus $\boldsymbol{A}$ hervorgeht.
- Dann hat der Vektor $\tilde{\boldsymbol{x}} = \tilde{\boldsymbol{A}}\boldsymbol{s}$ dieselbe Verteilung wie $\boldsymbol{x}$.

Beweis: Den Erwartungswert rechnet man analog zu oben aus. Aufgrund der Orthogonalität von $\boldsymbol{R}$ gilt

$$\mathbb{E}_{\boldsymbol{s}}[\tilde{\boldsymbol{x}}\tilde{\boldsymbol{x}}^\top] = \mathbb{E}_{\boldsymbol{s}}[\tilde{\boldsymbol{A}}\boldsymbol{s}\boldsymbol{s}^\top\tilde{\boldsymbol{A}}^\top] = \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{A}\boldsymbol{R}\boldsymbol{s}\boldsymbol{s}^\top\boldsymbol{R}^\top\boldsymbol{A}^\top] = \boldsymbol{A}\boldsymbol{R} \cdot \mathbb{D}[\boldsymbol{s}] \cdot \boldsymbol{R}^\top\boldsymbol{A}^\top = \boldsymbol{A}\boldsymbol{R}\boldsymbol{R}^\top\boldsymbol{A} = \boldsymbol{A}\boldsymbol{A}^\top,$$

sodass $\tilde{\boldsymbol{x}} \sim N_{\boldsymbol{0}, \boldsymbol{A}\boldsymbol{A}^\top}$ wie behauptet gilt. □

Warum sind Normalverteilungen verboten? (Forts.)

- Die voranstehenden Ausführungen zeigen, können wir in diesem Fall nicht rekonstruieren, ob die Daten mit der Matrix $\boldsymbol{A}$ oder $\tilde{\boldsymbol{A}}$ gemixt wurden.
- Für normalverteilte Daten können wir folglich die Komponenten *nur bis auf eine Drehung rekonstruieren*.

Ein einfaches Beispiel

Wir betrachten ein einfaches zweidimensionales Beispiel für den Fall, dass die Quellsignale s_1 und s_2 gleichverteilt sind:

$$p(s_i) := \begin{cases} \frac{1}{2\sqrt{3}} & \text{wenn } |s_i| \leq \sqrt{3} \\ 0 & \text{sonst} \end{cases}$$

Bemerkungen:

- Der Erwartungswert der Zufallsvariablen s_i $(i = 1, 2)$ ist jeweils 0.

  Beweis: Für die Gleichverteilung gilt $\mathbb{E}[s_i] = \frac{-\sqrt{3}+\sqrt{3}}{2} = 0$ (siehe Tabelle im Kapitel 'Statistik'). □

- Die Varianzen sind jeweils 1.

  Beweis: Es ist $\mathbb{V}[s_i] = \frac{(\sqrt{3}+\sqrt{3})^2}{12} = \frac{(2\sqrt{3})^2}{12} = \frac{12}{12} = 1$ (siehe Tabelle im Kapitel 'Statistik'). □

Ein einfaches Beispiel (Forts.)

Ausgangsdaten

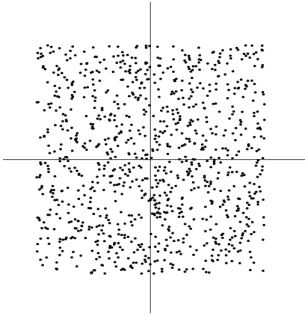

Abbildung: Gemeinsame Verteilung der unabhängigen Komponenten s_1 (horizontal) und s_2 (vertikal). Siehe [2], Seite 155.

Ein einfaches Beispiel (Forts.)

Gemischte Daten

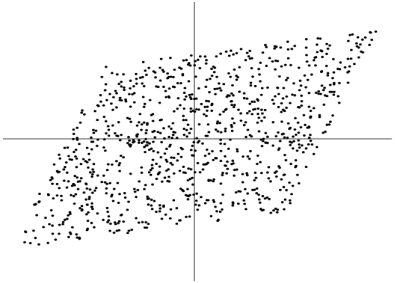

Abbildung: Gemeinsame Verteilung der gemischten/beobachteten Komponenten x_1 (horizontal) und x_2 (vertikal) nach Anwendung der Matrix $\boldsymbol{A} := \begin{pmatrix} 5 & 10 \\ 10 & 2 \end{pmatrix}$.

Whitening

Whitening wird häufig vor dem eigentlichen ICA-Algorithmus angewendet:

4.1 Definition: **Whitening** bezeichnet eine *lineare Transformation* $\boldsymbol{V}$, bei der zentrierte Zufallsvariablen $\boldsymbol{x} \in \mathbb{R}^N$ (zentriert bedeutet $\mathbb{E}[\boldsymbol{x}] = \boldsymbol{0}$) so zu neuen Zufallsvariablen $\boldsymbol{z} := \boldsymbol{V}\boldsymbol{x} \in \mathbb{R}^N$ transformiert werden, dass $\mathbb{D}[\boldsymbol{z}] = \mathbb{E}[\boldsymbol{z}\boldsymbol{z}^\top] = \boldsymbol{I}$ gilt.

In Worten bedeutet dies, dass die Komponenten von $\boldsymbol{z}$ untereinander unkorreliert und die Varianzen jeweils Eins sind, also

$$\mathbb{E}[z_i z_j] = \delta_{ij},$$

wobei $\delta_{ij} := \begin{cases} 1 & \text{falls } i = j \\ 0 & \text{falls } i \neq j \end{cases}$ das **Kronecker-Delta** bezeichnet.

Whitening (Forts.)

- Eine solche lineare Transformation ist z. B. gegeben durch $\boldsymbol{V} := \boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{E}^\top$, wobei $\boldsymbol{E} \in \mathbb{R}^{N\times N}$ eine orthogonale Matrix ist, deren Spalten aus *normalisierten Eigenvektoren* von $\mathbb{D}[\boldsymbol{x}]$ bestehen und $\boldsymbol{D} := \operatorname{diag}(d_1, d_2, \ldots, d_N) \in \mathbb{R}^{N\times N}$ eine Diagonalmatrix mit den zugehörigen *Eigenwerten* ist.

  Beweis: Wir rechnen nach, dass die Kovarianzmatrix von $\boldsymbol{z} = \boldsymbol{V}\boldsymbol{x}$ tatsächlich die Einheitsmatrix ist. Da $\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top]$ in praktischen Anwendungsfällen in der Regel positiv definit ist, gilt $\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top] = \boldsymbol{E}\boldsymbol{D}\boldsymbol{E}^\top$. Damit gilt tatsächlich

$$\mathbb{E}[\boldsymbol{z}\boldsymbol{z}^\top] = \mathbb{E}[\boldsymbol{V}\boldsymbol{x}\boldsymbol{x}^\top\boldsymbol{V}^\top] = \boldsymbol{V}\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top]\boldsymbol{V}^\top = \boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{E}^\top\boldsymbol{E}\boldsymbol{D}\boldsymbol{E}^\top\boldsymbol{E}\boldsymbol{D}^{-\frac{1}{2}} = \boldsymbol{I}.$$

□

- Aus der Zentriertheit von $\boldsymbol{x}$ folgt, dass auch $\boldsymbol{z}$ zentriert ist.

  Beweis: Wieder mit der Linearität des Erwartungswerts gilt $\mathbb{E}[\boldsymbol{z}] = \mathbb{E}[\boldsymbol{V}\boldsymbol{x}] = \boldsymbol{V}\mathbb{E}[\boldsymbol{x}] = \boldsymbol{0}$. □

Fortsetzung des Beispiels

Nach Anwendung von Whitening

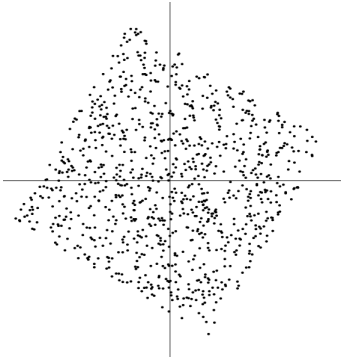

Abbildung: Gemeinsame Verteilung der Komponenten z_1 (horizontal) und z_2 (vertikal) nach dem Whitening.

Whitening löst bereits das halbe Problem

- Wir nehmen im Folgenden an, dass bereits ein Whitening stattgefunden hat.
- Whitening transformiert die Mixing Matrix $\boldsymbol{A}$ in eine neue Matrix $\tilde{\boldsymbol{A}}$, denn

$$\boldsymbol{z} = \boldsymbol{V}\boldsymbol{x} = \boldsymbol{V}\boldsymbol{A}\boldsymbol{s} = \tilde{\boldsymbol{A}}\boldsymbol{s}.$$

- Man könnte nun hoffen, dass Whitening das Problem bereits löst, da Unkorreliertheit und Unabhängigkeit verwandt sind. **Dem ist jedoch nicht so!**
- Sei dazu $\boldsymbol{U}$ eine orthogonale Matrix und $\boldsymbol{y} := \boldsymbol{U}\boldsymbol{z}$.
- Aufgrund der Orthogonalität von $\boldsymbol{U}$ gilt

$$\mathbb{E}[\boldsymbol{y}\boldsymbol{y}^\top] = \mathbb{E}[\boldsymbol{U}\boldsymbol{y}\boldsymbol{y}^\top\boldsymbol{U}^\top] = \boldsymbol{U}\boldsymbol{I}\boldsymbol{U}^\top = \boldsymbol{I}.$$

Somit ist auch $\boldsymbol{y}$ white. Die Komponenten sind durch Whitening nur bis auf eine Drehung eindeutig!

Whitening als Vorverarbeitungsschritt

- Die Whitening Operation eignet sich jedoch sehr gut als Vorverarbeitungsschritt, denn durch sie wird die Mixing Matrix $\tilde{\boldsymbol{A}} = \boldsymbol{V}\boldsymbol{A}$ orthogonal.

  Beweis: Da die Daten z white sind, gilt $\mathbb{E}[zz^\top] = \boldsymbol{I}$. Es gilt aber auch

  $$\mathbb{E}[zz^\top] = \mathbb{E}[\tilde{\boldsymbol{A}}ss^\top\tilde{\boldsymbol{A}}^\top] = \tilde{\boldsymbol{A}}\tilde{\boldsymbol{A}}^\top.$$

  Also gilt $\tilde{\boldsymbol{A}}\tilde{\boldsymbol{A}}^\top = \boldsymbol{I}$, woraus die Orthogonalität von $\tilde{\boldsymbol{A}}$ folgt. □

- Das heißt wir können uns bei der Suche nach der Mixing Matrix **auf orthogonale Matrizen beschränken!**
- Eine orthogonale $N \times N$ Matrix hat nur $N(N-1)/2$ Freiheitsgrade (im Gegensatz zu N^2 Freiheitsgraden für die ursprüngliche Matrix), z. B. wird eine zweidimensionale orthogonale Matrix eindeutig durch den Winkel der Drehung beschrieben.

Warum Normalverteilungen verboten sind!

- Durch Whitening können wir eine weitere Begründung dafür angeben, warum Normalverteilungen verboten sind.
- Wir nehmen an, dass die gemeinsame Verteilung der Quellsignale s_1 und s_2 durch eine Normalverteilung beschrieben werden:

$$p(s_1, s_2) = \frac{1}{2\pi} \exp\left(-\frac{s_1^2 + s_2^2}{2}\right) = \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{s}\|^2}{2}\right)$$

- Die Mixing Matrix $\boldsymbol{A}$ kann als orthogonal angenommen werden, da die Daten $\boldsymbol{x}$ als white vorausgesetzt sind.

Warum Normalverteilungen verboten sind! (Forts.)

Mit dem Transformationssatz 1.6 für Dichten erhalten wir daraus die Verteilung von x_1 und x_2:

$$p(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{A}^{-1}\boldsymbol{x}\|^2}{2}\right) |\det \boldsymbol{A}^{-1}|$$

[Aufgrund der Orthogonalität gilt $\boldsymbol{A}^{-1} = \boldsymbol{A}^\top$.]

$$= \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{A}^\top\boldsymbol{x}\|^2}{2}\right) |\det \boldsymbol{A}^\top|$$

[Wieder aufgrund der Orthogonalität gilt $\|\boldsymbol{A}^\top\boldsymbol{x}\| = \|\boldsymbol{x}\|$ und $\det \boldsymbol{A}^\top = 1$.]

$$= \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{x}\|^2}{2}\right)$$

Warum Normalverteilungen verboten sind! (Forts.)

- Wir sehen also, dass die Dichte der Quellsignale und der gemischten Signale identisch ist.
- Damit haben wir keine Chance, die Mixing Matrix aus den Daten zu schätzen.

Warum Normalverteilungen verboten sind! (Forts.)

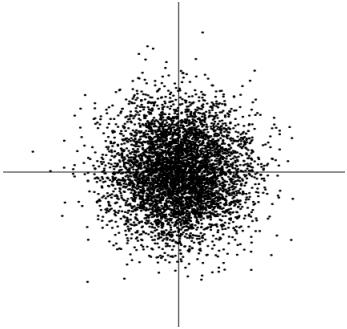

Abbildung: Gemeinsame Verteilung der Komponenten s_1 (horizontal) und s_2 (vertikal) bei Annahme einer Normalverteilung.

ICA Lösungsverfahren

Es gibt verschiedene Ansätze mit denen man die unabhängigen Komponenten bestimmen kann:

1. Maximierung der Likelihood Funktion.
2. Maximierung der *Non-Gaussianity*: Finde die unabhängigen Komponenten so, dass deren Verteilung maximal nicht-normal ist.
   - Basiert auf dem **zentralen Grenzwertsatz**: Eine Summe unabhängiger Zufallsvariablen ist (unter gewissen Voraussetzungen) zunehmend normalverteilt.
   - Hierzu muss man eine Maßzahl finden, welche die Nicht-Normalität einer Verteilung misst.
   - Beispiele: **Kurtosis**, **Negentropy**
3. Minimierung der Mutual Information.

Likelihood Funktion für die ICA

Wir leiten im Folgenden die Likelihood Funktion für die ICA her:

- Da die Komponenten s_n *stochastisch unabhängig* sind, finden wir deren gemeinsame Dichte als *Produktdichte* der Komponenten
$$p_{\boldsymbol{s}}(\boldsymbol{s}) = \prod_{n=1}^{N} p_n(s_n).$$
- Wir müssen dies allerdings mittels der beobachteten Daten $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s}$ ausdrücken, da $\boldsymbol{s}$ *latent* ist. Hierzu benutzen wir den Transformationssatz 1.6 und erhalten mit $\boldsymbol{s} = \boldsymbol{A}^{-1}\boldsymbol{x} = \boldsymbol{W}\boldsymbol{x}$ und $\boldsymbol{W} = (\boldsymbol{w}^1, \ldots, \boldsymbol{w}^N)^\top$ die Dichte von $\boldsymbol{x}$ als
$$p_{\boldsymbol{x}}(\boldsymbol{x}) = |\det \boldsymbol{W}| \cdot \prod_{n=1}^{N} p_n((\boldsymbol{w}^n)^\top \boldsymbol{x}). \tag{6}$$

Likelihood Funktion für die ICA (Forts.)

- Wir nehmen nun an, dass wir T Beobachtungen $\boldsymbol{x}(1), \boldsymbol{x}(2), \ldots, \boldsymbol{x}(T)$ von $\boldsymbol{x}$ haben.
- Die Likelihood Funktion ergibt sich als das Produkt der Dichte in (6) über die T Beobachtungen

$$L(\boldsymbol{W}) = \prod_{t=1}^{T} \left(|\det \boldsymbol{W}| \cdot \prod_{n=1}^{N} p_n((\boldsymbol{w}^n)^\top \boldsymbol{x}(t)) \right) = |\det \boldsymbol{W}|^T \cdot \prod_{t=1}^{T} \prod_{n=1}^{N} p_n((\boldsymbol{w}^n)^\top \boldsymbol{x}(t)).$$

- Im Folgenden betrachten wir die Log-Likelihood Funktion

$$l(\boldsymbol{W}) = \ln \left(|\det \boldsymbol{W}|^T \cdot \prod_{t=1}^{T} \prod_{n=1}^{N} p_n((\boldsymbol{w}^n)^\top \boldsymbol{x}(t)) \right) = \ln |\det \boldsymbol{W}|^T + \ln \left(\prod_{t=1}^{T} \prod_{n=1}^{N} p_n((\boldsymbol{w}^n)^\top \boldsymbol{x}(t)) \right)$$

$$= T \cdot \ln |\det \boldsymbol{W}| + \sum_{t=1}^{T} \sum_{n=1}^{N} \ln p_n((\boldsymbol{w}^n)^\top \boldsymbol{x}(t)).$$

Literatur

[1] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf.

[2] Aapo Hyvärinen. *Independent Component Analysis*. 2001. URL: https://www.cs.helsinki.fi/u/ahyvarin/papers/bookfinal_ICA.pdf.