

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

Inhaltsverzeichnis

- 1 Gaussian Mixture Models (GMMs)
- 2 Expectation-Maximization (EM) Algorithmus
- 3 Principal Component Analysis (PCA)

Kapitel

① Gaussian Mixture Models (GMMs)

Problemstellung

Gaussian Mixture Models und latente Variablen

Maximum-Likelihood Lösung

Expectation-Maximization (EM) Algorithmus für GMMs

Problemstellung

- Wir wissen bereits, wie wir die Parameter μ und Σ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**
 - Gegeben sei ein Datensatz X bestehend aus N unabhängig und identisch normalverteilten Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$.
 - Schätze den Mittelwert μ gemäß

$$\hat{\mu}_{ML} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (1.1)$$

- Schätze die Kovarianzmatrix Σ mittels

$$\hat{\Sigma}_{ML} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\mu}_{ML})(\mathbf{x}_n - \hat{\mu}_{ML})^\top. \quad (1.2)$$

Frage: Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung




Abbildung: Modell bestehend aus einer Normalverteilung. Siehe **Bishop2024**, Seite 86.

Visualisierung: Problemstellung (Forts.)




Abbildung: Mixture Modell bestehend aus zwei Normalverteilungen. Siehe **Bishop2024**, Seite 86.

Gaussian Mixture Models

- Wir können ein **Gaussian Mixture Model** als eine *Überlagerung mehrerer Normalverteilungen* ansehen.
- Die Dichte bei K Komponenten ist gegeben durch

$$p(\mathbf{x}; \boldsymbol{\theta}) := \sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (1.3)$$

- Dabei enthält $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ die Modellparameter.
- Die **Mischkoeffizienten** π_k stellen sicher, dass die Mixture-Dichte *normiert* ist, dass also $\int_{-\infty}^{+\infty} p(\mathbf{x}; \boldsymbol{\theta}) = 1$ gilt.
- Die π_k erfüllen zudem

$$0 \leq \pi_k \leq 1 \quad \text{und} \quad \sum_{k=1}^K \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $z \in \mathbb{R}^K$ ein K -dimensionaler **One-Hot Vektor**.
- Die Komponenten z_k erfüllen also $z_k \in \{0, 1\}$ und $\sum_{k=1}^K z_k = 1$, wobei *genau eine Komponente* den Wert 1 annimmt.
- Wir definieren nun die gemeinsame Verteilung von x und z über die Kettenregel

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x} \mid \mathbf{z}) \cdot p(\mathbf{z}).$$

- Für die Definition der Randverteilung $p(\mathbf{z})$ benutzen wir die Mischkoeffizienten: $p(z_k = 1; \pi_k) := \pi_k$.
- Da z ein One-Hot Vektor ist, können wir schreiben

$$p(\mathbf{z}; \boldsymbol{\pi}) = \prod_{k=1}^K \pi_k^{z_k}. \quad (1.4)$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Analog definieren wir

$$p(\mathbf{x} \mid z_k = 1; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) := \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Dies können wir ebenfalls vektorisiert ausdrücken als

$$p(\mathbf{x} \mid \mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) := \prod_{k=1}^K \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (1.5)$$

- Die Randverteilung $p(\mathbf{x}; \boldsymbol{\theta})$ erhalten wir schließlich, indem wir über alle möglichen Werte $\mathbf{z}$ summieren

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{z}; \boldsymbol{\pi}) \cdot p(\mathbf{x} \mid \mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (1.6)$$

- Im letzten Gleichheitszeichen haben wir (1.4) und (1.5) zusammen mit der One-Hot Eigenschaft von $\mathbf{z}$ benutzt.

Latente Variablen

- Falls ein Datensatz X bestehend aus N Punkten $x_1, x_2, \dots, x_N$ vorliegt (und nicht nur ein einzelner Punkt x), so führen wir für jedes x_n ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt x_n .
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass x_n von Komponente k generiert wurde.
- Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend.
- Allerdings können wir nun mit der Verteilung $p(x, z; \theta)$ anstelle von $p(x; \theta)$ arbeiten, was zu *wesentlichen Vereinfachungen* führen wird.
- Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Nachfolgend interessieren wir uns besonders für die Aposteriori-Wahrscheinlichkeit $p(z \mid \mathbf{x}; \boldsymbol{\theta})$.
- Mit $\gamma(z_k)$ bezeichnen wir die Wahrscheinlichkeit $p(z_k = 1 \mid \mathbf{x}; \boldsymbol{\theta})$.
- Mit dem *Satz von Bayes* gilt

$$\begin{aligned}\gamma(z_k) &:= p(z_k = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = \frac{p(z_k = 1) \cdot p(\mathbf{x} \mid z_k = 1)}{\sum_{j=1}^K p(z_j = 1) \cdot p(\mathbf{x} \mid z_j = 1)} \\ &= \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.\end{aligned}\tag{1.7}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $z_k = 1$ und $\gamma(z_k)$ die Aposteriori-Wahrscheinlichkeit für $z_k = 1$, nachdem $\mathbf{x}$ beobachtet wurde.
- Man nennt $\gamma(z_k)$ auch die **Responsibility** der k -ten Komponente für Punkt $\mathbf{x}$.

Visualisierung: Responsibilities




Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_{nk})$ gewählt. Siehe [Bishop2024](#), Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N *unabhängigen und identisch verteilten* Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ gegeben.
- Wir fassen die Punkte $\{\mathbf{x}_n\}$ in der Matrix $\mathbf{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n -te Zeile durch $\mathbf{x}_n^\top$ gegeben ist.
- Mit (1.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned}\ln p(\mathbf{X}; \boldsymbol{\theta}) &= \ln \left(\prod_{n=1}^N \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right).\end{aligned}\tag{1.8}$$

- Aufgrund der Summe im Argument des Logarithmus ist (1.8) schwer zu optimieren.

Gradient der Log-Likelihood für die Mittelwerte

$$\frac{\partial}{\partial \mu_k} \ln p(X; \theta) = \sum_{n=1}^N \frac{1}{p(x_n; \theta)} \cdot \frac{\partial}{\partial \mu_k} p(x_n; \theta)$$

Anwendung der Kettenregel.

$$= \sum_{n=1}^N \left(\frac{1}{p(x_n; \theta)} \cdot \sum_{j=1}^K \pi_j \frac{\partial}{\partial \mu_k} \mathcal{N}(x_n; \mu_j, \Sigma_j) \right)$$

Einsetzen der Definition von $p(x_n; \theta)$.

$$= \sum_{n=1}^N \frac{\pi_k}{p(x_n; \theta)} \cdot \frac{\partial}{\partial \mu_k} \mathcal{N}(x_n; \mu_k, \Sigma_k)$$

Nur k -ter Summand hängt von μ_k ab. (1.9)

$$= \sum_{n=1}^N \frac{\pi_k \cdot \mathcal{N}(x_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_n; \mu_j, \Sigma_j)} \cdot \Sigma_k^{-1} (x_n - \mu_k)$$

Kettenregel für Exponentialfunktion.

$$= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (x_n - \mu_k)$$

Definition der Responsibilities.

Lösung für die Mittelwerte

- Wir setzen den Gradienten (1.9) Null, lösen nach μ_k auf und erhalten

$$\sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1}(\mathbf{x}_n - \mu_k) \stackrel{!}{=} 0 \quad \Longleftrightarrow \quad \mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n. \quad (1.10)$$

- Hierbei ist N_k die Summe der Responsibilities der k -ten Komponente, also

$$N_k := \sum_{n=1}^N \gamma(z_{nk}).$$

- Der Mittelwert μ_k der k -ten Komponente ergibt sich also durch ein *gewichtetes arithmetisches Mittel* der Punkte $\{\mathbf{x}_n\}$, wobei die Gewichtungsfaktoren gerade die Aposteriori-Wahrscheinlichkeiten dafür sind, dass $\mathbf{x}_n$ durch die k -te Komponente generiert wurde.

Lösung für die Kovarianzmatrizen

- Ein ähnliches Ergebnis erhalten wir für die Kovarianzmatrizen Σ_k .
- Es gilt

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \quad (1.11)$$

- Auch hier ergeben sich die Parameter als gewichtetes arithmetisches Mittel.

1.1 Aufgabe: Beweisen Sie diese Aussage!

Optimierung bezüglich der Mischkoeffizienten

- Bei der Optimierung bezüglich der Mischkoeffizienten π_k müssen wir zusätzlich die Normierungsbedingung beachten:

$$\sum_{k=1}^K \pi_k = 1.$$

- Es handelt sich also um ein *restringiertes Optimierungsproblem*.
- Die **Lagrange-Funktion** ist

$$\begin{aligned} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \end{aligned} \tag{1.12}$$

Gradient der Log-Likelihood für die Mischkoeffizienten

$$\frac{\partial}{\partial \pi_k} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \frac{\partial}{\partial \pi_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \cdot \frac{\partial}{\partial \pi_k} \left(\sum_{k=1}^K \pi_k - 1 \right) \quad \text{Linearität des Differenzialoperators.}$$

$$= \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \pi_k} p(\mathbf{x}_n; \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) + \lambda \quad \text{Anwendung der Kettenregel.}$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda \quad \text{Zähler und Nenner mit } \pi_k \text{ erweitern.} \quad (1.13)$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \gamma(z_{nk}) + \lambda \quad \text{Definition der Responsibilities.}$$

$$= \frac{N_k}{\pi_k} + \lambda \quad \text{Definition von } N_k.$$

Lösung für die Mischkoeffizienten

- Zusätzlich benötigen wir noch die Ableitung von (1.12) nach λ .
- Wir erhalten

$$\frac{\partial}{\partial \lambda} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \sum_{k=1}^K \pi_k - 1. \quad (1.14)$$

- Setzen wir die Ableitungen (1.13) und (1.14) Null, so erhalten wir

$$\pi_k = -\frac{N_k}{\lambda} \quad \text{und} \quad 1 = \sum_{k=1}^K \pi_k.$$

- Setzen wir die erste Bedingung in die zweite ein, so erhalten wir $\lambda = -N$ und damit schließlich

$$\pi_k = \frac{N_k}{N}. \quad (1.15)$$

Expectation-Maximization (EM) Algorithmus für GMMs

- Bei den Lösungsformeln (1.10), (1.11) und (1.15) handelt es sich *nicht um geschlossene Lösungsformeln (!)*, da die Gewichte $\gamma(z_{nk})$ von den anderen Parametern abhängen.
- Allerdings legen die Ergebnisse ein einfaches *iteratives Verfahren* nahe, den **Expectation-Maximization (EM) Algorithmus**.
- Dieser besteht aus zwei Phasen, die **Expectation-Phase (E-Schritt)** und die **Maximization-Phase (M-Schritt)**.
- Im E-Schritt werden die Werte $\gamma(z_{nk})$ bei gegebenen Parametern π_k, μ_k, Σ_k bestimmt.
- Im darauffolgenden M-Schritt werden die Parameter mit den neuen Werten $\gamma(z_{nk})$ aufdatiert.
- Dies führt man solange fort, bis Konvergenz eintritt.

Visualisierung: EM für GMMs




Abbildung: Visualisierung EM für GMMs. Siehe [Bishop2024](#), Seite 473.

Visualisierung: EM für GMMs (Forts.)




Abbildung: Visualisierung EM für GMMs. Siehe [Bishop2024](#), Seite 473.

EM Algorithmus für GMMs

1.2 Algorithmus

- 1 Initialisiere die Parameter $\{\pi_k\}$, $\{\boldsymbol{\mu}_k\}$ und $\{\boldsymbol{\Sigma}_k\}$ (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Berechne die Responsibilities für alle n und alle k gemäß

$$\gamma(z_{nk}) := \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.$$

- 3 **M-Schritt:** Aktualisiere die Parameter, wobei $N_k := \sum_{n=1}^N \gamma(z_{nk})$

$$\boldsymbol{\mu}_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad \text{und} \quad \boldsymbol{\Sigma}_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \quad \text{und} \quad \pi_k := \frac{N_k}{N}.$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zu Schritt 2.

Kapitel

② Expectation-Maximization (EM) Algorithmus

Problemstellung

Ungleichung von Jensen

Herleitung des Expectation-Schritts

Herleitung des Maximization-Schritts

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Anwendung auf Gaussian Mixture Models

Problemstellung

- Wir betrachten ein statistisches Modell mit den Daten $X = (x_1, x_2, \dots, x_N)^\top$, den **latenten Variablen** $Z = (z_1, z_2, \dots, z_N)^\top$ und den Modellparametern θ .
- Wie üblich ist unser Ziel die Maximierung der Log-Likelihood $\ln p(X; \theta)$ bezüglich θ .
- Wir nehmen an, dass die gemeinsame Verteilung $p(X, Z; \theta)$ von X und Z gegeben ist.
- Hieraus können wir $\ln p(X; \theta)$ bestimmen, indem wir über Z *marginalisieren*:

$$\ln p(X; \theta) = \ln \sum_Z p(X, Z; \theta) \quad (2.1)$$

- In der Regel ist eine direkte Maximierung von (2.1) zu kompliziert, da der Logarithmus nicht direkt auf $p(X, Z; \theta)$ wirken kann.

Problemstellung (Forts.)

- Mit $\{X, Z\}$ bezeichnen wir den **vollständigen** Datensatz, X alleine nennen wir hingegen **unvollständig**.
- Analog nennen wir $\ln p(X, Z; \theta)$ die **vollständige Log-Likelihood** und $\ln p(X; \theta)$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von (2.1) schwer ist, möchten wir $\ln p(X, Z; \theta)$ maximieren.
- **Problem:** Wir kennen Z nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in *zwei Phasen*, wobei man in jeder Iteration ausgehend von θ_{alt} neue Parameter θ_{neu} erhält, die (2.1) erhöhen.

E-Phase: Bestimme den Erwartungswert von $\ln p(X, Z; \theta)$ unter der Aposteriori-Verteilung der latenten Variablen $p(Z \mid X; \theta_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(X; \theta)$.

M-Phase: Die berechnete untere Schranke wird bezüglich der Parameter θ maximiert, was zu den aktualisierten Parametern θ_{neu} führt.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

2.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen




Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(X; \theta)$.
- Hierzu führen wir die Verteilung q über Z mit $q(Z) \neq 0$ ein und erhalten

$$\begin{aligned}\ln p(X; \theta) &= \ln \sum_Z p(X, Z; \theta) = \ln \sum_Z q(Z) \cdot \frac{p(X, Z; \theta)}{q(Z)} \\ &= \ln \mathbb{E}_{Z \sim q(Z)} \left[\frac{p(X, Z; \theta)}{q(Z)} \right] \\ &\geq \mathbb{E}_{Z \sim q(Z)} \left[\ln \frac{p(X, Z; \theta)}{q(Z)} \right] =: \mathcal{L}(q, \theta).\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen**, Satz (2.1), mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(X, Z; \theta)}{q(Z)}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(X; \theta) \geq \underbrace{\mathbb{E}_{Z \sim q(Z)} [\ln p(X, Z; \theta)]}_{\text{Erwartete vollständige Log-Likelihood}} - \underbrace{\mathbb{E}_{Z \sim q(Z)} [\ln q(Z)]}_{\text{Entropie von } q}. \quad (2.2)$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müssen.
- Wir möchten q so wählen, dass für das aktuelle θ in (2.2) Gleichheit gilt.
- Die Ungleichung von Jensen, Satz (2.1), gilt mit Gleichheit, falls

$$\frac{p(X, Z; \theta)}{q(Z)} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\mathbf{Z}) \propto p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet *proportional zu*.
- Daraus erhalten wir (da q normiert sein muss)

$$\begin{aligned} q(\mathbf{Z}) &= \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\mathbf{Z}}} p(\mathbf{X}, \tilde{\mathbf{Z}}; \boldsymbol{\theta})} = \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{p(\mathbf{X}; \boldsymbol{\theta})} \\ &= p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}). \end{aligned}$$

- **Ergebnis:** Für q benutzen wir die Aposteriori-Verteilung von $\mathbf{Z}$ gegeben $\mathbf{X}$.
- Dies setzen wir in (2.2) ein und erhalten die Identität

$$\ln p(\mathbf{X}; \boldsymbol{\theta}) = \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor θ_{alt} , mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}\ln p(\mathbf{X}; \theta) &\geq \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{X}, \mathbf{Z}; \theta)] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})] \\ &= Q(\theta, \theta_{\text{alt}}) + H(\theta_{\text{alt}}, \theta_{\text{alt}}) \\ &= Q(\theta, \theta_{\text{alt}}) + \text{const},\end{aligned}$$

wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.

- Die Funktion $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ ist die **Entropie** von q unter θ_{alt} .

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ bezüglich θ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\theta, \theta_{\text{alt}})$ gegeben.
- Der M-Schritt hat damit also die Gestalt

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}). \quad (2.3)$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(X | \theta_{\text{neu}}) \geq p(X | \theta_{\text{alt}})$ gilt.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

2.2 Algorithmus

- 1 Initialisiere θ_{alt} (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Bestimme die untere Schranke

$$Q(\theta, \theta_{\text{alt}}) := \mathbb{E}_{Z \sim p(Z|X; \theta_{\text{alt}})} [\ln p(X, Z; \theta)] .$$

- 3 **M-Schritt:** Maximiere die untere Schranke und berechne

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zurück zu Schritt 2 und setze $\theta_{\text{alt}} := \theta_{\text{neu}}$.
- 5 Ansonsten gebe θ_{neu} zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus.
- Es gilt

$$\begin{aligned}\ln p(X; \theta_{\text{neu}}) &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | X; \theta_{\text{alt}}) \ln \frac{p(X, \mathbf{Z}; \theta_{\text{neu}})}{p(\mathbf{Z} | X; \theta_{\text{alt}})} \\ &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | X; \theta_{\text{alt}}) \ln \frac{p(X, \mathbf{Z}; \theta_{\text{alt}})}{p(\mathbf{Z} | X; \theta_{\text{alt}})} \\ &= \ln p(X; \theta_{\text{alt}}).\end{aligned}$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil θ_{neu} so gewählt wurde, dass es die untere Schranke maximiert.

Visualisierung: EM-Algorithmus




Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [Bishop2024](#), Seite 488.

Evidence Lower Bound (ELBO)

- Wir geben noch eine andere Sicht auf den EM-Algorithmus.
- Hierzu stellen wir fest, dass wir die Log-Likelihood $\ln p(X; \theta)$ folgendermaßen zerlegen können

$$\ln p(X; \theta) = \mathcal{L}(q, \theta) + \text{KL}(q \parallel p). \quad (2.4)$$

- Dabei ist:
 - $\mathcal{L}(q, \theta)$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound**

$$\mathcal{L}(q, \theta) := \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(X, \mathbf{Z}; \theta)}{q(\mathbf{Z})} = \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(X, \mathbf{Z}; \theta) - \ln q(\mathbf{Z})]. \quad (2.5)$$

- $\text{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\mathbf{Z})$ und $p(\mathbf{Z} \mid X; \theta)$

$$\text{KL}(q \parallel p) := - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z} \mid X; \theta)}{q(\mathbf{Z})} = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} \mid X; \theta) - \ln q(\mathbf{Z})]. \quad (2.6)$$

Beweis der Zerlegung (2.4)

Beweis: Wir beweisen die Zerlegung (2.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(X, Z; \theta)$ an. Wir erhalten $p(X, Z; \theta) = p(Z | X; \theta) \cdot p(X; \theta)$. Anwendung des Logarithmus ergibt

$$\ln p(X, Z; \theta) = \ln p(Z | X; \theta) + \ln p(X; \theta).$$

Dies setzen wir in die Evidence Lower Bound (2.5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \theta) &= \sum_Z q(Z) \cdot [\ln p(X, Z; \theta) - \ln q(Z)] \\ &= \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) + \ln p(X; \theta) - \ln q(Z)].\end{aligned}$$

Damit ergibt sich schließlich mit (2.6) und wegen $\sum_Z q(Z) = 1$

$$\begin{aligned}\mathcal{L}(q, \theta) + \text{KL}(q \parallel p) &= \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) + \ln p(X; \theta) - \ln q(Z)] - \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) - \ln q(Z)] \\ &= \sum_Z q(Z) \cdot \ln p(X; \theta) = \ln p(X; \theta) \cdot \sum_Z q(Z) = \ln p(X; \theta).\end{aligned}$$

□

Kullback-Leibler Divergenz

Eigenschaften der Kullback-Leibler Divergenz:

Für alle Wahrscheinlichkeitsverteilungen q und p gelten die folgenden Eigenschaften.

① **Nicht-Negativität:**

$$\text{KL}(q \parallel p) \geq 0 \quad (2.7)$$

② **Identität:**

$$\text{KL}(q \parallel p) = 0 \iff q = p. \quad (2.8)$$

- ③ Es sei angemerkt, dass die Kullback-Leibler Divergenz **nicht symmetrisch** und damit keine Metrik ist. Es ist also im Allgemeinen

$$\text{KL}(q \parallel p) \neq \text{KL}(p \parallel q).$$

Kullback-Leibler Divergenz (Forts.)

- Aus (2.6) ist ersichtlich, dass $\text{KL}(q \parallel p)$ die Kullback-Leibler Divergenz zwischen der Verteilung $q(\mathbf{Z})$ und der Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ von $\mathbf{Z}$ ist.
- Aus der Zerlegung (2.4) folgt mit der Nichtnegativität (2.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\mathbf{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\mathbf{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood




Abbildung: Veranschaulichung der Zerlegung (2.4). Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den E-Schritt

- Mit dieser Vorarbeit können wir nun die alternative Herleitung des EM-Algorithmus durchführen.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \theta_{\text{alt}})$ bezüglich $q(\mathbf{Z})$ bei gegebenem θ_{alt} maximiert, sodass die untere Schranke die eigentliche Zielfunktion $\ln p(\mathbf{X}; \theta)$ in θ_{alt} berührt.
- Da $p(\mathbf{X}; \theta_{\text{alt}})$ nicht von $q(\mathbf{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \theta_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (2.8) für $q(\mathbf{Z})$ gelten

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \theta_{\text{alt}}) = \ln p(\mathbf{X}; \theta_{\text{alt}}).$$

Visualisierung: E-Schritt




Abbildung: Veranschaulichung des E-Schritts. Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\mathbf{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Hierdurch erhalten wir die neuen Parameter $\boldsymbol{\theta}_{\text{neu}}$, die letztendlich zu einer höheren Log-Likelihood $p(\mathbf{X}; \boldsymbol{\theta})$ führen.
- Setzen wir $q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})$ in die Definition der unteren Schranke (2.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) - \sum_{\mathbf{Z}} p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \\ &= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\theta, \theta_{\text{alt}})$ maximieren, wobei Q die **erwartete vollständige Log-Likelihood** ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (2.3) an

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern θ_{alt} bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}) \neq p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}}),$$

sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.

- Im folgenden E-Schritt setzen wir dann $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt




Abbildung: Veranschaulichung des M-Schritts. Siehe **Bishop2024**, Seite 487.

Gaussian Mixture Models und EM

- Wir wenden das allgemeine EM-Framework nun auf GMMs an.
- Im E-Schritt benötigen wir die Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ der latenten Variablen, wobei $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ ist.
- Diese können wir mit (1.4), (1.5) und dem Satz von Bayes bestimmen zu

$$p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}.$$

- Als nächstes stellen wir die erwartete vollständige Log-Likelihood auf, wobei der Erwartungswert bezüglich der Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ zu berechnen ist.
- Dazu benötigen wir allerdings noch ein Zwischenergebnis, das wir auf der nächsten Folie bereitstellen.

Gaussian Mixture Models und EM (Forts.)

- Es gilt der Zusammenhang

$$\begin{aligned}\mathbb{E}_{Z \sim p(Z|X;\theta)}[z_{nk}] &= \frac{\sum_{z_n} z_{nk} \prod_{k'=1}^K [\pi_{k'} \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_{k'}, \boldsymbol{\Sigma}_{k'})]^{z_{nk'}}}{\sum_{z_n} \prod_{j=1}^K [\pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\ &= \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(z_{nk}).\end{aligned}\tag{2.9}$$

- Der Erwartungswert der Indikator-Variablen z_{nk} unter der Aposteriori-Verteilung von Z ergibt sich also gerade als die jeweilige Responsibility $\gamma(z_{nk})$.

Gaussian Mixture Models und EM (Forts.)

Hiermit können wir nun die **erwartete vollständige Log-Likelihood** (Funktion Q) aufstellen

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X};\boldsymbol{\theta})}[\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] &= \mathbb{E} \left[\ln \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}} \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_{nk}} \right] \\
 &= \mathbb{E} \left[\sum_{n=1}^N \sum_{k=1}^K z_{nk} \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \right] && \text{Logarithmengesetze.} \\
 &= \sum_{n=1}^N \sum_{k=1}^K \mathbb{E}[z_{nk}] \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} && \text{Linearität von } \mathbb{E}. \\
 &= \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} && \text{Anwendung von (2.9).}
 \end{aligned} \tag{2.10}$$

Gaussian Mixture Models und EM (Forts.)

- Die Funktion (2.10) müssen wir nun im M-Schritt bezüglich der Parameter maximieren.
- Beispielhaft:** Gradient bezüglich μ_k

$$\begin{aligned}\frac{\partial}{\partial \mu_k} \sum_{n=1}^N \sum_{j=1}^K \gamma(z_{nj}) \cdot \{\ln \pi_j + \ln \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)\} &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\partial}{\partial \mu_k} \ln \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \\ &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)} \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \\ &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k).\end{aligned}$$

- Vergleiche hierzu die Herleitung in (1.9).

Gaussian Mixture Models und EM (Forts.)

- Nullsetzen und Auflösen nach μ_k ergibt

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n.$$

- Dies hat dieselbe Form wie (1.10).
- Die anderen Formeln ergeben sich analog.

Kapitel

③ Principal Component Analysis (PCA)

Problemstellung

Orthogonale Projektionen

Maximum-Variance Formulierung der PCA

PCA-Algorithmus

Minimum-Error Formulierung der PCA

Anwendungen der PCA

Problemstellung

- Die **Principal Component Analysis (PCA)** projiziert hochdimensionale Daten *orthogonal* auf einen *linearen Raum* niedriger Dimension.
- Diesen linearen Raum nennt man auch **Principal Subspace**.
- Wir betrachten im Folgenden einen Datensatz $\{\mathbf{x}_n\}$ mit $n = 1, 2, \dots, N$ und $\mathbf{x}_n \in \mathbb{R}^M$.
- Unser Ziel ist die Projektion der Daten in einem Raum der Dimension D , wobei $D \ll M$.
- Für die PCA gibt es verschiedene Ansätze, die zu demselben Ergebnis führen.
- Die bekanntesten sind die **Maximum Variance** Formulierung und die **Minimum Error** Formulierung.
- Zunächst wiederholen wir, was man unter der orthogonalen Projektion von Vektoren versteht.

Visualisierung: Orthogonale Projektionen




Abbildung: Orthogonale Projektion der Daten $\{\mathbf{x}_n\}$ auf die von $\mathbf{u}_1$ definierte Gerade. Siehe **Bishop2024**, Seite 467.

Geometrisches Skalarprodukt

3.1 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$. Es gilt das geometrische Skalarprodukt $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b})$.

Beweis: Für $\|\mathbf{a} - \mathbf{b}\|^2 = (\mathbf{a} - \mathbf{b})^\top (\mathbf{a} - \mathbf{b})$ ergibt sich durch Ausmultiplizieren zum Einen

$$\begin{aligned}\|\mathbf{a} - \mathbf{b}\|^2 &= \mathbf{a}^\top \mathbf{a} - \mathbf{a}^\top \mathbf{b} - \mathbf{b}^\top \mathbf{a} + \mathbf{b}^\top \mathbf{b} \\ &= \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2\mathbf{a}^\top \mathbf{b}\end{aligned}\tag{3.1}$$

und zum Anderen aufgrund des **Kosinussatzes** (Verallgemeinerung des Satzes von Pythagoras) aus der Geometrie

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2 \cdot \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b}).\tag{3.2}$$

Setzt man die Ausdrücke (3.1) und (3.2) für $\|\mathbf{a} - \mathbf{b}\|^2$ gleich, subtrahiert auf beiden Seiten $\|\mathbf{a}\|^2 + \|\mathbf{b}\|^2$ und dividiert durch -2 , so ergibt sich $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b})$, die Behauptung. $\square$

Orthogonalität von Vektoren

3.2 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$ verschieden von $\mathbf{0}$. Es gilt $\mathbf{a}^\top \mathbf{b} = 0$ genau dann, wenn $\mathbf{a}$ und $\mathbf{b}$ orthogonal aufeinander stehen.

Beweis: Wenn die Vektoren $\mathbf{a}$ und $\mathbf{b}$ orthogonal, d. h. senkrecht, aufeinander stehen, dann gilt $\cos \angle(\mathbf{a}, \mathbf{b}) = 0$, da die Kosinus-Funktion bei $\pi/2$ (entspricht 90°) eine Nullstelle hat. Mit Satz 3.1 folgt

$$\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\|^2 \cdot \|\mathbf{b}\|^2 \cdot \cos \angle(\mathbf{a}, \mathbf{b}) = \|\mathbf{a}\|^2 \cdot \|\mathbf{b}\|^2 \cdot 0 = 0.$$

Sei nun $\mathbf{a}^\top \mathbf{b} = 0$. Da die Vektoren von $\mathbf{0}$ verschieden sind, muss wegen der Eigenschaften der Norm zwingend $\cos \angle(\mathbf{a}, \mathbf{b}) = 0$ gelten. Die Vektoren stehen also senkrecht aufeinander. Damit gilt die Behauptung. $\square$

Orthogonale Projektion von Vektoren

3.3 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$. Dann ist die orthogonale Projektion von $\mathbf{b}$ auf $\mathbf{a}$ gegeben durch

$$\text{proj}_{\mathbf{a}} \mathbf{b} = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2} \mathbf{a}.$$

Beweis: Es müssen zwei Bedingungen erfüllt sein. Einerseits ist der Projektionsvektor $\mathbf{p} := \text{proj}_{\mathbf{a}} \mathbf{b}$ der Anteil von $\mathbf{b}$, der in Richtung $\mathbf{a}$ zeigt, sodass dieser eine Stauchung bzw. Streckung von $\mathbf{a}$ ist. Mit $k \in \mathbb{R}$ gilt also

$$\mathbf{p} = k \cdot \mathbf{a}. \quad (3.3)$$

Andererseits soll die Projektion orthogonal sein, d. h. wir wollen den Vektor $\mathbf{p}$ so finden, dass $\mathbf{b} - \mathbf{p}$ senkrecht auf $\mathbf{a}$ steht. Mit Satz 3.2 lautet die Bedingung also

$$(\mathbf{b} - \mathbf{p})^\top \mathbf{a} = 0. \quad (3.4)$$

Einsetzen von (3.3) in (3.4) und auflösen nach k ergibt $(\mathbf{b} - k \cdot \mathbf{a})^\top \mathbf{a} = 0 \iff k = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2}$. Dieses Ergebnis setzen wir in (3.3) ein und erhalten die Behauptung. $\square$

Orthogonale Projektion von Vektoren (Forts.)




Abbildung: Projektion des Vektors $b \in \mathbb{R}^2$ auf den Vektor $a \in \mathbb{R}^2$. Im Kontext der PCA ist der Vektor a der Principal Subspace u_1 und b ist ein Datenpunkt, der auf diesen Raum projiziert wird.

Orthogonale Projektion von Vektoren (Forts.)

- Interessieren wir uns nur für die *Länge des Projektionsvektors*, so betrachten wir seine Norm

$$\|\text{proj}_a \mathbf{b}\| = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2} \|\mathbf{a}\| = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|}. \quad (3.5)$$

- Gilt zudem $\|\mathbf{a}\| = 1$ (dann ist $\mathbf{a}$ ein Einheitsvektor), so ergibt sich die Länge des Projektionsvektors einfach als das Skalarprodukt der beteiligten Vektoren

$$\|\text{proj}_a \mathbf{b}\| = \mathbf{a}^\top \mathbf{b}. \quad (3.6)$$

- Wir gehen im Folgenden davon aus, dass die **Principal Components** $\{\mathbf{u}_i\}$ normiert sind.

Maximum-Variance Formulierung

- Im Folgenden betrachten wir den Fall $D = 1$.
- Wir betrachten also nur eine einzelne Principal Component $\mathbf{u}_1$.
- Eine mögliche Formulierung der PCA ist es, die *Varianz der projizierten Daten zu maximieren*.
- Durch die Maximierung der Varianz erhofft man sich den Erhalt eines möglichst großen Anteils der Struktur der Daten.
- Dieses Vorgehen führt auf die **Maximum-Variance Formulierung** der PCA.
- Da $\|\mathbf{u}_1\| = 1$, ist die Projektion eines Datenpunkts $\mathbf{x}_n$ auf $\mathbf{u}_1$ gegeben durch

$$\tilde{x}_n = \mathbf{u}_1^\top \mathbf{x}_n. \quad (3.7)$$

Ziel: Finde $\mathbf{u}_1$ so, dass die Varianz der Projektionen $\{\tilde{x}_n\}$ maximal wird.

Projektion von Mittelwert und Varianz

- Der Mittelwert der projizierten Daten ist analog gegeben durch

$$\mathbf{u}_1^\top \bar{\mathbf{x}}, \quad \text{mit} \quad \bar{\mathbf{x}} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (3.8)$$

- Die projizierte Varianz bestimmt man mittels

$$\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1. \quad (3.9)$$

- Hierbei bezeichnet $\mathbf{S}$ die **Streuungsmatrix** der Daten im hochdimensionalen Raum.
- Sie ist gegeben durch

$$\mathbf{S} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^\top. \quad (3.10)$$

Beweis von (3.9)

Wir beweisen Gleichung (3.9):

Beweis: Wir setzen die Projektionen (3.7) und (3.8) in die Definition der Varianz ein und erhalten durch Ausmultiplizieren aufgrund der Symmetrie des Skalarprodukts

$$\begin{aligned}\frac{1}{N} \sum_{n=1}^N (u_1^\top x_n - u_1^\top \bar{x})^2 &= \frac{1}{N} \sum_{n=1}^N (u_1^\top x_n \cdot x_n^\top u_1 - 2 \cdot u_1^\top x_n \cdot \bar{x}^\top u_1 + u_1^\top \bar{x} \cdot \bar{x}^\top u_1) \\&= u_1^\top \left(\frac{1}{N} \sum_{n=1}^N (x_n x_n^\top - 2 \cdot x_n \bar{x}^\top + \bar{x} \bar{x}^\top) \right) u_1 \\&= u_1^\top \left(\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^\top \right) u_1 \\&= u_1^\top S u_1.\end{aligned}$$

Einsetzen von (3.10).

□

Maximierung der projizierten Varianz

- Unser Ziel ist nun die Maximierung der projizierten Varianz $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$ in $\mathbf{u}_1$.
- **Problem:** Dieses Maximierungsproblem ist unbeschränkt.
- Wir können diesen Ausdruck stets vergrößern, indem wir die Komponenten von $\mathbf{u}_1$ vergrößern.
- Um dies zu verhindern, fordern wir, dass $\|\mathbf{u}_1\| = 1$ gilt.

Maximierungsproblem für die PCA:

$$\begin{array}{ll} \text{Maximiere} & \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 \\ \text{unter} & \|\mathbf{u}_1\| = 1. \end{array} \quad (3.11)$$

Maximierung der projizierten Varianz (Forts.)

- Löst man Problem (3.11), so erhält man für $\mathbf{u}_1$ die Bedingung

$$S\mathbf{u}_1 = \lambda_1\mathbf{u}_1. \quad (3.12)$$

- Gleichung (3.12) sagt aus, dass $\mathbf{u}_1$ ein Eigenvektor von S sein muss.
- Der Lagrange-Multiplikator λ_1 ist der zugehörige Eigenwert.

3.4 Aufgabe: Zeigen Sie die Gültigkeit von (3.12), indem Sie das Optimierungsproblem (3.11) lösen. Stellen Sie hierzu die Lagrange-Funktion des Problems auf und finden Sie deren stationären Punkte.

Maximierung der projizierten Varianz (Forts.)

- Multiplizieren wir (3.12) von links mit $\mathbf{u}_1^\top$, so erhalten wir

$$\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1^\top \mathbf{u}_1 = \lambda_1 \|\mathbf{u}_1\|^2 = \lambda_1. \quad (3.13)$$

- Im letzten Gleichheitszeichen haben wir benutzt, dass eine Lösung von (3.11) die Nebenbedingung $\|\mathbf{u}_1\| = 1$ erfüllt.
- Wegen (3.13) ist der Eigenwert λ_1 die Varianz, die durch Projektion der Daten auf $\mathbf{u}_1$ erhalten bleibt.

Lösung für den Fall $D = 1$: Wir berechnen die Eigenzerlegung von $\mathbf{S}$ und benutzen als $\mathbf{u}_1$ einen (normierten) Eigenvektor zum größten Eigenwert. Wegen (3.13) erhält dieser den größten Anteil der Varianz.

Bestimmung weiterer Principal Components

- Die Bestimmung weiterer Principal Components ist einfach.
- Wir benutzen als $\mathbf{u}_2$ einen normierten Eigenvektor von S zum zweitgrößten Eigenwert λ_2 .
- Wir benutzen als $\mathbf{u}_3$ einen normierten Eigenvektor von S zum drittgrößten Eigenwert λ_3 .
- Dies führen wir solange fort, bis wir die vorgegebenen D Komponenten erreicht haben.
- Wir fassen die Vektoren $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_D$ in einer Matrix $V \in \mathbb{R}^{M \times D}$ zusammen.
- Die Projektionen $\tilde{X} \in \mathbb{R}^{N \times D}$ der Daten $X \in \mathbb{R}^{N \times M}$ erhalten wir dann mittels

$$\tilde{X} = XV. \quad (3.14)$$

Orthogonalität der Principal Components

3.5 Satz: Die Principal Components $\{\mathbf{u}_i\}$ stehen senkrecht aufeinander.

Beweis: Dies folgt direkt aus der Orthogonalität der Eigenvektoren von symmetrischen Matrizen zu verschiedenen Eigenwerten. Seien also λ_1 und λ_2 mit $\lambda_1 \neq \lambda_2$ zwei voneinander verschiedene Eigenwerte von S . Dann erfüllen diese die Gleichungen $S\mathbf{u}_1 = \lambda_1\mathbf{u}_1$ und $S\mathbf{u}_2 = \lambda_2\mathbf{u}_2$. Damit gilt

$$(S\mathbf{u}_1)^\top \mathbf{u}_2 = (\lambda_1\mathbf{u}_1)^\top \mathbf{u}_2 = \lambda_1 \mathbf{u}_1^\top \mathbf{u}_2. \quad (3.15)$$

Außerdem gilt aufgrund der Symmetrie von S und der Tatsache, dass man eine Matrix im Skalarprodukt transponiert auf die andere Seite bringen darf

$$(S\mathbf{u}_1)^\top \mathbf{u}_2 = \mathbf{u}_1^\top (S^\top \mathbf{u}_2) = \mathbf{u}_1^\top (S\mathbf{u}_2). \quad (3.16)$$

Nun setzen wir die Eigenwertgleichung in (3.16) ein und erhalten

$$(S\mathbf{u}_1)^\top \mathbf{u}_2 = \mathbf{u}_1^\top (\lambda_2 \mathbf{u}_2) = \lambda_2 \mathbf{u}_1^\top \mathbf{u}_2. \quad (3.17)$$

Setzt man nun (3.15) und (3.16) gleich, so erhält man schlussendlich $(\lambda_1 - \lambda_2) \cdot \mathbf{u}_1^\top \mathbf{u}_2 = 0$. Da $\lambda_1 \neq \lambda_2$ muss $\mathbf{u}_1^\top \mathbf{u}_2 = 0$ gelten. Mit Satz 3.2 folgt die Behauptung. □

PCA-Algorithmus

3.6 Algorithmus

- 1 Bestimme $\bar{x}$ und S gemäß (3.8) beziehungsweise (3.10).
- 2 Berechne die Eigenzerlegung von S , d. h. finde Matrizen U und Λ mit

$$S = U\Lambda U^T.$$

Dabei enthält die Matrix $U \in \mathbb{R}^{M \times M}$ die Eigenvektoren von S . $\Lambda \in \mathbb{R}^{M \times M}$ ist eine Diagonalmatrix mit den Eigenwerten auf der Hauptdiagonalen.

- 3 Normiere die Eigenvektoren, die zu den D größten Eigenwerten gehören und fasse sie in der Matrix $V \in \mathbb{R}^{M \times D}$ zusammen.
- 4 Berechne die Projektionen $\tilde{X} = XV$.

PCA-Algorithmus (Forts.)

3.7 Aufgabe: Es sei der zweidimensionale Datensatz

$$X := \begin{pmatrix} 1 & 4 \\ 4 & 1 \\ 1 & 1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

gegeben. Berechnen Sie die eindimensionalen Projektionen dieses Datensatzes mit dem PCA-Algorithmus.

Minimum-Error Formulierung

- Wir betrachten im Folgenden eine weitere Formulierung der PCA, welche auf der *Minimierung des Projektionsfehlers* basiert, die **Minimum-Error** Formulierung.
- Dazu seien $\{\mathbf{u}_i\}$ mit $i = 1, 2, \dots, M$ *orthonormale Basisvektoren*, d. h.

$$\mathbf{u}_i^\top \mathbf{u}_j = \delta_{ij} \quad \forall i, j. \quad (3.18)$$

- Die Basis $\{\mathbf{u}_i\}$ ist *vollständig*, weshalb sich jedes $\mathbf{x}_n$ *eindeutig* als Linearkombination der $\mathbf{u}_i$ darstellen lässt

$$\mathbf{x}_n = \sum_{i=1}^M \alpha_{ni} \mathbf{u}_i. \quad (3.19)$$

- Dies entspricht einer Drehung des Koordinatensystems.

Minimum-Error Formulierung (Forts.)

- Die Koeffizienten α_{nj} ergeben sich als Projektionen der $\mathbf{x}_n$ auf die $\mathbf{u}_j$.
- Wegen (3.18) ist $\alpha_{nj} = \mathbf{x}_n^\top \mathbf{u}_j$, sodass wir (3.19) schreiben können als

$$\mathbf{x}_n = \sum_{i=1}^M (\mathbf{x}_n^\top \mathbf{u}_i) \mathbf{u}_i. \quad (3.20)$$

- Unser Ziel ist jedoch die Approximation der $\{\mathbf{x}_n\}$ mit einer beschränkten Anzahl von Komponenten $D \ll M$.

Visualisierung: Basiswechsel

Projektionsfehler

- Wir approximieren jeden Datenpunkt $\mathbf{x}_n$ mittels

$$\tilde{\mathbf{x}}_n := \sum_{i=1}^D z_{ni} \mathbf{u}_i + \sum_{i=D+1}^M b_i \mathbf{u}_i. \quad (3.21)$$

- Die $\{z_{ni}\}$ hängen dabei von den Punkten $\{\mathbf{x}_n\}$ ab, die $\{b_i\}$ sind dagegen unabhängig.
- Wir möchten die $\{\mathbf{u}_i\}$, die $\{z_{ni}\}$ und die $\{b_i\}$ so wählen, dass der **Projektionsfehler** minimal wird.
- Diesen definieren wir als die durchschnittliche quadratische Abweichung der $\{\mathbf{x}_n\}$ und den $\{\tilde{\mathbf{x}}_n\}$.

PCA Fehlerfunktion:

$$J := \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2. \quad (3.22)$$

Minimierung des Projektionsfehlers

- Leiten wir (3.22) nach z_{nj} ab und setzen die Ableitung Null, so ergibt sich

$$z_{nj} = \mathbf{x}_n^\top \mathbf{u}_j. \quad (3.23)$$

- Analog erhalten wir für b_j

$$b_j = \bar{\mathbf{x}}^\top \mathbf{u}_j. \quad (3.24)$$

3.8 Aufgabe: Bestätigen Sie die Formeln (3.23) und (3.24) durch Nachrechnen.

Visualisierung: Projektionsfehler

Minimierung des Projektionsfehlers (Forts.)

- Die Ergebnisse (3.23) und (3.24) setzen wir nun in die Definition (3.21) von $\tilde{\mathbf{x}}_n$ ein.
- Zusammen mit der Darstellung (3.20) von $\mathbf{x}_n$ erhalten wir für den Differenzvektor

$$\mathbf{x}_n - \tilde{\mathbf{x}}_n = \sum_{i=D+1}^M \left\{ (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{u}_i \right\} \mathbf{u}_i. \quad (3.25)$$

- Dies substituieren wir schließlich in die Fehlerfunktion (3.22). Es gilt

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{i=D+1}^M (\mathbf{x}_n^\top \mathbf{u}_i - \bar{\mathbf{x}}^\top \mathbf{u}_i)^2 = \sum_{i=D+1}^M \mathbf{u}_i^\top \mathbf{S} \mathbf{u}_i = \text{trace}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}). \quad (3.26)$$

- Hierbei ist $\hat{\mathbf{U}}$ die Matrix, deren Spalten aus den Vektoren $\mathbf{u}_{D+1}, \dots, \mathbf{u}_M$ besteht.

Minimierung des Projektionsfehlers (Forts.)

- Wir müssen den Ausdruck (3.26) minimieren.
- Wieder muss eine Nebenbedingung eingeführt werden, um nicht das Ergebnis $\mathbf{u}_i = \mathbf{0}$ zu erhalten.
- Die Nebenbedingungen ergeben sich aus der vorausgesetzten *Orthonormalität* (3.18) der $\{\mathbf{u}_i\}$.
- Der Einfachheit halber betrachten wir den Fall $M = 2$ und $D = 1$.
- In diesem Fall erhalten wir die Lagrange-Funktion

$$\mathcal{L} = \mathbf{u}_2^\top \mathbf{S} \mathbf{u}_2 + \lambda_2 (1 - \mathbf{u}_2^\top \mathbf{u}_2). \quad (3.27)$$

- Ableiten nach $\mathbf{u}_2$ und Nullsetzen ergibt $\mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2$, sodass $\mathbf{u}_2$ ein Eigenvektor von $\mathbf{S}$ ist.
- Setzen wir dies in (3.26) ein, so finden wir

$$J = \mathbf{u}_2^\top \mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2^\top \mathbf{u}_2 = \lambda_2 \cdot \|\mathbf{u}_2\|^2 = \lambda_2. \quad (3.28)$$

Minimierung des Projektionsfehlers (Forts.)

- Der Fehler wird in diesem Fall also minimal, wenn man für $\mathbf{u}_2$ einen normierten Eigenvektor zum kleineren Eigenwert benutzt.
- Für allgemeines M und D erhält man den minimalen Fehler J , indem man die $\{\mathbf{u}_i\}$ als normierte Eigenvektoren von S wählt.
- Für alle $i = 1, 2, \dots, M$ müssen die $\{\mathbf{u}_i\}$ also erfüllen

$$S\mathbf{u}_i = \lambda_i\mathbf{u}_i. \quad (3.29)$$

- Für den Fehler J gilt dann

$$J = \sum_{i=D+1}^M \lambda_i. \quad (3.30)$$

Minimierung des Projektionsfehlers (Forts.)

Man projiziert die Daten also auf den Raum, welcher durch die D Eigenvektoren zu den größten Eigenwerten aufgespannt wird. Der Fehler ergibt sich dann als die Summe jener Eigenwerte, deren Eigenvektoren nicht für die Projektion benutzt wurden.

Datenkompression




Abbildung: Anwendung der PCA auf einen Datensatz bestehend aus 6.000 Bildern mit 28×28 Pixeln. Positive Werte sind blau, negative Werte gelb dargestellt. Siehe [Bishop2024](#), Seite 502.

Datenkompression (Forts.)





Abbildung: (a) Plot des Spektrums der Eigenwerte in absteigender Sortierung. (b) Plot der Summe der verworfenen Eigenwerte (Fehler J). Siehe **Bishop2024**, Seite 503.

Datenkompression (Forts.)




Abbildung: Reduktion eines Elements des Datensatzes auf verschiedene Dimensionen. Bishop benutzt M anstelle von D für die Dimension des Unterraums. Siehe [Bishop2024](#), Seite 502.

Literatur