

# Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

## 1 Grundlagen der Statistik

# Kapitel

## ① Grundlagen der Statistik

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Maximum-Likelihood Schätzer

Maximum-Aposteriori Schätzer

# Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel  $(\Omega, \mathcal{A}, \mathbb{P})$ .
- $\Omega$  ist der **Ereignisraum**, also die Menge aller Elementarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir  $\Omega := \{1, 2, 3, 4, 5, 6\}$ .
- Mit  $\mathcal{A}$  bezeichnen wir die zugehörige **Sigma-Algebra**, eine Menge von Teilmengen von  $\Omega$ . Im einfachsten Fall könnten wir  $\mathcal{A} := \text{Pot}(\Omega)$  wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra  $\mathbb{B}$  auf  $\mathbb{R}$  heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$  ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus  $\mathcal{A}$  eine Wahrscheinlichkeit zuordnet.

# Zufallsvariablen

Im Folgenden sei  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $(\mathcal{X}, \mathcal{B})$  ein messbarer Raum.

**1.1 Definition:** Die Abbildung  $X : \Omega \rightarrow \mathcal{X}$  heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : X^{-1}(B) := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von  $B$  unter  $X$  muss also eine messbare Menge in  $\mathcal{A}$  sein, der durch  $\mathbb{P}$  eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable  $X : \Omega \rightarrow \mathcal{X}$  die Funktion

$$\mathbb{P}^X : \mathcal{B} \rightarrow [0, 1] \quad \text{mit} \quad B \mapsto \mathbb{P}(X^{-1}(B))$$

die **Verteilung** der Zufallsvariable  $X$ .  $\mathbb{P}^X$  ist das **Bildmaß** von  $\mathbb{P}$  unter  $X$ .

# Zufallsvariablen (Forts.)

Sei  $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$  ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße  $X : \Omega \rightarrow \mathcal{X}$  ist *verteilt gemäß  $\mathbb{Q}$*  oder kurz  *$\mathbb{Q}$ -verteilt*, falls es einen Wahrscheinlichkeitsraum  $(\Omega, \mathcal{A}, \mathbb{P})$  gibt, sodass  $\mathbb{P}^X = \mathbb{Q}$  gilt.

**Beispiel:**  $X$  ist  $\mathcal{N}(\mu, \sigma^2)$ -verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum  $(\Omega, \mathcal{A}, \mathbb{P})$  gibt, sodass  $\forall B \in \mathbb{B} : \mathbb{P}(X \in B) = \mathcal{N}(B; \mu, \sigma^2)$ . Wir schreiben kurz  $X \sim \mathcal{N}(\mu, \sigma^2)$ .

# Wahrscheinlichkeitsdichten

**1.2 Definition:** Es seien  $(\Omega, \mathcal{A}, \mathbb{P})$  und  $(\mathcal{X}, \mathcal{B}, \mathbb{P}^X)$  Wahrscheinlichkeitsräume. Dabei ist  $\mathbb{P}^X$  die Verteilung der Zufallsvariablen  $X : \Omega \rightarrow \mathcal{X}$ . Wir nennen eine nichtnegative Funktion

$$p_X : \mathbb{R} \rightarrow [0, \infty)$$

eine **(Wahrscheinlichkeits-)Dichte** von  $\mathbb{P}^X$ , falls

$$\mathbb{P}^X(B) = \int_B p_X(\xi) \, d\xi \quad \forall B \in \mathcal{B}.$$

**Bemerkung:** Die Wahrscheinlichkeiten der Mengen  $B \in \mathcal{B}$  müssen sich also allesamt als Integral der Dichte  $p_X$  darstellen lassen können.

# Erwartungswert von Zufallsvariablen

**1.3 Definition:** Sei  $X \in \mathbb{R}$  eine Zufallsvariable. Wir definieren den **Erwartungswert** (erstes Moment) von  $X$  als

$$\mathbb{E}[X] := \int_{\mathbb{R}} \xi \cdot p_X(\xi) d\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen  $X$  und  $Y$  und eine beliebige aber feste Zahl  $\alpha \in \mathbb{R}$  (keine Zufallsvariable!) gelten

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \quad \text{und} \quad \mathbb{E}[\alpha \cdot X] = \alpha \cdot \mathbb{E}[X].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$  als

$$\mathbb{E}[\mathbf{x}] := (\mathbb{E}[x_1], \mathbb{E}[x_2], \dots, \mathbb{E}[x_n])^\top.$$

# Varianz von Zufallsvariablen

**1.4 Definition:** Die Varianz einer Zufallsvariablen  $X \in \mathbb{R}$  ist definiert als die *erwartete quadratische Abweichung vom Erwartungswert* (zweites zentriertes Moment), also

$$\mathbb{V}[X] := \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{\mathbb{R}} (\xi - \mathbb{E}[X])^2 \cdot p_X(\xi) \, d\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2 - 2X \cdot \mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2 \cdot \mathbb{E}[X]^2 + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2.\end{aligned}$$

# Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen. Seien dazu  $X$  und  $Y$  reelle Zufallsvariablen und  $\alpha \in \mathbb{R}$  beliebig aber fest.

Die Varianz ist **nicht** linear!

- Es gilt  $\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y]$  nur, wenn  $X$  und  $Y$  unkorreliert sind (**Satz von Bienaymé**).
- $\mathbb{V}[\alpha \cdot X] = \alpha^2 \cdot \mathbb{V}[X]$ .

Eine Verschiebung verändert die Varianz nicht, also  $\mathbb{V}[X + \alpha] = \mathbb{V}[X]$  ( $\alpha$  ist hierbei keine Zufallsvariable, sondern eine konstante reelle Zahl).

# Kovarianz

**1.5 Definition:** Es seien  $X$  und  $Y$  zwei Zufallsvariablen. Die **Kovarianz** zwischen  $X$  und  $Y$  ist definiert als

$$\text{Cov}[X, Y] := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

## Bemerkungen:

- Die Erwartungswerte müssen natürlich existieren, damit Definition 1.5 Sinn ergibt.
- Die Kovarianz ist symmetrisch: Es ist  $\text{Cov}[X, Y] = \text{Cov}[Y, X]$ .

**1.6 Aufgabe:** Was ist der Unterschied zwischen Kovarianz und Korrelation?

# Streuungsmatrix

**1.7 Definition:** Es sei  $\mathbf{x} \in \mathbb{R}^n$  ein Zufallsvektor. Wir definieren die **Streuungsmatrix**  $\mathbb{D}[\mathbf{x}]$  als

$$\mathbb{D}[\mathbf{x}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \in \mathbb{R}^{n \times n}.$$

Für die Einträge von  $\mathbb{D}[\mathbf{x}]$  gilt:

$$\begin{aligned} (\mathbb{D}[\mathbf{x}])_{ij} &= \mathbb{E}[(x_i - \mathbb{E}[x_i])(x_j - \mathbb{E}[x_j])] \\ &= \mathbb{E}[(x_j - \mathbb{E}[x_j])(x_i - \mathbb{E}[x_i])] = (\mathbb{D}[\mathbf{x}])_{ji} = \begin{cases} \text{Cov}[x_i, x_j] & \text{für } i \neq j \\ \mathbb{V}[x_i] & \text{für } i = j. \end{cases} \end{aligned}$$

**1.8 Aufgabe:** Zeigen Sie, dass  $\mathbb{D}[\mathbf{x}]$  positiv semidefinit ist.

# Kovarianzmatrix

**1.9 Definition:** Es seien  $\mathbf{x} \in \mathbb{R}^n$  und  $\mathbf{y} \in \mathbb{R}^m$  zwei Zufallsvektoren. Die **Kovarianzmatrix** von  $\mathbf{x}$  und  $\mathbf{y}$  ist

$$\text{Cov}[\mathbf{x}, \mathbf{y}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top] \in \mathbb{R}^{n \times m}.$$

# Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

| Name der Verteilung          | $\mathbb{P}^X$ | Zähldichte $p_X(k)$                                        | $\mathbb{E}[X]$       | $\mathbb{V}[X]$                                                     |
|------------------------------|----------------|------------------------------------------------------------|-----------------------|---------------------------------------------------------------------|
| Binomialverteilung           | $B_{n,p}$      | $\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$                 | $n \cdot p$           | $n \cdot p \cdot (1-p)$                                             |
| Hypergeometrische Verteilung | $H_{n,K,N}$    | $\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$ | $n \cdot \frac{K}{N}$ | $n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$ |
| Poisson-Verteilung           | $P_\lambda$    | $e^{-\lambda} \cdot \frac{\lambda^k}{k!}$                  | $\lambda$             | $\lambda$                                                           |

# Absolutstetige Verteilungen

| Name der Verteilung   | $\mathbb{P}^X$                | Lebesgue-Dichte $p_X(\xi)$                                                                                                                   | $\mathbb{E}[X]$     | $\mathbb{V}[X]$                           |
|-----------------------|-------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|---------------------|-------------------------------------------|
| Normalverteilung      | $\mathcal{N}_{\mu, \sigma^2}$ | $\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$                                                                     | $\mu$               | $\sigma^2$                                |
| Gammaverteilung       | $\Gamma_{\lambda, r}$         | $\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$                                             | $\frac{r}{\lambda}$ | $\frac{r}{\lambda^2}$                     |
| Chiquadrat-Verteilung | $\chi_f^2$                    | $\frac{1}{2^{\frac{f}{2}} \cdot \Gamma(\frac{f}{2})} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0, \infty)}(\xi)$ | $f$                 | $2 \cdot f$                               |
| Exponentialverteilung | $Exp_{\lambda}$               | $\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$                                                                          | $\frac{1}{\lambda}$ | $\frac{1}{\lambda^2}$                     |
| Betaverteilung        | $\beta_{a, b}$                | $\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0, 1)}(\xi)$                                  | $\frac{a}{a+b}$     | $\frac{a \cdot b}{(a+b)^2 \cdot (a+b+1)}$ |
| Gleichverteilung      | $U_{(a, b)}$                  | $\frac{1}{b-a} \cdot \mathbf{1}_{(a, b)}(\xi)$                                                                                               | $\frac{a+b}{2}$     | $\frac{(b-a)^2}{12}$                      |

# Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

**1.10 Definition:** Es seien  $X \in \mathbb{R}$  und  $Y \in \mathbb{R}$  reelle Zufallsvariablen mit den Verteilungen  $\mathbb{P}^X$ ,  $\mathbb{P}^Y$  und den Dichten  $p_X$  bzw.  $p_Y$ .

$X$  und  $Y$  heißen **stochastisch unabhängig** genau dann wenn  $p_{X,Y} := p_X \cdot p_Y$  eine **Produktdichte** der Verteilung  $\mathbb{P}^{X,Y}$  ist, d. h. die gemeinsame Dichte von  $X$  und  $Y$  ergibt sich als Produkt der Einzeldichten.

**Bemerkung:** Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. **Die Umkehrung gilt im Allgemeinen nicht!** Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als die der Unkorreliertheit.

# Bedingte Wahrscheinlichkeiten

- Wahrscheinlichkeiten von Ereignissen verändern sich, wenn wir zusätzliches Wissen mit einbeziehen.
- Wir definieren daher:

**1.11 Definition:** Es seien  $X$  und  $Y$  zwei Zufallsvariablen, wobei wir den Wert von  $Y$  bereits beobachtet haben (Vorwissen). Dann ist die **Wahrscheinlichkeitsdichte von  $X$  gegeben  $Y$** , in Notation  $p(X | Y)$ , definiert als

$$p(X | Y) := \frac{p(X, Y)}{p(Y)}.$$

# Satz von Bayes

Mit bedingten Wahrscheinlichkeiten können wir einen zentralen Satz der Wahrscheinlichkeitsrechnung angeben:

**1.12 Satz:** Es seien  $X$  und  $Y$  zwei Zufallsvariablen. Es gilt der **Satz von Bayes**

$$p(X | Y) = \frac{p(Y | X) \cdot p(X)}{p(Y)}.$$

**Beweis:** Mit Definition 1.11 gilt  $p(X | Y) = \frac{p(X, Y)}{p(Y)}$ . Analog gilt  $p(Y | X) = \frac{p(Y, X)}{p(X)}$ . Da  $p(X, Y) = p(Y, X)$ , können wir beide Gleichungen nach der Verbunddichte  $p(X, Y)$  auflösen. Wir erhalten also  $p(X, Y) = p(X | Y) \cdot p(Y)$  und  $p(X, Y) = p(Y | X) \cdot p(X)$ . Gleichsetzen liefert schließlich

$$p(X | Y) \cdot p(Y) = p(Y | X) \cdot p(X) \quad \Longleftrightarrow \quad p(X | Y) = \frac{p(Y | X) \cdot p(X)}{p(Y)},$$

die Behauptung. □

# Transformationssatz für Lebesgue-Dichten

**1.13 Satz:** Es seien  $x$  und  $y$   $n$ -dimensionale Zufallsvektoren mit dem Zusammenhang

$$y = T(x).$$

Die Abbildung  $T : \mathbb{R}^n \rightarrow \mathbb{R}^n$  sei *bijektiv*, sodass die Umkehrabbildung  $x = T^{-1}(y)$  existiert und eindeutig ist. Dann gilt für die Dichte  $p_y$  der transformierten Zufallsvariablen  $y$

$$p_y(y) = p_x(T^{-1}(y)) \cdot |\det JT^{-1}(y)|,$$

wobei  $p_x$  die Dichte von  $x$  und  $JT^{-1}$  die Jacobi-Matrix der Abbildung  $T^{-1}$  bezeichnet.

**Beweis:** Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

# Beispiel I

Es sei  $X \sim \text{Exp}_2$  eine exponentialverteilte Zufallsvariable mit Ankunftsrate  $\lambda = 2$ .

Gesucht ist die Dichte der Zufallsvariablen  $Y := 5X + 2$ .

## Lösung:

Es ist  $T(X) := 5X + 2$  eine bijektive Transformation mit der Umkehrabbildung  $X = T^{-1}(Y) = \frac{1}{5}(Y - 2)$ . Zusammen mit der Dichte  $p_X(x) = 2 \cdot e^{-2x} \cdot \mathbf{1}_{[0, \infty)}(x)$  der  $\text{Exp}_2$ -Verteilung erhalten wir für die Dichte  $p_Y(y)$  der transformierten Zufallsvariablen  $Y$

$$\begin{aligned} p_Y(y) &= p_X(T^{-1}(y)) \cdot (T^{-1})'(y) = 2 \cdot e^{-2(\frac{y}{5} - \frac{2}{5})} \cdot \mathbf{1}_{[0, \infty)}\left(\frac{1}{5}y - \frac{2}{5}\right) \cdot \frac{1}{5} \\ &= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2y}{5}} \cdot \mathbf{1}_{[2, \infty)}(y). \end{aligned}$$

## Beispiel II

Der Zufallsvektor  $\mathbf{x} \in \mathbb{R}^n$  habe eine beliebige Lebesgue-Dichte  $p_{\mathbf{x}}$ . Die Transformation  $\mathbf{T}$  sei linear und bijektiv, also von der Form  $\mathbf{y} = \mathbf{T}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$ . Wie lautet die Dichte von  $\mathbf{y}$ ?

### Lösung:

Unter obigen Voraussetzungen ist  $\mathbf{A}$  invertierbar. Also existiert die Umkehrfunktion, welche durch  $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})$  gegeben ist. Als Jacobi-Matrix erhält man  $J\mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}$ .

Die Anwendung der Transformationsformel 1.13 ergibt daher für die Dichte  $p_{\mathbf{y}}$  von  $\mathbf{y}$  den Ausdruck

$$p_{\mathbf{y}}(\mathbf{y}) = \frac{1}{|\det \mathbf{A}|} \cdot p_{\mathbf{x}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})),$$

wobei wir den Zusammenhang  $\det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$  benutzt haben.

## Beispiel III

Das nächste Beispiel wird als Übungsaufgabe gestellt:

**1.14 Aufgabe:** Es sei  $X$  eine Zufallsvariable, die  $\chi^2_2$ -verteilt ist.

- 1 Berechnen Sie die Lebesgue-Dichte der Zufallsvariable  $Y := \sqrt{X}$ .
- 2 Berechnen Sie die Wahrscheinlichkeit  $\mathbb{P}(Y > \frac{1}{2})$ .

# Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

**1.15 Satz:** Es sei  $\mathbf{x} := (x_1, x_2, \dots, x_n)^\top \in \mathbb{R}^n$  ein Zufallsvektor, dessen Komponenten  $x_i \in \mathbb{R}$  unabhängig und identisch standardnormalverteilt sind, d. h.  $x_i \sim \mathcal{N}(0, 1) \forall i \in \{1, \dots, n\}$ .

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$p_{\mathbf{x}}(\mathbf{x}) := \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

**Beweis:** Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$p_{\mathbf{x}}(\mathbf{x}) = \prod_{i=1}^n p_{x_i}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^n x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

□

# Multivariate Normalverteilung (Forts.)

Für die multivariate Standardnormalverteilung gilt  $\mathbb{E}[\mathbf{x}] = \mathbf{0}$  und  $\mathbb{D}[\mathbf{x}] = \mathbf{I}$ .

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren  $\boldsymbol{\mu} \in \mathbb{R}^n$  und Streuungsmatrizen  $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ . Wir fordern lediglich, dass die Streuungsmatrix  $\boldsymbol{\Sigma}$  *positiv definit* ist, dass also  $\mathbf{z}^\top \boldsymbol{\Sigma} \mathbf{z} > 0 \forall \mathbf{z} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$  gilt.

- 1 Aufgrund der positiven Definitheit von  $\boldsymbol{\Sigma}$  gibt es eine untere Dreiecksmatrix  $\mathbf{A}$  mit  $\boldsymbol{\Sigma} = \mathbf{A} \mathbf{A}^\top$  (Stichwort: **Cholesky-Zerlegung**).
- 2 Wir betrachten die Transformation  $\mathbf{y} := \mathbf{A} \mathbf{x} + \boldsymbol{\mu}$ . Es gilt

$$\mathbb{E}[\mathbf{y}] = \mathbb{E}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{E}[\mathbf{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \quad \text{und} \quad \mathbb{D}[\mathbf{y}] = \mathbb{D}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{D}[\mathbf{x}] \mathbf{A}^\top = \mathbf{A} \mathbf{A}^\top = \boldsymbol{\Sigma}.$$

- 3 Nun wenden wir die Transformationsformel 1.13 an, um die Dichte von  $\mathbf{y}$  zu bestimmen.

# Multivariate Normalverteilung (Forts.)

**Zu Schritt 3:** Es ist  $T^{-1}(x) = A^{-1}(y - \mu)$ . Mit Beispiel II zum Transformationssatz erhalten wir

$$|\det JT^{-1}(y)| = |\det A^{-1}| = \frac{1}{|\det A|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz die Identität

$\det \Sigma = \det(AA^T) = \det A \cdot \det A = \det^2 A$ . Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also  $|\det A| = (\det \Sigma)^{\frac{1}{2}}$ . Die Dichte  $p_y$  nimmt damit die Form

$$p_y(y) = \frac{1}{(\det \Sigma)^{\frac{1}{2}}} \cdot p_x(A^{-1}(y - \mu))$$

an, wobei  $p_x$  die Dichte der Standardnormalverteilung aus Satz 1.15 ist. Wir setzen dort

$x := A^{-1}(y - \mu)$ , sodass  $\|x\|^2 = (y - \mu)^T (A^{-1})^T A^{-1} (y - \mu) = (y - \mu)^T \Sigma^{-1} (y - \mu)$  gilt.

# Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

**1.16 Definition:** Es sei  $\mu \in \mathbb{R}^n$  ein Vektor und  $\Sigma \in \mathbb{R}^{n \times n}$  eine *positiv definite* Matrix.

Die Dichte der **multivariaten Normalverteilung**  $\mathcal{N}(\mu, \Sigma)$  ist gegeben durch

$$p_x(x) := \frac{1}{(2\pi)^{\frac{n}{2}} \cdot (\det \Sigma)^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

**Bemerkung:** Die positive Definitheit der Matrix  $\Sigma$  impliziert auch deren Invertierbarkeit (siehe hierzu Satz ??).

# Visualisierung: Multivariate Normalverteilung

tbd

# Partitionierte Normalverteilung

**1.17 Definition:** Es seien  $\mathbf{x} \in \mathbb{R}^d$  und  $\mathbf{y} \in \mathbb{R}^{(n-d)}$  zwei Zufallsvektoren. Wir fassen diese zu einem neuen Zufallsvektor  $\mathbf{z} := (\mathbf{x}^\top, \mathbf{y}^\top)^\top \in \mathbb{R}^n$  mit  $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  zusammen. Hierbei seien

$$\boldsymbol{\mu} := \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix} \quad \text{und} \quad \boldsymbol{\Sigma} := \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}.$$

Wir nennen dieses Modell **partitionierte Normalverteilung**.

**Bemerkungen:** Aus der Symmetrie von  $\boldsymbol{\Sigma}$  folgt die von  $\boldsymbol{\Sigma}_{xx}$  und  $\boldsymbol{\Sigma}_{yy}$ . Außerdem gilt  $\boldsymbol{\Sigma}_{xy} = \boldsymbol{\Sigma}_{yx}^\top$ .

Oft ist es einfacher mit der Inversen der Kovarianzmatrix zu arbeiten. Wir definieren daher  $\boldsymbol{\Lambda} := \boldsymbol{\Sigma}^{-1}$ . Man nennt diese Matrix **Präzisionsmatrix**.

# Bedingte Normalverteilung

**1.18 Satz:** Wir betrachten das Modell der partitionierten Normalverteilung aus Definition 1.17. Für die Zufallsvariable  $\mathbf{x} \mid \mathbf{y}$  gilt

$$\mathbf{x} \mid \mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{x} \mid \mathbf{y}}, \boldsymbol{\Sigma}_{\mathbf{x} \mid \mathbf{y}}),$$

wobei für die Parameter der folgende Zusammenhang gilt:

$$\boldsymbol{\mu}_{\mathbf{x} \mid \mathbf{y}} := \boldsymbol{\mu}_{\mathbf{x}} + \boldsymbol{\Sigma}_{\mathbf{xy}} \boldsymbol{\Sigma}_{\mathbf{yy}}^{-1} (\mathbf{y} - \boldsymbol{\mu}_{\mathbf{y}})$$



$$\boldsymbol{\Sigma}_{\mathbf{x} \mid \mathbf{y}} := \boldsymbol{\Sigma}_{\mathbf{xx}} - \boldsymbol{\Sigma}_{\mathbf{xy}} \boldsymbol{\Sigma}_{\mathbf{yy}}^{-1} \boldsymbol{\Sigma}_{\mathbf{yx}}.$$

Die Dichte dieser Verteilung bezeichnen wir mit  $p_{\mathbf{x} \mid \mathbf{y}}$ .

**Beweis:** Einen Beweis dieser Aussage finden Sie in **Bishop2006** auf den Seiten 85–87.



# Visualisierung: Bedingte Normalverteilung



**Abbildung:** Links: Zweidimensionale Normalverteilung. Rechts: Bedingte Verteilung in rot. Siehe **Bishop2024**, Seite 82.

# Aufgabe: Bedingte Normalverteilung

**1.19 Aufgabe:** Es sei  $\boldsymbol{\mu} := (0, 2)^\top \in \mathbb{R}^2$  und

$$\boldsymbol{\Sigma} := \begin{pmatrix} 0.3 & -1 \\ -1 & 5 \end{pmatrix} \in \mathbb{R}^{2 \times 2},$$

sodass die Verbunddichte von  $X_1$  und  $X_2$  gegeben ist durch  $p(X_1, X_2) := \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . Bestimmen Sie die Dichte der bedingten Verteilung  $p(X_1 \mid X_2 = -1)$ . Benutzen Sie hierzu die Formeln aus Satz 1.18.

# Normale Randverteilung

**1.20 Satz:** Erneut betrachten wir das Modell der partitionierten Normalverteilung aus Definition 1.17. Dann sind auch die Randverteilungen von  $\mathbf{x}$  und  $\mathbf{y}$  normalverteilt. Es gilt genauer

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

Die Dichten der Randverteilung bezeichnen wir mit  $p_x$  und  $p_y$ .



**Beweis:** Man erhält dieses Ergebnis durch **Marginalisierung** der Verbunddichte, d. h. wir integrieren über alle Variablen, die uns nicht interessieren. Für die Randverteilung von  $\mathbf{x}$  gilt zum Beispiel

$$p_x(\mathbf{x}) = \int p_{x,y}(\mathbf{x}, \mathbf{y}) d\mathbf{y}.$$

Einen ausführlichen Beweis finden Sie in **Bishop2006** auf den Seiten 88–89.

□

# Visualisierung: Normale Randverteilung



**Abbildung:** Links: Zweidimensionale Normalverteilung. Rechts: Randverteilung für  $x_a$  in blau. Siehe **Bishop2024**, Seite 82.

# Aufgabe: Normale Randverteilung

**1.21 Aufgabe:** Betrachten Sie erneut die Verbunddichte  $p(X_1, X_2)$  wie sie in Aufgabe 1.19 definiert wurde.

Wie lautet die Dichte der Randverteilung  $p(X_1)$ ?

# Satz von Bayes für Normalverteilungen

**1.22 Satz:** Es seien  $x$  und  $y$  Zufallsvektoren, sodass gilt

$$x \sim \mathcal{N}(\mu, \Sigma) \quad \text{und} \quad y | x \sim \mathcal{N}(Ax, \Lambda).$$

Dann gilt für die Verteilungen von  $y$  und  $x | y$

$$y \sim \mathcal{N}(A\mu, A\Sigma A^\top + \Lambda)$$

$$x | y \sim \mathcal{N}(\Gamma[\Sigma^{-1}\mu + A^\top \Lambda^{-1}y], \Gamma).$$

Hierbei ist  $\Gamma := (\Sigma^{-1} + A^\top \Lambda^{-1} A)^{-1}$ .

**Beweis:** Einen Beweis dieser Aussage findet Sie in **Bishop2006** auf den Seiten 90–93.

□

# Maximum-Likelihood Methode

- Im Folgenden sei ein Beobachtungsvektor  $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top$  bestehend aus  $N$  *unabhängig und identisch verteilten* (Englisch: *independent and identically distributed* - i.i.d.) Datenpunkten gegeben.
- Wir möchten Aussagen über die Parameter  $\boldsymbol{\theta} := (\theta_1, \theta_2, \dots, \theta_M)^\top$  der zugrundeliegenden Verteilung machen.
- Dies erledigen wir durch eine Punktschätzung des Parametervektors  $\boldsymbol{\theta}$ . Den Schätzer für  $\boldsymbol{\theta}$  bezeichnen wir mit  $\hat{\boldsymbol{\theta}}$ .
- Eine der am häufigsten angewendete Methode ist die **Maximum-Likelihood Methode**, die wir im Folgenden näher beleuchten werden.

# (Log-)Likelihood Funktion

Der Maximum-Likelihood Schätzer  $\hat{\theta}_{ML}$  für den Parametervektor  $\theta$  maximiert die Likelihood Funktion.

**1.23 Definition:** Es sei  $p(\mathbf{x}; \theta)$  die Dichte eines Zufallsvektors  $\mathbf{x} \in \mathbb{R}^N$ , welche durch den Parametervektor  $\theta \in \Theta$  parametrisiert wird. Die **Likelihood Funktion**  $L : \Theta \rightarrow \mathbb{R}$  ist dann definiert als

$$L(\theta) := p(\mathbf{x}; \theta) = p(x_1, x_2, \dots, x_N; \theta).$$

Häufig ist es einfacher, die **Log-Likelihood Funktion**  $l(\theta) := \ln p(\mathbf{x}; \theta)$  zu betrachten. Wir definieren  $\hat{\theta}_{ML} := \arg \max_{\theta} l(\theta)$ .

**Bemerkung:** Der Schätzer  $\hat{\theta}_{ML}$  maximiert sowohl  $L$  als auch  $l$ . (Warum?)

## (Log-)Likelihood Funktion (Forts.)

- Im Allgemeinen kann es schwer sein, die Likelihood Funktion zu bestimmen (*vor allem wenn die Beobachtungen voneinander abhängen*).
- Die Annahme der **Unabhängigkeit der Beobachtungen** vereinfacht dies maßgeblich, denn

$$\begin{aligned} L(\theta) &= p(x_1, x_2, \dots, x_N; \theta) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot \dots \cdot p(x_N; \theta) \\ &= \prod_{n=1}^N p(x_n; \theta). \end{aligned}$$

- Für die Log-Likelihood Funktion ergibt sich durch Anwendung der Logarithmengesetze

$$l(\theta) = \ln \prod_{n=1}^N p(x_n; \theta) = \sum_{n=1}^N \ln p(x_n; \theta).$$

# Maximum-Likelihood Gleichung

- Falls die Likelihood Funktion differenzierbar ist, so erfüllt der Maximum-Likelihood Schätzer  $\hat{\theta}_{ML}$  notwendig die **Likelihood Gleichung**

$$\left. \frac{\partial}{\partial \theta} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = \mathbf{0}.$$

- Diese sagt aus, dass  $\hat{\theta}_{ML}$  ein *stationärer Punkt der (Log-)Likelihood Funktion* sein muss.
- Es handelt sich dabei um ein System von  $M$ , im Allgemeinen nicht-linearen, Gleichungen der Form

$$\left. \frac{\partial}{\partial \theta_j} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = 0 \quad j = 1, 2, \dots, M.$$

**Achtung:** Es muss noch überprüft werden, ob  $\hat{\theta}_{ML}$  tatsächlich ein Maximum darstellt.

# Beispiel I: Binomialverteilung

**1.24 Satz:** Es sei die binomialverteilte Zufallsvariable  $X$  (Anzahl der Erfolge) und der Stichprobenumfang  $N$  gegeben. Der Maximum-Likelihood Schätzer  $\hat{\theta}_{ML}$  für die unbekannte Erfolgswahrscheinlichkeit  $\theta \in (0, 1)$  lautet  $\hat{\theta}_{ML} = \frac{k}{N}$ , wobei  $k$  die Anzahl der beobachteten Erfolge in der Stichprobe ist.

**Beweis:** Die Likelihood Funktion ist gegeben durch  $L(\theta) = \binom{N}{k} \cdot \theta^k \cdot (1 - \theta)^{N-k}$ . Wir wenden den Logarithmus an und erhalten die Log-Likelihood Funktion

$$l(\theta) = \ln \binom{N}{k} + k \cdot \ln \theta + (N - k) \cdot \ln(1 - \theta).$$

Diese leiten wir nach  $\theta$  ab und setzen sie Null. Auflösen nach  $\theta$  ergibt schließlich

$$\frac{d}{d\theta} l(\theta) = \frac{k}{\theta} - \frac{N - k}{1 - \theta} \stackrel{!}{=} 0 \iff \hat{\theta}_{ML} = \frac{k}{N}.$$

Wir prüfen noch das Vorzeichen der zweiten Ableitung. Es ist  $\frac{d^2}{d\theta^2} l(\theta) = -\frac{k}{\theta^2} - \frac{N-k}{(1-\theta)^2} < 0 \forall \theta \in (0, 1)$ , sodass  $\hat{\theta}_{ML}$  tatsächlich ein Maximum ist. Es handelt sich sogar um ein global eindeutiges Maximum. □

## Beispiel II: Normalverteilung

**1.25 Satz:** Es seien  $\mathbf{x} = (x_1, x_2, \dots, x_N)^\top$  *unabhängig und identisch normalverteilte* Beobachtungen mit unbekanntem Erwartungswert  $\mu \in \mathbb{R}$  und unbekannter Varianz  $\sigma^2 > 0$ . Der Parametervektor  $\theta$  ist in diesem Fall zweielementig und gegeben durch  $\theta := (\mu, \sigma^2)^\top$ .

Die Maximum-Likelihood Schätzer  $\hat{\mu}_{ML}$  und  $\hat{\sigma}_{ML}^2$  für die unbekannten Parameter  $\mu$  und  $\sigma^2$  werden in diesem Fall bestimmt mittels

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^n x_n \quad \text{und} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2.$$

**Beweis:** Die Dichte der Produktverteilung lautet aufgrund der Unabhängigkeit der Beobachtungen

$$p(\mathbf{x}; \mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \frac{1}{\sigma^N} \cdot \exp\left(-\frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}\right).$$

Aufgrund der auftretenden Exponentialverteilung bietet sich die Betrachtung der Log-Likelihood Funktion an. Wir erhalten

$$l(\mu, \sigma^2) = -\frac{N}{2} \cdot \ln(2\pi) - N \ln(\sigma) - \frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}.$$

Nun berechnen wir die partiellen Ableitungen von  $l$  nach  $\mu$  und  $\sigma^2$ . Es ist

$$\frac{\partial}{\partial \mu} l(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) \quad \text{und} \quad \frac{\partial}{\partial \sigma^2} l(\mu, \sigma^2) = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=1}^N (x_n - \mu)^2.$$

Durch Nullsetzen und auflösen erhalten wir die im Satz angegebenen Maximum-Likelihood Schätzer  $\hat{\mu}_{ML}$  und  $\hat{\sigma}_{ML}^2$ . Es bleibt noch zu zeigen, dass es sich tatsächlich um ein Maximum handelt. Man rechnet nach, dass die Hesse-Matrix von  $l(\mu, \sigma^2)$  and der Stelle  $(\hat{\mu}_{ML}, \hat{\sigma}_{ML}^2)$  gegeben ist durch

$$\nabla^2 l(\mu, \sigma^2) = \begin{pmatrix} -\frac{N}{\hat{\sigma}_{ML}^2} & 0 \\ 0 & -\frac{N}{(\hat{\sigma}_{ML}^2)^2} \end{pmatrix}.$$

Diese Matrix ist negativ definit, weshalb wir tatsächlich ein Maximum gefunden haben. □

# Erwartungstreue Schätzer

Wir definieren den Begriff der Erwartungstreue:

**1.26 Definition:** Wir nennen einen Schätzer  $\hat{\theta}$  **erwartungstreu**, falls  $\mathbb{E}[\hat{\theta}] = \theta$  gilt.

- Der Schätzer  $\hat{\mu}_{ML}$  ist erwartungstreu für den Erwartungswert  $\mu$  im Normalverteilungsmodell

**Beweis:** Es gilt

$$\mathbb{E}[\hat{\mu}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \cdot N \cdot \mu = \mu.$$

□

- Demgegenüber ist  $\hat{\sigma}_{ML}^2$  **nicht** erwartungstreu. Man kann diesen Schätzer jedoch durch eine geeignete Transformation zu einem erwartungstreuen Schätzer machen. Dies führt auf die **empirische Varianz**  $\frac{N}{N-1} \hat{\sigma}_{ML}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2$ .

# Aufgabe zur Maximum-Likelihood Schätzung

**1.27 Aufgabe:** Gegeben seien die  $N$  Beobachtungen  $x_1, x_2, \dots, x_N$ , wobei  $x_n \in \mathbb{N}$ ,  $n = 1, 2, \dots, N$ . Sie legen den Daten eine Poisson-Verteilung zugrunde. Diese hat die Dichte

$$p(x) := e^{-\lambda} \cdot \frac{\lambda^x}{x!}.$$

- 1 Bestimmen Sie den Maximum-Likelihood Schätzer  $\hat{\lambda}_{ML}$  für die Poisson-Verteilung. Vergessen Sie dabei nicht zu überprüfen, ob es sich tatsächlich um ein Maximum handelt.
- 2 Prüfen Sie den Schätzer auf Erwartungstreue.

# Erwartete quadratische Abweichung (MSE)

Ein weiteres Qualitätsmerkmal eines Schätzers  $\hat{\theta}$  ist seine erwartete quadratische Abweichung vom wahren Parameter  $\theta$ .

**1.28 Definition:** Die **erwartete quadratische Abweichung** von  $\hat{\theta}$  zu  $\theta$  ist

$$\text{MSE}[\hat{\theta}, \theta] = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Die  $\text{MSE}[\hat{\theta}, \theta]$  reduziert sich für erwartungstreue Schätzer  $\hat{\theta}$  auf die Varianz  $\mathbb{V}[\hat{\theta}]$ .

**Beweis:** Man rechnet nach, dass  $\text{MSE}[\hat{\theta}, \theta] = \mathbb{V}[\hat{\theta}] + (\mathbb{E}[\hat{\theta}] - \theta)^2$  gilt (multipliziere hierzu aus und nutze die Linearität des Erwartungswerts). Der zweite Summand (Quadrat der Verzerrung/Bias) verschwindet aber für erwartungstreue Schätzer, da  $\mathbb{E}[\hat{\theta}] = \theta$  gilt. Es folgt die Behauptung. □

# Maximum-Aposteriori Schätzer (MAP)

- ML Schätzer laufen Gefahr, sich übermäßig stark an die Daten anzupassen (**Overfitting**).
- Wir erweitern daher das Konzept der ML Schätzung, indem wir zusätzlich eine *Apriori-Verteilung* für die zu schätzenden Parameter mit einbeziehen.
- Wir nutzen den Satz von Bayes, um damit zusammen mit der Likelihood eine *Aposteriori-Verteilung* über die Parameter zu erhalten.
- Ein Schätzer  $\hat{\theta}_{MAP}$  heißt **Maximum-Aposteriori Schätzer** für den Parameter  $\theta$ , falls dieser die Aposteriori-Wahrscheinlichkeit maximiert.

# Binäre Variablen

- Wir betrachten eine binäre Zufallsvariable  $X \in \{0, 1\}$ , z. B. das Werfen einer (unfairen) Münze, wobei  $X = 1$  Kopf und  $X = 0$  Zahl bedeutet.
- Die Zufallsvariable  $X$  ist damit **Bernoulli-verteilt** mit der Dichte

$$p_X(k) := \mu^k \cdot (1 - \mu)^{1-k}.$$

- Es gilt

$$\mathbb{E}[X] = \mu$$

$$\mathbb{V}[X] = \mu \cdot (1 - \mu).$$

**1.29 Aufgabe:** Beweisen Sie die Aussagen  $\mathbb{E}[X] = \mu$  und  $\mathbb{V}[X] = \mu \cdot (1 - \mu)$ .

# Maximum Likelihood für die Bernoulli-Verteilung

- Wir gehen nun davon aus, dass  $N$  unabhängige Bernoulli-verteilte Zufallsvariablen  $X_1, X_2, \dots, X_N$  vorliegen.
- Dann ist die Likelihood Funktion für  $\mu$  gegeben durch

$$L(\mu) = \prod_{n=1}^N p_{X_n}(k_n) = \prod_{n=1}^N \mu^{k_n} \cdot (1 - \mu)^{1-k_n}.$$

- Hieraus ergibt sich die Log-Likelihood Funktion

$$l(\mu) = \sum_{n=1}^N \ln p_{X_n}(k_n) = \sum_{n=1}^N [k_n \ln \mu + (1 - k_n) \cdot \ln(1 - \mu)] = \ln \mu \sum_{n=1}^N k_n + \ln(1 - \mu) \left( N - \sum_{n=1}^N k_n \right).$$

- Wir sehen, dass die Log-Likelihood Funktion nur über die Statistik  $Y := \sum_{n=1}^N X_n$  von den Beobachtungen abhängt. Man nennt  $Y$  daher eine **suffiziente Statistik**.

# Maximum Likelihood für die Bernoulli-Verteilung

- Leiten wir  $l(\mu)$  nach  $\mu$  ab und setzen Null, so erhalten wir den Maximum-Likelihood Schätzer als arithmetisches Mittel der Beobachtungen

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N k_n.$$

- Schreiben wir für die Anzahl der Erfolge (Kopf)  $m := \sum_{n=1}^N k_n$ , so ist  $\hat{\mu}_{ML} = \frac{m}{N}$ .
- Werfen wir die Münze drei Mal und erhalten jedes Mal Kopf, so wäre  $\hat{\mu}_{ML} = 1$  (**Overfitting**).
- Die Zufallsvariable  $Y := X_1 + X_2 + \dots + X_N$  ist dann aufgrund der Unabhängigkeit der  $X_n$  **binomial-verteilt**, sodass gilt

$$\mathbb{P}(Y = m) := \binom{N}{m} \cdot \mu^m \cdot (1 - \mu)^{N-m}.$$

# Beta-Verteilung

Um die Overfitting-Problematik zu adressieren, führen wir einen Beta-verteilten Prior ein.

**1.30 Definition:** Es sei  $X$  eine **Beta-verteilte** Zufallsvariable, in Notation  $X \sim \beta_{a,b}$ , mit den Parametern  $a, b > 0$ . Die Dichte der Verteilung ist gegeben durch

$$p_X(\xi) = \frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi).$$

**Bemerkung:**  $\Gamma(x)$  ist hierbei die **Gamma-Funktion**. Es gilt  $\Gamma(x) := \int_0^\infty u^{x-1} e^{-u} du$ . Mithilfe partieller Integration kann man den Zusammenhang  $\Gamma(x+1) = x \cdot \Gamma(x)$  zeigen. Außerdem gilt  $\Gamma(1) = 1$ . Daraus folgt  $\Gamma(n+1) = n!$  für  $n \in \mathbb{N}$ . Somit ist die Gamma-Funktion die kontinuierliche Fortsetzung der Fakultäts-Funktion.

# Visualisierung: Beta-Verteilung

tbd

# Bestimmung des Posteriors

- Um den Posterior zu erhalten, multiplizieren wir nun den Beta-verteilten Prior mit der binomial-verteilten Likelihood.
- Ignorieren wir alle Terme, die nicht von  $\mu$  abhängen, so erhalten wir für den Posterior den Ausdruck

$$p(\mu \mid m, l; a, b) \propto \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1}, \quad (1.1)$$

wobei  $l := N - m$  die Anzahl der Misserfolge (Zahl) ist.

- Da Prior und Likelihood dieselbe funktionale Form haben, ist *auch der Posterior wieder Beta-verteilt*, wobei sich der Normierungsfaktor durch Vergleich mit Definition 1.30 ergibt

$$p(\mu \mid m, l; a, b) = \frac{\Gamma(m + a + l + b)}{\Gamma(m + a) \cdot \Gamma(l + b)} \cdot \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1}$$

- Diese Eigenschaft nennt man **Konjugiertheit**.

# Literatur