

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Probabilistische PCA

Kapitel

① Probabilistische PCA

PPCA Modell

PCA als latent Variable Model

- Wir modellieren die Repräsentation der Daten im Principal Subspace als latente Variablen $z \in \mathbb{R}^D$.
- Für die Verteilung von z gelte

$$z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (1.1)$$

- Zudem führen wir die bedingte Verteilung von $x \in \mathbb{R}^M$ gegeben z wie folgt ein

$$x \mid z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (1.2)$$

- Die Spalten der Matrix $\mathbf{W} \in \mathbb{R}^{M \times D}$ spannen hierbei den Principal Subspace auf.
- Es ist $\boldsymbol{\mu} \in \mathbb{R}^M$.
- Der Parameter σ^2 beeinflusst die Varianz der bedingten Verteilung (1.2).

PPCA als generatives Modell

Die PPCA kann als *generatives Modell* aufgefasst werden:

- Zunächst wählen wir ein z gemäß (1.1).
- Dann ziehen wir die beobachtete Variable x aus der Verteilung (1.2).
- Hierbei ergibt sich der Wert für x gemäß

$$x = Wz + \mu + \varepsilon. \quad (1.3)$$

- $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ ist hierbei *additives normalverteiltes Datenrauschen*, welches durch den Parameter σ^2 in (1.2) beeinflusst wird.

Das Mapping der Daten in den Principal Subspace erhalten wir mit dem Satz von Bayes.

PPCA als generatives Modell




Abbildung: PPCA als generatives Modell. Siehe **Bishop2006**, Seite 572.

Bestimmung der Verbunddichte

- Für die weiteren Ausführungen benötigen wir die Verbunddichte $p(\mathbf{z}, \mathbf{x})$ der beobachteten und latenten Variablen.
- Mit der Produktregel für Wahrscheinlichkeiten ist

$$p(\mathbf{z}, \mathbf{x}) = n(\mathbf{x} | \mathbf{z}) \cdot n(\mathbf{z}). \quad (1.4)$$

- Da es sich bei um ein Produkt von Normalverteilungen handelt, sind die Zufallsvariablen auch gemeinsam normalverteilt.
- Es ist also $p(\mathbf{z}, \mathbf{x}) = n(\mathbf{z}, \mathbf{x}; \boldsymbol{\nu}, \boldsymbol{\Sigma})$ beziehungsweise

$$\begin{pmatrix} \mathbf{z} \\ \mathbf{x} \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\nu}, \boldsymbol{\Sigma}). \quad (1.5)$$

Bestimmung der Verbunddichte (Forts.)

Wir bestimmen zunächst den Parameter ν :

- Mit der Linearität des Erwartungswerts und den obigen Definitionen – insbesondere die Definitionen (1.1) und (1.3) – gilt

$$\mathbb{E}[\mathbf{z}] = \mathbf{0}$$

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}[\mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\varepsilon}] = \mathbf{W} \underbrace{\mathbb{E}[\mathbf{z}]}_{=\mathbf{0}} + \mathbb{E}[\boldsymbol{\mu}] + \underbrace{\mathbb{E}[\boldsymbol{\varepsilon}]}_{=\mathbf{0}} = \boldsymbol{\mu}.$$

- Zusammenfassend gilt also

$$\boldsymbol{\nu} = \mathbb{E} \left[\begin{pmatrix} \mathbf{z} \\ \mathbf{x} \end{pmatrix} \right] = \begin{pmatrix} \mathbb{E}[\mathbf{z}] \\ \mathbb{E}[\mathbf{x}] \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ \boldsymbol{\mu} \end{pmatrix}. \quad (1.6)$$

Bestimmung der Verbunddichte (Forts.)

Nun bestimmen wir den Parameter $\Sigma = \begin{pmatrix} \Sigma_{zz} & \Sigma_{zx} \\ \Sigma_{xz} & \Sigma_{xx} \end{pmatrix}$:

- Zunächst ist $\Sigma_{zz} = \mathbb{E}[(z - \mathbb{E}[z])(z - \mathbb{E}[z])^\top] = \mathbb{E}[zz^\top] = \mathbb{D}[z] = I$.
- Ferner ist

$$\begin{aligned}\Sigma_{zx} &= \mathbb{E}[(z - \mathbb{E}[z])(x - \mathbb{E}[x])^\top] \\ &= \mathbb{E}[z(Wz + \mu + \varepsilon - \mathbb{E}[Wz + \mu + \varepsilon])^\top] \\ &= \mathbb{E}[z(Wz + \varepsilon)^\top] = \mathbb{E}[zz^\top W^\top + z\varepsilon^\top] = \mathbb{E}[zz^\top]W^\top + \mathbb{E}[z] \cdot \mathbb{E}[\varepsilon^\top] \\ &= W^\top.\end{aligned}$$

- Aus Symmetriegründen gilt $\Sigma_{xz} = W$.

Bestimmung der Verbunddichte (Forts.)

1.1 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{xx} = \mathbf{W}\mathbf{W}^\top + \sigma^2\mathbf{I}$ gilt.

Zusammenfassend erhalten wir für die gemeinsame Verteilung von z und x also

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\nu, \Sigma)$$
$$\nu := \begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix} \tag{1.7}$$
$$\Sigma := \begin{pmatrix} \mathbf{I} & \mathbf{W}^\top \\ \mathbf{W} & \mathbf{W}\mathbf{W}^\top + \sigma^2\mathbf{I} \end{pmatrix}.$$

Woodbury Matrix-Identität

1.2 Satz: Es gilt die **Woodbury Matrix-Identität**

$$(A + BD^{-1}E)^{-1} = A^{-1} - A^{-1}B(D + EA^{-1}B)^{-1}EA^{-1},$$

wobei A , B , D und E Matrizen geeigneter Form sind.

Beweis: Der Beweis erfolgt durch Nachrechnen, indem man beide Seiten der Gleichung mit $A + BD^{-1}E$ multipliziert und die rechte Seite zur Einheitsmatrix umformt. □

Bestimmung des Posteriors

- Für die Anwendung des EM-Algorithmus benötigen wir die Dichte $p(\mathbf{z} \mid \mathbf{x}) = n(\mathbf{z} \mid \mathbf{x}; \boldsymbol{\mu}_{\mathbf{z} \mid \mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{z} \mid \mathbf{x}})$.
- Diese können wir aus der Verbundverteilung (1.7) mittels Satz ?? berechnen.
- Zunächst definieren wir zwei Matrizen, die wir häufig benötigen werden

$$\mathbf{C} := \sigma^2 \mathbf{I} + \mathbf{W}\mathbf{W}^\top \quad (1.8)$$

$$\mathbf{M} := \sigma^2 \mathbf{I} + \mathbf{W}^\top \mathbf{W}. \quad (1.9)$$

- Außerdem benötigen wir $\mathbf{C}^{-1}$, für deren Berechnung wir die Woodbury Identität aus 1.2 benutzen, wobei wir $\mathbf{A} = \sigma^2 \mathbf{I}$, $\mathbf{B} = \mathbf{W}$, $\mathbf{D} = \mathbf{I}$ und $\mathbf{E} = \mathbf{W}^\top$ setzen (siehe nächste Folie).

Bestimmung des Posteriors (Forts.)

Es ist

$$\begin{aligned}
 \mathbf{C}^{-1} &= (\sigma^2 \mathbf{I} + \mathbf{W}\mathbf{W}^\top)^{-1} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{I} \mathbf{W} (\mathbf{I} + \mathbf{W}^\top \sigma^{-2} \mathbf{I} \mathbf{W})^{-1} \mathbf{W}^\top \sigma^{-2} \mathbf{I} && \text{Woodbury Identität, Satz 1.2.} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \left[\sigma^{-2} (\sigma^2 \mathbf{I} + \mathbf{W}^\top \mathbf{W}) \right]^{-1} \sigma^{-2} \mathbf{W}^\top && \text{In der Klammer } \sigma^{-2} \text{ ausklammern.} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \left[\sigma^{-2} \mathbf{M} \right]^{-1} \sigma^{-2} \mathbf{W}^\top && \text{Definition (1.9).} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \sigma^2 \mathbf{M}^{-1} \sigma^{-2} \mathbf{W}^\top && \text{Für } \mathbf{A} \text{ und } \mathbf{B} \text{ gilt } (\mathbf{A}\mathbf{B})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}. \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^\top. && \sigma^{-2} \sigma^2 = 1.
 \end{aligned}
 \tag{1.10}$$

Literatur