Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

Inhaltsverzeichnis

1 **Grundlagen der Statistik**

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ω ist der **Ereignisraum**, also die Menge aller Elemantarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir $\Omega := \{1, 2, 3, 4, 5, 6\}$.
- Mit $\mathcal{A}$ bezeichnen wir die zugehörige **Sigma-Algebra**, einer Menge von Teilmengen von Ω. Im einfachsten Fall könnten wir $\mathcal{A} := \text{Pot}(\Omega)$ wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra $\mathbb{B}$ auf $\mathbb{R}$ heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \to [0, 1]$ ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus $\mathcal{A}$ eine Wahrscheinlichkeit zuordnet.

Zufallsvariablen

Im Folgenden sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{B})$ ein messbarer Raum.

1.1 Definition: Die Abbildung $x : \Omega \to \mathcal{X}$ heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : x^{-1}(B) := \{\omega \in \Omega : x(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von B unter x muss also eine messbare Menge in $\mathcal{A}$ sein, der durch $\mathbb{P}$ eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable $x : \Omega \to \mathcal{X}$ die Funktion

$$\mathbb{P}^x : \mathcal{B} \to [0, 1] \qquad \text{mit} \qquad B \mapsto \mathbb{P}(x^{-1}(B))$$

die **Verteilung** der Zufallsvariablen x. $\mathbb{P}^x$ ist das **Bildmaß** von $\mathbb{P}$ unter x.

Zufallsvariablen (Forts.)

Sei $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$ ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße $x : \Omega \to \mathcal{X}$ ist *verteilt gemäß* $\mathbb{Q}$ oder kurz $\mathbb{Q}$-*verteilt*, falls es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\mathbb{P}^x = \mathbb{Q}$ gilt.

Beispiele:

- x ist N_{μ,σ^2}-verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\forall B \in \mathbb{B} : \mathbb{P}(x \in B) = N_{\mu,\sigma^2}(B)$. Wir schreiben kurz $x \sim N_{\mu,\sigma^2}$.
-

Wahrscheinlichkeitsdichten

In der Regel wollen wir mit Dichten rechnen:

1.2 Definition: Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{B}, \mathbb{P}^x)$ Wahrscheinlichkeitsräume. Dabei ist $\mathbb{P}^x$ die Verteilung der Zufallsvariablen $x : \Omega \to \mathcal{X}$. Wir nennen eine nichtnegative Funktion

$$p_x : \mathbb{R} \to [0, 1]$$

eine **(Wahrscheinlichkeits-)Dichte** von $\mathbb{P}^x$, falls

$$\mathbb{P}^x(B) = \int_B p_x(\xi)\, \mathrm{d}\xi \qquad \forall B \in \mathcal{B}.$$

Die Wahrscheinlichkeiten der Mengen $B \in \mathcal{B}$ müssen sich also allesamt als Integral der Dichte p_x darstellen lassen können.

Erwartungswert von Zufallsvariablen

1.3 Definition: Sei x eine Zufallsvariable. Wir definieren den **Erwartungswert** (1. Moment) von x als

$$\mathbb{E}[x] := \int_{\mathbb{R}} \xi \cdot p_x(\xi)\, \mathrm{d}\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen x und y und eine beliebige aber feste Zahl $a \in \mathbb{R}$ (keine Zufallsvariable!) gelten

$$\mathbb{E}[x + y] = \mathbb{E}[x] + \mathbb{E}[y] \qquad \text{und} \qquad \mathbb{E}[a \cdot x] = a \cdot \mathbb{E}[x].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)^\top$ als $\mathbb{E}[\boldsymbol{x}] = (\mathbb{E}[x_1], \mathbb{E}[x_2], \ldots, \mathbb{E}[x_n])^\top$.

Varianz von Zufallsvariablen

1.4 Definition: Die Varianz einer Zufallsvariablen x ist definiert als die erwartete quadratische Abweichung vom Erwartungswert, also

$$\mathbb{V}[x] := \mathbb{E}\big[(x - \mathbb{E}[x])^2\big] = \int_{\mathbb{R}} (\xi - \mathbb{E}[x])^2 \cdot p_x(\xi)\, \mathrm{d}\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[x] &= \mathbb{E}\big[(x - \mathbb{E}[x])^2\big] = \mathbb{E}\big[x^2 - 2x \cdot \mathbb{E}[x] + (\mathbb{E}[x])^2\big] \\ &= \mathbb{E}[x^2] - 2(\mathbb{E}[x])^2 + (\mathbb{E}[x])^2 \\ &= \mathbb{E}[x^2] - (\mathbb{E}[x])^2\end{aligned}$$

Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen:

- Die Varianz ist **nicht** linear. Seien x und y reelle Zufallsvariablen und $a \in \mathbb{R}$ beliebig aber fest.
  - Es gilt $\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$ nur, wenn x und y unkorreliert sind (Satz von Bienaymé).
  - $\mathbb{V}[a \cdot x] = a^2 \cdot \mathbb{V}[x]$

Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

1.5 Definition: Es seien $x \in \mathbb{R}$ und $y \in \mathbb{R}$ reelle Zufallsvariablen mit den Verteilungen $\mathbb{P}^x, \mathbb{P}^y$ und den Dichten p_x bzw. p_y.

x und y heißen **stochastisch unabhängig** genau dann wenn $p_{x,y} := p_x \cdot p_y$ eine Produktdichte der Verteilung $\mathbb{P}^{x,y}$ ist, d. h. die gemeinsame Dichte von x und y ergibt sich als Produkt der Einzeldichten.

Bemerkung: Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. Die Umkehrung gilt im Allgemeinen nicht. Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als Unkorreliertheit.

Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

Name der Verteilung	$\mathbb{P}^x$	Zähldichte $p_x(k)$	$\mathbb{E}[x]$	$\mathbb{V}[x]$
Binomialverteilung	$B_{n,p}$	$\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Hypergeometrische Verteilung	$H_{n,K,N}$	$\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \cdot \frac{K}{N}$	$n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$
Poisson-Verteilung	P_λ	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	λ	λ

Absolutstetige Verteilungen

Name der Verteilung	$\mathbb{P}^x$	Lebesgue-Dichte $p_x(\xi)$	$\mathbb{E}[x]$	$\mathbb{V}[x]$
Normalverteilung	N_{μ,σ^2}	$\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gammaverteilung	$\Gamma_{\lambda,r}$	$\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0,\infty)}(\xi)$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$
Chiquadrat-Verteilung	χ^2_f	$\frac{1}{2^{\frac{f}{2}} \cdot \Gamma\left(\frac{f}{2}\right)} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0,\infty)}(\xi)$	f	$2 \cdot f$
Exponentialverteilung	Exp_λ	$\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0,\infty)}(\xi)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Betaverteilung	$\beta_{a,b}$	$\frac{\Gamma(a+b)}{\Gamma(a)\cdot\Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi)$	$\frac{a}{a+b}$	$\frac{a\cdot b}{(a+b)^2\cdot(a+b+1)}$
Gleichverteilung	$U_{(a,b)}$	$\frac{1}{b-a} \cdot \mathbf{1}_{(a,b)}(\xi)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Transformationssatz für Lebesgue-Dichten

1.6 Satz: Es seien $\boldsymbol{x}$ und $\boldsymbol{y}$ n-dimensionale Zufallsvektoren mit dem Zusammenhang

$$\boldsymbol{y} = \boldsymbol{T}(\boldsymbol{x}).$$

Die Abbildung $\boldsymbol{T} : \mathbb{R}^n \to \mathbb{R}^n$ sei *bijektiv*, sodass die Umkehrabbildung $\boldsymbol{x} = \boldsymbol{T}^{-1}(\boldsymbol{y})$ existiert und eindeutig ist. Dann gilt für die Dichte $p_{\boldsymbol{y}}$ der transformierten Zufallsvariablen $\boldsymbol{y}$

$$p_{\boldsymbol{y}}(\boldsymbol{\gamma}) = p_{\boldsymbol{x}}(\boldsymbol{T}^{-1}(\boldsymbol{\gamma})) \cdot \left|\det J\boldsymbol{T}^{-1}(\boldsymbol{\gamma})\right|,$$

wobei $p_{\boldsymbol{x}}$ die Dichte von $\boldsymbol{x}$ und $J\boldsymbol{T}^{-1}$ die Jacobi-Matrix der Abbildung $\boldsymbol{T}^{-1}$ bezeichnet.

Beweis: Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

Beispiel I

Es sei $x \sim Exp_2$ eine reellwertige exponentialverteilte Zufallsvariable mit Ankunftsrate $\lambda = 2$. Gesucht ist die Dichte der Zufallsvariablen $y := 5x + 2$.

Lösung: Es ist $T(x) := 5x + 2$ eine bijektive Transformation mit der Umkehrabbildung $x = T^{-1}(y) = \frac{1}{5}(y - 2)$. Zusammen mit der Dichte $p_x(\xi) = 2 \cdot e^{-2\xi} \cdot \mathbf{1}_{[0,\infty)}(\xi)$ der Exp_2-Verteilung erhalten wir für die Dichte $p_y(\gamma)$ der transformierten Zufallsvariablen y

$$
\begin{aligned}
p_y(\gamma) &= p_x(T^{-1}(\gamma)) \cdot (T^{-1})'(\gamma) \\
&= 2 \cdot e^{-2\left(\frac{\gamma}{5} - \frac{2}{5}\right)} \cdot \mathbf{1}_{[0,\infty)}\left(\frac{1}{5}\gamma - \frac{2}{5}\right) \cdot \frac{1}{5} \\
&= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2\gamma}{5}} \cdot \mathbf{1}_{[2,\infty)}(\gamma).
\end{aligned}
$$

Beispiel II

Der Zufallsvektor $\boldsymbol{x} \in \mathbb{R}^n$ habe eine beliebige Lebesgue-Dichte $p_{\boldsymbol{x}}$. Die Transformation $\boldsymbol{T}$ sei linear und bijektiv, also von der Form $\boldsymbol{y} = \boldsymbol{T}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$. Insbesondere ist $\boldsymbol{A}$ in diesem Fall invertierbar. Dann existiert die Umkehrfunktion und ist gegeben durch $\boldsymbol{x} = \boldsymbol{T}^{-1}(\boldsymbol{y}) = \boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{b})$. Als Jacobi-Matrix erhält man $J\boldsymbol{T}^{-1}(\boldsymbol{\gamma}) = \boldsymbol{A}^{-1}$.

Die Anwendung der Transformationsformel **??** ergibt daher für die Dichte $p_{\boldsymbol{y}}$ von $\boldsymbol{y}$ den Ausdruck

$$p_{\boldsymbol{y}}(\boldsymbol{\gamma}) = \frac{1}{|\det \boldsymbol{A}|} \cdot p_{\boldsymbol{x}}(\boldsymbol{A}^{-1}(\boldsymbol{\gamma} - \boldsymbol{b})),$$

wobei wir den Zusammenhang $\det(\boldsymbol{A}^{-1}) = \frac{1}{\det \boldsymbol{A}}$ benutzt haben.

Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

1.7 Satz: Es sei $\boldsymbol{x} := (x_1, x_2, \ldots, x_n)^\top \in \mathbb{R}^n$ ein Zufallsvektor, dessen Komponenten $x_i \in \mathbb{R}$ unabhängig und identisch standardnormalverteilt sind, d. h. $x_i \sim N_{0,1}\ \forall i \in \{1, \ldots, n\}$.

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$p_{\boldsymbol{x}}(\boldsymbol{\xi}) := \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\boldsymbol{\xi}\|^2}{2}\right).$$

Beweis: Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$p_{\boldsymbol{x}}(\boldsymbol{\xi}) = \prod_{i=1}^{n} p_{x_i}(\xi_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{\xi_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^{n} \xi_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\boldsymbol{\xi}^\top \boldsymbol{\xi}}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\boldsymbol{\xi}\|^2}{2}\right).$$

□

Multivariate Normalverteilung (Forts.)

Die multivariate Standardnormalverteilung hat Erwartungswertvektor $\mathbb{E}[\boldsymbol{x}] = \boldsymbol{0}$ und Streuungsmatrix $\mathbb{D}[\boldsymbol{x}] = \boldsymbol{I}$.

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren $\boldsymbol{\mu} \in \mathbb{R}^n$ und Streuungsmatrizen $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$. Hierbei nehmen wir an, dass die Streuungsmatrix $\boldsymbol{\Sigma}$ *positiv definit* ist, also $z^\top \boldsymbol{\Sigma} z > 0 \; \forall z \in \mathbb{R}^n \backslash \{\boldsymbol{0}\}$ gilt. Die Schritte sind:

1. Aufgrund der positiven Definitheit von $\boldsymbol{\Sigma}$ gibt es eine untere Dreiecksmatrix $\boldsymbol{A}$ mit $\boldsymbol{\Sigma} = \boldsymbol{A}\boldsymbol{A}^\top$ (Stichwort: **Cholesky-Zerlegung**).
2. Wir betrachten die Transformation $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{\mu}$. Es gilt

$$\mathbb{E}[\boldsymbol{y}] = \mathbb{E}[\boldsymbol{A}\boldsymbol{x} + \boldsymbol{\mu}] = \boldsymbol{A}\mathbb{E}[\boldsymbol{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \qquad \text{und} \qquad \mathbb{D}[\boldsymbol{y}] = \mathbb{D}[\boldsymbol{A}\boldsymbol{x} + \boldsymbol{\mu}] = \boldsymbol{A}\mathbb{D}[\boldsymbol{x}]\boldsymbol{A}^\top = \boldsymbol{A}\boldsymbol{A}^\top = \boldsymbol{\Sigma}.$$

3. Nun wenden wir die Transformationsformel **??** an.

Multivariate Normalverteilung (Forts.)

Zu Schritt 3: Es ist $\boldsymbol{T}^{-1}(\boldsymbol{x}) = \boldsymbol{A}^{-1}(\boldsymbol{y} - \boldsymbol{\mu})$. Mit obigem Beispiel erhalten wir

$$\left|\det J\boldsymbol{T}^{-1}(\boldsymbol{\gamma})\right| = \left|\det \boldsymbol{A}^{-1}\right| = \frac{1}{|\det \boldsymbol{A}|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz[1] die Identität $\det \boldsymbol{\Sigma} = \det(\boldsymbol{A}\boldsymbol{A}^\top) = \det \boldsymbol{A} \cdot \det \boldsymbol{A} = \det^2 \boldsymbol{A}$. Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also $|\det \boldsymbol{A}| = \sqrt{\det \boldsymbol{\Sigma}}$. Die Dichte p_y hat also die Form

$$p_y(\boldsymbol{\gamma}) = \frac{1}{\sqrt{\det \boldsymbol{\Sigma}}} \cdot p_x(\boldsymbol{A}^{-1}(\boldsymbol{\gamma} - \boldsymbol{\mu})),$$

wobei p_x die Dichte der Standardnormalverteilung aus Satz **??** ist. Wir setzen $\boldsymbol{\xi} := \boldsymbol{A}^{-1}(\boldsymbol{\gamma} - \boldsymbol{\mu})$, sodass $\|\boldsymbol{\xi}\|^2 = (\boldsymbol{\gamma} - \boldsymbol{\mu})^\top (\boldsymbol{A}^{-1})^\top \boldsymbol{A}^{-1}(\boldsymbol{\gamma} - \boldsymbol{\mu}) = (\boldsymbol{\gamma} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{\gamma} - \boldsymbol{\mu})$ gilt.

[1] Für zwei $n \times n$ Matrizen $\boldsymbol{A}$ und $\boldsymbol{B}$ gilt $\det(\boldsymbol{A}\boldsymbol{B}) = \det \boldsymbol{A} \cdot \det \boldsymbol{B}$.

Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

1.8 Definition: Es sei $\boldsymbol{\mu} \in \mathbb{R}^n$ und $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ eine *positiv definite* Matrix.

Die Dichte der multivariaten Normalverteilung $N_{\boldsymbol{\mu},\boldsymbol{\Sigma}}$ ist gegeben durch

$$p_{\boldsymbol{x}}(\boldsymbol{\xi}) := \frac{1}{(2\pi)^{\frac{n}{2}} \cdot (\det \boldsymbol{\Sigma})^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(\boldsymbol{\xi} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{\xi} - \boldsymbol{\mu})\right).$$

Bemerkung: Die positive Definitheit der Matrix $\boldsymbol{\Sigma}$ impliziert deren Invertierbarkeit.