Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

Inhaltsverzeichnis

1. Gaussian Mixture Models (GMMs)
2. Expectation-Maximization (EM) Algorithmus

Kapitel

1 **Gaussian Mixture Models (GMMs)**

Problemstellung

Problemstellung

- Wir wissen bereits, wie wir die Parameter $\boldsymbol{\mu}$ und $\boldsymbol{\Sigma}$ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**
  - Gegeben sei ein Datensatz $\boldsymbol{X}$ bestehend aus N unabhängig und identisch normalverteilten Punkten $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N$.
  - Schätze den Mittelwert $\boldsymbol{\mu}$ gemäß

$$\hat{\boldsymbol{\mu}}_{ML} := \frac{1}{N} \sum_{n=1}^{N} \boldsymbol{x}_n. \tag{1.1}$$

  - Schätze die Kovarianzmatrix $\boldsymbol{\Sigma}$ mittels

$$\hat{\boldsymbol{\Sigma}}_{ML} := \frac{1}{N} \sum_{n=1}^{N} (\boldsymbol{x}_n - \hat{\boldsymbol{\mu}}_{ML})(\boldsymbol{x}_n - \hat{\boldsymbol{\mu}}_{ML})^\top. \tag{1.2}$$

- **Frage:** Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung

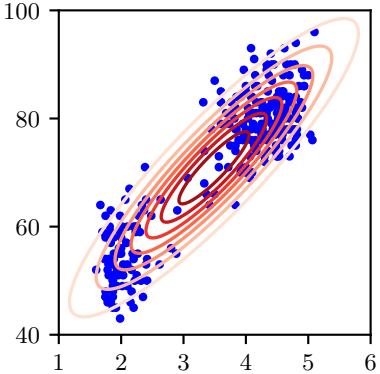

Abbildung: Modell bestehend aus einer Normalverteilung. Siehe **Bishop2024**, Seite 86.

Visualisierung: Problemstellung (Forts.)

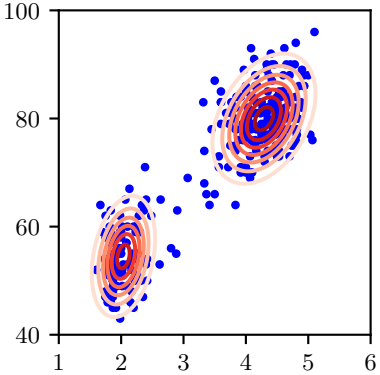

Abbildung: Mixture Modell bestehend aus zwei Normalverteilungen. Siehe **Bishop2024**, Seite 86.

Gaussian Mixture Models

- Wir können ein **Gaussian Mixture Model** als eine *Überlagerung mehrerer Normalverteilungen* ansehen.
- Die Dichte bei K Komponenten ist gegeben durch

$$p(\boldsymbol{x}) := \sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \tag{1.3}$$

- Die **Mischkoeffizienten** π_k stellen sicher, dass die Mixture-Dichte normiert ist, sodass also $\int_{-\infty}^{+\infty} p(\boldsymbol{x}) = 1$ gilt.
- Die π_k erfüllen zudem

$$0 \leq \pi_k \leq 1 \qquad \text{und} \qquad \sum_{k=1}^{K} \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $\boldsymbol{z} \in \mathbb{R}^K$ ein K-dimensionaler **One-Hot Vektor**.
- Die Komponenten z_k erfüllen also $z_k \in \{0,\ 1\}$ und $\sum_{k=1}^{K} z_k = 1$, wobei *genau eine Komponente* den Wert 1 annimmt.
- Wir definieren nun die gemeinsame Verteilung von $\boldsymbol{x}$ und $\boldsymbol{z}$ über die Kettenregel

$$p(\boldsymbol{x},\ \boldsymbol{z}) = p(\boldsymbol{x} \mid \boldsymbol{z}) \cdot p(\boldsymbol{z}).$$

- Für die Definition der Randverteilung $p(\boldsymbol{z})$ benutzen wir die Mischkoeffizienten: $p(z_k = 1) := \pi_k$.
- Da $\boldsymbol{z}$ ein One-Hot Vektor ist, können wir schreiben

$$p(\boldsymbol{z}) = \prod_{k=1}^{K} \pi_k^{z_k}. \tag{1.4}$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Analog definieren wir

$$p(\boldsymbol{x} \mid z_k = 1) := \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Dies können wir ebenfalls vektorisiert ausdrücken als

$$p(\boldsymbol{x} \mid \boldsymbol{z}) := \prod_{k=1}^{K} \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \tag{1.5}$$

- Die Randverteilung $p(\boldsymbol{x})$ erhalten wir schließlich, indem wir über alle möglichen Werte $\boldsymbol{z}$ summieren

$$p(\boldsymbol{x}) = \sum_{\boldsymbol{z}} p(\boldsymbol{z}) \cdot p(\boldsymbol{x} \mid \boldsymbol{z}) = \sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \tag{1.6}$$

- Im letzten Gleichheitszeichen haben wir (1.4) und (1.5) zusammen mit der One-Hot Eigenschaft von $\boldsymbol{z}$ benutzt.

Latente Variablen

- Falls ein Datensatz $\boldsymbol{X}$ bestehend aus N Punkten $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N$ vorliegt, so führen wir für jedes $\boldsymbol{x}_n$ ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt $\boldsymbol{x}_n$.
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass $\boldsymbol{x}_n$ von Komponente k generiert wurde.
- Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend.
- Allerdings können wir nun mit der Verteilung $p(\boldsymbol{x}, z)$ anstelle von $p(\boldsymbol{x})$ arbeiten, was zu wesentlichen Vereinfachungen führen wird.
- Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Im weiteren Verlauf interessieren wir uns besonders für die Aposteriori-Wahrscheinlichkeit $p(\boldsymbol{z} \mid \boldsymbol{x})$.
- Mit $\gamma(z_k)$ bezeichnen wir die Wahrscheinlichkeit $p(z_k = 1 \mid \boldsymbol{x})$.
- Mit dem *Satz von Bayes* gilt

$$\begin{aligned}\gamma(z_k) := p(z_k = 1 \mid \boldsymbol{x}) &= \frac{p(z_k = 1) \cdot p(\boldsymbol{x} \mid z_k = 1)}{\sum_{j=1}^{K} p(z_j = 1) \cdot p(\boldsymbol{x} \mid z_j = 1)} \\ &= \frac{\pi_k \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.\end{aligned}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $z_k = 1$ und $\gamma(z_k)$ die Aposteriori-Wahrscheinlichkeit für $z_k = 1$, nachdem $\boldsymbol{x}$ beobachtet wurde.
- Man nennt $\gamma(z_k)$ auch die **Responsibility** der k-ten Komponente für Punkt $\boldsymbol{x}$.

Visualisierung: Responsibilities

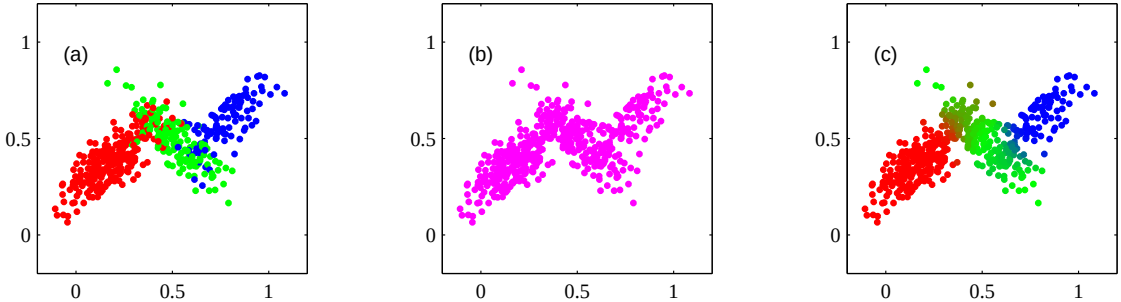

Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_n k)$ gewählt. Siehe **Bishop2024**, Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N unabhängigen und identisch verteilten Punkten $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N$ gegeben.
- Wir fassen die Punkte $\boldsymbol{x}_n$, $n = 1, 2, \ldots$ in der Matrix $\boldsymbol{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n-te Zeile durch $\boldsymbol{x}_n^\top$ gegeben ist.
- Mit (1.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned}\ln p(\boldsymbol{X}; \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \ln\left(\prod_{n=1}^{N}\left(\sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\right)\right) \\ &= \sum_{n=1}^{N} \ln\left(\sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\right).\end{aligned}$$

- Aufgrund der Summe im Argument des Logarithmus ist dieser Ausdruck schwer zu optimieren.

Kapitel

2 **Expectation-Maximization (EM) Algorithmus**

Problemstellung

Ungleichung von Jensen

Expectation-Schritt

Maximization-Schritt

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Problemstellung

- Wir betrachten ein statistisches Modell mit Daten $\boldsymbol{X} = (\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N)^\top$, **latenten Variablen** $\boldsymbol{Z} = (z_1, z_2, \ldots, z_N)^\top$ und Modellparametern $\boldsymbol{\theta}$.
- Unser Ziel ist die Maximierung der Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Da wir die latenten Variablen nicht beobachten, müssen wir *marginalisieren*:

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \tag{2.1}$$

- In der Regel ist eine direkte Maximierung dieses Ausdrucks zu kompliziert, da der Logarithmus nicht direkt auf $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ wirken kann.
- Mit $\{\boldsymbol{X}, \boldsymbol{Z}\}$ bezeichnen wir den **vollständigen** Datensatz, $\boldsymbol{X}$ alleine nennen wir **unvollständig**. Analog nennen wir $\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ die **vollständige Log-Likelihood** und $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von $\ln p(\boldsymbol{X};\boldsymbol{\theta})$ schwer ist, möchten wir also $\ln p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})$ maximieren.
- **Problem:** Wir kennen $\boldsymbol{Z}$ nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in zwei Phasen, indem $\boldsymbol{Z}$ in jeder Iteration bestmöglich geschätzt wird.
- Phasen:
  1. **E-Phase:** Bestimme den Erwartungswert von $\ln p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})$ unter der Aposteriori-Verteilung $p(\boldsymbol{Z} \mid \boldsymbol{X};\boldsymbol{\theta}_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(\boldsymbol{X};\boldsymbol{\theta})$.
  2. **M-Phase:** Die berechnete untere Schranke wird bezüglich der Parameter $\boldsymbol{\theta}$ maximiert, was zu den aktualisierten Parametern $\boldsymbol{\theta}_{\text{neu}}$ führt.
- Bei gegebenen Parametern $\boldsymbol{\theta}_{\text{alt}}$ erhält man so in jeder Iteration neue Parameter $\boldsymbol{\theta}_{\text{neu}}$, die zu einer höheren Log-Likelihood $\ln p(\boldsymbol{X};\boldsymbol{\theta})$ führen.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

2.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen

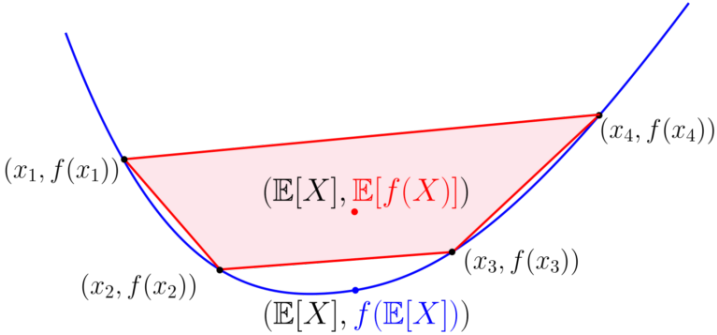

Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(\boldsymbol{X};\boldsymbol{\theta})$.
- Hierzu führen wir die Verteilung q über $\boldsymbol{Z}$ mit $q(\boldsymbol{Z}) \neq 0$ ein und erhalten

$$\begin{aligned}
\ln p(\boldsymbol{X};\boldsymbol{\theta}) &= \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} \\
&= \ln \mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}\right] \\
&\geq \mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln \frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}\right] =: \mathcal{L}(q,\ \boldsymbol{\theta}).
\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen** (Satz 2.1) mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(\boldsymbol{X},\boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(\boldsymbol{X};\boldsymbol{\theta}) \geq \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})\right]}_{\substack{\text{Erwartete vollständige}\\ \text{Log-Likelihood}}} - \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln q(\boldsymbol{Z})\right]}_{\text{Entropie von } q}. \tag{2.2}$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müsssen.
- Wir möchten q so wählen, dass für das aktuelle $\boldsymbol{\theta}$ in (2.2) Gleichheit gilt.
- Die Ungleichung von Jensen (Satz 2.1) gilt mit Gleichheit, falls

$$\frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\boldsymbol{Z}) \propto p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet *proportional zu*.
- Daraus erhalten wir (da q normiert sein muss)

$$q(\boldsymbol{Z}) = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\boldsymbol{Z}}} p(\boldsymbol{X}, \tilde{\boldsymbol{Z}}; \boldsymbol{\theta})} = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{p(\boldsymbol{X}; \boldsymbol{\theta})}$$

$$= p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}).$$

- **Ergebnis:** Für q benutzen wir die Aposteriori-Verteilung von $\boldsymbol{Z}$ gegeben $\boldsymbol{X}$.
- Dies setzen wir in (2.2) ein und erhalten die Identität

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \right].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor $\boldsymbol{\theta}_{\text{alt}}$, mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\boldsymbol{Z}) := p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}) &\geq \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \right] \\
&= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}}) \\
&= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},
\end{aligned}$$

  wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.
- Die Funktion $H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}})$ ist die **Entropie** von $\boldsymbol{\theta}_{\text{alt}}$.

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}})$ bezüglich $\boldsymbol{\theta}$ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}})$ gegeben.
- Der M-Schritt hat also die Form

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}). \tag{2.3}$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(\boldsymbol{X} \mid \boldsymbol{\theta}_{\text{neu}}) \geq p(\boldsymbol{X} \mid \boldsymbol{\theta}_{\text{alt}})$ gilt.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

2.2 Algorithmus

1. Initialisiere $\boldsymbol{\theta}_{\text{alt}}$.
2. **E-Schritt:** Bestimme die untere Schranke

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) := \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})\right].$$

3. **M-Schritt:** Maximiere die untere Schranke und berechne

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}).$$

4. Falls noch nicht konvergiert, gehe zurück zu Schritt 2 und setze $\boldsymbol{\theta}_{\text{alt}} := \boldsymbol{\theta}_{\text{neu}}$.
5. Ansonsten gebe $\boldsymbol{\theta}_{\text{neu}}$ zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus.
- Es gilt

$$
\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}}) &\geq \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}_{\text{neu}})}{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \\
&\geq \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}_{\text{alt}})}{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \\
&= \ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).
\end{aligned}
$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil $\boldsymbol{\theta}_{\text{neu}}$ so gewählt wurde, dass es die untere Schranke maximiert.

Visualisierung: EM-Algorithmus

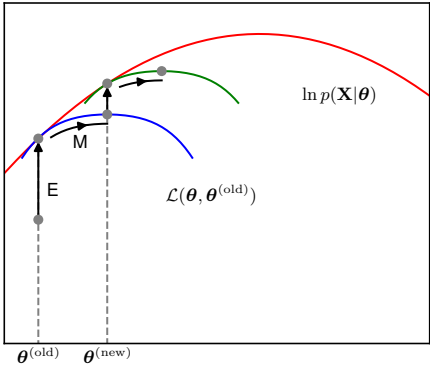

Abbildung: Veranschaulichung des EM-Algorithmus. Siehe **Bishop2024**, Seite 488.

Evidence Lower Bound (ELBO)

- Die Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ können wir zerlegen in

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \mathrm{KL}(q \parallel p). \tag{2.4}$$

- Dabei ist:
  - $\mathcal{L}(q, \boldsymbol{\theta})$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound** mit

$$\mathcal{L}(q, \boldsymbol{\theta}) := \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} = \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})]. \tag{2.5}$$

  - $\mathrm{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\boldsymbol{Z})$ und $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$, welche gegeben ist durch

$$\mathrm{KL}(q \parallel p) := -\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \ln \frac{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} = -\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})]. \tag{2.6}$$

Beweis der Zerlegung (2.4)

Beweis: Wir beweisen die Zerlegung (2.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ an. Wir erhalten $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \cdot p(\boldsymbol{X}; \boldsymbol{\theta})$. Anwendung des Logarithmus ergibt

$$\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = \ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}).$$

Dies setzen wir in die Evidence Lower Bound (2.5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})] \\ &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})].\end{aligned}$$

Damit erhalten wir schließlich

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) + \mathrm{KL}(q \parallel p) &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})] - \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})] \\ &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}) \cdot \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}).\end{aligned}$$

□

Kullback-Leibler Divergenz

- Aus (2.6) ist ersichtlich, dass $\mathrm{KL}(q \parallel p)$ die Kullback-Leibler Divergenz zwischen $q(\boldsymbol{Z})$ und der Aposteriori-Verteilung $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$ ist.
- **Eigenschaften der Kullback-Leibler Divergenz:** Für alle q und p gelten

$$\mathrm{KL}(q \parallel p) \geq 0 \tag{2.7}$$

und

$$\mathrm{KL}(q \parallel p) = 0 \quad \Longleftrightarrow \quad q = p. \tag{2.8}$$

- Aus (2.4) folgt mit der Nichtnegativität (2.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\boldsymbol{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\boldsymbol{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood

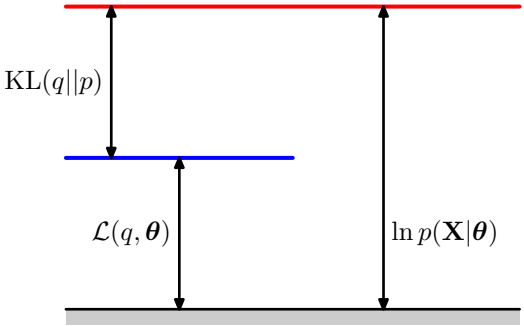

Abbildung: Veranschaulichung der Zerlegung (2.4). Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den E-Schritt

- Wir nutzen die Zerlegung (2.4), um eine alternative Herleitung des EM-Algorithmus zu erhalten.
- Hierzu nehmen wir an, dass die aktuellen Parameter durch $\boldsymbol{\theta}_{\text{alt}}$ gegeben sind.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta}_{\text{alt}})$ bezüglich $q(\boldsymbol{Z})$ bei gegebenem $\boldsymbol{\theta}_{\text{alt}}$ maximiert.
- Da $p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$ nicht von $q(\boldsymbol{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \boldsymbol{\theta}_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (2.8) für $q(\boldsymbol{Z})$ gelten

$$q(\boldsymbol{Z}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \boldsymbol{\theta}_{\text{alt}}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).$$

Visualisierung: E-Schritt

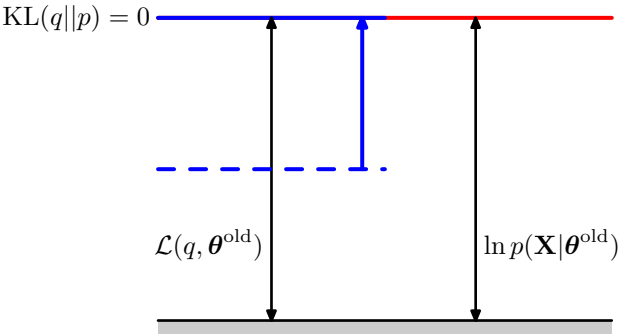

Abbildung: Veranschaulichung des E-Schritts. Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\boldsymbol{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Hierdurch erhalten wir die neuen Parameter $\boldsymbol{\theta}_{\text{neu}}$, die letztendlich zu einer höheren Log-Likelihood $p(\boldsymbol{X}; \boldsymbol{\theta})$ führen.
- Setzen wir $p(\boldsymbol{Z}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$ in die Definition der unteren Schranke (2.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \\ &= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}})$ maximieren, wobei Q die erwartete vollständige Log-Likelihood ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (2.3) an

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern $\boldsymbol{\theta}_{\text{alt}}$ bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\boldsymbol{Z}) \neq p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}}),$$

  sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.
- Im folgenden E-Schritt setzen wir dann $q(\boldsymbol{Z}) := p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt

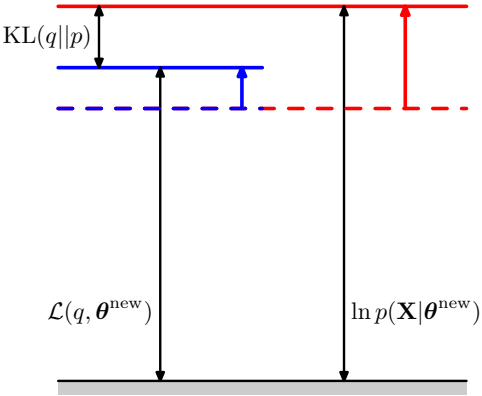

Abbildung: Veranschaulichung des M-Schritts. Siehe **Bishop2024**, Seite 487.

Literatur