

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Regression

Kapitel

① Regression

Wiederholung: Lineare Regression

Probabilistische Regression

Maximum A posteriori (MAP) Regression

Lineare Regression

Wir wiederholen die wichtigsten Aussagen zur linearen Regression:

- Wir betrachten einen Datensatz bestehend aus N Featurevektoren $\mathbf{x}_n \in \mathbb{R}^m$, $n = 1, 2, \dots, N$.
- Jeder Vektor $\mathbf{x}_n$ ist mit einem zugehörigen Label $y_n \in \mathbb{R}$, $n = 1, 2, \dots, N$ versehen.
- Das lineare Regressionsmodell hat die Form

$$h(\mathbf{x}; \boldsymbol{\theta}) = \theta_0 + \sum_{m=1}^M \theta_m x_m.$$

- Im Folgenden bietet es sich an, die Dummy-Komponente $x_0 := 1$ einzuführen, sodass gilt

$$h(\mathbf{x}; \boldsymbol{\theta}) = \sum_{m=0}^M \theta_m x_m = \boldsymbol{\theta}^\top \mathbf{x}.$$

Design Matrix

- Wir fassen die Featurevektoren $\mathbf{x}_n$ zeilenweise zu der Matrix

$$\mathbf{X} := \begin{pmatrix} \text{---} & \mathbf{x}_1 & \text{---} \\ \text{---} & \mathbf{x}_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \mathbf{x}_N & \text{---} \end{pmatrix} \in \mathbb{R}^{N \times (M+1)}$$

zusammen. Die erste Spalte ist hierbei konstant 1 (*wegen der Dummy-Komponente*).

- Wir nennen diese Matrix **Design Matrix**.
- Analog sammeln wir alle Labels in einem Vektor

$$\mathbf{y} := (y_1, y_2, \dots, y_N)^T \in \mathbb{R}^N.$$

Methode der kleinsten Quadrate

- Der Vektor $\theta \in \mathbb{R}^{M+1}$ beinhaltet die Modellparameter.
- Diese möchten wir so wählen, dass unser Modell die Daten möglichst gut erklärt, d. h. die Abweichung der Regressionsfunktion zu den Trainingsdaten sollte möglichst klein sein.

1.1 Definition: Mit den obigen Definitionen ist der **Least-Squares-Fehler** gegeben durch

$$J_{\text{LS}}(\theta) := \frac{1}{2N} \|X\theta - \mathbf{y}\|^2.$$

Bemerkung: Der Vektor $X\theta \in \mathbb{R}^N$ beinhaltet die Modellvorhersagen, wenn man dem Modell die Parameter θ zugrunde legt. J_{LS} misst also die mittlere quadratische Abweichung der Vorhersagen zu den wahren Werten.

Minimierung der Fehlerfunktion

Unser Ziel ist die Minimierung von J_{LS} . Hierzu schreiben J_{LS} unter Ausnutzung der Transpositionsregeln $(A + B)^T = A^T + B^T$ und $(AB)^T = B^T A^T$ um:

$$\begin{aligned} J_{LS}(\theta) &= \frac{1}{2N} \|X\theta - y\|^2 = \frac{1}{2N} (X\theta - y)^T (X\theta - y) \\ &= \frac{1}{2N} ((X\theta)^T - y^T)(X\theta - y) \\ &= \frac{1}{2N} ((X\theta)^T X\theta - (X\theta)^T y - y^T (X\theta) + y^T y) \\ &= \frac{1}{2N} (\theta^T X^T X\theta - 2(X\theta)^T y + y^T y) \\ &= \frac{1}{2N} (\theta^T X^T X\theta - 2\theta^T X^T y + y^T y) \end{aligned}$$

Minimierung der Fehlerfunktion (Forts.)

Um einen stationären Punkt zu finden, müssen wir J_{LS} nach θ ableiten und Null setzen.

- Es ist $\frac{\partial}{\partial \theta} \theta^\top X^\top X \theta = 2X^\top X \theta$, da $X^\top X$ symmetrisch ist.

Beweis: Wir nutzen die Transpositionsregeln und erhalten $(X^\top X)^\top = X^\top (X^\top)^\top = X^\top X$, woraus die Symmetrie folgt. $\square$

- Es ist $\frac{\partial}{\partial \theta} (-2\theta^\top X^\top y) = -2X^\top y$ und $\frac{\partial}{\partial \theta} y^\top y = 0$.
- Der Gradient der Fehlerfunktion J_{LS} ist damit gegeben durch

$$\begin{aligned} \frac{\partial}{\partial \theta} J_{LS}(\theta) &= \frac{1}{2N} (2X^\top X \theta - 2X^\top y) \propto X^\top X \theta - X^\top y \\ &= X^\top (X \theta - y) \end{aligned}$$

Bemerkung: Man beachte den Zusammenhang zwischen dem Gradienten und dem Vorhersagefehler.

Minimierung der Fehlerfunktion (Forts.)

Wir setzen den Gradienten nun Null und lösen nach θ auf:

$$\frac{\partial}{\partial \theta} J_{\text{LS}}(\theta) \stackrel{!}{=} \mathbf{0} \quad \Longleftrightarrow \quad X^{\top} X \theta - X^{\top} y = \mathbf{0}$$

$$\Longleftrightarrow \quad X^{\top} X \theta = X^{\top} y$$

$$\Longleftrightarrow \quad \theta^{\star} = (X^{\top} X)^{-1} X^{\top} y$$

Bemerkung: Wir haben damit einen stationären Punkt von J_{LS} gefunden. Allerdings wissen wir noch nicht, ob es sich tatsächlich um ein Minimum handelt. Außerdem sind wir hier etwas naiv von der Existenz der Inversen $(X^{\top} X)^{-1}$ ausgegangen. Existiert diese Matrix immer?

Mit diesen Fragen beschäftigen wir uns im Folgenden.

Ein paar nützliche Aussagen

1.2 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ ist $A^\top A$ positiv semidefinit.

Beweis: Für alle $z \in \mathbb{R}^M$ gilt $z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 \geq 0$, die Behauptung. $\square$

1.3 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ mit *vollem Spaltenrang* ist $A^\top A$ positiv definit.

Beweis: Da A vollen Spaltenrang hat, sind die Spaltenvektoren linear unabhängig. Daher ist Az für alle $z \in \mathbb{R}^M \setminus \{0\}$ eine nicht-triviale Linearkombination der Spalten von A . Folglich gilt $Az \neq 0$ und wir erhalten $z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 > 0$. $\square$

Ein paar nützliche Aussagen (Forts.)

1.4 Satz: Wenn A positiv definit ist, so ist A auch invertierbar.

Beweis: Wir nehmen an A sei nicht invertierbar. Dann sind die Spalten von A linear abhängig und es existiert ein $z \in \mathbb{R}^M \setminus \{\mathbf{0}\}$ mit $Az = \mathbf{0}$. Daraus folgt aber

$$z^T Az = z^T \mathbf{0} = 0,$$

was der Definitheitseigenschaft von A widerspricht. □

Handelt es sich nun um ein Minimum?

Um diese Frage zu klären, berechnen wir die Hesse-Matrix von J_{LS} und untersuchen, ob die Matrix im stationären Punkt positiv definit ist.

- Man rechnet nach, dass die Hesse-Matrix gegeben ist durch

$$\frac{\partial^2}{\partial \theta \partial \theta} J_{LS}(\theta) = X^T X.$$

- Mit Satz 1.3 ist diese Matrix positiv definit für alle θ , falls X vollen Spaltenrang hat, d. h. die Features müssen linear unabhängig sein. In diesem Fall handelt es sich bei θ^* also tatsächlich um ein Minimum.
- Unter derselben Voraussetzung haben wir damit sogar die **Konvexität** von J_{LS} bewiesen, sodass das Minimum global und eindeutig ist.

Und wie sieht es nun mit der Existenz der Inversen aus?

- Mit Satz 1.4 ist die Existenz der Inversen sichergestellt, wenn $X^T X$ positiv definit ist, was wiederum aus der linearen Unabhängigkeit der Features folgt (Satz 1.3).
- **Achtung:** Bei der numerischen Berechnung der Inversen auf dem Computer kann es jedoch trotzdem zu Problemen kommen. Es ist ratsam, die Inverse nicht explizit zu berechnen, sondern stattdessen das lineare Gleichungssystem $X^T X \theta = X^T y$ nach θ zu lösen. Dieses Vorgehen ist numerisch stabiler.
- Alternativ kann das Optimierungsproblem mit dem **Gradientenabstiegsverfahren** gelöst werden. Iteriere hierzu die Regel:

$$\theta_{t+1} \leftarrow \theta_t - \alpha X^T (X \theta_t - y). \quad (1.1)$$

Normalengleichungen

Wir fassen unsere Ergebnisse zusammen:

1.5 Satz: Die Design Matrix $X \in \mathbb{R}^{N \times (M+1)}$ des Regressionsproblems habe vollen Spaltenrang, d. h. die Features seien linear unabhängig. Dann existiert die Inverse $(X^\top X)^{-1}$ und

$$\theta^\star = (X^\top X)^{-1} X^\top y$$

ist das eindeutige globale Minimum von J_{LS} . Die Gleichungen $X^\top X \theta = X^\top y$ bezeichnet man als **Normalengleichungen**.

Eine probabilistische Sicht

Annahme 1: Die Zielwerte $y \in \mathbb{R}$ und die Eingaben $\mathbf{x} \in \mathbb{R}^{m+1}$ hängen über die Gleichung

$$y = \boldsymbol{\theta}^\top \mathbf{x} + \varepsilon \quad (1.2)$$

zusammen. Dabei ist $\varepsilon \in \mathbb{R}$ ein Fehlerterm, der nicht modellierte Effekte oder Datenrauschen repräsentiert.

Annahme 2: Für den Fehlerterm gilt $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Der Zielwert y kann damit als Zufallsvariable aufgefasst werden, für die gilt

$$y \mid \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2). \quad (1.3)$$

Visualisierung: Probabilistische Regression

tbd

Maximum-Likelihood Regression

- Wir betrachten wieder einen Datensatz $\{(\mathbf{x}_n, y_n)\}$ bestehend aus N Trainingsbeispielen.
- Die Likelihood des Modells ist gegeben durch

$$\begin{aligned} p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) &= \prod_{n=1}^N p(y_n \mid \mathbf{x}_n; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{1}{2\sigma^2} \left(y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n)\right)^2\right) \end{aligned} \tag{1.4}$$

Maximum-Likelihood Regression (Forts.)

- Durch Logarithmieren von (1.4) erhalten wir die Log-Likelihood Funktion

$$\begin{aligned} l(\boldsymbol{\theta}, \sigma^2) &:= \ln p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \end{aligned} \quad (1.5)$$

- Aus (1.5) wird ersichtlich, dass der Least-Squares-Fehler minimiert werden muss, um die Likelihood in $\boldsymbol{\theta}$ zu maximieren.
- Die Lösung für $\boldsymbol{\theta}$ ist dieselbe wie in (1.5), zusätzlich kann die globale Unsicherheit des Modells quantifiziert werden

$$\hat{\boldsymbol{\theta}}_{ML} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (y_n - \hat{\boldsymbol{\theta}}_{ML}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \quad (1.6)$$

Visualisierung: Maximum-Likelihood Regression

tbd

Berücksichtigung einer Apriori-Verteilung

- Die Maximum-Likelihood Lösung ist **anfällig für Overfitting**.
- Eine Möglichkeit der Regularisierung ist die Verwendung einer **Apriori-Verteilung** (Prior).
- Für diese Verteilung benutzen wir eine Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, b^2 \mathbf{I}). \quad (1.7)$$

- Es handelt sich hierbei um eine **isotropische Normalverteilung** (rotationsinvariant).
- Der Prior kann benutzt werden, um Vorwissen zu berücksichtigen.
- Häufig ist der Prior jedoch **nicht informativ** (z. B. Gleichverteilung).

MAP Regression

Literatur