Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

Inhaltsverzeichnis

1 **Expectation-Maximization (EM) Algorithmus**

Kapitel

1 **Expectation-Maximization (EM) Algorithmus**

Problemstellung

Ungleichung von Jensen

Expectation-Schritt

Maximization-Schritt

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Problemstellung

- Wir betrachten ein statistisches Modell mit Daten $\boldsymbol{X} = (\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N)^\top$, **latenten Variablen** $\boldsymbol{Z} = (z_1, z_2, \ldots, z_N)^\top$ und Modellparametern $\boldsymbol{\theta}$.
- Unser Ziel ist die Maximierung der Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Da wir die latenten Variablen nicht beobachten, müssen wir *marginalisieren*:

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \tag{1}$$

- In der Regel ist eine direkte Maximierung dieses Ausdrucks zu kompliziert, da der Logarithmus nicht direkt auf $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ wirken kann.
- Mit $\{\boldsymbol{X}, \boldsymbol{Z}\}$ bezeichnen wir den **vollständigen** Datensatz, $\boldsymbol{X}$ alleine nennen wir **unvollständig**. Analog nennen wir $\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ die **vollständige Log-Likelihood** und $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ schwer ist, möchten wir also $\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ maximieren.
- **Problem:** Wir kennen $\boldsymbol{Z}$ nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in zwei Phasen, indem $\boldsymbol{Z}$ in jeder Iteration bestmöglich geschätzt wird.
- Phasen:
  1. **E-Phase:** Bestimme den Erwartungswert von $\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ unter der Aposteriori-Verteilung $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$.
  2. **M-Phase:** Die berechnete untere Schranke wird bezüglich der Parameter $\boldsymbol{\theta}$ maximiert, was zu den aktualisierten Parametern $\boldsymbol{\theta}_{\text{neu}}$ führt.
- Bei gegebenen Parametern $\boldsymbol{\theta}_{\text{alt}}$ erhält man so in jeder Iteration neue Parameter $\boldsymbol{\theta}_{\text{neu}}$, die zu einer höheren Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ führen.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

1.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(\boldsymbol{X};\boldsymbol{\theta})$.
- Hierzu führen wir die Verteilung q über $\boldsymbol{Z}$ mit $q(\boldsymbol{Z}) \neq 0$ ein und erhalten

$$\begin{aligned}
\ln p(\boldsymbol{X};\boldsymbol{\theta}) &= \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X},\, \boldsymbol{Z};\boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \frac{p(\boldsymbol{X},\, \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} \\
&= \ln \mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\frac{p(\boldsymbol{X},\, \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}\right] \\
&\geq \mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln \frac{p(\boldsymbol{X},\, \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}\right] =: \mathcal{L}(q,\, \boldsymbol{\theta}).
\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen** (Satz 1.1) mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(\boldsymbol{X},\boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(\boldsymbol{X};\boldsymbol{\theta}) \geq \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln p(\boldsymbol{X},\,\boldsymbol{Z};\boldsymbol{\theta})\right]}_{\substack{\text{Erwartete vollständige}\\ \text{Log-Likelihood}}} - \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln q(\boldsymbol{Z})\right]}_{\text{Entropie von } q}. \tag{2}$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müsssen.
- Wir möchten q so wählen, dass für das aktuelle $\boldsymbol{\theta}$ in (2) Gleichheit gilt.
- Die Ungleichung von Jensen (Satz 1.1) gilt mit Gleichheit, falls

$$\frac{p(\boldsymbol{X},\,\boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\boldsymbol{Z}) \propto p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet *proportional zu*.
- Daraus erhalten wir (da q normiert sein muss)

$$q(\boldsymbol{Z}) = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\boldsymbol{Z}}} p(\boldsymbol{X}, \tilde{\boldsymbol{Z}}; \boldsymbol{\theta})} = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{p(\boldsymbol{X}; \boldsymbol{\theta})}$$

$$= p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}).$$

- **Ergebnis:** Für q benutzen wir die Aposteriori-Verteilung von $\boldsymbol{Z}$ gegeben $\boldsymbol{X}$.
- Dies setzen wir in (2) ein und erhalten die Identität

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \right].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor $\boldsymbol{\theta}_{\text{alt}}$, mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\boldsymbol{Z}) := p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}) &\geq \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \right] \\
&= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}}) \\
&= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},
\end{aligned}$$

  wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.
- Die Funktion $H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}})$ ist die **Entropie** von $\boldsymbol{\theta}_{\text{alt}}$.

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}})$ bezüglich $\boldsymbol{\theta}$ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}})$ gegeben.
- Der M-Schritt hat also die Form

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}). \tag{3}$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(\boldsymbol{X} \mid \boldsymbol{\theta}_{\text{neu}}) \geq p(\boldsymbol{X} \mid \boldsymbol{\theta}_{\text{alt}})$ gilt.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

1.2 Algorithmus:

1. Initialisiere $\boldsymbol{\theta}_{\text{alt}}$.
2. **E-Schritt:** Bestimme die untere Schranke

$$Q(\boldsymbol{\theta},\, \boldsymbol{\theta}_{\text{alt}}) := \mathbb{E}_{\boldsymbol{Z}\sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta}_{\text{alt}})}\left[\ln p(\boldsymbol{X},\, \boldsymbol{Z};\boldsymbol{\theta})\right].$$

3. **M-Schritt:** Maximiere die untere Schranke und berechne

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta},\, \boldsymbol{\theta}_{\text{alt}}).$$

4. Falls noch nicht konvergiert, gehe zurück zu Schritt 2 und setze $\boldsymbol{\theta}_{\text{alt}} := \boldsymbol{\theta}_{\text{neu}}$.
5. Ansonsten gebe $\boldsymbol{\theta}_{\text{neu}}$ zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus.
- Es gilt

$$
\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}}) &\geq \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}_{\text{neu}})}{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \\
&\geq \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}_{\text{alt}})}{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \\
&= \ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).
\end{aligned}
$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil $\boldsymbol{\theta}_{\text{neu}}$ so gewählt wurde, dass es die untere Schranke maximiert.

Visualisierung: EM-Algorithmus

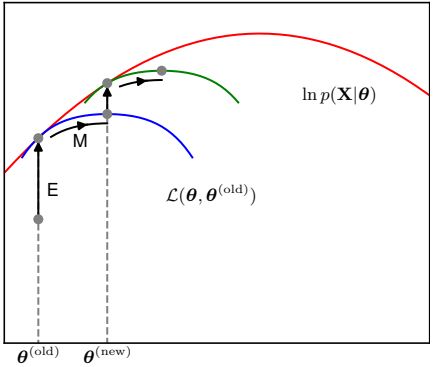

Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [1], Seite 488.

Eine andere Sicht auf den EM-Algorithmus

- Die Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ können wir zerlegen in

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \mathrm{KL}(q \parallel p). \tag{4}$$

- Dabei ist:
  - $\mathcal{L}(q, \boldsymbol{\theta})$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound** mit

$$\mathcal{L}(q, \boldsymbol{\theta}) := \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} = \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})]. \tag{5}$$

  - $\mathrm{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\boldsymbol{Z})$ und $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$, welche gegeben ist durch

$$\mathrm{KL}(q \parallel p) := -\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \ln \frac{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} = -\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})]. \tag{6}$$

Beweis der Zerlegung (4)

Beweis: Wir beweisen die Zerlegung (4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ an. Wir erhalten $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \cdot p(\boldsymbol{X}; \boldsymbol{\theta})$. Anwendung des Logarithmus ergibt

$$\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = \ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}).$$

Dies setzen wir in die Evidence Lower Bound (5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})\right] \\ &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})\right].\end{aligned}$$

Damit erhalten wir schließlich

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) + \mathrm{KL}(q \parallel p) &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})\right] - \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})\right] \\ &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}) \cdot \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}).\end{aligned}$$

□

Visualisierung: Zerlegung der Log-Likelihood

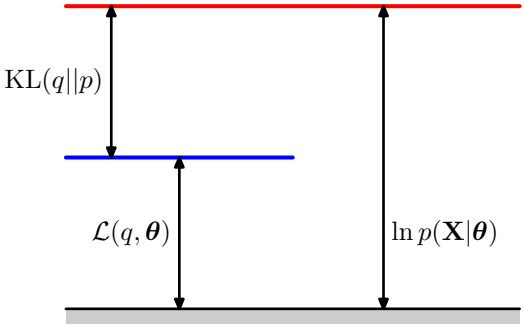

Abbildung: Veranschaulichung der Zerlegung (4). Siehe [1], Seite 486.

Literatur

[1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: https://www.bishopbook.com/.