

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Grundlagen der Statistik

Kapitel

① Grundlagen der Statistik

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Maximum-Likelihood Schätzer

Maximum-Aposteriori Schätzer

Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ω ist der **Ereignisraum**, also die Menge aller Elementarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir $\Omega := \{1, 2, 3, 4, 5, 6\}$.
- Mit $\mathcal{A}$ bezeichnen wir die zugehörige **Sigma-Algebra**, einer Menge von Teilmengen von Ω . Im einfachsten Fall könnten wir $\mathcal{A} := \text{Pot}(\Omega)$ wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra $\mathbb{B}$ auf $\mathbb{R}$ heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus $\mathcal{A}$ eine Wahrscheinlichkeit zuordnet.

Zufallsvariablen

Im Folgenden sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{B})$ ein messbarer Raum.

1.1 Definition: Die Abbildung $x : \Omega \rightarrow \mathcal{X}$ heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : x^{-1}(B) := \{\omega \in \Omega : x(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von B unter x muss also eine messbare Menge in $\mathcal{A}$ sein, der durch $\mathbb{P}$ eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable $x : \Omega \rightarrow \mathcal{X}$ die Funktion

$$\mathbb{P}^x : \mathcal{B} \rightarrow [0, 1] \quad \text{mit} \quad B \mapsto \mathbb{P}(x^{-1}(B))$$

die **Verteilung** der Zufallsvariablen x . $\mathbb{P}^x$ ist das **Bildmaß** von $\mathbb{P}$ unter x .

Zufallsvariablen (Forts.)

Sei $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$ ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße $x : \Omega \rightarrow \mathcal{X}$ ist *verteilt gemäß $\mathbb{Q}$* oder kurz *$\mathbb{Q}$ -verteilt*, falls es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\mathbb{P}^x = \mathbb{Q}$ gilt.

Beispiele:

- x ist N_{μ, σ^2} -verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\forall B \in \mathcal{B} : \mathbb{P}(x \in B) = N_{\mu, \sigma^2}(B)$. Wir schreiben kurz $x \sim N_{\mu, \sigma^2}$.
-

Wahrscheinlichkeitsdichten

In der Regel wollen wir mit Dichten rechnen:

1.2 Definition: Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{B}, \mathbb{P}^x)$ Wahrscheinlichkeitsräume. Dabei ist $\mathbb{P}^x$ die Verteilung der Zufallsvariablen $x : \Omega \rightarrow \mathcal{X}$. Wir nennen eine nichtnegative Funktion

$$p_x : \mathbb{R} \rightarrow [0, 1]$$

eine **(Wahrscheinlichkeits-)Dichte** von $\mathbb{P}^x$, falls

$$\mathbb{P}^x(B) = \int_B p_x(\xi) \, d\xi \quad \forall B \in \mathcal{B}.$$

Die Wahrscheinlichkeiten der Mengen $B \in \mathcal{B}$ müssen sich also allesamt als Integral der Dichte p_x darstellen lassen können.

Erwartungswert von Zufallsvariablen

1.3 Definition: Sei $x \in \mathbb{R}$ eine Zufallsvariable. Wir definieren den **Erwartungswert** (erstes Moment) von x als

$$\mathbb{E}[x] := \int_{\mathbb{R}} \xi \cdot p_x(\xi) \, d\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen x und y und eine beliebige aber feste Zahl $\alpha \in \mathbb{R}$ (keine Zufallsvariable!) gelten

$$\mathbb{E}[x + y] = \mathbb{E}[x] + \mathbb{E}[y] \quad \text{und} \quad \mathbb{E}[\alpha \cdot x] = \alpha \cdot \mathbb{E}[x].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ als

$$\mathbb{E}[\mathbf{x}] := (\mathbb{E}[x_1], \mathbb{E}[x_2], \dots, \mathbb{E}[x_n])^\top.$$

Varianz von Zufallsvariablen

1.4 Definition: Die Varianz einer Zufallsvariablen $x \in \mathbb{R}$ ist definiert als die erwartete quadratische Abweichung vom Erwartungswert (zweites zentriertes Moment), also

$$\mathbb{V}[x] := \mathbb{E}[(x - \mathbb{E}[x])^2] = \int_{\mathbb{R}} (\xi - \mathbb{E}[x])^2 \cdot p_x(\xi) \, d\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[x] &= \mathbb{E}[(x - \mathbb{E}[x])^2] = \mathbb{E}[x^2 - 2x \cdot \mathbb{E}[x] + (\mathbb{E}[x])^2] \\ &= \mathbb{E}[x^2] - 2(\mathbb{E}[x])^2 + (\mathbb{E}[x])^2 \\ &= \mathbb{E}[x^2] - (\mathbb{E}[x])^2\end{aligned}$$

Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen. Seien dazu x und y reelle Zufallsvariablen und $\alpha \in \mathbb{R}$ beliebig aber fest.

- Die Varianz ist **nicht** linear:
 - Es gilt $\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$ nur, wenn x und y unkorreliert sind (Satz von Bienaymé).
 - $\mathbb{V}[\alpha \cdot x] = \alpha^2 \cdot \mathbb{V}[x]$
- Eine Verschiebung verändert die Varianz nicht, also $\mathbb{V}[x + \alpha] = \mathbb{V}[x]$

Kovarianz und Streuungsmatrix

tbd

Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

Name der Verteilung	$\mathbb{P}^x$	Zähldichte $p_x(k)$	$\mathbb{E}[x]$	$\mathbb{V}[x]$
Binomialverteilung	$B_{n,p}$	$\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Hypergeometrische Verteilung	$H_{n,K,N}$	$\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \cdot \frac{K}{N}$	$n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$
Poisson-Verteilung	P_λ	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	λ	λ

Absolutstetige Verteilungen

Name der Verteilung	$\mathbb{P}^x$	Lebesgue-Dichte $p_x(\xi)$	$\mathbb{E}[x]$	$\mathbb{V}[x]$
Normalverteilung	N_{μ, σ^2}	$\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gammaverteilung	$\Gamma_{\lambda, r}$	$\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$
Chiquadrat-Verteilung	χ_f^2	$\frac{1}{2^{\frac{f}{2}} \cdot \Gamma(\frac{f}{2})} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	f	$2 \cdot f$
Exponentialverteilung	Exp_{λ}	$\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Betaverteilung	$\beta_{a,b}$	$\frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi)$	$\frac{a}{a+b}$	$\frac{a \cdot b}{(a+b)^2 \cdot (a+b+1)}$
Gleichverteilung	$U_{(a,b)}$	$\frac{1}{b-a} \cdot \mathbf{1}_{(a,b)}(\xi)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

1.5 Definition: Es seien $x \in \mathbb{R}$ und $y \in \mathbb{R}$ reelle Zufallsvariablen mit den Verteilungen $\mathbb{P}^x$, $\mathbb{P}^y$ und den Dichten p_x bzw. p_y .

x und y heißen **stochastisch unabhängig** genau dann wenn $p_{x,y} := p_x \cdot p_y$ eine Produktdichte der Verteilung $\mathbb{P}^{x,y}$ ist, d. h. die gemeinsame Dichte von x und y ergibt sich als Produkt der Einzeldichten.

Bemerkung: Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. Die Umkehrung gilt im Allgemeinen nicht. Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als Unkorreliertheit.

Bedingte Wahrscheinlichkeiten

tbd

Satz von Bayes

tbd

Transformationssatz für Lebesgue-Dichten

1.6 Satz: Es seien $\mathbf{x}$ und $\mathbf{y}$ n -dimensionale Zufallsvektoren mit dem Zusammenhang

$$\mathbf{y} = \mathbf{T}(\mathbf{x}).$$

Die Abbildung $\mathbf{T} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ sei *bijektiv*, sodass die Umkehrabbildung $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y})$ existiert und eindeutig ist. Dann gilt für die Dichte $p_{\mathbf{y}}$ der transformierten Zufallsvariablen $\mathbf{y}$

$$p_{\mathbf{y}}(\mathbf{y}) = p_{\mathbf{x}}(\mathbf{T}^{-1}(\mathbf{y})) \cdot |\det \mathbf{J}\mathbf{T}^{-1}(\mathbf{y})|,$$

wobei $p_{\mathbf{x}}$ die Dichte von $\mathbf{x}$ und $\mathbf{J}\mathbf{T}^{-1}$ die Jacobi-Matrix der Abbildung $\mathbf{T}^{-1}$ bezeichnet.

Beweis: Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

Beispiel I

Es sei $x \sim \text{Exp}_2$ eine reellwertige exponentialverteilte Zufallsvariable mit Ankunftsrate $\lambda = 2$.

Gesucht ist die Dichte der Zufallsvariablen $y := 5x + 2$.

Lösung: Es ist $T(x) := 5x + 2$ eine bijektive Transformation mit der Umkehrabbildung $x = T^{-1}(y) = \frac{1}{5}(y - 2)$. Zusammen mit der Dichte $p_x(x) = 2 \cdot e^{-2x} \cdot \mathbf{1}_{[0, \infty)}(x)$ der Exp_2 -Verteilung erhalten wir für die Dichte $p_y(y)$ der transformierten Zufallsvariablen y

$$\begin{aligned} p_y(y) &= p_x(T^{-1}(y)) \cdot (T^{-1})'(y) \\ &= 2 \cdot e^{-2\left(\frac{y}{5} - \frac{2}{5}\right)} \cdot \mathbf{1}_{[0, \infty)}\left(\frac{1}{5}y - \frac{2}{5}\right) \cdot \frac{1}{5} \\ &= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2y}{5}} \cdot \mathbf{1}_{[2, \infty)}(y). \end{aligned}$$

Beispiel II

Der Zufallsvektor $\mathbf{x} \in \mathbb{R}^n$ habe eine beliebige Lebesgue-Dichte $p_{\mathbf{x}}$. Die Transformation $\mathbf{T}$ sei linear und bijektiv, also von der Form $\mathbf{y} = \mathbf{T}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$. Insbesondere ist $\mathbf{A}$ in diesem Fall invertierbar. Dann existiert die Umkehrfunktion und ist gegeben durch $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})$. Als Jacobi-Matrix erhält man $J\mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}$.

Die Anwendung der Transformationsformel 1.6 ergibt daher für die Dichte $p_{\mathbf{y}}$ von $\mathbf{y}$ den Ausdruck

$$p_{\mathbf{y}}(\mathbf{y}) = \frac{1}{|\det \mathbf{A}|} \cdot p_{\mathbf{x}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})),$$

wobei wir den Zusammenhang $\det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$ benutzt haben.

Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

1.7 Satz: Es sei $\mathbf{x} := (x_1, x_2, \dots, x_n)^\top \in \mathbb{R}^n$ ein Zufallsvektor, dessen Komponenten $x_i \in \mathbb{R}$ unabhängig und identisch standardnormalverteilt sind, d. h. $x_i \sim N_{0,1} \forall i \in \{1, \dots, n\}$.

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$p_{\mathbf{x}}(\mathbf{x}) := \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

Beweis: Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$p_{\mathbf{x}}(\mathbf{x}) = \prod_{i=1}^n p_{x_i}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^n x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right) = \frac{1}{(2\pi)^{\frac{n}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

□

Multivariate Normalverteilung (Forts.)

Für die multivariate Standardnormalverteilung gilt $\mathbb{E}[\mathbf{x}] = \mathbf{0}$ und $\mathbb{D}[\mathbf{x}] = \mathbf{I}$.

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren $\boldsymbol{\mu} \in \mathbb{R}^n$ und Streuungsmatrizen $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$. Wir fordern lediglich, dass die Streuungsmatrix $\boldsymbol{\Sigma}$ *positiv definit* ist, dass also $\mathbf{z}^\top \boldsymbol{\Sigma} \mathbf{z} > 0 \forall \mathbf{z} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ gilt.

- 1 Aufgrund der positiven Definitheit von $\boldsymbol{\Sigma}$ gibt es eine untere Dreiecksmatrix $\mathbf{A}$ mit $\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top$ (Stichwort: **Cholesky-Zerlegung**).
- 2 Wir betrachten die Transformation $\mathbf{y} := \mathbf{A}\mathbf{x} + \boldsymbol{\mu}$. Es gilt

$$\mathbb{E}[\mathbf{y}] = \mathbb{E}[\mathbf{A}\mathbf{x} + \boldsymbol{\mu}] = \mathbf{A}\mathbb{E}[\mathbf{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \quad \text{und} \quad \mathbb{D}[\mathbf{y}] = \mathbb{D}[\mathbf{A}\mathbf{x} + \boldsymbol{\mu}] = \mathbf{A}\mathbb{D}[\mathbf{x}]\mathbf{A}^\top = \mathbf{A}\mathbf{A}^\top = \boldsymbol{\Sigma}.$$

- 3 Nun wenden wir die Transformationsformel 1.6 an.

Multivariate Normalverteilung (Forts.)

Es ist $T^{-1}(\mathbf{x}) = A^{-1}(\mathbf{y} - \boldsymbol{\mu})$. Mit obigem Beispiel II zum Transformationssatz erhalten wir

$$|\det JT^{-1}(\mathbf{y})| = |\det A^{-1}| = \frac{1}{|\det A|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz¹ die Identität

$\det \boldsymbol{\Sigma} = \det(AA^T) = \det A \cdot \det A = \det^2 A$. Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also $|\det A| = (\det \boldsymbol{\Sigma})^{\frac{1}{2}}$. Die Dichte p_y nimmt damit die Form

$$p_y(\mathbf{y}) = \frac{1}{(\det \boldsymbol{\Sigma})^{\frac{1}{2}}} \cdot p_x(A^{-1}(\mathbf{y} - \boldsymbol{\mu}))$$

an, wobei p_x die Dichte der Standardnormalverteilung aus Satz 1.7 ist. Wir setzen dort $\mathbf{x} := A^{-1}(\mathbf{y} - \boldsymbol{\mu})$, sodass $\|\mathbf{x}\|^2 = (\mathbf{y} - \boldsymbol{\mu})^T (A^{-1})^T A^{-1}(\mathbf{y} - \boldsymbol{\mu}) = (\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})$ gilt.

¹Für zwei $n \times n$ Matrizen A und B gilt $\det(AB) = \det A \cdot \det B$.

Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

1.8 Definition: Es sei $\mu \in \mathbb{R}^n$ und $\Sigma \in \mathbb{R}^{n \times n}$ eine *positiv definite* Matrix.

Die Dichte der multivariaten Normalverteilung $N_{\mu, \Sigma}$ ist gegeben durch

$$p_{\mathbf{x}}(\mathbf{x}) := \frac{1}{(2\pi)^{\frac{n}{2}} \cdot (\det \Sigma)^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^{\top} \Sigma^{-1}(\mathbf{x} - \mu)\right).$$

Bemerkung: Die positive Definitheit der Matrix Σ impliziert deren Invertierbarkeit.

Visualisierung: Multivariate Normalverteilung

tbd

Partitionierte Normalverteilung

1.9 Definition: Es seien $\mathbf{x} \in \mathbb{R}^d$ und $\mathbf{y} \in \mathbb{R}^{(n-d)}$ Zufallsvektoren. Wir fassen diese zu einem neuen Zufallsvektor $\mathbf{z} := (\mathbf{x}^\top, \mathbf{y}^\top)^\top \in \mathbb{R}^n$ mit $\mathbf{z} \sim N_{\mu, \Sigma}$ zusammen. Hierbei seien

$$\mu := \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix} \quad \text{und} \quad \Sigma := \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}.$$

Wir nennen dieses Modell **partitionierte Normalverteilung**.

Bemerkungen:

- Aus der Symmetrie von Σ folgt die von Σ_{xx} und Σ_{yy} . Außerdem gilt $\Sigma_{xy} = \Sigma_{yx}^\top$.
- Oft ist es einfacher mit der Inversen der Kovarianzmatrix zu arbeiten. Wir definieren daher $\Lambda := \Sigma^{-1}$. Man nennt diese Matrix **Präzisionsmatrix**.

Bedingte Normalverteilung

1.10 Satz: Wir betrachten die partitionierte Normalverteilung aus Definition 1.9. Dann ist die Verteilung von $x \mid y$ ebenfalls normalverteilt mit den Parametern

$$\mu_{x|y} := \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$$

$$\Sigma_{x|y} := \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$

Die Dichte dieser Verteilung bezeichnen wir mit $p_{x|y}$.

Beweis: Einen Beweis dieser Aussage finden Sie in Bishop (2006) auf den Seiten 85–87.



Visualisierung: Bedingte Normalverteilung

tbd

Normale Randverteilung

1.11 Satz: Wieder betrachten wir die partitionierte Normalverteilung aus Definition 1.9. Dann sind auch die Randverteilungen von $\mathbf{x}$ und $\mathbf{y}$ normalverteilt. Es gilt

$$\mathbf{x} \sim N_{\mu_x, \Sigma_{xx}}$$

$$\mathbf{y} \sim N_{\mu_y, \Sigma_{yy}}$$

Die Dichten der Randverteilung bezeichnen wir mit p_x und p_y .

Beweis: Man erhält dieses Ergebnis durch **Marginalisierung** der Verbunddichte, d. h. wir integrieren über alle Variablen, die uns nicht interessieren. Für die Randverteilung von $\mathbf{x}$ gilt zum Beispiel

$$p_x(\mathbf{x}) = \int p_{x,y}(\mathbf{x}, \mathbf{y}) d\mathbf{y}.$$

Einen ausführlichen Beweis finden Sie in Bishop (2006) auf den Seiten 88–89. □

Visualisierung: Normale Randverteilung

tbd

Satz von Bayes für Normalverteilungen

tbd

Maximum-Likelihood Methode

- Im Folgenden sei ein Beobachtungsvektor $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top$ bestehend aus N *unabhängig und identisch verteilten* (i. i. d.) Datenpunkten gegeben.
- Wir möchten Aussagen über die Parameter $\boldsymbol{\theta} := (\theta_1, \theta_2, \dots, \theta_M)^\top$ der zugrundeliegenden Verteilung machen.
- Dies erledigen wir durch eine Punktschätzung des Parametervektors $\boldsymbol{\theta}$. Den Schätzer für $\boldsymbol{\theta}$ bezeichnen wir mit $\hat{\boldsymbol{\theta}}$.
- Eine der am häufigsten angewendete Methode ist die **Maximum-Likelihood Methode**, die wir im Folgenden näher beleuchten werden.

(Log-)Likelihood Funktion

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für den Parametervektor θ maximiert die Likelihood Funktion.

1.12 Definition: Es sei $p(\mathbf{x}; \theta)$ die Dichte eines Zufallsvektors $\mathbf{x} \in \mathbb{R}^n$, welche durch den Parametervektor $\theta \in \Theta$ parametrisiert wird. Die **Likelihood Funktion** $L : \Theta \rightarrow \mathbb{R}$ ist dann definiert als

$$L(\theta) := p(\mathbf{x}; \theta) = p(x_1, x_2, \dots, x_N; \theta).$$

Häufig ist es einfacher, die **Log-Likelihood Funktion**

$$l(\theta) := \ln p(\mathbf{x}; \theta)$$

zu betrachten. Es ist $\hat{\theta}_{ML} := \arg \max_{\theta} l(\theta)$.

Bemerkung: Der Schätzer $\hat{\theta}_{ML}$ maximiert sowohl L als auch l . (Warum?)

(Log-)Likelihood Funktion (Forts.)

- Im Allgemeinen kann es schwer sein, die Likelihood Funktion zu bestimmen (vor allem wenn die Beobachtungen voneinander abhängen).
- Die Annahme der **Unabhängigkeit der Beobachtungen** vereinfacht dies maßgeblich, denn

$$\begin{aligned} L(\theta) &= p(x_1, x_2, \dots, x_N; \theta) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot \dots \cdot p(x_N; \theta) \\ &= \prod_{n=1}^N p(x_n; \theta). \end{aligned}$$

- Für die Log-Likelihood Funktion ergibt sich durch Anwendung der Logarithmengesetze

$$l(\theta) = \ln \prod_{n=1}^N p(x_n; \theta) = \sum_{n=1}^N \ln p(x_n; \theta).$$

Maximum-Likelihood Gleichung

- Falls die Likelihood Funktion differenzierbar ist, so erfüllt der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ notwendig die **Likelihood Gleichung**

$$\left. \frac{\partial}{\partial \theta} \ln p(x; \theta) \right|_{\theta=\hat{\theta}_{ML}} = \mathbf{0}.$$

- Diese sagt aus, dass $\hat{\theta}_{ML}$ ein stationärer Punkt der (Log-)Likelihood Funktion sein muss.
- Es handelt sich dabei um ein System von M , im Allgemeinen nicht-linearen, Gleichungen der Form

$$\left. \frac{\partial}{\partial \theta_j} \ln p(x; \theta) \right|_{\theta=\hat{\theta}_{ML}} = 0 \quad j = 1, 2, \dots, M.$$

- Achtung:** Es muss noch überprüft werden, ob $\hat{\theta}_{ML}$ tatsächlich ein Maximum darstellt.

Beispiel I: Binomialverteilung

1.13 Satz: Es sei die binomialverteilte Zufallsvariable x (beobachtete Anzahl der Erfolge) und der Stichprobenumfang N gegeben.

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für die unbekannte Erfolgswahrscheinlichkeit $\theta \in (0, 1)$ lautet $\hat{\theta}_{ML} = \frac{x}{N}$.

Beweis: Die Likelihood Funktion ist $L(\theta) = \binom{N}{x} \cdot \theta^x \cdot (1 - \theta)^{N-x}$. Durch Anwendung des Logarithmus erhalten wir die Log-Likelihood Funktion

$$l(\theta) = \ln \binom{N}{x} + x \cdot \ln \theta + (N - x) \cdot \ln(1 - \theta).$$

Diese leiten wir nach θ ab und setzen sie Null. Auflösen nach θ ergibt

$$\frac{d}{d\theta} l(\theta) = \frac{x}{\theta} + \frac{N - x}{1 - \theta} \stackrel{!}{=} 0 \iff \hat{\theta}_{ML} = \frac{x}{N}.$$

Zudem ist $\frac{d^2}{d\theta^2} l(\theta) = -\frac{x}{\theta^2} - \frac{N-x}{(1-\theta)^2} < 0 \forall \theta \in (0, 1)$, sodass $\hat{\theta}_{ML}$ tatsächlich ein Maximum ist. □

Beispiel II: Normalverteilung

1.14 Satz: Es seien

$$\mathbf{x} = (x_1, x_2, \dots, x_N)^\top$$

unabhängig und identisch normalverteilte Beobachtungen mit unbekanntem Erwartungswert $\mu \in \mathbb{R}$ und unbekannter Varianz $\sigma^2 > 0$. Der Parametervektor θ ist in diesem Fall $\theta := (\mu, \sigma^2)^\top$.

Die Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$ für die unbekannten Parameter μ und σ^2 sind gegeben durch

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^n x_n \quad \text{und} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2.$$

Beweis: Die Dichte der Produktverteilung lautet aufgrund der Unabhängigkeit der Beobachtungen

$$p(\mathbf{x}; \mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \frac{1}{\sigma^N} \cdot \exp\left(-\frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}\right).$$

Aufgrund der auftretenden Exponentialverteilung bietet sich die Betrachtung der Log-Likelihood Funktion an. Wir erhalten

$$l(\mu, \sigma^2) = -\frac{N}{2} \cdot \ln(2\pi) - N \ln(\sigma) - \frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}.$$

Nun berechnen wir die partiellen Ableitungen von l nach μ und σ^2 . Es ist

$$\frac{\partial}{\partial \mu} l(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) \quad \text{und} \quad \frac{\partial}{\partial \sigma^2} l(\mu, \sigma^2) = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=1}^N (x_n - \mu)^2.$$

Durch Nullsetzen und auflösen erhalten wir die im Satz angegebenen Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$. Es bleibt noch zu zeigen, dass es sich tatsächlich um ein Maximum handelt. Man rechnet nach, dass die Hesse-Matrix von $l(\mu, \sigma^2)$ and der Stelle $(\hat{\mu}_{ML}, \hat{\sigma}_{ML}^2)$ gegeben ist durch

$$\nabla^2 l(\mu, \sigma^2) = \begin{pmatrix} -\frac{N}{\hat{\sigma}_{ML}^2} & 0 \\ 0 & -\frac{N}{(\hat{\sigma}_{ML}^2)^2} \end{pmatrix}.$$

Diese Matrix ist negativ definit, weshalb wir tatsächlich ein Maximum gefunden haben. □

Erwartungstreue Schätzer

Wir definieren den Begriff der Erwartungstreue:

1.15 Definition: Wir nennen einen Schätzer $\hat{\theta}$ **erwartungstreu**, falls $\mathbb{E}[\hat{\theta}] = \theta$ gilt.

- Der Schätzer $\hat{\mu}_{ML}$ ist erwartungstreu für den Erwartungswert μ im Normalverteilungsmodell

Beweis: Es gilt

$$\mathbb{E}[\hat{\mu}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \cdot N \cdot \mu = \mu.$$

□

- Demgegenüber ist $\hat{\sigma}_{ML}^2$ **nicht** erwartungstreu. Man kann diesen Schätzer jedoch durch eine geeignete Transformation zu einem erwartungstreuen Schätzer machen. Dies führt auf die **empirische Varianz** $\frac{n}{n-1} \hat{\sigma}_{ML}^2 = \frac{1}{n-1} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2$.

Aufgabe zur Maximum-Likelihood Schätzung

1.16 Aufgabe: Gegeben seien die N Beobachtungen $x_1, x_2, \dots, x_N$, wobei $x_n \in \mathbb{N}$, $n = 1, 2, \dots, N$. Sie legen den Daten eine Poisson-Verteilung zugrunde. Diese hat die Dichte

$$p(x) := e^{-\lambda} \cdot \frac{\lambda^x}{x!}.$$

- 1 Bestimmen Sie den Maximum-Likelihood Schätzer $\hat{\lambda}_{ML}$ für die Poisson-Verteilung. Vergessen Sie dabei nicht zu überprüfen, ob es sich tatsächlich um ein Maximum handelt.
- 2 Prüfen Sie den Schätzer auf Erwartungstreue.

Erwartete quadratische Abweichung (MSE)

Ein weiteres Qualitätsmerkmal eines Schätzers $\hat{\theta}$ ist seine erwartete quadratische Abweichung vom wahren Parameter θ .

1.17 Definition: Die **erwartete quadratische Abweichung** von $\hat{\theta}$ zu θ ist

$$\text{MSE}[\hat{\theta}, \theta] = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Die $\text{MSE}[\hat{\theta}, \theta]$ reduziert sich für erwartungstreue Schätzer $\hat{\theta}$ auf die Varianz $\mathbb{V}[\hat{\theta}]$.

Beweis: Man rechnet nach, dass $\text{MSE}[\hat{\theta}, \theta] = \mathbb{V}[\hat{\theta}] + (\mathbb{E}[\hat{\theta}] - \theta)^2$ gilt (multipliziere hierzu aus und nutze die Linearität des Erwartungswerts). Der zweite Summand (Quadrat der Verzerrung/Bias) verschwindet aber für erwartungstreue Schätzer, da $\mathbb{E}[\hat{\theta}] = \theta$ gilt. Es folgt die Behauptung. □

Maximum-Aposteriori Schätzer (MAP)

- ML Schätzer laufen Gefahr, sich übermäßig stark an die Daten anzupassen (**Overfitting**).
- Wir erweitern daher das Konzept der ML Schätzung, indem wir zusätzlich eine *Apriori-Verteilung* für die zu schätzenden Parameter mit einbeziehen.
- Wir nutzen den Satz von Bayes, um damit zusammen mit der Likelihood eine *Aposteriori-Verteilung* über die Parameter zu erhalten.
- Ein Schätzer $\hat{\theta}_{MAP}$ heißt **Maximum-Aposteriori Schätzer** für den Parameter θ , falls dieser die Aposteriori-Wahrscheinlichkeit maximiert.

Literatur