

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Principal Component Analysis (PCA)

Kapitel

1 Principal Component Analysis (PCA)

Problemstellung

Orthogonale Projektionen

Maximum-Variance Formulierung der PCA

PCA-Algorithmus

Minimum-Error Formulierung der PCA

Anwendungen der PCA

Problemstellung

- Die **Principal Component Analysis (PCA)** projiziert hochdimensionale Daten *orthogonal* auf einen *linearen Raum* niedriger Dimension.
- Diesen linearen Raum nennt man auch **Principal Subspace**.
- Wir betrachten im Folgenden einen Datensatz $\{\mathbf{x}_n\}$ mit $n = 1, 2, \dots, N$ und $\mathbf{x}_n \in \mathbb{R}^M$.
- Unser Ziel ist die Projektion der Daten in einem Raum der Dimension D , wobei $D \ll M$.
- Für die PCA gibt es verschiedene Ansätze, die zu demselben Ergebnis führen.
- Die bekanntesten sind die **Maximum Variance** Formulierung und die **Minimum Error** Formulierung.
- Zunächst wiederholen wir, was man unter der orthogonalen Projektion von Vektoren versteht.

Visualisierung: Orthogonale Projektionen




Abbildung: Orthogonale Projektion der Daten $\{\mathbf{x}_n\}$ auf die von $\mathbf{u}_1$ definierte Gerade. Siehe **Bishop2024**, Seite 467.

Geometrisches Skalarprodukt

1.1 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$. Es gilt das geometrische Skalarprodukt $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b})$.

Beweis: Für $\|\mathbf{a} - \mathbf{b}\|^2 = (\mathbf{a} - \mathbf{b})^\top (\mathbf{a} - \mathbf{b})$ ergibt sich durch Ausmultiplizieren zum Einen

$$\begin{aligned}\|\mathbf{a} - \mathbf{b}\|^2 &= \mathbf{a}^\top \mathbf{a} - \mathbf{a}^\top \mathbf{b} - \mathbf{b}^\top \mathbf{a} + \mathbf{b}^\top \mathbf{b} \\ &= \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2\mathbf{a}^\top \mathbf{b}\end{aligned}\tag{1.1}$$

und zum Anderen aufgrund des **Kosinussatzes** (Verallgemeinerung des Satzes von Pythagoras) aus der Geometrie

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2 \cdot \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b}).\tag{1.2}$$

Setzt man die Ausdrücke (1.1) und (1.2) für $\|\mathbf{a} - \mathbf{b}\|^2$ gleich, subtrahiert auf beiden Seiten $\|\mathbf{a}\|^2 + \|\mathbf{b}\|^2$ und dividiert durch -2 , so ergibt sich $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b})$, die Behauptung. $\square$

Orthogonalität von Vektoren

1.2 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$ verschieden von $\mathbf{0}$. Es gilt $\mathbf{a}^\top \mathbf{b} = 0$ genau dann, wenn $\mathbf{a}$ und $\mathbf{b}$ orthogonal aufeinander stehen.

Beweis: Wenn die Vektoren $\mathbf{a}$ und $\mathbf{b}$ orthogonal, d. h. senkrecht, aufeinander stehen, dann gilt $\cos \angle(\mathbf{a}, \mathbf{b}) = 0$, da die Kosinus-Funktion bei $\pi/2$ (entspricht 90°) eine Nullstelle hat. Mit Satz 1.1 folgt

$$\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\|^2 \cdot \|\mathbf{b}\|^2 \cdot \cos \angle(\mathbf{a}, \mathbf{b}) = \|\mathbf{a}\|^2 \cdot \|\mathbf{b}\|^2 \cdot 0 = 0.$$

Sei nun $\mathbf{a}^\top \mathbf{b} = 0$. Da die Vektoren von $\mathbf{0}$ verschieden sind, muss wegen der Eigenschaften der Norm zwingend $\cos \angle(\mathbf{a}, \mathbf{b}) = 0$ gelten. Die Vektoren stehen also senkrecht aufeinander. Damit gilt die Behauptung. $\square$

Orthogonale Projektion von Vektoren

1.3 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$. Dann ist die orthogonale Projektion von $\mathbf{b}$ auf $\mathbf{a}$ gegeben durch

$$\text{proj}_{\mathbf{a}} \mathbf{b} = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2} \mathbf{a}.$$

Beweis: Es müssen zwei Bedingungen erfüllt sein. Einerseits ist der Projektionsvektor $\mathbf{p} := \text{proj}_{\mathbf{a}} \mathbf{b}$ der Anteil von $\mathbf{b}$, der in Richtung $\mathbf{a}$ zeigt, sodass dieser eine Stauchung bzw. Streckung von $\mathbf{a}$ ist. Mit $k \in \mathbb{R}$ gilt also

$$\mathbf{p} = k \cdot \mathbf{a}. \quad (1.3)$$

Andererseits soll die Projektion orthogonal sein, d. h. wir wollen den Vektor $\mathbf{p}$ so finden, dass $\mathbf{b} - \mathbf{p}$ senkrecht auf $\mathbf{a}$ steht. Mit Satz 1.2 lautet die Bedingung also

$$(\mathbf{b} - \mathbf{p})^\top \mathbf{a} = 0. \quad (1.4)$$

Einsetzen von (1.3) in (1.4) und auflösen nach k ergibt $(\mathbf{b} - k \cdot \mathbf{a})^\top \mathbf{a} = 0 \iff k = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2}$. Dieses Ergebnis setzen wir in (1.3) ein und erhalten die Behauptung. $\square$

Orthogonale Projektion von Vektoren (Forts.)




Abbildung: Projektion des Vektors $b \in \mathbb{R}^2$ auf den Vektor $a \in \mathbb{R}^2$. Im Kontext der PCA ist der Vektor a der Principal Subspace u_1 und b ist ein Datenpunkt, der auf diesen Raum projiziert wird.

Orthogonale Projektion von Vektoren (Forts.)

- Interessieren wir uns nur für die *Länge des Projektionsvektors*, so betrachten wir seine Norm

$$\|\text{proj}_a \mathbf{b}\| = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2} \|\mathbf{a}\| = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|}. \quad (1.5)$$

- Gilt zudem $\|\mathbf{a}\| = 1$ (dann ist $\mathbf{a}$ ein Einheitsvektor), so ergibt sich die Länge des Projektionsvektors einfach als das Skalarprodukt der beteiligten Vektoren

$$\|\text{proj}_a \mathbf{b}\| = \mathbf{a}^\top \mathbf{b}. \quad (1.6)$$

- Wir gehen im Folgenden davon aus, dass die **Principal Components** $\{\mathbf{u}_i\}$ normiert sind.

Maximum-Variance Formulierung

- Im Folgenden betrachten wir den Fall $D = 1$.
- Wir betrachten also nur eine einzelne Principal Component $\mathbf{u}_1$.
- Eine mögliche Formulierung der PCA ist es, die *Varianz der projizierten Daten zu maximieren*.
- Durch die Maximierung der Varianz erhofft man sich den Erhalt eines möglichst großen Anteils der Struktur der Daten.
- Dieses Vorgehen führt auf die **Maximum-Variance Formulierung** der PCA.
- Da $\|\mathbf{u}_1\| = 1$, ist die Projektion eines Datenpunkts $\mathbf{x}_n$ auf $\mathbf{u}_1$ gegeben durch

$$\tilde{x}_n = \mathbf{u}_1^\top \mathbf{x}_n. \quad (1.7)$$

Ziel: Finde $\mathbf{u}_1$ so, dass die Varianz der Projektionen $\{\tilde{x}_n\}$ maximal wird.

Projektion von Mittelwert und Varianz

- Der Mittelwert der projizierten Daten ist analog gegeben durch

$$\mathbf{u}_1^\top \bar{\mathbf{x}}, \quad \text{mit} \quad \bar{\mathbf{x}} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (1.8)$$

- Die projizierte Varianz bestimmt man mittels

$$\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1. \quad (1.9)$$

- Hierbei bezeichnet $\mathbf{S}$ die **Streuungsmatrix** der Daten im hochdimensionalen Raum.
- Sie ist gegeben durch

$$\mathbf{S} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^\top. \quad (1.10)$$

Beweis von (1.9)

Wir beweisen Gleichung (1.9):

Beweis: Wir setzen die Projektionen (1.7) und (1.8) in die Definition der Varianz ein und erhalten durch Ausmultiplizieren aufgrund der Symmetrie des Skalarprodukts

$$\begin{aligned}\frac{1}{N} \sum_{n=1}^N (u_1^\top x_n - u_1^\top \bar{x})^2 &= \frac{1}{N} \sum_{n=1}^N (u_1^\top x_n \cdot x_n^\top u_1 - 2 \cdot u_1^\top x_n \cdot \bar{x}^\top u_1 + u_1^\top \bar{x} \cdot \bar{x}^\top u_1) \\&= u_1^\top \left(\frac{1}{N} \sum_{n=1}^N (x_n x_n^\top - 2 \cdot x_n \bar{x}^\top + \bar{x} \bar{x}^\top) \right) u_1 \\&= u_1^\top \left(\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^\top \right) u_1 \\&= u_1^\top S u_1.\end{aligned}$$

Einsetzen von (1.10).

□

Maximierung der projizierten Varianz

- Unser Ziel ist nun die Maximierung der projizierten Varianz $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$ in $\mathbf{u}_1$.
- **Problem:** Dieses Maximierungsproblem ist unbeschränkt.
- Wir können diesen Ausdruck stets vergrößern, indem wir die Komponenten von $\mathbf{u}_1$ vergrößern.
- Um dies zu verhindern, fordern wir, dass $\|\mathbf{u}_1\| = 1$ gilt.

Maximierungsproblem für die PCA:

$$\begin{array}{ll} \text{Maximiere} & \mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 \\ \text{unter} & \|\mathbf{u}_1\| = 1. \end{array} \quad (1.11)$$

Maximierung der projizierten Varianz (Forts.)

- Löst man Problem (1.11), so erhält man für $\mathbf{u}_1$ die Bedingung

$$S\mathbf{u}_1 = \lambda_1\mathbf{u}_1. \quad (1.12)$$

- Gleichung (1.12) sagt aus, dass $\mathbf{u}_1$ ein Eigenvektor von S sein muss.
- Der Lagrange-Multiplikator λ_1 ist der zugehörige Eigenwert.

1.4 Aufgabe: Zeigen Sie die Gültigkeit von (1.12), indem Sie das Optimierungsproblem (1.11) lösen. Stellen Sie hierzu die Lagrange-Funktion des Problems auf und finden Sie deren stationären Punkte.

Maximierung der projizierten Varianz (Forts.)

- Multiplizieren wir (1.12) von links mit $\mathbf{u}_1^\top$, so erhalten wir

$$\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1^\top \mathbf{u}_1 = \lambda_1 \|\mathbf{u}_1\|^2 = \lambda_1. \quad (1.13)$$

- Im letzten Gleichheitszeichen haben wir benutzt, dass eine Lösung von (1.11) die Nebenbedingung $\|\mathbf{u}_1\| = 1$ erfüllt.
- Wegen (1.13) ist der Eigenwert λ_1 die Varianz, die durch Projektion der Daten auf $\mathbf{u}_1$ erhalten bleibt.

Lösung für den Fall $D = 1$: Wir berechnen die Eigenzerlegung von $\mathbf{S}$ und benutzen als $\mathbf{u}_1$ einen (normierten) Eigenvektor zum größten Eigenwert. Wegen (1.13) erhält dieser den größten Anteil der Varianz.

Bestimmung weiterer Principal Components

- Die Bestimmung weiterer Principal Components ist einfach.
- Wir benutzen als $\mathbf{u}_2$ einen normierten Eigenvektor von S zum zweitgrößten Eigenwert λ_2 .
- Wir benutzen als $\mathbf{u}_3$ einen normierten Eigenvektor von S zum drittgrößten Eigenwert λ_3 .
- Dies führen wir solange fort, bis wir die vorgegebenen D Komponenten erreicht haben.
- Wir fassen die Vektoren $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_D$ in einer Matrix $V \in \mathbb{R}^{M \times D}$ zusammen.
- Die Projektionen $\tilde{X} \in \mathbb{R}^{N \times D}$ der Daten $X \in \mathbb{R}^{N \times M}$ erhalten wir dann mittels

$$\tilde{X} = XV. \quad (1.14)$$

Orthogonalität der Principal Components

1.5 Satz: Die Principal Components $\{\mathbf{u}_i\}$ stehen senkrecht aufeinander.

Beweis: Dies folgt direkt aus der Orthogonalität der Eigenvektoren von symmetrischen Matrizen zu verschiedenen Eigenwerten. Seien also λ_1 und λ_2 mit $\lambda_1 \neq \lambda_2$ zwei voneinander verschiedene Eigenwerte von S . Dann erfüllen diese die Gleichungen $S\mathbf{u}_1 = \lambda_1\mathbf{u}_1$ und $S\mathbf{u}_2 = \lambda_2\mathbf{u}_2$. Damit gilt

$$(S\mathbf{u}_1)^\top \mathbf{u}_2 = (\lambda_1\mathbf{u}_1)^\top \mathbf{u}_2 = \lambda_1 \mathbf{u}_1^\top \mathbf{u}_2. \quad (1.15)$$

Außerdem gilt aufgrund der Symmetrie von S und der Tatsache, dass man eine Matrix im Skalarprodukt transponiert auf die andere Seite bringen darf

$$(S\mathbf{u}_1)^\top \mathbf{u}_2 = \mathbf{u}_1^\top (S^\top \mathbf{u}_2) = \mathbf{u}_1^\top (S\mathbf{u}_2). \quad (1.16)$$

Nun setzen wir die Eigenwertgleichung in (1.16) ein und erhalten

$$(S\mathbf{u}_1)^\top \mathbf{u}_2 = \mathbf{u}_1^\top (\lambda_2 \mathbf{u}_2) = \lambda_2 \mathbf{u}_1^\top \mathbf{u}_2. \quad (1.17)$$

Setzt man nun (1.15) und (1.16) gleich, so erhält man schlussendlich $(\lambda_1 - \lambda_2) \cdot \mathbf{u}_1^\top \mathbf{u}_2 = 0$. Da $\lambda_1 \neq \lambda_2$ muss $\mathbf{u}_1^\top \mathbf{u}_2 = 0$ gelten. Mit Satz 1.2 folgt die Behauptung. □

PCA-Algorithmus

1.6 Algorithmus

- 1 Bestimme $\bar{x}$ und S gemäß (1.8) beziehungsweise (1.10).
- 2 Berechne die Eigenzerlegung von S , d. h. finde Matrizen U und Λ mit

$$S = U\Lambda U^T.$$

Dabei enthält die Matrix $U \in \mathbb{R}^{M \times M}$ die Eigenvektoren von S . $\Lambda \in \mathbb{R}^{M \times M}$ ist eine Diagonalmatrix mit den Eigenwerten auf der Hauptdiagonalen.

- 3 Normiere die Eigenvektoren, die zu den D größten Eigenwerten gehören und fasse sie in der Matrix $V \in \mathbb{R}^{M \times D}$ zusammen.
- 4 Berechne die Projektionen $\tilde{X} = XV$.

PCA-Algorithmus (Forts.)

1.7 Aufgabe: Es sei der zweidimensionale Datensatz

$$X := \begin{pmatrix} 1 & 4 \\ 4 & 1 \\ 1 & 1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

gegeben. Berechnen Sie die eindimensionalen Projektionen dieses Datensatzes mit dem PCA-Algorithmus.

Minimum-Error Formulierung

- Wir betrachten im Folgenden eine weitere Formulierung der PCA, welche auf der *Minimierung des Projektionsfehlers* basiert, die **Minimum-Error** Formulierung.
- Dazu seien $\{\mathbf{u}_i\}$ mit $i = 1, 2, \dots, M$ *orthonormale Basisvektoren*, d. h.

$$\mathbf{u}_i^\top \mathbf{u}_j = \delta_{ij} \quad \forall i, j. \quad (1.18)$$

- Die Basis $\{\mathbf{u}_i\}$ ist *vollständig*, weshalb sich jedes $\mathbf{x}_n$ *eindeutig* als Linearkombination der $\mathbf{u}_i$ darstellen lässt

$$\mathbf{x}_n = \sum_{i=1}^M \alpha_{ni} \mathbf{u}_i. \quad (1.19)$$

- Dies entspricht einer Drehung des Koordinatensystems.

Minimum-Error Formulierung (Forts.)

- Die Koeffizienten α_{nj} ergeben sich als Projektionen der $\mathbf{x}_n$ auf die $\mathbf{u}_j$.
- Wegen (1.18) ist $\alpha_{nj} = \mathbf{x}_n^\top \mathbf{u}_j$, sodass wir (1.19) schreiben können als

$$\mathbf{x}_n = \sum_{i=1}^M (\mathbf{x}_n^\top \mathbf{u}_i) \mathbf{u}_i. \quad (1.20)$$

- Unser Ziel ist jedoch die Approximation der $\{\mathbf{x}_n\}$ mit einer beschränkten Anzahl von Komponenten $D \ll M$.

Visualisierung: Basiswechsel

Projektionsfehler

- Wir approximieren jeden Datenpunkt $\mathbf{x}_n$ mittels

$$\tilde{\mathbf{x}}_n := \sum_{i=1}^D z_{ni} \mathbf{u}_i + \sum_{i=D+1}^M b_i \mathbf{u}_i. \quad (1.21)$$

- Die $\{z_{ni}\}$ hängen dabei von den Punkten $\{\mathbf{x}_n\}$ ab, die $\{b_i\}$ sind dagegen unabhängig.
- Wir möchten die $\{\mathbf{u}_i\}$, die $\{z_{ni}\}$ und die $\{b_i\}$ so wählen, dass der **Projektionsfehler** minimal wird.
- Diesen definieren wir als die durchschnittliche quadratische Abweichung der $\{\mathbf{x}_n\}$ und den $\{\tilde{\mathbf{x}}_n\}$.

PCA Fehlerfunktion:

$$J := \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2. \quad (1.22)$$

Minimierung des Projektionsfehlers

- Leiten wir (1.22) nach z_{nj} ab und setzen die Ableitung Null, so ergibt sich

$$z_{nj} = \mathbf{x}_n^\top \mathbf{u}_j. \quad (1.23)$$

- Analog erhalten wir für b_j

$$b_j = \bar{\mathbf{x}}^\top \mathbf{u}_j. \quad (1.24)$$

1.8 Aufgabe: Bestätigen Sie die Formeln (1.23) und (1.24) durch Nachrechnen.

Visualisierung: Projektionsfehler

Minimierung des Projektionsfehlers (Forts.)

- Die Ergebnisse (1.23) und (1.24) setzen wir nun in die Definition (1.21) von $\tilde{\mathbf{x}}_n$ ein.
- Zusammen mit der Darstellung (1.20) von $\mathbf{x}_n$ erhalten wir für den Differenzvektor

$$\mathbf{x}_n - \tilde{\mathbf{x}}_n = \sum_{i=D+1}^M \left\{ (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{u}_i \right\} \mathbf{u}_i. \quad (1.25)$$

- Dies substituieren wir schließlich in die Fehlerfunktion (1.22). Es gilt

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{i=D+1}^M (\mathbf{x}_n^\top \mathbf{u}_i - \bar{\mathbf{x}}^\top \mathbf{u}_i)^2 = \sum_{i=D+1}^M \mathbf{u}_i^\top \mathbf{S} \mathbf{u}_i = \text{trace}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}). \quad (1.26)$$

- Hierbei ist $\hat{\mathbf{U}}$ die Matrix, deren Spalten aus den Vektoren $\mathbf{u}_{D+1}, \dots, \mathbf{u}_M$ besteht.

Minimierung des Projektionsfehlers (Forts.)

- Wir müssen den Ausdruck (1.26) minimieren.
- Wieder muss eine Nebenbedingung eingeführt werden, um nicht das Ergebnis $\mathbf{u}_i = \mathbf{0}$ zu erhalten.
- Die Nebenbedingungen ergeben sich aus der vorausgesetzten *Orthonormalität* (1.18) der $\{\mathbf{u}_i\}$.
- Der Einfachheit halber betrachten wir den Fall $M = 2$ und $D = 1$.
- In diesem Fall erhalten wir die Lagrange-Funktion

$$\mathcal{L} = \mathbf{u}_2^\top \mathbf{S} \mathbf{u}_2 + \lambda_2 (1 - \mathbf{u}_2^\top \mathbf{u}_2). \quad (1.27)$$

- Ableiten nach $\mathbf{u}_2$ und Nullsetzen ergibt $\mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2$, sodass $\mathbf{u}_2$ ein Eigenvektor von $\mathbf{S}$ ist.
- Setzen wir dies in (1.26) ein, so finden wir

$$J = \mathbf{u}_2^\top \mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2^\top \mathbf{u}_2 = \lambda_2 \cdot \|\mathbf{u}_2\|^2 = \lambda_2. \quad (1.28)$$

Minimierung des Projektionsfehlers (Forts.)

- Der Fehler wird in diesem Fall also minimal, wenn man für $\mathbf{u}_2$ einen normierten Eigenvektor zum kleineren Eigenwert benutzt.
- Für allgemeines M und D erhält man den minimalen Fehler J , indem man die $\{\mathbf{u}_i\}$ als normierte Eigenvektoren von S wählt.
- Für alle $i = 1, 2, \dots, M$ müssen die $\{\mathbf{u}_i\}$ also erfüllen

$$S\mathbf{u}_i = \lambda_i\mathbf{u}_i. \quad (1.29)$$

- Für den Fehler J gilt dann

$$J = \sum_{i=D+1}^M \lambda_i. \quad (1.30)$$

Minimierung des Projektionsfehlers (Forts.)

Man projiziert die Daten also auf den Raum, welcher durch die D Eigenvektoren zu den größten Eigenwerten aufgespannt wird. Der Fehler ergibt sich dann als die Summe jener Eigenwerte, deren Eigenvektoren nicht für die Projektion benutzt wurden.

Datenkompression




Abbildung: Anwendung der PCA auf einen Datensatz bestehend aus 6.000 Bildern mit 28×28 Pixeln. Positive Werte sind blau, negative Werte gelb dargestellt. Siehe [Bishop2024](#), Seite 502.

Datenkompression (Forts.)





Abbildung: (a) Plot des Spektrums der Eigenwerte in absteigender Sortierung. (b) Plot der Summe der verworfenen Eigenwerte (Fehler J). Siehe **Bishop2024**, Seite 503.

Datenkompression (Forts.)




Abbildung: Reduktion eines Elements des Datensatzes auf verschiedene Dimensionen. Bishop benutzt M anstelle von D für die Dimension des Unterraums. Siehe [Bishop2024](#), Seite 502.

Literatur