

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Regression

Kapitel

① Regression

Wiederholung: Lineare Regression

Probabilistische Regression

Maximum A posteriori (MAP) Regression

Bayes'sche Regression

Lineare Regression

Wir wiederholen die wichtigsten Aussagen zur linearen Regression:

- Wir betrachten einen Datensatz bestehend aus N Featurevektoren $\mathbf{x}_n \in \mathbb{R}^m$, $n = 1, 2, \dots, N$.
- Jeder Vektor $\mathbf{x}_n$ ist mit einem zugehörigen Label $y_n \in \mathbb{R}$ versehen, $n = 1, 2, \dots, N$.
- Das lineare Regressionsmodell hat die Form

$$h(\mathbf{x}; \boldsymbol{\theta}) = \theta_0 + \sum_{m=1}^M \theta_m x_m.$$

- Im Folgenden bietet es sich an, die Dummy-Komponente $x_0 := 1$ einzuführen, sodass gilt

$$h(\mathbf{x}; \boldsymbol{\theta}) = \sum_{m=0}^M \theta_m x_m = \boldsymbol{\theta}^\top \mathbf{x}.$$

Design Matrix

- Wir fassen die Featurevektoren $\mathbf{x}_n$ zeilenweise zu der Matrix

$$\mathbf{X} := \begin{pmatrix} \text{---} & \mathbf{x}_1 & \text{---} \\ \text{---} & \mathbf{x}_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \mathbf{x}_N & \text{---} \end{pmatrix} \in \mathbb{R}^{N \times (M+1)}$$

zusammen. Die erste Spalte ist hierbei konstant 1 (*wegen der Dummy-Komponente*).

- Wir nennen diese Matrix **Design Matrix**.
- Analog sammeln wir alle Labels in einem Vektor

$$\mathbf{y} := (y_1, y_2, \dots, y_N)^T \in \mathbb{R}^N.$$

Methode der kleinsten Quadrate

- Der Vektor $\theta \in \mathbb{R}^{M+1}$ beinhaltet die Modellparameter.
- Diese möchten wir so wählen, dass unser Modell die Daten möglichst gut erklärt, d. h. die Abweichung der Regressionsfunktion zu den Trainingsdaten sollte *möglichst klein* sein.

1.1 Definition: Mit den obigen Definitionen ist der **Least-Squares-Fehler** gegeben durch

$$J_{\text{LS}}(\theta) := \frac{1}{2N} \|X\theta - \mathbf{y}\|^2 = \frac{1}{2N} (X\theta - \mathbf{y})^\top (X\theta - \mathbf{y}).$$

Bemerkung: Der Vektor $X\theta \in \mathbb{R}^N$ beinhaltet die **Modellvorhersagen**, wenn man dem Modell die Parameter θ zugrunde legt. J_{LS} misst also die **mittlere quadratische Abweichung** der Vorhersagen zu den wahren Werten $\mathbf{y}$.

Minimierung der Fehlerfunktion

Unser Ziel ist die Minimierung von J_{LS} . Hierzu schreiben J_{LS} unter Ausnutzung der Transpositionsregeln $(A + B)^{\top} = A^{\top} + B^{\top}$ und $(AB)^{\top} = B^{\top} A^{\top}$ um:

$$\begin{aligned} J_{\text{LS}}(\theta) &= \frac{1}{2N} \|X\theta - y\|^2 = \frac{1}{2N} (X\theta - y)^{\top} (X\theta - y) \\ &= \frac{1}{2N} ((X\theta)^{\top} - y^{\top})(X\theta - y) \\ &= \frac{1}{2N} ((X\theta)^{\top} X\theta - (X\theta)^{\top} y - y^{\top} (X\theta) + y^{\top} y) \\ &= \frac{1}{2N} (\theta^{\top} X^{\top} X\theta - 2(X\theta)^{\top} y + y^{\top} y) \\ &= \frac{1}{2N} (\theta^{\top} X^{\top} X\theta - 2\theta^{\top} X^{\top} y + y^{\top} y) \end{aligned}$$

Minimierung der Fehlerfunktion (Forts.)

Um einen stationären Punkt zu finden, müssen wir J_{LS} nach θ ableiten und Null setzen.

- Es ist $\frac{\partial}{\partial \theta} \theta^\top X^\top X \theta = 2X^\top X \theta$, da $X^\top X$ symmetrisch ist.

Beweis: Wir nutzen die Transpositionsregeln und erhalten $(X^\top X)^\top = X^\top (X^\top)^\top = X^\top X$, woraus die Symmetrie folgt. $\square$

- Es ist $\frac{\partial}{\partial \theta} (-2\theta^\top X^\top y) = -2X^\top y$ und $\frac{\partial}{\partial \theta} y^\top y = 0$.
- Der Gradient der Fehlerfunktion J_{LS} ist damit gegeben durch

$$\frac{\partial}{\partial \theta} J_{LS}(\theta) = \frac{1}{2N} (2X^\top X \theta - 2X^\top y) \propto X^\top X \theta - X^\top y = X^\top (X \theta - y)$$

Bemerkung: Man beachte den Zusammenhang zwischen dem Gradienten und dem Vorhersagefehler: Je größer der Fehler, desto größer auch der Gradient!

Minimierung der Fehlerfunktion (Forts.)

Wir setzen den Gradienten nun Null und lösen nach θ auf:

$$\frac{\partial}{\partial \theta} J_{\text{LS}}(\theta) \stackrel{!}{=} \mathbf{0} \quad \Longleftrightarrow \quad X^{\top} X \theta - X^{\top} y = \mathbf{0}$$

$$\Longleftrightarrow \quad X^{\top} X \theta = X^{\top} y$$

$$\Longleftrightarrow \quad \theta^{\star} = (X^{\top} X)^{-1} X^{\top} y$$

Bemerkung: Wir haben damit einen stationären Punkt von J_{LS} gefunden. Allerdings wissen wir noch nicht, ob es sich tatsächlich um ein Minimum handelt. Außerdem sind wir hier etwas naiv von der Existenz der Inversen $(X^{\top} X)^{-1}$ ausgegangen. Existiert diese Matrix immer?

Mit diesen Fragen beschäftigen wir uns im Folgenden.

Ein paar nützliche Aussagen

1.2 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ ist $A^\top A$ positiv semidefinit.

Beweis: Für alle $z \in \mathbb{R}^M$ gilt $z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 \geq 0$, die Behauptung. □

1.3 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ mit *vollem Spaltenrang* ist $A^\top A$ positiv definit.

Beweis: Da A vollen Spaltenrang hat, sind die Spaltenvektoren linear unabhängig. Daher ist Az für alle $z \in \mathbb{R}^M \setminus \{0\}$ eine nicht-triviale Linearkombination der Spalten von A . Folglich gilt $Az \neq 0$ und wir erhalten

$$z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 > 0,$$

woraus die Behauptung folgt. □

Ein paar nützliche Aussagen (Forts.)

1.4 Satz: Wenn A positiv definit ist, so ist A auch invertierbar.

Beweis: Wir nehmen an, A sei nicht invertierbar. Dann sind die Spalten von A linear abhängig und es existiert ein $z \in \mathbb{R}^M \setminus \{0\}$ mit $Az = 0$. Daraus folgt aber

$$z^T Az = z^T 0 = 0,$$

was der Definitheitseigenschaft von A widerspricht. A muss folglich invertierbar sein. □

Handelt es sich nun um ein Minimum?

Um diese Frage zu klären, berechnen wir die **Hesse-Matrix** von J_{LS} und untersuchen, ob die Matrix im stationären Punkt θ^* positiv definit ist.

- Man rechnet nach, dass die Hesse-Matrix gegeben ist durch

$$\frac{\partial^2}{\partial \theta \partial \theta} J_{LS}(\theta) = X^T X.$$

- Mit Satz 1.3 ist diese Matrix positiv definit für alle θ , falls X vollen Spaltenrang hat, d. h. **die Features müssen linear unabhängig sein**. In diesem Fall handelt es sich bei θ^* also tatsächlich um ein Minimum.
- Unter derselben Voraussetzung haben wir damit sogar die **Konvexität** von J_{LS} bewiesen, sodass das Minimum **global und eindeutig** ist.

Und wie sieht es nun mit der Existenz der Inversen aus?

- Mit Satz 1.4 ist die Existenz der Inversen sichergestellt, wenn $X^T X$ positiv definit ist, was wiederum aus der linearen Unabhängigkeit der Features folgt (Satz 1.3).
- **Achtung:** Bei der numerischen Berechnung der Inversen auf dem Computer kann es jedoch trotzdem zu Problemen kommen. Es ist ratsam, die Inverse nicht explizit zu berechnen, sondern stattdessen das lineare Gleichungssystem $X^T X \theta = X^T y$ nach θ zu lösen. Dieses Vorgehen ist numerisch stabiler.
- Alternativ kann das Optimierungsproblem mit dem **Gradientenabstiegsverfahren** gelöst werden. Iteriere hierzu die Regel:

$$\theta_{t+1} \leftarrow \theta_t - \alpha X^T (X \theta_t - y). \quad (1.1)$$

Normalengleichungen

Wir fassen unsere Ergebnisse zusammen:

1.5 Satz: Die Design Matrix $X \in \mathbb{R}^{N \times (M+1)}$ des Regressionsproblems habe vollen Spaltenrang, d. h. die Features seien linear unabhängig. Dann existiert die Inverse $(X^\top X)^{-1}$ und

$$\theta^\star = (X^\top X)^{-1} X^\top y$$

ist das eindeutige globale Minimum von J_{LS} . Die Gleichungen $X^\top X \theta = X^\top y$ bezeichnet man als **Normalengleichungen**.

Eine probabilistische Sicht

Annahme 1: Die Zielwerte $y \in \mathbb{R}$ und die Eingaben $\mathbf{x} \in \mathbb{R}^{M+1}$ hängen über die Gleichung

$$y = \boldsymbol{\theta}^\top \mathbf{x} + \varepsilon \quad (1.2)$$

zusammen. Dabei ist $\varepsilon \in \mathbb{R}$ ein Fehlerterm, der nicht modellierte Effekte oder Datenrauschen repräsentiert.

Annahme 2: Für den Fehlerterm gilt $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Der Zielwert y kann damit als Zufallsvariable aufgefasst werden, für die gilt

$$y \mid \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2). \quad (1.3)$$

Visualisierung: Probabilistische Regression

tbd

Maximum-Likelihood Regression

- Wir betrachten wieder einen Datensatz $\{(\mathbf{x}_n, y_n)\}$ bestehend aus N Trainingsbeispielen.
- Die Likelihood des Modells ist gegeben durch

$$\begin{aligned} p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) &= \prod_{n=1}^N p(y_n \mid \mathbf{x}_n; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{1}{2\sigma^2} \left(y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n)\right)^2\right) \end{aligned} \tag{1.4}$$

- Wir gehen im Folgenden von der Verwendung von Basisfunktionen $\boldsymbol{\phi}$ aus.

Maximum-Likelihood Regression (Forts.)

- Durch Logarithmieren von (1.4) erhalten wir die Log-Likelihood Funktion

$$\begin{aligned} l(\boldsymbol{\theta}, \sigma^2) &:= \ln p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \end{aligned} \quad (1.5)$$

- Aus (1.5) wird ersichtlich, dass der Least-Squares-Fehler minimiert werden muss, um die Likelihood in $\boldsymbol{\theta}$ zu maximieren.
- Die Lösung für $\boldsymbol{\theta}$ ist dieselbe wie in Satz 1.5, zusätzlich kann die globale Unsicherheit des Modells quantifiziert werden

$$\hat{\boldsymbol{\theta}}_{ML} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (y_n - \hat{\boldsymbol{\theta}}_{ML}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \quad (1.6)$$

Visualisierung: Maximum-Likelihood Regression

tbd

Berücksichtigung einer Apriori-Verteilung

- Die Maximum-Likelihood Lösung ist **anfällig für Overfitting**.
- Eine Möglichkeit der **Regularisierung** ist die Verwendung einer **Apriori-Verteilung** (Prior).
- Für diese Verteilung über den Parametern θ benutzen wir die Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, b^2 \mathbf{I}). \quad (1.7)$$

- Es handelt sich hierbei um eine **isotropische Normalverteilung** (rotationsinvariant).
- Der Prior kann benutzt werden, um Vorwissen zu berücksichtigen.
- Er kodiert, welche Parameterwerte apriori plausibel sind.
- Häufig ist der Prior jedoch **nicht informativ** (z. B. Gleichverteilung).

Warum die Normalverteilung?

Frage: Warum benutzen wir eine Normalverteilung?

- Ein Argument ist **Konjugiertheit**: Da Prior und Likelihood durch Normalverteilungen gegeben sind, ist auch der *Posterior normalverteilt*. Dies vereinfacht die mathematischen Betrachtungen erheblich.
- Für Operationen auf Normalverteilungen gibt es meistens *analytische Lösungen*.

Satz von Bayes

- Wir benutzen den **Satz von Bayes**

$$p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) = \frac{\overbrace{p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2)}^{\text{Likelihood}} \cdot \overbrace{p(\boldsymbol{\theta}; b^2)}^{\text{Prior}}}{p(\mathbf{y} \mid \mathbf{X})} \quad (1.8)$$
$$\propto p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) \cdot p(\boldsymbol{\theta}; b^2).$$

- Wir betrachten $\boldsymbol{\theta}$ nun als (vektorwertige) Zufallsvariable (*sie steht nun vor dem Semikolon*).
- Bisher haben wir nur die Likelihood maximiert, nun berücksichtigen wir auch den Prior $p(\boldsymbol{\theta}; b^2)$.

Frage: Warum ignorieren wir den Nenner in (1.8)?

Log-Posterior Verteilung

- Anstelle der Log-Likelihood maximieren wir den **Log-Posterior**.
- Diesen erhalten wir aus (1.8) durch Logarithmieren

$$\ln p(\boldsymbol{\theta} \mid X, \mathbf{y}) = \ln p(\mathbf{y} \mid X, \boldsymbol{\theta}; \sigma^2) + \ln p(\boldsymbol{\theta}; b^2) + \text{const.} \quad (1.9)$$

- Die Konstante const enthält alle Terme, die nicht von $\boldsymbol{\theta}$ abhängen.
- Die **MAP-Schätzung** (Maximum A posteriori) ist ein Kompromiss zwischen dem datenunabhängigen Prior und der datenabhängigen Likelihood.
- Wir betrachten im Folgenden den **negativen Log-Posterior** und erhalten

$$\hat{\boldsymbol{\theta}}_{MAP} := \arg \min_{\boldsymbol{\theta}} \left\{ -\ln p(\mathbf{y} \mid X, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) \right\}. \quad (1.10)$$

Log-Posterior Verteilung (Forts.)

Unter Verwendung der Transpositionsregeln schreiben wir (1.10) um zu

$$\begin{aligned} -\ln p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) &= -\ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta})^\top (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \mathbf{y} + (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - 2\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \mathbf{y}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const}. \end{aligned} \tag{1.11}$$

1.6 Aufgabe: Überlegen Sie sich, wie man in (1.11) von Zeile 1 auf Zeile 2 kommt.

Berechnung des Gradienten

1.7 Aufgabe: Jetzt sind Sie an der Reihe:

- 1 Berechnen Sie den Gradienten der negativen Log-Likelihood $-\ln p(\theta | X, \mathbf{y})$. Benutzen Sie hierzu die Form aus (1.11).
- 2 Setzen Sie den Gradienten anschließend Null und lösen Sie nach θ auf.
- 3 Die Lösungsformel für $\hat{\theta}_{MAP}$ fordert die Invertierung einer Matrix. Zeigen Sie, dass diese Inverse (zumindest analytisch) immer existiert.

Vergleich der MLE und MAP Lösungen

MLE-Schätzer:

$$\hat{\theta}_{ML} = (\Phi^T \Phi)^{-1} \Phi^T y \quad (1.12)$$

MAP-Schätzer:

$$\hat{\theta}_{MAP} = \left(\Phi^T \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^T y \quad (1.13)$$

Bemerkung: Setzt man $\lambda := \sigma^2/b^2$, so entspricht die MAP-Schätzung der Ridge-Regression.

Visualisierung: Vergleich der MLE und MAP Lösungen

tbd

Bayes'sche Regression

- Wir haben gesehen, dass ML-Schätzungen zu **Overfitting** neigen.
- Für die MAP-Schätzung haben wir deshalb zusätzlich einen Prior $p(\theta)$ berücksichtigt, welcher der **Regularisierung** dient.

Die **Bayes'sche Regression** erweitert diesen Ansatz folgendermaßen:

- Wieder benutzen wir einen Prior $p(\theta)$ für die Parameter θ .
- **Aber:** Wir berechnen diesmal keine Punktschätzung der Parameter.
- Stattdessen nutzen wir die *volle Posterior-Verteilung* aus, um Vorhersagen zu machen.
- Hierzu berechnet man die **Predictive Distribution**, die sämtliche Parameterwerte mit ihren zugehörigen Wahrscheinlichkeiten in die Vorhersage einfließen lässt.

Bayes'sche Regression: Der Ausgangspunkt

- Für den Prior benutzen wir wieder eine Normalverteilung

$$\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0). \quad (1.14)$$

- Es ist $\boldsymbol{\mu}_0$ der Mittelwert des Priors (meistens setzen wir $\boldsymbol{\mu}_0 := \mathbf{0}$) und $\boldsymbol{\Sigma}_0$ dessen Kovarianzmatrix.
- Die Likelihood modellieren wir ebenfalls analog

$$y \mid \mathbf{x}', \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}'), \sigma^2). \quad (1.15)$$

- Hierbei ist $\mathbf{x}'$ ein Datenpunkt, für den eine Vorhersage berechnet werden soll.

Prior Predictive Distribution

- In der Praxis interessieren uns die konkreten Werte der Parameter in der Regel nicht.
- Wir wollen hauptsächlich die Labels für neue Instanzen vorhersagen.
- Sei also x' eine Testinstanz.
- Die **Prior Predictive Distribution** ist gegeben durch

$$p(y \mid x') = \int_{\theta} p(y \mid x', \theta) \cdot p(\theta) = \mathbb{E}_{\theta}[p(y \mid x', \theta)]. \quad (1.16)$$

- Man kann (1.16) als *mittlere Vorhersage* interpretieren.
- Es handelt sich um einen *gewichteten Durchschnitt über alle möglichen Parameterwerte gemäß ihrer Wahrscheinlichkeit*.

Parameter der Prior Predictive Distribution

Die Parameter lassen sich analytisch bestimmen:

1.8 Satz: Für die Prior Predictive Distribution gilt

$$y \mid \mathbf{x}' \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

wobei die Parameter $\boldsymbol{\mu}$ und $\boldsymbol{\Sigma}$ gegeben sind durch

$$\boldsymbol{\mu} := \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}')$$

$$\boldsymbol{\Sigma} := \boldsymbol{\phi}(\mathbf{x}')^\top \boldsymbol{\Sigma}_0 \boldsymbol{\phi}(\mathbf{x}') + \sigma^2.$$

1.9 Aufgabe: Machen Sie sich diese Aussage anhand von (??) klar.

Interpretation

- Der Erwartungswert μ ergibt sich als das Skalarprodukt des Erwartungswerts des Priors mit dem Feature Vektor.
- Der Term $\phi(x')^\top \Sigma_0 \phi(x')$ spiegelt die Unsicherheit der Parameter θ unter dem Prior wider.
- σ^2 stellt Unsicherheit aufgrund von Datenrauschen dar.
- Durch jedes θ , das wir vom Prior sampeln, erhält man eine Funktion $f(x') := \theta^\top \phi(x')$.

Die Parameterverteilung $p(\theta)$ induziert eine Verteilung $p(f(x))$ über mögliche Funktionen.

Beispiel

- Wir nehmen an, dass die Labels durch die (in der Praxis natürlich unbekannte) Funktion $f(x) = \sin(x)$ generiert werden.
- Zusätzlich addieren wir einen Noise-Term, für den $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ gilt.
- Ein Trainingsbeispiel (x_n, y_n) hat dann die Form

$$(x_n, y_n) = (x_n, \sin(x_n) + \varepsilon_n), \quad n = 1, 2, \dots, N.$$

- Als Prior über die Parameter θ wählen wir eine zentrierte, isotropische Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, I).$$

Beispiel (Forts.)




Abbildung: Plot des Datensatzes.

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Zufällige Samples, die von der Prior Verteilung gezogen werden.

Berücksichtigung der Trainingsdaten

- Unser bisheriges Modell nutzt noch nicht die Information aus den Trainingsdaten.
- Statt dem Prior $p(\theta)$ müssen wir den Posterior $p(\theta | X, y)$ benutzen.
- Hierfür benutzen wir wieder den **Satz von Bayes**

$$p(\theta | X, y) = \frac{\overbrace{p(y | X, \theta)}^{\text{Likelihood}} \cdot \overbrace{p(\theta)}^{\text{Prior}}}{p(y | X)} \quad (1.17)$$

1.10 Satz: Für den Posterior gilt $\theta | X, y \sim \mathcal{N}(\mu_N, \Sigma_N)$ mit

$$\Sigma_N := (\Sigma_0^{-1} + \sigma^{-2} \Phi^\top \Phi)^{-1}$$

$$\mu_N := \Sigma_N (\Sigma_0^{-1} \mu_0 + \sigma^{-2} \Phi^\top y).$$

Berücksichtigung der Trainingsdaten (Forts.)

1.11 Aufgabe: Machen Sie sich diese Aussage anhand von (??) klar.

- Die Parameter der Posterior Predictive Distribution werden analog zu Satz 1.8 bestimmt.
- Man ersetzt dort lediglich μ_0 durch μ_N und Σ_0 durch Σ_N .

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Plot der Posterior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Zufällige Samples, die von der Posterior Verteilung gezogen werden.

Literatur