Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

Inhaltsverzeichnis

1. Gaussian Mixture Models (GMMs)
2. Expectation-Maximization (EM) Algorithmus
3. Principal Component Analysis (PCA)
4. Independent Component Analysis (ICA)

Kapitel

1 **Gaussian Mixture Models (GMMs)**

Problemstellung

Gaussian Mixture Models und latente Variablen

Maximum-Likelihood Lösung

Expectation-Maximization (EM) Algorithmus für GMMs

Problemstellung

- Wir wissen bereits, wie wir die Parameter $\boldsymbol{\mu}$ und $\boldsymbol{\Sigma}$ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**
  - Gegeben sei ein Datensatz $\boldsymbol{X}$ bestehend aus N unabhängig und identisch normalverteilten Punkten $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N$.
  - Schätze den Mittelwert $\boldsymbol{\mu}$ gemäß

$$\hat{\boldsymbol{\mu}}_{ML} := \frac{1}{N} \sum_{n=1}^{N} \boldsymbol{x}_n. \tag{1.1}$$

  - Schätze die Kovarianzmatrix $\boldsymbol{\Sigma}$ mittels

$$\hat{\boldsymbol{\Sigma}}_{ML} := \frac{1}{N} \sum_{n=1}^{N} (\boldsymbol{x}_n - \hat{\boldsymbol{\mu}}_{ML})(\boldsymbol{x}_n - \hat{\boldsymbol{\mu}}_{ML})^\top. \tag{1.2}$$

Frage: Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung

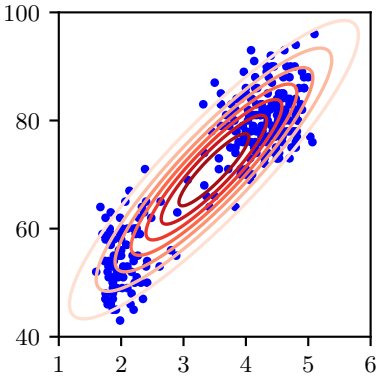

Abbildung: Modell bestehend aus einer Normalverteilung. Siehe **Bishop2024**, Seite 86.

Visualisierung: Problemstellung (Forts.)

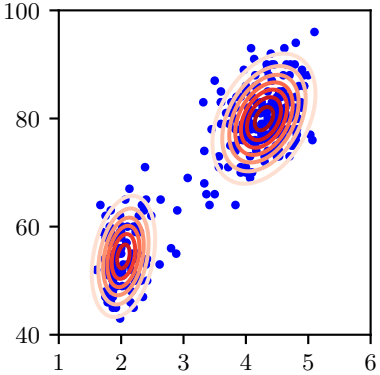

Abbildung: Mixture Modell bestehend aus zwei Normalverteilungen. Siehe **Bishop2024**, Seite 86.

Gaussian Mixture Models

- Wir können ein **Gaussian Mixture Model** als eine *Überlagerung mehrerer Normalverteilungen* ansehen.
- Die Dichte bei K Komponenten ist gegeben durch

$$p(\boldsymbol{x};\boldsymbol{\theta}) := \sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x};\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \tag{1.3}$$

- Dabei enthält $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \ldots, \pi_K, \boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \ldots, \boldsymbol{\Sigma}_K)$ die Modellparameter.
- Die **Mischkoeffizienten** π_k stellen sicher, dass die Mixture-Dichte *normiert* ist, dass also $\int_{-\infty}^{+\infty} p(\boldsymbol{x};\boldsymbol{\theta}) = 1$ gilt.
- Die π_k erfüllen zudem

$$0 \leq \pi_k \leq 1 \qquad \text{und} \qquad \sum_{k=1}^{K} \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $\boldsymbol{z} \in \mathbb{R}^K$ ein K-dimensionaler **One-Hot Vektor**.
- Die Komponenten z_k erfüllen also $z_k \in \{0,\ 1\}$ und $\sum_{k=1}^{K} z_k = 1$, wobei *genau eine Komponente* den Wert 1 annimmt.
- Wir definieren nun die gemeinsame Verteilung von $\boldsymbol{x}$ und $\boldsymbol{z}$ über die Kettenregel

$$p(\boldsymbol{x},\ \boldsymbol{z}) = p(\boldsymbol{x} \mid \boldsymbol{z}) \cdot p(\boldsymbol{z}).$$

- Für die Definition der Randverteilung $p(\boldsymbol{z})$ benutzen wir die Mischkoeffizienten: $p(z_k = 1; \pi_k) := \pi_k$.
- Da $\boldsymbol{z}$ ein One-Hot Vektor ist, können wir schreiben

$$p(\boldsymbol{z}; \boldsymbol{\pi}) = \prod_{k=1}^{K} \pi_k^{z_k}. \tag{1.4}$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Analog definieren wir

$$p(\boldsymbol{x} \mid z_k = 1; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) := \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Dies können wir ebenfalls vektorisiert ausdrücken als

$$p(\boldsymbol{x} \mid z; \boldsymbol{\mu}, \boldsymbol{\Sigma}) := \prod_{k=1}^{K} \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \tag{1.5}$$

- Die Randverteilung $p(\boldsymbol{x}; \boldsymbol{\theta})$ erhalten wir schließlich, indem wir über alle möglichen Werte z summieren

$$p(\boldsymbol{x}; \boldsymbol{\theta}) = \sum_{z} p(z; \boldsymbol{\pi}) \cdot p(\boldsymbol{x} \mid z; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \tag{1.6}$$

- Im letzten Gleichheitszeichen haben wir (1.4) und (1.5) zusammen mit der One-Hot Eigenschaft von z benutzt.

Latente Variablen

- Falls ein Datensatz $\boldsymbol{X}$ bestehend aus N Punkten $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N$ vorliegt (und nicht nur ein einzelner Punkt $\boldsymbol{x}$), so führen wir für jedes $\boldsymbol{x}_n$ ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt $\boldsymbol{x}_n$.
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass $\boldsymbol{x}_n$ von Komponente k generiert wurde.
- Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend.
- Allerdings können wir nun mit der Verteilung $p(\boldsymbol{x}, z; \boldsymbol{\theta})$ anstelle von $p(\boldsymbol{x}; \boldsymbol{\theta})$ arbeiten, was zu *wesentlichen Vereinfachungen* führen wird.
- Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Nachfolgend interessieren wir uns besonders für die Aposteriori-Wahrscheinlichkeit $p(\boldsymbol{z} \mid \boldsymbol{x}; \boldsymbol{\theta})$.
- Mit $\gamma(z_k)$ bezeichnen wir die Wahrscheinlichkeit $p(z_k = 1 \mid \boldsymbol{x}; \boldsymbol{\theta})$.
- Mit dem *Satz von Bayes* gilt

$$\begin{aligned} \gamma(z_k) := p(z_k = 1 \mid \boldsymbol{x}; \boldsymbol{\theta}) &= \frac{p(z_k = 1) \cdot p(\boldsymbol{x} \mid z_k = 1)}{\sum_{j=1}^{K} p(z_j = 1) \cdot p(\boldsymbol{x} \mid z_j = 1)} \\ &= \frac{\pi_k \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \cdot \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}. \end{aligned} \tag{1.7}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $z_k = 1$ und $\gamma(z_k)$ die Aposteriori-Wahrscheinlichkeit für $z_k = 1$, nachdem $\boldsymbol{x}$ beobachtet wurde.
- Man nennt $\gamma(z_k)$ auch die **Responsibility** der k-ten Komponente für Punkt $\boldsymbol{x}$.

Visualisierung: Responsibilities

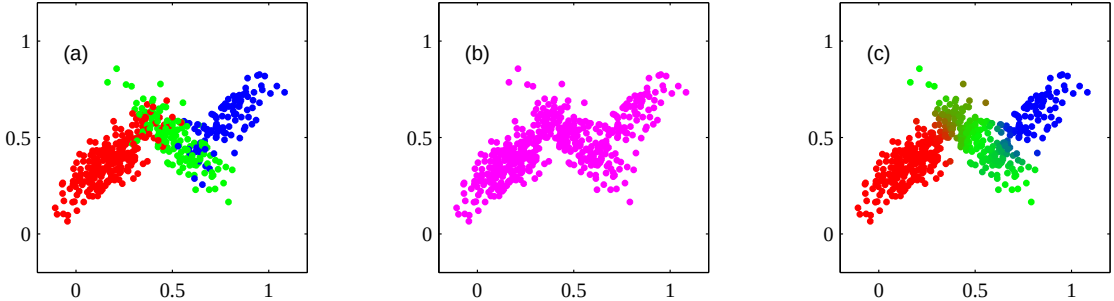

Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_{nk})$ gewählt. Siehe **Bishop2024**, Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N *unabhängigen und identisch verteilten* Punkten $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N$ gegeben.
- Wir fassen die Punkte $\{\boldsymbol{x}_n\}$ in der Matrix $\boldsymbol{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n-te Zeile durch $\boldsymbol{x}_n^\top$ gegeben ist.
- Mit (1.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned} \ln p(\boldsymbol{X}; \boldsymbol{\theta}) &= \ln \left(\prod_{n=1}^{N} \left(\sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \right) \\ &= \sum_{n=1}^{N} \ln \left(\sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right). \end{aligned} \tag{1.8}$$

- Aufgrund der Summe im Argument des Logarithmus ist (1.8) schwer zu optimieren.

Gradient der Log-Likelihood für die Mittelwerte

$$
\begin{aligned}
\frac{\partial}{\partial \boldsymbol{\mu}_k} \ln p(\boldsymbol{X}; \boldsymbol{\theta}) &= \sum_{n=1}^{N} \frac{1}{p(\boldsymbol{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} p(\boldsymbol{x}_n; \boldsymbol{\theta}) && \text{Anwendung der Kettenregel.} \\
&= \sum_{n=1}^{N} \left(\frac{1}{p(\boldsymbol{x}_n; \boldsymbol{\theta})} \cdot \sum_{j=1}^{K} \pi_j \frac{\partial}{\partial \boldsymbol{\mu}_k} \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) \right) && \text{Einsetzen der Definition von } p(\boldsymbol{x}_n; \boldsymbol{\theta}). \\
&= \sum_{n=1}^{N} \frac{\pi_k}{p(\boldsymbol{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) && \text{Nur } k\text{-ter Summand hängt von } \boldsymbol{\mu}_k \text{ ab.} \qquad (1.9) \\
&= \sum_{n=1}^{N} \frac{\pi_k \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \cdot \boldsymbol{\Sigma}_k^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}_k) && \text{Kettenregel für Exponentialfunktion.} \\
&= \sum_{n=1}^{N} \gamma(z_{nk}) \cdot \boldsymbol{\Sigma}_k^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}_k) && \text{Definition der Responsibilities.}
\end{aligned}
$$

Lösung für die Mittelwerte

- Wir setzen den Gradienten (1.9) Null, lösen nach $\boldsymbol{\mu}_k$ auf und erhalten

$$\sum_{n=1}^{N} \gamma(z_{nk}) \cdot \boldsymbol{\Sigma}_k^{-1}(\boldsymbol{x}_n - \boldsymbol{\mu}_k) \stackrel{!}{=} 0 \quad \Longleftrightarrow \quad \boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^{N} \gamma(z_{nk}) \cdot \boldsymbol{x}_n. \tag{1.10}$$

- Hierbei ist N_k die Summe der Responsibilities der k-ten Komponente, also

$$N_k := \sum_{n=1}^{N} \gamma(z_{nk}).$$

- Der Mittelwert $\boldsymbol{\mu}_k$ der k-ten Komponente ergibt sich also durch ein *gewichtetes arithmetisches Mittel* der Punkte $\{\boldsymbol{x}_n\}$, wobei die Gewichtungsfaktoren gerade die Aposteriori-Wahrscheinlichkeiten dafür sind, dass $\boldsymbol{x}_n$ durch die k-te Komponente generiert wurde.

Lösung für die Kovarianzmatrizen

- Ein ähnliches Ergebnis erhalten wir für die Kovarianzmatrizen $\boldsymbol{\Sigma}_k$.
- Es gilt

$$\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{n=1}^{N} \gamma(z_{nk}) \cdot (\boldsymbol{x}_n - \boldsymbol{\mu}_k)(\boldsymbol{x}_n - \boldsymbol{\mu}_k)^\top. \tag{1.11}$$

- Auch hier ergeben sich die Parameter als gewichtetes arithmetisches Mittel.

1.1 Aufgabe: Beweisen Sie diese Aussasge!

Optimierung bezüglich der Mischkoeffizienten

- Bei der Optimierung bezüglich der Mischkoeffizienten π_k müssen wir zusätzlich die Normierungsbedingung beachten:

$$\sum_{k=1}^{K} \pi_k = 1.$$

- Es handelt sich also um ein *restringiertes Optimierungsproblem*.
- Die **Lagrange-Funktion** ist

$$\begin{aligned} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \ln p(\boldsymbol{X}; \boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^{K} \pi_k - 1 \right) \\ &= \sum_{n=1}^{N} \ln \left(\sum_{k=1}^{K} \pi_k \cdot \mathcal{N}(\boldsymbol{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) + \lambda \left(\sum_{k=1}^{K} \pi_k - 1 \right) \end{aligned} \tag{1.12}$$

Gradient der Log-Likelihood für die Mischkoeffizienten

$$
\begin{aligned}
\frac{\partial}{\partial \pi_k} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \frac{\partial}{\partial \pi_k} \ln p(\boldsymbol{X}; \boldsymbol{\theta}) + \lambda \cdot \frac{\partial}{\partial \pi_k} \left(\sum_{k=1}^{K} \pi_k - 1 \right) && \text{Linearität des Differenzialoperators.} \\
&= \sum_{n=1}^{N} \frac{1}{p(\boldsymbol{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \pi_k} p(\boldsymbol{x}_n; \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) + \lambda && \text{Anwendung der Kettenregel.} \\
&= \frac{1}{\pi_k} \sum_{n=1}^{N} \frac{\pi_k \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda && \text{Zähler und Nenner mit } \pi_k \text{ erweitern.} \qquad (1.13) \\
&= \frac{1}{\pi_k} \sum_{n=1}^{N} \gamma(z_{nk}) + \lambda && \text{Definition der Responsibilities.} \\
&= \frac{N_k}{\pi_k} + \lambda && \text{Definition von } N_k.
\end{aligned}
$$

Lösung für die Mischkoeffizienten

- Zusätzlich benötigen wir noch die Ableitung von (1.12) nach λ.
- Wir erhalten

$$\frac{\partial}{\partial \lambda} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \sum_{k=1}^{K} \pi_k - 1. \tag{1.14}$$

- Setzen wir die Ableitungen (1.13) und (1.14) Null, so erhalten wir

$$\pi_k = -\frac{N_k}{\lambda} \quad \text{und} \quad 1 = \sum_{k=1}^{K} \pi_k.$$

- Setzen wir die erste Bedingung in die zweite ein, so erhalten wir $\lambda = -N$ und damit schließlich

$$\pi_k = \frac{N_k}{N}. \tag{1.15}$$

Expectation-Maximization (EM) Algorithmus für GMMs

- Bei den Lösungsformeln (1.10), (1.11) und (1.15) handelt es sich *nicht um geschlossene Lösungsformeln* **(!)**, da die Gewichte $\gamma(z_{nk})$ von den anderen Parametern abhängen.
- Allerdings legen die Ergebnisse ein einfaches *iteratives Verfahren* nahe, den **Expectation-Maximization (EM) Algorithmus**.
- Dieser besteht aus zwei Phasen, die **Expectation-Phase (E-Schritt)** und die **Maximization-Phase (M-Schritt)**.
- Im E-Schritt werden die Werte $\gamma(z_{nk})$ bei gegebenen Parametern $\boldsymbol{\pi}_k$, $\boldsymbol{\mu}_k$, $\boldsymbol{\Sigma}_k$ bestimmt.
- Im darauffolgenden M-Schritt werden die Parameter mit den neuen Werten $\gamma(z_{nk})$ aufdatiert.
- Dies führt man solange fort, bis Konvergenz eintritt.

Visualisierung: EM für GMMs

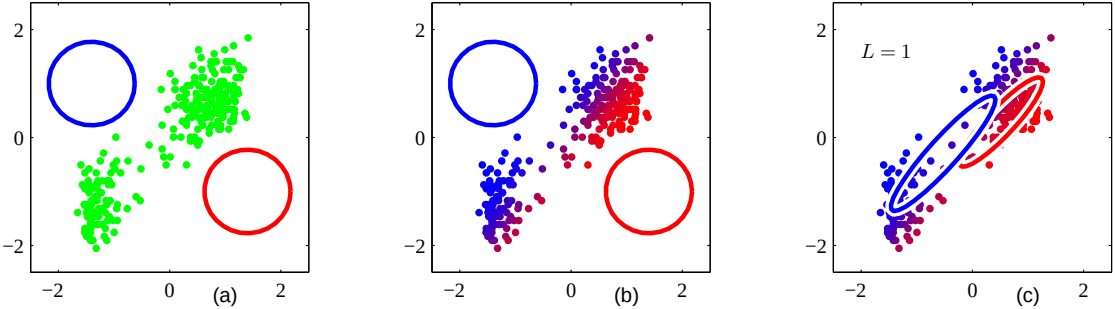

Abbildung: Visualisierung EM für GMMs. Siehe **Bishop2024**, Seite 473.

Visualisierung: EM für GMMs (Forts.)

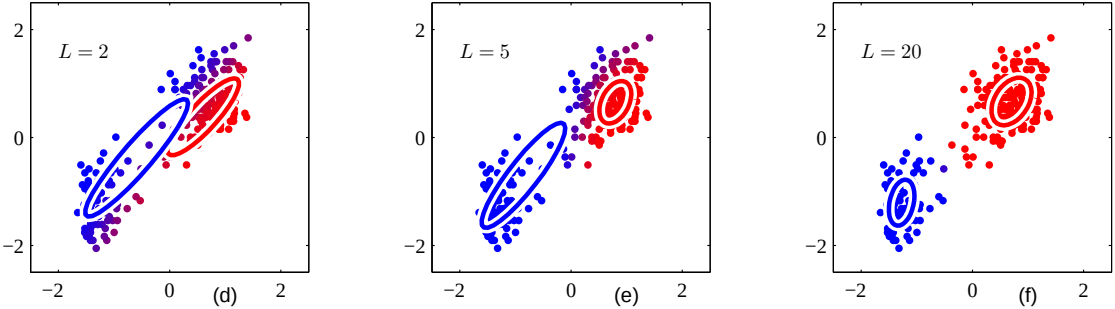

Abbildung: Visualisierung EM für GMMs. Siehe **Bishop2024**, Seite 473.

EM Algorithmus

Kapitel

2 **Expectation-Maximization (EM) Algorithmus**

Problemstellung

Ungleichung von Jensen

Herleitung des Expectation-Schritts

Herleitung des Maximization-Schritts

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Anwendung auf Gaussian Mixture Models

Problemstellung

- Wir betrachten ein statistisches Modell mit den Daten $\boldsymbol{X} = (\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N)^\top$, den **latenten Variablen** $\boldsymbol{Z} = (z_1, z_2, \ldots, z_N)^\top$ und den Modellparametern $\boldsymbol{\theta}$.
- Wie üblich ist unser Ziel die Maximierung der Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Wir nehmen an, dass die gemeinsame Verteilung $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ von $\boldsymbol{X}$ und $\boldsymbol{Z}$ gegeben ist.
- Hieraus können wir $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ bestimmen, indem wir über $\boldsymbol{Z}$ *marginalisieren*:

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \tag{2.1}$$

- In der Regel ist eine direkte Maximierung von (2.1) zu kompliziert, da der Logarithmus nicht direkt auf $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ wirken kann.

Problemstellung (Forts.)

- Mit $\{\boldsymbol{X},\ \boldsymbol{Z}\}$ bezeichnen wir den **vollständigen** Datensatz, $\boldsymbol{X}$ alleine nennen wir hingegen **unvollständig**.
- Analog nennen wir $\ln p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})$ die **vollständige Log-Likelihood** und $\ln p(\boldsymbol{X};\boldsymbol{\theta})$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von (2.1) schwer ist, möchten wir $\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ maximieren.
- **Problem:** Wir kennen $\boldsymbol{Z}$ nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in *zwei Phasen*, wobei man in jeder Iteration ausgehend von $\boldsymbol{\theta}_{\text{alt}}$ neue Parameter $\boldsymbol{\theta}_{\text{neu}}$ erhält, die (2.1) erhöhen.

E-Phase: Bestimme den Erwartungswert von $\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ unter der Aposteriori-Verteilung der latenten Variablen $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$.

M-Phase: Die berechnete untere Schranke wird bezüglich der Parameter $\boldsymbol{\theta}$ maximiert, was zu den aktualisierten Parametern $\boldsymbol{\theta}_{\text{neu}}$ führt.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

2.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen

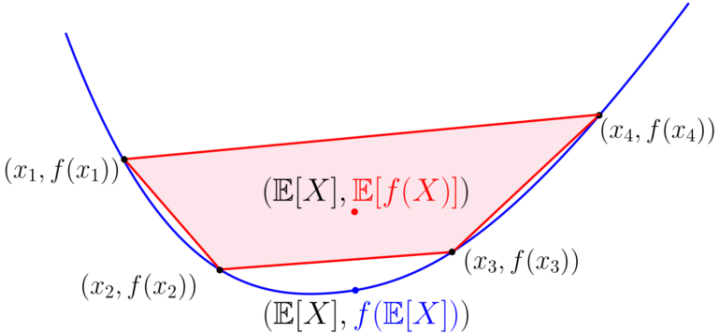

Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(\boldsymbol{X};\boldsymbol{\theta})$.
- Hierzu führen wir die Verteilung q über $\boldsymbol{Z}$ mit $q(\boldsymbol{Z}) \neq 0$ ein und erhalten

$$\begin{aligned}
\ln p(\boldsymbol{X};\boldsymbol{\theta}) &= \ln \sum_{\boldsymbol{Z}} p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta}) = \ln \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} \\
&= \ln \mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}\right] \\
&\geq \mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln \frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}\right] =: \mathcal{L}(q,\ \boldsymbol{\theta}).
\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen**, Satz (2.1), mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(\boldsymbol{X},\boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(\boldsymbol{X};\boldsymbol{\theta}) \geq \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})\right]}_{\substack{\textbf{Erwartete vollständige}\\ \textbf{Log-Likelihood}}} - \underbrace{\mathbb{E}_{\boldsymbol{Z}\sim q(\boldsymbol{Z})}\left[\ln q(\boldsymbol{Z})\right]}_{\textbf{Entropie}\text{ von } q}. \tag{2.2}$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müsssen.
- Wir möchten q so wählen, dass für das aktuelle $\boldsymbol{\theta}$ in (2.2) Gleichheit gilt.
- Die Ungleichung von Jensen, Satz (2.1), gilt mit Gleichheit, falls

$$\frac{p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})}{q(\boldsymbol{Z})} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\boldsymbol{Z}) \propto p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet *proportional zu*.
- Daraus erhalten wir (da q normiert sein muss)

$$q(\boldsymbol{Z}) = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\boldsymbol{Z}}} p(\boldsymbol{X}, \tilde{\boldsymbol{Z}}; \boldsymbol{\theta})} = \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{p(\boldsymbol{X}; \boldsymbol{\theta})}$$

$$= p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}).$$

- **Ergebnis:** Für q benutzen wir die Aposteriori-Verteilung von $\boldsymbol{Z}$ gegeben $\boldsymbol{X}$.
- Dies setzen wir in (2.2) ein und erhalten die Identität

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \right].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor $\boldsymbol{\theta}_{\text{alt}}$, mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\boldsymbol{Z}) := p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}) &\geq \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) \right] - \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \right] \\
&= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}}) \\
&= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},
\end{aligned}$$

  wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.
- Die Funktion $H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}})$ ist die **Entropie** von q unter $\boldsymbol{\theta}_{\text{alt}}$.

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\boldsymbol{\theta}_{\text{alt}}, \boldsymbol{\theta}_{\text{alt}})$ bezüglich $\boldsymbol{\theta}$ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}})$ gegeben.
- Der M-Schritt hat damit also die Gestalt

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}). \tag{2.3}$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(\boldsymbol{X} \mid \boldsymbol{\theta}_{\text{neu}}) \geq p(\boldsymbol{X} \mid \boldsymbol{\theta}_{\text{alt}})$ gilt.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

2.2 Algorithmus

1. Initialisiere $\boldsymbol{\theta}_{\text{alt}}$ (entweder zufällig oder mit Vorwissen).
2. **E-Schritt:** Bestimme die untere Schranke

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) := \mathbb{E}_{\boldsymbol{Z} \sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta}_{\text{alt}})} \left[\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})\right].$$

3. **M-Schritt:** Maximiere die untere Schranke und berechne

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}).$$

4. Falls noch keine Konvergenz vorliegt, gehe zurück zu Schritt 2 und setze $\boldsymbol{\theta}_{\text{alt}} := \boldsymbol{\theta}_{\text{neu}}$.
5. Ansonsten gebe $\boldsymbol{\theta}_{\text{neu}}$ zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus.
- Es gilt

$$
\begin{aligned}
\ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}}) &\geq \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}_{\text{neu}})}{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \\
&\geq \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}_{\text{alt}})}{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})} \\
&= \ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).
\end{aligned}
$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil $\boldsymbol{\theta}_{\text{neu}}$ so gewählt wurde, dass es die untere Schranke maximiert.

Visualisierung: EM-Algorithmus

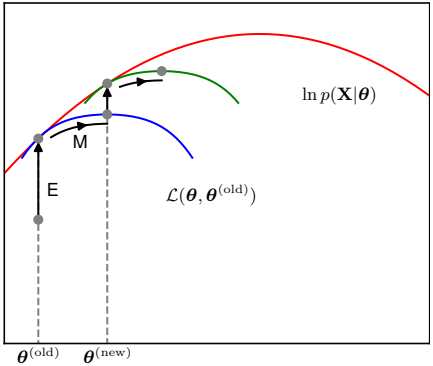

Abbildung: Veranschaulichung des EM-Algorithmus. Siehe **Bishop2024**, Seite 488.

Evidence Lower Bound (ELBO)

- Wir geben noch eine andere Sicht auf den EM-Algorithmus.
- Hierzu stellen wir fest, dass wir die Log-Likelihood $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ folgendermaßen zerlegen können

$$\ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \mathrm{KL}(q \parallel p). \tag{2.4}$$

- Dabei ist:
  - $\mathcal{L}(q, \boldsymbol{\theta})$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound**

$$\mathcal{L}(q, \boldsymbol{\theta}) := \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \ln \frac{p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} = \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})]. \tag{2.5}$$

  - $\mathrm{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\boldsymbol{Z})$ und $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$

$$\mathrm{KL}(q \parallel p) := -\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \ln \frac{p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})}{q(\boldsymbol{Z})} = -\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})]. \tag{2.6}$$

Beweis der Zerlegung (2.4)

Beweis: Wir beweisen die Zerlegung (2.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta})$ an. Wir erhalten $p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \cdot p(\boldsymbol{X}; \boldsymbol{\theta})$. Anwendung des Logarithmus ergibt

$$\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) = \ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}).$$

Dies setzen wir in die Evidence Lower Bound (2.5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})] \\ &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})].\end{aligned}$$

Damit ergibt sich schließlich mit (2.6) und wegen $\sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) = 1$

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) + \mathrm{KL}(q \parallel p) &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) + \ln p(\boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})] - \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot [\ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) - \ln q(\boldsymbol{Z})] \\ &= \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) \cdot \ln p(\boldsymbol{X}; \boldsymbol{\theta}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}) \cdot \sum_{\boldsymbol{Z}} q(\boldsymbol{Z}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}).\end{aligned}$$

□

Kullback-Leibler Divergenz

Eigenschaften der Kullback-Leibler Divergenz:

Für alle Wahrscheinlichkeitsverteilungen q und p gelten die folgenden Eigenschaften.

1. **Nicht-Negativität:**

$$\mathrm{KL}(q \parallel p) \geq 0 \tag{2.7}$$

2. **Identität:**

$$\mathrm{KL}(q \parallel p) = 0 \quad \Longleftrightarrow \quad q = p. \tag{2.8}$$

3. Es sei angemerkt, dass die Kullback-Leibler Divergenz **nicht symmetrisch** und damit keine Metrik ist. Es ist also im Allgemeinen

$$\mathrm{KL}(q \parallel p) \neq \mathrm{KL}(p \parallel q).$$

Kullback-Leibler Divergenz (Forts.)

- Aus (2.6) ist ersichtlich, dass $\mathrm{KL}(q \parallel p)$ die Kullback-Leibler Divergenz zwischen der Verteilung $q(\boldsymbol{Z})$ und der Aposteriori-Verteilung $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$ von $\boldsymbol{Z}$ ist.
- Aus der Zerlegung (2.4) folgt mit der Nichtnegativität (2.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\boldsymbol{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\boldsymbol{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood

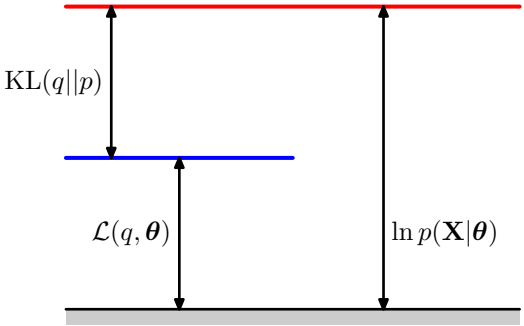

Abbildung: Veranschaulichung der Zerlegung (2.4). Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den E-Schritt

- Mit dieser Vorarbeit können wir nun die alternative Herleitung des EM-Algorithmus durchführen.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta}_{\text{alt}})$ bezüglich $q(\boldsymbol{Z})$ bei gegebenem $\boldsymbol{\theta}_{\text{alt}}$ maximiert, sodass die untere Schranke die eigentliche Zielfunktion $\ln p(\boldsymbol{X}; \boldsymbol{\theta})$ in $\boldsymbol{\theta}_{\text{alt}}$ berührt.
- Da $p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$ nicht von $q(\boldsymbol{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \boldsymbol{\theta}_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (2.8) für $q(\boldsymbol{Z})$ gelten

$$q(\boldsymbol{Z}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \boldsymbol{\theta}_{\text{alt}}) = \ln p(\boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}).$$

Visualisierung: E-Schritt

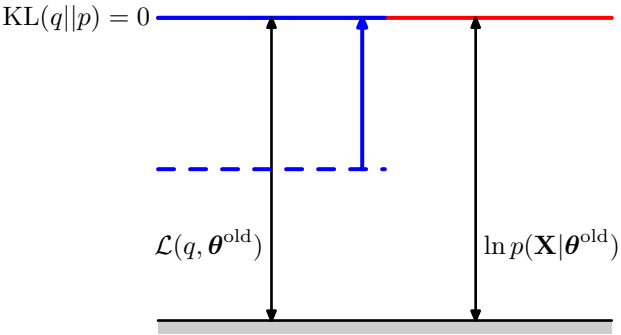

Abbildung: Veranschaulichung des E-Schritts. Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\boldsymbol{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Hierdurch erhalten wir die neuen Parameter $\boldsymbol{\theta}_{\text{neu}}$, die letztendlich zu einer höheren Log-Likelihood $p(\boldsymbol{X}; \boldsymbol{\theta})$ führen.
- Setzen wir $q(\boldsymbol{Z}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}})$ in die Definition der unteren Schranke (2.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\boldsymbol{X}, \boldsymbol{Z}; \boldsymbol{\theta}) - \sum_{\boldsymbol{Z}} p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \\ &= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}})$ maximieren, wobei Q die **erwartete vollständige Log-Likelihood** ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (2.3) an

$$\boldsymbol{\theta}_{\text{neu}} := \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern $\boldsymbol{\theta}_{\text{alt}}$ bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\boldsymbol{Z}) = p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{alt}}) \neq p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}}),$$

  sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.
- Im folgenden E-Schritt setzen wir dann $q(\boldsymbol{Z}) := p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt

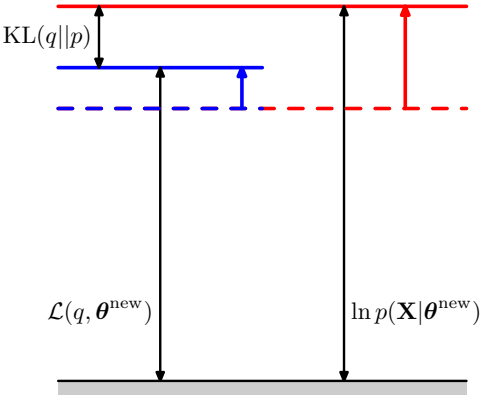

Abbildung: Veranschaulichung des M-Schritts. Siehe **Bishop2024**, Seite 487.

Gaussian Mixture Models und EM

- Wir wenden das allgemeine EM-Framework nun auf GMMs an.
- Im E-Schritt benötigen wir die Aposteriori-Verteilung $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$ der latenten Variablen, wobei $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \ldots, \pi_K, \boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \ldots, \boldsymbol{\Sigma}_K)$ ist.
- Diese können wir mit (1.4), (1.5) und dem Satz von Bayes bestimmen zu

$$p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta}) \propto \prod_{n=1}^{N} \prod_{k=1}^{K} [\pi_k \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}.$$

- Als nächstes stellen wir die erwartete vollständige Log-Likelihood auf, wobei der Erwartungswert bezüglich der Aposteriori-Verteilung $p(\boldsymbol{Z} \mid \boldsymbol{X}; \boldsymbol{\theta})$ zu berechnen ist.
- Dazu benötigen wir allerdings noch ein Zwischenergebnis, das wir auf der nächsten Folie bereitstellen.

Gaussian Mixture Models und EM (Forts.)

- Es gilt der Zusammenhang

$$\begin{aligned}\mathbb{E}_{\boldsymbol{Z}\sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta})}[z_{nk}] &= \frac{\sum_{\boldsymbol{z}_n} z_{nk} \prod_{k'=1}^{K} [\pi_{k'} \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_{k'}, \boldsymbol{\Sigma}_{k'})]^{z_{nk'}}}{\sum_{\boldsymbol{z}_n} \prod_{j=1}^{K} [\pi_j \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\ &= \frac{\pi_k \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \cdot \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(z_{nk}).\end{aligned} \tag{2.9}$$

- Der Erwartungswert der Indikator-Variablen z_{nk} unter der Aposteriori-Verteilung von $\boldsymbol{Z}$ ergibt sich also gerade als die jeweilige Responsibility $\gamma(z_{nk})$.

Gaussian Mixture Models und EM (Forts.)

Hiermit können wir nun die **erwartete vollständige Log-Likelihood** (Funktion Q) aufstellen

$$
\begin{aligned}
\mathbb{E}_{\boldsymbol{Z}\sim p(\boldsymbol{Z}|\boldsymbol{X};\boldsymbol{\theta})}[\ln p(\boldsymbol{X},\ \boldsymbol{Z};\boldsymbol{\theta})] &= \mathbb{E}\left[\ln \prod_{n=1}^{N}\prod_{k=1}^{K} \pi_k^{z_{nk}} \cdot \mathcal{N}(\boldsymbol{x}_n;\boldsymbol{\mu}_k,\ \boldsymbol{\Sigma}_k)^{z_{nk}}\right] \\
&= \mathbb{E}\left[\sum_{n=1}^{N}\sum_{k=1}^{K} z_{nk} \cdot \{\ln \pi_k + \ln \mathcal{N}(\boldsymbol{x}_n;\boldsymbol{\mu}_k,\ \boldsymbol{\Sigma}_k)\}\right] && \text{Logarithmengesetze.} \\
&= \sum_{n=1}^{N}\sum_{k=1}^{K} \mathbb{E}[z_{nk}] \cdot \{\ln \pi_k + \ln \mathcal{N}(\boldsymbol{x}_n;\boldsymbol{\mu}_k,\ \boldsymbol{\Sigma}_k)\} && \text{Linearität von } \mathbb{E}. \\
&= \sum_{n=1}^{N}\sum_{k=1}^{K} \gamma(z_{nk}) \cdot \{\ln \pi_k + \ln \mathcal{N}(\boldsymbol{x}_n;\boldsymbol{\mu}_k,\ \boldsymbol{\Sigma}_k)\} && \text{Anwendung von (2.9).}
\end{aligned}
\tag{2.10}
$$

Gaussian Mixture Models und EM (Forts.)

- Die Funktion (2.10) müssen wir nun im M-Schritt bezüglich der Parameter maximieren.
- **Beispielhaft:** Gradient bezüglich $\boldsymbol{\mu}_k$

$$\begin{aligned}
\frac{\partial}{\partial \boldsymbol{\mu}_k} \sum_{n=1}^{N} \sum_{j=1}^{K} \gamma(z_{nj}) \cdot \{\ln \pi_j + \ln \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)\} &= \sum_{n=1}^{N} \gamma(z_{nk}) \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} \ln \mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \\
&= \sum_{n=1}^{N} \gamma(z_{nk}) \cdot \frac{\mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\mathcal{N}(\boldsymbol{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \cdot \boldsymbol{\Sigma}_k^{-1}(\boldsymbol{x}_n - \boldsymbol{\mu}_k) \\
&= \sum_{n=1}^{N} \gamma(z_{nk}) \cdot \boldsymbol{\Sigma}_k^{-1}(\boldsymbol{x}_n - \boldsymbol{\mu}_k).
\end{aligned}$$

- Vergleiche hierzu die Herleitung in (1.9).

Gaussian Mixture Models und EM (Forts.)

- Nullsetzen und Auflösen nach $\boldsymbol{\mu}_k$ ergibt

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^{N} \gamma(z_{nk}) \cdot \boldsymbol{x}_n.$$

- Dies hat dieselbe Form wie (1.10).
- Die anderen Formeln ergeben sich analog.

Kapitel

3 Principal Component Analysis (PCA)

Problemstellung

Problemstellung

-

Kapitel

4 **Independent Component Analysis (ICA)**

Motivation: Cocktail Party Problem

Formalisierung des Problems

Annahmen und Limitationen der ICA

Whitening

ICA durch Maximum Likelihood Schätzung

Cocktail Party Problem

Zur Motivation betrachten wir das folgende Problem:

- Auf einer Party sprechen N Personen gleichzeitig.
- Im Raum werden Mikrofone aufgestellt, welche *überlappende Kombinationen* der Stimmen der Sprecher aufzeichnen.
- Der Einfachheit halber nehmen wir an, dass sich ebenfalls N Mikrofone im Raum befinden.
- Da die Entfernung der Sprecher zu den einzelnen Mikrofonen verschieden ist, handelt es sich hierbei um leicht *verschiedene Kombinationen*.

Frage: Können wir die Stimmen der N Sprecher aus den N Aufzeichnungen isolieren?

Beispiel: Cocktail Party Problem

tbd

Mathematische Formulierung des Problems

- Es seien die Signale $\boldsymbol{s}_t \in \mathbb{R}^N$ gegeben, welche von N *unabhängigen* **(!)** Quellen zum Zeitpunkt $t = 1, 2, \ldots, T$ erzeugt werden (das sind die Sprecher im Cocktail Party Problem).
- Allerdings beobachten wir nur die gemischten Daten $\boldsymbol{x}_t \in \mathbb{R}^N$ zum Zeitpunkt t (das sind die Aufnahmen der Mikrofone).
- Das ICA-Modell nimmt an, dass es sich hierbei um *Linearkombinationen* der Quellsignale handelt.
- Wir betrachten also das Modell

$$\boldsymbol{x}_t = \boldsymbol{A}\boldsymbol{s}_t, \tag{4.1}$$

  wobei $\boldsymbol{A} \in \mathbb{R}^{N \times N}$ die **Mixing Matrix** ist. Diese besteht aus den Koeffizienten der Linearkombinationen.

Mathematische Formulierung des Problems (Forts.)

- Unser Ziel ist es, die Quellsignale $\boldsymbol{s}$ aus den beobachteten Mischsignalen $\boldsymbol{x}$ zu rekonstruieren.
- Wäre $\boldsymbol{A}$ bekannt, so könnten wir in den meisten Fällen (falls die Inverse von $\boldsymbol{A}$ existiert)

$$\boldsymbol{s} = \boldsymbol{A}^{-1}\boldsymbol{x}$$

  berechnen und wären fertig.
- In der Regel ist $\boldsymbol{A}$ unbekannt, wodurch das Problem deutlich schwerer wird.
- Wir definieren die **Unmixing Matrix** $\boldsymbol{W} := \boldsymbol{A}^{-1}$.
- Mithilfe des ICA-Verfahrens werden wir diese Matrix approximieren. Mit ihr können wir dann die Quellsignale bestimmen, indem wir $\boldsymbol{s} = \boldsymbol{W}\boldsymbol{x}$ berechnen.

Annahmen des Verfahrens

Die folgenden Annahmen sind wesentlich für das ICA-Verfahren:

1. **Zentrale Annahme:** Die Quellsignale (ICs: Independent Components) sind *stochastisch unabhängig*.
2. Die ICs sind *nicht normalverteilt* (dazu später mehr).
3. Die Mixing Matrix $\boldsymbol{A}$ ist quadratisch. Es gibt allerdings Verallgemeinerungen der ICA, die auch rechteckige Matrizen erlauben. Wir machen diese Annahme hier, da das Problem selbst in diesem vereinfachten Fall schon schwer genug ist.

Im Cocktail Party Problem bedeutet Annahme 3, dass es genauso viele Mikrophone wie Personen gibt.

Limitationen des Verfahrens

Es gibt eine Reihe von Einschränkungen (*unidentifiabilities*) bei der Rekonstruktion der Quellsignale:

1. Die ursprüngliche *Reihenfolge* der Signale kann nicht rekonstruiert werden. Sei dazu $\boldsymbol{P}$ eine *Permutationsmatrix*. Dann ist $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s} = \boldsymbol{A}\boldsymbol{P}^{-1}\boldsymbol{P}\boldsymbol{s}$, wobei $\boldsymbol{P}\boldsymbol{s}$ die permutierten Quellsignale sind. $\boldsymbol{A}\boldsymbol{P}^{-1}$ ist lediglich eine neue zu schätzende Mixing Matrix. Wir können folglich kein Signal *das erste* Quellsignal nennen.
2. Die *Skalierung* der Quellsignale kann nicht wiederhergestellt werden (im Cocktail Party Problem entspricht dies der Lautstärke/Amplitude der Signale), wie man sich leicht überlegt:
   Sei dazu $\alpha \in \mathbb{R}$, dann gilt
   $$\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s} = \alpha\boldsymbol{A} \cdot \frac{1}{\alpha}\boldsymbol{s}.$$
3. Normalverteilte Signale können nicht aufgetrennt werden.

Warum sind Normalverteilungen verboten?

- Wir betrachten ein Beispiel mit $N = 2$ und $\boldsymbol{s} \sim N_{\boldsymbol{0}, \boldsymbol{I}}$.
- Die Konturlinien der Standardnormalverteilung sind perfekte Kreise, die auf dem Koordinatenursprung zentriert sind.
- Insbesondere ist die Dichte **rotationsinvariant**.
- Für $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s}$ gilt damit: $\boldsymbol{x} \sim N_{\boldsymbol{0}, \boldsymbol{A}\boldsymbol{A}^\top}$.

Beweis: Mit der Linearität des Erwartungswerts gilt $\mathbb{E}_{\boldsymbol{s}}[\boldsymbol{x}] = \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{A}\boldsymbol{s}] = \boldsymbol{A}\mathbb{E}_{\boldsymbol{s}}[\boldsymbol{s}] = \boldsymbol{0}$. Die Streuungsmatrix ist

$$\begin{aligned}\mathbb{D}[\boldsymbol{x}] &= \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{x}\boldsymbol{x}^\top] = \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{A}\boldsymbol{s}\boldsymbol{s}^\top\boldsymbol{A}^\top] = \boldsymbol{A}\mathbb{E}[\boldsymbol{s}\boldsymbol{s}^\top]\boldsymbol{A}^\top = \boldsymbol{A} \cdot \mathbb{D}[\boldsymbol{s}] \cdot \boldsymbol{A}^\top \\ &= \boldsymbol{A}\boldsymbol{A}^\top.\end{aligned}$$

Also gilt die Behauptung. □

Warum sind Normalverteilungen verboten? (Forts.)

- Sei nun $\boldsymbol{R} \in \mathbb{R}^{N \times N}$ eine beliebige *orthogonale Matrix*.

  Eigenschaften orthogonaler Matrizen:

  - Orthogonale Matrizen beschreiben eine Drehung/Spiegelung im Raum.
  - Es gilt stets $\boldsymbol{R}\boldsymbol{R}^\top = \boldsymbol{R}^\top\boldsymbol{R} = \boldsymbol{I}$. Es ist also $\boldsymbol{R}^{-1} = \boldsymbol{R}^\top$.
  - Es ist $\det \boldsymbol{R} = 1$ für alle orthogonalen Matrizen $\boldsymbol{R}$.
  - Da $\boldsymbol{R}$ nur eine Drehung beschreibt, gilt für alle $\boldsymbol{x} \in \mathbb{R}^N$ die Identität $\|\boldsymbol{R}\boldsymbol{x}\| = \|\boldsymbol{x}\|$.
- Sei ferner $\tilde{\boldsymbol{A}} := \boldsymbol{A}\boldsymbol{R}$ die Matrix, welche mit der von $\boldsymbol{R}$ beschriebenen Drehung aus $\boldsymbol{A}$ hervorgeht.
- Dann hat der Vektor $\tilde{\boldsymbol{x}} = \tilde{\boldsymbol{A}}\boldsymbol{s}$ dieselbe Verteilung wie $\boldsymbol{x}$.

Beweis: Den Erwartungswert rechnet man analog zu oben aus. Aufgrund der Orthogonalität von $\boldsymbol{R}$ gilt

$$\mathbb{E}_{\boldsymbol{s}}[\tilde{\boldsymbol{x}}\tilde{\boldsymbol{x}}^\top] = \mathbb{E}_{\boldsymbol{s}}[\tilde{\boldsymbol{A}}\boldsymbol{s}\boldsymbol{s}^\top\tilde{\boldsymbol{A}}^\top] = \mathbb{E}_{\boldsymbol{s}}[\boldsymbol{A}\boldsymbol{R}\boldsymbol{s}\boldsymbol{s}^\top\boldsymbol{R}^\top\boldsymbol{A}^\top] = \boldsymbol{A}\boldsymbol{R} \cdot \mathbb{D}[\boldsymbol{s}] \cdot \boldsymbol{R}^\top\boldsymbol{A}^\top = \boldsymbol{A}\boldsymbol{R}\boldsymbol{R}^\top\boldsymbol{A} = \boldsymbol{A}\boldsymbol{A}^\top,$$

sodass $\tilde{\boldsymbol{x}} \sim N_{\boldsymbol{0},\, \boldsymbol{A}\boldsymbol{A}^\top}$ wie behauptet gilt. □

Warum sind Normalverteilungen verboten? (Forts.)

- Wie die voranstehenden Ausführungen zeigen, können wir in diesem Fall nicht rekonstruieren, ob die Daten mit der Matrix $\boldsymbol{A}$ oder $\tilde{\boldsymbol{A}}$ gemixt wurden.
- Für normalverteilte Daten können wir folglich die Komponenten *nur bis auf eine Drehung rekonstruieren*.

Ein einfaches Beispiel

Wir betrachten ein einfaches zweidimensionales Beispiel für den Fall, dass die Quellsignale s_1 und s_2 gleichverteilt sind:

$$p(s_i) := \begin{cases} \frac{1}{2\sqrt{3}} & \text{wenn } |s_i| \leq \sqrt{3} \\ 0 & \text{sonst} \end{cases}$$

Bemerkungen:

- Der Erwartungswert der Zufallsvariablen s_i $(i = 1, 2)$ ist jeweils 0.

  Beweis: Für die Gleichverteilung gilt $\mathbb{E}[s_i] = \frac{-\sqrt{3}+\sqrt{3}}{2} = 0$ (siehe Tabelle im Kapitel 'Statistik'). □

- Die Varianzen sind jeweils 1.

  Beweis: Es ist $\mathbb{V}[s_i] = \frac{\left(\sqrt{3}+\sqrt{3}\right)^2}{12} = \frac{\left(2\sqrt{3}\right)^2}{12} = \frac{12}{12} = 1$ (siehe Tabelle im Kapitel 'Statistik'). □

Ein einfaches Beispiel (Forts.)

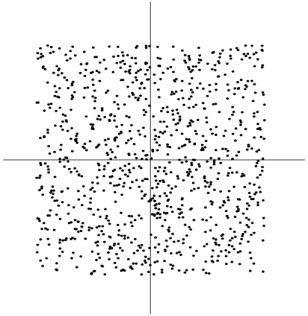

Abbildung: Gemeinsame Verteilung der unabhängigen Komponenten s_1 (horizontal) und s_2 (vertikal). Siehe **HyvÃďrinen2001**, Seite 155.

Ein einfaches Beispiel (Forts.)

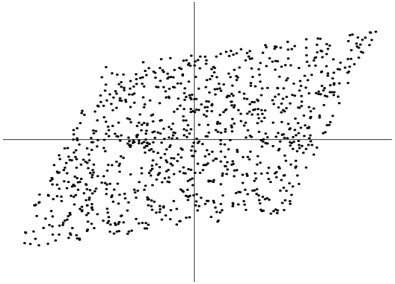

Abbildung: Gemeinsame Verteilung der gemischten/beobachteten Komponenten x_1 (horizontal) und x_2 (vertikal) nach Anwendung der Matrix $\boldsymbol{A} := \begin{pmatrix} 5 & 10 \\ 10 & 2 \end{pmatrix}$.

Whitening

Whitening wird häufig vor dem eigentlichen ICA-Algorithmus angewendet:

4.1 Definition: **Whitening** bezeichnet eine *lineare Transformation* $\boldsymbol{V}$, bei der zentrierte Zufallsvariablen $\boldsymbol{x} \in \mathbb{R}^N$ (zentriert bedeutet $\mathbb{E}[\boldsymbol{x}] = \boldsymbol{0}$) so zu neuen Zufallsvariablen $\boldsymbol{z} := \boldsymbol{V}\boldsymbol{x} \in \mathbb{R}^N$ transformiert werden, dass $\mathbb{D}[\boldsymbol{z}] = \mathbb{E}[\boldsymbol{z}\boldsymbol{z}^\top] = \boldsymbol{I}$ gilt.

In Worten bedeutet dies, dass die Komponenten von $\boldsymbol{z}$ untereinander unkorreliert und die Varianzen jeweils Eins sind, also

$$\mathbb{E}[z_i z_j] = \delta_{ij},$$

wobei $\delta_{ij} := \begin{cases} 1 & \text{falls } i = j \\ 0 & \text{falls } i \neq j \end{cases}$ das **Kronecker-Delta** bezeichnet.

Whitening (Forts.)

- Eine solche lineare Transformation ist z. B. gegeben durch $\boldsymbol{V} := \boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{E}^\top$, wobei $\boldsymbol{E} \in \mathbb{R}^{N\times N}$ eine orthogonale Matrix ist, deren Spalten aus *normalisierten Eigenvektoren* von $\mathbb{D}[\boldsymbol{x}]$ bestehen und $\boldsymbol{D} := \operatorname{diag}(d_1, d_2, \ldots, d_N) \in \mathbb{R}^{N\times N}$ eine Diagonalmatrix mit den zugehörigen *Eigenwerten* ist.

  Beweis: Wir rechnen nach, dass die Kovarianzmatrix von $\boldsymbol{z} = \boldsymbol{V}\boldsymbol{x}$ tatsächlich die Einheitsmatrix ist. Da $\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top] = \boldsymbol{E}\boldsymbol{D}\boldsymbol{E}^\top$. Damit gilt tatsächlich

$$\mathbb{E}[\boldsymbol{z}\boldsymbol{z}^\top] = \mathbb{E}[\boldsymbol{V}\boldsymbol{x}\boldsymbol{x}^\top\boldsymbol{V}^\top] = \boldsymbol{V}\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top]\boldsymbol{V}^\top = \boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{E}^\top\boldsymbol{E}\boldsymbol{D}\boldsymbol{E}^\top\boldsymbol{E}\boldsymbol{D}^{-\frac{1}{2}} = \boldsymbol{I}.$$

□

- Aus der Zentriertheit von $\boldsymbol{x}$ folgt, dass auch $\boldsymbol{z}$ zentriert ist.

  Beweis: Wieder mit der Linearität des Erwartungswerts gilt $\mathbb{E}[\boldsymbol{z}] = \mathbb{E}[\boldsymbol{V}\boldsymbol{x}] = \boldsymbol{V}\mathbb{E}[\boldsymbol{x}] = \boldsymbol{0}$. □

Fortsetzung des Beispiels

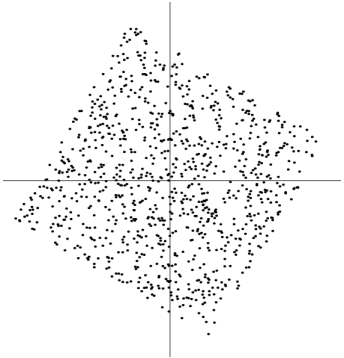

Abbildung: Gemeinsame Verteilung der Komponenten z_1 (horizontal) und z_2 (vertikal) nach dem Whitening.

Whitening löst bereits das halbe Problem

- Wir nehmen im Folgenden an, dass bereits ein Whitening stattgefunden hat.
- Whitening transformiert die Mixing Matrix $\boldsymbol{A}$ in eine neue Matrix $\tilde{\boldsymbol{A}}$, denn

$$\boldsymbol{z} = \boldsymbol{V}\boldsymbol{x} = \boldsymbol{V}\boldsymbol{A}\boldsymbol{s} = \tilde{\boldsymbol{A}}\boldsymbol{s}.$$

- Man könnte nun hoffen, dass Whitening das Problem bereits löst, da Unkorreliertheit und Unabhängigkeit verwandt sind. **Dem ist jedoch nicht so!**
- Sei dazu $\boldsymbol{U}$ eine orthogonale Matrix und $\boldsymbol{y} := \boldsymbol{U}\boldsymbol{z}$.
- Aufgrund der Orthogonalität von $\boldsymbol{U}$ gilt

$$\mathbb{E}[\boldsymbol{y}\boldsymbol{y}^\top] = \mathbb{E}[\boldsymbol{U}\boldsymbol{y}\boldsymbol{y}^\top\boldsymbol{U}^\top] = \boldsymbol{U}\boldsymbol{I}\boldsymbol{U}^\top = \boldsymbol{I}.$$

Somit ist auch $\boldsymbol{y}$ white. Die Komponenten sind durch Whitening nur bis auf eine Drehung eindeutig!

Whitening als Vorverarbeitungsschritt

- Die Whitening Operation eignet sich jedoch sehr gut als Vorverarbeitungsschritt, denn durch sie wird die Mixing Matrix $\tilde{\boldsymbol{A}} = \boldsymbol{V}\boldsymbol{A}$ orthogonal.

  Beweis: Da die Daten z white sind, gilt $\mathbb{E}[zz^\top] = \boldsymbol{I}$. Es gilt aber auch

  $$\mathbb{E}[zz^\top] = \mathbb{E}[\tilde{\boldsymbol{A}}ss^\top\tilde{\boldsymbol{A}}^\top] = \tilde{\boldsymbol{A}}\tilde{\boldsymbol{A}}^\top.$$

  Also gilt $\tilde{\boldsymbol{A}}\tilde{\boldsymbol{A}}^\top = \boldsymbol{I}$, woraus die Orthogonalität von $\tilde{\boldsymbol{A}}$ folgt. □

- Das heißt wir können uns bei der Suche nach der Mixing Matrix **auf orthogonale Matrizen beschränken!**
- Eine orthogonale $N \times N$ Matrix hat nur $N(N-1)/2$ Freiheitsgrade (im Gegensatz zu N^2 Freiheitsgraden für die ursprüngliche Matrix), z. B. wird eine zweidimensionale orthogonale Matrix eindeutig durch den Winkel der Drehung beschrieben.

Warum Normalverteilungen verboten sind!

- Durch Whitening können wir eine weitere Begründung dafür angeben, warum Normalverteilungen verboten sind.
- Wir nehmen an, dass die gemeinsame Verteilung der Quellsignale s_1 und s_2 durch eine Normalverteilung beschrieben werden:

$$p(s_1,\ s_2) = \frac{1}{2\pi} \exp\left(-\frac{s_1^2 + s_2^2}{2}\right) = \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{s}\|^2}{2}\right)$$

- Die Mixing Matrix $\boldsymbol{A}$ kann als orthogonal angenommen werden, da die Daten $\boldsymbol{x}$ als white vorausgesetzt sind.

Warum Normalverteilungen verboten sind! (Forts.)

Mit dem Transformationssatz **??** für Dichten erhalten wir daraus die Verteilung von x_1 und x_2:

$$p(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{A}^{-1}\boldsymbol{x}\|^2}{2}\right) |\det \boldsymbol{A}^{-1}|$$

[Aufgrund der Orthogonalität gilt $\boldsymbol{A}^{-1} = \boldsymbol{A}^\top$.]

$$= \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{A}^\top\boldsymbol{x}\|^2}{2}\right) |\det \boldsymbol{A}^\top|$$

[Wieder aufgrund der Orthogonalität gilt $\|\boldsymbol{A}^\top\boldsymbol{x}\| = \|\boldsymbol{x}\|$ und $\det \boldsymbol{A}^\top = 1$.]

$$= \frac{1}{2\pi} \exp\left(-\frac{\|\boldsymbol{x}\|^2}{2}\right)$$

Warum Normalverteilungen verboten sind! (Forts.)

- Wir sehen also, dass die Dichte der Quellsignale und der gemischten Signale identisch ist.
- Damit haben wir keine Chance, die Mixing Matrix aus den Daten zu schätzen.

Warum Normalverteilungen verboten sind! (Forts.)

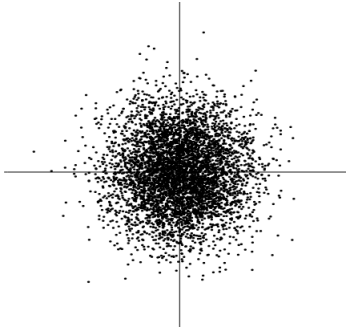

Abbildung: Gemeinsame Verteilung der Komponenten s_1 (horizontal) und s_2 (vertikal) bei Annahme einer Normalverteilung.

ICA Lösungsverfahren

Es gibt verschiedene Ansätze mit denen man die unabhängigen Komponenten bestimmen kann:

1. Maximierung der Likelihood Funktion.
2. Maximierung der *Non-Gaussianity*: Finde die unabhängigen Komponenten so, dass deren Verteilung maximal nicht-normal ist.
   - Basiert auf dem **zentralen Grenzwertsatz**: Eine Summe unabhängiger Zufallsvariablen ist (unter gewissen Voraussetzungen) zunehmend normalverteilt.
   - Hierzu muss man eine Maßzahl finden, welche die Nicht-Normalität einer Verteilung misst.
   - Beispiele: **Kurtosis**, **Negentropy**
3. Minimierung der Mutual Information.

ICA Likelihood Funktion

Wir leiten im Folgenden die Likelihood Funktion für die ICA her:

- Da die Komponenten s_n *stochastisch unabhängig* sind, finden wir deren gemeinsame Dichte als *Produktdichte* der Komponenten

$$p_{\boldsymbol{s}}(\boldsymbol{s}) = \prod_{n=1}^{N} p_n(s_n).$$

- Wir müssen dies allerdings mittels der beobachteten Daten $\boldsymbol{x} = \boldsymbol{A}\boldsymbol{s}$ ausdrücken, da $\boldsymbol{s}$ *latent* ist. Hierzu benutzen wir den Transformationssatz **??** und erhalten mit $\boldsymbol{s} = \boldsymbol{A}^{-1}\boldsymbol{x} = \boldsymbol{W}\boldsymbol{x}$ und $\boldsymbol{W} = (\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots, \boldsymbol{w}_N)^\top$ die Dichte von $\boldsymbol{x}$ als

$$p_{\boldsymbol{x}}(\boldsymbol{x}) = |\det \boldsymbol{W}| \cdot \prod_{n=1}^{N} p_n((\boldsymbol{w}_n)^\top \boldsymbol{x}). \tag{4.2}$$

ICA Likelihood Funktion (Forts.)

- Wir nehmen nun an, dass wir T Beobachtungen $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_T$ von $\boldsymbol{x}$ haben.
- Die Likelihood Funktion ergibt sich als das Produkt der Dichte in (4.2) über die T Beobachtungen

$$L(\boldsymbol{W}) = \prod_{t=1}^{T} \left(|\det \boldsymbol{W}| \cdot \prod_{n=1}^{N} p_n((\boldsymbol{w}_n)^\top \boldsymbol{x}_t) \right) = |\det \boldsymbol{W}|^T \cdot \prod_{t=1}^{T} \prod_{n=1}^{N} p_n((\boldsymbol{w}_n)^\top \boldsymbol{x}_t).$$

- Im Folgenden betrachten wir die Log-Likelihood Funktion

$$l(\boldsymbol{W}) = \ln \left(|\det \boldsymbol{W}|^T \cdot \prod_{t=1}^{T} \prod_{n=1}^{N} p_n((\boldsymbol{w}_n)^\top \boldsymbol{x}_t) \right) = \ln |\det \boldsymbol{W}|^T + \ln \left(\prod_{t=1}^{T} \prod_{n=1}^{N} p_n((\boldsymbol{w}_n)^\top \boldsymbol{x}_t) \right)$$

$$= T \cdot \ln |\det \boldsymbol{W}| + \sum_{t=1}^{T} \sum_{n=1}^{N} \ln p_n((\boldsymbol{w}_n)^\top \boldsymbol{x}_t).$$

Festlegung der Dichte der Quellsignale

- Um die Likelihood Funktion optimieren zu können, müssen wir noch die Dichten $p_n(s_n)$ $(n = 1, 2, \ldots, N)$ für die Quelldaten festlegen.
- Bei der Wahl dürfen wir aufgrund obiger Ausführungen *keine Normalverteilungen* verwenden.
- Aufgrund der Ähnlichkeit zur Normalverteilung schlägt **Ng2023** die **logistische Verteilung** vor.
- Die Verteilungsfunktion (CDF) ist folgendermaßen definiert:

$$F(s_0) = p(s \leq s_0) = \frac{1}{1 + e^{-s_0}} =: \sigma(s)$$

- Damit ergibt sich für die Dichte $p_n(s_n) = \sigma'(s) = \sigma(s) \cdot (1 - \sigma(s))$ und für die Log-Likelihood

$$T \cdot \ln |\det \boldsymbol{W}| + \sum_{t=1}^{T} \sum_{n=1}^{N} \ln \sigma'((\boldsymbol{w}_n)^\top \boldsymbol{x}_t).$$

Bestimmung des Gradienten

4.2 Satz: Es sei $\boldsymbol{W} \in \mathbb{R}^{N \times N}$. Dann ist $\frac{\partial}{\partial \boldsymbol{W}} \det \boldsymbol{W} = (\boldsymbol{W}^\top)^{-1} \det \boldsymbol{W}$.

Beweis: Mit dem Adjunktensatz der linearen Algebra gilt $\boldsymbol{W}^{-1} = \frac{1}{\det \boldsymbol{W}} \operatorname{adj}(\boldsymbol{W})$. Hierbei bezeichnet $\operatorname{adj}(\boldsymbol{W}) = (W_{ij})_{i,\, j=1,2,\ldots,N}$ die zu $\boldsymbol{W}$ **adjungierte Matrix**. Die **Kofaktoren** W_{ij} erhält man, indem man die Determinante der $(N-1) \times (N-1)$ Untermatrix von $\boldsymbol{W}$ berechnet, die aus der Streichung der i-ten Zeile und j-ten Spalte von $\boldsymbol{W}$ hervorgeht. Dieses Ergebnis muss schließlich noch mit $(-1)^{i+j}$ multipliziert werden.

Die Determinante kann nun in Form der Kofaktoren ausgedrückt werden (Stichwort: **Entwicklungssatz von Laplace**). Wir erhalten

$$\det \boldsymbol{W} = \sum_{k=1}^{N} w_{ik} W_{ik}$$

Zeile i kann dabei beliebig gewählt werden. Entscheidend ist nun, dass die Kofaktoren per Definition nicht von den Einträgen der Zeile i der Matrix abhängen, sodass die Determinante eine lineare Funktion dieser Einträge ist. Wir erhalten damit $\frac{\partial \det \boldsymbol{W}}{\partial w_{ij}} = W_{ij}$ und schließlich $\frac{\partial \det \boldsymbol{W}}{\partial \boldsymbol{W}} = \operatorname{adj}(\boldsymbol{W})^\top = (\boldsymbol{W}^\top)^{-1} \det \boldsymbol{W}$. Die letzte Gleichung gilt dabei wegen des Adjunktensatzes. □

Bestimmung des Gradienten (Forts.)

Mit diesem Ergebnis können wir nun eine einfache Regel für den stochastischen Gradientenaufstieg angeben:

- Sei dazu ein Trainingsbeispiel $\boldsymbol{x} \in \mathbb{R}^N$ und die Lernrate $\alpha \in \mathbb{R}$ gegeben.
- Die Update-Regel lautet dann

$$\boldsymbol{W}^{\text{neu}} := \boldsymbol{W} + \alpha \left[\begin{pmatrix} 1 - 2\sigma((\boldsymbol{w}_1)^\top \boldsymbol{x}) \\ 1 - 2\sigma((\boldsymbol{w}_2)^\top \boldsymbol{x}) \\ \vdots \\ 1 - 2\sigma((\boldsymbol{w}_N)^\top \boldsymbol{x}) \end{pmatrix} \boldsymbol{x}^\top + (\boldsymbol{W}^\top)^{-1} \right]. \tag{4.3}$$

Bestimmung des Gradienten (Forts.)

Beweis:

□

Literatur