

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

- ① Expectation-Maximization (EM) Algorithmus
- ② Probabilistische PCA (PPCA)

Kapitel

1 Expectation-Maximization (EM) Algorithmus

Problemstellung

Ungleichung von Jensen

Herleitung des Expectation-Schritts

Herleitung des Maximization-Schritts

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Anwendung auf Gaussian Mixture Models

Problemstellung

- Wir betrachten ein statistisches Modell mit den Daten $\mathbf{X} = (x_1, x_2, \dots, x_N)^\top$, den **latenten Variablen** $\mathbf{Z} = (z_1, z_2, \dots, z_N)^\top$ und den Modellparametern θ .
- Wie üblich ist unser Ziel die Maximierung der Log-Likelihood $\ln p(\mathbf{X}; \theta)$ bezüglich θ .
- Wir nehmen an, dass die gemeinsame Verteilung $p(\mathbf{X}, \mathbf{Z}; \theta)$ von $\mathbf{X}$ und $\mathbf{Z}$ gegeben ist.
- Hieraus können wir $\ln p(\mathbf{X}; \theta)$ bestimmen, indem wir $\mathbf{Z}$ *marginalisieren*:

$$\ln p(\mathbf{X}; \theta) = \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}; \theta) \quad (1.1)$$

- In der Regel ist eine direkte Maximierung von (1.1) zu kompliziert, da der Logarithmus nicht direkt auf $p(\mathbf{X}, \mathbf{Z}; \theta)$ wirken kann.

Problemstellung (Forts.)

- Mit $\{X, Z\}$ bezeichnen wir den **vollständigen** Datensatz, X alleine nennen wir hingegen **unvollständig**.
- Analog nennen wir $\ln p(X, Z; \theta)$ die **vollständige Log-Likelihood** und $\ln p(X; \theta)$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von (1.1) schwer ist, möchten wir stattdessen $\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ maximieren.
- **Problem:** Wir kennen $\mathbf{Z}$ nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in *zwei Phasen*, wobei man in jeder Iteration ausgehend von $\boldsymbol{\theta}_{\text{alt}}$ neue Parameter $\boldsymbol{\theta}_{\text{neu}}$ erhält, die (1.1) erhöhen.

E-Phase: Bestimme den Erwartungswert von $\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ unter der Posterior-Verteilung der latenten Variablen $p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(\mathbf{X}; \boldsymbol{\theta})$.

M-Phase: Die berechnete untere Schranke wird bezüglich der Parameter $\boldsymbol{\theta}$ maximiert, was zu den aktualisierten Parametern $\boldsymbol{\theta}_{\text{neu}}$ führt.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

1.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen




Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(\mathbf{X} ; \boldsymbol{\theta})$.
- Hierzu führen wir die Verteilung q über $\mathbf{Z}$ mit $q(\mathbf{Z}) \neq 0$ ein und erhalten

$$\begin{aligned}\ln p(\mathbf{X} ; \boldsymbol{\theta}) &= \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta}) = \ln \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot \frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} \\ &= \ln \mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} \left[\frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} \right] \\ &\geq \mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} \left[\ln \frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} \right] =: \mathcal{L}(q, \boldsymbol{\theta}).\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen**, Satz 1.1, mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(\mathbf{X} ; \boldsymbol{\theta}) \geq \underbrace{\mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} [\ln p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})]}_{\text{Erwartete vollständige Log-Likelihood}} - \underbrace{\mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} [\ln q(\mathbf{Z})]}_{\text{Entropie von } q}. \quad (1.2)$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müssen.
- Wir möchten q so wählen, dass für das aktuelle $\boldsymbol{\theta}$ in (1.2) Gleichheit gilt.
- Die Ungleichung von Jensen, Satz 1.1, gilt mit Gleichheit, falls

$$\frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\mathbf{Z}) \propto p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet 'proportional zu'.
- Daraus erhalten wir (da q normiert sein muss)

$$\begin{aligned} q(\mathbf{Z}) &= \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\mathbf{Z}}} p(\mathbf{X}, \tilde{\mathbf{Z}}; \boldsymbol{\theta})} = \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{p(\mathbf{X}; \boldsymbol{\theta})} \\ &= p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}). \end{aligned}$$

- **Ergebnis:** Für q benutzen wir die Posterior-Verteilung von $\mathbf{Z}$ gegeben $\mathbf{X}$.
- Dies setzen wir in (1.2) ein und erhalten die Identität

$$\ln p(\mathbf{X}; \boldsymbol{\theta}) = \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor θ_{alt} , mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}\ln p(\mathbf{X}; \theta) &\geq \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{X}, \mathbf{Z}; \theta)] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})] \\ &= Q(\theta, \theta_{\text{alt}}) + H(\theta_{\text{alt}}, \theta_{\text{alt}}) \\ &= Q(\theta, \theta_{\text{alt}}) + \text{const},\end{aligned}$$

wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.

- Die Funktion $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ ist die **Entropie** von q unter θ_{alt} .

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ bezüglich θ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\theta, \theta_{\text{alt}})$ gegeben.
- Der M-Schritt hat damit also die Gestalt

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}). \quad (1.3)$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(\mathbf{X} \mid \theta_{\text{neu}}) \geq p(\mathbf{X} \mid \theta_{\text{alt}})$ gilt, dass also eine Iteration des EM-Verfahrens die Log-Likelihood tatsächlich erhöht.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

1.2 Algorithmus

- 1 Initialisiere θ_{alt} (*entweder zufällig oder mit Vorwissen*).
- 2 **E-Schritt:** Bestimme die untere Schranke

$$Q(\theta, \theta_{\text{alt}}) := \mathbb{E}_{Z \sim p(Z | X; \theta_{\text{alt}})} [\ln p(X, Z; \theta)].$$

- 3 **M-Schritt:** Maximiere die untere Schranke und berechne

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zurück zu Schritt 2 und setze $\theta_{\text{alt}} := \theta_{\text{neu}}$.
- 5 Ansonsten gebe θ_{neu} zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus

$$\begin{aligned}\ln p(\mathbf{X}; \boldsymbol{\theta}_{\text{neu}}) &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}_{\text{neu}})}{p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})} \\ &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}_{\text{alt}})}{p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})} = \ln p(\mathbf{X}; \boldsymbol{\theta}_{\text{alt}}).\end{aligned}$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil $\boldsymbol{\theta}_{\text{neu}}$ so gewählt wurde, dass es die untere Schranke maximiert.
- Die letzte Gleichheit gilt, da die untere Schranke bzgl. $\boldsymbol{\theta}_{\text{alt}}$ die Log-Likelihood in $\boldsymbol{\theta}_{\text{alt}}$ berührt.

Bemerkung: Allerdings kann das Verfahren in lokalen Maxima hängen bleiben!

Visualisierung: EM-Algorithmus




Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [1], Seite 488.

Aufgabe: EM für Probleme mit fehlenden Daten

1.3 Aufgabe: Das EM-Verfahren kann auch für Schätzprobleme benutzt werden, falls einzelne Werte im Datensatz fehlen. Eine Voraussetzung ist jedoch, dass das Fehlen der Daten zufällig ist und nicht systematisch.

Man nehme an...

Evidence Lower Bound (ELBO)

- Wir geben noch eine andere Sicht auf den EM-Algorithmus.
- Hierzu stellen wir fest, dass wir die Log-Likelihood $\ln p(\mathbf{X}; \boldsymbol{\theta})$ folgendermaßen zerlegen können

$$\ln p(\mathbf{X}; \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q \parallel p). \quad (1.4)$$

- Dabei ist:
 - $\mathcal{L}(q, \boldsymbol{\theta})$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound**

$$\mathcal{L}(q, \boldsymbol{\theta}) := \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{q(\mathbf{Z})} = \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) - \ln q(\mathbf{Z})]. \quad (1.5)$$

- $\text{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\mathbf{Z})$ und $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$

$$\text{KL}(q \parallel p) := - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})}{q(\mathbf{Z})} = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}) - \ln q(\mathbf{Z})]. \quad (1.6)$$

Beweis der Zerlegung (1.4)

Beweis: Wir beweisen die Zerlegung (1.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ an. Wir erhalten $p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) = p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}) \cdot p(\mathbf{X}; \boldsymbol{\theta})$. Anwendung des Logarithmus ergibt

$$\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) = \ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}) + \ln p(\mathbf{X}; \boldsymbol{\theta}).$$

Dies setzen wir in die Evidence Lower Bound (1.5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) - \ln q(\mathbf{Z})] \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}) + \ln p(\mathbf{X}; \boldsymbol{\theta}) - \ln q(\mathbf{Z})].\end{aligned}$$

Damit ergibt sich schließlich mit (1.6) und wegen $\sum_{\mathbf{Z}} q(\mathbf{Z}) = 1$

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q \parallel p) &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}) + \ln p(\mathbf{X}; \boldsymbol{\theta}) - \ln q(\mathbf{Z})] - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}) - \ln q(\mathbf{Z})] \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot \ln p(\mathbf{X}; \boldsymbol{\theta}) = \ln p(\mathbf{X}; \boldsymbol{\theta}) \cdot \sum_{\mathbf{Z}} q(\mathbf{Z}) = \ln p(\mathbf{X}; \boldsymbol{\theta}).\end{aligned}$$

□

Kullback-Leibler Divergenz

Eigenschaften der Kullback-Leibler Divergenz:

Für alle Wahrscheinlichkeitsverteilungen q und p gelten die folgenden Eigenschaften.

❶ **Nicht-Negativität:**

$$\text{KL}(q \parallel p) \geq 0 \quad (1.7)$$

❷ **Identität:**

$$\text{KL}(q \parallel p) = 0 \iff q = p. \quad (1.8)$$

❸ Die Kullback-Leibler Divergenz ist **nicht symmetrisch** und damit keine Metrik. Es ist also im Allgemeinen

$$\text{KL}(q \parallel p) \neq \text{KL}(p \parallel q).$$

Kullback-Leibler Divergenz (Forts.)

- Aus (1.6) ist ersichtlich, dass $KL(q \parallel p)$ die Kullback-Leibler Divergenz zwischen der Verteilung $q(\mathbf{Z})$ und der Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ von $\mathbf{Z}$ ist.
- Aus der Zerlegung (1.4) folgt mit der Nichtnegativität (1.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\mathbf{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\mathbf{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood




Abbildung: Veranschaulichung der Zerlegung (1.4). Siehe [1], Seite 486.

Eine andere Sicht auf den E-Schritt

- Mit dieser Vorarbeit können wir nun die alternative Herleitung des EM-Algorithmus durchführen.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \theta_{\text{alt}})$ bezüglich $q(\mathbf{Z})$ bei gegebenem θ_{alt} maximiert, sodass die untere Schranke die eigentliche Zielfunktion $\ln p(\mathbf{X}; \theta)$ in θ_{alt} berührt.
- Da $p(\mathbf{X}; \theta_{\text{alt}})$ nicht von $q(\mathbf{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \theta_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (1.8) für $q(\mathbf{Z})$ gelten

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \theta_{\text{alt}}) = \ln p(\mathbf{X}; \theta_{\text{alt}}).$$

Visualisierung: E-Schritt




Abbildung: Veranschaulichung des E-Schritts. Siehe [1], Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\mathbf{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Hierdurch erhalten wir die neuen Parameter $\boldsymbol{\theta}_{\text{neu}}$, die letztendlich zu einer höheren Log-Likelihood $p(\mathbf{X}; \boldsymbol{\theta})$ führen.
- Setzen wir $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})$ in die Definition der unteren Schranke (1.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) - \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \\ &= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\theta, \theta_{\text{alt}})$ maximieren, wobei Q die **erwartete vollständige Log-Likelihood** ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (1.3) an

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern θ_{alt} bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}) \neq p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}}),$$

sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.

- Im folgenden E-Schritt setzen wir dann $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt




Abbildung: Veranschaulichung des M-Schritts. Siehe [1], Seite 487.

Gaussian Mixture Models und EM

Wir wenden das allgemeine EM-Framework nun auf GMMs an:

- Im *E-Schritt* benötigen wir die Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X} ; \boldsymbol{\theta})$ der latenten Variablen, wobei $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ ist.
- Diese können wir mit (??), (??) und dem *Satz von Bayes* bestimmen zu

$$p(\mathbf{Z} \mid \mathbf{X} ; \boldsymbol{\theta}) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k \cdot \mathbf{n}(\mathbf{x}_n ; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}.$$

- Als nächstes stellen wir die *erwartete vollständige Log-Likelihood* auf, wobei der Erwartungswert bezüglich der Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X} ; \boldsymbol{\theta})$ zu berechnen ist.
- Dazu benötigen wir allerdings noch ein Zwischenergebnis, das wir auf der nächsten Folie bereitstellen.

Gaussian Mixture Models und EM (Forts.)

- Es gilt der Zusammenhang

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})}[z_{nk}] &= \frac{\sum_{z_n} z_{nk} \prod_{k'=1}^K [\pi_{k'} \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_{k'}, \boldsymbol{\Sigma}_{k'})]^{z_{nk'}}}{\sum_{z_n} \prod_{j=1}^K [\pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\
 &= \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(z_{nk}).
 \end{aligned} \tag{1.9}$$

- Der Erwartungswert der Indikator-Variablen z_{nk} unter der Posterior-Verteilung von $\mathbf{Z}$ stellt sich also gerade als die jeweilige Responsibility $\gamma(z_{nk})$ heraus.

Gaussian Mixture Models und EM (Forts.)

Hiermit können wir nun die *erwartete vollständige Log-Likelihood* (Funktion Q) aufstellen

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] &= \mathbb{E} \left[\ln \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}} \cdot \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_{nk}} \right] \\
 &= \mathbb{E} \left[\sum_{n=1}^N \sum_{k=1}^K z_{nk} \cdot \{\ln \pi_k + \ln \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \right] && \text{Logarithmengesetze.} \\
 &= \sum_{n=1}^N \sum_{k=1}^K \mathbb{E}[z_{nk}] \cdot \{\ln \pi_k + \ln \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} && \text{Linearität von } \mathbb{E}. \\
 &= \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \cdot \{\ln \pi_k + \ln \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} && \text{Anwendung von (1.9).}
 \end{aligned} \tag{1.10}$$

Gaussian Mixture Models und EM (Forts.)

- Die Funktion (1.10) müssen wir nun im *M-Schritt* bezüglich der Parameter maximieren.
- Beispielhaft:** Gradient bezüglich μ_k

$$\begin{aligned}
 \frac{\partial}{\partial \mu_k} \sum_{n=1}^N \sum_{j=1}^K \gamma(z_{nj}) \cdot \{\ln \pi_j + \ln \mathbf{n}(\mathbf{x}_n; \mu_j, \Sigma_j)\} &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\partial}{\partial \mu_k} \ln \mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k) \\
 &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k)} \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \\
 &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k).
 \end{aligned}$$

- Vergleiche hierzu die Herleitung in (??).

Gaussian Mixture Models und EM (Forts.)

- Nullsetzen und Auflösen nach μ_k ergibt

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n.$$

- Dieses Ergebnis hat dieselbe Form wie (??).
- Die anderen Formeln ergeben sich analog.

Kapitel

② Probabilistische PCA (PPCA)

PPCA Modell

Bestimmung der Verbunddichte

Bestimmung des Posteriors der latenten Variablen

Bestimmung der Likelihood

PCA als latent Variable Model

- Wir modellieren die Repräsentation der Daten im Principal Subspace als latente Variablen $z \in \mathbb{R}^D$.
- Für die Verteilung von z gelte

$$z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (2.1)$$

- Zudem führen wir die bedingte Verteilung von $x \in \mathbb{R}^M$ gegeben z wie folgt ein

$$x \mid z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (2.2)$$

- Die Spalten der Matrix $\mathbf{W} \in \mathbb{R}^{M \times D}$ spannen hierbei den Principal Subspace auf.
- Es ist $\boldsymbol{\mu} \in \mathbb{R}^M$.
- Der Parameter σ^2 beeinflusst die Varianz der bedingten Verteilung (2.2).

PPCA als generatives Modell

Die PPCA kann als **generatives Modell** aufgefasst werden:

- Zunächst wählen wir ein z gemäß (2.1).
- Dann ziehen wir die beobachtete Variable x aus der Verteilung (2.2).
- Hierbei ergibt sich der Wert für x gemäß

$$x = Wz + \mu + \varepsilon. \quad (2.3)$$

- $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ ist hierbei *additives normalverteiltes Datenrauschen*, welches durch den Parameter σ^2 in (2.2) beeinflusst wird.

Das Mapping der Daten in den Principal Subspace erhalten wir mit dem Satz von Bayes.

PPCA als generatives Modell




Abbildung: PPCA als generatives Modell. Siehe [2], Seite 572.

Bestimmung der Verbunddichte

- Für die weiteren Ausführungen benötigen wir die Verbunddichte $p(z, x)$ der beobachteten und latenten Variablen.
- Mit der Produktregel für Wahrscheinlichkeiten ist

$$p(z, x) = \boldsymbol{n}(x | z) \cdot \boldsymbol{n}(z). \quad (2.4)$$

- Da es sich bei (2.7) um ein Produkt von Normalverteilungen handelt, sind die Zufallsvariablen auch gemeinsam normalverteilt.
- Es ist also $p(z, x) = \boldsymbol{n}(z, x; \boldsymbol{\nu}, \boldsymbol{\Sigma})$ beziehungsweise

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\nu}, \boldsymbol{\Sigma}). \quad (2.5)$$

Bestimmung der Verbunddichte (Forts.)

Wir bestimmen zunächst den Parameter $\nu = (\mu_z, \mu_x)^\top$:

- Mit der Linearität des Erwartungswerts und den obigen Definitionen – insbesondere die Definitionen (2.1) und (2.3) – gilt

$$\mathbb{E}[z] = \mathbf{0}$$

$$\mathbb{E}[x] = \mathbb{E}[Wz + \mu + \varepsilon] = W \underbrace{\mathbb{E}[z]}_{=0} + \mathbb{E}[\mu] + \underbrace{\mathbb{E}[\varepsilon]}_{=0} = \mu.$$

- Zusammenfassend gilt also

$$\nu = \mathbb{E} \left[\begin{pmatrix} z \\ x \end{pmatrix} \right] = \begin{pmatrix} \mathbb{E}[z] \\ \mathbb{E}[x] \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix}. \quad (2.6)$$

Bestimmung der Verbunddichte (Forts.)

Nun bestimmen wir den Parameter $\Sigma = \begin{pmatrix} \Sigma_{zz} & \Sigma_{zx} \\ \Sigma_{xz} & \Sigma_{xx} \end{pmatrix}$:

- Zunächst ist $\Sigma_{zz} = \mathbb{E}[(z - \mathbb{E}[z])(z - \mathbb{E}[z])^\top] = \mathbb{E}[zz^\top] = \mathbb{D}[z] = I$.
- Ferner ist

$$\begin{aligned} \Sigma_{zx} &= \mathbb{E}[(z - \mathbb{E}[z])(x - \mathbb{E}[x])^\top] \\ &= \mathbb{E}[z(Wz + \mu + \varepsilon - \mathbb{E}[Wz + \mu + \varepsilon])^\top] \\ &= \mathbb{E}[z(Wz + \varepsilon)^\top] = \mathbb{E}[zz^\top W^\top + z\varepsilon^\top] = \mathbb{E}[zz^\top]W^\top + \mathbb{E}[z] \cdot \mathbb{E}[\varepsilon^\top] \\ &= W^\top. \end{aligned}$$

- Aus Symmetriegründen gilt $\Sigma_{xz} = W$.

Bestimmung der Verbunddichte (Forts.)

2.1 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{xx} = \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}$ gilt.

Zusammenfassung: Für die gemeinsame Verteilung von z und x erhalten wir also

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\nu, \Sigma)$$

$$\nu := \begin{pmatrix} 0 \\ \mu \end{pmatrix} \tag{2.7}$$

$$\Sigma := \begin{pmatrix} \mathbf{I} & \mathbf{W}^\top \\ \mathbf{W} & \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I} \end{pmatrix}.$$

Woodbury Matrix-Identität

2.2 Satz: Es gilt die **Woodbury Matrix-Identität**

$$(A + BD^{-1}E)^{-1} = A^{-1} - A^{-1}B(D + EA^{-1}B)^{-1}EA^{-1},$$

wobei A , B , D und E Matrizen geeigneter Form sind.

Beweis: Der Beweis erfolgt durch Nachrechnen, indem man beide Seiten der Gleichung mit $A + BD^{-1}E$ multipliziert und die rechte Seite zur Einheitsmatrix umformt. □

Bestimmung des Posteriors

- Für die Anwendung des EM-Algorithmus benötigen wir die Dichte $p(\mathbf{z} \mid \mathbf{x}) = n(\mathbf{z} \mid \mathbf{x}; \boldsymbol{\mu}_{\mathbf{z} \mid \mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{z} \mid \mathbf{x}})$.
- Diese können wir aus der Verbundverteilung (2.7) mittels Satz ?? berechnen.
- Zunächst definieren wir zwei Matrizen, die wir häufig benötigen werden

$$\mathbf{C} := \sigma^2 \mathbf{I} + \mathbf{W} \mathbf{W}^\top \quad (2.8)$$

$$\mathbf{M} := \sigma^2 \mathbf{I} + \mathbf{W}^\top \mathbf{W}. \quad (2.9)$$

- Außerdem benötigen wir $\mathbf{C}^{-1}$, für deren Berechnung wir die Woodbury Identität aus 2.2 benutzen, wobei wir $\mathbf{A} = \sigma^2 \mathbf{I}$, $\mathbf{B} = \mathbf{W}$, $\mathbf{D} = \mathbf{I}$ und $\mathbf{E} = \mathbf{W}^\top$ setzen (siehe nächste Folie).

Bestimmung des Posteriors (Forts.)

Es ist

$$\begin{aligned}
 C^{-1} &= (\sigma^2 I + W W^\top)^{-1} \\
 &= \sigma^{-2} I - \sigma^{-2} I W (I + W^\top \sigma^{-2} I W)^{-1} W^\top \sigma^{-2} I && \text{Woodbury Identität, Satz 2.2.} \\
 &= \sigma^{-2} I - \sigma^{-2} W \left[\sigma^{-2} (\sigma^2 I + W^\top W) \right]^{-1} \sigma^{-2} W^\top && \text{In der Klammer } \sigma^{-2} \text{ ausklammern.} \\
 &= \sigma^{-2} I - \sigma^{-2} W \left[\sigma^{-2} M \right]^{-1} \sigma^{-2} W^\top && \text{Definition (2.9).} \\
 &= \sigma^{-2} I - \sigma^{-2} W \sigma^2 M^{-1} \sigma^{-2} W^\top && \text{Für } A \text{ und } B \text{ gilt } (AB)^{-1} = B^{-1} A^{-1}. \\
 &= \sigma^{-2} I - \sigma^{-2} W M^{-1} W^\top. && \sigma^{-2} \sigma^2 = 1.
 \end{aligned}
 \tag{2.10}$$

Bestimmung des Posteriors (Forts.)

In den weiteren Rechnungen brauchen wir auch noch einen Ausdruck für $\mathbf{W}^\top \mathbf{C}^{-1}$. Hierzu multiplizieren wir (2.10) von links mit $\mathbf{W}^\top$

$$\begin{aligned}
 \mathbf{W}^\top \mathbf{C}^{-1} &= \sigma^{-2} \mathbf{W}^\top - \sigma^{-2} \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^\top. \\
 &= \sigma^{-2} (\mathbf{I} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \sigma^{-2} \text{ und } \mathbf{W}^\top \text{ ausklammern.} \\
 &= \sigma^{-2} (\mathbf{M} \mathbf{M}^{-1} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \text{Es ist } \mathbf{I} = \mathbf{M} \mathbf{M}^{-1}. \\
 &= \sigma^{-2} (\mathbf{M} - \mathbf{W}^\top \mathbf{W}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Wir klammern } \mathbf{M}^{-1} \text{ aus.} \\
 &= \sigma^{-2} (\sigma^2 \mathbf{I}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Aus (2.9) folgt } \mathbf{M} - \mathbf{W}^\top \mathbf{W} = \sigma^2 \mathbf{I}. \\
 &= \mathbf{M}^{-1} \mathbf{W}^\top.
 \end{aligned} \tag{2.11}$$

Bestimmung des Posteriors (Forts.)

- Nun haben wir alles zusammen, um den Posterior mit Satz ?? auszurechnen.
- Wir beginnen mit dem bedingten Erwartungswert $\mu_{z|x}$

$$\begin{aligned}\mu_{z|x} &= \mu_z + \Sigma_{zx} \Sigma_{xx}^{-1} (x - \mu_x) \\ &= \mathbf{0} + \mathbf{W}^\top (\mathbf{W} \mathbf{W}^\top + \sigma^2 \mathbf{I})^{-1} (x - \mu) \\ &= \mathbf{W}^\top \mathbf{C}^{-1} (x - \mu) && \text{Definition (2.8)} \\ &= \mathbf{M}^{-1} \mathbf{W}^\top (x - \mu). && \text{Ausdruck aus (2.11)}\end{aligned}\tag{2.12}$$

2.3 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{z|x} = \sigma^2 \mathbf{M}^{-1}$ gilt.

Bestimmung des Posteriors (Forts.)

Zusammenfassung: Wir erhalten damit

$$z \mid x \sim \mathcal{N}(M^{-1}W^{\top}(x - \mu), \sigma^2 M^{-1}). \quad (2.13)$$

Bemerkung: Dasselbe Ergebnis erhält man, wenn man den Satz von Bayes ?? auf $z \sim \mathcal{N}(0, I)$ und $x \mid z \sim \mathcal{N}(Wz + \mu, \sigma^2 I)$ anwendet.

Bemerkung: In (2.13) kommt die Matrix $C^{-1} \in \mathbb{R}^{M \times M}$ nicht mehr vor. Stattdessen müssen wir nun die Matrix $M^{-1} \in \mathbb{R}^{D \times D}$ invertieren, was einfacher ist, da in der Regel $D \ll M$ ist.

Bestimmung der Likelihood

- Eine Möglichkeit zur Bestimmung der Parameter des PPCA-Modells ist die *Maximierung der Likelihood*.
- Hierfür benötigen wir einen Ausdruck für die Dichte $p(x)$ der beobachteten Daten x .
- Diesen können wir leicht aus der Verbundverteilung (2.7) bestimmen, indem wir z marginalisieren (siehe hierzu Satz ??).
- Die Randverteilung folgt zudem einer Normalverteilung.

Randdichte der Daten:

$$p(x) = \int_z n(z, x; \nu, \Sigma) dz = n(x; \mu, WW^\top + \sigma^2 I).$$

Log-Likelihood Funktion

Wir bestimmen die Log-Likelihood Funktion:

$$\begin{aligned}l(\boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) &= \ln \boldsymbol{n}(\boldsymbol{X}; \boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) = \sum_{n=1}^N \ln \boldsymbol{n}(\boldsymbol{x}_n; \boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) \\&= \sum_{n=1}^N \ln \left(\frac{1}{(2\pi)^{\frac{D}{2}} \cdot (\det \boldsymbol{C})^{\frac{1}{2}}} \cdot \exp \left\{ -\frac{1}{2} (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}) \right\} \right) \\&= \sum_{n=1}^N \left(-\frac{D}{2} \ln(2\pi) - \frac{1}{2} \ln \det(\boldsymbol{C}) - \frac{1}{2} (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}) \right) \\&= -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(\boldsymbol{C}) - \frac{1}{2} \sum_{n=1}^N (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}).\end{aligned}\tag{2.14}$$

Log-Likelihood Funktion (Forts.)

- Von der Log-Likelihood (2.14) können wir aufgrund der bekannten Maximum-Likelihood Lösung für Normalverteilungen direkt den Schätzer für μ ablesen

$$\mu = \bar{x} := \frac{1}{N} \sum_{n=1}^N x_n. \quad (2.15)$$

- Wir setzen daher (2.15) in (2.14) ein und erhalten

$$-\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(C) - \frac{1}{2} \sum_{n=1}^N (x_n - \bar{x})^\top C^{-1} (x_n - \bar{x}). \quad (2.16)$$

- Den Ausdruck (2.16) wollen wir noch weiter vereinfachen.
- Hierzu benötigen wir noch den Begriff der **Spur**.

Intermezzo: Spur einer Matrix und deren Eigenschaften

Um (2.16) noch weiter zu vereinfachen, benötigen wir noch den Begriff der **Spur**:

2.4 Definition: Es sei $\mathbf{A} \in \mathbb{R}^{N \times N}$ eine quadratische Matrix. Die **Spur** (Englisch: trace) von $\mathbf{A}$ ist die Summe der Elemente auf der Hauptdiagonalen von $\mathbf{A}$, genauer definieren wir

$$\text{trace}(\mathbf{A}) := \sum_{i=1}^N a_{ii}.$$

Intermezzo: Spur einer Matrix und deren Eigenschaften (Forts.)

2.5 Satz: Ohne Beweis folgen wichtige Eigenschaften und Rechenregeln der Spur einer Matrix:

- Im Folgenden benutzen wir häufig die *zyklische Eigenschaft* der Spur. Für Matrizen A , B und C passender Dimension gilt nämlich

$$\text{trace}(ABC) = \text{trace}(CAB) = \text{trace}(BCA). \quad (2.17)$$

- Sei $\alpha \in \mathbb{R}$ ein Skalar. Dann ist

$$\text{trace}(\alpha) = \alpha. \quad (2.18)$$

- Die Spur ist *linear*, d. h. für $\alpha, \beta \in \mathbb{R}$ und Matrizen $A, B \in \mathbb{R}^{N \times N}$ gilt

$$\text{trace}(\alpha A + \beta B) = \alpha \text{trace}(A) + \beta \text{trace}(B). \quad (2.19)$$

Log-Likelihood Funktion (Forts.)

- Für den Summanden in (2.16) gilt

$$\begin{aligned}
 (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}) &\stackrel{(2.18)}{=} \text{trace}((\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}})) \\
 &\stackrel{(2.17)}{=} \text{trace}(\mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^\top).
 \end{aligned}
 \tag{2.20}$$

- Hieraus folgt

$$\begin{aligned}
 -\frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}) &\stackrel{(2.19)}{=} -\frac{1}{2} \text{trace} \left(\mathbf{C}^{-1} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^\top \right) \\
 &\stackrel{(2.19)}{=} -\frac{N}{2} \text{trace}(\mathbf{C}^{-1} \mathbf{S}).
 \end{aligned}
 \tag{2.21}$$

Log-Likelihood Funktion (Forts.)

Zusammenfassung: Die Log-Likelihood Funktion der PPCA lautet damit

$$\begin{aligned} l(\mathbf{W}, \sigma^2) &= -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(\mathbf{C}) - \frac{N}{2} \text{trace}(\mathbf{C}^{-1} \mathbf{S}) \\ &= -\frac{N}{2} \{ D \ln(2\pi) + \ln \det(\mathbf{C}) + \text{trace}(\mathbf{C}^{-1} \mathbf{S}) \} \end{aligned} \quad (2.22)$$

Dies ist dieselbe Form wie in (12.44) in [2].

Optimierung der Log-Likelihood Funktion

tbd...

Anwendung des EM-Verfahrens

- Wir möchten nun die Lösung mit dem *EM-Verfahren* bestimmen.
- **Zur Erinnerung:** Im E-Schritt müssen wir $\mathbb{E}_{Z \sim p(Z|X)} [\ln p(X, Z; \theta)]$ bestimmen.
- Mit dem *Satz von Bayes* und der Linearität des Erwartungswerts können wir schreiben

$$\mathbb{E}_{Z \sim p(Z|X)} [\ln p(X, Z; \theta)] \propto \mathbb{E}_{Z \sim p(Z|X)} [\ln p(Z)] + \mathbb{E}_{Z \sim p(Z|X)} [\ln p(X | Z)] \quad (2.23)$$

- Wir betrachten zunächst ein einzelnes Beispiel x mit latenter Variable z .
- Hierfür gilt

$$\begin{aligned} \ln p(z) &= -\frac{M}{2} \ln(2\pi) - \frac{1}{2} z^\top z \\ &= -\frac{M}{2} \ln(2\pi) - \frac{1}{2} \text{trace}(z z^\top). \end{aligned} \quad (2.24)$$

Anwendung des EM-Verfahrens (Forts.)

- Des Weiteren haben wir

$$\begin{aligned}\ln p(\mathbf{x} \mid \mathbf{z}) &= \ln \left(\frac{1}{(2\pi)^{\frac{D}{2}} \det(\sigma^2 \mathbf{I})^{\frac{1}{2}}} \right) - \frac{1}{2} (\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu})^\top (\sigma^2 \mathbf{I})^{-1} (\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}). \\ &= -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}\|^2.\end{aligned}\tag{2.25}$$

Literatur

- [1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: <https://www.bishopbook.com/>.
- [2] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>.