

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Gaussian Mixture Models (GMMs)

② Expectation-Maximization (EM) Algorithmus

Kapitel

1 Gaussian Mixture Models (GMMs)

Problemstellung

Gaussian Mixture Models und latente Variablen

Maximum-Likelihood Lösung

Expectation-Maximization (EM) Algorithmus für GMMs

Problemstellung

- Wir wissen bereits, wie wir die Parameter μ und Σ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**
 - Gegeben sei ein Datensatz X bestehend aus N unabhängig und identisch normalverteilten Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$.
 - Schätze den Mittelwert μ gemäß

$$\hat{\mu}_{ML} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (1.1)$$

- Schätze die Kovarianzmatrix Σ mittels

$$\hat{\Sigma}_{ML} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\mu}_{ML})(\mathbf{x}_n - \hat{\mu}_{ML})^\top. \quad (1.2)$$

Frage: Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung




Abbildung: Modell bestehend aus einer Normalverteilung. Siehe [1], Seite 86.

Visualisierung: Problemstellung (Forts.)




Abbildung: Mixture-Modell bestehend aus zwei Normalverteilungen. Siehe [1], Seite 86.

Gaussian Mixture Models

1.1 Definition: Ein **Gaussian Mixture Model** ist eine *Überlagerung mehrerer Normalverteilungen*. Die Dichte bei K Komponenten ist gegeben durch

$$p(\mathbf{x}; \boldsymbol{\theta}) := \sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (1.3)$$

- Dabei enthält $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ die Modellparameter.
- Die **Mischkoeffizienten** π_k stellen sicher, dass $\int_{-\infty}^{+\infty} p(\mathbf{x}; \boldsymbol{\theta}) = 1$ gilt.
- Bei (1.3) handelt es sich um eine *Konvexkombination*, denn die π_k erfüllen

$$0 \leq \pi_k \leq 1 \quad \text{und} \quad \sum_{k=1}^K \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $z \in \mathbb{R}^K$ ein K -dimensionaler **One-Hot Vektor**.
- Dessen Komponenten erfüllen $z_k \in \{0, 1\}$ und $\sum_{k=1}^K z_k = 1$, wobei *genau ein* z_k den Wert 1 annimmt.
- Mit der Kettenregel gilt für die Verbunddichte von x und z

$$p(x, z) = p(x | z) \cdot p(z).$$

- Für die Definition der Dichte $p(z)$ benutzen wir die Mischkoeffizienten:

$$p(z_k = 1) := \pi_k.$$

- Da z ein One-Hot Vektor ist, können wir schreiben

$$p(z) = \prod_{k=1}^K \pi_k^{z_k}. \quad (1.4)$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Für die bedingte Dichte benutzen wir eine Normalverteilung der Form

$$p(\mathbf{x} \mid z_k = 1) := \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Aufgrund der One-Hot Eigenschaft können wir dies ebenfalls vektorisiert ausdrücken als

$$p(\mathbf{x} \mid \mathbf{z}) = \prod_{k=1}^K \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (1.5)$$

- Die interessierende Randdichte $p(\mathbf{x}; \boldsymbol{\theta})$ erhalten wir schließlich durch Marginalisierung von $\mathbf{z}$

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{z}) \cdot p(\mathbf{x} \mid \mathbf{z}) \stackrel{(\Delta)}{=} \sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (1.6)$$

- In (Δ) haben wir (1.4) und (1.5) zusammen mit der One-Hot Eigenschaft von $\mathbf{z}$ benutzt.

Latente Variablen

- Falls ein Datensatz X bestehend aus N Punkten $x_1, x_2, \dots, x_N$ vorliegt (und nicht nur ein einzelner Punkt x), so führen wir für jedes x_n ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt x_n .
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass x_n von Komponente k generiert wurde.

Bemerkung: Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend. Allerdings können wir nun mit der gemeinsamen Dichte $p(x, z; \theta)$ anstelle von $p(x; \theta)$ arbeiten, was zu *wesentlichen Vereinfachungen* führen wird. Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Nachfolgend interessieren wir uns besonders für die Posterior-Dichte $p(z | \mathbf{x})$.
- Mit $\gamma(z_k)$ bezeichnen wir die Wahrscheinlichkeit $p(z_k = 1 | \mathbf{x})$.
- Mit dem **Satz von Bayes** gilt

$$\begin{aligned}\gamma(z_k) &:= p(z_k = 1 | \mathbf{x}) = \frac{p(z_k = 1) \cdot p(\mathbf{x} | z_k = 1)}{\sum_{j=1}^K p(z_j = 1) \cdot p(\mathbf{x} | z_j = 1)} \\ &= \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.\end{aligned}\tag{1.7}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $z_k = 1$ und $\gamma(z_k)$ die Aposteriori-Wahrscheinlichkeit für $z_k = 1$, nachdem $\mathbf{x}$ beobachtet wurde.
- Man nennt $\gamma(z_k)$ auch die **Responsibility** der k -ten Komponente für Punkt $\mathbf{x}$.

Visualisierung: Responsibilities




Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_{nk})$ gewählt. Siehe [1], Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N *unabhängigen und identisch verteilten* Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ gegeben.
- Wir fassen die Punkte $\{\mathbf{x}_n\}$ in der Matrix $\mathbf{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n -te Zeile durch $\mathbf{x}_n^\top$ gegeben ist.
- Mit (1.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned} l(\theta) &:= \ln p(\mathbf{X}; \theta) = \ln \left(\prod_{n=1}^N \left(\sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) = \sum_{n=1}^N \ln p(\mathbf{x}_n; \theta). \end{aligned} \tag{1.8}$$

- Aufgrund der Summe im Argument des Logarithmus ist (1.8) schwer zu optimieren.

Gradient der Log-Likelihood für die Mittelwerte

$$\frac{\partial}{\partial \boldsymbol{\mu}_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) = \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} p(\mathbf{x}_n; \boldsymbol{\theta})$$

Anwendung der Kettenregel.

$$= \sum_{n=1}^N \left(\frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \sum_{j=1}^K \pi_j \frac{\partial}{\partial \boldsymbol{\mu}_k} \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) \right)$$

Einsetzen der Definition von $p(\mathbf{x}_n; \boldsymbol{\theta})$.

$$= \sum_{n=1}^N \frac{\pi_k}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

Nur k -ter Summand hängt von $\boldsymbol{\mu}_k$ ab. (1.9)

$$\stackrel{(\square)}{=} \sum_{n=1}^N \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \cdot \boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n - \boldsymbol{\mu}_k)$$

Kettenregel für Exponentialfunktion.

$$= \sum_{n=1}^N \gamma(z_{nk}) \cdot \boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n - \boldsymbol{\mu}_k)$$

Definition der Responsibilities.

Aufgabe: Gradient der Log-Likelihood für die Mittelwerte

1.2 Aufgabe: Machen Sie sich den Schritt ($\square$) in (1.9) klar.

Lösung für die Mittelwerte

- Wir setzen den Gradienten (1.9) Null, lösen nach μ_k auf und erhalten schließlich

$$\sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \stackrel{!}{=} \mathbf{0} \iff \mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n. \quad (1.10)$$

- Hierbei ist N_k die Summe der Responsibilities der k -ten Komponente, also

$$N_k := \sum_{n=1}^N \gamma(z_{nk}).$$

Interpretation: Der Mittelwert μ_k der k -ten Komponente ergibt sich also durch ein *gewichtetes arithmetisches Mittel* der Punkte $\{\mathbf{x}_n\}$, wobei die Gewichte gerade die Aposteriori-Wahrscheinlichkeiten dafür sind, dass $\mathbf{x}_n$ durch die k -te Komponente generiert wurde.

Lösung für die Kovarianzmatrizen

- Ein ähnliches Ergebnis erhalten wir für die Kovarianzmatrizen Σ_k .
- Es gilt

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \quad (1.11)$$

- Auch hier ergeben sich die Parameter als gewichtetes arithmetisches Mittel.

1.3 Aufgabe: Beweisen Sie diese Aussage!

Optimierung bezüglich der Mischkoeffizienten

- Bei der Optimierung bezüglich der Mischkoeffizienten π_k müssen wir zusätzlich die Normierungsbedingung beachten

$$\sum_{k=1}^K \pi_k = 1.$$

- Es handelt sich also um ein *Optimierungsproblem unter Nebenbedingungen*.
- Die **Lagrange-Funktion** des Problems ergibt sich zu

$$\begin{aligned} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right). \end{aligned} \tag{1.12}$$

Gradient der Log-Likelihood für die Mischkoeffizienten

$$\frac{\partial}{\partial \pi_k} \mathcal{L}(\boldsymbol{\theta}, \lambda) = \frac{\partial}{\partial \pi_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \cdot \frac{\partial}{\partial \pi_k} \left(\sum_{k=1}^K \pi_k - 1 \right) \quad \text{Linearität des Differenzialoperators.}$$

$$= \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \pi_k} p(\mathbf{x}_n; \boldsymbol{\theta}) + \lambda \quad \text{Anwendung der Kettenregel.}$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda \quad \text{Zähler und Nenner mit } \pi_k \text{ erweitern.} \quad (1.13)$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \gamma(z_{nk}) + \lambda \quad \text{Definition der Responsibilities.}$$

$$= \frac{N_k}{\pi_k} + \lambda \quad \text{Definition von } N_k.$$

Lösung für die Mischkoeffizienten

- Zusätzlich benötigen wir noch die Ableitung von (1.12) nach λ .
- Wir erhalten

$$\frac{\partial}{\partial \lambda} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \sum_{k=1}^K \pi_k - 1. \quad (1.14)$$

- Setzen wir die Ableitungen (1.13) und (1.14) Null, so erhalten wir

$$\pi_k = -\frac{N_k}{\lambda} \quad \text{und} \quad 1 = \sum_{k=1}^K \pi_k.$$

- Setzen wir die erste Bedingung in die zweite ein, so erhalten wir $\lambda = -N$ und damit schließlich

$$\pi_k = \frac{N_k}{N}. \quad (1.15)$$

Expectation-Maximization (EM) Algorithmus für GMMs

- Bei den Lösungsformeln (1.10), (1.11) und (1.15) handelt es sich *nicht um geschlossene Lösungsformeln (!)*, da die Gewichte $\gamma(z_{nk})$ von den anderen Parametern abhängen.
- Allerdings legen die Ergebnisse ein einfaches *iteratives Verfahren* nahe, den **Expectation-Maximization (EM) Algorithmus**.
- Dieser besteht aus zwei Phasen, die **Expectation-Phase (E-Schritt)** und die **Maximization-Phase (M-Schritt)**.
- Im E-Schritt werden die Werte $\gamma(z_{nk})$ bei gegebenen Parametern π_k , μ_k , Σ_k bestimmt.
- Im darauffolgenden M-Schritt werden die Parameter mit den neuen Werten $\gamma(z_{nk})$ aufdatiert.
- Dies führt man solange fort, bis Konvergenz eintritt.

Visualisierung: EM für GMMs




Abbildung: Visualisierung des EM Verfahrens für GMMs. Siehe [1], Seite 473.

Visualisierung: EM für GMMs (Forts.)




Abbildung: Visualisierung des EM Verfahrens für GMMs. Siehe [1], Seite 473.

EM Algorithmus für GMMs

1.4 Algorithmus

- 1 Initialisiere die Parameter $\{\pi_k\}$, $\{\mu_k\}$ und $\{\Sigma_k\}$ (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Berechne die Responsibilities für alle n und alle k gemäß

$$\gamma(z_{nk}) := \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \mu_j, \Sigma_j)}.$$

- 3 **M-Schritt:** Aktualisiere die Parameter, wobei $N_k := \sum_{n=1}^N \gamma(z_{nk})$

$$\mu_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad \text{und} \quad \Sigma_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^\top \quad \text{und} \quad \pi_k := \frac{N_k}{N}.$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zu Schritt 2.

Kapitel

② Expectation-Maximization (EM) Algorithmus

Problemstellung

Ungleichung von Jensen

Herleitung des Expectation-Schritts

Herleitung des Maximization-Schritts

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Anwendung auf Gaussian Mixture Models

Problemstellung

- Wir betrachten ein statistisches Modell mit den Daten $X = (x_1, x_2, \dots, x_N)^T$, den **latenten Variablen** $Z = (z_1, z_2, \dots, z_N)^T$ und den Modellparametern θ .
- Wie üblich ist unser Ziel die Maximierung der Log-Likelihood $\ln p(X; \theta)$ bezüglich θ .
- Wir nehmen an, dass die gemeinsame Verteilung $p(X, Z; \theta)$ von X und Z gegeben ist.
- Hieraus können wir $\ln p(X; \theta)$ bestimmen, indem wir Z *marginalisieren*:

$$\ln p(X; \theta) = \ln \sum_Z p(X, Z; \theta) \quad (2.1)$$

- In der Regel ist eine direkte Maximierung von (2.1) zu kompliziert, da der Logarithmus nicht direkt auf $p(X, Z; \theta)$ wirken kann.

Problemstellung (Forts.)

- Mit $\{X, Z\}$ bezeichnen wir den **vollständigen** Datensatz, X alleine nennen wir hingegen **unvollständig**.
- Analog nennen wir $\ln p(X, Z; \theta)$ die **vollständige Log-Likelihood** und $\ln p(X; \theta)$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von (2.1) schwer ist, möchten wir stattdessen $\ln p(X, Z; \theta)$ maximieren.
- **Problem:** Wir kennen Z nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in *zwei Phasen*, wobei man in jeder Iteration ausgehend von θ_{alt} neue Parameter θ_{neu} erhält, die (2.1) erhöhen.

E-Phase: Bestimme den Erwartungswert von $\ln p(X, Z; \theta)$ unter der Posterior-Verteilung der latenten Variablen $p(Z | X; \theta_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(X; \theta)$.

M-Phase: Die berechnete untere Schranke wird bezüglich der Parameter θ maximiert, was zu den aktualisierten Parametern θ_{neu} führt.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

2.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen




Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(X; \theta)$.
- Hierzu führen wir die Verteilung q über Z mit $q(Z) \neq 0$ ein und erhalten

$$\begin{aligned}\ln p(X; \theta) &= \ln \sum_Z p(X, Z; \theta) = \ln \sum_Z q(Z) \cdot \frac{p(X, Z; \theta)}{q(Z)} \\ &= \ln \mathbb{E}_{Z \sim q(Z)} \left[\frac{p(X, Z; \theta)}{q(Z)} \right] \\ &\geq \mathbb{E}_{Z \sim q(Z)} \left[\ln \frac{p(X, Z; \theta)}{q(Z)} \right] =: \mathcal{L}(q, \theta).\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen**, Satz 2.1, mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(X, Z; \theta)}{q(Z)}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(X; \theta) \geq \underbrace{\mathbb{E}_{Z \sim q(Z)} [\ln p(X, Z; \theta)]}_{\text{Erwartete vollständige Log-Likelihood}} - \underbrace{\mathbb{E}_{Z \sim q(Z)} [\ln q(Z)]}_{\text{Entropie von } q}. \quad (2.2)$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müssen.
- Wir möchten q so wählen, dass für das aktuelle θ in (2.2) Gleichheit gilt.
- Die Ungleichung von Jensen, Satz 2.1, gilt mit Gleichheit, falls

$$\frac{p(X, Z; \theta)}{q(Z)} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\mathbf{Z}) \propto p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet 'proportional zu'.
- Daraus erhalten wir (da q normiert sein muss)

$$\begin{aligned} q(\mathbf{Z}) &= \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\mathbf{Z}}} p(\mathbf{X}, \tilde{\mathbf{Z}}; \boldsymbol{\theta})} = \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{p(\mathbf{X}; \boldsymbol{\theta})} \\ &= p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}). \end{aligned}$$

- **Ergebnis:** Für q benutzen wir die Posterior-Verteilung von $\mathbf{Z}$ gegeben $\mathbf{X}$.
- Dies setzen wir in (2.2) ein und erhalten die Identität

$$\ln p(\mathbf{X}; \boldsymbol{\theta}) = \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor θ_{alt} , mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}\ln p(\mathbf{X}; \theta) &\geq \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{X}, \mathbf{Z}; \theta)] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})] \\ &= Q(\theta, \theta_{\text{alt}}) + H(\theta_{\text{alt}}, \theta_{\text{alt}}) \\ &= Q(\theta, \theta_{\text{alt}}) + \text{const},\end{aligned}$$

wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.

- Die Funktion $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ ist die **Entropie** von q unter θ_{alt} .

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ bezüglich θ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\theta, \theta_{\text{alt}})$ gegeben.
- Der M-Schritt hat damit also die Gestalt

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}). \quad (2.3)$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(X | \theta_{\text{neu}}) \geq p(X | \theta_{\text{alt}})$ gilt, dass also eine Iteration des EM-Verfahrens die Log-Likelihood tatsächlich erhöht.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

2.2 Algorithmus

1 Initialisiere θ_{alt} (entweder zufällig oder mit Vorwissen).

2 **E-Schritt:** Bestimme die untere Schranke

$$Q(\theta, \theta_{\text{alt}}) := \mathbb{E}_{Z \sim p(Z|X; \theta_{\text{alt}})} [\ln p(X, Z; \theta)].$$

3 **M-Schritt:** Maximiere die untere Schranke und berechne

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

4 Falls noch keine Konvergenz vorliegt, gehe zurück zu Schritt 2 und setze $\theta_{\text{alt}} := \theta_{\text{neu}}$.

5 Ansonsten gebe θ_{neu} zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus

$$\begin{aligned}\ln p(X; \theta_{\text{neu}}) &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | X; \theta_{\text{alt}}) \ln \frac{p(X, \mathbf{Z}; \theta_{\text{neu}})}{p(\mathbf{Z} | X; \theta_{\text{alt}})} \\ &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | X; \theta_{\text{alt}}) \ln \frac{p(X, \mathbf{Z}; \theta_{\text{alt}})}{p(\mathbf{Z} | X; \theta_{\text{alt}})} = \ln p(X; \theta_{\text{alt}}).\end{aligned}$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil θ_{neu} so gewählt wurde, dass es die untere Schranke maximiert.
- Die letzte Gleichheit gilt, da die untere Schranke bzgl. θ_{alt} die Log-Likelihood in θ_{alt} berührt.

Bemerkung: Allerdings kann das Verfahren in lokalen Maxima hängen bleiben!

Visualisierung: EM-Algorithmus




Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [1], Seite 488.

Aufgabe: EM für Probleme mit fehlenden Daten

2.3 Aufgabe: Das EM-Verfahren kann auch für Schätzprobleme benutzt werden, falls einzelne Werte im Datensatz fehlen. Eine Voraussetzung ist jedoch, dass das Fehlen der Daten zufällig ist und nicht systematisch.

Man nehme an...

Evidence Lower Bound (ELBO)

- Wir geben noch eine andere Sicht auf den EM-Algorithmus.
- Hierzu stellen wir fest, dass wir die Log-Likelihood $\ln p(X; \theta)$ folgendermaßen zerlegen können

$$\ln p(X; \theta) = \mathcal{L}(q, \theta) + \text{KL}(q \parallel p). \quad (2.4)$$

- Dabei ist:
 - $\mathcal{L}(q, \theta)$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound**

$$\mathcal{L}(q, \theta) := \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(X, \mathbf{Z}; \theta)}{q(\mathbf{Z})} = \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(X, \mathbf{Z}; \theta) - \ln q(\mathbf{Z})]. \quad (2.5)$$

- $\text{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\mathbf{Z})$ und $p(\mathbf{Z} \mid X; \theta)$

$$\text{KL}(q \parallel p) := - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z} \mid X; \theta)}{q(\mathbf{Z})} = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} \mid X; \theta) - \ln q(\mathbf{Z})]. \quad (2.6)$$

Beweis der Zerlegung (2.4)

Beweis: Wir beweisen die Zerlegung (2.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(X, Z; \theta)$ an. Wir erhalten $p(X, Z; \theta) = p(Z | X; \theta) \cdot p(X; \theta)$. Anwendung des Logarithmus ergibt

$$\ln p(X, Z; \theta) = \ln p(Z | X; \theta) + \ln p(X; \theta).$$

Dies setzen wir in die Evidence Lower Bound (2.5) ein und erhalten

$$\begin{aligned} \mathcal{L}(q, \theta) &= \sum_Z q(Z) \cdot [\ln p(X, Z; \theta) - \ln q(Z)] \\ &= \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) + \ln p(X; \theta) - \ln q(Z)]. \end{aligned}$$

Damit ergibt sich schließlich mit (2.6) und wegen $\sum_Z q(Z) = 1$

$$\begin{aligned} \mathcal{L}(q, \theta) + \text{KL}(q \parallel p) &= \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) + \ln p(X; \theta) - \ln q(Z)] - \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) - \ln q(Z)] \\ &= \sum_Z q(Z) \cdot \ln p(X; \theta) = \ln p(X; \theta) \cdot \sum_Z q(Z) = \ln p(X; \theta). \end{aligned}$$

□

Kullback-Leibler Divergenz

Eigenschaften der Kullback-Leibler Divergenz:

Für alle Wahrscheinlichkeitsverteilungen q und p gelten die folgenden Eigenschaften.

1 Nicht-Negativität:

$$\text{KL}(q \parallel p) \geq 0 \quad (2.7)$$

2 Identität:

$$\text{KL}(q \parallel p) = 0 \iff q = p. \quad (2.8)$$

- 3 Die Kullback-Leibler Divergenz ist **nicht symmetrisch** und damit keine Metrik. Es ist also im Allgemeinen

$$\text{KL}(q \parallel p) \neq \text{KL}(p \parallel q).$$

Kullback-Leibler Divergenz (Forts.)

- Aus (2.6) ist ersichtlich, dass $\text{KL}(q \parallel p)$ die Kullback-Leibler Divergenz zwischen der Verteilung $q(\mathbf{Z})$ und der Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ von $\mathbf{Z}$ ist.
- Aus der Zerlegung (2.4) folgt mit der Nichtnegativität (2.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\mathbf{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\mathbf{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood




Abbildung: Veranschaulichung der Zerlegung (2.4). Siehe [1], Seite 486.

Eine andere Sicht auf den E-Schritt

- Mit dieser Vorarbeit können wir nun die alternative Herleitung des EM-Algorithmus durchführen.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \theta_{\text{alt}})$ bezüglich $q(\mathbf{Z})$ bei gegebenem θ_{alt} maximiert, sodass die untere Schranke die eigentliche Zielfunktion $\ln p(\mathbf{X}; \theta)$ in θ_{alt} berührt.
- Da $p(\mathbf{X}; \theta_{\text{alt}})$ nicht von $q(\mathbf{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \theta_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (2.8) für $q(\mathbf{Z})$ gelten

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \theta_{\text{alt}}) = \ln p(\mathbf{X}; \theta_{\text{alt}}).$$

Visualisierung: E-Schritt




Abbildung: Veranschaulichung des E-Schritts. Siehe [1], Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\mathbf{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \theta)$ bezüglich θ .
- Hierdurch erhalten wir die neuen Parameter θ_{neu} , die letztendlich zu einer höheren Log-Likelihood $p(\mathbf{X}; \theta)$ führen.
- Setzen wir $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}; \theta_{\text{alt}})$ in die Definition der unteren Schranke (2.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \theta) &= \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \theta_{\text{alt}}) \ln p(\mathbf{X}, \mathbf{Z}; \theta) - \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \theta_{\text{alt}}) \ln p(\mathbf{Z} | \mathbf{X}; \theta_{\text{alt}}) \\ &= Q(\theta, \theta_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\theta, \theta_{\text{alt}})$ maximieren, wobei Q die **erwartete vollständige Log-Likelihood** ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (2.3) an

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern θ_{alt} bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}) \neq p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}}),$$

sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.

- Im folgenden E-Schritt setzen wir dann $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt




Abbildung: Veranschaulichung des M-Schritts. Siehe [1], Seite 487.

Gaussian Mixture Models und EM

- Wir wenden das allgemeine EM-Framework nun auf GMMs an.
- Im E-Schritt benötigen wir die Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ der latenten Variablen, wobei $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ ist.
- Diese können wir mit (1.4), (1.5) und dem Satz von Bayes bestimmen zu

$$p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}.$$

- Als nächstes stellen wir die erwartete vollständige Log-Likelihood auf, wobei der Erwartungswert bezüglich der Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ zu berechnen ist.
- Dazu benötigen wir allerdings noch ein Zwischenergebnis, das wir auf der nächsten Folie bereitstellen.

Gaussian Mixture Models und EM (Forts.)

- Es gilt der Zusammenhang

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}; \boldsymbol{\theta})}[z_{nk}] &= \frac{\sum_{z_n} z_{nk} \prod_{k'=1}^K [\pi_{k'} \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_{k'}, \boldsymbol{\Sigma}_{k'})]^{z_{nk'}}}{\sum_{z_n} \prod_{j=1}^K [\pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\
 &= \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(z_{nk}).
 \end{aligned} \tag{2.9}$$

- Der Erwartungswert der Indikator-Variablen z_{nk} unter der Aposteriori-Verteilung von $\mathbf{Z}$ ergibt sich also gerade als die jeweilige Responsibility $\gamma(z_{nk})$.

Gaussian Mixture Models und EM (Forts.)

Hiermit können wir nun die **erwartete vollständige Log-Likelihood** (Funktion Q) aufstellen

$$\begin{aligned}\mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}; \boldsymbol{\theta})}[\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] &= \mathbb{E} \left[\ln \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}} \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_{nk}} \right] \\ &= \mathbb{E} \left[\sum_{n=1}^N \sum_{k=1}^K z_{nk} \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \right] \quad \text{Logarithmengesetze.} \\ &= \sum_{n=1}^N \sum_{k=1}^K \mathbb{E}[z_{nk}] \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \quad \text{Linearität von } \mathbb{E}. \\ &= \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \quad \text{Anwendung von (2.9).}\end{aligned}\tag{2.10}$$

Gaussian Mixture Models und EM (Forts.)

- Die Funktion (2.10) müssen wir nun im M-Schritt bezüglich der Parameter maximieren.
- Beispielhaft:** Gradient bezüglich μ_k

$$\begin{aligned}\frac{\partial}{\partial \mu_k} \sum_{n=1}^N \sum_{j=1}^K \gamma(z_{nj}) \cdot \{\ln \pi_j + \ln \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)\} &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\partial}{\partial \mu_k} \ln \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \\ &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)} \cdot \Sigma_k^{-1}(\mathbf{x}_n - \mu_k) \\ &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1}(\mathbf{x}_n - \mu_k).\end{aligned}$$

- Vergleiche hierzu die Herleitung in (1.9).

Gaussian Mixture Models und EM (Forts.)

- Nullsetzen und Auflösen nach μ_k ergibt

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n.$$

- Dies hat dieselbe Form wie (1.10).
- Die anderen Formeln ergeben sich analog.

Literatur

- [1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: <https://www.bishopbook.com/>.