

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

1 Expectation-Maximization (EM) Algorithmus

Kapitel

1 Expectation-Maximization (EM) Algorithmus

Problemstellung

Ungleichung von Jensen

Herleitung des Expectation-Schritts

Herleitung des Maximization-Schritts

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Anwendung auf Gaussian Mixture Models

Problemstellung

- Wir betrachten ein statistisches Modell mit den Daten $\mathbf{X} = (x_1, x_2, \dots, x_N)^\top$, den **latenten Variablen** $\mathbf{Z} = (z_1, z_2, \dots, z_N)^\top$ und den Modellparametern θ .
- Wie üblich ist unser Ziel die Maximierung der Log-Likelihood $\ln p(\mathbf{X}; \theta)$ bezüglich θ .
- Wir nehmen an, dass die gemeinsame Verteilung $p(\mathbf{X}, \mathbf{Z}; \theta)$ von $\mathbf{X}$ und $\mathbf{Z}$ gegeben ist.
- Hieraus können wir $\ln p(\mathbf{X}; \theta)$ bestimmen, indem wir $\mathbf{Z}$ *marginalisieren*:

$$\ln p(\mathbf{X}; \theta) = \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}; \theta) \quad (1.1)$$

- In der Regel ist eine direkte Maximierung von (1.1) zu kompliziert, da der Logarithmus nicht direkt auf $p(\mathbf{X}, \mathbf{Z}; \theta)$ wirken kann.

Problemstellung (Forts.)

- Mit $\{X, Z\}$ bezeichnen wir den **vollständigen** Datensatz, X alleine nennen wir hingegen **unvollständig**.
- Analog nennen wir $\ln p(X, Z; \theta)$ die **vollständige Log-Likelihood** und $\ln p(X; \theta)$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von (1.1) schwer ist, möchten wir stattdessen $\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ maximieren.
- **Problem:** Wir kennen $\mathbf{Z}$ nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in *zwei Phasen*, wobei man in jeder Iteration ausgehend von $\boldsymbol{\theta}_{\text{alt}}$ neue Parameter $\boldsymbol{\theta}_{\text{neu}}$ erhält, die (1.1) erhöhen.

E-Phase: Bestimme den Erwartungswert von $\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ unter der Posterior-Verteilung der latenten Variablen $p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(\mathbf{X}; \boldsymbol{\theta})$.

M-Phase: Die berechnete untere Schranke wird bezüglich der Parameter $\boldsymbol{\theta}$ maximiert, was zu den aktualisierten Parametern $\boldsymbol{\theta}_{\text{neu}}$ führt.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

1.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen




Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(\mathbf{X} ; \boldsymbol{\theta})$.
- Hierzu führen wir die Verteilung q über $\mathbf{Z}$ mit $q(\mathbf{Z}) \neq 0$ ein und erhalten

$$\begin{aligned}\ln p(\mathbf{X} ; \boldsymbol{\theta}) &= \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta}) = \ln \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot \frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} \\ &= \ln \mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} \left[\frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} \right] \\ &\geq \mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} \left[\ln \frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} \right] =: \mathcal{L}(q, \boldsymbol{\theta}).\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen**, Satz 1.1, mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(\mathbf{X} ; \boldsymbol{\theta}) \geq \underbrace{\mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} [\ln p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})]}_{\text{Erwartete vollständige Log-Likelihood}} - \underbrace{\mathbb{E}_{\mathbf{Z} \sim q(\mathbf{Z})} [\ln q(\mathbf{Z})]}_{\text{Entropie von } q}. \quad (1.2)$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müssen.
- Wir möchten q so wählen, dass für das aktuelle $\boldsymbol{\theta}$ in (1.2) Gleichheit gilt.
- Die Ungleichung von Jensen, Satz 1.1, gilt mit Gleichheit, falls

$$\frac{p(\mathbf{X}, \mathbf{Z} ; \boldsymbol{\theta})}{q(\mathbf{Z})} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\mathbf{Z}) \propto p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet 'proportional zu'.
- Daraus erhalten wir (da q normiert sein muss)

$$\begin{aligned} q(\mathbf{Z}) &= \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\mathbf{Z}}} p(\mathbf{X}, \tilde{\mathbf{Z}}; \boldsymbol{\theta})} = \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{p(\mathbf{X}; \boldsymbol{\theta})} \\ &= p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}). \end{aligned}$$

- **Ergebnis:** Für q benutzen wir die Posterior-Verteilung von $\mathbf{Z}$ gegeben $\mathbf{X}$.
- Dies setzen wir in (1.2) ein und erhalten die Identität

$$\ln p(\mathbf{X}; \boldsymbol{\theta}) = \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor θ_{alt} , mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X} ; \theta_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}\ln p(\mathbf{X} ; \theta) &\geq \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X} ; \theta_{\text{alt}})} [\ln p(\mathbf{X}, \mathbf{Z} ; \theta)] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X} ; \theta_{\text{alt}})} [\ln p(\mathbf{Z} \mid \mathbf{X} ; \theta_{\text{alt}})] \\ &= Q(\theta, \theta_{\text{alt}}) + H(\theta_{\text{alt}}, \theta_{\text{alt}}) \\ &= Q(\theta, \theta_{\text{alt}}) + \text{const},\end{aligned}$$

wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.

- Die Funktion $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ ist die **Entropie** von q unter θ_{alt} .

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ bezüglich θ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\theta, \theta_{\text{alt}})$ gegeben.
- Der M-Schritt hat damit also die Gestalt

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}). \quad (1.3)$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(\mathbf{X} \mid \theta_{\text{neu}}) \geq p(\mathbf{X} \mid \theta_{\text{alt}})$ gilt, dass also eine Iteration des EM-Verfahrens die Log-Likelihood tatsächlich erhöht.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

1.2 Algorithmus

- 1 Initialisiere θ_{alt} (*entweder zufällig oder mit Vorwissen*).
- 2 **E-Schritt:** Bestimme die untere Schranke

$$Q(\theta, \theta_{\text{alt}}) := \mathbb{E}_{Z \sim p(Z | X; \theta_{\text{alt}})} [\ln p(X, Z; \theta)].$$

- 3 **M-Schritt:** Maximiere die untere Schranke und berechne

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zurück zu Schritt 2 und setze $\theta_{\text{alt}} := \theta_{\text{neu}}$.
- 5 Ansonsten gebe θ_{neu} zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus

$$\begin{aligned}\ln p(\mathbf{X}; \boldsymbol{\theta}_{\text{neu}}) &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}_{\text{neu}})}{p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})} \\ &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}_{\text{alt}})}{p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})} = \ln p(\mathbf{X}; \boldsymbol{\theta}_{\text{alt}}).\end{aligned}$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil $\boldsymbol{\theta}_{\text{neu}}$ so gewählt wurde, dass es die untere Schranke maximiert.
- Die letzte Gleichheit gilt, da die untere Schranke bzgl. $\boldsymbol{\theta}_{\text{alt}}$ die Log-Likelihood in $\boldsymbol{\theta}_{\text{alt}}$ berührt.

Bemerkung: Allerdings kann das Verfahren in lokalen Maxima hängen bleiben!

Visualisierung: EM-Algorithmus




Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [Bishop2024](#), Seite 488.

Aufgabe: EM für Probleme mit fehlenden Daten

1.3 Aufgabe: Das EM-Verfahren kann auch für Schätzprobleme benutzt werden, falls einzelne Werte im Datensatz fehlen. Eine Voraussetzung ist jedoch, dass das Fehlen der Daten zufällig ist und nicht systematisch.

Eine Münze mit unbekanntem Parameter θ (Wahrscheinlichkeit für Kopf) wird $N = 3$ Mal geworfen. Leider wurden nur die ersten zwei Würfe beobachtet, der dritte Wurf ging verloren (latente Variable). Der erste Wurf sei $X_1 = 1$ (Kopf) und der zweite $X_2 = 0$ (Zahl).

Führen Sie ausgehend vom Startwert $\theta_{\text{alt}} = 0.7$ eine vollständige Iteration des EM-Verfahrens durch. Wie lautet der neue Parameter θ_{neu} ?

Evidence Lower Bound (ELBO)

- Wir geben noch eine andere Sicht auf den EM-Algorithmus.
- Hierzu stellen wir fest, dass wir die Log-Likelihood $\ln p(\mathbf{X}; \theta)$ folgendermaßen zerlegen können

$$\ln p(\mathbf{X}; \theta) = \mathcal{L}(q, \theta) + \text{KL}(q \parallel p). \quad (1.4)$$

- Dabei ist:

- $\mathcal{L}(q, \theta)$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound**

$$\mathcal{L}(q, \theta) := \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}; \theta)}{q(\mathbf{Z})} = \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{X}, \mathbf{Z}; \theta) - \ln q(\mathbf{Z})]. \quad (1.5)$$

- $\text{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\mathbf{Z})$ und $p(\mathbf{Z} \mid \mathbf{X}; \theta)$

$$\text{KL}(q \parallel p) := - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z} \mid \mathbf{X}; \theta)}{q(\mathbf{Z})} = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} \mid \mathbf{X}; \theta) - \ln q(\mathbf{Z})]. \quad (1.6)$$

Beweis der Zerlegung (1.4)

Beweis: Wir beweisen die Zerlegung (1.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(\mathbf{X}, \mathbf{Z}; \theta)$ an. Wir erhalten $p(\mathbf{X}, \mathbf{Z}; \theta) = p(\mathbf{Z} | \mathbf{X}; \theta) \cdot p(\mathbf{X}; \theta)$. Anwendung des Logarithmus ergibt

$$\ln p(\mathbf{X}, \mathbf{Z}; \theta) = \ln p(\mathbf{Z} | \mathbf{X}; \theta) + \ln p(\mathbf{X}; \theta).$$

Dies setzen wir in die Evidence Lower Bound (1.5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \theta) &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{X}, \mathbf{Z}; \theta) - \ln q(\mathbf{Z})] \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} | \mathbf{X}; \theta) + \ln p(\mathbf{X}; \theta) - \ln q(\mathbf{Z})].\end{aligned}$$

Damit ergibt sich schließlich mit (1.6) und wegen $\sum_{\mathbf{Z}} q(\mathbf{Z}) = 1$

$$\begin{aligned}\mathcal{L}(q, \theta) + \text{KL}(q \parallel p) &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} | \mathbf{X}; \theta) + \ln p(\mathbf{X}; \theta) - \ln q(\mathbf{Z})] - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} | \mathbf{X}; \theta) - \ln q(\mathbf{Z})] \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot \ln p(\mathbf{X}; \theta) = \ln p(\mathbf{X}; \theta) \cdot \sum_{\mathbf{Z}} q(\mathbf{Z}) = \ln p(\mathbf{X}; \theta).\end{aligned}$$

□

Kullback-Leibler Divergenz

Eigenschaften der Kullback-Leibler Divergenz:

Für alle Wahrscheinlichkeitsverteilungen q und p gelten die folgenden Eigenschaften.

❶ **Nicht-Negativität:**

$$\text{KL}(q \parallel p) \geq 0 \quad (1.7)$$

❷ **Identität:**

$$\text{KL}(q \parallel p) = 0 \iff q = p. \quad (1.8)$$

❸ Die Kullback-Leibler Divergenz ist **nicht symmetrisch** und damit keine Metrik. Es ist also im Allgemeinen

$$\text{KL}(q \parallel p) \neq \text{KL}(p \parallel q).$$

Kullback-Leibler Divergenz (Forts.)

- Aus (1.6) ist ersichtlich, dass $\text{KL}(q \parallel p)$ die Kullback-Leibler Divergenz zwischen der Verteilung $q(\mathbf{Z})$ und der Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ von $\mathbf{Z}$ ist.
- Aus der Zerlegung (1.4) folgt mit der Nichtnegativität (1.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\mathbf{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\mathbf{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood




Abbildung: Veranschaulichung der Zerlegung (1.4). Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den E-Schritt

- Mit dieser Vorarbeit können wir nun die alternative Herleitung des EM-Algorithmus durchführen.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \theta_{\text{alt}})$ bezüglich $q(\mathbf{Z})$ bei gegebenem θ_{alt} maximiert, sodass die untere Schranke die eigentliche Zielfunktion $\ln p(\mathbf{X}; \theta)$ in θ_{alt} berührt.
- Da $p(\mathbf{X}; \theta_{\text{alt}})$ nicht von $q(\mathbf{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \theta_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (1.8) für $q(\mathbf{Z})$ gelten

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \theta_{\text{alt}}) = \ln p(\mathbf{X}; \theta_{\text{alt}}).$$

Visualisierung: E-Schritt




Abbildung: Veranschaulichung des E-Schritts. Siehe **Bishop2024**, Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\mathbf{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Hierdurch erhalten wir die neuen Parameter $\boldsymbol{\theta}_{\text{neu}}$, die letztendlich zu einer höheren Log-Likelihood $p(\mathbf{X}; \boldsymbol{\theta})$ führen.
- Setzen wir $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})$ in die Definition der unteren Schranke (1.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) - \sum_{\mathbf{Z}} p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \\ &= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\theta, \theta_{\text{alt}})$ maximieren, wobei Q die **erwartete vollständige Log-Likelihood** ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (1.3) an

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern θ_{alt} bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}) \neq p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}}),$$

sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.

- Im folgenden E-Schritt setzen wir dann $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt




Abbildung: Veranschaulichung des M-Schritts. Siehe **Bishop2024**, Seite 487.

Gaussian Mixture Models und EM

Wir wenden das allgemeine EM-Framework nun auf GMMs an:

- Im *E-Schritt* benötigen wir die Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X} ; \boldsymbol{\theta})$ der latenten Variablen, wobei $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ ist.
- Diese können wir mit (??), (??) und dem *Satz von Bayes* bestimmen zu

$$p(\mathbf{Z} \mid \mathbf{X} ; \boldsymbol{\theta}) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k \cdot \mathbf{n}(\mathbf{x}_n ; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}.$$

- Als nächstes stellen wir die *erwartete vollständige Log-Likelihood* auf, wobei der Erwartungswert bezüglich der Posterior-Verteilung $p(\mathbf{Z} \mid \mathbf{X} ; \boldsymbol{\theta})$ zu berechnen ist.
- Dazu benötigen wir allerdings noch ein Zwischenergebnis, das wir auf der nächsten Folie bereitstellen.

Gaussian Mixture Models und EM (Forts.)

- Es gilt der Zusammenhang

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})}[z_{nk}] &= \frac{\sum_{z_n} z_{nk} \prod_{k'=1}^K [\pi_{k'} \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_{k'}, \boldsymbol{\Sigma}_{k'})]^{z_{nk'}}}{\sum_{z_n} \prod_{j=1}^K [\pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\
 &= \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(z_{nk}).
 \end{aligned} \tag{1.9}$$

- Der Erwartungswert der Indikator-Variablen z_{nk} unter der Posterior-Verteilung von $\mathbf{Z}$ stellt sich also gerade als die jeweilige Responsibility $\gamma(z_{nk})$ heraus.

Gaussian Mixture Models und EM (Forts.)

Hiermit können wir nun die *erwartete vollständige Log-Likelihood* (Funktion Q) aufstellen

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} | \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] &= \mathbb{E} \left[\ln \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}} \cdot \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_{nk}} \right] \\
 &= \mathbb{E} \left[\sum_{n=1}^N \sum_{k=1}^K z_{nk} \cdot \{\ln \pi_k + \ln \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \right] && \text{Logarithmengesetze.} \\
 &= \sum_{n=1}^N \sum_{k=1}^K \mathbb{E}[z_{nk}] \cdot \{\ln \pi_k + \ln \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} && \text{Linearität von } \mathbb{E}. \\
 &= \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \cdot \{\ln \pi_k + \ln \boldsymbol{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} && \text{Anwendung von (1.9).}
 \end{aligned} \tag{1.10}$$

Gaussian Mixture Models und EM (Forts.)

- Die Funktion (1.10) müssen wir nun im *M-Schritt* bezüglich der Parameter maximieren.
- Beispielhaft:** Gradient bezüglich μ_k

$$\begin{aligned}
 \frac{\partial}{\partial \mu_k} \sum_{n=1}^N \sum_{j=1}^K \gamma(z_{nj}) \cdot \{\ln \pi_j + \ln \mathbf{n}(\mathbf{x}_n; \mu_j, \Sigma_j)\} &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\partial}{\partial \mu_k} \ln \mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k) \\
 &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k)} \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \\
 &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k).
 \end{aligned}$$

- Vergleiche hierzu die Herleitung in (??).

Gaussian Mixture Models und EM (Forts.)

- Nullsetzen und Auflösen nach μ_k ergibt

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n.$$

- Dieses Ergebnis hat dieselbe Form wie (??).
- Die anderen Formeln ergeben sich analog.

Literatur