

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

1 Gaussian Mixture Models (GMMs)

Kapitel

① Gaussian Mixture Models (GMMs)

Problemstellung

Gaussian Mixture Models und latente Variablen

Maximum-Likelihood Lösung

Expectation-Maximization (EM) Algorithmus für GMMs

Problemstellung

- Wir wissen bereits, wie wir die Parameter μ und Σ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**
 - Gegeben sei ein Datensatz X bestehend aus N unabhängig und identisch normalverteilten Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$.
 - Schätze den Mittelwert μ gemäß

$$\hat{\mu}_{ML} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (1.1)$$

- Schätze die Kovarianzmatrix Σ mittels

$$\hat{\Sigma}_{ML} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\mu}_{ML})(\mathbf{x}_n - \hat{\mu}_{ML})^\top. \quad (1.2)$$

Frage: Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung




Abbildung: Modell bestehend aus einer Normalverteilung. Siehe [1], Seite 86.

Visualisierung: Problemstellung (Forts.)




Abbildung: Mixture-Modell bestehend aus zwei Normalverteilungen. Siehe [1], Seite 86.

Gaussian Mixture Models

- Wir können ein **Gaussian Mixture Model** als eine *Überlagerung mehrerer Normalverteilungen* ansehen.
- Die Dichte bei K Komponenten ist gegeben durch

$$p(\mathbf{x}; \boldsymbol{\theta}) := \sum_{k=1}^K \pi_k \cdot p(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (1.3)$$

- Dabei enthält $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ die Modellparameter.
- Die **Mischkoeffizienten** π_k stellen sicher, dass die Mixture-Dichte *normiert* ist, dass also $\int_{-\infty}^{+\infty} p(\mathbf{x}; \boldsymbol{\theta}) = 1$ gilt.
- Die π_k erfüllen zudem

$$0 \leq \pi_k \leq 1 \quad \text{und} \quad \sum_{k=1}^K \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $z \in \mathbb{R}^K$ ein K -dimensionaler **One-Hot Vektor**.
- Dessen Komponenten erfüllen $z_k \in \{0, 1\}$ und $\sum_{k=1}^K z_k = 1$, wobei *genau ein* z_k den Wert 1 annimmt.
- Mit der Kettenregel gilt für die Verbunddichte von x und z

$$p(x, z) = p(x | z) \cdot p(z).$$

- Für die Definition der Dichte $p(z)$ benutzen wir die Mischkoeffizienten:

$$p(z_k = 1; \pi_k) := \pi_k.$$

- Da z ein One-Hot Vektor ist, können wir schreiben

$$p(z; \pi) = \prod_{k=1}^K \pi_k^{z_k}. \quad (1.4)$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Analog definieren wir

$$p(\mathbf{x} \mid z_k = 1; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) := p(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Dies können wir ebenfalls vektorisiert ausdrücken als

$$p(\mathbf{x} \mid \mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \prod_{k=1}^K p(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (1.5)$$

- Die Randdichte $p(\mathbf{x}; \boldsymbol{\theta})$ erhalten wir schließlich durch Marginalisierung in $\mathbf{z}$

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{z}; \boldsymbol{\pi}) \cdot p(\mathbf{x} \mid \mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{k=1}^K \pi_k \cdot p(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (1.6)$$

- Im letzten Gleichheitszeichen haben wir (1.4) und (1.5) zusammen mit der One-Hot Eigenschaft von $\mathbf{z}$ benutzt.

Latente Variablen

- Falls ein Datensatz X bestehend aus N Punkten $x_1, x_2, \dots, x_N$ vorliegt (und nicht nur ein einzelner Punkt x), so führen wir für jedes x_n ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt x_n .
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass x_n von Komponente k generiert wurde.
- Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend.
- Allerdings können wir nun mit der gemeinsamen Dichte $p(x, z; \theta)$ anstelle von $p(x; \theta)$ arbeiten, was zu *wesentlichen Vereinfachungen* führen wird.
- Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Nachfolgend interessieren wir uns besonders für die Posterior-Dichte $p(\mathbf{z} \mid \mathbf{x}; \boldsymbol{\theta})$.
- Mit $\gamma(z_k)$ bezeichnen wir die Wahrscheinlichkeit $p(z_k = 1 \mid \mathbf{x}; \boldsymbol{\theta})$.
- Mit dem *Satz von Bayes* gilt

$$\begin{aligned}\gamma(z_k) &:= p(z_k = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = \frac{p(z_k = 1) \cdot p(\mathbf{x} \mid z_k = 1)}{\sum_{j=1}^K p(z_j = 1) \cdot p(\mathbf{x} \mid z_j = 1)} \\ &= \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.\end{aligned}\tag{1.7}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $z_k = 1$ und $\gamma(z_k)$ die Aposteriori-Wahrscheinlichkeit für $z_k = 1$, nachdem $\mathbf{x}$ beobachtet wurde.
- Man nennt $\gamma(z_k)$ auch die **Responsibility** der k -ten Komponente für Punkt $\mathbf{x}$.

Visualisierung: Responsibilities




Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_{nk})$ gewählt. Siehe [1], Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N *unabhängigen und identisch verteilten* Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ gegeben.
- Wir fassen die Punkte $\{\mathbf{x}_n\}$ in der Matrix $\mathbf{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n -te Zeile durch $\mathbf{x}_n^\top$ gegeben ist.
- Mit (1.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned}\ln p(\mathbf{X}; \boldsymbol{\theta}) &= \ln \left(\prod_{n=1}^N \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right).\end{aligned}\tag{1.8}$$

- Aufgrund der Summe im Argument des Logarithmus ist (1.8) schwer zu optimieren.

Gradient der Log-Likelihood für die Mittelwerte

$$\frac{\partial}{\partial \mu_k} \ln p(X; \theta) = \sum_{n=1}^N \frac{1}{p(x_n; \theta)} \cdot \frac{\partial}{\partial \mu_k} p(x_n; \theta)$$

Anwendung der Kettenregel.

$$= \sum_{n=1}^N \left(\frac{1}{p(x_n; \theta)} \cdot \sum_{j=1}^K \pi_j \frac{\partial}{\partial \mu_k} \mathcal{N}(x_n; \mu_j, \Sigma_j) \right)$$

Einsetzen der Definition von $p(x_n; \theta)$.

$$= \sum_{n=1}^N \frac{\pi_k}{p(x_n; \theta)} \cdot \frac{\partial}{\partial \mu_k} \mathcal{N}(x_n; \mu_k, \Sigma_k)$$

Nur k -ter Summand hängt von μ_k ab. (1.9)

$$= \sum_{n=1}^N \frac{\pi_k \cdot \mathcal{N}(x_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_n; \mu_j, \Sigma_j)} \cdot \Sigma_k^{-1} (x_n - \mu_k)$$

Kettenregel für Exponentialfunktion.

$$= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (x_n - \mu_k)$$

Definition der Responsibilities.

Lösung für die Mittelwerte

- Wir setzen den Gradienten (1.9) Null, lösen nach μ_k auf und erhalten

$$\sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1}(\mathbf{x}_n - \mu_k) \stackrel{!}{=} 0 \quad \Longleftrightarrow \quad \mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n. \quad (1.10)$$

- Hierbei ist N_k die Summe der Responsibilities der k -ten Komponente, also

$$N_k := \sum_{n=1}^N \gamma(z_{nk}).$$

- Der Mittelwert μ_k der k -ten Komponente ergibt sich also durch ein *gewichtetes arithmetisches Mittel* der Punkte $\{\mathbf{x}_n\}$, wobei die Gewichtungsfaktoren gerade die Aposteriori-Wahrscheinlichkeiten dafür sind, dass $\mathbf{x}_n$ durch die k -te Komponente generiert wurde.

Lösung für die Kovarianzmatrizen

- Ein ähnliches Ergebnis erhalten wir für die Kovarianzmatrizen Σ_k .
- Es gilt

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \quad (1.11)$$

- Auch hier ergeben sich die Parameter als gewichtetes arithmetisches Mittel.

1.1 Aufgabe: Beweisen Sie diese Aussage!

Optimierung bezüglich der Mischkoeffizienten

- Bei der Optimierung bezüglich der Mischkoeffizienten π_k müssen wir zusätzlich die Normierungsbedingung beachten:

$$\sum_{k=1}^K \pi_k = 1.$$

- Es handelt sich also um ein *restringiertes Optimierungsproblem*.
- Die **Lagrange-Funktion** ist

$$\begin{aligned} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \ln p(X; \boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \end{aligned} \tag{1.12}$$

Gradient der Log-Likelihood für die Mischkoeffizienten

$$\frac{\partial}{\partial \pi_k} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \frac{\partial}{\partial \pi_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \cdot \frac{\partial}{\partial \pi_k} \left(\sum_{k=1}^K \pi_k - 1 \right) \quad \text{Linearität des Differenzialoperators.}$$

$$= \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \pi_k} p(\mathbf{x}_n; \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) + \lambda \quad \text{Anwendung der Kettenregel.}$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda \quad \text{Zähler und Nenner mit } \pi_k \text{ erweitern.} \quad (1.13)$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \gamma(z_{nk}) + \lambda \quad \text{Definition der Responsibilities.}$$

$$= \frac{N_k}{\pi_k} + \lambda \quad \text{Definition von } N_k.$$

Lösung für die Mischkoeffizienten

- Zusätzlich benötigen wir noch die Ableitung von (1.12) nach λ .
- Wir erhalten

$$\frac{\partial}{\partial \lambda} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \sum_{k=1}^K \pi_k - 1. \quad (1.14)$$

- Setzen wir die Ableitungen (1.13) und (1.14) Null, so erhalten wir

$$\pi_k = -\frac{N_k}{\lambda} \quad \text{und} \quad 1 = \sum_{k=1}^K \pi_k.$$

- Setzen wir die erste Bedingung in die zweite ein, so erhalten wir $\lambda = -N$ und damit schließlich

$$\pi_k = \frac{N_k}{N}. \quad (1.15)$$

Expectation-Maximization (EM) Algorithmus für GMMs

- Bei den Lösungsformeln (1.10), (1.11) und (1.15) handelt es sich *nicht um geschlossene Lösungsformeln (!)*, da die Gewichte $\gamma(z_{nk})$ von den anderen Parametern abhängen.
- Allerdings legen die Ergebnisse ein einfaches *iteratives Verfahren* nahe, den **Expectation-Maximization (EM) Algorithmus**.
- Dieser besteht aus zwei Phasen, die **Expectation-Phase (E-Schritt)** und die **Maximization-Phase (M-Schritt)**.
- Im E-Schritt werden die Werte $\gamma(z_{nk})$ bei gegebenen Parametern π_k, μ_k, Σ_k bestimmt.
- Im darauffolgenden M-Schritt werden die Parameter mit den neuen Werten $\gamma(z_{nk})$ aufdatiert.
- Dies führt man solange fort, bis Konvergenz eintritt.

Visualisierung: EM für GMMs




Abbildung: Visualisierung EM für GMMs. Siehe [1], Seite 473.

Visualisierung: EM für GMMs (Forts.)




Abbildung: Visualisierung EM für GMMs. Siehe [1], Seite 473.

EM Algorithmus für GMMs

1.2 Algorithmus

- 1 Initialisiere die Parameter $\{\pi_k\}$, $\{\mu_k\}$ und $\{\Sigma_k\}$ (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Berechne die Responsibilities für alle n und alle k gemäß

$$\gamma(z_{nk}) := \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)}.$$

- 3 **M-Schritt:** Aktualisiere die Parameter, wobei $N_k := \sum_{n=1}^N \gamma(z_{nk})$

$$\mu_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad \text{und} \quad \Sigma_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^\top \quad \text{und} \quad \pi_k := \frac{N_k}{N}.$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zu Schritt 2.

Literatur

- [1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: <https://www.bishopbook.com/>.