

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

1 Probabilistische PCA (PPCA)

Kapitel

1 Probabilistische PCA (PPCA)

PPCA Modell

Bestimmung der Verbunddichte

Bestimmung des Posteriors der latenten Variablen

Bestimmung der Likelihood und exakte Lösung

EM-Algorithmus für die PPCA

PCA als latent Variable Model

- Wir modellieren die Repräsentation der Daten im Principal Subspace als latente Variablen $z \in \mathbb{R}^D$.
- Für die Verteilung von z gelte

$$z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (1.1)$$

- Zudem führen wir die bedingte Verteilung von $x \in \mathbb{R}^M$ gegeben z wie folgt ein

$$x \mid z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (1.2)$$

- Die Spalten der Matrix $\mathbf{W} \in \mathbb{R}^{M \times D}$ spannen hierbei den Principal Subspace auf.
- Es ist $\boldsymbol{\mu} \in \mathbb{R}^M$.
- Der Parameter σ^2 beeinflusst die Varianz der bedingten Verteilung (1.2).

PPCA als generatives Modell

Die PPCA kann als **generatives Modell** aufgefasst werden:

- Zunächst wählen wir ein z gemäß (1.1).
- Dann ziehen wir die beobachtete Variable x aus der Verteilung (1.2).
- Hierbei ergibt sich der Wert für x gemäß

$$x = Wz + \mu + \varepsilon. \quad (1.3)$$

- $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ ist hierbei *additives normalverteiltes Datenrauschen*, welches durch den Parameter σ^2 in (1.2) beeinflusst wird.

Das Mapping der Daten in den Principal Subspace erhalten wir mit dem Satz von Bayes.

PPCA als generatives Modell




Abbildung: PPCA als generatives Modell. Siehe [1], Seite 572.

Bestimmung der Verbunddichte

- Für die weiteren Ausführungen benötigen wir die Verbunddichte $p(z, x)$ der beobachteten und latenten Variablen.
- Mit der Produktregel für Wahrscheinlichkeiten ist

$$p(z, x) = \boldsymbol{n}(x | z) \cdot \boldsymbol{n}(z). \quad (1.4)$$

- Da es sich bei (1.7) um ein Produkt von Normalverteilungen handelt, sind die Zufallsvariablen auch gemeinsam normalverteilt.
- Es ist also $p(z, x) = \boldsymbol{n}(z, x; \boldsymbol{\nu}, \boldsymbol{\Sigma})$ beziehungsweise

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\nu}, \boldsymbol{\Sigma}). \quad (1.5)$$

Bestimmung der Verbunddichte (Forts.)

Wir bestimmen zunächst den Parameter $\nu = (\mu_z, \mu_x)^\top$:

- Mit der Linearität des Erwartungswerts und den obigen Definitionen – insbesondere die Definitionen (1.1) und (1.3) – gilt

$$\mathbb{E}[z] = \mathbf{0}$$

$$\mathbb{E}[x] = \mathbb{E}[Wz + \mu + \varepsilon] = W \underbrace{\mathbb{E}[z]}_{=0} + \mathbb{E}[\mu] + \underbrace{\mathbb{E}[\varepsilon]}_{=0} = \mu.$$

- Zusammenfassend gilt also

$$\nu = \mathbb{E} \begin{bmatrix} z \\ x \end{bmatrix} = \begin{pmatrix} \mathbb{E}[z] \\ \mathbb{E}[x] \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix}. \quad (1.6)$$

Bestimmung der Verbunddichte (Forts.)

Nun bestimmen wir den Parameter $\Sigma = \begin{pmatrix} \Sigma_{zz} & \Sigma_{zx} \\ \Sigma_{xz} & \Sigma_{xx} \end{pmatrix}$:

- Zunächst ist $\Sigma_{zz} = \mathbb{E}[(z - \mathbb{E}[z])(z - \mathbb{E}[z])^\top] = \mathbb{E}[zz^\top] = \mathbb{D}[z] = I$.
- Ferner ist

$$\begin{aligned}\Sigma_{zx} &= \mathbb{E}[(z - \mathbb{E}[z])(x - \mathbb{E}[x])^\top] \\ &= \mathbb{E}[z(Wz + \mu + \varepsilon - \mathbb{E}[Wz + \mu + \varepsilon])^\top] \\ &= \mathbb{E}[z(Wz + \varepsilon)^\top] = \mathbb{E}[zz^\top W^\top + z\varepsilon^\top] = \mathbb{E}[zz^\top]W^\top + \mathbb{E}[z] \cdot \mathbb{E}[\varepsilon^\top] \\ &= W^\top.\end{aligned}$$

- Aus Symmetriegründen gilt $\Sigma_{xz} = W$.

Bestimmung der Verbunddichte (Forts.)

1.1 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{xx} = \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}$ gilt.

Zusammenfassung: Für die gemeinsame Verteilung von z und x erhalten wir also

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\nu, \Sigma)$$

$$\nu := \begin{pmatrix} 0 \\ \mu \end{pmatrix} \tag{1.7}$$

$$\Sigma := \begin{pmatrix} \mathbf{I} & \mathbf{W}^\top \\ \mathbf{W} & \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I} \end{pmatrix}.$$

Woodbury Matrix-Identität

1.2 Satz: Es gilt die **Woodbury Matrix-Identität**

$$(A + BD^{-1}E)^{-1} = A^{-1} - A^{-1}B(D + EA^{-1}B)^{-1}EA^{-1},$$

wobei A , B , D und E Matrizen geeigneter Form sind.

Beweis: Der Beweis erfolgt durch Nachrechnen, indem man beide Seiten der Gleichung mit $A + BD^{-1}E$ multipliziert und die rechte Seite zur Einheitsmatrix umformt. □

Bestimmung des Posteriors

- Für die Anwendung des EM-Algorithmus benötigen wir die Dichte $p(z | x) = \mathbf{n}(z | x; \mu_{z|x}, \Sigma_{z|x})$.
- Diese können wir aus der Verbundverteilung (1.7) mittels Satz ?? berechnen.
- Zunächst definieren wir zwei Matrizen, die wir häufig benötigen werden

$$C := \sigma^2 I + WW^\top \quad (1.8)$$

$$M := \sigma^2 I + W^\top W. \quad (1.9)$$

- Außerdem benötigen wir C^{-1} , für deren Berechnung wir die Woodbury Identität aus 1.2 benutzen, wobei wir $A = \sigma^2 I$, $B = W$, $D = I$ und $E = W^\top$ setzen (siehe nächste Folie).

Bestimmung des Posteriors (Forts.)

Es ist

$$\begin{aligned}
 C^{-1} &= (\sigma^2 I + W W^\top)^{-1} \\
 &= \sigma^{-2} I - \sigma^{-2} I W (I + W^\top \sigma^{-2} I W)^{-1} W^\top \sigma^{-2} I && \text{Woodbury Identität, Satz 1.2.} \\
 &= \sigma^{-2} I - \sigma^{-2} W \left[\sigma^{-2} (\sigma^2 I + W^\top W) \right]^{-1} \sigma^{-2} W^\top && \text{In der Klammer } \sigma^{-2} \text{ ausklammern.} \\
 &= \sigma^{-2} I - \sigma^{-2} W \left[\sigma^{-2} M \right]^{-1} \sigma^{-2} W^\top && \text{Definition (1.9).} \\
 &= \sigma^{-2} I - \sigma^{-2} W \sigma^2 M^{-1} \sigma^{-2} W^\top && \text{Für } A \text{ und } B \text{ gilt } (AB)^{-1} = B^{-1} A^{-1}. \\
 &= \sigma^{-2} I - \sigma^{-2} W M^{-1} W^\top. && \sigma^{-2} \sigma^2 = 1.
 \end{aligned}
 \tag{1.10}$$

Bestimmung des Posteriors (Forts.)

In den weiteren Rechnungen brauchen wir auch noch einen Ausdruck für $\mathbf{W}^\top \mathbf{C}^{-1}$. Hierzu multiplizieren wir (1.10) von links mit $\mathbf{W}^\top$

$$\begin{aligned}
 \mathbf{W}^\top \mathbf{C}^{-1} &= \sigma^{-2} \mathbf{W}^\top - \sigma^{-2} \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^\top. \\
 &= \sigma^{-2} (\mathbf{I} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \sigma^{-2} \text{ und } \mathbf{W}^\top \text{ ausklammern.} \\
 &= \sigma^{-2} (\mathbf{M} \mathbf{M}^{-1} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \text{Es ist } \mathbf{I} = \mathbf{M} \mathbf{M}^{-1}. \\
 &= \sigma^{-2} (\mathbf{M} - \mathbf{W}^\top \mathbf{W}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Wir klammern } \mathbf{M}^{-1} \text{ aus.} \\
 &= \sigma^{-2} (\sigma^2 \mathbf{I}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Aus (1.9) folgt } \mathbf{M} - \mathbf{W}^\top \mathbf{W} = \sigma^2 \mathbf{I}. \\
 &= \mathbf{M}^{-1} \mathbf{W}^\top.
 \end{aligned} \tag{1.11}$$

Bestimmung des Posteriors (Forts.)

- Nun haben wir alles zusammen, um den Posterior mit Satz ?? auszurechnen.
- Wir beginnen mit dem bedingten Erwartungswert $\mu_{z|x}$

$$\begin{aligned}\mu_{z|x} &= \mu_z + \Sigma_{zx} \Sigma_{xx}^{-1} (x - \mu_x) \\ &= \mathbf{0} + \mathbf{W}^\top (\mathbf{W} \mathbf{W}^\top + \sigma^2 \mathbf{I})^{-1} (x - \mu) \\ &= \mathbf{W}^\top \mathbf{C}^{-1} (x - \mu) && \text{Definition (1.8)} \\ &= \mathbf{M}^{-1} \mathbf{W}^\top (x - \mu). && \text{Ausdruck aus (1.11)}\end{aligned}\tag{1.12}$$

1.3 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{z|x} = \sigma^2 \mathbf{M}^{-1}$ gilt.

Bestimmung des Posteriors (Forts.)

Zusammenfassung: Wir erhalten damit

$$z \mid x \sim \mathcal{N}(M^{-1}W^{\top}(x - \mu), \sigma^2 M^{-1}). \quad (1.13)$$

Bemerkung: Dasselbe Ergebnis erhält man, wenn man den Satz von Bayes ?? auf $z \sim \mathcal{N}(0, I)$ und $x \mid z \sim \mathcal{N}(Wz + \mu, \sigma^2 I)$ anwendet.

Bemerkung: In (1.13) kommt die Matrix $C^{-1} \in \mathbb{R}^{M \times M}$ nicht mehr vor. Stattdessen müssen wir nun die Matrix $M^{-1} \in \mathbb{R}^{D \times D}$ invertieren, was einfacher ist, da in der Regel $D \ll M$ ist.

Bestimmung der Likelihood

- Eine Möglichkeit zur Bestimmung der Parameter des PPCA-Modells ist die *Maximierung der Likelihood*.
- Hierfür benötigen wir einen Ausdruck für die Dichte $p(x)$ der beobachteten Daten x .
- Diesen können wir leicht aus der Verbundverteilung (1.7) bestimmen, indem wir z marginalisieren (siehe hierzu Satz ??).
- Die Randverteilung folgt zudem einer Normalverteilung.

Randdichte der Daten:

$$p(x) = \int_z n(z, x; \nu, \Sigma) dz = n(x; \mu, WW^\top + \sigma^2 I).$$

Log-Likelihood Funktion

Wir bestimmen die Log-Likelihood Funktion:

$$\begin{aligned}l(\boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) &= \ln \boldsymbol{n}(\boldsymbol{X} ; \boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) = \sum_{n=1}^N \ln \boldsymbol{n}(\boldsymbol{x}_n ; \boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) \\&= \sum_{n=1}^N \ln \left(\frac{1}{(2\pi)^{\frac{D}{2}} \cdot (\det \boldsymbol{C})^{\frac{1}{2}}} \cdot \exp \left\{ -\frac{1}{2} (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}) \right\} \right) \\&= \sum_{n=1}^N \left(-\frac{D}{2} \ln(2\pi) - \frac{1}{2} \ln \det(\boldsymbol{C}) - \frac{1}{2} (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}) \right) \\&= -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(\boldsymbol{C}) - \frac{1}{2} \sum_{n=1}^N (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}).\end{aligned}\tag{1.14}$$

Log-Likelihood Funktion (Forts.)

- Von der Log-Likelihood (1.14) können wir aufgrund der bekannten Maximum-Likelihood Lösung für Normalverteilungen direkt den Schätzer für μ ablesen

$$\mu = \bar{x} := \frac{1}{N} \sum_{n=1}^N x_n. \quad (1.15)$$

- Wir setzen daher (1.15) in (1.14) ein und erhalten

$$-\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(C) - \frac{1}{2} \sum_{n=1}^N (x_n - \bar{x})^\top C^{-1} (x_n - \bar{x}). \quad (1.16)$$

- Den Ausdruck (1.16) wollen wir noch weiter vereinfachen.
- Hierzu benötigen wir noch den Begriff der **Spur**.

Intermezzo: Spur einer Matrix und deren Eigenschaften

Um (1.16) noch weiter zu vereinfachen, benötigen wir noch den Begriff der **Spur**:

1.4 Definition: Es sei $\mathbf{A} \in \mathbb{R}^{N \times N}$ eine quadratische Matrix. Die **Spur** (Englisch: trace) von $\mathbf{A}$ ist die Summe der Elemente auf der Hauptdiagonalen von $\mathbf{A}$, genauer definieren wir

$$\text{trace}(\mathbf{A}) := \sum_{i=1}^N a_{ii}.$$

Intermezzo: Spur einer Matrix und deren Eigenschaften (Forts.)

Ohne Beweis folgen wichtige Eigenschaften und Rechenregeln der Spur einer Matrix:

- Sei $\alpha \in \mathbb{R}$ ein Skalar. Dann ist

$$\text{trace}(\alpha) = \alpha. \quad (1.17)$$

- Die Spur ändert sich durch Transponieren nicht, d. h. für die Matrix $A \in \mathbb{R}^{N \times N}$ gilt

$$\text{trace}(A) = \text{trace}(A^T). \quad (1.18)$$

- *Zyklische Invarianz*: Für Matrizen A , B und C passender Dimension gilt

$$\text{trace}(ABC) = \text{trace}(CAB) = \text{trace}(BCA). \quad (1.19)$$

Intermezzo: Spur einer Matrix und deren Eigenschaften (Forts.)

Fortsetzung:

- Die Spur ist *linear*, d. h. für $\alpha, \beta \in \mathbb{R}$ und Matrizen $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{N \times N}$ gilt

$$\text{trace}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{trace}(\mathbf{A}) + \beta \text{trace}(\mathbf{B}). \quad (1.20)$$

- Ableitungsregeln: Es gelten die Regeln

$$\frac{\partial}{\partial \mathbf{A}} \text{trace}(\mathbf{A}\mathbf{B}) = \mathbf{B}^\top \quad (1.21)$$

$$\frac{\partial}{\partial \mathbf{A}} \text{trace}(\mathbf{A}\mathbf{B}\mathbf{A}^\top) = 2\mathbf{A}\mathbf{B}. \quad (\text{falls } \mathbf{B} \text{ symmetrisch ist}) \quad (1.22)$$

Log-Likelihood Funktion (Forts.)

- Für den Summanden in (1.16) gilt

$$\begin{aligned}
 (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}) &\stackrel{(1.17)}{=} \text{trace}((\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}})) \\
 &\stackrel{(1.19)}{=} \text{trace}(\mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^\top).
 \end{aligned}
 \tag{1.23}$$

- Hieraus folgt

$$\begin{aligned}
 -\frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}) &\stackrel{(1.20)}{=} -\frac{1}{2} \text{trace} \left(\mathbf{C}^{-1} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^\top \right) \\
 &\stackrel{(1.20)}{=} -\frac{N}{2} \text{trace}(\mathbf{C}^{-1} \mathbf{S}).
 \end{aligned}
 \tag{1.24}$$

Log-Likelihood Funktion (Forts.)

Zusammenfassung: Die Log-Likelihood Funktion der PPCA lautet damit

$$\begin{aligned} l(\mathbf{W}, \sigma^2) &= -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(\mathbf{C}) - \frac{N}{2} \text{trace}(\mathbf{C}^{-1} \mathbf{S}) \\ &= -\frac{N}{2} \{ D \ln(2\pi) + \ln \det(\mathbf{C}) + \text{trace}(\mathbf{C}^{-1} \mathbf{S}) \} \end{aligned} \quad (1.25)$$

Dies ist dieselbe Form wie in (12.44) in [1].

Optimierung der Log-Likelihood Funktion

tbd...

EM: E-Schritt

- Wir möchten nun die Lösung mit dem *EM-Verfahren* bestimmen.
- **Zur Erinnerung:** Im E-Schritt müssen wir $\mathbb{E}_{Z \sim \mathbf{n}(Z|X)} [\ln \mathbf{n}(X, Z; \theta)]$ bestimmen.
- Mit dem *Satz von Bayes* und der Linearität des Erwartungswerts können wir schreiben

$$\mathbb{E}_{Z \sim \mathbf{n}(Z|X)} [\ln \mathbf{n}(X, Z; \theta)] \propto \mathbb{E}_{Z \sim \mathbf{n}(Z|X)} [\ln \mathbf{n}(Z)] + \mathbb{E}_{Z \sim \mathbf{n}(Z|X)} [\ln \mathbf{n}(X | Z)] \quad (1.26)$$

- Wir betrachten zunächst ein einzelnes Beispiel x mit latenter Variable z .
- Hierfür gilt

$$\begin{aligned} \ln \mathbf{n}(z) &= -\frac{M}{2} \ln(2\pi) - \frac{1}{2} z^\top z \\ &= -\frac{M}{2} \ln(2\pi) - \frac{1}{2} \text{trace}(zz^\top). \end{aligned} \quad (1.27)$$

EM: E-Schritt (Forts.)

- Des Weiteren haben wir

$$\begin{aligned}\ln \mathbf{n}(\mathbf{x} \mid \mathbf{z}) &= \ln \left(\frac{1}{(2\pi)^{\frac{D}{2}} \det(\sigma^2 \mathbf{I})^{\frac{1}{2}}} \right) - \frac{1}{2}(\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu})^\top (\sigma^2 \mathbf{I})^{-1} (\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}). \\ &= -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}\|^2.\end{aligned}\tag{1.28}$$

- Wir multiplizieren den quadratischen Term $\|\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}\|^2$ aus

$$\begin{aligned}\|\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}\|^2 &= \|\mathbf{x} - \boldsymbol{\mu}\|^2 - 2(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{W}\mathbf{z} + \|\mathbf{W}\mathbf{z}\|^2 \\ &= \|\mathbf{x} - \boldsymbol{\mu}\|^2 - 2\mathbf{z}^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) + \mathbf{z}^\top \mathbf{W}^\top \mathbf{W} \mathbf{z} \\ &= \|\mathbf{x} - \boldsymbol{\mu}\|^2 - 2\mathbf{z}^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) + \text{trace}(\mathbf{z}\mathbf{z}^\top \mathbf{W}^\top \mathbf{W})\end{aligned}\tag{1.29}$$

EM: E-Schritt (Forts.)

- Mit diesen Ergebnissen können wir die Erwartungswerte aus (1.26) bestimmen.
- Wir erhalten mit der Linearität des Erwartungswerts

$$\begin{aligned}\mathbb{E}_{\mathbf{z} \sim \mathbf{n}(\mathbf{z} | \mathbf{x})} [\ln p(\mathbf{z})] &= -\frac{M}{2} \ln(2\pi) - \frac{1}{2} \text{trace}(\mathbb{E}[\mathbf{z} \mathbf{z}^\top]) \\ \mathbb{E}_{\mathbf{z} \sim \mathbf{n}(\mathbf{z} | \mathbf{x})} [\ln p(\mathbf{x} | \mathbf{z})] &= -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}\|^2 + \frac{1}{\sigma^2} \mathbb{E}[\mathbf{z}]^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) \\ &\quad - \frac{1}{2\sigma^2} \text{trace}(\mathbb{E}[\mathbf{z} \mathbf{z}^\top \mathbf{W}^\top \mathbf{W}])\end{aligned}\tag{1.30}$$

EM: E-Schritt (Forts.)

Durch Summation über alle Instanzen des Datensatzes erhalten wir das Endergebnis:

$$\begin{aligned} \mathbb{E}_{Z \sim \mathbf{n}(Z|X)}[\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\mu}, \mathbf{W}, \sigma^2)] \propto & - \sum_{n=1}^N \left\{ \frac{D}{2} \ln(2\pi\sigma^2) + \frac{1}{2} \text{trace}(\mathbb{E}[z_n z_n^\top]) \right. \\ & + \frac{1}{2\sigma^2} \|\mathbf{x}_n - \boldsymbol{\mu}\|^2 - \frac{1}{\sigma^2} \mathbb{E}[z_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \boldsymbol{\mu}) \\ & \left. + \frac{1}{2\sigma^2} \text{trace}(\mathbb{E}[z_n z_n^\top] \mathbf{W}^\top \mathbf{W}) \right\} \end{aligned} \quad (1.31)$$

Bemerkung: Der Ausdruck (1.31) hängt von der Posterior-Verteilung von z nur über die suffizienten Statistiken der Normalverteilung ab. Die Ausdrücke hierfür kennen wir aus (1.13).

EM: E-Schritt (Forts.)

- Die Ausdrücke $\mathbb{E}[z_n]$ und $\mathbb{E}[z_n z_n^\top]$ lassen sich mit (1.13) leicht bestimmen.
- Es ist

$$\mathbb{E}[z_n] = M^{-1} W^\top (x_n - \bar{x})$$

$$\begin{aligned}\mathbb{E}[z_n z_n^\top] &= \text{Cov}[z_n] + \mathbb{E}[z_n] \mathbb{E}[z_n]^\top \\ &= \sigma^2 M^{-1} + \mathbb{E}[z_n] \mathbb{E}[z_n]^\top\end{aligned}\tag{1.32}$$

- Für $\mathbb{E}[z_n z_n^\top]$ haben wir die Definition der Kovarianz benutzt.
- Damit haben wir den E-Schritt abgeschlossen.

EM: M-Schritt

- Wir kommen nun zum M-Schritt, in dem wir (1.31) in den Parametern $\mathbf{W}$ und σ^2 maximieren.
- Für die Ableitung nach $\mathbf{W}$ betrachten wir nur die Terme, die von $\mathbf{W}$ abhängen

$$f(\mathbf{W}) := \frac{1}{\sigma^2} \sum_{n=1}^N \left\{ \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) - \frac{1}{2} \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \right\}. \quad (1.33)$$

- Auf den ersten Term wenden wir die Spur und deren Rechenregeln an

$$\begin{aligned} \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) &\stackrel{(1.17)}{=} \text{trace}(\mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}})) \\ &\stackrel{(1.19)}{=} \text{trace}((\mathbf{x}_n - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top) \\ &\stackrel{(1.18)}{=} \text{trace}(\mathbf{W} \mathbb{E}[\mathbf{z}_n] (\mathbf{x}_n - \bar{\mathbf{x}})^\top). \end{aligned} \quad (1.34)$$

EM: M-Schritt (Forts.)

- Auf den zweiten Term wenden wir ebenfalls die zyklische Invarianz der Spur (1.19) an

$$\text{trace}(\mathbb{E}[z_n z_n^\top] \mathbf{W}^\top \mathbf{W}) = \text{trace}(\mathbf{W} \mathbb{E}[z_n z_n^\top] \mathbf{W}^\top). \quad (1.35)$$

- Nun haben wir beide Terme in der Form von (1.21) und (1.22) und können die Ableitung daher einfach bilden

$$\frac{\partial}{\partial \mathbf{W}} f(\mathbf{W}) = \frac{1}{\sigma^2} \sum_{n=1}^N \left\{ (x_n - \bar{x}) \mathbb{E}[z_n]^\top - \mathbf{W} \mathbb{E}[z_n z_n^\top] \right\}. \quad (1.36)$$

1.5 Aufgabe: Zeigen Sie, dass für σ^2 gilt

$$\frac{\partial}{\partial \sigma^2} f(\sigma^2) = -\frac{ND}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{n=1}^N \left\{ \|x_n - \bar{x}\|^2 - 2\mathbb{E}[z_n]^\top \mathbf{W}^\top (x_n - \bar{x}) + \text{trace}(\mathbb{E}[z_n z_n^\top] \mathbf{W}^\top \mathbf{W}) \right\}. \quad (1.37)$$

EM: M-Schritt (Forts.)

- Nullsetzen und Auflösen nach den jeweiligen Parametern ergibt schließlich die Aufdatierungsregeln für die Parameter $\mathbf{W}$ und σ^2

$$\mathbf{W}_{\text{neu}} = \left[\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_n]^\top \right] \left[\sum_{n=1}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \right]^{-1} \quad (1.38)$$

$$\sigma_{\text{neu}}^2 = \frac{1}{ND} \sum_{n=1}^N \left\{ \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 - 2 \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}_{\text{neu}}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) + \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}_{\text{neu}}^\top \mathbf{W}_{\text{neu}}) \right\}. \quad (1.39)$$

- Die Parameter $\mathbf{W}$ und σ^2 werden zunächst initialisiert.
- Anschließend werden die Erwartungswerte $\mathbb{E}[\mathbf{z}_n]$ und $\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top]$ mit den aktuellen Parametern bestimmt.
- Mit den neuen Erwartungswerten bestimmen wir die neuen Parameter gemäß (1.38) und (1.39).

EM-Algorithmus für die PPCA

1.6 Algorithmus

- 1 Bestimme $\bar{x} := \frac{1}{N} \sum_{n=1}^N x_n$ und initialisiere W_{alt} und σ_{alt}^2 zufällig (oder mit Vorwissen).
- 2 **E-Schritt:** Berechne für alle $n = 1, 2, \dots, N$

$$\mathbb{E}[z_n] = M^{-1} W_{\text{alt}}^{\top} (x_n - \bar{x})$$

$$\mathbb{E}[z_n z_n^{\top}] = \sigma_{\text{alt}}^2 M^{-1} + \mathbb{E}[z_n] \mathbb{E}[z_n]^{\top}.$$

- 3 **M-Schritt:** Berechne die neuen Parameter mithilfe der zuvor berechneten Erwartungswerte $W_{\text{neu}} = (1.38)$ und $\sigma_{\text{neu}}^2 = (1.39)$.
- 4 Falls noch keine Konvergenz vorliegt, setze $W_{\text{alt}} := W_{\text{neu}}$ und $\sigma_{\text{alt}}^2 := \sigma_{\text{neu}}^2$ und gehe zu 2.

Literatur

- [1] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>.