

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Grundlagen der Statistik

② Regression

③ Gaussian Mixture Models (GMMs)

Kapitel

① Grundlagen der Statistik

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Maximum-Likelihood Schätzer

Maximum-Aposteriori Schätzer

Bayes'sche Inferenz

Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ω ist der **Ereignisraum**, also die Menge aller Elementarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir $\Omega := \{1, 2, 3, 4, 5, 6\}$.
- Mit $\mathcal{A}$ bezeichnen wir die zugehörige **Sigma-Algebra**, eine Menge von Teilmengen von Ω . Im einfachsten Fall könnten wir $\mathcal{A} := \text{Pot}(\Omega)$ wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra $\mathbb{B}$ auf $\mathbb{R}$ heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus $\mathcal{A}$ eine Wahrscheinlichkeit zuordnet.

Zufallsvariablen

Im Folgenden sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{B})$ ein messbarer Raum.

1.1 Definition: Die Abbildung $X : \Omega \rightarrow \mathcal{X}$ heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : X^{-1}(B) := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von B unter X muss also eine messbare Menge in $\mathcal{A}$ sein, der durch $\mathbb{P}$ eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable $X : \Omega \rightarrow \mathcal{X}$ die Funktion

$$\mathbb{P}^X : \mathcal{B} \rightarrow [0, 1] \quad \text{mit} \quad B \mapsto \mathbb{P}(X^{-1}(B))$$

die **Verteilung** der Zufallsvariable X . $\mathbb{P}^X$ ist das **Bildmaß** von $\mathbb{P}$ unter X .

Zufallsvariablen (Forts.)

Sei $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$ ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße $X : \Omega \rightarrow \mathcal{X}$ ist *verteilt gemäß $\mathbb{Q}$* oder kurz *$\mathbb{Q}$ -verteilt*, falls es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\mathbb{P}^X = \mathbb{Q}$ gilt.

Beispiel: X ist $\mathcal{N}(\mu, \sigma^2)$ -verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\forall B \in \mathbb{B} : \mathbb{P}(X \in B) = \mathcal{N}(B; \mu, \sigma^2)$. Wir schreiben kurz $X \sim \mathcal{N}(\mu, \sigma^2)$.

Wahrscheinlichkeitsdichten

1.2 Definition: Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{B}, \mathbb{P}^X)$ Wahrscheinlichkeitsräume. Dabei ist $\mathbb{P}^X$ die Verteilung der Zufallsvariablen $X : \Omega \rightarrow \mathcal{X}$. Wir nennen eine nichtnegative Funktion

$$p_X : \mathbb{R} \rightarrow [0, \infty)$$

eine **(Wahrscheinlichkeits-)Dichte** von $\mathbb{P}^X$, falls

$$\mathbb{P}^X(B) = \int_B p_X(\xi) \, d\xi \quad \forall B \in \mathcal{B}.$$

Bemerkung: Die Wahrscheinlichkeiten der Mengen $B \in \mathcal{B}$ müssen sich also allesamt als Integral der Dichte p_X darstellen lassen können.

Erwartungswert von Zufallsvariablen

1.3 Definition: Sei $X \in \mathbb{R}$ eine Zufallsvariable. Wir definieren den **Erwartungswert** (erstes Moment) von X als

$$\mathbb{E}[X] := \int_{\mathbb{R}} \xi \cdot p_X(\xi) d\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen X und Y und eine beliebige aber feste Zahl $\alpha \in \mathbb{R}$ (keine Zufallsvariable!) gelten

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \quad \text{und} \quad \mathbb{E}[\alpha \cdot X] = \alpha \cdot \mathbb{E}[X].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ als

$$\mathbb{E}[\mathbf{x}] := (\mathbb{E}[x_1], \mathbb{E}[x_2], \dots, \mathbb{E}[x_n])^\top.$$

Varianz von Zufallsvariablen

1.4 Definition: Die Varianz einer Zufallsvariablen $X \in \mathbb{R}$ ist definiert als die *erwartete quadratische Abweichung vom Erwartungswert* (zweites zentriertes Moment), also

$$\mathbb{V}[X] := \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{\mathbb{R}} (\xi - \mathbb{E}[X])^2 \cdot p_X(\xi) \, d\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2 - 2X \cdot \mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2 \cdot \mathbb{E}[X]^2 + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2.\end{aligned}$$

Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen. Seien dazu X und Y reelle Zufallsvariablen und $\alpha \in \mathbb{R}$ beliebig aber fest.

Die Varianz ist **nicht** linear!

- Es gilt $\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y]$ nur, wenn X und Y unkorreliert sind (**Satz von Bienaymé**).
- $\mathbb{V}[\alpha \cdot X] = \alpha^2 \cdot \mathbb{V}[X]$.

Eine Verschiebung verändert die Varianz nicht, also $\mathbb{V}[X + \alpha] = \mathbb{V}[X]$ (α ist hierbei keine Zufallsvariable, sondern eine konstante reelle Zahl).

Kovarianz

1.5 Definition: Es seien X und Y zwei Zufallsvariablen. Die **Kovarianz** zwischen X und Y ist definiert als

$$\text{Cov}[X, Y] := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Bemerkungen:

- Die Erwartungswerte müssen natürlich existieren, damit Definition 1.5 Sinn ergibt.
- Die Kovarianz ist symmetrisch: Es ist $\text{Cov}[X, Y] = \text{Cov}[Y, X]$.

1.6 Aufgabe: Was ist der Unterschied zwischen Kovarianz und Korrelation?

Streuungsmatrix

1.7 Definition: Es sei $\mathbf{x} \in \mathbb{R}^N$ ein Zufallsvektor. Wir definieren die **Streuungsmatrix** $\mathbb{D}[\mathbf{x}]$ als

$$\mathbb{D}[\mathbf{x}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \in \mathbb{R}^{N \times N}.$$

Für die Einträge von $\mathbb{D}[\mathbf{x}]$ gilt:

$$\begin{aligned} (\mathbb{D}[\mathbf{x}])_{ij} &= \mathbb{E}[(x_i - \mathbb{E}[x_i])(x_j - \mathbb{E}[x_j])] \\ &= \mathbb{E}[(x_j - \mathbb{E}[x_j])(x_i - \mathbb{E}[x_i])] = (\mathbb{D}[\mathbf{x}])_{ji} = \begin{cases} \text{Cov}[x_i, x_j] & \text{für } i \neq j \\ \mathbb{V}[x_i] & \text{für } i = j. \end{cases} \end{aligned}$$

1.8 Aufgabe: Zeigen Sie, dass $\mathbb{D}[\mathbf{x}]$ positiv semidefinit ist.

Kovarianzmatrix

1.9 Definition: Es seien $x \in \mathbb{R}^N$ und $y \in \mathbb{R}^M$ zwei Zufallsvektoren. Die **Kovarianzmatrix** von x und y ist

$$\text{Cov}[x, y] := \mathbb{E}[(x - \mathbb{E}[x])(y - \mathbb{E}[y])^\top] \in \mathbb{R}^{N \times M}.$$

Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

Name der Verteilung	$\mathbb{P}^X$	Zähldichte $p_X(k)$	$\mathbb{E}[X]$	$\mathbb{V}[X]$
Bernoulli-Verteilung	$B_{1,p}$	$p^k \cdot (1-p)^{1-k}$	p	$p \cdot (1-p)$
Binomial-Verteilung	$B_{n,p}$	$\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Hypergeometrische Verteilung	$H_{n,K,N}$	$\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \cdot \frac{K}{N}$	$n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$
Poisson-Verteilung	P_λ	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	λ	λ

Absolutstetige Verteilungen

Name der Verteilung	$\mathbb{P}^X$	Lebesgue-Dichte $p_X(\xi)$	$\mathbb{E}[X]$	$\mathbb{V}[X]$
Normalverteilung	$\mathcal{N}_{\mu, \sigma^2}$	$\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma-Verteilung	$\Gamma_{\lambda, r}$	$\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$
Chiquadrat-Verteilung	χ_f^2	$\frac{1}{2^{\frac{f}{2}} \cdot \Gamma(\frac{f}{2})} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	f	$2 \cdot f$
Exponential-Verteilung	Exp_{λ}	$\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Beta-Verteilung	$\beta_{a, b}$	$\frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0, 1)}(\xi)$	$\frac{a}{a+b}$	$\frac{a \cdot b}{(a+b)^2 \cdot (a+b+1)}$
Gleichverteilung	$U_{(a, b)}$	$\frac{1}{b-a} \cdot \mathbf{1}_{(a, b)}(\xi)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

1.10 Definition: Es seien $X \in \mathbb{R}$ und $Y \in \mathbb{R}$ reelle Zufallsvariablen mit den Verteilungen $\mathbb{P}^X$, $\mathbb{P}^Y$ und den Dichten p_X bzw. p_Y .

X und Y heißen **stochastisch unabhängig** genau dann, wenn $p_{X,Y} := p_X \cdot p_Y$ eine **Produktdichte** der Verteilung $\mathbb{P}^{X,Y}$ ist, d. h. die gemeinsame Dichte von X und Y ergibt sich als Produkt der Einzeldichten.

Bemerkung: Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. **Die Umkehrung gilt im Allgemeinen nicht!** Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als die der Unkorreliertheit.

Bedingte Wahrscheinlichkeiten

- Wahrscheinlichkeiten von Ereignissen verändern sich, wenn wir zusätzliches Wissen mit einbeziehen.
- Wir definieren daher:

1.11 Definition: Es seien X und Y zwei Zufallsvariablen, wobei wir den Wert von Y bereits beobachtet haben (Vorwissen). Dann ist die **Wahrscheinlichkeitsdichte von X gegeben Y** , in Notation $p_{X|Y}(x | y)$, definiert als

$$p_{X|Y}(x | y) := \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Satz von Bayes

Mit bedingten Wahrscheinlichkeiten können wir einen zentralen Satz der Wahrscheinlichkeitsrechnung angeben:

1.12 Satz: Es seien X und Y zwei Zufallsvariablen. Es gilt der **Satz von Bayes**

$$p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) \cdot p_X(x)}{p_Y(y)}.$$

Beweis: Mit Definition 1.11 gilt $p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}$. Analog gilt $p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}$. Da $p_{X,Y}(x, y) = p_{Y,X}(y, x)$, können wir beide Gleichungen nach der Verbunddichte $p_{X,Y}(x, y)$ auflösen. Wir erhalten also $p_{X,Y}(x, y) = p_{X|Y}(x | y) \cdot p_Y(y)$ und $p_{X,Y}(x, y) = p_{Y|X}(y | x) \cdot p_X(x)$. Gleichsetzen liefert schließlich

$$p_{X|Y}(x | y) \cdot p_Y(y) = p_{Y|X}(y | x) \cdot p_X(x) \quad \Longleftrightarrow \quad p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) \cdot p_X(x)}{p_Y(y)},$$

die Behauptung. □

Transformationssatz für Lebesgue-Dichten

1.13 Satz: Es seien $\mathbf{x}$ und $\mathbf{y}$ N -dimensionale Zufallsvektoren mit dem Zusammenhang

$$\mathbf{y} = \mathbf{T}(\mathbf{x}).$$

Die Abbildung $\mathbf{T} : \mathbb{R}^N \rightarrow \mathbb{R}^N$ sei *bijektiv*, sodass die Umkehrabbildung $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y})$ existiert und eindeutig ist. Dann gilt für die Dichte $p_{\mathbf{y}}$ der transformierten Zufallsvariablen $\mathbf{y}$

$$p_{\mathbf{y}}(\mathbf{y}) = p_{\mathbf{x}}(\mathbf{T}^{-1}(\mathbf{y})) \cdot |\det \mathbf{J}\mathbf{T}^{-1}(\mathbf{y})|,$$

wobei $p_{\mathbf{x}}$ die Dichte von $\mathbf{x}$ und $\mathbf{J}\mathbf{T}^{-1}$ die Jacobi-Matrix der Abbildung $\mathbf{T}^{-1}$ bezeichnet.

Beweis: Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

Beispiel I

Es sei $X \sim \text{Exp}_2$ eine exponentialverteilte Zufallsvariable mit Ankunftsrate $\lambda = 2$.

Gesucht ist die Dichte der Zufallsvariablen $Y := 5X + 2$.

Lösung:

Es ist $T(X) := 5X + 2$ eine bijektive Transformation mit der Umkehrabbildung $X = T^{-1}(Y) = \frac{1}{5}(Y - 2)$. Zusammen mit der Dichte $p_X(x) = 2 \cdot e^{-2x} \cdot \mathbf{1}_{[0, \infty)}(x)$ der Exp_2 -Verteilung erhalten wir für die Dichte $p_Y(y)$ der transformierten Zufallsvariablen Y

$$\begin{aligned} p_Y(y) &= p_X(T^{-1}(y)) \cdot (T^{-1})'(y) = 2 \cdot e^{-2\left(\frac{y}{5} - \frac{2}{5}\right)} \cdot \mathbf{1}_{[0, \infty)}\left(\frac{1}{5}y - \frac{2}{5}\right) \cdot \frac{1}{5} \\ &= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2y}{5}} \cdot \mathbf{1}_{[2, \infty)}(y). \end{aligned}$$

Beispiel II

Der Zufallsvektor $\mathbf{x} \in \mathbb{R}^N$ habe eine beliebige Lebesgue-Dichte $p_{\mathbf{x}}$. Die Transformation $\mathbf{T}$ sei linear und bijektiv, also von der Form $\mathbf{y} = \mathbf{T}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$. Wie lautet die Dichte von $\mathbf{y}$?

Lösung:

Unter obigen Voraussetzungen ist $\mathbf{A}$ invertierbar. Also existiert die Umkehrfunktion, welche durch $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})$ gegeben ist. Als Jacobi-Matrix erhält man $J\mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}$.

Die Anwendung der Transformationsformel 1.13 ergibt daher für die Dichte $p_{\mathbf{y}}$ von $\mathbf{y}$ den Ausdruck

$$p_{\mathbf{y}}(\mathbf{y}) = \frac{1}{|\det \mathbf{A}|} \cdot p_{\mathbf{x}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})),$$

wobei wir den Zusammenhang $\det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$ benutzt haben.

Beispiel III

Das nächste Beispiel wird als Übungsaufgabe gestellt:

1.14 Aufgabe: Es sei X eine Zufallsvariable, die χ^2_2 -verteilt ist.

- 1 Berechnen Sie die Lebesgue-Dichte der Zufallsvariable $Y := \sqrt{X}$.
- 2 Berechnen Sie die Wahrscheinlichkeit $\mathbb{P}(Y > \frac{1}{2})$.

Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

1.15 Satz: Es sei $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top \in \mathbb{R}^N$ ein Zufallsvektor, dessen Komponenten $x_i \in \mathbb{R}$ unabhängig und identisch standardnormalverteilt sind, d. h. $x_i \sim \mathcal{N}(0, 1) \forall i \in \{1, \dots, N\}$.

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$\mathbf{n}_{\mathbf{x}}(\mathbf{x}) := \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

Beweis: Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$\mathbf{n}_{\mathbf{x}}(\mathbf{x}) = \prod_{i=1}^N \mathbf{n}_{x_i}(x_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^N x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

□

Multivariate Normalverteilung (Forts.)

Für die multivariate Standardnormalverteilung gilt $\mathbb{E}[\mathbf{x}] = \mathbf{0}$ und $\mathbb{D}[\mathbf{x}] = \mathbf{I}$.

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren $\boldsymbol{\mu} \in \mathbb{R}^N$ und Streuungsmatrizen $\boldsymbol{\Sigma} \in \mathbb{R}^{N \times N}$. Wir fordern lediglich, dass die Streuungsmatrix $\boldsymbol{\Sigma}$ *positiv definit* ist, dass also $\mathbf{z}^\top \boldsymbol{\Sigma} \mathbf{z} > 0 \forall \mathbf{z} \in \mathbb{R}^N \setminus \{\mathbf{0}\}$ gilt.

- 1 Aufgrund der positiven Definitheit von $\boldsymbol{\Sigma}$ gibt es eine untere Dreiecksmatrix $\mathbf{A}$ mit $\boldsymbol{\Sigma} = \mathbf{A} \mathbf{A}^\top$ (Stichwort: **Cholesky-Zerlegung**).
- 2 Wir betrachten die Transformation $\mathbf{y} := \mathbf{A} \mathbf{x} + \boldsymbol{\mu}$. Es gilt

$$\mathbb{E}[\mathbf{y}] = \mathbb{E}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{E}[\mathbf{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \quad \text{und} \quad \mathbb{D}[\mathbf{y}] = \mathbb{D}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{D}[\mathbf{x}] \mathbf{A}^\top = \mathbf{A} \mathbf{A}^\top = \boldsymbol{\Sigma}.$$

- 3 Nun wenden wir die Transformationsformel 1.13 an, um die Dichte von $\mathbf{y}$ zu bestimmen.

Multivariate Normalverteilung (Forts.)

Zu Schritt 3: Es ist $T^{-1}(x) = A^{-1}(y - \mu)$. Mit Beispiel II zum Transformationssatz erhalten wir

$$|\det JT^{-1}(y)| = |\det A^{-1}| = \frac{1}{|\det A|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz die Identität

$\det \Sigma = \det(AA^T) = \det A \cdot \det A = \det^2 A$. Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also $|\det A| = (\det \Sigma)^{\frac{1}{2}}$. Die Dichte p_y nimmt damit die Form

$$p_y(y) = \frac{1}{(\det \Sigma)^{\frac{1}{2}}} \cdot n_x(A^{-1}(y - \mu))$$

an, wobei p_x die Dichte der Standardnormalverteilung aus Satz 1.15 ist. Wir setzen dort $x := A^{-1}(y - \mu)$, sodass $\|x\|^2 = (y - \mu)^T (A^{-1})^T A^{-1}(y - \mu) = (y - \mu)^T \Sigma^{-1}(y - \mu)$ gilt.

Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

1.16 Definition: Es sei $\mu \in \mathbb{R}^N$ ein Vektor und $\Sigma \in \mathbb{R}^{N \times N}$ eine *positiv definite* Matrix.

Die Dichte der **multivariaten Normalverteilung** $\mathcal{N}(\mu, \Sigma)$ ist gegeben durch

$$n_x(x) := \frac{1}{(2\pi)^{\frac{N}{2}} \cdot (\det \Sigma)^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

Bemerkung: Die positive Definitheit der Matrix Σ impliziert auch deren Invertierbarkeit (siehe hierzu Satz 2.4).

Visualisierung: Multivariate Normalverteilung




Abbildung: Multivariate (genauer zweidimensionale) Normalverteilung mit (Links): Allgemeiner Kovarianzmatrix. (Mitte): Diagonaler Kovarianzmatrix, sodass die Konturen achsenparallel verlaufen. (Rechts): Kovarianz proportional zur Einheitsmatrix, also aI mit $a > 0$, sodass die Konturen perfekte Kreise bilden. Siehe [1], Seite 76.

Partitionierte Normalverteilung

1.17 Definition: Es seien $\mathbf{x} \in \mathbb{R}^D$ und $\mathbf{y} \in \mathbb{R}^{N-D}$ zwei Zufallsvektoren. Wir fassen diese zu einem neuen Zufallsvektor $\mathbf{z} := (\mathbf{x}^\top, \mathbf{y}^\top)^\top \in \mathbb{R}^N$ mit $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ zusammen. Hierbei seien

$$\boldsymbol{\mu} := \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix} \quad \text{und} \quad \boldsymbol{\Sigma} := \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}.$$

Wir nennen dieses Modell **partitionierte Normalverteilung**.

Bemerkungen: Aus der Symmetrie von $\boldsymbol{\Sigma}$ folgt die von $\boldsymbol{\Sigma}_{xx}$ und $\boldsymbol{\Sigma}_{yy}$. Außerdem gilt $\boldsymbol{\Sigma}_{xy} = \boldsymbol{\Sigma}_{yx}^\top$.

Oft ist es einfacher mit der Inversen der Kovarianzmatrix zu arbeiten. Wir definieren daher $\boldsymbol{\Lambda} := \boldsymbol{\Sigma}^{-1}$. Man nennt diese Matrix **Präzisionsmatrix**.

Bedingte Normalverteilung

1.18 Satz: Wir betrachten das Modell der partitionierten Normalverteilung aus Definition 1.17. Für die Zufallsvariable $x | y$ gilt

$$x | y \sim \mathcal{N}(\mu_{x|y}, \Sigma_{x|y}),$$

wobei für die Parameter der folgende Zusammenhang gilt:

$$\mu_{x|y} := \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$$

$$\Sigma_{x|y} := \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}.$$

Die Dichte dieser Verteilung bezeichnen wir mit $p_{x|y}$.

Beweis: Einen Beweis dieser Aussage finden Sie in [2] auf den Seiten 85–87.



Visualisierung: Bedingte Normalverteilung





Abbildung: Links: Zweidimensionale Normalverteilung. Rechts: Bedingte Verteilung in rot. Siehe [1], Seite 82.

Aufgabe: Bedingte Normalverteilung

1.19 Aufgabe: Es seien X_1 und X_2 zwei Zufallsvariablen mit $(X_1, X_2)^\top \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Hierbei sind die Parameter gegeben durch $\boldsymbol{\mu} := (0, 2)^\top \in \mathbb{R}^2$ und

$$\boldsymbol{\Sigma} := \begin{pmatrix} 0.3 & -1 \\ -1 & 5 \end{pmatrix} \in \mathbb{R}^{2 \times 2}.$$

Bestimmen Sie die bedingte Dichte $p_{X_1|X_2}(x_1 | x_2 = -1)$. Benutzen Sie hierzu die Formeln aus Satz 1.18.

Normale Randverteilung

1.20 Satz: Erneut betrachten wir das Modell der partitionierten Normalverteilung aus Definition 1.17. Dann sind auch die Randverteilungen von $\mathbf{x}$ und $\mathbf{y}$ normalverteilt. Es gilt genauer

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

Die Dichten der Randverteilung bezeichnen wir mit n_x und n_y .

Beweis: Man erhält dieses Ergebnis durch **Marginalisierung** der Verbunddichte, d. h. wir integrieren über alle Variablen, die uns nicht interessieren. Für die Randverteilung von $\mathbf{x}$ gilt zum Beispiel

$$n_x(\mathbf{x}) = \int n_{x,y}(\mathbf{x}, \mathbf{y}) d\mathbf{y}.$$

Einen ausführlichen Beweis finden Sie in [2] auf den Seiten 88–89.

□

Visualisierung: Normale Randverteilung





Abbildung: Links: Zweidimensionale Normalverteilung. Rechts: Randverteilung für x_a in blau. Siehe [1], Seite 82.

Aufgabe: Normale Randverteilung

1.21 Aufgabe: Betrachten Sie erneut die Situation aus Aufgabe 1.19.

Wie lautet die Dichte der Randverteilung $p_{X_1}(x_1)$?

Satz von Bayes für Normalverteilungen

1.22 Satz: Es seien x und y Zufallsvektoren, sodass gilt

$$x \sim \mathcal{N}(\mu, \Sigma) \quad \text{und} \quad y | x \sim \mathcal{N}(Ax + b, \Lambda).$$

Dann gilt für die Dichten der Verteilungen von y und $x | y$

$$y \sim \mathcal{N}(A\mu + b, A\Sigma A^\top + \Lambda)$$

$$x | y \sim \mathcal{N}(\Gamma[\Sigma^{-1}\mu + A^\top \Lambda^{-1}(y - b)], \Gamma).$$

Hierbei ist $\Gamma := (\Sigma^{-1} + A^\top \Lambda^{-1} A)^{-1}$.

Beweis: Einen Beweis dieser Aussage finden Sie in [2] auf den Seiten 90–93.

□

Maximum-Likelihood Methode

- Im Folgenden sei ein Beobachtungsvektor $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top$ bestehend aus N *unabhängig und identisch verteilten* (Englisch: *independent and identically distributed* - i.i.d.) Datenpunkten gegeben.
- Wir möchten Aussagen über die Parameter $\boldsymbol{\theta} := (\theta_1, \theta_2, \dots, \theta_M)^\top$ der zugrundeliegenden Verteilung machen.
- Dies erledigen wir durch eine Punktschätzung des Parametervektors $\boldsymbol{\theta}$. Den Schätzer für $\boldsymbol{\theta}$ bezeichnen wir mit $\hat{\boldsymbol{\theta}}$.
- Eine der am häufigsten angewendete Methode ist die **Maximum-Likelihood Methode**, die wir im Folgenden näher beleuchten werden.

(Log-)Likelihood Funktion

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für den Parametervektor θ maximiert die Likelihood Funktion.

1.23 Definition: Es sei $p(\mathbf{x}; \theta)$ die Dichte eines Zufallsvektors $\mathbf{x} \in \mathbb{R}^N$, welche durch den Parametervektor $\theta \in \Theta$ parametrisiert wird. Die **Likelihood Funktion** $L : \Theta \rightarrow \mathbb{R}$ ist dann definiert als

$$L(\theta) := p(\mathbf{x}; \theta) = p(x_1, x_2, \dots, x_N; \theta).$$

Häufig ist es einfacher, die **Log-Likelihood Funktion** $l(\theta) := \ln p(\mathbf{x}; \theta)$ zu betrachten. Wir definieren $\hat{\theta}_{ML} := \arg \max_{\theta} l(\theta)$.

Bemerkung: Der Schätzer $\hat{\theta}_{ML}$ maximiert sowohl L als auch l . (Warum?)

(Log-)Likelihood Funktion (Forts.)

- Im Allgemeinen kann es schwer sein, die Likelihood Funktion zu bestimmen (*vor allem wenn die Beobachtungen voneinander abhängen*).
- Die Annahme der **Unabhängigkeit der Beobachtungen** vereinfacht dies maßgeblich, denn

$$\begin{aligned} L(\theta) &= p(x_1, x_2, \dots, x_N; \theta) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot \dots \cdot p(x_N; \theta) \\ &= \prod_{n=1}^N p(x_n; \theta). \end{aligned}$$

- Für die Log-Likelihood Funktion ergibt sich durch Anwendung der Logarithmengesetze

$$l(\theta) = \ln \prod_{n=1}^N p(x_n; \theta) = \sum_{n=1}^N \ln p(x_n; \theta).$$

Maximum-Likelihood Gleichung

- Falls die Likelihood Funktion differenzierbar ist, so erfüllt der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ notwendig die **Likelihood Gleichung**

$$\left. \frac{\partial}{\partial \theta} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = \mathbf{0}.$$

- Diese sagt aus, dass $\hat{\theta}_{ML}$ ein *stationärer Punkt der (Log-)Likelihood Funktion* sein muss.
- Es handelt sich dabei um ein System von M , im Allgemeinen nicht-linearen, Gleichungen der Form

$$\left. \frac{\partial}{\partial \theta_j} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = 0 \quad j = 1, 2, \dots, M.$$

Achtung: Es muss noch überprüft werden, ob $\hat{\theta}_{ML}$ tatsächlich ein Maximum darstellt.

Beispiel I: Binomialverteilung

1.24 Satz: Es sei die binomialverteilte Zufallsvariable X (Anzahl der Erfolge) und der Stichprobenumfang N gegeben. Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für die unbekannte Erfolgswahrscheinlichkeit $\theta \in (0, 1)$ lautet $\hat{\theta}_{ML} = \frac{k}{N}$, wobei k die Anzahl der beobachteten Erfolge in der Stichprobe ist.

Beweis: Die Likelihood Funktion ist gegeben durch $L(\theta) = \binom{N}{k} \cdot \theta^k \cdot (1 - \theta)^{N-k}$. Wir wenden den Logarithmus an und erhalten die Log-Likelihood Funktion

$$l(\theta) = \ln \binom{N}{k} + k \cdot \ln \theta + (N - k) \cdot \ln(1 - \theta).$$

Diese leiten wir nach θ ab und setzen sie Null. Auflösen nach θ ergibt schließlich

$$\frac{d}{d\theta} l(\theta) = \frac{k}{\theta} - \frac{N - k}{1 - \theta} \stackrel{!}{=} 0 \iff \hat{\theta}_{ML} = \frac{k}{N}.$$

Wir prüfen noch das Vorzeichen der zweiten Ableitung. Es ist $\frac{d^2}{d\theta^2} l(\theta) = -\frac{k}{\theta^2} - \frac{N-k}{(1-\theta)^2} < 0 \forall \theta \in (0, 1)$, sodass $\hat{\theta}_{ML}$ tatsächlich ein Maximum ist. Es handelt sich sogar um ein global eindeutiges Maximum. □

Beispiel II: Normalverteilung

1.25 Satz: Es seien $\mathbf{x} = (x_1, x_2, \dots, x_N)^\top$ *unabhängig und identisch normalverteilte* Beobachtungen mit unbekanntem Erwartungswert $\mu \in \mathbb{R}$ und unbekannter Varianz $\sigma^2 > 0$. Der Parametervektor θ ist in diesem Fall zweielementig und gegeben durch $\theta := (\mu, \sigma^2)^\top$.

Die Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$ für die unbekannten Parameter μ und σ^2 werden in diesem Fall bestimmt mittels

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N x_n \quad \text{und} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2.$$

Beweis: Die Dichte der Produktverteilung lautet aufgrund der Unabhängigkeit der Beobachtungen

$$p(\mathbf{x}; \mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \frac{1}{\sigma^N} \cdot \exp\left(-\frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}\right).$$

Aufgrund der auftretenden Exponentialverteilung bietet sich die Betrachtung der Log-Likelihood Funktion an. Wir erhalten

$$l(\mu, \sigma^2) = -\frac{N}{2} \cdot \ln(2\pi) - N \ln(\sigma) - \frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}.$$

Nun berechnen wir die partiellen Ableitungen von l nach μ und σ^2 . Es ist

$$\frac{\partial}{\partial \mu} l(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) \quad \text{und} \quad \frac{\partial}{\partial \sigma^2} l(\mu, \sigma^2) = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=1}^N (x_n - \mu)^2.$$

Durch Nullsetzen und auflösen erhalten wir die im Satz angegebenen Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$. Es bleibt noch zu zeigen, dass es sich tatsächlich um ein Maximum handelt. Man rechnet nach, dass die Hesse-Matrix von $l(\mu, \sigma^2)$ and der Stelle $(\hat{\mu}_{ML}, \hat{\sigma}_{ML}^2)$ gegeben ist durch

$$\nabla^2 l(\mu, \sigma^2) = \begin{pmatrix} -\frac{N}{\hat{\sigma}_{ML}^2} & 0 \\ 0 & -\frac{N}{(\hat{\sigma}_{ML}^2)^2} \end{pmatrix}.$$

Diese Matrix ist negativ definit, weshalb wir tatsächlich ein Maximum gefunden haben. □

Erwartungstreue Schätzer

Wir definieren den Begriff der Erwartungstreue:

1.26 Definition: Wir nennen einen Schätzer $\hat{\theta}$ **erwartungstreu**, falls $\mathbb{E}[\hat{\theta}] = \theta$ gilt.

- Der Schätzer $\hat{\mu}_{ML}$ ist erwartungstreu für den Erwartungswert μ im Normalverteilungsmodell

Beweis: Es gilt

$$\mathbb{E}[\hat{\mu}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \cdot N \cdot \mu = \mu.$$

□

- Demgegenüber ist $\hat{\sigma}_{ML}^2$ **nicht** erwartungstreu. Man kann diesen Schätzer jedoch durch eine geeignete Transformation zu einem erwartungstreuen Schätzer machen. Dies führt auf die **empirische Varianz** $\frac{N}{N-1} \hat{\sigma}_{ML}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2$.

Aufgabe zur Maximum-Likelihood Schätzung

1.27 Aufgabe: Gegeben seien die N Beobachtungen $x_1, x_2, \dots, x_N$, wobei $x_n \in \mathbb{N}$, $n = 1, 2, \dots, N$. Sie legen den Daten eine Poisson-Verteilung zugrunde. Diese hat die Dichte

$$p(x) := e^{-\lambda} \cdot \frac{\lambda^x}{x!}.$$

- 1 Bestimmen Sie den Maximum-Likelihood Schätzer $\hat{\lambda}_{ML}$ für die Poisson-Verteilung. Vergessen Sie dabei nicht zu überprüfen, ob es sich tatsächlich um ein Maximum handelt.
- 2 Prüfen Sie den Schätzer auf Erwartungstreue.

Erwartete quadratische Abweichung (MSE)

Ein weiteres Qualitätsmerkmal eines Schätzers $\hat{\theta}$ ist seine erwartete quadratische Abweichung vom wahren Parameter θ .

1.28 Definition: Die **erwartete quadratische Abweichung** von $\hat{\theta}$ zu θ ist

$$\text{MSE}[\hat{\theta}, \theta] = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Die $\text{MSE}[\hat{\theta}, \theta]$ reduziert sich für erwartungstreue Schätzer $\hat{\theta}$ auf die Varianz $\mathbb{V}[\hat{\theta}]$.

Beweis: Man rechnet nach, dass $\text{MSE}[\hat{\theta}, \theta] = \mathbb{V}[\hat{\theta}] + (\mathbb{E}[\hat{\theta}] - \theta)^2$ gilt (multipliziere hierzu aus und nutze die Linearität des Erwartungswerts). Der zweite Summand (Quadrat der Verzerrung/Bias) verschwindet aber für erwartungstreue Schätzer, da $\mathbb{E}[\hat{\theta}] = \theta$ gilt. Es folgt die Behauptung. □

Maximum-Aposteriori Schätzer (MAP)

- ML Schätzer laufen Gefahr, sich übermäßig stark an die Daten anzupassen (**Overfitting**).
- Wir erweitern daher das Konzept der ML Schätzung, indem wir zusätzlich eine *Apriori-Verteilung* für die zu schätzenden Parameter mit einbeziehen.
- Wir nutzen den Satz von Bayes, um damit zusammen mit der Likelihood eine *Aposteriori-Verteilung* über die Parameter zu erhalten.
- Ein Schätzer $\hat{\theta}_{MAP}$ heißt **Maximum-Aposteriori Schätzer** für den Parameter θ , falls dieser die Aposteriori-Wahrscheinlichkeit maximiert.

Binäre Variablen

- Wir betrachten eine binäre Zufallsvariable $X \in \{0, 1\}$, z. B. das Werfen einer (unfairen) Münze, wobei $X = 1$ 'Kopf' und $X = 0$ 'Zahl' bedeutet.
- Die Zufallsvariable X ist damit **Bernoulli-verteilt** mit der Dichte

$$p_X(k) := \mu^k \cdot (1 - \mu)^{1-k}. \quad (1.1)$$

- Es gilt

$$\mathbb{E}[X] = \mu$$

$$\mathbb{V}[X] = \mu \cdot (1 - \mu).$$

1.29 Aufgabe: Beweisen Sie die Aussagen $\mathbb{E}[X] = \mu$ und $\mathbb{V}[X] = \mu \cdot (1 - \mu)$.

Maximum Likelihood für die Bernoulli-Verteilung

- Wir gehen nun von N unabhängigen Bernoulli-verteilten Zufallsvariablen $X_1, X_2, \dots, X_N$ aus.
- Dann ist die Likelihood Funktion für den Parameter μ gegeben durch

$$L(\mu) = \prod_{n=1}^N p_{X_n}(k_n) = \prod_{n=1}^N \mu^{k_n} \cdot (1 - \mu)^{1-k_n}.$$

- Hieraus ergibt sich die Log-Likelihood Funktion

$$l(\mu) = \sum_{n=1}^N \ln p_{X_n}(k_n) = \sum_{n=1}^N [k_n \ln \mu + (1 - k_n) \cdot \ln(1 - \mu)] = \ln \mu \sum_{n=1}^N k_n + \ln(1 - \mu) \left(N - \sum_{n=1}^N k_n \right).$$

Bemerkung: Die Log-Likelihood Funktion hängt von den Beobachtungen nur über die Statistik $Y := \sum_{n=1}^N X_n$ ab. Man nennt Y daher eine **suffiziente Statistik**.

Maximum Likelihood für die Bernoulli-Verteilung

- Leiten wir $l(\mu)$ nach μ ab und setzen Null, so erhalten wir den Maximum-Likelihood Schätzer als arithmetisches Mittel der Beobachtungen

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N k_n.$$

- Schreiben wir für die Anzahl der Erfolge (Kopf) $m := \sum_{n=1}^N k_n$, so ist $\hat{\mu}_{ML} = \frac{m}{N}$.
- Werfen wir die Münze drei Mal und erhalten jedes Mal Kopf, so wäre $\hat{\mu}_{ML} = 1$ (**Overfitting**).
- Die Zufallsvariable $Y := X_1 + X_2 + \dots + X_N$ ist aufgrund der Unabhängigkeit der X_n ($1 \leq n \leq N$) **binomial-verteilt**, sodass gilt

$$\mathbb{P}(Y = m) := \binom{N}{m} \cdot \mu^m \cdot (1 - \mu)^{N-m}.$$

Beta-Verteilung

Um die Overfitting-Problematik zu adressieren, führen wir einen Beta-verteilten Prior ein.

1.30 Definition: Es sei X eine **Beta-verteilte** Zufallsvariable, in Notation $X \sim \beta_{a,b}$, mit den Parametern $a, b > 0$. Die Dichte der Verteilung ist gegeben durch

$$p_X(\xi) = \frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi).$$

Bemerkung: $\Gamma(x)$ ist hierbei die **Gamma-Funktion**. Es gilt $\Gamma(x) := \int_0^\infty u^{x-1} e^{-u} du$. Mithilfe partieller Integration kann man den Zusammenhang $\Gamma(x+1) = x \cdot \Gamma(x)$ zeigen. Außerdem gilt $\Gamma(1) = 1$. Daraus folgt $\Gamma(n+1) = n!$ für $n \in \mathbb{N}$. Somit ist die Gamma-Funktion die kontinuierliche Fortsetzung der Fakultäts-Funktion.

Visualisierung: Beta-Verteilung





Abbildung: Beta-Verteilungen für einige Parameter a , b . Siehe [2], Seite 72.

Visualisierung: Beta-Verteilung (Forts.)





Abbildung: Beta-Verteilungen für einige Parameter a , b . Siehe [2], Seite 72.

Bestimmung des Posteriors

- Um den Posterior zu erhalten, multiplizieren wir den Beta-verteilten Prior mit der binomial-verteilten Likelihood.
- Ignorieren wir alle von μ unabhängigen Terme, so erhalten wir für den Posterior mit $l := N - m$ (Anzahl Misserfolge)

$$p(\mu \mid m, l; a, b) \propto \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1}. \quad (1.2)$$

- Da Prior und Likelihood *dieselbe funktionale Form* haben, ist *auch der Posterior wieder Beta-verteilt*, wobei sich der Normierungsfaktor durch Vergleich mit der Dichte aus 1.30 ergibt

$$p(\mu \mid m, l; a, b) = \frac{\Gamma(m + a + l + b)}{\Gamma(m + a) \cdot \Gamma(l + b)} \cdot \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1} \quad (1.3)$$

Wir gehen also vom Prior mit der Dichte $\beta_{a,b}$ über zum Posterior mit der Dichte $\beta_{a+m,b+l}$.

Visualisierung: Bestimmung des Posteriors




Abbildung: Ein Schritt der Bayes'schen Inferenz. Der Prior ist gegeben durch eine Beta-Verteilung mit $a = 2 = b$. Die Likelihood Funktion ist hingegen gegeben durch eine Binomial-Verteilung mit $N = m = 1$. Der Posterior ist damit wieder Beta-verteilt mit den Parametern $a = 3$ und $b = 2$. Siehe [2], Seite 73.

Konjugierte Verteilungen

1.31 Definition: Ein Prior heißt **konjugiert** zur Likelihood, wenn der daraus berechnete Posterior exakt dieselbe funktionale Form wie der Prior annimmt.

- **Vorteil:** Der Posterior kann durch Aufdatierung der Parameter des Priors einfach bestimmt werden.

- Wichtige Paare:

Binomial-Verteilung

Beta-Verteilung

Poisson-Verteilung

Gamma-Verteilung

Normalverteilung

Normalverteilung (μ zu schätzen, Varianz σ^2 bekannt)

Aufgabe: Konjugierte Verteilungen

1.32 Aufgabe: Weisen Sie nach, dass die Gamma-Verteilung der konjugierte Prior zur Likelihood der Poisson-Verteilung für den Parameter λ ist.

Hinweis: Schreiben Sie hierzu die Likelihood-Funktion und den Prior für λ auf. Ignorieren Sie alle Terme, die nicht von λ abhängen. Wenden Sie anschließend den Satz von Bayes an, um den Posterior zu erhalten. Können Sie diesen in dieselbe Form wie den Prior bringen?

Bestimmung des MAP-Schätzers

- Der MAP-Schätzer *maximiert den Posterior* (1.3).
- Der **Log-Posterior** lautet

$$\ln p(\mu \mid m, l; a, b) = (m + a - 1) \ln \mu + (l + b - 1) \ln(1 - \mu) + \text{const.}$$

- Ableiten nach μ , Nullsetzen und Auflösen nach μ ergibt den MAP-Schätzer

$$\hat{\mu}_{MAP} = \frac{m + a - 1}{m + a + l + b - 2}.$$

- Vergleich mit dem ML-Schätzer

$$\hat{\mu}_{ML} = \frac{m}{m + l}.$$

Bayes'sche Inferenz

- Wir haben N Münzwürfe mit m Erfolgen (Kopf) und l Misserfolgen (Zahl) beobachtet.
- Unser Ziel ist es nun, den Ausgang des nächsten Wurfs vorherzusagen.
- Hierzu werden wir die **Prädiktivverteilung (Vorhersageverteilung)** aus

$$\begin{aligned}\mathbb{P}(X_{N+1} = 1 \mid m, l) &= \int_0^1 \mathbb{P}(X_{N+1} = 1 \mid \mu) \cdot p(\mu \mid m, l) \, d\mu = \int_0^1 \mu \cdot p(\mu \mid m, l) \, d\mu \\ &= \mathbb{E}[\mu \mid m, l].\end{aligned}$$

- Der Erwartungswert des Posteriors können wir nun aus (1.3) ablesen, wir erhalten

$$\mathbb{P}(X_{N+1} = 1 \mid m, l) = \frac{m + a}{m + a + l + b}.$$

Kapitel

② Regression

Wiederholung: Lineare Regression

Probabilistische Regression

Maximum A posteriori (MAP) Regression

Bayes'sche Regression

Lineare Regression

Wir wiederholen die wichtigsten Aussagen zur **linearen Regression**:

- Wir betrachten einen Datensatz bestehend aus N Featurevektoren $\phi(x_n) \in \mathbb{R}^M$, $n = 1, 2, \dots, N$.
- Die Funktion ϕ ist hierbei eine **Basisfunktion**, z. B. die polynomiale Basis.
- Um den **Bias** zu modellieren, vereinbaren wir, dass stets $\phi_1(x) = 1$ gilt.
- Des Weiteren ist jeder Vektor $\phi(x_n) \in \mathbb{R}^M$ mit einem zugehörigen Label $y_n \in \mathbb{R}$ versehen, $n = 1, 2, \dots, N$.
- Das lineare Regressionsmodell hat die Form

$$h(x; \theta) = \sum_{m=1}^M \theta_m \phi_m(x) = \theta^\top \phi(x).$$

Design Matrix

- Wir fassen die N Featurevektoren $\phi(x_n) \in \mathbb{R}^M$ zeilenweise zu der Matrix Φ zusammen.
- Diese hat damit die allgemeine Form

$$\Phi := \begin{pmatrix} \text{---} & \phi(x_1) & \text{---} \\ \text{---} & \phi(x_2) & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \phi(x_N) & \text{---} \end{pmatrix} \in \mathbb{R}^{N \times M}.$$

- Die erste Spalte ist hierbei konstant 1 (*wegen der Dummy-Komponente für den Bias*).
- Wir nennen diese Matrix die **Design Matrix**.
- Analog sammeln wir alle Labels in einem Vektor

$$\mathbf{y} := (y_1, y_2, \dots, y_N)^\top \in \mathbb{R}^N.$$

Methode der kleinsten Quadrate

- Der Vektor $\theta \in \mathbb{R}^M$ beinhaltet die **Modellparameter**.
- Diese möchten wir so wählen, dass unser Modell die Daten möglichst gut erklärt
- Die Abweichung der Vorhersagen zu den Trainingsdaten sollte also *möglichst klein* sein.

2.1 Definition: Mit den obigen Definitionen ist der **Least-Squares-Fehler** gegeben durch

$$J_{\text{LS}}(\theta) := \frac{1}{2N} \|\Phi\theta - y\|^2 = \frac{1}{2N} (\Phi\theta - y)^\top (\Phi\theta - y).$$

Bemerkung: Der Vektor $\Phi\theta \in \mathbb{R}^N$ beinhaltet die **Modellvorhersagen**, wenn man dem Modell die Parameter θ zugrunde legt. J_{LS} misst also die **mittlere quadratische Abweichung** der Vorhersagen zu den wahren Werten y .

Minimierung der Fehlerfunktion

Unser Ziel ist die Minimierung von J_{LS} . Hierzu schreiben J_{LS} unter Ausnutzung der Transpositionsregeln $(A + B)^T = A^T + B^T$ und $(AB)^T = B^T A^T$ zunächst um:

$$\begin{aligned} J_{LS}(\theta) &= \frac{1}{2N} \|\Phi\theta - y\|^2 = \frac{1}{2N} (\Phi\theta - y)^T (\Phi\theta - y) \\ &= \frac{1}{2N} ((\Phi\theta)^T - y^T) (\Phi\theta - y) \\ &= \frac{1}{2N} ((\Phi\theta)^T \Phi\theta - (\Phi\theta)^T y - y^T (\Phi\theta) + y^T y) \\ &= \frac{1}{2N} (\theta^T \Phi^T \Phi\theta - 2(\Phi\theta)^T y + y^T y) \\ &= \frac{1}{2N} (\theta^T \Phi^T \Phi\theta - 2\theta^T \Phi^T y + y^T y) \end{aligned}$$

Minimierung der Fehlerfunktion (Forts.)

Um einen stationären Punkt zu finden, müssen wir J_{LS} nach θ ableiten und Null setzen.

- Es ist $\frac{\partial}{\partial \theta} \theta^\top \Phi^\top \Phi \theta = 2\Phi^\top \Phi \theta$, da $\Phi^\top \Phi$ symmetrisch ist.

Beweis: Wir nutzen die Transpositionsregeln und erhalten $(\Phi^\top \Phi)^\top = \Phi^\top (\Phi^\top)^\top = \Phi^\top \Phi$, woraus die Symmetrie folgt. $\square$

- Es ist $\frac{\partial}{\partial \theta} (-2\theta^\top \Phi^\top y) = -2\Phi^\top y$ und $\frac{\partial}{\partial \theta} y^\top y = 0$.
- Der Gradient der Fehlerfunktion J_{LS} ist damit gegeben durch

$$\frac{\partial}{\partial \theta} J_{LS}(\theta) = \frac{1}{2N} (2\Phi^\top \Phi \theta - 2\Phi^\top y) \propto \Phi^\top \Phi \theta - \Phi^\top y = \Phi^\top (\Phi \theta - y)$$

Bemerkung: Man beachte den Zusammenhang zwischen dem Gradienten und dem Vorhersagefehler: Je größer der Fehler, desto größer auch der Gradient!

Minimierung der Fehlerfunktion (Forts.)

Wir setzen den Gradienten Null und lösen nach θ auf:

$$\frac{\partial}{\partial \theta} J_{\text{LS}}(\theta) \stackrel{!}{=} \mathbf{0} \quad \Longleftrightarrow \quad \Phi^{\top} \Phi \theta - \Phi^{\top} y = \mathbf{0}$$

$$\Longleftrightarrow \quad \Phi^{\top} \Phi \theta = \Phi^{\top} y$$

$$\Longleftrightarrow \quad \theta^{\star} = (\Phi^{\top} \Phi)^{-1} \Phi^{\top} y$$

Bemerkung: Wir haben damit einen stationären Punkt von J_{LS} gefunden. Allerdings wissen wir noch nicht, ob es sich tatsächlich um ein Minimum handelt. Außerdem sind wir hier etwas naiv von der Existenz der Inversen $(\Phi^{\top} \Phi)^{-1}$ ausgegangen. Existiert diese Matrix immer?

Mit diesen Fragen beschäftigen wir uns im Folgenden.

Ein paar nützliche Aussagen

2.2 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ ist $A^\top A$ positiv semidefinit.

Beweis: Für alle $z \in \mathbb{R}^M$ gilt $z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 \geq 0$, woraus die Behauptung folgt. □

2.3 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ mit *vollem Spaltenrang* ist $A^\top A$ positiv definit.

Beweis: Da A vollen Spaltenrang hat, sind die Spaltenvektoren linear unabhängig. Daher ist Az für alle $z \in \mathbb{R}^M \setminus \{0\}$ eine nicht-triviale Linearkombination der Spalten von A . Folglich gilt $Az \neq 0$ und wir erhalten

$$z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 > 0,$$

woraus die Behauptung folgt. □

Ein paar nützliche Aussagen (Forts.)

2.4 Satz: Wenn $A \in \mathbb{R}^{N \times N}$ positiv definit ist, so ist A auch invertierbar.

Beweis: Wir nehmen an, A sei nicht invertierbar. Dann sind die Spalten von A linear abhängig und es existiert ein $z \in \mathbb{R}^N \setminus \{0\}$ mit $Az = 0$. Daraus folgt aber

$$z^\top Az = z^\top 0 = 0,$$

was der vorausgesetzten positiven Definitheit von A widerspricht. Es muss A folglich invertierbar sein. □

Handelt es sich nun um ein Minimum?

Um diese Frage zu klären, berechnen wir die **Hesse-Matrix** von J_{LS} und untersuchen, ob die Matrix im stationären Punkt θ^* positiv definit ist.

- Man rechnet nach, dass die Hesse-Matrix von J_{LS} gegeben ist durch

$$\frac{\partial^2}{\partial \theta \partial \theta} J_{LS}(\theta) = \Phi^T \Phi.$$

- Mit Satz 2.3 ist diese Matrix positiv definit für alle θ , falls Φ vollen Spaltenrang hat, d. h. *die Features müssen linear unabhängig sein*. In diesem Fall handelt es sich bei θ^* tatsächlich um ein Minimum.
- Unter derselben Voraussetzung haben wir damit sogar die **Konvexität** von J_{LS} bewiesen (**warum?**), sodass das Minimum *global und eindeutig* ist.

Und wie sieht es nun mit der Existenz der Inversen aus?

- Mit Satz 2.4 ist die Existenz der Inversen sichergestellt, wenn $\Phi^\top \Phi$ positiv definit ist, was wiederum aus der linearen Unabhängigkeit der Features folgt (Satz 2.3).
- **Achtung:** Bei der numerischen Berechnung der Inversen auf dem Computer kann es trotzdem zu Problemen kommen.
- Es ist *numerisch stabiler*, die Inverse nicht explizit zu berechnen, sondern stattdessen das folgende lineare Gleichungssystem in θ zu lösen

$$\Phi^\top \Phi \theta = \Phi^\top y.$$

- Alternativ kann das Optimierungsproblem mit dem **Gradientenabstiegsverfahren** gelöst werden.
- Iteriere hierzu die Regel:

$$\theta_{t+1} \leftarrow \theta_t - \alpha \Phi^\top (\Phi \theta_t - y). \quad (2.1)$$

Normalengleichungen

Wir fassen unsere Ergebnisse zusammen:

2.5 Satz: Die Design Matrix $\Phi \in \mathbb{R}^{N \times M}$ des Regressionsproblems habe vollen Spaltenrang, d. h. die Features seien linear unabhängig. Dann existiert die Inverse $(\Phi^\top \Phi)^{-1}$ und

$$\theta^\star = (\Phi^\top \Phi)^{-1} \Phi^\top y$$

ist das eindeutige globale Minimum von J_{LS} . Die Gleichungen $\Phi^\top \Phi \theta = \Phi^\top y$ bezeichnet man als **Normalengleichungen**.

Eine probabilistische Sicht

Annahme 1: Die Zielwerte $y \in \mathbb{R}$ und die Features $\phi(x) \in \mathbb{R}^M$ hängen über die Gleichung

$$y = \theta^\top \phi(x) + \varepsilon \quad (2.2)$$

zusammen. Der Fehlerterm $\varepsilon \in \mathbb{R}$ repräsentiert nicht modellierte Effekte oder Datenrauschen.

Annahme 2: Für den Fehlerterm gilt $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Bemerkung: Der Zielwert y kann damit als Zufallsvariable aufgefasst werden, für die gilt

$$y \mid x \sim \mathcal{N}(\theta^\top \phi(x), \sigma^2). \quad (2.3)$$

Visualisierung: Probabilistische Regression




Abbildung: Visualisierung der probabilistischen Regression. x_0 ist hierbei ein Testpunkt.

Maximum-Likelihood Regression

- Wir betrachten wieder einen Datensatz $\{(\mathbf{x}_n, y_n)\}_{n=1}^N$ bestehend aus N Trainingsbeispielen.
- Die Likelihood Funktion des Modells ist gegeben durch

$$\begin{aligned} L(\boldsymbol{\theta}, \sigma^2) &= p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N \boldsymbol{n}(y_n \mid \mathbf{x}_n; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{1}{2\sigma^2} \left(y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n)\right)^2\right) \end{aligned} \tag{2.4}$$

Maximum-Likelihood Regression (Forts.)

- Durch Logarithmieren von (2.4) erhalten wir die Log-Likelihood Funktion

$$\begin{aligned} l(\boldsymbol{\theta}, \sigma^2) &:= \ln p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \end{aligned} \quad (2.5)$$

- Aus (2.5) wird ersichtlich, dass der Least-Squares-Fehler minimiert werden muss, um die Likelihood in $\boldsymbol{\theta}$ zu maximieren.
- Die Lösung für $\boldsymbol{\theta}$ ist dieselbe wie in Satz 2.5, zusätzlich kann aber die *globale Unsicherheit* des Modells quantifiziert werden

$$\hat{\boldsymbol{\theta}}_{ML} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (y_n - \hat{\boldsymbol{\theta}}_{ML}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \quad (2.6)$$

Visualisierung: Maximum-Likelihood Regression




Abbildung: Die Maximum Likelihood Lösung erlaubt zusätzlich die Quantifizierung der (globalen) Unsicherheit (Varianz) des Modells. Die Varianz wird dabei als grauer Korridor um die Regressionsgerade dargestellt.

Berücksichtigung einer Apriori-Verteilung

- Die Maximum-Likelihood Lösung ist **anfällig für Overfitting**.
- Eine Möglichkeit der **Regularisierung** ist die Verwendung einer **Apriori-Verteilung** (*Prior*).
- Für den Prior des Parametervektors θ benutzen wir die Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, b^2 \mathbf{I}). \quad (2.7)$$

- Hierbei kontrolliert $b > 0$ die Varianz der Parameter.
- Es handelt sich hierbei um eine **isotropische Normalverteilung** (*rotationsinvariant*).
- Der Prior kann benutzt werden, um Vorwissen zu berücksichtigen: Er kodiert, welche Parameterwerte apriori plausibel sind.
- Häufig ist der Prior jedoch **nicht informativ** (z. B. Gleichverteilung) und wird eher aus mathematischer Bequemlichkeit gewählt.

Bestimmung des Posteriors

- Um den Posterior zu bestimmen, benutzen wir den **Satz von Bayes**

$$p(\boldsymbol{\theta} \mid \boldsymbol{X}, \boldsymbol{y}) = \frac{\overbrace{p(\boldsymbol{y} \mid \boldsymbol{X}, \boldsymbol{\theta}; \sigma^2)}^{\text{Likelihood}} \cdot \overbrace{p(\boldsymbol{\theta}; b^2)}^{\text{Prior}}}{p(\boldsymbol{y} \mid \boldsymbol{X})} \quad (2.8)$$
$$\propto p(\boldsymbol{y} \mid \boldsymbol{X}, \boldsymbol{\theta}; \sigma^2) \cdot p(\boldsymbol{\theta}; b^2).$$

- Wir betrachten $\boldsymbol{\theta}$ nun als (vektorwertige) Zufallsvariable (*sie steht nun vor dem Semikolon*).
- Bisher haben wir nur die Likelihood maximiert, nun berücksichtigen wir auch den Prior $p(\boldsymbol{\theta}; b^2)$.

Frage: Warum ignorieren wir den Nenner in (2.8)?

Optimierung des Posteriors

- Anstelle der Log-Likelihood maximieren wir nun den **Log-Posterior**.
- Diesen erhalten wir aus (2.8) durch Logarithmieren

$$\ln p(\boldsymbol{\theta} \mid X, \mathbf{y}) = \ln p(\mathbf{y} \mid X, \boldsymbol{\theta}; \sigma^2) + \ln p(\boldsymbol{\theta}; b^2) + \text{const.} \quad (2.9)$$

- Die Konstante 'const' enthält alle Terme, die nicht von $\boldsymbol{\theta}$ abhängen.
- Die **MAP-Schätzung** (*Maximum A posteriori*) ist ein Kompromiss zwischen dem datenunabhängigen Prior und der datenabhängigen Likelihood.
- Wir betrachten im Folgenden den **negativen Log-Posterior** indem wir (2.9) negieren und erhalten für den MAP-Schätzer

$$\hat{\boldsymbol{\theta}}_{MAP} := \arg \min_{\boldsymbol{\theta}} \left\{ -\ln p(\mathbf{y} \mid X, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) \right\}. \quad (2.10)$$

Optimierung des Posteriors (Forts.)

Unter Verwendung der Transpositionsregeln schreiben wir (2.10) um zu

$$\begin{aligned} -\ln p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) &= -\ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta})^\top (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \mathbf{y} + (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - 2\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \mathbf{y}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const}. \end{aligned} \tag{2.11}$$

2.6 Aufgabe: Überlegen Sie sich, wie man in (2.11) von Zeile 1 auf Zeile 2 kommt.

Aufgabe: Berechnung des Gradienten

2.7 Aufgabe: Jetzt sind Sie an der Reihe:

- 1 Berechnen Sie den Gradienten des negativen Log-Posteriors $-\ln p(\boldsymbol{\theta} \mid \boldsymbol{X}, \boldsymbol{y})$. Benutzen Sie hierzu die Form aus (2.11).
- 2 Setzen Sie den Gradienten anschließend Null und lösen Sie nach $\boldsymbol{\theta}$ auf.
- 3 Die Lösungsformel für $\hat{\boldsymbol{\theta}}_{MAP}$ fordert die Invertierung der Matrix $\boldsymbol{\Phi}^\top \boldsymbol{\Phi} + \frac{\sigma^2}{b^2} \boldsymbol{I}$. Zeigen Sie, dass diese Inverse (zumindest *analytisch*) immer existiert.

Vergleich der MLE und MAP Lösungen

MLE-Schätzer:

$$\hat{\theta}_{ML} = (\Phi^T \Phi)^{-1} \Phi^T y \quad (2.12)$$

MAP-Schätzer:

$$\hat{\theta}_{MAP} = \left(\Phi^T \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^T y \quad (2.13)$$

Bemerkung: Setzt man $\lambda := \sigma^2/b^2$, so entspricht die MAP-Schätzung der Ridge-Regression.

Visualisierung: Vergleich der MLE und MAP Lösungen




Abbildung: Die MLE-Lösung (lila) und die MAP-Lösung (blau) im Vergleich.

Bayes'sche Regression

- Wir haben gesehen, dass MLE-Schätzungen zu **Overfitting** neigen.
- Für die MAP-Schätzung haben wir deshalb zusätzlich einen Prior $p(\theta)$ berücksichtigt, welcher der **Regularisierung** dient.

Die **Bayes'sche Regression** erweitert diesen Ansatz folgendermaßen:

- Wieder benutzen wir einen Prior $p(\theta)$ für die Modellparameter θ .
- **Aber:** Wir berechnen diesmal keine Punktschätzung der Parameter.
- Stattdessen nutzen wir die *volle Posterior-Verteilung* aus, um Vorhersagen zu machen.
- Hierzu berechnet man die **Predictive Distribution**, die sämtliche Parameterwerte mit ihren zugehörigen Wahrscheinlichkeiten in die Vorhersage einfließen lässt.

Modellannahmen

- Für den Prior benutzen wir wieder eine Normalverteilung

$$\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0). \quad (2.14)$$

- Es ist $\boldsymbol{\mu}_0$ der Mittelwert des Priors (oft benutzt man $\boldsymbol{\mu}_0 := \mathbf{0}$) und $\boldsymbol{\Sigma}_0$ dessen Kovarianzmatrix (wie oben ist diese häufig von der Form $\boldsymbol{\Sigma}_0 := b^2 \mathbf{I}$ mit $b > 0$).
- Die Likelihood modellieren wir ebenfalls analog zu oben

$$y \mid \mathbf{x}', \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}'), \sigma^2). \quad (2.15)$$

- Hierbei ist $\mathbf{x}'$ ein Datenpunkt, für den eine Vorhersage berechnet werden soll.

Prior Predictive Distribution

- In der Praxis interessieren uns die konkreten Werte der Parameter in der Regel nicht.
- Wir wollen hauptsächlich die Labels für neue Instanzen vorhersagen.
- Sei also x' eine Testinstanz.
- Die **Prior Predictive Distribution** ist gegeben durch

$$p(y | x') = \int_{\theta} p(y | x', \theta) \cdot p(\theta) = \mathbb{E}_{\theta}[p(y | x', \theta)]. \quad (2.16)$$

- Man kann (2.16) als *mittlere Vorhersage* interpretieren.
- Es handelt sich um einen *gewichteten Durchschnitt über alle möglichen Parameterwerte gemäß ihrer Wahrscheinlichkeit*.

Aufgabe: Bestimmung der Verbunddichte

2.8 Aufgabe: Der Integrand in (2.16) ist die Verbunddichte von y und θ . Mit der Produktregel gilt

$$p(y \mid \mathbf{x}', \theta; \sigma^2) \cdot p(\theta; b^2) = p(y, \theta \mid \mathbf{x}'; \sigma^2, b^2).$$

Bestimmen Sie einen Ausdruck für diese Verbunddichte.

Ein paar Hinweise:

- Sie müssen Erwartungswert und Kovarianz der Verbundverteilung bestimmen, denn ein Produkt von Normalverteilungen ist wieder normalverteilt.
- Schreiben Sie y in der Form $y = \theta^\top \phi(\mathbf{x}') + \varepsilon$ mit $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.
- Verwenden Sie die Rechenregeln für den Erwartungswert, insbesondere die Linearität.

Parameter der Prior Predictive Distribution

Die Parameter der Predictive Distribution lassen sich analytisch bestimmen:

2.9 Satz: Für die Prior Predictive Distribution gilt

$$y \mid \mathbf{x}' \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

wobei die Parameter $\boldsymbol{\mu}$ und $\boldsymbol{\Sigma}$ gegeben sind durch

$$\boldsymbol{\mu} := \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}')$$

$$\boldsymbol{\Sigma} := \boldsymbol{\phi}(\mathbf{x}')^\top \boldsymbol{\Sigma}_0 \boldsymbol{\phi}(\mathbf{x}') + \sigma^2.$$

2.10 Aufgabe: Machen Sie sich diese Aussage anhand von Satz 1.22 und mit Aufgabe 2.8 klar.

Interpretation

- Der Erwartungswert μ ergibt sich als das Skalarprodukt des Erwartungswerts des Priors mit dem Featurevektor.
- Der Term $\phi(\mathbf{x}')^\top \Sigma_0 \phi(\mathbf{x}')$ in der Formel für Σ spiegelt die Unsicherheit der Parameter θ unter dem Prior wider.
- σ^2 stellt Unsicherheit aufgrund von Datenrauschen oder nicht modellierten Effekten dar.
- Durch jedes θ , das wir vom Prior sampeln, erhält man eine Funktion $f(\mathbf{x}') := \theta^\top \phi(\mathbf{x}')$.

Der Prior $p(\theta)$ über θ induziert eine Verteilung $p(f(\mathbf{x}))$ über mögliche Funktionen.

Beispiel

- Wir nehmen an, dass die Labels durch die folgende (in der Praxis natürlich unbekannte) Funktion generiert werden

$$f(x) = \sin(x).$$

- Zusätzlich addieren wir einen Fehler-Term ε , für den $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ gilt.
- Ein Trainingsbeispiel (x_n, y_n) hat dann die Form

$$(x_n, y_n) = (x_n, \sin(x_n) + \varepsilon_n), \quad n = 1, 2, \dots, N.$$

- Als Prior über die Parameter θ wählen wir eine zentrierte (d. h. mit Erwartungswert $\mu_0 = \mathbf{0}$), isotropische Normalverteilung (hier $\Sigma_0 = \mathbf{I}$), also

$$\theta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Beispiel (Forts.)




Abbildung: Plot des Trainingsdatensatzes. Die Labels wurden hierbei mittels $y = \sin(x) + \varepsilon$ erzeugt.

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions (lila) und der (punktuellen) Unsicherheit (grau). Die Regressionsfunktion passt sich den Daten noch nicht an, da wir bisher nur den Prior benutzen, um Vorhersagen zu machen.

Beispiel (Forts.)




Abbildung: Zufällige Samples für die Regressionsfunktion, die von der Prior Verteilung gezogen werden.

Berücksichtigung der Trainingsdaten

- Unser bisheriges Modell nutzt noch nicht die Information aus den Trainingsdaten.
- Statt dem Prior $p(\theta)$ müssen wir den Posterior $p(\theta | X, \mathbf{y})$ benutzen.
- Hierfür benutzen wir wieder den **Satz von Bayes**

$$p(\theta | X, \mathbf{y}) = \frac{\overbrace{p(\mathbf{y} | X, \theta)}^{\text{Likelihood}} \cdot \overbrace{p(\theta)}^{\text{Prior}}}{p(\mathbf{y} | X)} \quad (2.17)$$

Berücksichtigung der Trainingsdaten (Forts.)

Der Posterior kann wieder analytisch berechnet werden:

2.11 Satz: Für den Posterior gilt $\theta \mid X, \mathbf{y} \sim \mathcal{N}(\mu_N, \Sigma_N)$ mit

$$\Sigma_N := (\Sigma_0^{-1} + \sigma^{-2} \Phi^T \Phi)^{-1}$$

$$\mu_N := \Sigma_N (\Sigma_0^{-1} \mu_0 + \sigma^{-2} \Phi^T \mathbf{y}).$$

2.12 Aufgabe: Machen Sie sich diese Aussage anhand von Satz 1.22 klar. Zusätzlich überlegen Sie sich bitte, wie Sie dieses Ergebnis mit der Verbunddichte aus Aufgabe 2.8 erhalten.

Posterior Predictive Distribution

- Die Parameter der Posterior Predictive Distribution werden analog zu Satz 2.9 bestimmt (vergleiche dazu Aufgabe 2.10).
- Man ersetzt dort lediglich μ_0 durch μ_N und Σ_0 durch Σ_N .
- Hier nutzen wir die **Konjugiertheit** des Priors aus: Da der Posterior dieselbe funktionale Form hat wie der Prior, können wir Letzteren in Satz 2.9 einfach durch den Posterior ersetzen.

2.13 Satz: Für die Posterior Predictive Distribution gilt $y \mid \mathbf{x}' \sim \mathcal{N}(\mu, \Sigma)$, wobei die Parameter μ und Σ gegeben sind durch

$$\mu := \mu_N^\top \phi(\mathbf{x}')$$

$$\Sigma := \phi(\mathbf{x}')^\top \Sigma_N \phi(\mathbf{x}') + \sigma^2.$$

Beispiel (Forts.)




Abbildung: Hier noch einmal der Plot der Prior Predictions (lila) und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Nun der Plot der Posterior Predictions (lila) und der Unsicherheit (grau). Man erkennt sehr gut, dass die Unsicherheit in Bereichen mit weniger Daten größer wird.

Beispiel (Forts.)





Abbildung: Zufällige Samples, die von der Posterior Verteilung gezogen werden. Zusätzlich ist in rot die Lösung der herkömmlichen Regression geplottet.

Visualisierung: Bayes'sche Regression







- Wir generieren einen Datensatz mittels der affin-linearen Funktion

$$f(x) = 0.5x - 0.3 + \varepsilon.$$







- Die wahren Parameter sind also $\theta_0 = -0.3$ und $\theta_1 = 0.5$
- Bei ε handelt es sich um additives Datenrauschen mit Mittelwert $\mu_\varepsilon = 0$ und Varianz $\sigma_\varepsilon^2 = 1$.
- Wir benutzen den rechts abgebildeten Prior für die Parameter $\theta \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.



Visualisierung: Bayes'sche Regression (Forts.)

 $N = 1$

 $N = 2$

 $N = 3$


Visualisierung: Bayes'sche Regression (Forts.)

 $N = 5$  $N = 10$  $N = 100$ 

Kapitel

③ Gaussian Mixture Models (GMMs)

Problemstellung

Gaussian Mixture Models und latente Variablen

Maximum-Likelihood Lösung

Expectation-Maximization (EM) Algorithmus für GMMs

Problemstellung

- Wir wissen bereits, wie wir die Parameter μ und Σ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**

- Gegeben sei ein Datensatz X bestehend aus N unabhängig und identisch normalverteilten Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$.
- Schätze den Mittelwert μ gemäß

$$\hat{\mu}_{ML} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (3.1)$$

- Schätze die Kovarianzmatrix Σ mittels

$$\hat{\Sigma}_{ML} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\mu}_{ML})(\mathbf{x}_n - \hat{\mu}_{ML})^\top. \quad (3.2)$$

Frage: Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung




Abbildung: Modell bestehend aus einer Normalverteilung. Siehe [1], Seite 86.

Visualisierung: Problemstellung (Forts.)




Abbildung: Mixture-Modell bestehend aus zwei Normalverteilungen. Siehe [1], Seite 86.

Gaussian Mixture Models

3.1 Definition: Ein **Gaussian Mixture Model** ist eine *Überlagerung mehrerer Normalverteilungen*. Die Dichte bei K Komponenten ist gegeben durch

$$p(\mathbf{x}; \boldsymbol{\theta}) := \sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (3.3)$$

- Dabei enthält $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ die Modellparameter.
- Die **Mischkoeffizienten** π_k stellen sicher, dass $\int_{-\infty}^{+\infty} p(\mathbf{x}; \boldsymbol{\theta}) = 1$ gilt.
- Bei (3.3) handelt es sich um eine *Konvexkombination*, denn die π_k erfüllen

$$0 \leq \pi_k \leq 1 \quad \text{und} \quad \sum_{k=1}^K \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $z \in \mathbb{R}^K$ ein K -dimensionaler **One-Hot Vektor**.
- Dessen Komponenten erfüllen $z_k \in \{0, 1\}$ und $\sum_{k=1}^K z_k = 1$, wobei *genau ein* z_k den Wert 1 annimmt.
- Mit der Kettenregel gilt für die Verbunddichte von x und z

$$p(x, z) = p(x | z) \cdot p(z).$$

- Für die Definition der Dichte $p(z)$ benutzen wir die Mischkoeffizienten:

$$p(z_k = 1) := \pi_k.$$

- Da z ein One-Hot Vektor ist, können wir schreiben

$$p(z) = \prod_{k=1}^K \pi_k^{z_k}. \quad (3.4)$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Für die bedingte Dichte benutzen wir eine Normalverteilung der Form

$$p(\mathbf{x} \mid z_k = 1) := \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Aufgrund der One-Hot Eigenschaft können wir dies ebenfalls vektorisiert ausdrücken als

$$p(\mathbf{x} \mid \mathbf{z}) = \prod_{k=1}^K \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (3.5)$$

- Die interessierende Randdichte $p(\mathbf{x}; \boldsymbol{\theta})$ erhalten wir schließlich durch Marginalisierung von $\mathbf{z}$

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{z}) \cdot p(\mathbf{x} \mid \mathbf{z}) \stackrel{(\Delta)}{=} \sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (3.6)$$

- In (Δ) haben wir (3.4) und (3.5) zusammen mit der One-Hot Eigenschaft von $\mathbf{z}$ benutzt.

Latente Variablen

- Falls ein Datensatz X bestehend aus N Punkten $x_1, x_2, \dots, x_N$ vorliegt (und nicht nur ein einzelner Punkt x), so führen wir für jedes x_n ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt x_n .
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass x_n von Komponente k generiert wurde.

Bemerkung: Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend. Allerdings können wir nun mit der gemeinsamen Dichte $p(x, z; \theta)$ anstelle von $p(x; \theta)$ arbeiten, was zu *wesentlichen Vereinfachungen* führen wird. Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Nachfolgend interessieren wir uns besonders für die Posterior-Dichte $p(\mathbf{z} | \mathbf{x})$.
- Mit $\gamma(\mathbf{z}_k)$ bezeichnen wir die Wahrscheinlichkeit $p(\mathbf{z}_k = 1 | \mathbf{x})$.
- Mit dem **Satz von Bayes** gilt

$$\begin{aligned}\gamma(\mathbf{z}_k) &:= p(\mathbf{z}_k = 1 | \mathbf{x}) = \frac{p(\mathbf{z}_k = 1) \cdot p(\mathbf{x} | \mathbf{z}_k = 1)}{\sum_{j=1}^K p(\mathbf{z}_j = 1) \cdot p(\mathbf{x} | \mathbf{z}_j = 1)} \\ &= \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.\end{aligned}\tag{3.7}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $\mathbf{z}_k = 1$ und $\gamma(\mathbf{z}_k)$ die Aposteriori-Wahrscheinlichkeit für $\mathbf{z}_k = 1$, nachdem $\mathbf{x}$ beobachtet wurde.
- Man nennt $\gamma(\mathbf{z}_k)$ auch die **Responsibility** der k -ten Komponente für Punkt $\mathbf{x}$.

Visualisierung: Responsibilities




Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_{nk})$ gewählt. Siehe [1], Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N *unabhängigen und identisch verteilten* Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ gegeben.
- Wir fassen die Punkte $\{\mathbf{x}_n\}$ in der Matrix $\mathbf{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n -te Zeile durch $\mathbf{x}_n^\top$ gegeben ist.
- Mit (3.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned} l(\theta) &:= \ln p(\mathbf{X}; \theta) = \ln \left(\prod_{n=1}^N \left(\sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) = \sum_{n=1}^N \ln p(\mathbf{x}_n; \theta). \end{aligned} \tag{3.8}$$

- Aufgrund der Summe im Argument des Logarithmus ist (3.8) schwer zu optimieren.

Gradient der Log-Likelihood für die Mittelwerte

$$\frac{\partial}{\partial \boldsymbol{\mu}_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) = \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} p(\mathbf{x}_n; \boldsymbol{\theta})$$

Anwendung der Kettenregel.

$$= \sum_{n=1}^N \left(\frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \sum_{j=1}^K \pi_j \frac{\partial}{\partial \boldsymbol{\mu}_k} \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) \right)$$

Einsetzen der Definition von $p(\mathbf{x}_n; \boldsymbol{\theta})$.

$$= \sum_{n=1}^N \frac{\pi_k}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \boldsymbol{\mu}_k} \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

Nur k -ter Summand hängt von $\boldsymbol{\mu}_k$ ab. (3.9)

$$\stackrel{(\square)}{=} \sum_{n=1}^N \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \cdot \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_k)$$

Kettenregel für Exponentialfunktion.

$$= \sum_{n=1}^N \gamma(z_{nk}) \cdot \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_k)$$

Definition der Responsibilities.

Aufgabe: Gradient der Log-Likelihood für die Mittelwerte

3.2 Aufgabe: Machen Sie sich den Schritt ($\square$) in (3.9) klar.

Lösung für die Mittelwerte

- Wir setzen den Gradienten (3.9) Null, lösen nach μ_k auf und erhalten schließlich

$$\sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \stackrel{!}{=} \mathbf{0} \iff \mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n. \quad (3.10)$$

- Hierbei ist N_k die Summe der Responsibilities der k -ten Komponente, also

$$N_k := \sum_{n=1}^N \gamma(z_{nk}).$$

Interpretation: Der Mittelwert μ_k der k -ten Komponente ergibt sich also durch ein *gewichtetes arithmetisches Mittel* der Punkte $\{\mathbf{x}_n\}$, wobei die Gewichte gerade die Aposteriori-Wahrscheinlichkeiten dafür sind, dass $\mathbf{x}_n$ durch die k -te Komponente generiert wurde.

Lösung für die Kovarianzmatrizen

- Ein ähnliches Ergebnis erhalten wir für die Kovarianzmatrizen Σ_k .
- Es gilt

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \quad (3.11)$$

- Auch hier ergeben sich die Parameter als gewichtetes arithmetisches Mittel.

3.3 Aufgabe: Beweisen Sie diese Aussage!

Optimierung bezüglich der Mischkoeffizienten

- Bei der Optimierung bezüglich der Mischkoeffizienten π_k müssen wir zusätzlich die Normierungsbedingung beachten

$$\sum_{k=1}^K \pi_k = 1.$$

- Es handelt sich also um ein *Optimierungsproblem unter Nebenbedingungen*.
- Die **Lagrange-Funktion** des Problems ergibt sich zu

$$\begin{aligned} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right). \end{aligned} \tag{3.12}$$

Gradient der Log-Likelihood für die Mischkoeffizienten

$$\frac{\partial}{\partial \pi_k} \mathcal{L}(\boldsymbol{\theta}, \lambda) = \frac{\partial}{\partial \pi_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \cdot \frac{\partial}{\partial \pi_k} \left(\sum_{k=1}^K \pi_k - 1 \right)$$

Linearität des Differenzialoperators.

$$= \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \pi_k} p(\mathbf{x}_n; \boldsymbol{\theta}) + \lambda$$

Anwendung der Kettenregel.

$$= \frac{1}{\pi_k} \sum_{n=1}^N \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda$$

Zähler und Nenner mit π_k erweitern. (3.13)

$$= \frac{1}{\pi_k} \sum_{n=1}^N \gamma(z_{nk}) + \lambda$$

Definition der Responsibilities.

$$= \frac{N_k}{\pi_k} + \lambda$$

Definition von N_k .

Lösung für die Mischkoeffizienten

- Zusätzlich benötigen wir noch die Ableitung von (3.12) nach λ .
- Wir erhalten

$$\frac{\partial}{\partial \lambda} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \sum_{k=1}^K \pi_k - 1. \quad (3.14)$$

- Setzen wir die Ableitungen (3.13) und (3.14) Null, so erhalten wir

$$\pi_k = -\frac{N_k}{\lambda} \quad \text{und} \quad 1 = \sum_{k=1}^K \pi_k.$$

- Setzen wir die erste Bedingung in die zweite ein, so erhalten wir $\lambda = -N$ und damit schließlich

$$\pi_k = \frac{N_k}{N}. \quad (3.15)$$

Expectation-Maximization (EM) Algorithmus für GMMs

- Bei den Lösungsformeln (3.10), (3.11) und (3.15) handelt es sich *nicht um geschlossene Lösungsformeln (!)*, da die Gewichte $\gamma(z_{nk})$ von den anderen Parametern abhängen.
- Allerdings legen die Ergebnisse ein einfaches *iteratives Verfahren* nahe, den **Expectation-Maximization (EM) Algorithmus**.
- Dieser besteht aus zwei Phasen, die **Expectation-Phase (E-Schritt)** und die **Maximization-Phase (M-Schritt)**.
- Im E-Schritt werden die Werte $\gamma(z_{nk})$ bei gegebenen Parametern π_k , μ_k , Σ_k bestimmt.
- Im darauffolgenden M-Schritt werden die Parameter mit den neuen Werten $\gamma(z_{nk})$ aufdatiert.
- Dies führt man solange fort, bis Konvergenz eintritt.

Visualisierung: EM für GMMs




Abbildung: Visualisierung des EM Verfahrens für GMMs. Siehe [1], Seite 473.

Visualisierung: EM für GMMs (Forts.)




Abbildung: Visualisierung des EM Verfahrens für GMMs. Siehe [1], Seite 473.

EM Algorithmus für GMMs

3.4 Algorithmus

- 1 Initialisiere die Parameter $\{\pi_k\}$, $\{\mu_k\}$ und $\{\Sigma_k\}$ (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Berechne die Responsibilities für alle n und alle k gemäß

$$\gamma(z_{nk}) := \frac{\pi_k \cdot \mathbf{n}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathbf{n}(\mathbf{x}_n; \mu_j, \Sigma_j)}.$$

- 3 **M-Schritt:** Aktualisiere die Parameter, wobei $N_k := \sum_{n=1}^N \gamma(z_{nk})$

$$\mu_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad \text{und} \quad \Sigma_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^\top \quad \text{und} \quad \pi_k := \frac{N_k}{N}.$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zu Schritt 2.

Literatur

- [1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: <https://www.bishopbook.com/>.
- [2] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>.