

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

1 Probabilistische PCA (PPCA)

Kapitel

1 Probabilistische PCA (PPCA)

PPCA Modell

Bestimmung der Verbunddichte

Bestimmung des Posteriors der latenten Variablen

Bestimmung der Likelihood

PCA als latent Variable Model

- Wir modellieren die Repräsentation der Daten im Principal Subspace als latente Variablen $z \in \mathbb{R}^D$.
- Für die Verteilung von z gelte

$$z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (1.1)$$

- Zudem führen wir die bedingte Verteilung von $x \in \mathbb{R}^M$ gegeben z wie folgt ein

$$x \mid z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (1.2)$$

- Die Spalten der Matrix $\mathbf{W} \in \mathbb{R}^{M \times D}$ spannen hierbei den Principal Subspace auf.
- Es ist $\boldsymbol{\mu} \in \mathbb{R}^M$.
- Der Parameter σ^2 beeinflusst die Varianz der bedingten Verteilung (1.2).

PPCA als generatives Modell

Die PPCA kann als **generatives Modell** aufgefasst werden:

- Zunächst wählen wir ein z gemäß (1.1).
- Dann ziehen wir die beobachtete Variable x aus der Verteilung (1.2).
- Hierbei ergibt sich der Wert für x gemäß

$$x = Wz + \mu + \varepsilon. \quad (1.3)$$

- $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ ist hierbei *additives normalverteiltes Datenrauschen*, welches durch den Parameter σ^2 in (1.2) beeinflusst wird.

Das Mapping der Daten in den Principal Subspace erhalten wir mit dem Satz von Bayes.

PPCA als generatives Modell




Abbildung: PPCA als generatives Modell. Siehe [1], Seite 572.

Bestimmung der Verbunddichte

- Für die weiteren Ausführungen benötigen wir die Verbunddichte $p(z, x)$ der beobachteten und latenten Variablen.
- Mit der Produktregel für Wahrscheinlichkeiten ist

$$p(z, x) = \boldsymbol{n}(x | z) \cdot \boldsymbol{n}(z). \quad (1.4)$$

- Da es sich bei (1.7) um ein Produkt von Normalverteilungen handelt, sind die Zufallsvariablen auch gemeinsam normalverteilt.
- Es ist also $p(z, x) = \boldsymbol{n}(z, x; \boldsymbol{\nu}, \boldsymbol{\Sigma})$ beziehungsweise

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\nu}, \boldsymbol{\Sigma}). \quad (1.5)$$

Bestimmung der Verbunddichte (Forts.)

Wir bestimmen zunächst den Parameter $\nu = (\mu_z, \mu_x)^\top$:

- Mit der Linearität des Erwartungswerts und den obigen Definitionen – insbesondere die Definitionen (1.1) und (1.3) – gilt

$$\mathbb{E}[z] = \mathbf{0}$$

$$\mathbb{E}[x] = \mathbb{E}[Wz + \mu + \varepsilon] = W \underbrace{\mathbb{E}[z]}_{=0} + \mathbb{E}[\mu] + \underbrace{\mathbb{E}[\varepsilon]}_{=0} = \mu.$$

- Zusammenfassend gilt also

$$\nu = \mathbb{E} \begin{bmatrix} z \\ x \end{bmatrix} = \begin{pmatrix} \mathbb{E}[z] \\ \mathbb{E}[x] \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix}. \quad (1.6)$$

Bestimmung der Verbunddichte (Forts.)

Nun bestimmen wir den Parameter $\Sigma = \begin{pmatrix} \Sigma_{zz} & \Sigma_{zx} \\ \Sigma_{xz} & \Sigma_{xx} \end{pmatrix}$:

- Zunächst ist $\Sigma_{zz} = \mathbb{E}[(z - \mathbb{E}[z])(z - \mathbb{E}[z])^\top] = \mathbb{E}[zz^\top] = \mathbb{D}[z] = I$.
- Ferner ist

$$\begin{aligned}\Sigma_{zx} &= \mathbb{E}[(z - \mathbb{E}[z])(x - \mathbb{E}[x])^\top] \\ &= \mathbb{E}[z(Wz + \mu + \varepsilon - \mathbb{E}[Wz + \mu + \varepsilon])^\top] \\ &= \mathbb{E}[z(Wz + \varepsilon)^\top] = \mathbb{E}[zz^\top W^\top + z\varepsilon^\top] = \mathbb{E}[zz^\top]W^\top + \mathbb{E}[z] \cdot \mathbb{E}[\varepsilon^\top] \\ &= W^\top.\end{aligned}$$

- Aus Symmetriegründen gilt $\Sigma_{xz} = W$.

Bestimmung der Verbunddichte (Forts.)

1.1 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{xx} = \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}$ gilt.

Zusammenfassung: Für die gemeinsame Verteilung von z und x erhalten wir also

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\nu}, \boldsymbol{\Sigma})$$

$$\boldsymbol{\nu} := \begin{pmatrix} \mathbf{0} \\ \boldsymbol{\mu} \end{pmatrix} \tag{1.7}$$

$$\boldsymbol{\Sigma} := \begin{pmatrix} \mathbf{I} & \mathbf{W}^\top \\ \mathbf{W} & \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I} \end{pmatrix}.$$

Woodbury Matrix-Identität

1.2 Satz: Es gilt die **Woodbury Matrix-Identität**

$$(A + BD^{-1}E)^{-1} = A^{-1} - A^{-1}B(D + EA^{-1}B)^{-1}EA^{-1},$$

wobei A , B , D und E Matrizen geeigneter Form sind.

Beweis: Der Beweis erfolgt durch Nachrechnen, indem man beide Seiten der Gleichung mit $A + BD^{-1}E$ multipliziert und die rechte Seite zur Einheitsmatrix umformt. □

Bestimmung des Posteriors

- Für die Anwendung des EM-Algorithmus benötigen wir die Dichte $p(z | x) = n(z | x; \mu_{z|x}, \Sigma_{z|x})$.
- Diese können wir aus der Verbundverteilung (1.7) mittels Satz ?? berechnen.
- Zunächst definieren wir zwei Matrizen, die wir häufig benötigen werden

$$C := \sigma^2 I + WW^\top \quad (1.8)$$

$$M := \sigma^2 I + W^\top W. \quad (1.9)$$

- Außerdem benötigen wir C^{-1} , für deren Berechnung wir die Woodbury Identität aus 1.2 benutzen, wobei wir $A = \sigma^2 I$, $B = W$, $D = I$ und $E = W^\top$ setzen (siehe nächste Folie).

Bestimmung des Posteriors (Forts.)

Es ist

$$\begin{aligned}
 C^{-1} &= (\sigma^2 I + W W^\top)^{-1} \\
 &= \sigma^{-2} I - \sigma^{-2} I W (I + W^\top \sigma^{-2} I W)^{-1} W^\top \sigma^{-2} I && \text{Woodbury Identität, Satz 1.2.} \\
 &= \sigma^{-2} I - \sigma^{-2} W \left[\sigma^{-2} (\sigma^2 I + W^\top W) \right]^{-1} \sigma^{-2} W^\top && \text{In der Klammer } \sigma^{-2} \text{ ausklammern.} \\
 &= \sigma^{-2} I - \sigma^{-2} W \left[\sigma^{-2} M \right]^{-1} \sigma^{-2} W^\top && \text{Definition (1.9).} \\
 &= \sigma^{-2} I - \sigma^{-2} W \sigma^2 M^{-1} \sigma^{-2} W^\top && \text{Für } A \text{ und } B \text{ gilt } (AB)^{-1} = B^{-1} A^{-1}. \\
 &= \sigma^{-2} I - \sigma^{-2} W M^{-1} W^\top. && \sigma^{-2} \sigma^2 = 1.
 \end{aligned}
 \tag{1.10}$$

Bestimmung des Posteriors (Forts.)

In den weiteren Rechnungen brauchen wir auch noch einen Ausdruck für $\mathbf{W}^\top \mathbf{C}^{-1}$. Hierzu multiplizieren wir (1.10) von links mit $\mathbf{W}^\top$

$$\begin{aligned}
 \mathbf{W}^\top \mathbf{C}^{-1} &= \sigma^{-2} \mathbf{W}^\top - \sigma^{-2} \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^\top. \\
 &= \sigma^{-2} (\mathbf{I} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \sigma^{-2} \text{ und } \mathbf{W}^\top \text{ ausklammern.} \\
 &= \sigma^{-2} (\mathbf{M} \mathbf{M}^{-1} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \text{Es ist } \mathbf{I} = \mathbf{M} \mathbf{M}^{-1}. \\
 &= \sigma^{-2} (\mathbf{M} - \mathbf{W}^\top \mathbf{W}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Wir klammern } \mathbf{M}^{-1} \text{ aus.} \\
 &= \sigma^{-2} (\sigma^2 \mathbf{I}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Aus (1.9) folgt } \mathbf{M} - \mathbf{W}^\top \mathbf{W} = \sigma^2 \mathbf{I}. \\
 &= \mathbf{M}^{-1} \mathbf{W}^\top.
 \end{aligned}
 \tag{1.11}$$

Bestimmung des Posteriors (Forts.)

- Nun haben wir alles zusammen, um den Posterior mit Satz ?? auszurechnen.
- Wir beginnen mit dem bedingten Erwartungswert $\mu_{z|x}$

$$\begin{aligned}\mu_{z|x} &= \mu_z + \Sigma_{zx} \Sigma_{xx}^{-1} (x - \mu_x) \\ &= \mathbf{0} + \mathbf{W}^\top (\mathbf{W} \mathbf{W}^\top + \sigma^2 \mathbf{I})^{-1} (x - \mu) \\ &= \mathbf{W}^\top \mathbf{C}^{-1} (x - \mu) && \text{Definition (1.8)} \\ &= \mathbf{M}^{-1} \mathbf{W}^\top (x - \mu). && \text{Ausdruck aus (1.11)}\end{aligned}\tag{1.12}$$

1.3 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{z|x} = \sigma^2 \mathbf{M}^{-1}$ gilt.

Bestimmung des Posteriors (Forts.)

Zusammenfassung: Wir erhalten damit

$$z \mid x \sim \mathcal{N}(M^{-1}W^{\top}(x - \mu), \sigma^2 M^{-1}). \quad (1.13)$$

Bemerkung: Dasselbe Ergebnis erhält man, wenn man den Satz von Bayes ?? auf $z \sim \mathcal{N}(0, I)$ und $x \mid z \sim \mathcal{N}(Wz + \mu, \sigma^2 I)$ anwendet.

Bemerkung: In (1.13) kommt die Matrix $C^{-1} \in \mathbb{R}^{M \times M}$ nicht mehr vor. Stattdessen müssen wir nun die Matrix $M^{-1} \in \mathbb{R}^{D \times D}$ invertieren, was einfacher ist, da in der Regel $D \ll M$ ist.

Bestimmung der Likelihood

- Eine Möglichkeit zur Bestimmung der Parameter des PPCA-Modells ist die *Maximierung der Likelihood*.
- Hierfür benötigen wir einen Ausdruck für die Dichte $p(x)$ der beobachteten Daten x .
- Diesen können wir leicht aus der Verbundverteilung (1.7) bestimmen, indem wir z marginalisieren (siehe hierzu Satz ??).
- Die Randverteilung folgt zudem einer Normalverteilung.

Randdichte der Daten:

$$p(x) = \int_z n(z, x; \nu, \Sigma) dz = n(x; \mu, WW^\top + \sigma^2 I).$$

Log-Likelihood Funktion

Wir bestimmen die Log-Likelihood Funktion:

$$\begin{aligned}l(\boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) &= \ln \boldsymbol{n}(\boldsymbol{X} ; \boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) = \sum_{n=1}^N \ln \boldsymbol{n}(\boldsymbol{x}_n ; \boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) \\&= \sum_{n=1}^N \ln \left(\frac{1}{(2\pi)^{\frac{D}{2}} \cdot (\det \boldsymbol{C})^{\frac{1}{2}}} \cdot \exp \left\{ -\frac{1}{2} (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}) \right\} \right) \\&= \sum_{n=1}^N \left(-\frac{D}{2} \ln(2\pi) - \frac{1}{2} \ln \det(\boldsymbol{C}) - \frac{1}{2} (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}) \right) \\&= -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(\boldsymbol{C}) - \frac{1}{2} \sum_{n=1}^N (\boldsymbol{x}_n - \boldsymbol{\mu})^\top \boldsymbol{C}^{-1} (\boldsymbol{x}_n - \boldsymbol{\mu}).\end{aligned}\tag{1.14}$$

Log-Likelihood Funktion (Forts.)

- Von der Log-Likelihood (1.14) können wir aufgrund der bekannten Maximum-Likelihood Lösung für Normalverteilungen direkt den Schätzer für μ ablesen

$$\mu = \bar{x} := \frac{1}{N} \sum_{n=1}^N x_n. \quad (1.15)$$

- Wir setzen daher (1.15) in (1.14) ein und erhalten

$$-\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln \det(C) - \frac{1}{2} \sum_{n=1}^N (x_n - \bar{x})^\top C^{-1} (x_n - \bar{x}). \quad (1.16)$$

- Den Ausdruck (1.16) wollen wir noch weiter vereinfachen.
- Hierzu benötigen wir noch den Begriff der **Spur**

Intermezzo: Spur einer Matrix und deren Eigenschaften

Um (1.16) noch weiter zu vereinfachen, benötigen wir noch den Begriff der **Spur**:

1.4 Definition: Es sei $\mathbf{A} \in \mathbb{R}^{N \times N}$ eine quadratische Matrix. Die **Spur** (Englisch: trace) von $\mathbf{A}$ ist die Summe der Elemente auf der Hauptdiagonalen von $\mathbf{A}$, genauer definieren wir

$$\text{trace}(\mathbf{A}) := \sum_{i=1}^N a_{ii}.$$

Bemerkung: Im Folgenden benutzen wir häufig die *zyklische Eigenschaft* der Spur. Für die Matrizen $\mathbf{A}$, $\mathbf{B}$ und $\mathbf{C}$ passender Dimension gilt

$$\text{trace}(\mathbf{ABC}) = \text{trace}(\mathbf{CAB}) = \text{trace}(\mathbf{BCA}). \quad (1.17)$$

Literatur

- [1] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>.