

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

- 1 Grundlagen der Statistik
- 2 Regression
- 3 Gaussian Mixture Models (GMMs)
- 4 Expectation-Maximization (EM) Algorithmus
- 5 Principal Component Analysis (PCA)
- 6 Probabilistische PCA (PPCA)
- 7 Independent Component Analysis (ICA)

Kapitel

1 Grundlagen der Statistik

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Maximum-Likelihood Schätzer

Maximum-Aposteriori Schätzer

Bayes'sche Inferenz

Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ω ist der **Ereignisraum**, also die Menge aller Elementarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir $\Omega := \{1, 2, 3, 4, 5, 6\}$.
- Mit $\mathcal{A}$ bezeichnen wir die zugehörige **Sigma-Algebra**, eine Menge von Teilmengen von Ω . Im einfachsten Fall könnten wir $\mathcal{A} := \text{Pot}(\Omega)$ wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra $\mathbb{B}$ auf $\mathbb{R}$ heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus $\mathcal{A}$ eine Wahrscheinlichkeit zuordnet.

Zufallsvariablen

Im Folgenden sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{B})$ ein messbarer Raum.

1.1 Definition: Die Abbildung $X : \Omega \rightarrow \mathcal{X}$ heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : X^{-1}(B) := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von B unter X muss also eine messbare Menge in $\mathcal{A}$ sein, der durch $\mathbb{P}$ eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable $X : \Omega \rightarrow \mathcal{X}$ die Funktion

$$\mathbb{P}^X : \mathcal{B} \rightarrow [0, 1] \quad \text{mit} \quad B \mapsto \mathbb{P}(X^{-1}(B))$$

die **Verteilung** der Zufallsvariable X . $\mathbb{P}^X$ ist das **Bildmaß** von $\mathbb{P}$ unter X .

Zufallsvariablen (Forts.)

Sei $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$ ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße $X : \Omega \rightarrow \mathcal{X}$ ist *verteilt gemäß $\mathbb{Q}$* oder kurz *$\mathbb{Q}$ -verteilt*, falls es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\mathbb{P}^X = \mathbb{Q}$ gilt.

Beispiel: X ist $\mathcal{N}(\mu, \sigma^2)$ -verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\forall B \in \mathbb{B} : \mathbb{P}(X \in B) = \mathcal{N}(B; \mu, \sigma^2)$. Wir schreiben kurz $X \sim \mathcal{N}(\mu, \sigma^2)$.

Wahrscheinlichkeitsdichten

1.2 Definition: Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{B}, \mathbb{P}^X)$ Wahrscheinlichkeitsräume. Dabei ist $\mathbb{P}^X$ die Verteilung der Zufallsvariablen $X : \Omega \rightarrow \mathcal{X}$. Wir nennen eine nichtnegative Funktion

$$p_X : \mathbb{R} \rightarrow [0, \infty)$$

eine **(Wahrscheinlichkeits-)Dichte** von $\mathbb{P}^X$, falls

$$\mathbb{P}^X(B) = \int_B p_X(\xi) \, d\xi \quad \forall B \in \mathcal{B}.$$

Bemerkung: Die Wahrscheinlichkeiten der Mengen $B \in \mathcal{B}$ müssen sich also allesamt als Integral der Dichte p_X darstellen lassen können.

Erwartungswert von Zufallsvariablen

1.3 Definition: Sei $X \in \mathbb{R}$ eine Zufallsvariable. Wir definieren den **Erwartungswert** (erstes Moment) von X als

$$\mathbb{E}[X] := \int_{\mathbb{R}} \xi \cdot p_X(\xi) d\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen X und Y und eine beliebige aber feste Zahl $\alpha \in \mathbb{R}$ (keine Zufallsvariable!) gelten

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \quad \text{und} \quad \mathbb{E}[\alpha \cdot X] = \alpha \cdot \mathbb{E}[X].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ als

$$\mathbb{E}[\mathbf{x}] := (\mathbb{E}[x_1], \mathbb{E}[x_2], \dots, \mathbb{E}[x_n])^\top.$$

Varianz von Zufallsvariablen

1.4 Definition: Die Varianz einer Zufallsvariablen $X \in \mathbb{R}$ ist definiert als die *erwartete quadratische Abweichung vom Erwartungswert* (zweites zentriertes Moment), also

$$\mathbb{V}[X] := \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{\mathbb{R}} (\xi - \mathbb{E}[X])^2 \cdot p_X(\xi) \, d\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2 - 2X \cdot \mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2 \cdot \mathbb{E}[X]^2 + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2.\end{aligned}$$

Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen. Seien dazu X und Y reelle Zufallsvariablen und $\alpha \in \mathbb{R}$ beliebig aber fest.

Die Varianz ist **nicht** linear!

- Es gilt $\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y]$ nur, wenn X und Y unkorreliert sind (**Satz von Bienaymé**).
- $\mathbb{V}[\alpha \cdot X] = \alpha^2 \cdot \mathbb{V}[X]$.

Eine Verschiebung verändert die Varianz nicht, also $\mathbb{V}[X + \alpha] = \mathbb{V}[X]$ (α ist hierbei keine Zufallsvariable, sondern eine konstante reelle Zahl).

Kovarianz

1.5 Definition: Es seien X und Y zwei Zufallsvariablen. Die **Kovarianz** zwischen X und Y ist definiert als

$$\text{Cov}[X, Y] := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Bemerkungen:

- Die Erwartungswerte müssen natürlich existieren, damit Definition 1.5 Sinn ergibt.
- Die Kovarianz ist symmetrisch: Es ist $\text{Cov}[X, Y] = \text{Cov}[Y, X]$.

1.6 Aufgabe: Was ist der Unterschied zwischen Kovarianz und Korrelation?

Streuungsmatrix

1.7 Definition: Es sei $\mathbf{x} \in \mathbb{R}^N$ ein Zufallsvektor. Wir definieren die **Streuungsmatrix** $\mathbb{D}[\mathbf{x}]$ als

$$\mathbb{D}[\mathbf{x}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \in \mathbb{R}^{N \times N}.$$

Für die Einträge von $\mathbb{D}[\mathbf{x}]$ gilt:

$$\begin{aligned} (\mathbb{D}[\mathbf{x}])_{ij} &= \mathbb{E}[(x_i - \mathbb{E}[x_i])(x_j - \mathbb{E}[x_j])] \\ &= \mathbb{E}[(x_j - \mathbb{E}[x_j])(x_i - \mathbb{E}[x_i])] = (\mathbb{D}[\mathbf{x}])_{ji} = \begin{cases} \text{Cov}[x_i, x_j] & \text{für } i \neq j \\ \mathbb{V}[x_i] & \text{für } i = j. \end{cases} \end{aligned}$$

1.8 Aufgabe: Zeigen Sie, dass $\mathbb{D}[\mathbf{x}]$ positiv semidefinit ist.

Kovarianzmatrix

1.9 Definition: Es seien $x \in \mathbb{R}^N$ und $y \in \mathbb{R}^M$ zwei Zufallsvektoren. Die **Kovarianzmatrix** von x und y ist

$$\text{Cov}[x, y] := \mathbb{E}[(x - \mathbb{E}[x])(y - \mathbb{E}[y])^\top] \in \mathbb{R}^{N \times M}.$$

Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

Name der Verteilung	$\mathbb{P}^X$	Zähldichte $p_X(k)$	$\mathbb{E}[X]$	$\mathbb{V}[X]$
Bernoulli-Verteilung	$B_{1,p}$	$p^k \cdot (1-p)^{1-k}$	p	$p \cdot (1-p)$
Binomial-Verteilung	$B_{n,p}$	$\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Hypergeometrische Verteilung	$H_{n,K,N}$	$\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \cdot \frac{K}{N}$	$n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$
Poisson-Verteilung	P_λ	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	λ	λ

Absolutstetige Verteilungen

Name der Verteilung	$\mathbb{P}^X$	Lebesgue-Dichte $p_X(\xi)$	$\mathbb{E}[X]$	$\mathbb{V}[X]$
Normalverteilung	$\mathcal{N}_{\mu, \sigma^2}$	$\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma-Verteilung	$\Gamma_{\lambda, r}$	$\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$
Chiquadrat-Verteilung	χ_f^2	$\frac{1}{2^{\frac{f}{2}} \cdot \Gamma(\frac{f}{2})} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	f	$2 \cdot f$
Exponential-Verteilung	Exp_{λ}	$\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Beta-Verteilung	$\beta_{a, b}$	$\frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0, 1)}(\xi)$	$\frac{a}{a+b}$	$\frac{a \cdot b}{(a+b)^2 \cdot (a+b+1)}$
Gleichverteilung	$U_{(a, b)}$	$\frac{1}{b-a} \cdot \mathbf{1}_{(a, b)}(\xi)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

1.10 Definition: Es seien $X \in \mathbb{R}$ und $Y \in \mathbb{R}$ reelle Zufallsvariablen mit den Verteilungen $\mathbb{P}^X$, $\mathbb{P}^Y$ und den Dichten p_X bzw. p_Y .

X und Y heißen **stochastisch unabhängig** genau dann, wenn $p_{X,Y} := p_X \cdot p_Y$ eine **Produktdichte** der Verteilung $\mathbb{P}^{X,Y}$ ist, d. h. die gemeinsame Dichte von X und Y ergibt sich als Produkt der Einzeldichten.

Bemerkung: Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. **Die Umkehrung gilt im Allgemeinen nicht!** Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als die der Unkorreliertheit.

Bedingte Wahrscheinlichkeiten

- Wahrscheinlichkeiten von Ereignissen verändern sich, wenn wir zusätzliches Wissen mit einbeziehen.
- Wir definieren daher:

1.11 Definition: Es seien X und Y zwei Zufallsvariablen, wobei wir den Wert von Y bereits beobachtet haben (Vorwissen). Dann ist die **Wahrscheinlichkeitsdichte von X gegeben Y** , in Notation $p_{X|Y}(x | y)$, definiert als

$$p_{X|Y}(x | y) := \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Satz von Bayes

Mit bedingten Wahrscheinlichkeiten können wir einen zentralen Satz der Wahrscheinlichkeitsrechnung angeben:

1.12 Satz: Es seien X und Y zwei Zufallsvariablen. Es gilt der **Satz von Bayes**

$$p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) \cdot p_X(x)}{p_Y(y)}.$$

Beweis: Mit Definition 1.11 gilt $p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}$. Analog gilt $p_{Y|X}(y | x) = \frac{p_{Y,X}(y, x)}{p_X(x)}$. Da $p_{X,Y}(x, y) = p_{Y,X}(y, x)$, können wir beide Gleichungen nach der Verbunddichte $p_{X,Y}(x, y)$ auflösen. Wir erhalten also $p_{X,Y}(x, y) = p_{X|Y}(x | y) \cdot p_Y(y)$ und $p_{X,Y}(x, y) = p_{Y|X}(y | x) \cdot p_X(x)$. Gleichsetzen liefert schließlich

$$p_{X|Y}(x | y) \cdot p_Y(y) = p_{Y|X}(y | x) \cdot p_X(x) \quad \Longleftrightarrow \quad p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) \cdot p_X(x)}{p_Y(y)},$$

die Behauptung. □

Transformationssatz für Lebesgue-Dichten

1.13 Satz: Es seien x und y N -dimensionale Zufallsvektoren mit dem Zusammenhang

$$y = T(x).$$

Die Abbildung $T : \mathbb{R}^N \rightarrow \mathbb{R}^N$ sei *bijektiv*, sodass die Umkehrabbildung $x = T^{-1}(y)$ existiert und eindeutig ist. Dann gilt für die Dichte p_y der transformierten Zufallsvariablen y

$$p_y(y) = p_x(T^{-1}(y)) \cdot |\det JT^{-1}(y)|,$$

wobei p_x die Dichte von x und JT^{-1} die Jacobi-Matrix der Abbildung T^{-1} bezeichnet.

Beweis: Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

Beispiel I

Es sei $X \sim \text{Exp}_2$ eine exponentialverteilte Zufallsvariable mit Ankunftsrate $\lambda = 2$.

Gesucht ist die Dichte der Zufallsvariablen $Y := 5X + 2$.

Lösung:

Es ist $T(X) := 5X + 2$ eine bijektive Transformation mit der Umkehrabbildung $X = T^{-1}(Y) = \frac{1}{5}(Y - 2)$. Zusammen mit der Dichte $p_X(x) = 2 \cdot e^{-2x} \cdot \mathbf{1}_{[0, \infty)}(x)$ der Exp_2 -Verteilung erhalten wir für die Dichte $p_Y(y)$ der transformierten Zufallsvariablen Y

$$\begin{aligned} p_Y(y) &= p_X(T^{-1}(y)) \cdot (T^{-1})'(y) = 2 \cdot e^{-2(\frac{y}{5} - \frac{2}{5})} \cdot \mathbf{1}_{[0, \infty)}\left(\frac{1}{5}y - \frac{2}{5}\right) \cdot \frac{1}{5} \\ &= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2y}{5}} \cdot \mathbf{1}_{[2, \infty)}(y). \end{aligned}$$

Beispiel II

Der Zufallsvektor $\mathbf{x} \in \mathbb{R}^N$ habe eine beliebige Lebesgue-Dichte $p_{\mathbf{x}}$. Die Transformation $\mathbf{T}$ sei linear und bijektiv, also von der Form $\mathbf{y} = \mathbf{T}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$. Wie lautet die Dichte von $\mathbf{y}$?

Lösung:

Unter obigen Voraussetzungen ist $\mathbf{A}$ invertierbar. Also existiert die Umkehrfunktion, welche durch $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})$ gegeben ist. Als Jacobi-Matrix erhält man $J\mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}$.

Die Anwendung der Transformationsformel 1.13 ergibt daher für die Dichte $p_{\mathbf{y}}$ von $\mathbf{y}$ den Ausdruck

$$p_{\mathbf{y}}(\mathbf{y}) = \frac{1}{|\det \mathbf{A}|} \cdot p_{\mathbf{x}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})),$$

wobei wir den Zusammenhang $\det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$ benutzt haben.

Beispiel III

Das nächste Beispiel wird als Übungsaufgabe gestellt:

1.14 Aufgabe: Es sei X eine Zufallsvariable, die χ^2_2 -verteilt ist.

- 1 Berechnen Sie die Lebesgue-Dichte der Zufallsvariable $Y := \sqrt{X}$.
- 2 Berechnen Sie die Wahrscheinlichkeit $\mathbb{P}(Y > \frac{1}{2})$.

Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

1.15 Satz: Es sei $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top \in \mathbb{R}^N$ ein Zufallsvektor, dessen Komponenten $x_i \in \mathbb{R}$ unabhängig und identisch standardnormalverteilt sind, d. h. $x_i \sim \mathcal{N}(0, 1) \forall i \in \{1, \dots, N\}$.

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$n_{\mathbf{x}}(\mathbf{x}) := \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

Beweis: Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$n_{\mathbf{x}}(\mathbf{x}) = \prod_{i=1}^N p_{x_i}(x_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^N x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

□

Multivariate Normalverteilung (Forts.)

Für die multivariate Standardnormalverteilung gilt $\mathbb{E}[\mathbf{x}] = \mathbf{0}$ und $\mathbb{D}[\mathbf{x}] = \mathbf{I}$.

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren $\boldsymbol{\mu} \in \mathbb{R}^N$ und Streuungsmatrizen $\boldsymbol{\Sigma} \in \mathbb{R}^{N \times N}$. Wir fordern lediglich, dass die Streuungsmatrix $\boldsymbol{\Sigma}$ *positiv definit* ist, dass also $\mathbf{z}^\top \boldsymbol{\Sigma} \mathbf{z} > 0 \forall \mathbf{z} \in \mathbb{R}^N \setminus \{\mathbf{0}\}$ gilt.

- 1 Aufgrund der positiven Definitheit von $\boldsymbol{\Sigma}$ gibt es eine untere Dreiecksmatrix $\mathbf{A}$ mit $\boldsymbol{\Sigma} = \mathbf{A} \mathbf{A}^\top$ (Stichwort: **Cholesky-Zerlegung**).
- 2 Wir betrachten die Transformation $\mathbf{y} := \mathbf{A} \mathbf{x} + \boldsymbol{\mu}$. Es gilt

$$\mathbb{E}[\mathbf{y}] = \mathbb{E}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{E}[\mathbf{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \quad \text{und} \quad \mathbb{D}[\mathbf{y}] = \mathbb{D}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{D}[\mathbf{x}] \mathbf{A}^\top = \mathbf{A} \mathbf{A}^\top = \boldsymbol{\Sigma}.$$

- 3 Nun wenden wir die Transformationsformel 1.13 an, um die Dichte von $\mathbf{y}$ zu bestimmen.

Multivariate Normalverteilung (Forts.)

Zu Schritt 3: Es ist $T^{-1}(x) = A^{-1}(y - \mu)$. Mit Beispiel II zum Transformationssatz erhalten wir

$$|\det JT^{-1}(y)| = |\det A^{-1}| = \frac{1}{|\det A|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz die Identität

$\det \Sigma = \det(AA^T) = \det A \cdot \det A = \det^2 A$. Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also $|\det A| = (\det \Sigma)^{\frac{1}{2}}$. Die Dichte p_y nimmt damit die Form

$$p_y(y) = \frac{1}{(\det \Sigma)^{\frac{1}{2}}} \cdot p_x(A^{-1}(y - \mu))$$

an, wobei p_x die Dichte der Standardnormalverteilung aus Satz 1.15 ist. Wir setzen dort $x := A^{-1}(y - \mu)$, sodass $\|x\|^2 = (y - \mu)^T (A^{-1})^T A^{-1}(y - \mu) = (y - \mu)^T \Sigma^{-1}(y - \mu)$ gilt.

Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

1.16 Definition: Es sei $\mu \in \mathbb{R}^N$ ein Vektor und $\Sigma \in \mathbb{R}^{N \times N}$ eine *positiv definite* Matrix.

Die Dichte der **multivariaten Normalverteilung** $\mathcal{N}(\mu, \Sigma)$ ist gegeben durch

$$n_x(x) := \frac{1}{(2\pi)^{\frac{N}{2}} \cdot (\det \Sigma)^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

Bemerkung: Die positive Definitheit der Matrix Σ impliziert auch deren Invertierbarkeit (siehe hierzu Satz 2.4).

Visualisierung: Multivariate Normalverteilung




Abbildung: Multivariate (genauer zweidimensionale) Normalverteilung mit (Links): Allgemeiner Kovarianzmatrix. (Mitte): Diagonaler Kovarianzmatrix, sodass die Konturen achsenparallel verlaufen. (Rechts): Kovarianz proportional zur Einheitsmatrix, also aI mit $a > 0$, sodass die Konturen perfekte Kreise bilden. Siehe [\[1\]](#), Seite 76.

Partitionierte Normalverteilung

1.17 Definition: Es seien $\mathbf{x} \in \mathbb{R}^D$ und $\mathbf{y} \in \mathbb{R}^{N-D}$ zwei Zufallsvektoren. Wir fassen diese zu einem neuen Zufallsvektor $\mathbf{z} := (\mathbf{x}^\top, \mathbf{y}^\top)^\top \in \mathbb{R}^N$ mit $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ zusammen. Hierbei seien

$$\boldsymbol{\mu} := \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix} \quad \text{und} \quad \boldsymbol{\Sigma} := \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}.$$

Wir nennen dieses Modell **partitionierte Normalverteilung**.

Bemerkungen: Aus der Symmetrie von $\boldsymbol{\Sigma}$ folgt die von $\boldsymbol{\Sigma}_{xx}$ und $\boldsymbol{\Sigma}_{yy}$. Außerdem gilt $\boldsymbol{\Sigma}_{xy} = \boldsymbol{\Sigma}_{yx}^\top$.

Oft ist es einfacher mit der Inversen der Kovarianzmatrix zu arbeiten. Wir definieren daher $\boldsymbol{\Lambda} := \boldsymbol{\Sigma}^{-1}$. Man nennt diese Matrix **Präzisionsmatrix**.

Bedingte Normalverteilung

1.18 Satz: Wir betrachten das Modell der partitionierten Normalverteilung aus Definition 1.17. Für die Zufallsvariable $x \mid y$ gilt

$$x \mid y \sim \mathcal{N}(\mu_{x|y}, \Sigma_{x|y}),$$

wobei für die Parameter der folgende Zusammenhang gilt:

$$\mu_{x|y} := \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$$

$$\Sigma_{x|y} := \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}.$$

Die Dichte dieser Verteilung bezeichnen wir mit $p_{x|y}$.

Beweis: Einen Beweis dieser Aussage finden Sie in [2] auf den Seiten 85–87.

□

Visualisierung: Bedingte Normalverteilung





Abbildung: Links: Zweidimensionale Normalverteilung. Rechts: Bedingte Verteilung in rot. Siehe [1], Seite 82.

Aufgabe: Bedingte Normalverteilung

1.19 Aufgabe: Es sei $\boldsymbol{\mu} := (0, 2)^T \in \mathbb{R}^2$ und

$$\boldsymbol{\Sigma} := \begin{pmatrix} 0.3 & -1 \\ -1 & 5 \end{pmatrix} \in \mathbb{R}^{2 \times 2},$$

sodass die Verbunddichte von X_1 und X_2 gegeben ist durch $p_{X_1, X_2}(x_1, x_2) := n(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$. Bestimmen Sie die Dichte der bedingten Verteilung $p_{X_1 | X_2}(x_1 \mid x_2 = -1)$. Benutzen Sie hierzu die Formeln aus Satz 1.18.

Normale Randverteilung

1.20 Satz: Erneut betrachten wir das Modell der partitionierten Normalverteilung aus Definition 1.17. Dann sind auch die Randverteilungen von $\mathbf{x}$ und $\mathbf{y}$ normalverteilt. Es gilt genauer

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

Die Dichten der Randverteilung bezeichnen wir mit n_x und n_y .

Beweis: Man erhält dieses Ergebnis durch **Marginalisierung** der Verbunddichte, d. h. wir integrieren über alle Variablen, die uns nicht interessieren. Für die Randverteilung von $\mathbf{x}$ gilt zum Beispiel

$$n_x(\mathbf{x}) = \int n_{x,y}(\mathbf{x}, \mathbf{y}) d\mathbf{y}.$$

Einen ausführlichen Beweis finden Sie in [2] auf den Seiten 88–89.

□

Visualisierung: Normale Randverteilung





Abbildung: Links: Zweidimensionale Normalverteilung. Rechts: Randverteilung für x_a in blau. Siehe [1], Seite 82.

Aufgabe: Normale Randverteilung

1.21 Aufgabe: Betrachten Sie erneut die Verbunddichte $p_{X_1, X_2}(x_1, x_2)$ wie sie in Aufgabe 1.19 definiert wurde.

Wie lautet die Dichte der Randverteilung $p_{X_1}(x_1)$?

Satz von Bayes für Normalverteilungen

1.22 Satz: Es seien x und y Zufallsvektoren, sodass gilt

$$x \sim \mathcal{N}(\mu, \Sigma) \quad \text{und} \quad y | x \sim \mathcal{N}(Ax + b, \Lambda).$$

Dann gilt für die Dichten der Verteilungen von y und $x | y$

$$y \sim \mathcal{N}(A\mu + b, A\Sigma A^\top + \Lambda)$$

$$x | y \sim \mathcal{N}(\Gamma[\Sigma^{-1}\mu + A^\top \Lambda^{-1}(y - b)], \Gamma).$$

Hierbei ist $\Gamma := (\Sigma^{-1} + A^\top \Lambda^{-1} A)^{-1}$.

Beweis: Einen Beweis dieser Aussage finden Sie in [2] auf den Seiten 90–93.

□

Maximum-Likelihood Methode

- Im Folgenden sei ein Beobachtungsvektor $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top$ bestehend aus N *unabhängig und identisch verteilten* (Englisch: *independent and identically distributed* - i.i.d.) Datenpunkten gegeben.
- Wir möchten Aussagen über die Parameter $\boldsymbol{\theta} := (\theta_1, \theta_2, \dots, \theta_M)^\top$ der zugrundeliegenden Verteilung machen.
- Dies erledigen wir durch eine Punktschätzung des Parametervektors $\boldsymbol{\theta}$. Den Schätzer für $\boldsymbol{\theta}$ bezeichnen wir mit $\hat{\boldsymbol{\theta}}$.
- Eine der am häufigsten angewendete Methode ist die **Maximum-Likelihood Methode**, die wir im Folgenden näher beleuchten werden.

(Log-)Likelihood Funktion

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für den Parametervektor θ maximiert die Likelihood Funktion.

1.23 Definition: Es sei $p(\mathbf{x}; \theta)$ die Dichte eines Zufallsvektors $\mathbf{x} \in \mathbb{R}^N$, welche durch den Parametervektor $\theta \in \Theta$ parametrisiert wird. Die **Likelihood Funktion** $L : \Theta \rightarrow \mathbb{R}$ ist dann definiert als

$$L(\theta) := p(\mathbf{x}; \theta) = p(x_1, x_2, \dots, x_N; \theta).$$

Häufig ist es einfacher, die **Log-Likelihood Funktion** $l(\theta) := \ln p(\mathbf{x}; \theta)$ zu betrachten. Wir definieren $\hat{\theta}_{ML} := \arg \max_{\theta} l(\theta)$.

Bemerkung: Der Schätzer $\hat{\theta}_{ML}$ maximiert sowohl L als auch l . (Warum?)

(Log-)Likelihood Funktion (Forts.)

- Im Allgemeinen kann es schwer sein, die Likelihood Funktion zu bestimmen (*vor allem wenn die Beobachtungen voneinander abhängen*).
- Die Annahme der **Unabhängigkeit der Beobachtungen** vereinfacht dies maßgeblich, denn

$$\begin{aligned} L(\theta) &= p(x_1, x_2, \dots, x_N; \theta) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot \dots \cdot p(x_N; \theta) \\ &= \prod_{n=1}^N p(x_n; \theta). \end{aligned}$$

- Für die Log-Likelihood Funktion ergibt sich durch Anwendung der Logarithmengesetze

$$l(\theta) = \ln \prod_{n=1}^N p(x_n; \theta) = \sum_{n=1}^N \ln p(x_n; \theta).$$

Maximum-Likelihood Gleichung

- Falls die Likelihood Funktion differenzierbar ist, so erfüllt der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ notwendig die **Likelihood Gleichung**

$$\left. \frac{\partial}{\partial \theta} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = \mathbf{0}.$$

- Diese sagt aus, dass $\hat{\theta}_{ML}$ ein *stationärer Punkt der (Log-)Likelihood Funktion* sein muss.
- Es handelt sich dabei um ein System von M , im Allgemeinen nicht-linearen, Gleichungen der Form

$$\left. \frac{\partial}{\partial \theta_j} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = 0 \quad j = 1, 2, \dots, M.$$

Achtung: Es muss noch überprüft werden, ob $\hat{\theta}_{ML}$ tatsächlich ein Maximum darstellt.

Beispiel I: Binomialverteilung

1.24 Satz: Es sei die binomialverteilte Zufallsvariable X (Anzahl der Erfolge) und der Stichprobenumfang N gegeben. Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für die unbekannte Erfolgswahrscheinlichkeit $\theta \in (0, 1)$ lautet $\hat{\theta}_{ML} = \frac{k}{N}$, wobei k die Anzahl der beobachteten Erfolge in der Stichprobe ist.

Beweis: Die Likelihood Funktion ist gegeben durch $L(\theta) = \binom{N}{k} \cdot \theta^k \cdot (1 - \theta)^{N-k}$. Wir wenden den Logarithmus an und erhalten die Log-Likelihood Funktion

$$l(\theta) = \ln \binom{N}{k} + k \cdot \ln \theta + (N - k) \cdot \ln(1 - \theta).$$

Diese leiten wir nach θ ab und setzen sie Null. Auflösen nach θ ergibt schließlich

$$\frac{d}{d\theta} l(\theta) = \frac{k}{\theta} - \frac{N - k}{1 - \theta} \stackrel{!}{=} 0 \iff \hat{\theta}_{ML} = \frac{k}{N}.$$

Wir prüfen noch das Vorzeichen der zweiten Ableitung. Es ist $\frac{d^2}{d\theta^2} l(\theta) = -\frac{k}{\theta^2} - \frac{N-k}{(1-\theta)^2} < 0 \forall \theta \in (0, 1)$, sodass $\hat{\theta}_{ML}$ tatsächlich ein Maximum ist. Es handelt sich sogar um ein global eindeutiges Maximum. □

Beispiel II: Normalverteilung

1.25 Satz: Es seien $\mathbf{x} = (x_1, x_2, \dots, x_N)^\top$ *unabhängig und identisch normalverteilte* Beobachtungen mit unbekanntem Erwartungswert $\mu \in \mathbb{R}$ und unbekannter Varianz $\sigma^2 > 0$. Der Parametervektor θ ist in diesem Fall zweielementig und gegeben durch $\theta := (\mu, \sigma^2)^\top$.

Die Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$ für die unbekannten Parameter μ und σ^2 werden in diesem Fall bestimmt mittels

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N x_n \quad \text{und} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2.$$

Beweis: Die Dichte der Produktverteilung lautet aufgrund der Unabhängigkeit der Beobachtungen

$$p(\mathbf{x}; \mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \frac{1}{\sigma^N} \cdot \exp\left(-\frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}\right).$$

Aufgrund der auftretenden Exponentialverteilung bietet sich die Betrachtung der Log-Likelihood Funktion an. Wir erhalten

$$l(\mu, \sigma^2) = -\frac{N}{2} \cdot \ln(2\pi) - N \ln(\sigma) - \frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}.$$

Nun berechnen wir die partiellen Ableitungen von l nach μ und σ^2 . Es ist

$$\frac{\partial}{\partial \mu} l(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) \quad \text{und} \quad \frac{\partial}{\partial \sigma^2} l(\mu, \sigma^2) = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=1}^N (x_n - \mu)^2.$$

Durch Nullsetzen und auflösen erhalten wir die im Satz angegebenen Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$. Es bleibt noch zu zeigen, dass es sich tatsächlich um ein Maximum handelt. Man rechnet nach, dass die Hesse-Matrix von $l(\mu, \sigma^2)$ and der Stelle $(\hat{\mu}_{ML}, \hat{\sigma}_{ML}^2)$ gegeben ist durch

$$\nabla^2 l(\mu, \sigma^2) = \begin{pmatrix} -\frac{N}{\hat{\sigma}_{ML}^2} & 0 \\ 0 & -\frac{N}{(\hat{\sigma}_{ML}^2)^2} \end{pmatrix}.$$

Diese Matrix ist negativ definit, weshalb wir tatsächlich ein Maximum gefunden haben. □

Erwartungstreue Schätzer

Wir definieren den Begriff der Erwartungstreue:

1.26 Definition: Wir nennen einen Schätzer $\hat{\theta}$ **erwartungstreu**, falls $\mathbb{E}[\hat{\theta}] = \theta$ gilt.

- Der Schätzer $\hat{\mu}_{ML}$ ist erwartungstreu für den Erwartungswert μ im Normalverteilungsmodell

Beweis: Es gilt

$$\mathbb{E}[\hat{\mu}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \cdot N \cdot \mu = \mu.$$

□

- Demgegenüber ist $\hat{\sigma}_{ML}^2$ **nicht** erwartungstreu. Man kann diesen Schätzer jedoch durch eine geeignete Transformation zu einem erwartungstreuen Schätzer machen. Dies führt auf die **empirische Varianz** $\frac{N}{N-1} \hat{\sigma}_{ML}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2$.

Aufgabe zur Maximum-Likelihood Schätzung

1.27 Aufgabe: Gegeben seien die N Beobachtungen $x_1, x_2, \dots, x_N$, wobei $x_n \in \mathbb{N}$, $n = 1, 2, \dots, N$. Sie legen den Daten eine Poisson-Verteilung zugrunde. Diese hat die Dichte

$$p(x) := e^{-\lambda} \cdot \frac{\lambda^x}{x!}.$$

- 1 Bestimmen Sie den Maximum-Likelihood Schätzer $\hat{\lambda}_{ML}$ für die Poisson-Verteilung. Vergessen Sie dabei nicht zu überprüfen, ob es sich tatsächlich um ein Maximum handelt.
- 2 Prüfen Sie den Schätzer auf Erwartungstreue.

Erwartete quadratische Abweichung (MSE)

Ein weiteres Qualitätsmerkmal eines Schätzers $\hat{\theta}$ ist seine erwartete quadratische Abweichung vom wahren Parameter θ .

1.28 Definition: Die **erwartete quadratische Abweichung** von $\hat{\theta}$ zu θ ist

$$\text{MSE}[\hat{\theta}, \theta] = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Die $\text{MSE}[\hat{\theta}, \theta]$ reduziert sich für erwartungstreue Schätzer $\hat{\theta}$ auf die Varianz $\mathbb{V}[\hat{\theta}]$.

Beweis: Man rechnet nach, dass $\text{MSE}[\hat{\theta}, \theta] = \mathbb{V}[\hat{\theta}] + (\mathbb{E}[\hat{\theta}] - \theta)^2$ gilt (multipliziere hierzu aus und nutze die Linearität des Erwartungswerts). Der zweite Summand (Quadrat der Verzerrung/Bias) verschwindet aber für erwartungstreue Schätzer, da $\mathbb{E}[\hat{\theta}] = \theta$ gilt. Es folgt die Behauptung. □

Maximum-Aposteriori Schätzer (MAP)

- ML Schätzer laufen Gefahr, sich übermäßig stark an die Daten anzupassen (**Overfitting**).
- Wir erweitern daher das Konzept der ML Schätzung, indem wir zusätzlich eine *Apriori-Verteilung* für die zu schätzenden Parameter mit einbeziehen.
- Wir nutzen den Satz von Bayes, um damit zusammen mit der Likelihood eine *Aposteriori-Verteilung* über die Parameter zu erhalten.
- Ein Schätzer $\hat{\theta}_{MAP}$ heißt **Maximum-Aposteriori Schätzer** für den Parameter θ , falls dieser die Aposteriori-Wahrscheinlichkeit maximiert.

Binäre Variablen

- Wir betrachten eine binäre Zufallsvariable $X \in \{0, 1\}$, z. B. das Werfen einer (unfairen) Münze, wobei $X = 1$ 'Kopf' und $X = 0$ 'Zahl' bedeutet.
- Die Zufallsvariable X ist damit **Bernoulli-verteilt** mit der Dichte

$$p_X(k) := \mu^k \cdot (1 - \mu)^{1-k}. \quad (1.1)$$

- Es gilt

$$\mathbb{E}[X] = \mu$$

$$\mathbb{V}[X] = \mu \cdot (1 - \mu).$$

1.29 Aufgabe: Beweisen Sie die Aussagen $\mathbb{E}[X] = \mu$ und $\mathbb{V}[X] = \mu \cdot (1 - \mu)$.

Maximum Likelihood für die Bernoulli-Verteilung

- Wir gehen nun von N unabhängigen Bernoulli-verteilten Zufallsvariablen $X_1, X_2, \dots, X_N$ aus.
- Dann ist die Likelihood Funktion für den Parameter μ gegeben durch

$$L(\mu) = \prod_{n=1}^N p_{X_n}(k_n) = \prod_{n=1}^N \mu^{k_n} \cdot (1 - \mu)^{1-k_n}.$$

- Hieraus ergibt sich die Log-Likelihood Funktion

$$l(\mu) = \sum_{n=1}^N \ln p_{X_n}(k_n) = \sum_{n=1}^N [k_n \ln \mu + (1 - k_n) \cdot \ln(1 - \mu)] = \ln \mu \sum_{n=1}^N k_n + \ln(1 - \mu) \left(N - \sum_{n=1}^N k_n \right).$$

Bemerkung: Die Log-Likelihood Funktion hängt von den Beobachtungen nur über die Statistik $Y := \sum_{n=1}^N X_n$ ab. Man nennt Y daher eine **suffiziente Statistik**.

Maximum Likelihood für die Bernoulli-Verteilung

- Leiten wir $l(\mu)$ nach μ ab und setzen Null, so erhalten wir den Maximum-Likelihood Schätzer als arithmetisches Mittel der Beobachtungen

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N k_n.$$

- Schreiben wir für die Anzahl der Erfolge (Kopf) $m := \sum_{n=1}^N k_n$, so ist $\hat{\mu}_{ML} = \frac{m}{N}$.
- Werfen wir die Münze drei Mal und erhalten jedes Mal Kopf, so wäre $\hat{\mu}_{ML} = 1$ (**Overfitting**).
- Die Zufallsvariable $Y := X_1 + X_2 + \dots + X_N$ ist aufgrund der Unabhängigkeit der X_n ($1 \leq n \leq N$) **binomial-verteilt**, sodass gilt

$$\mathbb{P}(Y = m) := \binom{N}{m} \cdot \mu^m \cdot (1 - \mu)^{N-m}.$$

Beta-Verteilung

Um die Overfitting-Problematik zu adressieren, führen wir einen Beta-verteilten Prior ein.

1.30 Definition: Es sei X eine **Beta-verteilte** Zufallsvariable, in Notation $X \sim \beta_{a,b}$, mit den Parametern $a, b > 0$. Die Dichte der Verteilung ist gegeben durch

$$p_X(\xi) = \frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi).$$

Bemerkung: $\Gamma(x)$ ist hierbei die **Gamma-Funktion**. Es gilt $\Gamma(x) := \int_0^\infty u^{x-1} e^{-u} du$. Mithilfe partieller Integration kann man den Zusammenhang $\Gamma(x+1) = x \cdot \Gamma(x)$ zeigen. Außerdem gilt $\Gamma(1) = 1$. Daraus folgt $\Gamma(n+1) = n!$ für $n \in \mathbb{N}$. Somit ist die Gamma-Funktion die kontinuierliche Fortsetzung der Fakultäts-Funktion.

Visualisierung: Beta-Verteilung





Abbildung: Beta-Verteilungen für einige Parameter a , b . Siehe [2], Seite 72.

Visualisierung: Beta-Verteilung (Forts.)





Abbildung: Beta-Verteilungen für einige Parameter a , b . Siehe [2], Seite 72.

Bestimmung des Posteriors

- Um den Posterior zu erhalten, multiplizieren wir den Beta-verteilten Prior mit der binomial-verteilten Likelihood.
- Ignorieren wir alle von μ unabhängigen Terme, so erhalten wir für den Posterior mit $l := N - m$ (Anzahl Misserfolge)

$$p(\mu \mid m, l; a, b) \propto \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1}. \quad (1.2)$$

- Da Prior und Likelihood *dieselbe funktionale Form* haben, ist *auch der Posterior wieder Beta-verteilt*, wobei sich der Normierungsfaktor durch Vergleich mit der Dichte aus 1.30 ergibt

$$p(\mu \mid m, l; a, b) = \frac{\Gamma(m + a + l + b)}{\Gamma(m + a) \cdot \Gamma(l + b)} \cdot \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1} \quad (1.3)$$

Wir gehen also vom Prior mit der Dichte $\beta_{a,b}$ über zum Posterior mit der Dichte $\beta_{a+m,b+l}$.

Visualisierung: Bestimmung des Posteriors




Abbildung: Ein Schritt der Bayes'schen Inferenz. Der Prior ist gegeben durch eine Beta-Verteilung mit $a = 2 = b$. Die Likelihood Funktion ist hingegen gegeben durch eine Binomial-Verteilung mit $N = m = 1$. Der Posterior ist damit wieder Beta-verteilt mit den Parametern $a = 3$ und $b = 2$. Siehe [2], Seite 73.

Konjugierte Verteilungen

1.31 Definition: Ein Prior heißt **konjugiert** zur Likelihood, wenn der daraus berechnete Posterior exakt dieselbe funktionale Form wie der Prior annimmt.

- **Vorteil:** Der Posterior kann durch Aufdatierung der Parameter des Priors einfach bestimmt werden.

- Wichtige Paare:

Binomial-Verteilung

Beta-Verteilung

Poisson-Verteilung

Gamma-Verteilung

Normalverteilung

Normalverteilung (μ zu schätzen, Varianz σ^2 bekannt)

Aufgabe: Konjugierte Verteilungen

1.32 Aufgabe: Weisen Sie nach, dass die Gamma-Verteilung der konjugierte Prior zur Likelihood der Poisson-Verteilung für den Parameter λ ist.

Hinweis: Schreiben Sie hierzu die Likelihood-Funktion und den Prior für λ auf. Ignorieren Sie alle Terme, die nicht von λ abhängen. Wenden Sie anschließend den Satz von Bayes an, um den Posterior zu erhalten. Können Sie diesen in dieselbe Form wie den Prior bringen?

Bestimmung des MAP-Schätzers

- Der MAP-Schätzer *maximiert den Posterior* (1.3).
- Der **Log-Posterior** lautet

$$\ln p(\mu \mid m, l; a, b) = (m + a - 1) \ln \mu + (l + b - 1) \ln(1 - \mu) + \text{const.}$$

- Ableiten nach μ , Nullsetzen und Auflösen nach μ ergibt den MAP-Schätzer

$$\hat{\mu}_{MAP} = \frac{m + a - 1}{m + a + l + b - 2}.$$

- Vergleich mit dem ML-Schätzer

$$\hat{\mu}_{ML} = \frac{m}{m + l}.$$

Bayes'sche Inferenz

- Wir haben N Münzwürfe mit m Erfolgen (Kopf) und l Misserfolgen (Zahl) beobachtet.
- Unser Ziel ist es nun, den Ausgang des nächsten Wurfs vorherzusagen.
- Hierzu werden wir die **Prädikтивverteilung (Vorhersageverteilung)** aus

$$\begin{aligned}\mathbb{P}(X_{N+1} = 1 \mid m, l) &= \int_0^1 \mathbb{P}(X_{N+1} = 1 \mid \mu) \cdot p(\mu \mid m, l) \, d\mu = \int_0^1 \mu \cdot p(\mu \mid m, l) \, d\mu \\ &= \mathbb{E}[\mu \mid m, l].\end{aligned}$$

- Der Erwartungswert des Posteriors können wir nun aus (1.3) ablesen, wir erhalten

$$\mathbb{P}(X_{N+1} = 1 \mid m, l) = \frac{m + a}{m + a + l + b}.$$

Kapitel

② Regression

Wiederholung: Lineare Regression

Probabilistische Regression

Maximum Aposteriori (MAP) Regression

Bayes'sche Regression

Lineare Regression

Wir wiederholen die wichtigsten Aussagen zur linearen Regression:

- Wir betrachten einen Datensatz bestehend aus N Featurevektoren $\mathbf{x}_n \in \mathbb{R}^m$, $n = 1, 2, \dots, N$.
- Jeder Vektor $\mathbf{x}_n$ ist mit einem zugehörigen Label $y_n \in \mathbb{R}$ versehen, $n = 1, 2, \dots, N$.
- Das lineare Regressionsmodell hat die Form

$$h(\mathbf{x}; \boldsymbol{\theta}) = \theta_0 + \sum_{m=1}^M \theta_m x_m.$$

- Im Folgenden bietet es sich an, die Dummy-Komponente $x_0 := 1$ einzuführen, sodass gilt

$$h(\mathbf{x}; \boldsymbol{\theta}) = \sum_{m=0}^M \theta_m x_m = \boldsymbol{\theta}^\top \mathbf{x}.$$

Design Matrix

- Wir fassen die Featurevektoren $\mathbf{x}_n$ zeilenweise zu der Matrix

$$\mathbf{X} := \begin{pmatrix} \text{---} & \mathbf{x}_1 & \text{---} \\ \text{---} & \mathbf{x}_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \mathbf{x}_N & \text{---} \end{pmatrix} \in \mathbb{R}^{N \times (M+1)}$$

zusammen. Die erste Spalte ist hierbei konstant 1 (*wegen der Dummy-Komponente*).

- Wir nennen diese Matrix **Design Matrix**.
- Analog sammeln wir alle Labels in einem Vektor

$$\mathbf{y} := (y_1, y_2, \dots, y_N)^T \in \mathbb{R}^N.$$

Methode der kleinsten Quadrate

- Der Vektor $\theta \in \mathbb{R}^{M+1}$ beinhaltet die Modellparameter.
- Diese möchten wir so wählen, dass unser Modell die Daten möglichst gut erklärt, d. h. die Abweichung der Regressionsfunktion zu den Trainingsdaten sollte *möglichst klein* sein.

2.1 Definition: Mit den obigen Definitionen ist der **Least-Squares-Fehler** gegeben durch

$$J_{\text{LS}}(\theta) := \frac{1}{2N} \|X\theta - \mathbf{y}\|^2 = \frac{1}{2N} (X\theta - \mathbf{y})^\top (X\theta - \mathbf{y}).$$

Bemerkung: Der Vektor $X\theta \in \mathbb{R}^N$ beinhaltet die **Modellvorhersagen**, wenn man dem Modell die Parameter θ zugrunde legt. J_{LS} misst also die **mittlere quadratische Abweichung** der Vorhersagen zu den wahren Werten $\mathbf{y}$.

Minimierung der Fehlerfunktion

Unser Ziel ist die Minimierung von J_{LS} . Hierzu schreiben J_{LS} unter Ausnutzung der Transpositionsregeln $(A + B)^T = A^T + B^T$ und $(AB)^T = B^T A^T$ um:

$$\begin{aligned} J_{LS}(\theta) &= \frac{1}{2N} \|X\theta - y\|^2 = \frac{1}{2N} (X\theta - y)^T (X\theta - y) \\ &= \frac{1}{2N} ((X\theta)^T - y^T)(X\theta - y) \\ &= \frac{1}{2N} ((X\theta)^T X\theta - (X\theta)^T y - y^T (X\theta) + y^T y) \\ &= \frac{1}{2N} (\theta^T X^T X\theta - 2(X\theta)^T y + y^T y) \\ &= \frac{1}{2N} (\theta^T X^T X\theta - 2\theta^T X^T y + y^T y) \end{aligned}$$

Minimierung der Fehlerfunktion (Forts.)

Um einen stationären Punkt zu finden, müssen wir J_{LS} nach θ ableiten und Null setzen.

- Es ist $\frac{\partial}{\partial \theta} \theta^\top X^\top X \theta = 2X^\top X \theta$, da $X^\top X$ symmetrisch ist.

Beweis: Wir nutzen die Transpositionsregeln und erhalten $(X^\top X)^\top = X^\top (X^\top)^\top = X^\top X$, woraus die Symmetrie folgt. $\square$

- Es ist $\frac{\partial}{\partial \theta} (-2\theta^\top X^\top y) = -2X^\top y$ und $\frac{\partial}{\partial \theta} y^\top y = 0$.
- Der Gradient der Fehlerfunktion J_{LS} ist damit gegeben durch

$$\frac{\partial}{\partial \theta} J_{LS}(\theta) = \frac{1}{2N} (2X^\top X \theta - 2X^\top y) \propto X^\top X \theta - X^\top y = X^\top (X \theta - y)$$

Bemerkung: Man beachte den Zusammenhang zwischen dem Gradienten und dem Vorhersagefehler: Je größer der Fehler, desto größer auch der Gradient!

Minimierung der Fehlerfunktion (Forts.)

Wir setzen den Gradienten nun Null und lösen nach θ auf:

$$\frac{\partial}{\partial \theta} J_{\text{LS}}(\theta) \stackrel{!}{=} \mathbf{0} \quad \Longleftrightarrow \quad X^{\top} X \theta - X^{\top} y = \mathbf{0}$$

$$\Longleftrightarrow \quad X^{\top} X \theta = X^{\top} y$$

$$\Longleftrightarrow \quad \theta^{\star} = (X^{\top} X)^{-1} X^{\top} y$$

Bemerkung: Wir haben damit einen stationären Punkt von J_{LS} gefunden. Allerdings wissen wir noch nicht, ob es sich tatsächlich um ein Minimum handelt. Außerdem sind wir hier etwas naiv von der Existenz der Inversen $(X^{\top} X)^{-1}$ ausgegangen. Existiert diese Matrix immer?

Mit diesen Fragen beschäftigen wir uns im Folgenden.

Ein paar nützliche Aussagen

2.2 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ ist $A^\top A$ positiv semidefinit.

Beweis: Für alle $z \in \mathbb{R}^M$ gilt $z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 \geq 0$, die Behauptung. □

2.3 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ mit *vollem Spaltenrang* ist $A^\top A$ positiv definit.

Beweis: Da A vollen Spaltenrang hat, sind die Spaltenvektoren linear unabhängig. Daher ist Az für alle $z \in \mathbb{R}^M \setminus \{0\}$ eine nicht-triviale Linearkombination der Spalten von A . Folglich gilt $Az \neq 0$ und wir erhalten

$$z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 > 0,$$

woraus die Behauptung folgt. □

Ein paar nützliche Aussagen (Forts.)

2.4 Satz: Wenn A positiv definit ist, so ist A auch invertierbar.

Beweis: Wir nehmen an, A sei nicht invertierbar. Dann sind die Spalten von A linear abhängig und es existiert ein $z \in \mathbb{R}^M \setminus \{0\}$ mit $Az = 0$. Daraus folgt aber

$$z^T Az = z^T 0 = 0,$$

was der Definitheitseigenschaft von A widerspricht. A muss folglich invertierbar sein. □

Handelt es sich nun um ein Minimum?

Um diese Frage zu klären, berechnen wir die **Hesse-Matrix** von J_{LS} und untersuchen, ob die Matrix im stationären Punkt θ^* positiv definit ist.

- Man rechnet nach, dass die Hesse-Matrix gegeben ist durch

$$\frac{\partial^2}{\partial \theta \partial \theta} J_{LS}(\theta) = X^T X.$$

- Mit Satz 2.3 ist diese Matrix positiv definit für alle θ , falls X vollen Spaltenrang hat, d. h. **die Features müssen linear unabhängig sein**. In diesem Fall handelt es sich bei θ^* also tatsächlich um ein Minimum.
- Unter derselben Voraussetzung haben wir damit sogar die **Konvexität** von J_{LS} bewiesen, sodass das Minimum **global und eindeutig** ist.

Und wie sieht es nun mit der Existenz der Inversen aus?

- Mit Satz 2.4 ist die Existenz der Inversen sichergestellt, wenn $X^T X$ positiv definit ist, was wiederum aus der linearen Unabhängigkeit der Features folgt (Satz 2.3).
- **Achtung:** Bei der numerischen Berechnung der Inversen auf dem Computer kann es jedoch trotzdem zu Problemen kommen. Es ist ratsam, die Inverse nicht explizit zu berechnen, sondern stattdessen das lineare Gleichungssystem $X^T X \theta = X^T y$ nach θ zu lösen. Dieses Vorgehen ist numerisch stabiler.
- Alternativ kann das Optimierungsproblem mit dem **Gradientenabstiegsverfahren** gelöst werden. Iteriere hierzu die Regel:

$$\theta_{t+1} \leftarrow \theta_t - \alpha X^T (X \theta_t - y). \quad (2.1)$$

Normalengleichungen

Wir fassen unsere Ergebnisse zusammen:

2.5 Satz: Die Design Matrix $X \in \mathbb{R}^{N \times (M+1)}$ des Regressionsproblems habe vollen Spaltenrang, d. h. die Features seien linear unabhängig. Dann existiert die Inverse $(X^\top X)^{-1}$ und

$$\theta^\star = (X^\top X)^{-1} X^\top y$$

ist das eindeutige globale Minimum von J_{LS} . Die Gleichungen $X^\top X \theta = X^\top y$ bezeichnet man als **Normalengleichungen**.

Eine probabilistische Sicht

Annahme 1: Die Zielwerte $y \in \mathbb{R}$ und die Eingaben $\mathbf{x} \in \mathbb{R}^{M+1}$ hängen über die Gleichung

$$y = \boldsymbol{\theta}^\top \mathbf{x} + \varepsilon \quad (2.2)$$

zusammen. Dabei ist $\varepsilon \in \mathbb{R}$ ein Fehlerterm, der nicht modellierte Effekte oder Datenrauschen repräsentiert.

Annahme 2: Für den Fehlerterm gilt $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Der Zielwert y kann damit als Zufallsvariable aufgefasst werden, für die gilt

$$y \mid \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2). \quad (2.3)$$

Visualisierung: Probabilistische Regression




Abbildung: Visualisierung der probabilistischen Regression. x_0 ist hierbei ein Testpunkt.

Maximum-Likelihood Regression

- Wir betrachten wieder einen Datensatz $\{(\mathbf{x}_n, y_n)\}$ bestehend aus N Trainingsbeispielen.
- Die Likelihood des Modells ist gegeben durch

$$\begin{aligned} p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) &= \prod_{n=1}^N p(y_n \mid \mathbf{x}_n; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{1}{2\sigma^2} \left(y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n)\right)^2\right) \end{aligned} \tag{2.4}$$

- Wir gehen im Folgenden von der Verwendung von Basisfunktionen $\boldsymbol{\phi}$ aus.

Maximum-Likelihood Regression (Forts.)

- Durch Logarithmieren von (2.4) erhalten wir die Log-Likelihood Funktion

$$\begin{aligned} l(\boldsymbol{\theta}, \sigma^2) &:= \ln p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \end{aligned} \quad (2.5)$$

- Aus (2.5) wird ersichtlich, dass der Least-Squares-Fehler minimiert werden muss, um die Likelihood in $\boldsymbol{\theta}$ zu maximieren.
- Die Lösung für $\boldsymbol{\theta}$ ist dieselbe wie in Satz 2.5, zusätzlich kann die globale Unsicherheit des Modells quantifiziert werden

$$\hat{\boldsymbol{\theta}}_{ML} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (y_n - \hat{\boldsymbol{\theta}}_{ML}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \quad (2.6)$$

Visualisierung: Maximum-Likelihood Regression




Abbildung: Die MLE-Lösung erlaubt zusätzlich eine Quantifizierung der (globalen) Unsicherheit (grau).

Berücksichtigung einer Apriori-Verteilung

- Die Maximum-Likelihood Lösung ist **anfällig für Overfitting**.
- Eine Möglichkeit der **Regularisierung** ist die Verwendung einer **Apriori-Verteilung** (Prior).
- Für diese Verteilung über den Parametern θ benutzen wir die Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, b^2 \mathbf{I}). \quad (2.7)$$

- Es handelt sich hierbei um eine **isotropische Normalverteilung** (rotationsinvariant).
- Der Prior kann benutzt werden, um Vorwissen zu berücksichtigen.
- Er kodiert, welche Parameterwerte apriori plausibel sind.
- Häufig ist der Prior jedoch **nicht informativ** (z. B. Gleichverteilung).

Warum die Normalverteilung?

Frage: Warum benutzen wir eine Normalverteilung?

- Ein Argument ist **Konjugiertheit**: Da Prior und Likelihood durch Normalverteilungen gegeben sind, ist auch der *Posterior normalverteilt*. Dies vereinfacht die mathematischen Betrachtungen erheblich.
- Für Operationen auf Normalverteilungen gibt es meistens *analytische Lösungen*.

Satz von Bayes

- Wir benutzen den **Satz von Bayes**

$$p(\boldsymbol{\theta} \mid X, \mathbf{y}) = \frac{\overbrace{p(\mathbf{y} \mid X, \boldsymbol{\theta}; \sigma^2)}^{\text{Likelihood}} \cdot \overbrace{p(\boldsymbol{\theta}; b^2)}^{\text{Prior}}}{p(\mathbf{y} \mid X)} \quad (2.8)$$
$$\propto p(\mathbf{y} \mid X, \boldsymbol{\theta}; \sigma^2) \cdot p(\boldsymbol{\theta}; b^2).$$

- Wir betrachten $\boldsymbol{\theta}$ nun als (vektorwertige) Zufallsvariable (*sie steht nun vor dem Semikolon*).
- Bisher haben wir nur die Likelihood maximiert, nun berücksichtigen wir auch den Prior $p(\boldsymbol{\theta}; b^2)$.

Frage: Warum ignorieren wir den Nenner in (2.8)?

Log-Posterior Verteilung

- Anstelle der Log-Likelihood maximieren wir den **Log-Posterior**.
- Diesen erhalten wir aus (2.8) durch Logarithmieren

$$\ln p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) = \ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) + \ln p(\boldsymbol{\theta}; b^2) + \text{const.} \quad (2.9)$$

- Die Konstante const enthält alle Terme, die nicht von $\boldsymbol{\theta}$ abhängen.
- Die **MAP-Schätzung** (Maximum A posteriori) ist ein Kompromiss zwischen dem datenunabhängigen Prior und der datenabhängigen Likelihood.
- Wir betrachten im Folgenden den **negativen Log-Posterior** und erhalten

$$\hat{\boldsymbol{\theta}}_{MAP} := \arg \min_{\boldsymbol{\theta}} \left\{ -\ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) \right\}. \quad (2.10)$$

Log-Posterior Verteilung (Forts.)

Unter Verwendung der Transpositionsregeln schreiben wir (2.10) um zu

$$\begin{aligned} -\ln p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) &= -\ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta})^\top (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \mathbf{y} + (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - 2\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \mathbf{y}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const}. \end{aligned} \tag{2.11}$$

2.6 Aufgabe: Überlegen Sie sich, wie man in (2.11) von Zeile 1 auf Zeile 2 kommt.

Berechnung des Gradienten

2.7 Aufgabe: Jetzt sind Sie an der Reihe:

- 1 Berechnen Sie den Gradienten der negativen Log-Likelihood $-\ln p(\theta | X, \mathbf{y})$. Benutzen Sie hierzu die Form aus (2.11).
- 2 Setzen Sie den Gradienten anschließend Null und lösen Sie nach θ auf.
- 3 Die Lösungsformel für $\hat{\theta}_{MAP}$ fordert die Invertierung einer Matrix. Zeigen Sie, dass diese Inverse (zumindest analytisch) immer existiert.

Vergleich der MLE und MAP Lösungen

MLE-Schätzer:

$$\hat{\theta}_{ML} = (\Phi^T \Phi)^{-1} \Phi^T y \quad (2.12)$$

MAP-Schätzer:

$$\hat{\theta}_{MAP} = \left(\Phi^T \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^T y \quad (2.13)$$

Bemerkung: Setzt man $\lambda := \sigma^2/b^2$, so entspricht die MAP-Schätzung der Ridge-Regression.

Visualisierung: Vergleich der MLE und MAP Lösungen




Abbildung: Die MLE-Lösung (lila) und die MAP-Lösung (blau) im Vergleich.

Bayes'sche Regression

- Wir haben gesehen, dass ML-Schätzungen zu **Overfitting** neigen.
- Für die MAP-Schätzung haben wir deshalb zusätzlich einen Prior $p(\theta)$ berücksichtigt, welcher der **Regularisierung** dient.

Die **Bayes'sche Regression** erweitert diesen Ansatz folgendermaßen:

- Wieder benutzen wir einen Prior $p(\theta)$ für die Parameter θ .
- **Aber:** Wir berechnen diesmal keine Punktschätzung der Parameter.
- Stattdessen nutzen wir die *volle Posterior-Verteilung* aus, um Vorhersagen zu machen.
- Hierzu berechnet man die **Predictive Distribution**, die sämtliche Parameterwerte mit ihren zugehörigen Wahrscheinlichkeiten in die Vorhersage einfließen lässt.

Bayes'sche Regression: Der Ausgangspunkt

- Für den Prior benutzen wir wieder eine Normalverteilung

$$\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0). \quad (2.14)$$

- Es ist $\boldsymbol{\mu}_0$ der Mittelwert des Priors (meistens setzen wir $\boldsymbol{\mu}_0 := \mathbf{0}$) und $\boldsymbol{\Sigma}_0$ dessen Kovarianzmatrix.
- Die Likelihood modellieren wir ebenfalls analog

$$y \mid \mathbf{x}', \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}'), \sigma^2). \quad (2.15)$$

- Hierbei ist $\mathbf{x}'$ ein Datenpunkt, für den eine Vorhersage berechnet werden soll.

Prior Predictive Distribution

- In der Praxis interessieren uns die konkreten Werte der Parameter in der Regel nicht.
- Wir wollen hauptsächlich die Labels für neue Instanzen vorhersagen.
- Sei also x' eine Testinstanz.
- Die **Prior Predictive Distribution** ist gegeben durch

$$p(y | x') = \int_{\theta} p(y | x', \theta) \cdot p(\theta) = \mathbb{E}_{\theta}[p(y | x', \theta)]. \quad (2.16)$$

- Man kann (2.16) als *mittlere Vorhersage* interpretieren.
- Es handelt sich um einen *gewichteten Durchschnitt über alle möglichen Parameterwerte gemäß ihrer Wahrscheinlichkeit*.

Parameter der Prior Predictive Distribution

Die Parameter lassen sich analytisch bestimmen:

2.8 Satz: Für die Prior Predictive Distribution gilt

$$y \mid \mathbf{x}' \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

wobei die Parameter $\boldsymbol{\mu}$ und $\boldsymbol{\Sigma}$ gegeben sind durch

$$\boldsymbol{\mu} := \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}')$$

$$\boldsymbol{\Sigma} := \boldsymbol{\phi}(\mathbf{x}')^\top \boldsymbol{\Sigma}_0 \boldsymbol{\phi}(\mathbf{x}') + \sigma^2.$$

2.9 Aufgabe: Machen Sie sich diese Aussage anhand von (??) klar.

Interpretation

- Der Erwartungswert μ ergibt sich als das Skalarprodukt des Erwartungswerts des Priors mit dem Feature Vektor.
- Der Term $\phi(x')^\top \Sigma_0 \phi(x')$ spiegelt die Unsicherheit der Parameter θ unter dem Prior wider.
- σ^2 stellt Unsicherheit aufgrund von Datenrauschen dar.
- Durch jedes θ , das wir vom Prior sampeln, erhält man eine Funktion $f(x') := \theta^\top \phi(x')$.

Die Parameterverteilung $p(\theta)$ induziert eine Verteilung $p(f(x))$ über mögliche Funktionen.

Beispiel

- Wir nehmen an, dass die Labels durch die (in der Praxis natürlich unbekannte) Funktion $f(x) = \sin(x)$ generiert werden.
- Zusätzlich addieren wir einen Noise-Term, für den $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ gilt.
- Ein Trainingsbeispiel (x_n, y_n) hat dann die Form

$$(x_n, y_n) = (x_n, \sin(x_n) + \varepsilon_n), \quad n = 1, 2, \dots, N.$$

- Als Prior über die Parameter θ wählen wir eine zentrierte, isotropische Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Beispiel (Forts.)




Abbildung: Plot des Datensatzes.

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Zufällige Samples, die von der Prior Verteilung gezogen werden.

Berücksichtigung der Trainingsdaten

- Unser bisheriges Modell nutzt noch nicht die Information aus den Trainingsdaten.
- Statt dem Prior $p(\theta)$ müssen wir den Posterior $p(\theta | X, y)$ benutzen.
- Hierfür benutzen wir wieder den **Satz von Bayes**

$$p(\theta | X, y) = \frac{\overbrace{p(y | X, \theta)}^{\text{Likelihood}} \cdot \overbrace{p(\theta)}^{\text{Prior}}}{p(y | X)} \quad (2.17)$$

2.10 Satz: Für den Posterior gilt $\theta | X, y \sim \mathcal{N}(\mu_N, \Sigma_N)$ mit

$$\Sigma_N := (\Sigma_0^{-1} + \sigma^{-2} \Phi^\top \Phi)^{-1}$$

$$\mu_N := \Sigma_N (\Sigma_0^{-1} \mu_0 + \sigma^{-2} \Phi^\top y).$$

Berücksichtigung der Trainingsdaten (Forts.)

2.11 Aufgabe: Machen Sie sich diese Aussage anhand von (??) klar.

- Die Parameter der Posterior Predictive Distribution werden analog zu Satz 2.8 bestimmt.
- Man ersetzt dort lediglich μ_0 durch μ_N und Σ_0 durch Σ_N .

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Plot der Posterior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Zufällige Samples, die von der Posterior Verteilung gezogen werden.


Visualisierung: Bayes'sche Regression

- Wir generieren einen Datensatz mittels der Funktion







$$f(x) = 0.5x - 0.3 + \varepsilon.$$

- Bei ε handelt es sich um additives Datenrauschen mit Mittelwert $\mu_\varepsilon = 0$ und Varianz $\sigma_\varepsilon^2 = 1$.
- Wir benutzen einen Prior für die Parameter θ







$$\theta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$



Visualisierung: Bayes'sche Regression (Forts.)

 $N = 1$

 $N = 2$

 $N = 3$


Visualisierung: Bayes'sche Regression (Forts.)

 $N = 5$  $N = 10$  $N = 100$ 

Kapitel

③ Gaussian Mixture Models (GMMs)

Problemstellung

Gaussian Mixture Models und latente Variablen

Maximum-Likelihood Lösung

Expectation-Maximization (EM) Algorithmus für GMMs

Problemstellung

- Wir wissen bereits, wie wir die Parameter μ und Σ einer Normalverteilung aus Daten schätzen.
- Wiederholung: **Maximum-Likelihood Lösung**
 - Gegeben sei ein Datensatz X bestehend aus N unabhängig und identisch normalverteilten Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$.
 - Schätze den Mittelwert μ gemäß

$$\hat{\mu}_{ML} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (3.1)$$

- Schätze die Kovarianzmatrix Σ mittels

$$\hat{\Sigma}_{ML} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\mu}_{ML})(\mathbf{x}_n - \hat{\mu}_{ML})^\top. \quad (3.2)$$

Frage: Wie gehen wir mit multimodalen Daten um?

Visualisierung: Problemstellung




Abbildung: Modell bestehend aus einer Normalverteilung. Siehe [1], Seite 86.

Visualisierung: Problemstellung (Forts.)




Abbildung: Mixture Modell bestehend aus zwei Normalverteilungen. Siehe [1], Seite 86.

Gaussian Mixture Models

- Wir können ein **Gaussian Mixture Model** als eine *Überlagerung mehrerer Normalverteilungen* ansehen.
- Die Dichte bei K Komponenten ist gegeben durch

$$p(\mathbf{x}; \boldsymbol{\theta}) := \sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (3.3)$$

- Dabei enthält $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ die Modellparameter.
- Die **Mischkoeffizienten** π_k stellen sicher, dass die Mixture-Dichte *normiert* ist, dass also $\int_{-\infty}^{+\infty} p(\mathbf{x}; \boldsymbol{\theta}) = 1$ gilt.
- Die π_k erfüllen zudem

$$0 \leq \pi_k \leq 1 \quad \text{und} \quad \sum_{k=1}^K \pi_k = 1.$$

Gaussian Mixture Models als Latent Variable Models

- Sei im Folgenden $z \in \mathbb{R}^K$ ein K -dimensionaler **One-Hot Vektor**.
- Die Komponenten z_k erfüllen also $z_k \in \{0, 1\}$ und $\sum_{k=1}^K z_k = 1$, wobei *genau eine Komponente* den Wert 1 annimmt.
- Wir definieren nun die gemeinsame Verteilung von x und z über die Kettenregel

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x} \mid \mathbf{z}) \cdot p(\mathbf{z}).$$

- Für die Definition der Randverteilung $p(\mathbf{z})$ benutzen wir die Mischkoeffizienten: $p(z_k = 1; \pi_k) := \pi_k$.
- Da z ein One-Hot Vektor ist, können wir schreiben

$$p(\mathbf{z}; \boldsymbol{\pi}) = \prod_{k=1}^K \pi_k^{z_k}. \quad (3.4)$$

Gaussian Mixture Models als Latent Variable Models (Forts.)

- Analog definieren wir

$$p(\mathbf{x} \mid z_k = 1; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) := \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

- Dies können wir ebenfalls vektorisiert ausdrücken als

$$p(\mathbf{x} \mid \mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) := \prod_{k=1}^K \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (3.5)$$

- Die Randverteilung $p(\mathbf{x}; \boldsymbol{\theta})$ erhalten wir schließlich, indem wir über alle möglichen Werte $\mathbf{z}$ summieren

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{z}; \boldsymbol{\pi}) \cdot p(\mathbf{x} \mid \mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (3.6)$$

- Im letzten Gleichheitszeichen haben wir (3.4) und (3.5) zusammen mit der One-Hot Eigenschaft von $\mathbf{z}$ benutzt.

Latente Variablen

- Falls ein Datensatz X bestehend aus N Punkten $x_1, x_2, \dots, x_N$ vorliegt (und nicht nur ein einzelner Punkt x), so führen wir für jedes x_n ein entsprechendes z_n ein.
- Die Variablen z_n nennt man **latent**, da man sie nicht beobachtet.
- Sei z_n die latente Variable für Punkt x_n .
- Die Aussage $z_{nk} = 1$ bedeutet dann, dass x_n von Komponente k generiert wurde.
- Auf den ersten Blick wirkt die Einführung zusätzlicher Variablen nicht zielführend.
- Allerdings können wir nun mit der Verteilung $p(x, z; \theta)$ anstelle von $p(x; \theta)$ arbeiten, was zu *wesentlichen Vereinfachungen* führen wird.
- Insbesondere kann der **Expectation-Maximization (EM) Algorithmus** verwendet werden (siehe nächstes Kapitel).

Responsibilities

- Nachfolgend interessieren wir uns besonders für die Aposteriori-Wahrscheinlichkeit $p(z \mid \mathbf{x}; \boldsymbol{\theta})$.
- Mit $\gamma(z_k)$ bezeichnen wir die Wahrscheinlichkeit $p(z_k = 1 \mid \mathbf{x}; \boldsymbol{\theta})$.
- Mit dem *Satz von Bayes* gilt

$$\begin{aligned}\gamma(z_k) &:= p(z_k = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = \frac{p(z_k = 1) \cdot p(\mathbf{x} \mid z_k = 1)}{\sum_{j=1}^K p(z_j = 1) \cdot p(\mathbf{x} \mid z_j = 1)} \\ &= \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}.\end{aligned}\tag{3.7}$$

- In diesem Zusammenhang ist π_k die Apriori-Wahrscheinlichkeit für $z_k = 1$ und $\gamma(z_k)$ die Aposteriori-Wahrscheinlichkeit für $z_k = 1$, nachdem $\mathbf{x}$ beobachtet wurde.
- Man nennt $\gamma(z_k)$ auch die **Responsibility** der k -ten Komponente für Punkt $\mathbf{x}$.

Visualisierung: Responsibilities




Abbildung: (a) Beispiel von 500 Punkten, die von drei verschiedenen Normalverteilungen stammen. (b) Datensatz ohne die Information, von welcher Verteilung die Daten stammen. (c) Plot der Responsibilities. Dabei wurden die Farben im Verhältnis der Wahrscheinlichkeiten $\gamma(z_{nk})$ gewählt. Siehe [1], Seite 469.

Likelihood Funktion

- Im Folgenden sei ein Datensatz bestehend aus N *unabhängigen und identisch verteilten* Punkten $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ gegeben.
- Wir fassen die Punkte $\{\mathbf{x}_n\}$ in der Matrix $\mathbf{X} \in \mathbb{R}^{N \times M}$ zusammen, wobei die n -te Zeile durch $\mathbf{x}_n^\top$ gegeben ist.
- Mit (3.3) ergibt sich die Log-Likelihood Funktion des Mixture Models zu

$$\begin{aligned}\ln p(\mathbf{X}; \boldsymbol{\theta}) &= \ln \left(\prod_{n=1}^N \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right).\end{aligned}\tag{3.8}$$

- Aufgrund der Summe im Argument des Logarithmus ist (3.8) schwer zu optimieren.

Gradient der Log-Likelihood für die Mittelwerte

$$\frac{\partial}{\partial \mu_k} \ln p(X; \theta) = \sum_{n=1}^N \frac{1}{p(x_n; \theta)} \cdot \frac{\partial}{\partial \mu_k} p(x_n; \theta)$$

Anwendung der Kettenregel.

$$= \sum_{n=1}^N \left(\frac{1}{p(x_n; \theta)} \cdot \sum_{j=1}^K \pi_j \frac{\partial}{\partial \mu_k} \mathcal{N}(x_n; \mu_j, \Sigma_j) \right)$$

Einsetzen der Definition von $p(x_n; \theta)$.

$$= \sum_{n=1}^N \frac{\pi_k}{p(x_n; \theta)} \cdot \frac{\partial}{\partial \mu_k} \mathcal{N}(x_n; \mu_k, \Sigma_k)$$

Nur k -ter Summand hängt von μ_k ab. (3.9)

$$= \sum_{n=1}^N \frac{\pi_k \cdot \mathcal{N}(x_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(x_n; \mu_j, \Sigma_j)} \cdot \Sigma_k^{-1} (x_n - \mu_k)$$

Kettenregel für Exponentialfunktion.

$$= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (x_n - \mu_k)$$

Definition der Responsibilities.

Lösung für die Mittelwerte

- Wir setzen den Gradienten (3.9) Null, lösen nach μ_k auf und erhalten

$$\sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1}(\mathbf{x}_n - \mu_k) \stackrel{!}{=} 0 \quad \Longleftrightarrow \quad \mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n. \quad (3.10)$$

- Hierbei ist N_k die Summe der Responsibilities der k -ten Komponente, also

$$N_k := \sum_{n=1}^N \gamma(z_{nk}).$$

- Der Mittelwert μ_k der k -ten Komponente ergibt sich also durch ein *gewichtetes arithmetisches Mittel* der Punkte $\{\mathbf{x}_n\}$, wobei die Gewichtungsfaktoren gerade die Aposteriori-Wahrscheinlichkeiten dafür sind, dass $\mathbf{x}_n$ durch die k -te Komponente generiert wurde.

Lösung für die Kovarianzmatrizen

- Ein ähnliches Ergebnis erhalten wir für die Kovarianzmatrizen Σ_k .
- Es gilt

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \quad (3.11)$$

- Auch hier ergeben sich die Parameter als gewichtetes arithmetisches Mittel.

3.1 Aufgabe: Beweisen Sie diese Aussage!

Optimierung bezüglich der Mischkoeffizienten

- Bei der Optimierung bezüglich der Mischkoeffizienten π_k müssen wir zusätzlich die Normierungsbedingung beachten:

$$\sum_{k=1}^K \pi_k = 1.$$

- Es handelt sich also um ein *restringiertes Optimierungsproblem*.
- Die **Lagrange-Funktion** ist

$$\begin{aligned} \mathfrak{L}(\boldsymbol{\theta}, \lambda) &= \ln p(X; \boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \\ &= \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right) \end{aligned} \tag{3.12}$$

Gradient der Log-Likelihood für die Mischkoeffizienten

$$\frac{\partial}{\partial \pi_k} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \frac{\partial}{\partial \pi_k} \ln p(\mathbf{X}; \boldsymbol{\theta}) + \lambda \cdot \frac{\partial}{\partial \pi_k} \left(\sum_{k=1}^K \pi_k - 1 \right) \quad \text{Linearität des Differenzialoperators.}$$

$$= \sum_{n=1}^N \frac{1}{p(\mathbf{x}_n; \boldsymbol{\theta})} \cdot \frac{\partial}{\partial \pi_k} p(\mathbf{x}_n; \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) + \lambda \quad \text{Anwendung der Kettenregel.}$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda \quad \text{Zähler und Nenner mit } \pi_k \text{ erweitern.} \quad (3.13)$$

$$= \frac{1}{\pi_k} \sum_{n=1}^N \gamma(z_{nk}) + \lambda \quad \text{Definition der Responsibilities.}$$

$$= \frac{N_k}{\pi_k} + \lambda \quad \text{Definition von } N_k.$$

Lösung für die Mischkoeffizienten

- Zusätzlich benötigen wir noch die Ableitung von (3.12) nach λ .
- Wir erhalten

$$\frac{\partial}{\partial \lambda} \mathfrak{L}(\boldsymbol{\theta}, \lambda) = \sum_{k=1}^K \pi_k - 1. \quad (3.14)$$

- Setzen wir die Ableitungen (3.13) und (3.14) Null, so erhalten wir

$$\pi_k = -\frac{N_k}{\lambda} \quad \text{und} \quad 1 = \sum_{k=1}^K \pi_k.$$

- Setzen wir die erste Bedingung in die zweite ein, so erhalten wir $\lambda = -N$ und damit schließlich

$$\pi_k = \frac{N_k}{N}. \quad (3.15)$$

Expectation-Maximization (EM) Algorithmus für GMMs

- Bei den Lösungsformeln (3.10), (3.11) und (3.15) handelt es sich *nicht um geschlossene Lösungsformeln (!)*, da die Gewichte $\gamma(z_{nk})$ von den anderen Parametern abhängen.
- Allerdings legen die Ergebnisse ein einfaches *iteratives Verfahren* nahe, den **Expectation-Maximization (EM) Algorithmus**.
- Dieser besteht aus zwei Phasen, die **Expectation-Phase (E-Schritt)** und die **Maximization-Phase (M-Schritt)**.
- Im E-Schritt werden die Werte $\gamma(z_{nk})$ bei gegebenen Parametern π_k, μ_k, Σ_k bestimmt.
- Im darauffolgenden M-Schritt werden die Parameter mit den neuen Werten $\gamma(z_{nk})$ aufdatiert.
- Dies führt man solange fort, bis Konvergenz eintritt.

Visualisierung: EM für GMMs




Abbildung: Visualisierung EM für GMMs. Siehe [1], Seite 473.

Visualisierung: EM für GMMs (Forts.)




Abbildung: Visualisierung EM für GMMs. Siehe [1], Seite 473.

EM Algorithmus für GMMs

3.2 Algorithmus

- 1 Initialisiere die Parameter $\{\pi_k\}$, $\{\mu_k\}$ und $\{\Sigma_k\}$ (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Berechne die Responsibilities für alle n und alle k gemäß

$$\gamma(z_{nk}) := \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)}.$$

- 3 **M-Schritt:** Aktualisiere die Parameter, wobei $N_k := \sum_{n=1}^N \gamma(z_{nk})$

$$\mu_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad \text{und} \quad \Sigma_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^\top \quad \text{und} \quad \pi_k := \frac{N_k}{N}.$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zu Schritt 2.

Kapitel

4 Expectation-Maximization (EM) Algorithmus

Problemstellung

Ungleichung von Jensen

Herleitung des Expectation-Schritts

Herleitung des Maximization-Schritts

EM-Algorithmus und Konvergenz

Evidence-Lower-Bound und Kullback-Leibler Divergenz

Anwendung auf Gaussian Mixture Models

Problemstellung

- Wir betrachten ein statistisches Modell mit den Daten $X = (x_1, x_2, \dots, x_N)^\top$, den **latenten Variablen** $Z = (z_1, z_2, \dots, z_N)^\top$ und den Modellparametern θ .
- Wie üblich ist unser Ziel die Maximierung der Log-Likelihood $\ln p(X; \theta)$ bezüglich θ .
- Wir nehmen an, dass die gemeinsame Verteilung $p(X, Z; \theta)$ von X und Z gegeben ist.
- Hieraus können wir $\ln p(X; \theta)$ bestimmen, indem wir über Z *marginalisieren*:

$$\ln p(X; \theta) = \ln \sum_Z p(X, Z; \theta) \quad (4.1)$$

- In der Regel ist eine direkte Maximierung von (4.1) zu kompliziert, da der Logarithmus nicht direkt auf $p(X, Z; \theta)$ wirken kann.

Problemstellung (Forts.)

- Mit $\{X, Z\}$ bezeichnen wir den **vollständigen** Datensatz, X alleine nennen wir hingegen **unvollständig**.
- Analog nennen wir $\ln p(X, Z; \theta)$ die **vollständige Log-Likelihood** und $\ln p(X; \theta)$ die **unvollständige Log-Likelihood**.

Expectation-Maximization (EM)

- Da die Optimierung von (4.1) schwer ist, möchten wir $\ln p(X, Z; \theta)$ maximieren.
- **Problem:** Wir kennen Z nicht.
- Der **Expectation-Maximization (EM) Algorithmus** löst dieses Problem iterativ in *zwei Phasen*, wobei man in jeder Iteration ausgehend von θ_{alt} neue Parameter θ_{neu} erhält, die (4.1) erhöhen.

E-Phase: Bestimme den Erwartungswert von $\ln p(X, Z; \theta)$ unter der Aposteriori-Verteilung der latenten Variablen $p(Z | X; \theta_{\text{alt}})$. Die Erwartungswertfunktion bildet eine untere Schranke für $\ln p(X; \theta)$.

M-Phase: Die berechnete untere Schranke wird bezüglich der Parameter θ maximiert, was zu den aktualisierten Parametern θ_{neu} führt.

Ungleichung von Jensen

Für unsere weiteren Betrachtungen benötigen wir die folgende Ungleichung:

4.1 Satz: Es sei X eine Zufallsvariable und f eine *konvexe* Funktion. Dann gilt die **Ungleichung von Jensen** (falls alle Erwartungswerte existieren)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Bemerkungen:

- Für *konkave* Funktionen f gilt die Ungleichung in die andere Richtung: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$.
- Wenn f *strikt konvex* bzw. *strikt konkav* ist, so gilt Gleichheit genau dann, wenn X konstant (also nicht zufällig) ist.

Visualisierung: Ungleichung von Jensen




Abbildung: Visualisierung der Ungleichung von Jensen.

Bestimmung der unteren Schranke

- Im Folgenden konstruieren wir die oben erwähnte untere Schranke für $\ln p(X; \theta)$.
- Hierzu führen wir die Verteilung q über Z mit $q(Z) \neq 0$ ein und erhalten

$$\begin{aligned}\ln p(X; \theta) &= \ln \sum_Z p(X, Z; \theta) = \ln \sum_Z q(Z) \cdot \frac{p(X, Z; \theta)}{q(Z)} \\ &= \ln \mathbb{E}_{Z \sim q(Z)} \left[\frac{p(X, Z; \theta)}{q(Z)} \right] \\ &\geq \mathbb{E}_{Z \sim q(Z)} \left[\ln \frac{p(X, Z; \theta)}{q(Z)} \right] =: \mathcal{L}(q, \theta).\end{aligned}$$

- Für die Abschätzung im letzten Schritt haben wir die **Ungleichung von Jensen**, Satz (4.1), mit $f(x) := \ln(x)$ (der Logarithmus ist strikt konkav) und $X := \frac{p(X, Z; \theta)}{q(Z)}$ benutzt.

Bestimmung der unteren Schranke (Forts.)

- Die hergeleitete Ungleichung lässt sich mit den Logarithmengesetzen und der Linearität des Erwartungswerts umschreiben zu

$$\ln p(X; \theta) \geq \underbrace{\mathbb{E}_{Z \sim q(Z)} [\ln p(X, Z; \theta)]}_{\text{Erwartete vollständige Log-Likelihood}} - \underbrace{\mathbb{E}_{Z \sim q(Z)} [\ln q(Z)]}_{\text{Entropie von } q}. \quad (4.2)$$

- Die untere Schranke hängt von der Dichte q ab, die wir noch bestimmen müssen.
- Wir möchten q so wählen, dass für das aktuelle θ in (4.2) Gleichheit gilt.
- Die Ungleichung von Jensen, Satz (4.1), gilt mit Gleichheit, falls

$$\frac{p(X, Z; \theta)}{q(Z)} = \text{const.}$$

Bestimmung der unteren Schranke (Forts.)

- Wegen der vorausgehenden Überlegungen müssen wir also $q(\mathbf{Z}) \propto p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})$ wählen. Das Symbol $\propto$ bedeutet *proportional zu*.
- Daraus erhalten wir (da q normiert sein muss)

$$\begin{aligned} q(\mathbf{Z}) &= \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{\sum_{\tilde{\mathbf{Z}}} p(\mathbf{X}, \tilde{\mathbf{Z}}; \boldsymbol{\theta})} = \frac{p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})}{p(\mathbf{X}; \boldsymbol{\theta})} \\ &= p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}). \end{aligned}$$

- **Ergebnis:** Für q benutzen wir die Aposteriori-Verteilung von $\mathbf{Z}$ gegeben $\mathbf{X}$.
- Dies setzen wir in (4.2) ein und erhalten die Identität

$$\ln p(\mathbf{X}; \boldsymbol{\theta}) = \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta})] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})].$$

Maximierung der unteren Schranke

- Zu Beginn einer jeden EM-Iteration verfügen wir über den Parametervektor θ_{alt} , mit dem wir im E-Schritt die untere Schranke konstruieren.
- Hierbei wählen wir $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})$.
- Als untere Schranke erhalten wir damit

$$\begin{aligned}\ln p(\mathbf{X}; \theta) &\geq \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{X}, \mathbf{Z}; \theta)] - \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})} [\ln p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}})] \\ &= Q(\theta, \theta_{\text{alt}}) + H(\theta_{\text{alt}}, \theta_{\text{alt}}) \\ &= Q(\theta, \theta_{\text{alt}}) + \text{const},\end{aligned}$$

wobei Q der erste Erwartungswert und H der negierte zweite Erwartungswert ist.

- Die Funktion $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ ist die **Entropie** von q unter θ_{alt} .

Maximierung der unteren Schranke (Forts.)

- Da die Entropie $H(\theta_{\text{alt}}, \theta_{\text{alt}})$ bezüglich θ konstant ist, ist der im M-Schritt zu maximierende Ausdruck durch $Q(\theta, \theta_{\text{alt}})$ gegeben.
- Der M-Schritt hat damit also die Gestalt

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}). \quad (4.3)$$

- Weiter unten beweisen wir noch, dass tatsächlich $p(X | \theta_{\text{neu}}) \geq p(X | \theta_{\text{alt}})$ gilt.
- Zunächst fassen wir den EM-Algorithmus übersichtlich zusammen.

EM-Algorithmus

4.2 Algorithmus

- 1 Initialisiere θ_{alt} (entweder zufällig oder mit Vorwissen).
- 2 **E-Schritt:** Bestimme die untere Schranke

$$Q(\theta, \theta_{\text{alt}}) := \mathbb{E}_{Z \sim p(Z|X; \theta_{\text{alt}})} [\ln p(X, Z; \theta)].$$

- 3 **M-Schritt:** Maximiere die untere Schranke und berechne

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- 4 Falls noch keine Konvergenz vorliegt, gehe zurück zu Schritt 2 und setze $\theta_{\text{alt}} := \theta_{\text{neu}}$.
- 5 Ansonsten gebe θ_{neu} zurück.

Konvergenz des EM-Algorithmus

- Zum Abschluss beweisen wir noch die Konvergenz des EM-Algorithmus.
- Es gilt

$$\begin{aligned}\ln p(X; \theta_{\text{neu}}) &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | X; \theta_{\text{alt}}) \ln \frac{p(X, \mathbf{Z}; \theta_{\text{neu}})}{p(\mathbf{Z} | X; \theta_{\text{alt}})} \\ &\geq \sum_{\mathbf{Z}} p(\mathbf{Z} | X; \theta_{\text{alt}}) \ln \frac{p(X, \mathbf{Z}; \theta_{\text{alt}})}{p(\mathbf{Z} | X; \theta_{\text{alt}})} \\ &= \ln p(X; \theta_{\text{alt}}).\end{aligned}$$

- Die erste Ungleichung gilt hierbei aufgrund der Definition der unteren Schranke.
- Die zweite Ungleichung gilt, weil θ_{neu} so gewählt wurde, dass es die untere Schranke maximiert.

Visualisierung: EM-Algorithmus




Abbildung: Veranschaulichung des EM-Algorithmus. Siehe [1], Seite 488.

Evidence Lower Bound (ELBO)

- Wir geben noch eine andere Sicht auf den EM-Algorithmus.
- Hierzu stellen wir fest, dass wir die Log-Likelihood $\ln p(X; \theta)$ folgendermaßen zerlegen können

$$\ln p(X; \theta) = \mathcal{L}(q, \theta) + \text{KL}(q \parallel p). \quad (4.4)$$

- Dabei ist:
 - $\mathcal{L}(q, \theta)$ die **Evidence Lower Bound (ELBO)** oder auch **Variational Lower Bound**

$$\mathcal{L}(q, \theta) := \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(X, \mathbf{Z}; \theta)}{q(\mathbf{Z})} = \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(X, \mathbf{Z}; \theta) - \ln q(\mathbf{Z})]. \quad (4.5)$$

- $\text{KL}(q \parallel p)$ die **Kullback-Leibler Divergenz** zwischen $q(\mathbf{Z})$ und $p(\mathbf{Z} \mid X; \theta)$

$$\text{KL}(q \parallel p) := - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z} \mid X; \theta)}{q(\mathbf{Z})} = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \cdot [\ln p(\mathbf{Z} \mid X; \theta) - \ln q(\mathbf{Z})]. \quad (4.6)$$

Beweis der Zerlegung (4.4)

Beweis: Wir beweisen die Zerlegung (4.4). Hierzu wenden wir die Kettenregel für Wahrscheinlichkeiten auf $p(X, Z; \theta)$ an. Wir erhalten $p(X, Z; \theta) = p(Z | X; \theta) \cdot p(X; \theta)$. Anwendung des Logarithmus ergibt

$$\ln p(X, Z; \theta) = \ln p(Z | X; \theta) + \ln p(X; \theta).$$

Dies setzen wir in die Evidence Lower Bound (4.5) ein und erhalten

$$\begin{aligned}\mathcal{L}(q, \theta) &= \sum_Z q(Z) \cdot [\ln p(X, Z; \theta) - \ln q(Z)] \\ &= \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) + \ln p(X; \theta) - \ln q(Z)].\end{aligned}$$

Damit ergibt sich schließlich mit (4.6) und wegen $\sum_Z q(Z) = 1$

$$\begin{aligned}\mathcal{L}(q, \theta) + \text{KL}(q \parallel p) &= \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) + \ln p(X; \theta) - \ln q(Z)] - \sum_Z q(Z) \cdot [\ln p(Z | X; \theta) - \ln q(Z)] \\ &= \sum_Z q(Z) \cdot \ln p(X; \theta) = \ln p(X; \theta) \cdot \sum_Z q(Z) = \ln p(X; \theta).\end{aligned}$$

□

Kullback-Leibler Divergenz

Eigenschaften der Kullback-Leibler Divergenz:

Für alle Wahrscheinlichkeitsverteilungen q und p gelten die folgenden Eigenschaften.

❶ **Nicht-Negativität:**

$$\text{KL}(q \parallel p) \geq 0 \quad (4.7)$$

❷ **Identität:**

$$\text{KL}(q \parallel p) = 0 \iff q = p. \quad (4.8)$$

- ❸ Es sei angemerkt, dass die Kullback-Leibler Divergenz **nicht symmetrisch** und damit keine Metrik ist. Es ist also im Allgemeinen

$$\text{KL}(q \parallel p) \neq \text{KL}(p \parallel q).$$

Kullback-Leibler Divergenz (Forts.)

- Aus (4.6) ist ersichtlich, dass $\text{KL}(q \parallel p)$ die Kullback-Leibler Divergenz zwischen der Verteilung $q(\mathbf{Z})$ und der Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ von $\mathbf{Z}$ ist.
- Aus der Zerlegung (4.4) folgt mit der Nichtnegativität (4.7) der Kullback-Leibler Divergenz

$$\mathcal{L}(q, \boldsymbol{\theta}) \leq p(\mathbf{X}; \boldsymbol{\theta}).$$

- $\mathcal{L}(q, \boldsymbol{\theta})$ ist also eine untere Schranke für $p(\mathbf{X}; \boldsymbol{\theta})$.

Visualisierung: Zerlegung der Log-Likelihood




Abbildung: Veranschaulichung der Zerlegung (4.4). Siehe [1], Seite 486.

Eine andere Sicht auf den E-Schritt

- Mit dieser Vorarbeit können wir nun die alternative Herleitung des EM-Algorithmus durchführen.
- Im **E-Schritt** wird die untere Schranke $\mathcal{L}(q, \theta_{\text{alt}})$ bezüglich $q(\mathbf{Z})$ bei gegebenem θ_{alt} maximiert, sodass die untere Schranke die eigentliche Zielfunktion $\ln p(\mathbf{X}; \theta)$ in θ_{alt} berührt.
- Da $p(\mathbf{X}; \theta_{\text{alt}})$ nicht von $q(\mathbf{Z})$ abhängt, folgt aus der Maximierung von $\mathcal{L}(q, \theta_{\text{alt}})$, dass $\text{KL}(q \parallel p) = 0$ gelten muss.
- Damit $\text{KL}(q \parallel p) = 0$ gilt, muss wegen (4.8) für $q(\mathbf{Z})$ gelten

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}).$$

- Das heißt, nach dem E-Schritt gilt

$$\mathcal{L}(q, \theta_{\text{alt}}) = \ln p(\mathbf{X}; \theta_{\text{alt}}).$$

Visualisierung: E-Schritt




Abbildung: Veranschaulichung des E-Schritts. Siehe [1], Seite 486.

Eine andere Sicht auf den M-Schritt

- Im darauffolgenden **M-Schritt** halten wir nun die Verteilung $q(\mathbf{Z})$ fest und maximieren die untere Schranke $\mathcal{L}(q, \boldsymbol{\theta})$ bezüglich $\boldsymbol{\theta}$.
- Hierdurch erhalten wir die neuen Parameter $\boldsymbol{\theta}_{\text{neu}}$, die letztendlich zu einer höheren Log-Likelihood $p(\mathbf{X}; \boldsymbol{\theta})$ führen.
- Setzen wir $q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}})$ in die Definition der unteren Schranke (4.5) ein, so erhalten wir

$$\begin{aligned}\mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) - \sum_{\mathbf{Z}} p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \ln p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}_{\text{alt}}) \\ &= Q(\boldsymbol{\theta}, \boldsymbol{\theta}_{\text{alt}}) + \text{const},\end{aligned}$$

wobei const wieder die Entropie von q ist.

Eine andere Sicht auf den M-Schritt (Forts.)

- Um die gegebene untere Schranke zu maximieren, müssen wir also die Funktion $Q(\theta, \theta_{\text{alt}})$ maximieren, wobei Q die **erwartete vollständige Log-Likelihood** ist.
- Damit nimmt der M-Schritt dieselbe Form wie in (4.3) an

$$\theta_{\text{neu}} := \arg \max_{\theta} Q(\theta, \theta_{\text{alt}}).$$

- Weil die Verteilung q im vorhergehenden E-Schritt mit den alten Parametern θ_{alt} bestimmt wurde und diese für den gesamten M-Schritt fixiert wird, gilt

$$q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{alt}}) \neq p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}}),$$

sodass die Kullback-Leibler Divergenz zwischen diesen beiden Verteilung größer als 0 ist.

- Im folgenden E-Schritt setzen wir dann $q(\mathbf{Z}) := p(\mathbf{Z} \mid \mathbf{X}; \theta_{\text{neu}})$ und iterieren weiter.

Visualisierung: M-Schritt




Abbildung: Veranschaulichung des M-Schritts. Siehe [1], Seite 487.

Gaussian Mixture Models und EM

- Wir wenden das allgemeine EM-Framework nun auf GMMs an.
- Im E-Schritt benötigen wir die Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ der latenten Variablen, wobei $\boldsymbol{\theta} := (\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) := (\pi_1, \dots, \pi_K, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_K)$ ist.
- Diese können wir mit (3.4), (3.5) und dem Satz von Bayes bestimmen zu

$$p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta}) \propto \prod_{n=1}^N \prod_{k=1}^K [\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_{nk}}.$$

- Als nächstes stellen wir die erwartete vollständige Log-Likelihood auf, wobei der Erwartungswert bezüglich der Aposteriori-Verteilung $p(\mathbf{Z} \mid \mathbf{X}; \boldsymbol{\theta})$ zu berechnen ist.
- Dazu benötigen wir allerdings noch ein Zwischenergebnis, das wir auf der nächsten Folie bereitstellen.

Gaussian Mixture Models und EM (Forts.)

- Es gilt der Zusammenhang

$$\begin{aligned}\mathbb{E}_{Z \sim p(Z|X;\theta)}[z_{nk}] &= \frac{\sum_{z_n} z_{nk} \prod_{k'=1}^K [\pi_{k'} \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_{k'}, \boldsymbol{\Sigma}_{k'})]^{z_{nk'}}}{\sum_{z_n} \prod_{j=1}^K [\pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)]^{z_{nj}}} \\ &= \frac{\pi_k \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} = \gamma(z_{nk}).\end{aligned}\tag{4.9}$$

- Der Erwartungswert der Indikator-Variablen z_{nk} unter der Aposteriori-Verteilung von Z ergibt sich also gerade als die jeweilige Responsibility $\gamma(z_{nk})$.

Gaussian Mixture Models und EM (Forts.)

Hiermit können wir nun die **erwartete vollständige Log-Likelihood** (Funktion Q) aufstellen

$$\begin{aligned}
 \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X};\theta)}[\ln p(\mathbf{X}, \mathbf{Z}; \theta)] &= \mathbb{E} \left[\ln \prod_{n=1}^N \prod_{k=1}^K \pi_k^{z_{nk}} \cdot \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_{nk}} \right] \\
 &= \mathbb{E} \left[\sum_{n=1}^N \sum_{k=1}^K z_{nk} \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \right] \quad \text{Logarithmengesetze.} \\
 &= \sum_{n=1}^N \sum_{k=1}^K \mathbb{E}[z_{nk}] \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \quad \text{Linearität von } \mathbb{E}. \\
 &= \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \cdot \{\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\} \quad \text{Anwendung von (4.9).}
 \end{aligned} \tag{4.10}$$

Gaussian Mixture Models und EM (Forts.)

- Die Funktion (4.10) müssen wir nun im M-Schritt bezüglich der Parameter maximieren.
- Beispielhaft:** Gradient bezüglich μ_k

$$\begin{aligned}\frac{\partial}{\partial \mu_k} \sum_{n=1}^N \sum_{j=1}^K \gamma(z_{nj}) \cdot \{\ln \pi_j + \ln \mathcal{N}(\mathbf{x}_n; \mu_j, \Sigma_j)\} &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\partial}{\partial \mu_k} \ln \mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k) \\ &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \frac{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)}{\mathcal{N}(\mathbf{x}_n; \mu_k, \Sigma_k)} \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \\ &= \sum_{n=1}^N \gamma(z_{nk}) \cdot \Sigma_k^{-1} (\mathbf{x}_n - \mu_k).\end{aligned}$$

- Vergleiche hierzu die Herleitung in (3.9).

Gaussian Mixture Models und EM (Forts.)

- Nullsetzen und Auflösen nach μ_k ergibt

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \cdot \mathbf{x}_n.$$

- Dies hat dieselbe Form wie (3.10).
- Die anderen Formeln ergeben sich analog.

Kapitel

5 Principal Component Analysis (PCA)

Problemstellung

Orthogonale Projektionen

Maximum-Variance Formulierung der PCA

PCA-Algorithmus

Minimum-Error Formulierung der PCA

Anwendungen der PCA

Problemstellung

- Die **Principal Component Analysis (PCA)** projiziert hochdimensionale Daten *orthogonal* auf einen *linearen Raum* niedriger Dimension.
- Diesen linearen Raum nennt man auch **Principal Subspace**.
- Wir betrachten im Folgenden einen Datensatz $\{\mathbf{x}_n\}$ mit $n = 1, 2, \dots, N$ und $\mathbf{x}_n \in \mathbb{R}^M$.
- Unser Ziel ist die Projektion der Daten in einem Raum der Dimension D , wobei $D \ll M$.
- Für die PCA gibt es verschiedene Ansätze, die zu demselben Ergebnis führen.
- Die bekanntesten sind die **Maximum Variance** Formulierung und die **Minimum Error** Formulierung.
- Zunächst wiederholen wir, was man unter der orthogonalen Projektion von Vektoren versteht.

Visualisierung: Orthogonale Projektionen




Abbildung: Orthogonale Projektion der Daten $\{\mathbf{x}_n\}$ auf die von $\mathbf{u}_1$ definierte Gerade. Siehe [1], Seite 467.

Geometrisches Skalarprodukt

5.1 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$. Es gilt das geometrische Skalarprodukt $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b})$.

Beweis: Für $\|\mathbf{a} - \mathbf{b}\|^2 = (\mathbf{a} - \mathbf{b})^\top (\mathbf{a} - \mathbf{b})$ ergibt sich durch Ausmultiplizieren zum Einen

$$\begin{aligned}\|\mathbf{a} - \mathbf{b}\|^2 &= \mathbf{a}^\top \mathbf{a} - \mathbf{a}^\top \mathbf{b} - \mathbf{b}^\top \mathbf{a} + \mathbf{b}^\top \mathbf{b} \\ &= \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2\mathbf{a}^\top \mathbf{b}\end{aligned}\tag{5.1}$$

und zum Anderen aufgrund des **Kosinussatzes** (Verallgemeinerung des Satzes von Pythagoras) aus der Geometrie

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2 \cdot \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b}).\tag{5.2}$$

Setzt man die Ausdrücke (5.1) und (5.2) für $\|\mathbf{a} - \mathbf{b}\|^2$ gleich, subtrahiert auf beiden Seiten $\|\mathbf{a}\|^2 + \|\mathbf{b}\|^2$ und dividiert durch -2 , so ergibt sich $\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \angle(\mathbf{a}, \mathbf{b})$, die Behauptung. $\square$

Orthogonalität von Vektoren

5.2 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$ verschieden von $\mathbf{0}$. Es gilt $\mathbf{a}^\top \mathbf{b} = 0$ genau dann, wenn $\mathbf{a}$ und $\mathbf{b}$ orthogonal aufeinander stehen.

Beweis: Wenn die Vektoren $\mathbf{a}$ und $\mathbf{b}$ orthogonal, d. h. senkrecht, aufeinander stehen, dann gilt $\cos \angle(\mathbf{a}, \mathbf{b}) = 0$, da die Kosinus-Funktion bei $\pi/2$ (entspricht 90°) eine Nullstelle hat. Mit Satz 5.1 folgt

$$\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\|^2 \cdot \|\mathbf{b}\|^2 \cdot \cos \angle(\mathbf{a}, \mathbf{b}) = \|\mathbf{a}\|^2 \cdot \|\mathbf{b}\|^2 \cdot 0 = 0.$$

Sei nun $\mathbf{a}^\top \mathbf{b} = 0$. Da die Vektoren von $\mathbf{0}$ verschieden sind, muss wegen der Eigenschaften der Norm zwingend $\cos \angle(\mathbf{a}, \mathbf{b}) = 0$ gelten. Die Vektoren stehen also senkrecht aufeinander. Damit gilt die Behauptung. $\square$

Orthogonale Projektion von Vektoren

5.3 Satz: Es seien $\mathbf{a}, \mathbf{b} \in \mathbb{R}^M$. Dann ist die orthogonale Projektion von $\mathbf{b}$ auf $\mathbf{a}$ gegeben durch

$$\text{proj}_{\mathbf{a}} \mathbf{b} = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2} \mathbf{a}.$$

Beweis: Es müssen zwei Bedingungen erfüllt sein. Einerseits ist der Projektionsvektor $\mathbf{p} := \text{proj}_{\mathbf{a}} \mathbf{b}$ der Anteil von $\mathbf{b}$, der in Richtung $\mathbf{a}$ zeigt, sodass dieser eine Stauchung bzw. Streckung von $\mathbf{a}$ ist. Mit $k \in \mathbb{R}$ gilt also

$$\mathbf{p} = k \cdot \mathbf{a}. \quad (5.3)$$

Andererseits soll die Projektion orthogonal sein, d. h. wir wollen den Vektor $\mathbf{p}$ so finden, dass $\mathbf{b} - \mathbf{p}$ senkrecht auf $\mathbf{a}$ steht. Mit Satz 5.2 lautet die Bedingung also

$$(\mathbf{b} - \mathbf{p})^\top \mathbf{a} = 0. \quad (5.4)$$

Einsetzen von (5.3) in (5.4) und auflösen nach k ergibt $(\mathbf{b} - k \cdot \mathbf{a})^\top \mathbf{a} = 0 \iff k = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2}$. Dieses Ergebnis setzen wir in (5.3) ein und erhalten die Behauptung. $\square$

Orthogonale Projektion von Vektoren (Forts.)




Abbildung: Projektion des Vektors $b \in \mathbb{R}^2$ auf den Vektor $a \in \mathbb{R}^2$. Im Kontext der PCA ist der Vektor a der Principal Subspace u_1 und b ist ein Datenpunkt, der auf diesen Raum projiziert wird.

Orthogonale Projektion von Vektoren (Forts.)

- Interessieren wir uns nur für die *Länge des Projektionsvektors*, so betrachten wir seine Norm

$$\|\text{proj}_a \mathbf{b}\| = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|^2} \|\mathbf{a}\| = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|}. \quad (5.5)$$

- Gilt zudem $\|\mathbf{a}\| = 1$ (dann ist $\mathbf{a}$ ein Einheitsvektor), so ergibt sich die Länge des Projektionsvektors einfach als das Skalarprodukt der beteiligten Vektoren

$$\|\text{proj}_a \mathbf{b}\| = \mathbf{a}^\top \mathbf{b}. \quad (5.6)$$

- Wir gehen im Folgenden davon aus, dass die **Principal Components** $\{\mathbf{u}_i\}$ normiert sind.

Maximum-Variance Formulierung

- Im Folgenden betrachten wir den Fall $D = 1$.
- Wir betrachten also nur eine einzelne Principal Component $\mathbf{u}_1$.
- Eine mögliche Formulierung der PCA ist es, die *Varianz der projizierten Daten zu maximieren*.
- Durch die Maximierung der Varianz erhofft man sich den Erhalt eines möglichst großen Anteils der Struktur der Daten.
- Dieses Vorgehen führt auf die **Maximum-Variance Formulierung** der PCA.
- Da $\|\mathbf{u}_1\| = 1$, ist die Projektion eines Datenpunkts $\mathbf{x}_n$ auf $\mathbf{u}_1$ gegeben durch

$$\tilde{x}_n = \mathbf{u}_1^\top \mathbf{x}_n. \quad (5.7)$$

Ziel: Finde $\mathbf{u}_1$ so, dass die Varianz der Projektionen $\{\tilde{x}_n\}$ maximal wird.

Projektion von Mittelwert und Varianz

- Der Mittelwert der projizierten Daten ist analog gegeben durch

$$\mathbf{u}_1^\top \bar{\mathbf{x}}, \quad \text{mit} \quad \bar{\mathbf{x}} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n. \quad (5.8)$$

- Die projizierte Varianz bestimmt man mittels

$$\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1. \quad (5.9)$$

- Hierbei bezeichnet $\mathbf{S}$ die **Streuungsmatrix** der Daten im hochdimensionalen Raum.
- Sie ist gegeben durch

$$\mathbf{S} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^\top. \quad (5.10)$$

Beweis von (5.9)

Wir beweisen Gleichung (5.9):

Beweis: Wir setzen die Projektionen (5.7) und (5.8) in die Definition der Varianz ein und erhalten durch Ausmultiplizieren aufgrund der Symmetrie des Skalarprodukts

$$\begin{aligned}\frac{1}{N} \sum_{n=1}^N (u_1^\top x_n - u_1^\top \bar{x})^2 &= \frac{1}{N} \sum_{n=1}^N (u_1^\top x_n \cdot x_n^\top u_1 - 2 \cdot u_1^\top x_n \cdot \bar{x}^\top u_1 + u_1^\top \bar{x} \cdot \bar{x}^\top u_1) \\&= u_1^\top \left(\frac{1}{N} \sum_{n=1}^N (x_n x_n^\top - 2 \cdot x_n \bar{x}^\top + \bar{x} \bar{x}^\top) \right) u_1 \\&= u_1^\top \left(\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^\top \right) u_1 \\&= u_1^\top S u_1.\end{aligned}$$

Einsetzen von (5.10).

□

Maximierung der projizierten Varianz

- Unser Ziel ist nun die Maximierung der projizierten Varianz $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$ in $\mathbf{u}_1$.
- **Problem:** Dieses Maximierungsproblem ist unbeschränkt.
- Wir können diesen Ausdruck stets vergrößern, indem wir die Komponenten von $\mathbf{u}_1$ vergrößern.
- Um dies zu verhindern, fordern wir, dass $\|\mathbf{u}_1\| = 1$ gilt.

Maximierungsproblem für die PCA:

$$\begin{array}{ll} \text{Maximiere} & \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 \\ \text{unter} & \|\mathbf{u}_1\| = 1. \end{array} \quad (5.11)$$

Maximierung der projizierten Varianz (Forts.)

- Löst man Problem (5.11), so erhält man für $\mathbf{u}_1$ die Bedingung

$$S\mathbf{u}_1 = \lambda_1\mathbf{u}_1. \quad (5.12)$$

- Gleichung (5.12) sagt aus, dass $\mathbf{u}_1$ ein Eigenvektor von S sein muss.
- Der Lagrange-Multiplikator λ_1 ist der zugehörige Eigenwert.

5.4 Aufgabe: Zeigen Sie die Gültigkeit von (5.12), indem Sie das Optimierungsproblem (5.11) lösen. Stellen Sie hierzu die Lagrange-Funktion des Problems auf und finden Sie deren stationären Punkte.

Maximierung der projizierten Varianz (Forts.)

- Multiplizieren wir (5.12) von links mit $\mathbf{u}_1^\top$, so erhalten wir

$$\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1^\top \mathbf{u}_1 = \lambda_1 \|\mathbf{u}_1\|^2 = \lambda_1. \quad (5.13)$$

- Im letzten Gleichheitszeichen haben wir benutzt, dass eine Lösung von (5.11) die Nebenbedingung $\|\mathbf{u}_1\| = 1$ erfüllt.
- Wegen (5.13) ist der Eigenwert λ_1 die Varianz, die durch Projektion der Daten auf $\mathbf{u}_1$ erhalten bleibt.

Lösung für den Fall $D = 1$: Wir berechnen die Eigenzerlegung von $\mathbf{S}$ und benutzen als $\mathbf{u}_1$ einen (normierten) Eigenvektor zum größten Eigenwert. Wegen (5.13) erhält dieser den größten Anteil der Varianz.

Bestimmung weiterer Principal Components

- Die Bestimmung weiterer Principal Components ist einfach.
- Wir benutzen als $\mathbf{u}_2$ einen normierten Eigenvektor von S zum zweitgrößten Eigenwert λ_2 .
- Wir benutzen als $\mathbf{u}_3$ einen normierten Eigenvektor von S zum drittgrößten Eigenwert λ_3 .
- Dies führen wir solange fort, bis wir die vorgegebenen D Komponenten erreicht haben.
- Wir fassen die Vektoren $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_D$ in einer Matrix $V \in \mathbb{R}^{M \times D}$ zusammen.
- Die Projektionen $\tilde{X} \in \mathbb{R}^{N \times D}$ der Daten $X \in \mathbb{R}^{N \times M}$ erhalten wir dann mittels

$$\tilde{X} = XV. \quad (5.14)$$

Orthogonalität der Principal Components

5.5 Satz: Die Principal Components $\{u_i\}$ stehen senkrecht aufeinander.

Beweis: Dies folgt direkt aus der Orthogonalität der Eigenvektoren von symmetrischen Matrizen zu verschiedenen Eigenwerten. Seien also λ_1 und λ_2 mit $\lambda_1 \neq \lambda_2$ zwei voneinander verschiedene Eigenwerte von S . Dann erfüllen diese die Gleichungen $Su_1 = \lambda_1 u_1$ und $Su_2 = \lambda_2 u_2$. Damit gilt

$$(Su_1)^T u_2 = (\lambda_1 u_1)^T u_2 = \lambda_1 u_1^T u_2. \quad (5.15)$$

Außerdem gilt aufgrund der Symmetrie von S und der Tatsache, dass man eine Matrix im Skalarprodukt transponiert auf die andere Seite bringen darf

$$(Su_1)^T u_2 = u_1^T (S^T u_2) = u_1^T (Su_2). \quad (5.16)$$

Nun setzen wir die Eigenwertgleichung in (5.16) ein und erhalten

$$(Su_1)^T u_2 = u_1^T (\lambda_2 u_2) = \lambda_2 u_1^T u_2. \quad (5.17)$$

Setzt man nun (5.15) und (5.16) gleich, so erhält man schlussendlich $(\lambda_1 - \lambda_2) \cdot u_1^T u_2 = 0$. Da $\lambda_1 \neq \lambda_2$ muss $u_1^T u_2 = 0$ gelten. Mit Satz 5.2 folgt die Behauptung. □

PCA-Algorithmus

5.6 Algorithmus

- 1 Bestimme $\bar{x}$ und S gemäß (5.8) beziehungsweise (5.10).
- 2 Berechne die Eigenzerlegung von S , d. h. finde Matrizen U und Λ mit

$$S = U\Lambda U^T.$$

Dabei enthält die Matrix $U \in \mathbb{R}^{M \times M}$ die Eigenvektoren von S . $\Lambda \in \mathbb{R}^{M \times M}$ ist eine Diagonalmatrix mit den Eigenwerten auf der Hauptdiagonalen.

- 3 Normiere die Eigenvektoren, die zu den D größten Eigenwerten gehören und fasse sie in der Matrix $V \in \mathbb{R}^{M \times D}$ zusammen.
- 4 Berechne die Projektionen $\tilde{X} = XV$.

PCA-Algorithmus (Forts.)

5.7 Aufgabe: Es sei der zweidimensionale Datensatz

$$X := \begin{pmatrix} 1 & 4 \\ 4 & 1 \\ 1 & 1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

gegeben. Berechnen Sie die eindimensionalen Projektionen dieses Datensatzes mit dem PCA-Algorithmus.

Minimum-Error Formulierung

- Wir betrachten im Folgenden eine weitere Formulierung der PCA, welche auf der *Minimierung des Projektionsfehlers* basiert, die **Minimum-Error** Formulierung.
- Dazu seien $\{\mathbf{u}_i\}$ mit $i = 1, 2, \dots, M$ *orthonormale Basisvektoren*, d. h.

$$\mathbf{u}_i^\top \mathbf{u}_j = \delta_{ij} \quad \forall i, j. \quad (5.18)$$

- Die Basis $\{\mathbf{u}_i\}$ ist *vollständig*, weshalb sich jedes $\mathbf{x}_n$ *eindeutig* als Linearkombination der $\mathbf{u}_i$ darstellen lässt

$$\mathbf{x}_n = \sum_{i=1}^M \alpha_{ni} \mathbf{u}_i. \quad (5.19)$$

- Dies entspricht einer Drehung des Koordinatensystems.

Minimum-Error Formulierung (Forts.)

- Die Koeffizienten α_{nj} ergeben sich als Projektionen der $\mathbf{x}_n$ auf die $\mathbf{u}_j$.
- Wegen (5.18) ist $\alpha_{nj} = \mathbf{x}_n^\top \mathbf{u}_j$, sodass wir (5.19) schreiben können als

$$\mathbf{x}_n = \sum_{i=1}^M (\mathbf{x}_n^\top \mathbf{u}_i) \mathbf{u}_i. \quad (5.20)$$

- Unser Ziel ist jedoch die Approximation der $\{\mathbf{x}_n\}$ mit einer beschränkten Anzahl von Komponenten $D \ll M$.

Visualisierung: Basiswechsel

Projektionsfehler

- Wir approximieren jeden Datenpunkt $\mathbf{x}_n$ mittels

$$\tilde{\mathbf{x}}_n := \sum_{i=1}^D z_{ni} \mathbf{u}_i + \sum_{i=D+1}^M b_i \mathbf{u}_i. \quad (5.21)$$

- Die $\{z_{ni}\}$ hängen dabei von den Punkten $\{\mathbf{x}_n\}$ ab, die $\{b_i\}$ sind dagegen unabhängig.
- Wir möchten die $\{\mathbf{u}_i\}$, die $\{z_{ni}\}$ und die $\{b_i\}$ so wählen, dass der **Projektionsfehler** minimal wird.
- Diesen definieren wir als die durchschnittliche quadratische Abweichung der $\{\mathbf{x}_n\}$ und den $\{\tilde{\mathbf{x}}_n\}$.

PCA Fehlerfunktion:

$$J := \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2. \quad (5.22)$$

Minimierung des Projektionsfehlers

- Leiten wir (5.22) nach z_{nj} ab und setzen die Ableitung Null, so ergibt sich

$$z_{nj} = \mathbf{x}_n^\top \mathbf{u}_j. \quad (5.23)$$

- Analog erhalten wir für b_j

$$b_j = \bar{\mathbf{x}}^\top \mathbf{u}_j. \quad (5.24)$$

5.8 Aufgabe: Bestätigen Sie die Formeln (5.23) und (5.24) durch Nachrechnen.

Visualisierung: Projektionsfehler

Minimierung des Projektionsfehlers (Forts.)

- Die Ergebnisse (5.23) und (5.24) setzen wir nun in die Definition (5.21) von $\tilde{\mathbf{x}}_n$ ein.
- Zusammen mit der Darstellung (5.20) von $\mathbf{x}_n$ erhalten wir für den Differenzvektor

$$\mathbf{x}_n - \tilde{\mathbf{x}}_n = \sum_{i=D+1}^M \left\{ (\mathbf{x}_n - \bar{\mathbf{x}})^\top \mathbf{u}_i \right\} \mathbf{u}_i. \quad (5.25)$$

- Dies substituieren wir schließlich in die Fehlerfunktion (5.22). Es gilt

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{i=D+1}^M (\mathbf{x}_n^\top \mathbf{u}_i - \bar{\mathbf{x}}^\top \mathbf{u}_i)^2 = \sum_{i=D+1}^M \mathbf{u}_i^\top \mathbf{S} \mathbf{u}_i = \text{trace}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}). \quad (5.26)$$

- Hierbei ist $\hat{\mathbf{U}}$ die Matrix, deren Spalten aus den Vektoren $\mathbf{u}_{D+1}, \dots, \mathbf{u}_M$ besteht.

Minimierung des Projektionsfehlers (Forts.)

- Wir müssen den Ausdruck (5.26) minimieren.
- Wieder muss eine Nebenbedingung eingeführt werden, um nicht das Ergebnis $\mathbf{u}_i = \mathbf{0}$ zu erhalten.
- Die Nebenbedingungen ergeben sich aus der vorausgesetzten *Orthonormalität* (5.18) der $\{\mathbf{u}_i\}$.
- Der Einfachheit halber betrachten wir den Fall $M = 2$ und $D = 1$.
- In diesem Fall erhalten wir die Lagrange-Funktion

$$\mathcal{L} = \mathbf{u}_2^\top \mathbf{S} \mathbf{u}_2 + \lambda_2 (1 - \mathbf{u}_2^\top \mathbf{u}_2). \quad (5.27)$$

- Ableiten nach $\mathbf{u}_2$ und Nullsetzen ergibt $\mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2$, sodass $\mathbf{u}_2$ ein Eigenvektor von $\mathbf{S}$ ist.
- Setzen wir dies in (5.26) ein, so finden wir

$$J = \mathbf{u}_2^\top \mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2^\top \mathbf{u}_2 = \lambda_2 \cdot \|\mathbf{u}_2\|^2 = \lambda_2. \quad (5.28)$$

Minimierung des Projektionsfehlers (Forts.)

- Der Fehler wird in diesem Fall also minimal, wenn man für $\mathbf{u}_2$ einen normalisierten Eigenvektor zum kleineren Eigenwert benutzt.
- Für allgemeines M und D erhält man den minimalen Fehler J , indem man die $\{\mathbf{u}_i\}$ als normierte Eigenvektoren von S wählt.
- Für alle $i = 1, 2, \dots, M$ müssen die $\{\mathbf{u}_i\}$ also erfüllen

$$S\mathbf{u}_i = \lambda_i\mathbf{u}_i. \quad (5.29)$$

- Für den Fehler J gilt dann

$$J = \sum_{i=D+1}^M \lambda_i. \quad (5.30)$$

Minimierung des Projektionsfehlers (Forts.)

Man projiziert die Daten also auf den Raum, welcher durch die D Eigenvektoren zu den größten Eigenwerten aufgespannt wird. Der Fehler ergibt sich dann als die Summe jener Eigenwerte, deren Eigenvektoren nicht für die Projektion benutzt wurden.

Datenkompression




Abbildung: Anwendung der PCA auf einen Datensatz bestehend aus 6.000 Bildern mit 28×28 Pixeln. Positive Werte sind blau, negative Werte gelb dargestellt. Siehe [1], Seite 502.

Datenkompression (Forts.)





Abbildung: (a) Plot des Spektrums der Eigenwerte in absteigender Sortierung. (b) Plot der Summe der verworfenen Eigenwerte (Fehler J). Siehe [1], Seite 503.

Datenkompression (Forts.)




Abbildung: Reduktion eines Elements des Datensatzes auf verschiedene Dimensionen. Bishop benutzt M anstelle von D für die Dimension des Unterraums. Siehe [\[1\]](#), Seite 502.

Kapitel

6 Probabilistische PCA (PPCA)

PPCA Modell

PCA als latent Variable Model

- Wir modellieren die Repräsentation der Daten im Principal Subspace als latente Variablen $z \in \mathbb{R}^D$.
- Für die Verteilung von z gelte

$$z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (6.1)$$

- Zudem führen wir die bedingte Verteilung von $x \in \mathbb{R}^M$ gegeben z wie folgt ein

$$x \mid z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (6.2)$$

- Die Spalten der Matrix $\mathbf{W} \in \mathbb{R}^{M \times D}$ spannen hierbei den Principal Subspace auf.
- Es ist $\boldsymbol{\mu} \in \mathbb{R}^M$.
- Der Parameter σ^2 beeinflusst die Varianz der bedingten Verteilung (6.2).

PPCA als generatives Modell

Die PPCA kann als *generatives Modell* aufgefasst werden:

- Zunächst wählen wir ein z gemäß (6.1).
- Dann ziehen wir die beobachtete Variable x aus der Verteilung (6.2).
- Hierbei ergibt sich der Wert für x gemäß

$$x = Wz + \mu + \varepsilon. \quad (6.3)$$

- $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ ist hierbei *additives normalverteiltes Datenrauschen*, welches durch den Parameter σ^2 in (6.2) beeinflusst wird.

Das Mapping der Daten in den Principal Subspace erhalten wir mit dem Satz von Bayes.

PPCA als generatives Modell




Abbildung: PPCA als generatives Modell. Siehe [2], Seite 572.

Bestimmung der Verbunddichte

- Für die weiteren Ausführungen benötigen wir die Verbunddichte $p(\mathbf{z}, \mathbf{x})$ der beobachteten und latenten Variablen.
- Mit der Produktregel für Wahrscheinlichkeiten ist

$$p(\mathbf{z}, \mathbf{x}) = n(\mathbf{x} | \mathbf{z}) \cdot n(\mathbf{z}). \quad (6.4)$$

- Da es sich bei (6.4) um ein Produkt von Normalverteilungen handelt, sind die Zufallsvariablen auch gemeinsam normalverteilt.
- Es ist also $p(\mathbf{z}, \mathbf{x}) = n(\mathbf{z}, \mathbf{x}; \boldsymbol{\nu}, \boldsymbol{\Sigma})$ beziehungsweise

$$\begin{pmatrix} \mathbf{z} \\ \mathbf{x} \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\nu}, \boldsymbol{\Sigma}). \quad (6.5)$$

Bestimmung der Verbunddichte (Forts.)

Wir bestimmen zunächst den Parameter $\boldsymbol{\nu} = (\boldsymbol{\mu}_z, \boldsymbol{\mu}_x)^\top$:

- Mit der Linearität des Erwartungswerts und den obigen Definitionen – insbesondere die Definitionen (6.1) und (6.3) – gilt

$$\mathbb{E}[\mathbf{z}] = \mathbf{0}$$

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}[\mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\varepsilon}] = \mathbf{W} \underbrace{\mathbb{E}[\mathbf{z}]}_{=\mathbf{0}} + \mathbb{E}[\boldsymbol{\mu}] + \underbrace{\mathbb{E}[\boldsymbol{\varepsilon}]}_{=\mathbf{0}} = \boldsymbol{\mu}.$$

- Zusammenfassend gilt also

$$\boldsymbol{\nu} = \mathbb{E} \left[\begin{pmatrix} \mathbf{z} \\ \mathbf{x} \end{pmatrix} \right] = \begin{pmatrix} \mathbb{E}[\mathbf{z}] \\ \mathbb{E}[\mathbf{x}] \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ \boldsymbol{\mu} \end{pmatrix}. \quad (6.6)$$

Bestimmung der Verbunddichte (Forts.)

Nun bestimmen wir den Parameter $\Sigma = \begin{pmatrix} \Sigma_{zz} & \Sigma_{zx} \\ \Sigma_{xz} & \Sigma_{xx} \end{pmatrix}$:

- Zunächst ist $\Sigma_{zz} = \mathbb{E}[(z - \mathbb{E}[z])(z - \mathbb{E}[z])^\top] = \mathbb{E}[zz^\top] = \mathbb{D}[z] = I$.
- Ferner ist

$$\begin{aligned} \Sigma_{zx} &= \mathbb{E}[(z - \mathbb{E}[z])(x - \mathbb{E}[x])^\top] \\ &= \mathbb{E}[z(Wz + \mu + \varepsilon - \mathbb{E}[Wz + \mu + \varepsilon])^\top] \\ &= \mathbb{E}[z(Wz + \varepsilon)^\top] = \mathbb{E}[zz^\top W^\top + z\varepsilon^\top] = \mathbb{E}[zz^\top]W^\top + \mathbb{E}[z] \cdot \mathbb{E}[\varepsilon^\top] \\ &= W^\top. \end{aligned}$$

- Aus Symmetriegründen gilt $\Sigma_{xz} = W$.

Bestimmung der Verbunddichte (Forts.)

6.1 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{xx} = \mathbf{W}\mathbf{W}^\top + \sigma^2\mathbf{I}$ gilt.

Zusammenfassung: Für die gemeinsame Verteilung von z und x erhalten wir also

$$\begin{pmatrix} z \\ x \end{pmatrix} \sim \mathcal{N}(\nu, \Sigma)$$
$$\nu := \begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix} \tag{6.7}$$
$$\Sigma := \begin{pmatrix} \mathbf{I} & \mathbf{W}^\top \\ \mathbf{W} & \mathbf{W}\mathbf{W}^\top + \sigma^2\mathbf{I} \end{pmatrix}.$$

Woodbury Matrix-Identität

6.2 Satz: Es gilt die **Woodbury Matrix-Identität**

$$(A + BD^{-1}E)^{-1} = A^{-1} - A^{-1}B(D + EA^{-1}B)^{-1}EA^{-1},$$

wobei A , B , D und E Matrizen geeigneter Form sind.

Beweis: Der Beweis erfolgt durch Nachrechnen, indem man beide Seiten der Gleichung mit $A + BD^{-1}E$ multipliziert und die rechte Seite zur Einheitsmatrix umformt. □

Bestimmung des Posteriors

- Für die Anwendung des EM-Algorithmus benötigen wir die Dichte $p(\mathbf{z} \mid \mathbf{x}) = n(\mathbf{z} \mid \mathbf{x}; \boldsymbol{\mu}_{\mathbf{z} \mid \mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{z} \mid \mathbf{x}})$.
- Diese können wir aus der Verbundverteilung (6.7) mittels Satz ?? berechnen.
- Zunächst definieren wir zwei Matrizen, die wir häufig benötigen werden

$$\mathbf{C} := \sigma^2 \mathbf{I} + \mathbf{W}\mathbf{W}^\top \quad (6.8)$$

$$\mathbf{M} := \sigma^2 \mathbf{I} + \mathbf{W}^\top \mathbf{W}. \quad (6.9)$$

- Außerdem benötigen wir $\mathbf{C}^{-1}$, für deren Berechnung wir die Woodbury Identität aus 6.2 benutzen, wobei wir $\mathbf{A} = \sigma^2 \mathbf{I}$, $\mathbf{B} = \mathbf{W}$, $\mathbf{D} = \mathbf{I}$ und $\mathbf{E} = \mathbf{W}^\top$ setzen (siehe nächste Folie).

Bestimmung des Posteriors (Forts.)

Es ist

$$\begin{aligned}
 \mathbf{C}^{-1} &= (\sigma^2 \mathbf{I} + \mathbf{W}\mathbf{W}^\top)^{-1} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{I} \mathbf{W} (\mathbf{I} + \mathbf{W}^\top \sigma^{-2} \mathbf{I} \mathbf{W})^{-1} \mathbf{W}^\top \sigma^{-2} \mathbf{I} && \text{Woodbury Identität, Satz 6.2.} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \left[\sigma^{-2} (\sigma^2 \mathbf{I} + \mathbf{W}^\top \mathbf{W}) \right]^{-1} \sigma^{-2} \mathbf{W}^\top && \text{In der Klammer } \sigma^{-2} \text{ ausklammern.} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \left[\sigma^{-2} \mathbf{M} \right]^{-1} \sigma^{-2} \mathbf{W}^\top && \text{Definition (6.9).} \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \sigma^2 \mathbf{M}^{-1} \sigma^{-2} \mathbf{W}^\top && \text{Für } \mathbf{A} \text{ und } \mathbf{B} \text{ gilt } (\mathbf{A}\mathbf{B})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}. \\
 &= \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^\top. && \sigma^{-2} \sigma^2 = 1.
 \end{aligned} \tag{6.10}$$

Bestimmung des Posteriors (Forts.)

In den weiteren Rechnungen brauchen wir auch noch einen Ausdruck für $\mathbf{W}^\top \mathbf{C}^{-1}$. Hierzu multiplizieren wir (6.10) von links mit $\mathbf{W}^\top$

$$\begin{aligned}
 \mathbf{W}^\top \mathbf{C}^{-1} &= \sigma^{-2} \mathbf{W}^\top - \sigma^{-2} \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^\top. \\
 &= \sigma^{-2} (\mathbf{I} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \sigma^{-2} \text{ und } \mathbf{W}^\top \text{ ausklammern.} \\
 &= \sigma^{-2} (\mathbf{M} \mathbf{M}^{-1} - \mathbf{W}^\top \mathbf{W} \mathbf{M}^{-1}) \mathbf{W}^\top && \text{Es ist } \mathbf{I} = \mathbf{M} \mathbf{M}^{-1}. \\
 &= \sigma^{-2} (\mathbf{M} - \mathbf{W}^\top \mathbf{W}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Wir klammern } \mathbf{M}^{-1} \text{ aus.} \\
 &= \sigma^{-2} (\sigma^2 \mathbf{I}) \mathbf{M}^{-1} \mathbf{W}^\top && \text{Aus (6.9) folgt } \mathbf{M} - \mathbf{W}^\top \mathbf{W} = \sigma^2 \mathbf{I}. \\
 &= \mathbf{M}^{-1} \mathbf{W}^\top.
 \end{aligned} \tag{6.11}$$

Bestimmung des Posteriors (Forts.)

- Nun haben wir alles zusammen, um den Posterior mit Satz ?? auszurechnen.
- Wir beginnen mit dem bedingten Erwartungswert $\mu_{z|x}$

$$\begin{aligned}\mu_{z|x} &= \mu_z + \Sigma_{zx}\Sigma_{xx}^{-1}(x - \mu_x) \\ &= \mathbf{0} + \mathbf{W}^\top(\mathbf{W}\mathbf{W}^\top + \sigma^2\mathbf{I})^{-1}(x - \mu) \\ &= \mathbf{W}^\top\mathbf{C}^{-1}(x - \mu) && \text{Definition (6.8)} \\ &= \mathbf{M}^{-1}\mathbf{W}^\top(x - \mu). && \text{Ausdruck aus (6.11)}\end{aligned}\tag{6.12}$$

6.3 Aufgabe: Zeigen Sie durch analoge Rechnung, dass $\Sigma_{z|x} = \sigma^2\mathbf{M}^{-1}$ gilt.

Bestimmung des Posteriors (Forts.)

Zusammenfassung: Wir erhalten damit

$$z \mid x \sim \mathcal{N}(\mathbf{M}^{-1}\mathbf{W}^{\top}(\mathbf{x} - \boldsymbol{\mu}), \sigma^2\mathbf{M}^{-1}). \quad (6.13)$$

Bemerkung: Dasselbe Ergebnis erhält man, wenn man den Satz von Bayes 1.22 auf $z \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ und $x \mid z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2\mathbf{I})$ anwendet.

Bemerkung: In (6.13) kommt die Matrix $\mathbf{C}^{-1} \in \mathbb{R}^{M \times M}$ nicht mehr vor. Stattdessen müssen wir nun die Matrix $\mathbf{M}^{-1} \in \mathbb{R}^{D \times D}$ invertieren, was einfacher ist, da in der Regel $D \ll M$ ist.

Kapitel

7 Independent Component Analysis (ICA)

Motivation: Cocktail Party Problem

Formalisierung des Problems

Annahmen und Limitationen der ICA

Whitening

ICA durch Maximum Likelihood Schätzung

Cocktail Party Problem

Zur Motivation betrachten wir das folgende Problem:

- Auf einer Party sprechen N Personen gleichzeitig.
- Im Raum werden Mikrofone aufgestellt, welche *überlappende Kombinationen* der Stimmen der Sprecher aufzeichnen.
- Der Einfachheit halber nehmen wir an, dass sich ebenfalls N Mikrofone im Raum befinden.
- Da die Entfernung der Sprecher zu den einzelnen Mikrofonen verschieden ist, handelt es sich hierbei um leicht *verschiedene Kombinationen*.

Frage: Können wir die Stimmen der N Sprecher aus den N Aufzeichnungen isolieren?

Beispiel: Cocktail Party Problem

tbd

Mathematische Formulierung des Problems

- Es seien die Signale $s_t \in \mathbb{R}^N$ gegeben, welche von N *unabhängigen (!)* Quellen zum Zeitpunkt $t = 1, 2, \dots, T$ erzeugt werden (das sind die Sprecher im Cocktail Party Problem).
- Allerdings beobachten wir nur die gemischten Daten $x_t \in \mathbb{R}^N$ zum Zeitpunkt t (das sind die Aufnahmen der Mikrofone).
- Das ICA-Modell nimmt an, dass es sich hierbei um *Linearkombinationen* der Quellsignale handelt.
- Wir betrachten also das Modell

$$x_t = A s_t, \tag{7.1}$$

wobei $A \in \mathbb{R}^{N \times N}$ die **Mixing Matrix** ist. Diese besteht aus den Koeffizienten der Linearkombinationen.

Mathematische Formulierung des Problems (Forts.)

- Unser Ziel ist es, die Quellsignale s aus den beobachteten Mischsignalen x zu rekonstruieren.
- Wäre A bekannt, so könnten wir in den meisten Fällen (falls die Inverse von A existiert)

$$s = A^{-1}x$$

berechnen und wären fertig.

- In der Regel ist A unbekannt, wodurch das Problem deutlich schwerer wird.
- Wir definieren die **Unmixing Matrix** $W := A^{-1}$.
- Mithilfe des ICA-Verfahrens werden wir diese Matrix approximieren. Mit ihr können wir dann die Quellsignale bestimmen, indem wir $s = Wx$ berechnen.

Annahmen des Verfahrens

Die folgenden Annahmen sind wesentlich für das ICA-Verfahren:

- 1 **Zentrale Annahme:** Die Quellsignale (ICs: Independent Components) sind *stochastisch unabhängig*.
- 2 Die ICs sind *nicht normalverteilt* (dazu später mehr).
- 3 Die Mixing Matrix A ist quadratisch. Es gibt allerdings Verallgemeinerungen der ICA, die auch rechteckige Matrizen erlauben. Wir machen diese Annahme hier, da das Problem selbst in diesem vereinfachten Fall schon schwer genug ist.

Im Cocktail Party Problem bedeutet Annahme 3, dass es genauso viele Mikrophone wie Personen gibt.

Limitationen des Verfahrens

Es gibt eine Reihe von Einschränkungen (*unidentifiabilities*) bei der Rekonstruktion der Quellsignale:

- 1 Die ursprüngliche *Reihenfolge* der Signale kann nicht rekonstruiert werden. Sei dazu P eine *Permutationsmatrix*. Dann ist $\mathbf{x} = \mathbf{A}\mathbf{s} = \mathbf{A}P^{-1}\mathbf{P}\mathbf{s}$, wobei $\mathbf{P}\mathbf{s}$ die permutierten Quellsignale sind. $\mathbf{A}P^{-1}$ ist lediglich eine neue zu schätzende Mixing Matrix. Wir können folglich kein Signal *das erste* Quellsignal nennen.
- 2 Die *Skalierung* der Quellsignale kann nicht wiederhergestellt werden (im Cocktail Party Problem entspricht dies der Lautstärke/Amplitude der Signale), wie man sich leicht überlegt:
Sei dazu $\alpha \in \mathbb{R}$, dann gilt

$$\mathbf{x} = \mathbf{A}\mathbf{s} = \alpha\mathbf{A} \cdot \frac{1}{\alpha}\mathbf{s}.$$

- 3 Normalverteilte Signale können nicht aufgetrennt werden.

Warum sind Normalverteilungen verboten?

- Wir betrachten ein Beispiel mit $N = 2$ und $s \sim N_{\mathbf{0}, I}$.
- Die Konturlinien der Standardnormalverteilung sind perfekte Kreise, die auf dem Koordinatenursprung zentriert sind.
- Insbesondere ist die Dichte **rotationsinvariant**.
- Für $\mathbf{x} = \mathbf{A}s$ gilt damit: $\mathbf{x} \sim N_{\mathbf{0}, \mathbf{A}\mathbf{A}^\top}$.

Beweis: Mit der Linearität des Erwartungswerts gilt $\mathbb{E}_s[\mathbf{x}] = \mathbb{E}_s[\mathbf{A}s] = \mathbf{A}\mathbb{E}_s[s] = \mathbf{0}$. Die Streuungsmatrix ist

$$\begin{aligned}\mathbb{D}[\mathbf{x}] &= \mathbb{E}_s[\mathbf{x}\mathbf{x}^\top] = \mathbb{E}_s[\mathbf{A}s s^\top \mathbf{A}^\top] = \mathbf{A}\mathbb{E}[ss^\top]\mathbf{A}^\top = \mathbf{A} \cdot \mathbb{D}[s] \cdot \mathbf{A}^\top \\ &= \mathbf{A}\mathbf{A}^\top.\end{aligned}$$

Also gilt die Behauptung. □

Warum sind Normalverteilungen verboten? (Forts.)

- Sei nun $\mathbf{R} \in \mathbb{R}^{N \times N}$ eine beliebige *orthogonale Matrix*.

Eigenschaften orthogonaler Matrizen:

- Orthogonale Matrizen beschreiben eine Drehung/Spiegelung im Raum.
- Es gilt stets $\mathbf{R}\mathbf{R}^\top = \mathbf{R}^\top\mathbf{R} = \mathbf{I}$. Es ist also $\mathbf{R}^{-1} = \mathbf{R}^\top$.
- Es ist $\det \mathbf{R} = 1$ für alle orthogonalen Matrizen $\mathbf{R}$.
- Da $\mathbf{R}$ nur eine Drehung beschreibt, gilt für alle $\mathbf{x} \in \mathbb{R}^N$ die Identität $\|\mathbf{R}\mathbf{x}\| = \|\mathbf{x}\|$.
- Sei ferner $\tilde{\mathbf{A}} := \mathbf{A}\mathbf{R}$ die Matrix, welche mit der von $\mathbf{R}$ beschriebenen Drehung aus $\mathbf{A}$ hervorgeht.
- Dann hat der Vektor $\tilde{\mathbf{x}} = \tilde{\mathbf{A}}\mathbf{s}$ dieselbe Verteilung wie $\mathbf{x}$.

Beweis: Den Erwartungswert rechnet man analog zu oben aus. Aufgrund der Orthogonalität von $\mathbf{R}$ gilt

$$\mathbb{E}_s[\tilde{\mathbf{x}}\tilde{\mathbf{x}}^\top] = \mathbb{E}_s[\tilde{\mathbf{A}}\mathbf{s}\mathbf{s}^\top\tilde{\mathbf{A}}^\top] = \mathbb{E}_s[\mathbf{A}\mathbf{R}\mathbf{s}\mathbf{s}^\top\mathbf{R}^\top\mathbf{A}^\top] = \mathbf{A}\mathbf{R} \cdot \mathbb{D}[\mathbf{s}] \cdot \mathbf{R}^\top\mathbf{A}^\top = \mathbf{A}\mathbf{R}\mathbf{R}^\top\mathbf{A} = \mathbf{A}\mathbf{A}^\top,$$

sodass $\tilde{\mathbf{x}} \sim N_{\mathbf{0}, \mathbf{A}\mathbf{A}^\top}$ wie behauptet gilt. □

Warum sind Normalverteilungen verboten? (Forts.)

- Wie die voranstehenden Ausführungen zeigen, können wir in diesem Fall nicht rekonstruieren, ob die Daten mit der Matrix A oder $\tilde{A}$ gemixt wurden.
- Für normalverteilte Daten können wir folglich die Komponenten *nur bis auf eine Drehung rekonstruieren*.

Ein einfaches Beispiel

Wir betrachten ein einfaches zweidimensionales Beispiel für den Fall, dass die Quellsignale s_1 und s_2 gleichverteilt sind:

$$p(s_i) := \begin{cases} \frac{1}{2\sqrt{3}} & \text{wenn } |s_i| \leq \sqrt{3} \\ 0 & \text{sonst} \end{cases}$$

Bemerkungen:

- Der Erwartungswert der Zufallsvariablen s_i ($i = 1, 2$) ist jeweils 0.

Beweis: Für die Gleichverteilung gilt $\mathbb{E}[s_i] = \frac{-\sqrt{3} + \sqrt{3}}{2} = 0$ (siehe Tabelle im Kapitel 'Statistik'). □

- Die Varianzen sind jeweils 1.

Beweis: Es ist $\mathbb{V}[s_i] = \frac{(\sqrt{3} + \sqrt{3})^2}{12} = \frac{(2\sqrt{3})^2}{12} = \frac{12}{12} = 1$ (siehe Tabelle im Kapitel 'Statistik'). □

Ein einfaches Beispiel (Forts.)




Abbildung: Gemeinsame Verteilung der unabhängigen Komponenten s_1 (horizontal) und s_2 (vertikal). Siehe [3], Seite 155.

Ein einfaches Beispiel (Forts.)




Abbildung: Gemeinsame Verteilung der gemischten/beobachteten Komponenten x_1 (horizontal) und x_2 (vertikal) nach Anwendung der Matrix $A := \begin{pmatrix} 5 & 10 \\ 10 & 2 \end{pmatrix}$.

Whitening

Whitening wird häufig vor dem eigentlichen ICA-Algorithmus angewendet:

7.1 Definition: **Whitening** bezeichnet eine *lineare Transformation* V , bei der zentrierte Zufallsvariablen $\mathbf{x} \in \mathbb{R}^N$ (zentriert bedeutet $\mathbb{E}[\mathbf{x}] = \mathbf{0}$) so zu neuen Zufallsvariablen $\mathbf{z} := V\mathbf{x} \in \mathbb{R}^N$ transformiert werden, dass $\mathbb{D}[\mathbf{z}] = \mathbb{E}[\mathbf{z}\mathbf{z}^\top] = \mathbf{I}$ gilt.

In Worten bedeutet dies, dass die Komponenten von $\mathbf{z}$ untereinander unkorreliert und die Varianzen jeweils Eins sind, also

$$\mathbb{E}[z_i z_j] = \delta_{ij},$$

wobei $\delta_{ij} := \begin{cases} 1 & \text{falls } i = j \\ 0 & \text{falls } i \neq j \end{cases}$ das **Kronecker-Delta** bezeichnet.

Whitening (Forts.)

- Eine solche lineare Transformation ist z. B. gegeben durch $V := D^{-\frac{1}{2}} E^T$, wobei $E \in \mathbb{R}^{N \times N}$ eine orthogonale Matrix ist, deren Spalten aus *normalisierten Eigenvektoren* von $\mathbb{D}[x]$ bestehen und $D := \text{diag}(d_1, d_2, \dots, d_N) \in \mathbb{R}^{N \times N}$ eine Diagonalmatrix mit den zugehörigen *Eigenwerten* ist.

Beweis: Wir rechnen nach, dass die Kovarianzmatrix von $z = Vx$ tatsächlich die Einheitsmatrix ist. Da $\mathbb{E}[xx^T]$ in praktischen Anwendungsfällen in der Regel positiv definit ist, gilt $\mathbb{E}[xx^T] = EDE^T$. Damit gilt tatsächlich

$$\mathbb{E}[zz^T] = \mathbb{E}[Vxx^T V^T] = V\mathbb{E}[xx^T]V^T = D^{-\frac{1}{2}} E^T E D E^T E D^{-\frac{1}{2}} = I.$$

□

- Aus der Zentriertheit von x folgt, dass auch z zentriert ist.

Beweis: Wieder mit der Linearität des Erwartungswerts gilt $\mathbb{E}[z] = \mathbb{E}[Vx] = V\mathbb{E}[x] = \mathbf{0}$.

□

Fortsetzung des Beispiels




Abbildung: Gemeinsame Verteilung der Komponenten z_1 (horizontal) und z_2 (vertikal) nach dem Whitening.

Whitening löst bereits das halbe Problem

- Wir nehmen im Folgenden an, dass bereits ein Whitening stattgefunden hat.
- Whitening transformiert die Mixing Matrix A in eine neue Matrix $\tilde{A}$, denn

$$\mathbf{z} = V\mathbf{x} = V\mathbf{A}\mathbf{s} = \tilde{A}\mathbf{s}.$$

- Man könnte nun hoffen, dass Whitening das Problem bereits löst, da Unkorreliertheit und Unabhängigkeit verwandt sind. **Dem ist jedoch nicht so!**
- Sei dazu U eine orthogonale Matrix und $\mathbf{y} := U\mathbf{z}$.
- Aufgrund der Orthogonalität von U gilt

$$\mathbb{E}[\mathbf{y}\mathbf{y}^T] = \mathbb{E}[U\mathbf{y}\mathbf{y}^T U^T] = U\mathbf{I}U^T = \mathbf{I}.$$

Somit ist auch $\mathbf{y}$ white. Die Komponenten sind durch Whitening nur bis auf eine Drehung eindeutig!

Whitening als Vorverarbeitungsschritt

- Die Whitening Operation eignet sich jedoch sehr gut als Vorverarbeitungsschritt, denn durch sie wird die Mixing Matrix $\tilde{A} = VA$ orthogonal.

Beweis: Da die Daten z white sind, gilt $\mathbb{E}[zz^T] = I$. Es gilt aber auch

$$\mathbb{E}[zz^T] = \mathbb{E}[\tilde{A}ss^T\tilde{A}^T] = \tilde{A}\tilde{A}^T.$$

Also gilt $\tilde{A}\tilde{A}^T = I$, woraus die Orthogonalität von $\tilde{A}$ folgt. □

- Das heißt wir können uns bei der Suche nach der Mixing Matrix **auf orthogonale Matrizen beschränken!**
- Eine orthogonale $N \times N$ Matrix hat nur $N(N-1)/2$ Freiheitsgrade (im Gegensatz zu N^2 Freiheitsgraden für die ursprüngliche Matrix), z. B. wird eine zweidimensionale orthogonale Matrix eindeutig durch den Winkel der Drehung beschrieben.

Warum Normalverteilungen verboten sind!

- Durch Whitening können wir eine weitere Begründung dafür angeben, warum Normalverteilungen verboten sind.
- Wir nehmen an, dass die gemeinsame Verteilung der Quellsignale s_1 und s_2 durch eine Normalverteilung beschrieben werden:

$$p(s_1, s_2) = \frac{1}{2\pi} \exp\left(-\frac{s_1^2 + s_2^2}{2}\right) = \frac{1}{2\pi} \exp\left(-\frac{\|\mathbf{s}\|^2}{2}\right)$$

- Die Mixing Matrix A kann als orthogonal angenommen werden, da die Daten x als white vorausgesetzt sind.

Warum Normalverteilungen verboten sind! (Forts.)

Mit dem Transformationssatz ?? für Dichten erhalten wir daraus die Verteilung von x_1 und x_2 :

$$p(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{\|\mathbf{A}^{-1}\mathbf{x}\|^2}{2}\right) |\det \mathbf{A}^{-1}|$$

$$= \frac{1}{2\pi} \exp\left(-\frac{\|\mathbf{A}^\top \mathbf{x}\|^2}{2}\right) |\det \mathbf{A}^\top|$$

Aufgrund der Orthogonalität gilt $\mathbf{A}^{-1} = \mathbf{A}^\top$.

$$= \frac{1}{2\pi} \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right)$$

Aufgrund der Orthogonalität gilt $\|\mathbf{A}^\top \mathbf{x}\| = \|\mathbf{x}\|$ und $\det \mathbf{A}^\top = 1$.

Warum Normalverteilungen verboten sind! (Forts.)

- Wir sehen also, dass die Dichte der Quellsignale und der gemischten Signale identisch ist.
- Damit haben wir keine Chance, die Mixing Matrix aus den Daten zu schätzen.

Warum Normalverteilungen verboten sind! (Forts.)




Abbildung: Gemeinsame Verteilung der Komponenten s_1 (horizontal) und s_2 (vertikal) bei Annahme einer Normalverteilung.

ICA Lösungsverfahren

Es gibt verschiedene Ansätze mit denen man die unabhängigen Komponenten bestimmen kann:

- ① Maximierung der Likelihood Funktion.
- ② Maximierung der *Non-Gaussianity*: Finde die unabhängigen Komponenten so, dass deren Verteilung maximal nicht-normal ist.
 - Basiert auf dem **zentralen Grenzwertsatz**: Eine Summe unabhängiger Zufallsvariablen ist (unter gewissen Voraussetzungen) zunehmend normalverteilt.
 - Hierzu muss man eine Maßzahl finden, welche die Nicht-Normalität einer Verteilung misst.
 - Beispiele: **Kurtosis**, **Negentropy**
- ③ Minimierung der Mutual Information.

ICA Likelihood Funktion

Wir leiten im Folgenden die Likelihood Funktion für die ICA her:

- Da die Komponenten s_n *stochastisch unabhängig* sind, finden wir deren gemeinsame Dichte als *Produktdichte* der Komponenten

$$p_s(s) = \prod_{n=1}^N p_n(s_n).$$

- Wir müssen dies allerdings mittels der beobachteten Daten $\mathbf{x} = \mathbf{A}\mathbf{s}$ ausdrücken, da $\mathbf{s}$ *latent* ist. Hierzu benutzen wir den Transformationssatz ?? und erhalten mit $\mathbf{s} = \mathbf{A}^{-1}\mathbf{x} = \mathbf{W}\mathbf{x}$ und $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_N)^\top$ die Dichte von $\mathbf{x}$ als

$$p_{\mathbf{x}}(\mathbf{x}) = |\det \mathbf{W}| \cdot \prod_{n=1}^N p_n((\mathbf{w}_n)^\top \mathbf{x}). \quad (7.2)$$

ICA Likelihood Funktion (Forts.)

- Wir nehmen nun an, dass wir T Beobachtungen $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T$ von $\mathbf{x}$ haben.
- Die Likelihood Funktion ergibt sich als das Produkt der Dichte in (7.2) über die T Beobachtungen

$$L(\mathbf{W}) = \prod_{t=1}^T \left(|\det \mathbf{W}| \cdot \prod_{n=1}^N p_n((\mathbf{w}_n)^\top \mathbf{x}_t) \right) = |\det \mathbf{W}|^T \cdot \prod_{t=1}^T \prod_{n=1}^N p_n((\mathbf{w}_n)^\top \mathbf{x}_t).$$

- Im Folgenden betrachten wir die Log-Likelihood Funktion

$$\begin{aligned} l(\mathbf{W}) &= \ln \left(|\det \mathbf{W}|^T \cdot \prod_{t=1}^T \prod_{n=1}^N p_n((\mathbf{w}_n)^\top \mathbf{x}_t) \right) = \ln |\det \mathbf{W}|^T + \ln \left(\prod_{t=1}^T \prod_{n=1}^N p_n((\mathbf{w}_n)^\top \mathbf{x}_t) \right) \\ &= T \cdot \ln |\det \mathbf{W}| + \sum_{t=1}^T \sum_{n=1}^N \ln p_n((\mathbf{w}_n)^\top \mathbf{x}_t). \end{aligned}$$

Festlegung der Dichte der Quellsignale

- Um die Likelihood Funktion optimieren zu können, müssen wir noch die Dichten $p_n(s_n)$ ($n = 1, 2, \dots, N$) für die Quelldaten festlegen.
- Bei der Wahl dürfen wir aufgrund obiger Ausführungen *keine Normalverteilungen* verwenden.
- Aufgrund der Ähnlichkeit zur Normalverteilung schlägt [4] die **logistische Verteilung** vor.
- Die Verteilungsfunktion (CDF) ist folgendermaßen definiert:

$$F(s_0) = p(s \leq s_0) = \frac{1}{1 + e^{-s_0}} =: \sigma(s)$$

- Damit ergibt sich für die Dichte $p_n(s_n) = \sigma'(s) = \sigma(s) \cdot (1 - \sigma(s))$ und für die Log-Likelihood

$$T \cdot \ln |\det \mathbf{W}| + \sum_{t=1}^T \sum_{n=1}^N \ln \sigma'((\mathbf{w}_n)^\top \mathbf{x}_t).$$

Bestimmung des Gradienten

7.2 Satz: Es sei $\mathbf{W} \in \mathbb{R}^{N \times N}$. Dann ist $\frac{\partial}{\partial \mathbf{W}} \det \mathbf{W} = (\mathbf{W}^\top)^{-1} \det \mathbf{W}$.

Beweis: Mit dem Adjunktensatz der linearen Algebra gilt $\mathbf{W}^{-1} = \frac{1}{\det \mathbf{W}} \text{adj}(\mathbf{W})$. Hierbei bezeichnet $\text{adj}(\mathbf{W}) = (W_{ij})_{i,j=1,2,\dots,N}$ die zu $\mathbf{W}$ **adjungierte Matrix**. Die **Kofaktoren** W_{ij} erhält man, indem man die Determinante der $(N-1) \times (N-1)$ Untermatrix von $\mathbf{W}$ berechnet, die aus der Streichung der i -ten Zeile und j -ten Spalte von $\mathbf{W}$ hervorgeht. Dieses Ergebnis muss schließlich noch mit $(-1)^{i+j}$ multipliziert werden.

Die Determinante kann nun in Form der Kofaktoren ausgedrückt werden (Stichwort: **Entwicklungssatz von Laplace**). Wir erhalten

$$\det \mathbf{W} = \sum_{k=1}^N w_{ik} W_{ik}$$

Zeile i kann dabei beliebig gewählt werden. Entscheidend ist nun, dass die Kofaktoren per Definition nicht von den Einträgen der Zeile i der Matrix abhängen, sodass die Determinante eine lineare Funktion dieser Einträge ist. Wir erhalten damit $\frac{\partial \det \mathbf{W}}{\partial w_{ij}} = W_{ij}$ und schließlich $\frac{\partial \det \mathbf{W}}{\partial \mathbf{W}} = \text{adj}(\mathbf{W})^\top = (\mathbf{W}^\top)^{-1} \det \mathbf{W}$. Die letzte Gleichung gilt dabei wegen des Adjunktensatzes. $\square$

Bestimmung des Gradienten (Forts.)

Mit diesem Ergebnis können wir nun eine einfache Regel für den stochastischen Gradientenaufstieg angeben:

- Sei dazu ein Trainingsbeispiel $\mathbf{x} \in \mathbb{R}^N$ und die Lernrate $\alpha \in \mathbb{R}$ gegeben.
- Die Update-Regel lautet dann

$$\mathbf{W}^{\text{neu}} := \mathbf{W} + \alpha \begin{bmatrix} 1 - 2\sigma((\mathbf{w}_1)^\top \mathbf{x}) \\ 1 - 2\sigma((\mathbf{w}_2)^\top \mathbf{x}) \\ \vdots \\ 1 - 2\sigma((\mathbf{w}_N)^\top \mathbf{x}) \end{bmatrix} \mathbf{x}^\top + (\mathbf{W}^\top)^{-1}. \quad (7.3)$$

Bestimmung des Gradienten (Forts.)

Beweis:



Literatur

- [1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: <https://www.bishopbook.com/>.
- [2] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>.
- [3] Aapo Hyvärinen. *Independent Component Analysis*. 2001. URL: https://www.cs.helsinki.fi/u/ahyvarin/papers/bookfinal_ICA.pdf.
- [4] Andrew Ng. *CS229 Lecture Notes*. 2023. URL: https://cs229.stanford.edu/main_notes.pdf.