

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

M.Sc. Daniel Wehner

DHBW Center of Advanced Studies (CAS) Heilbronn

Sommersemester 2027

① Grundlagen der Statistik

② Regression

Kapitel

1 Grundlagen der Statistik

Grundbegriffe der Wahrscheinlichkeitstheorie

Transformationssatz

Multivariate Normalverteilung

Maximum-Likelihood Schätzer

Maximum-Aposteriori Schätzer

Bayes'sche Inferenz

Wahrscheinlichkeitsräume

Wir definieren zunächst, was man unter einem **Wahrscheinlichkeitsraum** versteht.

- Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{A}, \mathbb{P})$.
- Ω ist der **Ereignisraum**, also die Menge aller Elementarereignisse. Beim Werfen eines sechsseitigen Würfels betrachten wir $\Omega := \{1, 2, 3, 4, 5, 6\}$.
- Mit $\mathcal{A}$ bezeichnen wir die zugehörige **Sigma-Algebra**, eine Menge von Teilmengen von Ω . Im einfachsten Fall könnten wir $\mathcal{A} := \text{Pot}(\Omega)$ wählen, jedoch kann man zeigen, dass die Potenzmenge im Allgemeinen nicht messbare Mengen enthält, denen keine Wahrscheinlichkeit zugeordnet werden kann. Die Sigma-Algebra $\mathbb{B}$ auf $\mathbb{R}$ heißt **Borel-Sigma-Algebra**.
- $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ ist ein **Wahrscheinlichkeitsmaß**, das jedem Element aus $\mathcal{A}$ eine Wahrscheinlichkeit zuordnet.

Zufallsvariablen

Im Folgenden sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{B})$ ein messbarer Raum.

1.1 Definition: Die Abbildung $X : \Omega \rightarrow \mathcal{X}$ heißt **Zufallsvariable**, falls

$$\forall B \in \mathcal{B} : X^{-1}(B) := \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}$$

gilt. Das Urbild von B unter X muss also eine messbare Menge in $\mathcal{A}$ sein, der durch $\mathbb{P}$ eine Wahrscheinlichkeit zugeordnet werden kann. Ferner heißt für jede Zufallsvariable $X : \Omega \rightarrow \mathcal{X}$ die Funktion

$$\mathbb{P}^X : \mathcal{B} \rightarrow [0, 1] \quad \text{mit} \quad B \mapsto \mathbb{P}(X^{-1}(B))$$

die **Verteilung** der Zufallsvariable X . $\mathbb{P}^X$ ist das **Bildmaß** von $\mathbb{P}$ unter X .

Zufallsvariablen (Forts.)

Sei $(\mathcal{X}, \mathcal{B}, \mathbb{Q})$ ein Wahrscheinlichkeitsraum. Man sagt, die Zufallsgröße $X : \Omega \rightarrow \mathcal{X}$ ist *verteilt gemäß $\mathbb{Q}$* oder kurz *$\mathbb{Q}$ -verteilt*, falls es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\mathbb{P}^X = \mathbb{Q}$ gilt.

Beispiel: X ist $\mathcal{N}(\mu, \sigma^2)$ -verteilt genau dann, wenn es einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ gibt, sodass $\forall B \in \mathbb{B} : \mathbb{P}(X \in B) = \mathcal{N}(B; \mu, \sigma^2)$. Wir schreiben kurz $X \sim \mathcal{N}(\mu, \sigma^2)$.

Wahrscheinlichkeitsdichten

1.2 Definition: Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{B}, \mathbb{P}^X)$ Wahrscheinlichkeitsräume. Dabei ist $\mathbb{P}^X$ die Verteilung der Zufallsvariablen $X : \Omega \rightarrow \mathcal{X}$. Wir nennen eine nichtnegative Funktion

$$p_X : \mathbb{R} \rightarrow [0, \infty)$$

eine **(Wahrscheinlichkeits-)Dichte** von $\mathbb{P}^X$, falls

$$\mathbb{P}^X(B) = \int_B p_X(\xi) \, d\xi \quad \forall B \in \mathcal{B}.$$

Bemerkung: Die Wahrscheinlichkeiten der Mengen $B \in \mathcal{B}$ müssen sich also allesamt als Integral der Dichte p_X darstellen lassen können.

Erwartungswert von Zufallsvariablen

1.3 Definition: Sei $X \in \mathbb{R}$ eine Zufallsvariable. Wir definieren den **Erwartungswert** (erstes Moment) von X als

$$\mathbb{E}[X] := \int_{\mathbb{R}} \xi \cdot p_X(\xi) d\xi.$$

Aus der Linearität des Integrals folgt die des Erwartungswerts, d. h. für zwei Zufallsvariablen X und Y und eine beliebige aber feste Zahl $\alpha \in \mathbb{R}$ (keine Zufallsvariable!) gelten

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \quad \text{und} \quad \mathbb{E}[\alpha \cdot X] = \alpha \cdot \mathbb{E}[X].$$

Wir definieren den Erwartungswert einer vektorwertigen Zufallsvariablen $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ als

$$\mathbb{E}[\mathbf{x}] := (\mathbb{E}[x_1], \mathbb{E}[x_2], \dots, \mathbb{E}[x_n])^\top.$$

Varianz von Zufallsvariablen

1.4 Definition: Die Varianz einer Zufallsvariablen $X \in \mathbb{R}$ ist definiert als die *erwartete quadratische Abweichung vom Erwartungswert* (zweites zentriertes Moment), also

$$\mathbb{V}[X] := \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{\mathbb{R}} (\xi - \mathbb{E}[X])^2 \cdot p_X(\xi) \, d\xi.$$

Unter Ausnutzung der Linearität des Erwartungswerts können wir die Varianz folgendermaßen umschreiben:

$$\begin{aligned}\mathbb{V}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2 - 2X \cdot \mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2 \cdot \mathbb{E}[X]^2 + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2.\end{aligned}$$

Varianz von Zufallsvariablen (Forts.)

Ein paar Bemerkungen. Seien dazu X und Y reelle Zufallsvariablen und $\alpha \in \mathbb{R}$ beliebig aber fest.

Die Varianz ist **nicht** linear!

- Es gilt $\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y]$ nur, wenn X und Y unkorreliert sind (**Satz von Bienaymé**).
- $\mathbb{V}[\alpha \cdot X] = \alpha^2 \cdot \mathbb{V}[X]$.

Eine Verschiebung verändert die Varianz nicht, also $\mathbb{V}[X + \alpha] = \mathbb{V}[X]$ (α ist hierbei keine Zufallsvariable, sondern eine konstante reelle Zahl).

Kovarianz

1.5 Definition: Es seien X und Y zwei Zufallsvariablen. Die **Kovarianz** zwischen X und Y ist definiert als

$$\text{Cov}[X, Y] := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Bemerkungen:

- Die Erwartungswerte müssen natürlich existieren, damit Definition 1.5 Sinn ergibt.
- Die Kovarianz ist symmetrisch: Es ist $\text{Cov}[X, Y] = \text{Cov}[Y, X]$.

1.6 Aufgabe: Was ist der Unterschied zwischen Kovarianz und Korrelation?

Streuungsmatrix

1.7 Definition: Es sei $\mathbf{x} \in \mathbb{R}^N$ ein Zufallsvektor. Wir definieren die **Streuungsmatrix** $\mathbb{D}[\mathbf{x}]$ als

$$\mathbb{D}[\mathbf{x}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \in \mathbb{R}^{N \times N}.$$

Für die Einträge von $\mathbb{D}[\mathbf{x}]$ gilt:

$$\begin{aligned} (\mathbb{D}[\mathbf{x}])_{ij} &= \mathbb{E}[(x_i - \mathbb{E}[x_i])(x_j - \mathbb{E}[x_j])] \\ &= \mathbb{E}[(x_j - \mathbb{E}[x_j])(x_i - \mathbb{E}[x_i])] = (\mathbb{D}[\mathbf{x}])_{ji} = \begin{cases} \text{Cov}[x_i, x_j] & \text{für } i \neq j \\ \mathbb{V}[x_i] & \text{für } i = j. \end{cases} \end{aligned}$$

1.8 Aufgabe: Zeigen Sie, dass $\mathbb{D}[\mathbf{x}]$ positiv semidefinit ist.

Kovarianzmatrix

1.9 Definition: Es seien $x \in \mathbb{R}^N$ und $y \in \mathbb{R}^M$ zwei Zufallsvektoren. Die **Kovarianzmatrix** von x und y ist

$$\text{Cov}[x, y] := \mathbb{E}[(x - \mathbb{E}[x])(y - \mathbb{E}[y])^\top] \in \mathbb{R}^{N \times M}.$$

Diskrete Verteilungen

Einige bekannte diskrete Verteilungen lauten:

Name der Verteilung	$\mathbb{P}^X$	Zähldichte $p_X(k)$	$\mathbb{E}[X]$	$\mathbb{V}[X]$
Bernoulli-Verteilung	$B_{1,p}$	$p^k \cdot (1-p)^{1-k}$	p	$p \cdot (1-p)$
Binomial-Verteilung	$B_{n,p}$	$\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Hypergeometrische Verteilung	$H_{n,K,N}$	$\frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \cdot \frac{K}{N}$	$n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-n}{N-1}$
Poisson-Verteilung	P_λ	$e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	λ	λ

Absolutstetige Verteilungen

Name der Verteilung	$\mathbb{P}^X$	Lebesgue-Dichte $p_X(\xi)$	$\mathbb{E}[X]$	$\mathbb{V}[X]$
Normalverteilung	$\mathcal{N}_{\mu, \sigma^2}$	$\frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(\xi-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma-Verteilung	$\Gamma_{\lambda, r}$	$\frac{\lambda^r}{\Gamma(r)} \cdot \xi^{r-1} \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{r}{\lambda}$	$\frac{r}{\lambda^2}$
Chiquadrat-Verteilung	χ_f^2	$\frac{1}{2^{\frac{f}{2}} \cdot \Gamma(\frac{f}{2})} \cdot \xi^{\frac{f}{2}-1} \cdot e^{-\frac{\xi}{2}} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	f	$2 \cdot f$
Exponential-Verteilung	Exp_{λ}	$\lambda \cdot e^{-\lambda\xi} \cdot \mathbf{1}_{[0, \infty)}(\xi)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Beta-Verteilung	$\beta_{a, b}$	$\frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0, 1)}(\xi)$	$\frac{a}{a+b}$	$\frac{a \cdot b}{(a+b)^2 \cdot (a+b+1)}$
Gleichverteilung	$U_{(a, b)}$	$\frac{1}{b-a} \cdot \mathbf{1}_{(a, b)}(\xi)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Stochastische Unabhängigkeit

Mit Dichten können wir auch die **stochastische Unabhängigkeit** von Zufallsvariablen definieren:

1.10 Definition: Es seien $X \in \mathbb{R}$ und $Y \in \mathbb{R}$ reelle Zufallsvariablen mit den Verteilungen $\mathbb{P}^X$, $\mathbb{P}^Y$ und den Dichten p_X bzw. p_Y .

X und Y heißen **stochastisch unabhängig** genau dann, wenn $p_{X,Y} := p_X \cdot p_Y$ eine **Produktdichte** der Verteilung $\mathbb{P}^{X,Y}$ ist, d. h. die gemeinsame Dichte von X und Y ergibt sich als Produkt der Einzeldichten.

Bemerkung: Stochastisch unabhängige Zufallsvariablen sind auch unkorreliert. **Die Umkehrung gilt im Allgemeinen nicht!** Somit ist die stochastische Unabhängigkeit eine stärkere Forderung als die der Unkorreliertheit.

Bedingte Wahrscheinlichkeiten

- Wahrscheinlichkeiten von Ereignissen verändern sich, wenn wir zusätzliches Wissen mit einbeziehen.
- Wir definieren daher:

1.11 Definition: Es seien X und Y zwei Zufallsvariablen, wobei wir den Wert von Y bereits beobachtet haben (Vorwissen). Dann ist die **Wahrscheinlichkeitsdichte von X gegeben Y** , in Notation $p_{X|Y}(x | y)$, definiert als

$$p_{X|Y}(x | y) := \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Satz von Bayes

Mit bedingten Wahrscheinlichkeiten können wir einen zentralen Satz der Wahrscheinlichkeitsrechnung angeben:

1.12 Satz: Es seien X und Y zwei Zufallsvariablen. Es gilt der **Satz von Bayes**

$$p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) \cdot p_X(x)}{p_Y(y)}.$$

Beweis: Mit Definition 1.11 gilt $p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}$. Analog gilt $p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}$. Da $p_{X,Y}(x, y) = p_{Y,X}(y, x)$, können wir beide Gleichungen nach der Verbunddichte $p_{X,Y}(x, y)$ auflösen. Wir erhalten also $p_{X,Y}(x, y) = p_{X|Y}(x | y) \cdot p_Y(y)$ und $p_{X,Y}(x, y) = p_{Y|X}(y | x) \cdot p_X(x)$. Gleichsetzen liefert schließlich

$$p_{X|Y}(x | y) \cdot p_Y(y) = p_{Y|X}(y | x) \cdot p_X(x) \quad \Longleftrightarrow \quad p_{X|Y}(x | y) = \frac{p_{Y|X}(y | x) \cdot p_X(x)}{p_Y(y)},$$

die Behauptung. □

Transformationssatz für Lebesgue-Dichten

1.13 Satz: Es seien x und y N -dimensionale Zufallsvektoren mit dem Zusammenhang

$$y = T(x).$$

Die Abbildung $T : \mathbb{R}^N \rightarrow \mathbb{R}^N$ sei *bijektiv*, sodass die Umkehrabbildung $x = T^{-1}(y)$ existiert und eindeutig ist. Dann gilt für die Dichte p_y der transformierten Zufallsvariablen y

$$p_y(y) = p_x(T^{-1}(y)) \cdot |\det JT^{-1}(y)|,$$

wobei p_x die Dichte von x und JT^{-1} die Jacobi-Matrix der Abbildung T^{-1} bezeichnet.

Beweis: Für den Beweis werden Argumente aus der Maß- und Integrationstheorie benötigt, deren Behandlung den Rahmen dieses Kurses übersteigt. □

Beispiel I

Es sei $X \sim \text{Exp}_2$ eine exponentialverteilte Zufallsvariable mit Ankunftsrate $\lambda = 2$.

Gesucht ist die Dichte der Zufallsvariablen $Y := 5X + 2$.

Lösung:

Es ist $T(X) := 5X + 2$ eine bijektive Transformation mit der Umkehrabbildung $X = T^{-1}(Y) = \frac{1}{5}(Y - 2)$. Zusammen mit der Dichte $p_X(x) = 2 \cdot e^{-2x} \cdot \mathbf{1}_{[0, \infty)}(x)$ der Exp_2 -Verteilung erhalten wir für die Dichte $p_Y(y)$ der transformierten Zufallsvariablen Y

$$\begin{aligned} p_Y(y) &= p_X(T^{-1}(y)) \cdot (T^{-1})'(y) = 2 \cdot e^{-2(\frac{y}{5} - \frac{2}{5})} \cdot \mathbf{1}_{[0, \infty)}\left(\frac{1}{5}y - \frac{2}{5}\right) \cdot \frac{1}{5} \\ &= \frac{2}{5} \cdot e^{\frac{4}{5}} \cdot e^{-\frac{2y}{5}} \cdot \mathbf{1}_{[2, \infty)}(y). \end{aligned}$$

Beispiel II

Der Zufallsvektor $\mathbf{x} \in \mathbb{R}^N$ habe eine beliebige Lebesgue-Dichte $p_{\mathbf{x}}$. Die Transformation $\mathbf{T}$ sei linear und bijektiv, also von der Form $\mathbf{y} = \mathbf{T}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$. Wie lautet die Dichte von $\mathbf{y}$?

Lösung:

Unter obigen Voraussetzungen ist $\mathbf{A}$ invertierbar. Also existiert die Umkehrfunktion, welche durch $\mathbf{x} = \mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})$ gegeben ist. Als Jacobi-Matrix erhält man $J\mathbf{T}^{-1}(\mathbf{y}) = \mathbf{A}^{-1}$.

Die Anwendung der Transformationsformel 1.13 ergibt daher für die Dichte $p_{\mathbf{y}}$ von $\mathbf{y}$ den Ausdruck

$$p_{\mathbf{y}}(\mathbf{y}) = \frac{1}{|\det \mathbf{A}|} \cdot p_{\mathbf{x}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})),$$

wobei wir den Zusammenhang $\det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$ benutzt haben.

Beispiel III

Das nächste Beispiel wird als Übungsaufgabe gestellt:

1.14 Aufgabe: Es sei X eine Zufallsvariable, die χ^2_2 -verteilt ist.

- 1 Berechnen Sie die Lebesgue-Dichte der Zufallsvariable $Y := \sqrt{X}$.
- 2 Berechnen Sie die Wahrscheinlichkeit $\mathbb{P}(Y > \frac{1}{2})$.

Multivariate Normalverteilung

Die multivariate Normalverteilung spielt im weiteren Verlauf eine zentrale Rolle:

1.15 Satz: Es sei $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top \in \mathbb{R}^N$ ein Zufallsvektor, dessen Komponenten $x_i \in \mathbb{R}$ unabhängig und identisch standardnormalverteilt sind, d. h. $x_i \sim \mathcal{N}(0, 1) \forall i \in \{1, \dots, N\}$.

Die Dichte der **multivariaten Standardnormalverteilung** ist dann gegeben durch

$$n_{\mathbf{x}}(\mathbf{x}) := \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

Beweis: Wegen der Unabhängigkeit der Komponenten gilt für die Verbunddichte

$$n_{\mathbf{x}}(\mathbf{x}) = \prod_{i=1}^N p_{x_i}(x_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\sum_{i=1}^N x_i^2}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right).$$

□

Multivariate Normalverteilung (Forts.)

Für die multivariate Standardnormalverteilung gilt $\mathbb{E}[\mathbf{x}] = \mathbf{0}$ und $\mathbb{D}[\mathbf{x}] = \mathbf{I}$.

Wir verallgemeinern dies auf beliebige Erwartungswertvektoren $\boldsymbol{\mu} \in \mathbb{R}^N$ und Streuungsmatrizen $\boldsymbol{\Sigma} \in \mathbb{R}^{N \times N}$. Wir fordern lediglich, dass die Streuungsmatrix $\boldsymbol{\Sigma}$ *positiv definit* ist, dass also $\mathbf{z}^\top \boldsymbol{\Sigma} \mathbf{z} > 0 \forall \mathbf{z} \in \mathbb{R}^N \setminus \{\mathbf{0}\}$ gilt.

- 1 Aufgrund der positiven Definitheit von $\boldsymbol{\Sigma}$ gibt es eine untere Dreiecksmatrix $\mathbf{A}$ mit $\boldsymbol{\Sigma} = \mathbf{A} \mathbf{A}^\top$ (Stichwort: **Cholesky-Zerlegung**).
- 2 Wir betrachten die Transformation $\mathbf{y} := \mathbf{A} \mathbf{x} + \boldsymbol{\mu}$. Es gilt

$$\mathbb{E}[\mathbf{y}] = \mathbb{E}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{E}[\mathbf{x}] + \boldsymbol{\mu} = \boldsymbol{\mu} \quad \text{und} \quad \mathbb{D}[\mathbf{y}] = \mathbb{D}[\mathbf{A} \mathbf{x} + \boldsymbol{\mu}] = \mathbf{A} \mathbb{D}[\mathbf{x}] \mathbf{A}^\top = \mathbf{A} \mathbf{A}^\top = \boldsymbol{\Sigma}.$$

- 3 Nun wenden wir die Transformationsformel 1.13 an, um die Dichte von $\mathbf{y}$ zu bestimmen.

Multivariate Normalverteilung (Forts.)

Zu Schritt 3: Es ist $T^{-1}(x) = A^{-1}(y - \mu)$. Mit Beispiel II zum Transformationssatz erhalten wir

$$|\det JT^{-1}(y)| = |\det A^{-1}| = \frac{1}{|\det A|}.$$

Außerdem gilt mit dem Determinantenmultiplikationssatz die Identität

$\det \Sigma = \det(AA^T) = \det A \cdot \det A = \det^2 A$. Durch Ziehen der Wurzel auf beiden Seiten erhalten wir also $|\det A| = (\det \Sigma)^{\frac{1}{2}}$. Die Dichte p_y nimmt damit die Form

$$p_y(y) = \frac{1}{(\det \Sigma)^{\frac{1}{2}}} \cdot p_x(A^{-1}(y - \mu))$$

an, wobei p_x die Dichte der Standardnormalverteilung aus Satz 1.15 ist. Wir setzen dort $x := A^{-1}(y - \mu)$, sodass $\|x\|^2 = (y - \mu)^T (A^{-1})^T A^{-1}(y - \mu) = (y - \mu)^T \Sigma^{-1}(y - \mu)$ gilt.

Multivariate Normalverteilung (Forts.)

Wir fassen zusammen:

1.16 Definition: Es sei $\mu \in \mathbb{R}^N$ ein Vektor und $\Sigma \in \mathbb{R}^{N \times N}$ eine *positiv definite* Matrix.

Die Dichte der **multivariaten Normalverteilung** $\mathcal{N}(\mu, \Sigma)$ ist gegeben durch

$$n_x(x) := \frac{1}{(2\pi)^{\frac{N}{2}} \cdot (\det \Sigma)^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

Bemerkung: Die positive Definitheit der Matrix Σ impliziert auch deren Invertierbarkeit (siehe hierzu Satz 2.4).

Visualisierung: Multivariate Normalverteilung




Abbildung: Multivariate (genauer zweidimensionale) Normalverteilung mit (Links): Allgemeiner Kovarianzmatrix. (Mitte): Diagonaler Kovarianzmatrix, sodass die Konturen achsenparallel verlaufen. (Rechts): Kovarianz proportional zur Einheitsmatrix, also aI mit $a > 0$, sodass die Konturen perfekte Kreise bilden. Siehe [1], Seite 76.

Partitionierte Normalverteilung

1.17 Definition: Es seien $\mathbf{x} \in \mathbb{R}^D$ und $\mathbf{y} \in \mathbb{R}^{N-D}$ zwei Zufallsvektoren. Wir fassen diese zu einem neuen Zufallsvektor $\mathbf{z} := (\mathbf{x}^\top, \mathbf{y}^\top)^\top \in \mathbb{R}^N$ mit $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ zusammen. Hierbei seien

$$\boldsymbol{\mu} := \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix} \quad \text{und} \quad \boldsymbol{\Sigma} := \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}.$$

Wir nennen dieses Modell **partitionierte Normalverteilung**.

Bemerkungen: Aus der Symmetrie von $\boldsymbol{\Sigma}$ folgt die von $\boldsymbol{\Sigma}_{xx}$ und $\boldsymbol{\Sigma}_{yy}$. Außerdem gilt $\boldsymbol{\Sigma}_{xy} = \boldsymbol{\Sigma}_{yx}^\top$.

Oft ist es einfacher mit der Inversen der Kovarianzmatrix zu arbeiten. Wir definieren daher $\boldsymbol{\Lambda} := \boldsymbol{\Sigma}^{-1}$. Man nennt diese Matrix **Präzisionsmatrix**.

Bedingte Normalverteilung

1.18 Satz: Wir betrachten das Modell der partitionierten Normalverteilung aus Definition 1.17. Für die Zufallsvariable $x | y$ gilt

$$x | y \sim \mathcal{N}(\mu_{x|y}, \Sigma_{x|y}),$$

wobei für die Parameter der folgende Zusammenhang gilt:

$$\mu_{x|y} := \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$$

$$\Sigma_{x|y} := \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}.$$

Die Dichte dieser Verteilung bezeichnen wir mit $p_{x|y}$.

Beweis: Einen Beweis dieser Aussage finden Sie in [2] auf den Seiten 85–87.

□

Visualisierung: Bedingte Normalverteilung





Abbildung: Links: Zweidimensionale Normalverteilung. Rechts: Bedingte Verteilung in rot. Siehe [1], Seite 82.

Aufgabe: Bedingte Normalverteilung

1.19 Aufgabe: Es sei $\boldsymbol{\mu} := (0, 2)^T \in \mathbb{R}^2$ und

$$\boldsymbol{\Sigma} := \begin{pmatrix} 0.3 & -1 \\ -1 & 5 \end{pmatrix} \in \mathbb{R}^{2 \times 2},$$

sodass die Verbunddichte von X_1 und X_2 gegeben ist durch $p_{X_1, X_2}(x_1, x_2) := n(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$. Bestimmen Sie die Dichte der bedingten Verteilung $p_{X_1 | X_2}(x_1 \mid x_2 = -1)$. Benutzen Sie hierzu die Formeln aus Satz 1.18.

Normale Randverteilung

1.20 Satz: Erneut betrachten wir das Modell der partitionierten Normalverteilung aus Definition 1.17. Dann sind auch die Randverteilungen von $\mathbf{x}$ und $\mathbf{y}$ normalverteilt. Es gilt genauer

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

Die Dichten der Randverteilung bezeichnen wir mit n_x und n_y .

Beweis: Man erhält dieses Ergebnis durch **Marginalisierung** der Verbunddichte, d. h. wir integrieren über alle Variablen, die uns nicht interessieren. Für die Randverteilung von $\mathbf{x}$ gilt zum Beispiel

$$n_x(\mathbf{x}) = \int n_{x,y}(\mathbf{x}, \mathbf{y}) d\mathbf{y}.$$

Einen ausführlichen Beweis finden Sie in [2] auf den Seiten 88–89.

□

Visualisierung: Normale Randverteilung





Abbildung: Links: Zweidimensionale Normalverteilung. Rechts: Randverteilung für x_a in blau. Siehe [\[1\]](#), Seite 82.

Aufgabe: Normale Randverteilung

1.21 Aufgabe: Betrachten Sie erneut die Verbunddichte $p_{X_1, X_2}(x_1, x_2)$ wie sie in Aufgabe 1.19 definiert wurde.

Wie lautet die Dichte der Randverteilung $p_{X_1}(x_1)$?

Satz von Bayes für Normalverteilungen

1.22 Satz: Es seien x und y Zufallsvektoren, sodass gilt

$$x \sim \mathcal{N}(\mu, \Sigma) \quad \text{und} \quad y | x \sim \mathcal{N}(Ax + b, \Lambda).$$

Dann gilt für die Dichten der Verteilungen von y und $x | y$

$$y \sim \mathcal{N}(A\mu + b, A\Sigma A^\top + \Lambda)$$

$$x | y \sim \mathcal{N}(\Gamma[\Sigma^{-1}\mu + A^\top\Lambda^{-1}(y - b)], \Gamma).$$

Hierbei ist $\Gamma := (\Sigma^{-1} + A^\top\Lambda^{-1}A)^{-1}$.

Beweis: Einen Beweis dieser Aussage finden Sie in [2] auf den Seiten 90–93.



Maximum-Likelihood Methode

- Im Folgenden sei ein Beobachtungsvektor $\mathbf{x} := (x_1, x_2, \dots, x_N)^\top$ bestehend aus N *unabhängig und identisch verteilten* (Englisch: *independent and identically distributed* - i.i.d.) Datenpunkten gegeben.
- Wir möchten Aussagen über die Parameter $\boldsymbol{\theta} := (\theta_1, \theta_2, \dots, \theta_M)^\top$ der zugrundeliegenden Verteilung machen.
- Dies erledigen wir durch eine Punktschätzung des Parametervektors $\boldsymbol{\theta}$. Den Schätzer für $\boldsymbol{\theta}$ bezeichnen wir mit $\hat{\boldsymbol{\theta}}$.
- Eine der am häufigsten angewendete Methode ist die **Maximum-Likelihood Methode**, die wir im Folgenden näher beleuchten werden.

(Log-)Likelihood Funktion

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für den Parametervektor θ maximiert die Likelihood Funktion.

1.23 Definition: Es sei $p(\mathbf{x}; \theta)$ die Dichte eines Zufallsvektors $\mathbf{x} \in \mathbb{R}^N$, welche durch den Parametervektor $\theta \in \Theta$ parametrisiert wird. Die **Likelihood Funktion** $L : \Theta \rightarrow \mathbb{R}$ ist dann definiert als

$$L(\theta) := p(\mathbf{x}; \theta) = p(x_1, x_2, \dots, x_N; \theta).$$

Häufig ist es einfacher, die **Log-Likelihood Funktion** $l(\theta) := \ln p(\mathbf{x}; \theta)$ zu betrachten. Wir definieren $\hat{\theta}_{ML} := \arg \max_{\theta} l(\theta)$.

Bemerkung: Der Schätzer $\hat{\theta}_{ML}$ maximiert sowohl L als auch l . (Warum?)

(Log-)Likelihood Funktion (Forts.)

- Im Allgemeinen kann es schwer sein, die Likelihood Funktion zu bestimmen (*vor allem wenn die Beobachtungen voneinander abhängen*).
- Die Annahme der **Unabhängigkeit der Beobachtungen** vereinfacht dies maßgeblich, denn

$$\begin{aligned} L(\theta) &= p(x_1, x_2, \dots, x_N; \theta) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot \dots \cdot p(x_N; \theta) \\ &= \prod_{n=1}^N p(x_n; \theta). \end{aligned}$$

- Für die Log-Likelihood Funktion ergibt sich durch Anwendung der Logarithmengesetze

$$l(\theta) = \ln \prod_{n=1}^N p(x_n; \theta) = \sum_{n=1}^N \ln p(x_n; \theta).$$

Maximum-Likelihood Gleichung

- Falls die Likelihood Funktion differenzierbar ist, so erfüllt der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ notwendig die **Likelihood Gleichung**

$$\left. \frac{\partial}{\partial \theta} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = \mathbf{0}.$$

- Diese sagt aus, dass $\hat{\theta}_{ML}$ ein *stationärer Punkt der (Log-)Likelihood Funktion* sein muss.
- Es handelt sich dabei um ein System von M , im Allgemeinen nicht-linearen, Gleichungen der Form

$$\left. \frac{\partial}{\partial \theta_j} \ln p(x; \theta) \right|_{\theta = \hat{\theta}_{ML}} = 0 \quad j = 1, 2, \dots, M.$$

Achtung: Es muss noch überprüft werden, ob $\hat{\theta}_{ML}$ tatsächlich ein Maximum darstellt.

Beispiel I: Binomialverteilung

1.24 Satz: Es sei die binomialverteilte Zufallsvariable X (Anzahl der Erfolge) und der Stichprobenumfang N gegeben. Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ für die unbekannte Erfolgswahrscheinlichkeit $\theta \in (0, 1)$ lautet $\hat{\theta}_{ML} = \frac{k}{N}$, wobei k die Anzahl der beobachteten Erfolge in der Stichprobe ist.

Beweis: Die Likelihood Funktion ist gegeben durch $L(\theta) = \binom{N}{k} \cdot \theta^k \cdot (1 - \theta)^{N-k}$. Wir wenden den Logarithmus an und erhalten die Log-Likelihood Funktion

$$l(\theta) = \ln \binom{N}{k} + k \cdot \ln \theta + (N - k) \cdot \ln(1 - \theta).$$

Diese leiten wir nach θ ab und setzen sie Null. Auflösen nach θ ergibt schließlich

$$\frac{d}{d\theta} l(\theta) = \frac{k}{\theta} - \frac{N - k}{1 - \theta} \stackrel{!}{=} 0 \iff \hat{\theta}_{ML} = \frac{k}{N}.$$

Wir prüfen noch das Vorzeichen der zweiten Ableitung. Es ist $\frac{d^2}{d\theta^2} l(\theta) = -\frac{k}{\theta^2} - \frac{N-k}{(1-\theta)^2} < 0 \forall \theta \in (0, 1)$, sodass $\hat{\theta}_{ML}$ tatsächlich ein Maximum ist. Es handelt sich sogar um ein global eindeutiges Maximum. □

Beispiel II: Normalverteilung

1.25 Satz: Es seien $\mathbf{x} = (x_1, x_2, \dots, x_N)^\top$ *unabhängig und identisch normalverteilte* Beobachtungen mit unbekanntem Erwartungswert $\mu \in \mathbb{R}$ und unbekannter Varianz $\sigma^2 > 0$. Der Parametervektor θ ist in diesem Fall zweielementig und gegeben durch $\theta := (\mu, \sigma^2)^\top$.

Die Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$ für die unbekannten Parameter μ und σ^2 werden in diesem Fall bestimmt mittels

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N x_n \quad \text{und} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2.$$

Beweis: Die Dichte der Produktverteilung lautet aufgrund der Unabhängigkeit der Beobachtungen

$$p(\mathbf{x}; \mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi)^{\frac{N}{2}}} \cdot \frac{1}{\sigma^N} \cdot \exp\left(-\frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}\right).$$

Aufgrund der auftretenden Exponentialverteilung bietet sich die Betrachtung der Log-Likelihood Funktion an. Wir erhalten

$$l(\mu, \sigma^2) = -\frac{N}{2} \cdot \ln(2\pi) - N \ln(\sigma) - \frac{\sum_{n=1}^N (x_n - \mu)^2}{2\sigma^2}.$$

Nun berechnen wir die partiellen Ableitungen von l nach μ und σ^2 . Es ist

$$\frac{\partial}{\partial \mu} l(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) \quad \text{und} \quad \frac{\partial}{\partial \sigma^2} l(\mu, \sigma^2) = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=1}^N (x_n - \mu)^2.$$

Durch Nullsetzen und auflösen erhalten wir die im Satz angegebenen Maximum-Likelihood Schätzer $\hat{\mu}_{ML}$ und $\hat{\sigma}_{ML}^2$. Es bleibt noch zu zeigen, dass es sich tatsächlich um ein Maximum handelt. Man rechnet nach, dass die Hesse-Matrix von $l(\mu, \sigma^2)$ and der Stelle $(\hat{\mu}_{ML}, \hat{\sigma}_{ML}^2)$ gegeben ist durch

$$\nabla^2 l(\mu, \sigma^2) = \begin{pmatrix} -\frac{N}{\hat{\sigma}_{ML}^2} & 0 \\ 0 & -\frac{N}{(\hat{\sigma}_{ML}^2)^2} \end{pmatrix}.$$

Diese Matrix ist negativ definit, weshalb wir tatsächlich ein Maximum gefunden haben. □

Erwartungstreue Schätzer

Wir definieren den Begriff der Erwartungstreue:

1.26 Definition: Wir nennen einen Schätzer $\hat{\theta}$ **erwartungstreu**, falls $\mathbb{E}[\hat{\theta}] = \theta$ gilt.

- Der Schätzer $\hat{\mu}_{ML}$ ist erwartungstreu für den Erwartungswert μ im Normalverteilungsmodell

Beweis: Es gilt

$$\mathbb{E}[\hat{\mu}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \cdot N \cdot \mu = \mu.$$

□

- Demgegenüber ist $\hat{\sigma}_{ML}^2$ **nicht** erwartungstreu. Man kann diesen Schätzer jedoch durch eine geeignete Transformation zu einem erwartungstreuen Schätzer machen. Dies führt auf die **empirische Varianz** $\frac{N}{N-1} \hat{\sigma}_{ML}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \hat{\mu}_{ML})^2$.

Aufgabe zur Maximum-Likelihood Schätzung

1.27 Aufgabe: Gegeben seien die N Beobachtungen $x_1, x_2, \dots, x_N$, wobei $x_n \in \mathbb{N}$, $n = 1, 2, \dots, N$. Sie legen den Daten eine Poisson-Verteilung zugrunde. Diese hat die Dichte

$$p(x) := e^{-\lambda} \cdot \frac{\lambda^x}{x!}.$$

- 1 Bestimmen Sie den Maximum-Likelihood Schätzer $\hat{\lambda}_{ML}$ für die Poisson-Verteilung. Vergessen Sie dabei nicht zu überprüfen, ob es sich tatsächlich um ein Maximum handelt.
- 2 Prüfen Sie den Schätzer auf Erwartungstreue.

Erwartete quadratische Abweichung (MSE)

Ein weiteres Qualitätsmerkmal eines Schätzers $\hat{\theta}$ ist seine erwartete quadratische Abweichung vom wahren Parameter θ .

1.28 Definition: Die **erwartete quadratische Abweichung** von $\hat{\theta}$ zu θ ist

$$\text{MSE}[\hat{\theta}, \theta] = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Die $\text{MSE}[\hat{\theta}, \theta]$ reduziert sich für erwartungstreue Schätzer $\hat{\theta}$ auf die Varianz $\mathbb{V}[\hat{\theta}]$.

Beweis: Man rechnet nach, dass $\text{MSE}[\hat{\theta}, \theta] = \mathbb{V}[\hat{\theta}] + (\mathbb{E}[\hat{\theta}] - \theta)^2$ gilt (multipliziere hierzu aus und nutze die Linearität des Erwartungswerts). Der zweite Summand (Quadrat der Verzerrung/Bias) verschwindet aber für erwartungstreue Schätzer, da $\mathbb{E}[\hat{\theta}] = \theta$ gilt. Es folgt die Behauptung. □

Maximum-Aposteriori Schätzer (MAP)

- ML Schätzer laufen Gefahr, sich übermäßig stark an die Daten anzupassen (**Overfitting**).
- Wir erweitern daher das Konzept der ML Schätzung, indem wir zusätzlich eine *Apriori-Verteilung* für die zu schätzenden Parameter mit einbeziehen.
- Wir nutzen den Satz von Bayes, um damit zusammen mit der Likelihood eine *Aposteriori-Verteilung* über die Parameter zu erhalten.
- Ein Schätzer $\hat{\theta}_{MAP}$ heißt **Maximum-Aposteriori Schätzer** für den Parameter θ , falls dieser die Aposteriori-Wahrscheinlichkeit maximiert.

Binäre Variablen

- Wir betrachten eine binäre Zufallsvariable $X \in \{0, 1\}$, z. B. das Werfen einer (unfairen) Münze, wobei $X = 1$ 'Kopf' und $X = 0$ 'Zahl' bedeutet.
- Die Zufallsvariable X ist damit **Bernoulli-verteilt** mit der Dichte

$$p_X(k) := \mu^k \cdot (1 - \mu)^{1-k}. \quad (1.1)$$

- Es gilt

$$\mathbb{E}[X] = \mu$$

$$\mathbb{V}[X] = \mu \cdot (1 - \mu).$$

1.29 Aufgabe: Beweisen Sie die Aussagen $\mathbb{E}[X] = \mu$ und $\mathbb{V}[X] = \mu \cdot (1 - \mu)$.

Maximum Likelihood für die Bernoulli-Verteilung

- Wir gehen nun von N unabhängigen Bernoulli-verteilten Zufallsvariablen $X_1, X_2, \dots, X_N$ aus.
- Dann ist die Likelihood Funktion für den Parameter μ gegeben durch

$$L(\mu) = \prod_{n=1}^N p_{X_n}(k_n) = \prod_{n=1}^N \mu^{k_n} \cdot (1 - \mu)^{1-k_n}.$$

- Hieraus ergibt sich die Log-Likelihood Funktion

$$l(\mu) = \sum_{n=1}^N \ln p_{X_n}(k_n) = \sum_{n=1}^N [k_n \ln \mu + (1 - k_n) \cdot \ln(1 - \mu)] = \ln \mu \sum_{n=1}^N k_n + \ln(1 - \mu) \left(N - \sum_{n=1}^N k_n \right).$$

Bemerkung: Die Log-Likelihood Funktion hängt von den Beobachtungen nur über die Statistik $Y := \sum_{n=1}^N X_n$ ab. Man nennt Y daher eine **suffiziente Statistik**.

Maximum Likelihood für die Bernoulli-Verteilung

- Leiten wir $l(\mu)$ nach μ ab und setzen Null, so erhalten wir den Maximum-Likelihood Schätzer als arithmetisches Mittel der Beobachtungen

$$\hat{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N k_n.$$

- Schreiben wir für die Anzahl der Erfolge (Kopf) $m := \sum_{n=1}^N k_n$, so ist $\hat{\mu}_{ML} = \frac{m}{N}$.
- Werfen wir die Münze drei Mal und erhalten jedes Mal Kopf, so wäre $\hat{\mu}_{ML} = 1$ (**Overfitting**).
- Die Zufallsvariable $Y := X_1 + X_2 + \dots + X_N$ ist aufgrund der Unabhängigkeit der X_n ($1 \leq n \leq N$) **binomial-verteilt**, sodass gilt

$$\mathbb{P}(Y = m) := \binom{N}{m} \cdot \mu^m \cdot (1 - \mu)^{N-m}.$$

Beta-Verteilung

Um die Overfitting-Problematik zu adressieren, führen wir einen Beta-verteilten Prior ein.

1.30 Definition: Es sei X eine **Beta-verteilte** Zufallsvariable, in Notation $X \sim \beta_{a,b}$, mit den Parametern $a, b > 0$. Die Dichte der Verteilung ist gegeben durch

$$p_X(\xi) = \frac{\Gamma(a+b)}{\Gamma(a) \cdot \Gamma(b)} \cdot \xi^{a-1} \cdot (1-\xi)^{b-1} \cdot \mathbf{1}_{(0,1)}(\xi).$$

Bemerkung: $\Gamma(x)$ ist hierbei die **Gamma-Funktion**. Es gilt $\Gamma(x) := \int_0^\infty u^{x-1} e^{-u} du$. Mithilfe partieller Integration kann man den Zusammenhang $\Gamma(x+1) = x \cdot \Gamma(x)$ zeigen. Außerdem gilt $\Gamma(1) = 1$. Daraus folgt $\Gamma(n+1) = n!$ für $n \in \mathbb{N}$. Somit ist die Gamma-Funktion die kontinuierliche Fortsetzung der Fakultäts-Funktion.

Visualisierung: Beta-Verteilung





Abbildung: Beta-Verteilungen für einige Parameter a , b . Siehe [2], Seite 72.

Visualisierung: Beta-Verteilung (Forts.)





Abbildung: Beta-Verteilungen für einige Parameter a , b . Siehe [2], Seite 72.

Bestimmung des Posteriors

- Um den Posterior zu erhalten, multiplizieren wir den Beta-verteilten Prior mit der binomial-verteilten Likelihood.
- Ignorieren wir alle von μ unabhängigen Terme, so erhalten wir für den Posterior mit $l := N - m$ (Anzahl Misserfolge)

$$p(\mu \mid m, l; a, b) \propto \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1}. \quad (1.2)$$

- Da Prior und Likelihood *dieselbe funktionale Form* haben, ist *auch der Posterior wieder Beta-verteilt*, wobei sich der Normierungsfaktor durch Vergleich mit der Dichte aus 1.30 ergibt

$$p(\mu \mid m, l; a, b) = \frac{\Gamma(m + a + l + b)}{\Gamma(m + a) \cdot \Gamma(l + b)} \cdot \mu^{m+a-1} \cdot (1 - \mu)^{l+b-1} \quad (1.3)$$

Wir gehen also vom Prior mit der Dichte $\beta_{a,b}$ über zum Posterior mit der Dichte $\beta_{a+m,b+l}$.

Visualisierung: Bestimmung des Posteriors




Abbildung: Ein Schritt der Bayes'schen Inferenz. Der Prior ist gegeben durch eine Beta-Verteilung mit $a = 2 = b$. Die Likelihood Funktion ist hingegen gegeben durch eine Binomial-Verteilung mit $N = m = 1$. Der Posterior ist damit wieder Beta-verteilt mit den Parametern $a = 3$ und $b = 2$. Siehe [2], Seite 73.

Konjugierte Verteilungen

1.31 Definition: Ein Prior heißt **konjugiert** zur Likelihood, wenn der daraus berechnete Posterior exakt dieselbe funktionale Form wie der Prior annimmt.

- **Vorteil:** Der Posterior kann durch Aufdatierung der Parameter des Priors einfach bestimmt werden.

- Wichtige Paare:

Binomial-Verteilung

Beta-Verteilung

Poisson-Verteilung

Gamma-Verteilung

Normalverteilung

Normalverteilung (μ zu schätzen, Varianz σ^2 bekannt)

Aufgabe: Konjugierte Verteilungen

1.32 Aufgabe: Weisen Sie nach, dass die Gamma-Verteilung der konjugierte Prior zur Likelihood der Poisson-Verteilung für den Parameter λ ist.

Hinweis: Schreiben Sie hierzu die Likelihood-Funktion und den Prior für λ auf. Ignorieren Sie alle Terme, die nicht von λ abhängen. Wenden Sie anschließend den Satz von Bayes an, um den Posterior zu erhalten. Können Sie diesen in dieselbe Form wie den Prior bringen?

Bestimmung des MAP-Schätzers

- Der MAP-Schätzer *maximiert den Posterior* (1.3).
- Der **Log-Posterior** lautet

$$\ln p(\mu \mid m, l; a, b) = (m + a - 1) \ln \mu + (l + b - 1) \ln(1 - \mu) + \text{const.}$$

- Ableiten nach μ , Nullsetzen und Auflösen nach μ ergibt den MAP-Schätzer

$$\hat{\mu}_{MAP} = \frac{m + a - 1}{m + a + l + b - 2}.$$

- Vergleich mit dem ML-Schätzer

$$\hat{\mu}_{ML} = \frac{m}{m + l}.$$

Bayes'sche Inferenz

- Wir haben N Münzwürfe mit m Erfolgen (Kopf) und l Misserfolgen (Zahl) beobachtet.
- Unser Ziel ist es nun, den Ausgang des nächsten Wurfs vorherzusagen.
- Hierzu werten wir die **Prädiktivverteilung (Vorhersageverteilung)** aus

$$\begin{aligned}\mathbb{P}(X_{N+1} = 1 \mid m, l) &= \int_0^1 \mathbb{P}(X_{N+1} = 1 \mid \mu) \cdot p(\mu \mid m, l) \, d\mu = \int_0^1 \mu \cdot p(\mu \mid m, l) \, d\mu \\ &= \mathbb{E}[\mu \mid m, l].\end{aligned}$$

- Der Erwartungswert des Posteriors können wir nun aus (1.3) ablesen, wir erhalten

$$\mathbb{P}(X_{N+1} = 1 \mid m, l) = \frac{m + a}{m + a + l + b}.$$

Kapitel

② Regression

Wiederholung: Lineare Regression

Probabilistische Regression

Maximum A posteriori (MAP) Regression

Bayes'sche Regression

Lineare Regression

Wir wiederholen die wichtigsten Aussagen zur **linearen Regression**:

- Wir betrachten einen Datensatz bestehend aus N Featurevektoren $\phi(x_n) \in \mathbb{R}^M$, $n = 1, 2, \dots, N$.
- Die Funktion ϕ ist hierbei eine **Basisfunktion**, z. B. die polynomiale Basis.
- Um den **Bias** zu modellieren, vereinbaren wir, dass stets $\phi_1(x) = 1$ gilt.
- Des Weiteren ist jeder Vektor $\phi(x_n) \in \mathbb{R}^M$ mit einem zugehörigen Label $y_n \in \mathbb{R}$ versehen, $n = 1, 2, \dots, N$.
- Das lineare Regressionsmodell hat die Form

$$h(x; \theta) = \sum_{m=1}^M \theta_m \phi_m(x) = \theta^\top \phi(x).$$

Design Matrix

- Wir fassen die N Featurevektoren $\phi(x_n) \in \mathbb{R}^M$ zeilenweise zu der Matrix Φ zusammen.
- Diese hat damit die allgemeine Form

$$\Phi := \begin{pmatrix} \text{---} & \phi(x_1) & \text{---} \\ \text{---} & \phi(x_2) & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \phi(x_N) & \text{---} \end{pmatrix} \in \mathbb{R}^{N \times M}.$$

- Die erste Spalte ist hierbei konstant 1 (*wegen der Dummy-Komponente für den Bias*).
- Wir nennen diese Matrix die **Design Matrix**.
- Analog sammeln wir alle Labels in einem Vektor

$$\mathbf{y} := (y_1, y_2, \dots, y_N)^\top \in \mathbb{R}^N.$$

Methode der kleinsten Quadrate

- Der Vektor $\theta \in \mathbb{R}^M$ beinhaltet die **Modellparameter**.
- Diese möchten wir so wählen, dass unser Modell die Daten möglichst gut erklärt
- Die Abweichung der Vorhersagen zu den Trainingsdaten sollte also *möglichst klein* sein.

2.1 Definition: Mit den obigen Definitionen ist der **Least-Squares-Fehler** gegeben durch

$$J_{\text{LS}}(\theta) := \frac{1}{2N} \|\Phi\theta - y\|^2 = \frac{1}{2N} (\Phi\theta - y)^\top (\Phi\theta - y).$$

Bemerkung: Der Vektor $\Phi\theta \in \mathbb{R}^N$ beinhaltet die **Modellvorhersagen**, wenn man dem Modell die Parameter θ zugrunde legt. J_{LS} misst also die **mittlere quadratische Abweichung** der Vorhersagen zu den wahren Werten y .

Minimierung der Fehlerfunktion

Unser Ziel ist die Minimierung von J_{LS} . Hierzu schreiben J_{LS} unter Ausnutzung der Transpositionsregeln $(A + B)^T = A^T + B^T$ und $(AB)^T = B^T A^T$ zunächst um:

$$\begin{aligned} J_{LS}(\theta) &= \frac{1}{2N} \|\Phi\theta - y\|^2 = \frac{1}{2N} (\Phi\theta - y)^T (\Phi\theta - y) \\ &= \frac{1}{2N} ((\Phi\theta)^T - y^T) (\Phi\theta - y) \\ &= \frac{1}{2N} ((\Phi\theta)^T \Phi\theta - (\Phi\theta)^T y - y^T (\Phi\theta) + y^T y) \\ &= \frac{1}{2N} (\theta^T \Phi^T \Phi\theta - 2(\Phi\theta)^T y + y^T y) \\ &= \frac{1}{2N} (\theta^T \Phi^T \Phi\theta - 2\theta^T \Phi^T y + y^T y) \end{aligned}$$

Minimierung der Fehlerfunktion (Forts.)

Um einen stationären Punkt zu finden, müssen wir J_{LS} nach θ ableiten und Null setzen.

- Es ist $\frac{\partial}{\partial \theta} \theta^\top \Phi^\top \Phi \theta = 2\Phi^\top \Phi \theta$, da $\Phi^\top \Phi$ symmetrisch ist.

Beweis: Wir nutzen die Transpositionsregeln und erhalten $(\Phi^\top \Phi)^\top = \Phi^\top (\Phi^\top)^\top = \Phi^\top \Phi$, woraus die Symmetrie folgt. $\square$

- Es ist $\frac{\partial}{\partial \theta} (-2\theta^\top \Phi^\top y) = -2\Phi^\top y$ und $\frac{\partial}{\partial \theta} y^\top y = 0$.
- Der Gradient der Fehlerfunktion J_{LS} ist damit gegeben durch

$$\frac{\partial}{\partial \theta} J_{LS}(\theta) = \frac{1}{2N} (2\Phi^\top \Phi \theta - 2\Phi^\top y) \propto \Phi^\top \Phi \theta - \Phi^\top y = \Phi^\top (\Phi \theta - y)$$

Bemerkung: Man beachte den Zusammenhang zwischen dem Gradienten und dem Vorhersagefehler: Je größer der Fehler, desto größer auch der Gradient!

Minimierung der Fehlerfunktion (Forts.)

Wir setzen den Gradienten Null und lösen nach θ auf:

$$\frac{\partial}{\partial \theta} J_{\text{LS}}(\theta) \stackrel{!}{=} \mathbf{0} \quad \Longleftrightarrow \quad \Phi^{\top} \Phi \theta - \Phi^{\top} y = \mathbf{0}$$

$$\Longleftrightarrow \quad \Phi^{\top} \Phi \theta = \Phi^{\top} y$$

$$\Longleftrightarrow \quad \theta^{\star} = (\Phi^{\top} \Phi)^{-1} \Phi^{\top} y$$

Bemerkung: Wir haben damit einen stationären Punkt von J_{LS} gefunden. Allerdings wissen wir noch nicht, ob es sich tatsächlich um ein Minimum handelt. Außerdem sind wir hier etwas naiv von der Existenz der Inversen $(\Phi^{\top} \Phi)^{-1}$ ausgegangen. Existiert diese Matrix immer?

Mit diesen Fragen beschäftigen wir uns im Folgenden.

Ein paar nützliche Aussagen

2.2 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ ist $A^\top A$ positiv semidefinit.

Beweis: Für alle $z \in \mathbb{R}^M$ gilt $z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 \geq 0$, woraus die Behauptung folgt. □

2.3 Satz: Für alle $A \in \mathbb{R}^{N \times M}$ mit *vollem Spaltenrang* ist $A^\top A$ positiv definit.

Beweis: Da A vollen Spaltenrang hat, sind die Spaltenvektoren linear unabhängig. Daher ist Az für alle $z \in \mathbb{R}^M \setminus \{0\}$ eine nicht-triviale Linearkombination der Spalten von A . Folglich gilt $Az \neq 0$ und wir erhalten

$$z^\top (A^\top A) z = (Az)^\top (Az) = \|Az\|^2 > 0,$$

woraus die Behauptung folgt. □

Ein paar nützliche Aussagen (Forts.)

2.4 Satz: Wenn $A \in \mathbb{R}^{N \times N}$ positiv definit ist, so ist A auch invertierbar.

Beweis: Wir nehmen an, A sei nicht invertierbar. Dann sind die Spalten von A linear abhängig und es existiert ein $z \in \mathbb{R}^M \setminus \{\mathbf{0}\}$ mit $Az = \mathbf{0}$. Daraus folgt aber

$$z^\top Az = z^\top \mathbf{0} = 0,$$

was der vorausgesetzten positiven Definitheit von A widerspricht. Es muss A folglich invertierbar sein. □

Handelt es sich nun um ein Minimum?

Um diese Frage zu klären, berechnen wir die **Hesse-Matrix** von J_{LS} und untersuchen, ob die Matrix im stationären Punkt θ^* positiv definit ist.

- Man rechnet nach, dass die Hesse-Matrix von J_{LS} gegeben ist durch

$$\frac{\partial^2}{\partial \theta \partial \theta} J_{LS}(\theta) = \Phi^T \Phi.$$

- Mit Satz 2.3 ist diese Matrix positiv definit für alle θ , falls Φ vollen Spaltenrang hat, d. h. *die Features müssen linear unabhängig sein*. In diesem Fall handelt es sich bei θ^* tatsächlich um ein Minimum.
- Unter derselben Voraussetzung haben wir damit sogar die **Konvexität** von J_{LS} bewiesen (**warum?**), sodass das Minimum *global und eindeutig* ist.

Und wie sieht es nun mit der Existenz der Inversen aus?

- Mit Satz 2.4 ist die Existenz der Inversen sichergestellt, wenn $\Phi^\top \Phi$ positiv definit ist, was wiederum aus der linearen Unabhängigkeit der Features folgt (Satz 2.3).
- **Achtung:** Bei der numerischen Berechnung der Inversen auf dem Computer kann es trotzdem zu Problemen kommen.
- Es ist *numerisch stabiler*, die Inverse nicht explizit zu berechnen, sondern stattdessen das folgende lineare Gleichungssystem in θ zu lösen

$$\Phi^\top \Phi \theta = \Phi^\top y.$$

- Alternativ kann das Optimierungsproblem mit dem **Gradientenabstiegsverfahren** gelöst werden.
- Iteriere hierzu die Regel:

$$\theta_{t+1} \longleftarrow \theta_t - \alpha \Phi^\top (\Phi \theta_t - y). \quad (2.1)$$

Normalengleichungen

Wir fassen unsere Ergebnisse zusammen:

2.5 Satz: Die Design Matrix $\Phi \in \mathbb{R}^{N \times M}$ des Regressionsproblems habe vollen Spaltenrang, d. h. die Features seien linear unabhängig. Dann existiert die Inverse $(\Phi^\top \Phi)^{-1}$ und

$$\theta^\star = (\Phi^\top \Phi)^{-1} \Phi^\top y$$

ist das eindeutige globale Minimum von J_{LS} . Die Gleichungen $\Phi^\top \Phi \theta = \Phi^\top y$ bezeichnet man als **Normalengleichungen**.

Eine probabilistische Sicht

Annahme 1: Die Zielwerte $y \in \mathbb{R}$ und die Features $\phi(x) \in \mathbb{R}^M$ hängen über die Gleichung

$$y = \theta^\top \phi(x) + \varepsilon \quad (2.2)$$

zusammen. Der Fehlerterm $\varepsilon \in \mathbb{R}$ repräsentiert nicht modellierte Effekte oder Datenrauschen.

Annahme 2: Für den Fehlerterm gilt $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Bemerkung: Der Zielwert y kann damit als Zufallsvariable aufgefasst werden, für die gilt

$$y \mid x \sim \mathcal{N}(\theta^\top \phi(x), \sigma^2). \quad (2.3)$$

Visualisierung: Probabilistische Regression




Abbildung: Visualisierung der probabilistischen Regression. x_0 ist hierbei ein Testpunkt.

Maximum-Likelihood Regression

- Wir betrachten wieder einen Datensatz $\{(\mathbf{x}_n, y_n)\}_{n=1}^N$ bestehend aus N Trainingsbeispielen.
- Die Likelihood Funktion des Modells ist gegeben durch

$$\begin{aligned} L(\boldsymbol{\theta}, \sigma^2) &= p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N p(y_n \mid \mathbf{x}_n; \boldsymbol{\theta}, \sigma^2) \\ &= \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{1}{2\sigma^2} \left(y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n)\right)^2\right) \end{aligned} \tag{2.4}$$

Maximum-Likelihood Regression (Forts.)

- Durch Logarithmieren von (2.4) erhalten wir die Log-Likelihood Funktion

$$\begin{aligned} l(\boldsymbol{\theta}, \sigma^2) &:= \ln p(\mathbf{y} \mid \mathbf{X}; \boldsymbol{\theta}, \sigma^2) \\ &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \end{aligned} \quad (2.5)$$

- Aus (2.5) wird ersichtlich, dass der Least-Squares-Fehler minimiert werden muss, um die Likelihood in $\boldsymbol{\theta}$ zu maximieren.
- Die Lösung für $\boldsymbol{\theta}$ ist dieselbe wie in Satz 2.5, zusätzlich kann aber die *globale Unsicherheit* des Modells quantifiziert werden

$$\hat{\boldsymbol{\theta}}_{ML} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y} \quad \hat{\sigma}_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (y_n - \hat{\boldsymbol{\theta}}_{ML}^\top \boldsymbol{\phi}(\mathbf{x}_n))^2. \quad (2.6)$$

Visualisierung: Maximum-Likelihood Regression




Abbildung: Die Maximum Likelihood Lösung erlaubt zusätzlich die Quantifizierung der (globalen) Unsicherheit (Varianz) des Modells. Die Varianz wird dabei als grauer Korridor um die Regressionsgerade dargestellt.

Berücksichtigung einer Apriori-Verteilung

- Die Maximum-Likelihood Lösung ist **anfällig für Overfitting**.
- Eine Möglichkeit der **Regularisierung** ist die Verwendung einer **Apriori-Verteilung** (*Prior*).
- Für den Prior des Parametervektors θ benutzen wir die Normalverteilung

$$\theta \sim \mathcal{N}(\mathbf{0}, b^2 \mathbf{I}). \quad (2.7)$$

- Hierbei kontrolliert $b > 0$ die Varianz der Parameter.
- Es handelt sich hierbei um eine **isotropische Normalverteilung** (*rotationsinvariant*).
- Der Prior kann benutzt werden, um Vorwissen zu berücksichtigen: Er kodiert, welche Parameterwerte apriori plausibel sind.
- Häufig ist der Prior jedoch **nicht informativ** (z. B. Gleichverteilung) und wird eher aus mathematischer Bequemlichkeit gewählt.

Bestimmung des Posteriors

- Um den Posterior zu bestimmen, benutzen wir den **Satz von Bayes**

$$p(\boldsymbol{\theta} \mid \boldsymbol{X}, \boldsymbol{y}) = \frac{\overbrace{p(\boldsymbol{y} \mid \boldsymbol{X}, \boldsymbol{\theta}; \sigma^2)}^{\text{Likelihood}} \cdot \overbrace{p(\boldsymbol{\theta}; b^2)}^{\text{Prior}}}{p(\boldsymbol{y} \mid \boldsymbol{X})} \quad (2.8)$$
$$\propto p(\boldsymbol{y} \mid \boldsymbol{X}, \boldsymbol{\theta}; \sigma^2) \cdot p(\boldsymbol{\theta}; b^2).$$

- Wir betrachten $\boldsymbol{\theta}$ nun als (vektorwertige) Zufallsvariable (*sie steht nun vor dem Semikolon*).
- Bisher haben wir nur die Likelihood maximiert, nun berücksichtigen wir auch den Prior $p(\boldsymbol{\theta}; b^2)$.

Frage: Warum ignorieren wir den Nenner in (2.8)?

Optimierung des Posteriors

- Anstelle der Log-Likelihood maximieren wir nun den **Log-Posterior**.
- Diesen erhalten wir aus (2.8) durch Logarithmieren

$$\ln p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) = \ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) + \ln p(\boldsymbol{\theta}; b^2) + \text{const.} \quad (2.9)$$

- Die Konstante 'const' enthält alle Terme, die nicht von $\boldsymbol{\theta}$ abhängen.
- Die **MAP-Schätzung** (*Maximum A posteriori*) ist ein Kompromiss zwischen dem datenunabhängigen Prior und der datenabhängigen Likelihood.
- Wir betrachten im Folgenden den **negativen Log-Posterior** indem wir (2.9) negieren und erhalten für den MAP-Schätzer

$$\hat{\boldsymbol{\theta}}_{MAP} := \arg \min_{\boldsymbol{\theta}} \left\{ -\ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) \right\}. \quad (2.10)$$

Optimierung des Posteriors (Forts.)

Unter Verwendung der Transpositionsregeln schreiben wir (2.10) um zu

$$\begin{aligned} -\ln p(\boldsymbol{\theta} \mid \mathbf{X}, \mathbf{y}) &= -\ln p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}; \sigma^2) - \ln p(\boldsymbol{\theta}; b^2) + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta})^\top (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \mathbf{y} + (\boldsymbol{\Phi}\boldsymbol{\theta})^\top \boldsymbol{\Phi}\boldsymbol{\theta}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const} \\ &= \frac{1}{2\sigma^2} (\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \boldsymbol{\Phi}\boldsymbol{\theta} - 2\boldsymbol{\theta}^\top \boldsymbol{\Phi}^\top \mathbf{y}) + \frac{1}{2b^2} \boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const}. \end{aligned} \tag{2.11}$$

2.6 Aufgabe: Überlegen Sie sich, wie man in (2.11) von Zeile 1 auf Zeile 2 kommt.

Aufgabe: Berechnung des Gradienten

2.7 Aufgabe: Jetzt sind Sie an der Reihe:

- 1 Berechnen Sie den Gradienten der negativen Log-Likelihood $-\ln p(\boldsymbol{\theta} \mid \boldsymbol{X}, \boldsymbol{y})$. Benutzen Sie hierzu die Form aus (2.11).
- 2 Setzen Sie den Gradienten anschließend Null und lösen Sie nach $\boldsymbol{\theta}$ auf.
- 3 Die Lösungsformel für $\hat{\boldsymbol{\theta}}_{MAP}$ fordert die Invertierung der Matrix $\boldsymbol{\Phi}^\top \boldsymbol{\Phi} + \frac{\sigma^2}{b^2} \boldsymbol{I}$. Zeigen Sie, dass diese Inverse (zumindest *analytisch*) immer existiert.

Vergleich der MLE und MAP Lösungen

MLE-Schätzer:

$$\hat{\theta}_{ML} = (\Phi^T \Phi)^{-1} \Phi^T y \quad (2.12)$$

MAP-Schätzer:

$$\hat{\theta}_{MAP} = \left(\Phi^T \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^T y \quad (2.13)$$

Bemerkung: Setzt man $\lambda := \sigma^2/b^2$, so entspricht die MAP-Schätzung der Ridge-Regression.

Visualisierung: Vergleich der MLE und MAP Lösungen




Abbildung: Die MLE-Lösung (lila) und die MAP-Lösung (blau) im Vergleich.

Bayes'sche Regression

- Wir haben gesehen, dass MLE-Schätzungen zu **Overfitting** neigen.
- Für die MAP-Schätzung haben wir deshalb zusätzlich einen Prior $p(\theta)$ berücksichtigt, welcher der **Regularisierung** dient.

Die **Bayes'sche Regression** erweitert diesen Ansatz folgendermaßen:

- Wieder benutzen wir einen Prior $p(\theta)$ für die Modellparameter θ .
- **Aber:** Wir berechnen diesmal keine Punktschätzung der Parameter.
- Stattdessen nutzen wir die *volle Posterior-Verteilung* aus, um Vorhersagen zu machen.
- Hierzu berechnet man die **Predictive Distribution**, die sämtliche Parameterwerte mit ihren zugehörigen Wahrscheinlichkeiten in die Vorhersage einfließen lässt.

Modellannahmen

- Für den Prior benutzen wir wieder eine Normalverteilung

$$\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0). \quad (2.14)$$

- Es ist $\boldsymbol{\mu}_0$ der Mittelwert des Priors (oft benutzt man $\boldsymbol{\mu}_0 := \mathbf{0}$) und $\boldsymbol{\Sigma}_0$ dessen Kovarianzmatrix (wie oben ist diese häufig von der Form $\boldsymbol{\Sigma}_0 := b^2 \mathbf{I}$ mit $b > 0$).
- Die Likelihood modellieren wir ebenfalls analog zu oben

$$y \mid \mathbf{x}', \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}'), \sigma^2). \quad (2.15)$$

- Hierbei ist $\mathbf{x}'$ ein Datenpunkt, für den eine Vorhersage berechnet werden soll.

Prior Predictive Distribution

- In der Praxis interessieren uns die konkreten Werte der Parameter in der Regel nicht.
- Wir wollen hauptsächlich die Labels für neue Instanzen vorhersagen.
- Sei also x' eine Testinstanz.
- Die **Prior Predictive Distribution** ist gegeben durch

$$p(y | x') = \int_{\theta} p(y | x', \theta) \cdot p(\theta) = \mathbb{E}_{\theta}[p(y | x', \theta)]. \quad (2.16)$$

- Man kann (2.16) als *mittlere Vorhersage* interpretieren.
- Es handelt sich um einen *gewichteten Durchschnitt über alle möglichen Parameterwerte gemäß ihrer Wahrscheinlichkeit*.

Aufgabe: Bestimmung der Verbunddichte

2.8 Aufgabe: Der Integrand in (2.16) ist die Verbunddichte von y und θ . Mit der Produktregel gilt

$$p(y \mid \mathbf{x}', \theta; \sigma^2) \cdot p(\theta; b^2) = p(y, \theta \mid \mathbf{x}'; \sigma^2, b^2).$$

Bestimmen Sie einen Ausdruck für diese Verbunddichte.

Ein paar Hinweise:

- Sie müssen Erwartungswert und Kovarianz der Verbundverteilung bestimmen, denn ein Produkt von Normalverteilungen ist wieder normalverteilt.
- Schreiben Sie y in der Form $y = \theta^\top \phi(\mathbf{x}') + \varepsilon$ mit $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.
- Verwenden Sie die Rechenregeln für den Erwartungswert, insbesondere die Linearität.

Parameter der Prior Predictive Distribution

Die Parameter der Predictive Distribution lassen sich analytisch bestimmen:

2.9 Satz: Für die Prior Predictive Distribution gilt

$$y \mid \mathbf{x}' \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

wobei die Parameter $\boldsymbol{\mu}$ und $\boldsymbol{\Sigma}$ gegeben sind durch

$$\boldsymbol{\mu} := \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}')$$

$$\boldsymbol{\Sigma} := \boldsymbol{\phi}(\mathbf{x}')^\top \boldsymbol{\Sigma}_0 \boldsymbol{\phi}(\mathbf{x}') + \sigma^2.$$

2.10 Aufgabe: Machen Sie sich diese Aussage anhand von Satz 1.22 und mit Aufgabe 2.8 klar.

Interpretation

- Der Erwartungswert μ ergibt sich als das Skalarprodukt des Erwartungswerts des Priors mit dem Featurevektor.
- Der Term $\phi(\mathbf{x}')^\top \Sigma_0 \phi(\mathbf{x}')$ in der Formel für Σ spiegelt die Unsicherheit der Parameter θ unter dem Prior wider.
- σ^2 stellt Unsicherheit aufgrund von Datenrauschen oder nicht modellierten Effekten dar.
- Durch jedes θ , das wir vom Prior sampeln, erhält man eine Funktion $f(\mathbf{x}') := \theta^\top \phi(\mathbf{x}')$.

Der Prior $p(\theta)$ über θ induziert eine Verteilung $p(f(\mathbf{x}))$ über mögliche Funktionen.

Beispiel

- Wir nehmen an, dass die Labels durch die folgende (in der Praxis natürlich unbekannte) Funktion generiert werden

$$f(x) = \sin(x).$$

- Zusätzlich addieren wir einen Fehler-Term ε , für den $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ gilt.
- Ein Trainingsbeispiel (x_n, y_n) hat dann die Form

$$(x_n, y_n) = (x_n, \sin(x_n) + \varepsilon_n), \quad n = 1, 2, \dots, N.$$

- Als Prior über die Parameter θ wählen wir eine zentrierte (d. h. mit Erwartungswert $\mu_0 = \mathbf{0}$), isotropische Normalverteilung (hier $\Sigma_0 = \mathbf{I}$), also

$$\theta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Beispiel (Forts.)




Abbildung: Plot des Trainingsdatensatzes. Die Labels wurden hierbei mittels $y = \sin(x) + \varepsilon$ erzeugt.

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Zufällige Samples, die von der Prior Verteilung gezogen werden.

Berücksichtigung der Trainingsdaten

- Unser bisheriges Modell nutzt noch nicht die Information aus den Trainingsdaten.
- Statt dem Prior $p(\theta)$ müssen wir den Posterior $p(\theta | X, y)$ benutzen.
- Hierfür benutzen wir wieder den **Satz von Bayes**

$$p(\theta | X, y) = \frac{\overbrace{p(y | X, \theta)}^{\text{Likelihood}} \cdot \overbrace{p(\theta)}^{\text{Prior}}}{p(y | X)} \quad (2.17)$$

2.11 Satz: Für den Posterior gilt $\theta | X, y \sim \mathcal{N}(\mu_N, \Sigma_N)$ mit

$$\Sigma_N := (\Sigma_0^{-1} + \sigma^{-2} \Phi^\top \Phi)^{-1}$$

$$\mu_N := \Sigma_N (\Sigma_0^{-1} \mu_0 + \sigma^{-2} \Phi^\top y).$$

Berücksichtigung der Trainingsdaten (Forts.)

2.12 Aufgabe: Machen Sie sich diese Aussage anhand von Satz 1.22 klar.

- Die Parameter der Posterior Predictive Distribution werden analog zu Satz ?? bestimmt.
- Man ersetzt dort lediglich μ_0 durch μ_N und Σ_0 durch Σ_N .

Beispiel (Forts.)




Abbildung: Plot der Prior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Plot der Posterior Predictions und der Unsicherheit (grau).

Beispiel (Forts.)




Abbildung: Zufällige Samples, die von der Posterior Verteilung gezogen werden.


Visualisierung: Bayes'sche Regression

- Wir generieren einen Datensatz mittels der Funktion







$$f(x) = 0.5x - 0.3 + \varepsilon.$$

- Bei ε handelt es sich um additives Datenrauschen mit Mittelwert $\mu_{\varepsilon} = 0$ und Varianz $\sigma_{\varepsilon}^2 = 1$.
- Wir benutzen einen Prior für die Parameter θ







$$\theta \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$



Visualisierung: Bayes'sche Regression (Forts.)

 $N = 1$

 $N = 2$

 $N = 3$


Visualisierung: Bayes'sche Regression (Forts.)

 $N = 5$  $N = 10$  $N = 100$ 

Literatur

- [1] Christopher Bishop. *Deep Learning - Foundations and Concepts*. 2024. URL: <https://www.bishopbook.com/>.
- [2] Christopher Bishop. *Pattern Recognition and Machine Learning*. 2006. URL: <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>.