

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

Duale Hochschule Baden-Württemberg (DHBW)
Center of Advanced Studies (CAS)
Heilbronn

Lösungen zu den Übungsaufgaben

Autor:
Daniel Wehner

Semester:
Sommersemester 2027

1 Grundlagen der Statistik

Lösung zu Aufgabe 1.6

Es seien X und Y Zufallsvariablen. Die Korrelation $\text{Cor}[X, Y]$ von X und Y ist eine normierte Kovarianz von X und Y , sodass diese im Intervall $[-1, 1]$ liegt. Genauer gilt der Zusammenhang

$$\text{Cor}[X, Y] := \frac{\text{Cov}[X, Y]}{\sqrt{\text{V}[X]} \cdot \sqrt{\text{V}[Y]}}.$$

Lösung zu Aufgabe 1.8

Es sei $\mathbf{x} \in \mathbb{R}^N$ ein Zufallsvektor. Wir zeigen, dass die Matrix $\mathbb{D}[\mathbf{x}] \in \mathbb{R}^{N \times N}$ positiv semidefinit ist. Für alle $\mathbf{z} \in \mathbb{R}^N$ gilt aufgrund der Linearität und Monotonie des Erwartungswerts und der Symmetrie des Skalarprodukts

$$\begin{aligned} \mathbf{z}^\top \mathbb{D}[\mathbf{x}] \mathbf{z} &= \mathbf{z}^\top \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \mathbf{z} \\ &= \mathbb{E}[\mathbf{z}^\top (\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top \mathbf{z}] \\ &= \mathbb{E}[\underbrace{(\mathbf{z}^\top (\mathbf{x} - \mathbb{E}[\mathbf{x}]))^2}_{\geq 0}] \\ &\geq 0, \end{aligned}$$

womit die positive Semidefinitheit gezeigt ist.

Lösung zu Aufgabe 1.14

Teilaufgabe 1

Es sei $X \sim \chi_2^2$. Wir bestimmen die Dichte der transformierten Zufallsvariable $Y := \sqrt{X}$ unter Verwendung von Satz 1.13. Die Dichte der χ_2^2 -Verteilung lautet

$$p_X(x) = \frac{1}{2} e^{-\frac{x}{2}} \cdot \mathbf{1}_{[0, \infty)}(x).$$

Wir definieren $T(x) := \sqrt{x}$. Die Umkehrabbildung hiervon ist $x = T^{-1}(y) = y^2$ mit Ableitung $(T^{-1})'(y) = 2y$. Setzen wir dies in die Transformationsformel 1.13 ein, dann erhalten wir

$$\begin{aligned} p_Y(y) &= p_X(T^{-1}(y)) \cdot (T^{-1})'(y) = \frac{1}{2} e^{-\frac{y^2}{2}} \cdot \mathbf{1}_{[0, \infty)}(y^2) \cdot 2y \\ &= y e^{-\frac{1}{2}y^2}. \end{aligned}$$

Die Indikatorfunktion fällt hierbei weg, da $\mathbf{1}_{[0, \infty)}(y^2) = 1$ für alle y gilt.

Teilaufgabe 2

Wir berechnen $\mathbb{P}(Y > \frac{1}{2})$. Es ist

$$\begin{aligned} \mathbb{P}\left(Y > \frac{1}{2}\right) &= \int_{\frac{1}{2}}^{\infty} y e^{-\frac{1}{2}y^2} dy \\ &= \int_{\frac{1}{8}}^{\infty} e^{-u} du \\ &= [-e^{-u}]_{\frac{1}{8}}^{\infty} = e^{-\frac{1}{8}} \approx 0.88. \end{aligned}$$

Für das zweite Gleichheitszeichen haben wir die Substitution $u := \frac{1}{2}y^2$ benutzt. Hieraus folgt $\frac{du}{dy} = y$ und damit $dy = \frac{1}{y} du$.

Lösung zu Aufgabe 1.19

Wir benutzen Satz 1.18 und erhalten

$$\begin{aligned} \mu_{X_1|X_2} &= \mu_{X_1} + \Sigma_{X_1X_2} \cdot \Sigma_{X_2X_2}^{-1} (X_2 - \mu_{X_2}) \\ &= \mathbb{E}[X_1] + \text{Cov}[X_1, X_2] \cdot \mathbb{V}[X_2]^{-1} \cdot (X_2 - \mathbb{E}[X_2]) \\ &= 0 + (-1) \cdot \frac{1}{5} \cdot (-1 - 2) \\ &= 0.6 \end{aligned}$$

und

$$\begin{aligned}
 \Sigma_{X_1|X_2} &= \Sigma_{X_1X_1} - \Sigma_{X_1X_2} \Sigma_{X_2X_2}^{-1} \Sigma_{X_2X_1} \\
 &= \mathbb{V}[X_1] - \text{Cov}[X_1, X_2] \cdot \mathbb{V}[X_2]^{-1} \cdot \text{Cov}[X_2, X_1] \\
 &= 0.3 - (-1) \cdot \frac{1}{5} \cdot (-1) \\
 &= 0.1.
 \end{aligned}$$

Es ist also $(X_1 | X_2 = -1) \sim \mathcal{N}(0.6, 0.1)$. Wir erhalten damit eine univariate Normalverteilung.

Lösung zu Aufgabe 1.21

Mit Satz 1.20 lautet die Randverteilung der Zufallsvariablen X_1

$$X_1 \sim \mathcal{N}(0, 0.3).$$

Lösung zu Aufgabe 1.27

Teilaufgabe 1

Wir stellen zunächst die Likelihood Funktion $L(\lambda)$ auf und wenden den Logarithmus an, um die Log-Likelihood Funktion $l(\lambda)$ zu erhalten. Diese ist nach Anwendung der bekannten Logarithmengesetze durch die folgende Funktion gegeben:

$$\begin{aligned}
 l(\lambda) &:= \ln \left[\prod_{n=1}^N \frac{\lambda^{x_n}}{x_n!} e^{-\lambda} \right] \\
 &= \sum_{n=1}^N \left(\ln(\lambda^{x_n}) - \ln(x_n!) + \ln(e^{-\lambda}) \right) \\
 &= \sum_{n=1}^N \left(x_n \ln(\lambda) - \ln(x_n!) - \lambda \right) \\
 &= -N\lambda + \ln(\lambda) \sum_{n=1}^N x_n - \sum_{n=1}^N \ln(x_n!)
 \end{aligned}$$

Nun bestimmen wir die Ableitung von l nach dem Parameter λ . Diese ist nun einfach zu bestimmen. Wir erhalten

$$\frac{d}{d\lambda} l(\lambda) = -N + \frac{1}{\lambda} \sum_{n=1}^N x_n.$$

Nullsetzen der ersten Ableitung ergibt

$$\frac{1}{\lambda} \sum_{n=1}^N x_n = N \iff \lambda_* = \frac{1}{N} \sum_{n=1}^N x_n.$$

Wir bestimmen nun das Vorzeichen der zweiten Ableitung, um festzustellen, ob es sich tatsächlich um ein Maximum handelt. Die zweite Ableitung ist

$$\frac{d^2}{d\lambda^2} l(\lambda) = -\frac{1}{\lambda^2} \sum_{n=1}^N x_n.$$

Diese ist negativ für alle $\lambda > 0$ wegen $x_n \in \mathbb{N}$ und dem negativen Vorzeichen. Somit ist das arithmetische Mittel der Datenpunkte der Maximum Likelihood Schätzer für den Parameter λ der Poisson-Verteilung, also $\hat{\lambda}_{ML} := \lambda_*$.

Teilaufgabe 2

Der Schätzer $\hat{\lambda}_{ML}$ ist erwartungstreu, denn mit der Linearität des Erwartungswerts folgt

$$\mathbb{E}[\hat{\lambda}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \sum_{n=1}^N \lambda = \frac{1}{N} \cdot N \cdot \lambda = \lambda.$$

Lösung zu Aufgabe 1.29

Es sei $X \sim B_{1,\mu}$ eine Zufallsvariable mit der Dichte $p_X(k) = \mu^k \cdot (1-\mu)^{1-k}$. Hierbei gilt $k \in \{0, 1\}$. Wir bestimmen zunächst den Erwartungswert von X . Es ist

$$\mathbb{E}[X] = \sum_{k=0}^1 k \cdot p_X(k) = 0 \cdot (1-\mu) + 1 \cdot \mu = \mu.$$

Nun bestimmen wir die Varianz von X . Hier gilt

$$\mathbb{V}[X] = \sum_{k=0}^1 (k-\mu)^2 \cdot p_X(k) = \mu^2 \cdot (1-\mu) + (1-\mu)^2 \cdot \mu$$

$$\begin{aligned}
&= \mu^2 - \mu^3 + \mu - 2\mu^2 + \mu^3 = \mu - \mu^2 \\
&= \mu \cdot (1 - \mu).
\end{aligned}$$

Lösung zu Aufgabe 1.32

Um zu beweisen, dass die Gamma-Verteilung der konjugierte Prior für den Parameter λ der Poisson-Verteilung ist, zeigt man, dass die aus Prior und Likelihood gebildete Posterior-Verteilung ebenfalls von der Form einer Gamma-Verteilung ist.

Likelihood (Poisson): Mit der Dichte der Poisson-Verteilung bestimmen wir zunächst die Likelihood für die Beobachtungen $x_1, x_2, \dots, x_N$. Es ist

$$L(\lambda) = \prod_{n=1}^N \frac{\lambda^{x_n}}{x_n!} e^{-\lambda} \propto \lambda^{\sum_{n=1}^N x_i} \cdot e^{-N\lambda}.$$

Prior (Gamma): Nun nehmen wir an, dass λ vor Beobachtung der Daten einer Gamma-Verteilung folgt. Diese verfügt über die Parameter α (Form) und β (Raten-/Skalenparameter). Hier gilt

$$p(\lambda) = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \lambda^{\alpha-1} \cdot e^{-\beta\lambda} \propto \lambda^{\alpha-1} \cdot e^{-\beta\lambda}.$$

Mit dem Satz von Bayes ist die Posterior-Verteilung proportional zum Produkt aus Likelihood und Prior, d. h.

$$\begin{aligned}
p(\lambda \mid \mathbf{x}) &\propto \lambda^{\sum_{n=1}^N x_i} \cdot e^{-N\lambda} \cdot \lambda^{\alpha-1} \cdot e^{-\beta\lambda} \\
&= \lambda^{\alpha + \sum_{n=1}^N x_n - 1} \cdot e^{-(\beta + N)\lambda}.
\end{aligned}$$

Der letzte Ausdruck besitzt (bis auf Normierung) die funktionale Form einer Gamma-Verteilung mit den Parametern $\hat{\alpha} := \alpha + \sum_{n=1}^N x_n$ und $\hat{\beta} := \beta + N$. Da der Posterior also wie der Prior zur Familie der Gamma-Verteilungen gehört, ist die Konjugiertheit formal gezeigt.

2 Regression

Lösung zu Aufgabe [2.6](#)

Lösung zu Aufgabe [2.7](#)

Lösung zu Aufgabe [2.9](#)

Lösung zu Aufgabe [2.11](#)