

Vertiefung Wissensgewinnung aus Daten und Deep Learning (Teil I)

Duale Hochschule Baden-Württemberg (DHBW)
Center of Advanced Studies (CAS)
Heilbronn

Lösungen zu den Übungsaufgaben

Autor:
Daniel Wehner

Semester:
Sommersemester 2027

1 Grundlagen der Statistik

Lösung zu Aufgabe 1.6

Es seien X und Y Zufallsvariablen. Die Korrelation $\text{Cor}[X, Y]$ von X und Y ist eine normierte Kovarianz von X und Y , sodass diese im Intervall $[-1, 1]$ liegt. Genauer gilt der Zusammenhang

$$\text{Cor}[X, Y] := \frac{\text{Cov}[X, Y]}{\sqrt{\text{V}[X]} \cdot \sqrt{\text{V}[Y]}}.$$

Lösung zu Aufgabe 1.8

Es sei $\mathbf{x} \in \mathbb{R}^N$ ein Zufallsvektor. Wir zeigen, dass die Matrix $\mathbb{D}[\mathbf{x}] \in \mathbb{R}^{N \times N}$ positiv semidefinit ist. Für alle $\mathbf{z} \in \mathbb{R}^N$ gilt aufgrund der Linearität und Monotonie des Erwartungswerts und der Symmetrie des Skalarprodukts

$$\begin{aligned} \mathbf{z}^\top \mathbb{D}[\mathbf{x}] \mathbf{z} &= \mathbf{z}^\top \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top] \mathbf{z} \\ &= \mathbb{E}[\mathbf{z}^\top (\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^\top \mathbf{z}] \\ &= \mathbb{E}[\underbrace{(\mathbf{z}^\top (\mathbf{x} - \mathbb{E}[\mathbf{x}]))^2}_{\geq 0}] \\ &\geq 0, \end{aligned}$$

womit die positive Semidefinitheit gezeigt ist.

Lösung zu Aufgabe 1.14

Teilaufgabe 1

Es sei $X \sim \chi_2^2$. Wir bestimmen die Dichte der transformierten Zufallsvariable $Y := \sqrt{X}$ unter Verwendung von Satz 1.13. Die Dichte der χ_2^2 -Verteilung lautet

$$p_X(x) = \frac{1}{2} e^{-\frac{x}{2}} \cdot \mathbf{1}_{[0, \infty)}(x).$$

Wir definieren $T(x) := \sqrt{x}$. Die Umkehrabbildung hiervon ist $x = T^{-1}(y) = y^2$ mit Ableitung $(T^{-1})'(y) = 2y$. Setzen wir dies in die Transformationsformel 1.13 ein, dann erhalten wir

$$\begin{aligned} p_Y(y) &= p_X(T^{-1}(y)) \cdot (T^{-1})'(y) = \frac{1}{2} e^{-\frac{y^2}{2}} \cdot \mathbf{1}_{[0, \infty)}(y^2) \cdot 2y \\ &= y e^{-\frac{1}{2}y^2}. \end{aligned}$$

Die Indikatorfunktion fällt hierbei weg, da $\mathbf{1}_{[0, \infty)}(y^2) = 1$ für alle y gilt.

Teilaufgabe 2

Wir berechnen $\mathbb{P}\left(Y > \frac{1}{2}\right)$. Es ist

$$\begin{aligned} \mathbb{P}\left(Y > \frac{1}{2}\right) &= \int_{\frac{1}{2}}^{\infty} y e^{-\frac{1}{2}y^2} dy \\ &= \int_{\frac{1}{8}}^{\infty} e^{-u} du \\ &= [-e^{-u}]_{\frac{1}{8}}^{\infty} = e^{-\frac{1}{8}} \approx 0.88. \end{aligned}$$

Für das zweite Gleichheitszeichen haben wir die Substitution $u := \frac{1}{2}y^2$ benutzt. Hieraus folgt $\frac{du}{dy} = y$ und damit $dy = \frac{1}{y} du$.

Lösung zu Aufgabe 1.19

Wir benutzen Satz 1.18 und erhalten

$$\begin{aligned} \mu_{X_1|X_2} &= \mu_{X_1} + \Sigma_{X_1X_2} \cdot \Sigma_{X_2X_2}^{-1} (X_2 - \mu_{X_2}) \\ &= \mathbb{E}[X_1] + \text{Cov}[X_1, X_2] \cdot \mathbb{V}[X_2]^{-1} \cdot (X_2 - \mathbb{E}[X_2]) \\ &= 0 + (-1) \cdot \frac{1}{5} \cdot (-1 - 2) \\ &= 0.6 \end{aligned}$$

und

$$\begin{aligned}
 \Sigma_{X_1|X_2} &= \Sigma_{X_1X_1} - \Sigma_{X_1X_2} \Sigma_{X_2X_2}^{-1} \Sigma_{X_2X_1} \\
 &= \mathbb{V}[X_1] - \text{Cov}[X_1, X_2] \cdot \mathbb{V}[X_2]^{-1} \cdot \text{Cov}[X_2, X_1] \\
 &= 0.3 - (-1) \cdot \frac{1}{5} \cdot (-1) \\
 &= 0.1.
 \end{aligned}$$

Es ist also $(X_1 | X_2 = -1) \sim \mathcal{N}(0.6, 0.1)$. Wir erhalten damit eine univariate Normalverteilung.

Lösung zu Aufgabe 1.21

Mit Satz 1.20 lautet die Randverteilung der Zufallsvariablen X_1

$$X_1 \sim \mathcal{N}(0, 0.3).$$

Lösung zu Aufgabe 1.27

Teilaufgabe 1

Wir stellen zunächst die Likelihood Funktion $L(\lambda)$ auf und wenden den Logarithmus an, um die Log-Likelihood Funktion $l(\lambda)$ zu erhalten. Diese ist nach Anwendung der bekannten Logarithmengesetze durch die folgende Funktion gegeben:

$$\begin{aligned}
 l(\lambda) &:= \ln \left[\prod_{n=1}^N \frac{\lambda^{x_n}}{x_n!} e^{-\lambda} \right] \\
 &= \sum_{n=1}^N (\ln(\lambda^{x_n}) - \ln(x_n!) + \ln(e^{-\lambda})) \\
 &= \sum_{n=1}^N (x_n \ln(\lambda) - \ln(x_n!) - \lambda) \\
 &= -N\lambda + \ln(\lambda) \sum_{n=1}^N x_n - \sum_{n=1}^N \ln(x_n!)
 \end{aligned}$$

Nun bestimmen wir die Ableitung von l nach dem Parameter λ . Diese ist nun einfach zu bestimmen. Wir erhalten

$$\frac{d}{d\lambda} l(\lambda) = -N + \frac{1}{\lambda} \sum_{n=1}^N x_n.$$

Nullsetzen der ersten Ableitung ergibt

$$\frac{1}{\lambda} \sum_{n=1}^N x_n = N \iff \lambda_* = \frac{1}{N} \sum_{n=1}^N x_n.$$

Wir bestimmen nun das Vorzeichen der zweiten Ableitung, um festzustellen, ob es sich tatsächlich um ein Maximum handelt. Die zweite Ableitung ist

$$\frac{d^2}{d\lambda^2} l(\lambda) = -\frac{1}{\lambda^2} \sum_{n=1}^N x_n.$$

Diese ist negativ für alle $\lambda > 0$ wegen $x_n \in \mathbb{N}$ und dem negativen Vorzeichen. Somit ist das arithmetische Mittel der Datenpunkte der Maximum Likelihood Schätzer für den Parameter λ der Poisson-Verteilung, also $\hat{\lambda}_{ML} := \lambda_*$.

Teilaufgabe 2

Der Schätzer $\hat{\lambda}_{ML}$ ist erwartungstreu, denn mit der Linearität des Erwartungswerts folgt

$$\mathbb{E}[\hat{\lambda}_{ML}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \sum_{n=1}^N \lambda = \frac{1}{N} \cdot N \cdot \lambda = \lambda.$$

Lösung zu Aufgabe 1.29

Es sei $X \sim B_{1,\mu}$ eine Zufallsvariable mit der Dichte $p_X(k) = \mu^k \cdot (1 - \mu)^{1-k}$. Hierbei gilt $k \in \{0, 1\}$. Wir bestimmen zunächst den Erwartungswert von X . Es ist

$$\mathbb{E}[X] = \sum_{k=0}^1 k \cdot p_X(k) = 0 \cdot (1 - \mu) + 1 \cdot \mu = \mu.$$

Nun bestimmen wir die Varianz von X . Hier gilt

$$\begin{aligned}\mathbb{V}[X] &= \sum_{k=0}^1 (k - \mu)^2 \cdot p_X(k) = \mu^2 \cdot (1 - \mu) + (1 - \mu)^2 \cdot \mu \\ &= \mu^2 - \mu^3 + \mu - 2\mu^2 + \mu^3 = \mu - \mu^2 \\ &= \mu \cdot (1 - \mu).\end{aligned}$$

Lösung zu Aufgabe 1.32

Um zu beweisen, dass die Gamma-Verteilung der konjugierte Prior für den Parameter λ der Poisson-Verteilung ist, zeigt man, dass die aus Prior und Likelihood gebildete Posterior-Verteilung ebenfalls von der Form einer Gamma-Verteilung ist.

Likelihood (Poisson): Mit der Dichte der Poisson-Verteilung bestimmen wir zunächst die Likelihood für die Beobachtungen $x_1, x_2, \dots, x_N$. Es ist

$$L(\lambda) = \prod_{n=1}^N \frac{\lambda^{x_n}}{x_n!} e^{-\lambda} \propto \lambda^{\sum_{n=1}^N x_n} \cdot e^{-N\lambda}.$$

Prior (Gamma): Nun nehmen wir an, dass λ vor Beobachtung der Daten einer Gamma-Verteilung folgt. Diese verfügt über die Parameter α (Form) und β (Raten-/Skalenparameter). Hier gilt

$$p(\lambda) = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \lambda^{\alpha-1} \cdot e^{-\beta\lambda} \propto \lambda^{\alpha-1} \cdot e^{-\beta\lambda}.$$

Mit dem Satz von Bayes ist die Posterior-Verteilung proportional zum Produkt aus Likelihood und Prior, d. h.

$$\begin{aligned}p(\lambda \mid \mathbf{x}) &\propto \lambda^{\sum_{n=1}^N x_n} \cdot e^{-N\lambda} \cdot \lambda^{\alpha-1} \cdot e^{-\beta\lambda} \\ &= \lambda^{(\alpha + \sum_{n=1}^N x_n) - 1} \cdot e^{-(\beta + N)\lambda}.\end{aligned}$$

Der letzte Ausdruck besitzt (bis auf Normierung) die funktionale Form einer Gamma-Verteilung mit den Parametern $\hat{\alpha} := \alpha + \sum_{n=1}^N x_n$ und $\hat{\beta} := \beta + N$. Da der Posterior also wie der Prior zur Familie der Gamma-Verteilungen gehört, ist die Konjugiertheit formal gezeigt.

2 Regression

Lösung zu Aufgabe 2.6

Die Log-Likelihood des Modells für den Parametervektor θ ist gegeben durch die Funktion

$$\begin{aligned} l(\theta) &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \theta^\top \phi(x_n))^2 \\ &= -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\Phi\theta - \mathbf{y})^\top (\Phi\theta - \mathbf{y}) \\ &\propto -\frac{1}{2\sigma^2} (\Phi\theta - \mathbf{y})^\top (\Phi\theta - \mathbf{y}). \end{aligned}$$

Ferner gilt für die Prior-Verteilung des Parametervektors $\theta \sim \mathcal{N}(\mathbf{0}, b^2 \mathbf{I})$, also

$$\pi(\theta; \mathbf{0}, b^2 \mathbf{I}) = \frac{1}{(2\pi)^{\frac{M+1}{2}} \cdot b^{M+1}} \cdot \exp\left(-\frac{\theta^\top \theta}{2b^2}\right) \propto -\frac{1}{2b^2} \theta^\top \theta.$$

Num summieren wir beide Terme und negieren das Vorzeichen, um den negativen Log-Posterior zu erhalten.

Lösung zu Aufgabe 2.7

Teilaufgabe 1

Der Gradient des negativen Log-Posteriors lautet

$$\begin{aligned} \frac{\partial}{\partial \theta} -\ln p(\theta|X, \mathbf{y}) &= \frac{\partial}{\partial \theta} \frac{1}{2\sigma^2} (\theta^\top \Phi^\top \Phi \theta - 2\theta^\top \Phi^\top \mathbf{y}) + \frac{\partial}{\partial \theta} \frac{1}{2b^2} \theta^\top \theta \\ &= \frac{1}{\sigma^2} (\Phi^\top \Phi \theta - \Phi^\top \mathbf{y}) + \frac{1}{b^2} \theta. \end{aligned}$$

Teilaufgabe 2

Nun setzen wir den Gradienten Null und lösen nach θ auf um den MAP-Schätzer zu erhalten

$$\begin{aligned} \frac{1}{\sigma^2}(\Phi^\top \Phi \theta - \Phi^\top y) + \frac{1}{b^2} \theta &\stackrel{!}{=} 0 \\ \Leftrightarrow \left(\Phi^\top \Phi + \frac{\sigma^2}{b^2} I \right) \theta &= \Phi^\top y \\ \Leftrightarrow \hat{\theta}_{MAP} &= \left(\Phi^\top \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^\top y. \end{aligned}$$

Teilaufgabe 3

Wir prüfen die positive Semidefinitheit der Matrix $\Phi^\top \Phi + \frac{\sigma^2}{b^2} I$. Dazu sei $z \in \mathbb{R}^{M+1} \setminus \{0\}$. Dann ist

$$z^\top \left(\Phi^\top \Phi + \frac{\sigma^2}{b^2} I \right) z = z^\top \Phi^\top \Phi z + \frac{\sigma^2}{b^2} z^\top I z > 0,$$

denn zum Einen ist die Matrix $\Phi^\top \Phi$ mit Satz 2.2 positiv semidefinit, also $z^\top \Phi^\top \Phi z \geq 0$ und zum Andern $\frac{\sigma^2}{b^2} I$ positiv definit, da $\sigma^2 > 0$, $b > 0$ ist.

Lösung zu Aufgabe 2.8

Da ein Produkt von Normalverteilungen wieder normalverteilt ist, folgt die Verbunddichte $p(y, \theta \mid x')$ einer partitionierten Normalverteilung der Form

$$(y \quad \theta^\top)^\top \mid x' \sim \mathcal{N} \left(\begin{bmatrix} \mu_y \\ \mu_\theta \end{bmatrix}, \begin{bmatrix} \Sigma_{yy} & \Sigma_{y\theta} \\ \Sigma_{\theta y} & \Sigma_{\theta\theta} \end{bmatrix} \right).$$

Da eine Normalverteilung durch Festlegung der Parameter eindeutig bestimmt ist, genügt es also, die obigen Parameter zu berechnen. Hierzu schreiben wir $y = \theta^\top \phi(x') + \varepsilon$ und nutzen die Linearität des Erwartungswerts.

Wir beginnen mit den Erwartungswerten. Es ist

$$\begin{aligned} \mu_y &= \mathbb{E}[y] \\ &= \mathbb{E}[\theta^\top \phi(x') + \varepsilon] = \mathbb{E}[\theta]^\top \phi(x') + \mathbb{E}[\varepsilon] \end{aligned}$$

$$= \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}')$$

und

$$\boldsymbol{\mu}_\theta = \mathbb{E}[\boldsymbol{\theta}] = \boldsymbol{\mu}_0.$$

Nun bestimmen wir die Parameter Σ_{yy} , $\Sigma_{y\theta}$, $\Sigma_{\theta y}$ und $\Sigma_{\theta\theta}$. Es ist

$$\begin{aligned} \Sigma_{yy} &= \mathbb{E}[(y - \mathbb{E}[y])(y - \mathbb{E}[y])^\top] \\ &= \mathbb{E}[(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}') + \varepsilon - \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}'))(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}') + \varepsilon - \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}'))^\top] \\ &= \mathbb{E}[((\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}') + \varepsilon)(\boldsymbol{\phi}(\mathbf{x}')^\top (\boldsymbol{\theta} - \boldsymbol{\mu}_0) + \varepsilon^\top)] \\ &= \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}') \boldsymbol{\phi}(\mathbf{x}')^\top (\boldsymbol{\theta} - \boldsymbol{\mu}_0) + (\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}') \varepsilon^\top \\ &\quad + \varepsilon \boldsymbol{\phi}(\mathbf{x}')^\top (\boldsymbol{\theta} - \boldsymbol{\mu}_0) + \varepsilon \varepsilon^\top] \end{aligned}$$

Für den ersten Term gilt

$$\begin{aligned} \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}') \boldsymbol{\phi}(\mathbf{x}')^\top (\boldsymbol{\theta} - \boldsymbol{\mu}_0)] &= \boldsymbol{\phi}(\mathbf{x}')^\top \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top] \boldsymbol{\phi}(\mathbf{x}') \\ &= \boldsymbol{\phi}(\mathbf{x}')^\top \Sigma_0 \boldsymbol{\phi}(\mathbf{x}'). \end{aligned}$$

Die beiden Kreuzterme fallen weg, da die Zufallsvariablen $\boldsymbol{\theta}$ und ε stochastisch unabhängig sind und $\mathbb{E}[\varepsilon] = 0$ ist. Es gilt

$$\mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}') \varepsilon^\top] = \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}')] \cdot \mathbb{E}[\varepsilon^\top] = 0.$$

Schließlich gilt $\mathbb{E}[\varepsilon \varepsilon^\top] = \sigma^2$. Zusammen erhalten wir also $\Sigma_{yy} = \boldsymbol{\phi}(\mathbf{x}')^\top \Sigma_0 \boldsymbol{\phi}(\mathbf{x}') + \sigma^2$.

Mit analogen Schritten berechnet man

$$\begin{aligned} \Sigma_{y\theta} &= \mathbb{E}[(y - \mathbb{E}[y])(\boldsymbol{\theta} - \mathbb{E}[\boldsymbol{\theta}])^\top] \\ &= \mathbb{E}[(\boldsymbol{\theta}^\top \boldsymbol{\phi}(\mathbf{x}') + \varepsilon - \boldsymbol{\mu}_0^\top \boldsymbol{\phi}(\mathbf{x}'))(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top] \\ &= \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}')(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top + \varepsilon(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top] \\ &= \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \boldsymbol{\phi}(\mathbf{x}')(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top] \\ &= \mathbb{E}[\boldsymbol{\phi}(\mathbf{x}')^\top (\boldsymbol{\theta} - \boldsymbol{\mu}_0)(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top] \\ &= \boldsymbol{\phi}(\mathbf{x}')^\top \mathbb{E}[(\boldsymbol{\theta} - \boldsymbol{\mu}_0)(\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top] \\ &= \boldsymbol{\phi}(\mathbf{x}')^\top \Sigma_0. \end{aligned}$$

Aus Symmetriegründen gilt $\Sigma_{\theta y} = \Sigma_0 \phi(x')$. Per Definition ist schließlich $\Sigma_{\theta\theta} = \Sigma_0$. Zusammenfassend erhalten wir für die Verbundverteilung also

$$(y \quad \theta^\top)^\top | x' \sim \mathcal{N} \left(\begin{bmatrix} \mu_0^\top \phi(x') \\ \mu_0 \end{bmatrix}, \begin{bmatrix} \phi(x')^\top \Sigma_0 \phi(x') + \sigma^2 & \phi(x')^\top \Sigma_0 \\ \Sigma_0 \phi(x') & \Sigma_0 \end{bmatrix} \right).$$

Lösung zu Aufgabe 2.10

Um die Parameter der Prior Predictive Distribution aus Satz 2.9 mithilfe des allgemeinen Satzes 1.22 zu bestimmen, ordnen wir die Variablen des Bayes'schen Regressionsmodells den Variablen aus Satz 1.22 zu.

Allgemeiner Satz 1.22	x	μ	Σ	y	A	b	Λ
Bayes'sche Regression – Satz 2.9	θ	μ_0	Σ_0	y	$\phi(x')^\top$	0	σ^2

Laut Satz 1.22 gilt für die unbedingte Verteilung von y

$$y \sim \mathcal{N}(A\mu + b, A\Sigma A^\top + \Lambda).$$

Nutzen wir das Mapping aus obiger Tabelle und berücksichtigen noch, dass die Verteilung für die Bayes'sche Regression zusätzlich von der ungesehenen Test-Instanz x' abhängt, so erhalten wir

$$\begin{aligned} y | x' &\sim \mathcal{N}(\phi(x')^\top \mu_0 + 0, \phi(x')^\top \Sigma_0 \phi(x') + \sigma^2) \\ &= \mathcal{N}(\mu_0^\top \phi(x'), \phi(x')^\top \Sigma_0 \phi(x') + \sigma^2). \end{aligned}$$

Dies entspricht exakt der Form aus Satz 2.9.

Analog ergibt sich die Aussage durch Marginalisierung der Verbundverteilung aus Aufgabe 2.8. Verwende hierzu Satz 1.20.

Lösung zu Aufgabe 2.12

Wir bestimmen die Parameter der Posterior-Verteilung analog zur Lösung von Aufgabe 2.10. Das oben dargestellte Mapping stimmt weitestgehend überein. Wir müssen lediglich berücksichtigen, dass die Posterior-Verteilung der Parameter von allen Punkten des Trai-

ningsdatensatzes abhängt, und nicht nur von einer einzigen Testinstanz. Wir müssen also $\mathbf{A}$ auf Φ und Λ auf $\sigma^2 \mathbf{I}$ mappen.

Setzen wir dieses Mapping in die Formel aus Satz 1.22 ein, so erhalten wir für die Kovarianz

$$\begin{aligned}\Sigma_N &= \Gamma \\ &= (\Sigma^{-1} + \mathbf{A}^\top \Lambda^{-1} \mathbf{A})^{-1} \\ &= (\Sigma_0^{-1} + \Phi^\top \sigma^{-2} \mathbf{I} \Phi)^{-1} \\ &= (\Sigma_0^{-1} + \sigma^{-2} \Phi^\top \Phi)^{-1}.\end{aligned}$$

Analog erhalten wir für den Mittelwert

$$\begin{aligned}\mu_N &= \Gamma[\Sigma^{-1} \mu + \mathbf{A}^\top \Lambda^{-1}(\mathbf{y} - \mathbf{b})] \\ &= \Sigma_N[\Sigma_0^{-1} \mu_0 + \Phi^\top \sigma^{-2} \mathbf{I} \mathbf{y}] \\ &= \Sigma_N[\Sigma_0^{-1} \mu_0 + \sigma^{-2} \Phi^\top \mathbf{y}].\end{aligned}$$

Auch diese Aussage lässt sich über die Verbundverteilung aus Aufgabe 2.8, allerdings werden hier noch weitere Matrixidentitäten benötigt, um die in Satz 2.11 aufgeführte Form zu erhalten.

3 Gaussian Mixture Models (GMMs)

Lösung zu Aufgabe [3.2](#)

Lösung zu Aufgabe [3.3](#)

4 Expectation-Maximization (EM) Algorithmus

Lösung zu Aufgabe 4.3

Schritt 1: Ermittlung der vollständigen Log-Likelihood.

Da alle Münzwürfe *stochastisch unabhängig* sind, ist die gemeinsame Wahrscheinlichkeit des Gesamtexperiments das Produkt der Einzelwahrscheinlichkeiten

$$p(x_1, x_2, z_3; \theta) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot p(z_3; \theta).$$

Die Datenpunkte folgen einer *Bernoulli-Verteilung*. Setzen wir deren Dichte ein, so erhalten wir

$$\begin{aligned} p(x_1, x_2, z_3; \theta) &= [\theta^{x_1} \cdot (1 - \theta)^{1-x_1}] \cdot [\theta^{x_2} \cdot (1 - \theta)^{1-x_2}] \cdot [\theta^{z_3} \cdot (1 - \theta)^{1-z_3}] \\ &= \theta^{x_1+x_2+z_3} \cdot (1 - \theta)^{(1-x_1)+(1-x_2)+(1-z_3)} \\ &= \theta^{x_1+x_2+z_3} \cdot (1 - \theta)^{3-x_1-x_2-z_3}. \end{aligned}$$

Die Anwendung des Logarithmus ergibt schließlich

$$\ln p(x_1, x_2, z_3; \theta) = (x_1 + x_2 + z_3) \ln \theta + (3 - x_1 - x_2 - z_3) \ln(1 - \theta).$$

Laut Aufgabenstellung ist $x_1 = 1$ und $x_2 = 0$. Dies können wir direkt in das vorangehende Ergebnis einsetzen und erhalten

$$\ln p(x_1 = 1, x_2 = 0, z_3; \theta) = (1 + z_3) \ln \theta + (2 - z_3) \ln(1 - \theta).$$

Schritt 2: Der E-Schritt (Bestimmung des Erwartungswerts).

Wir bestimmen die Funktion $Q(\theta, \theta_{\text{alt}}) = \mathbb{E}_{z_3 \sim p(z_3 | x_1=1, x_2=0; \theta_{\text{alt}})}[\ln p(x_1, x_2, z_3; \theta)]$. Da die drei Münzwürfe *stochastisch unabhängig* sind, hängt die Verteilung des fehlenden Wurfes z_3 nicht von den vorherigen Würfeln x_1 und x_2 ab. Der kompliziert aussehende Ausdruck für den Posterior $p(z_3 | x_1 = 1, x_2 = 0; \theta_{\text{alt}})$ vereinfacht sich deshalb wesentlich zu $p(z_3; \theta_{\text{alt}})$. Denn aufgrund der Unabhängigkeit verändert die Tatsache, dass man x_1 und x_2 beobachtet, nichts an der Wahrscheinlichkeit für z_3 . Für den Erwartungswert von z_3 unter der Posterior-Verteilung gilt daher $\mathbb{E}_{z_3 \sim p(z_3; \theta_{\text{alt}})}[z_3] = \theta_{\text{alt}} = 0.7$, denn z_3 folgt einer Bernoulli-Verteilung. Damit und mit der Linearität des Erwartungswerts erhalten wir für

$Q(\theta, \theta_{\text{alt}})$ den folgenden Ausdruck

$$\begin{aligned}
 Q(\theta, \theta_{\text{alt}}) &= \mathbb{E}_{z_3 \sim p(z_3; \theta_{\text{alt}})} [\ln p(x_1, x_2, z_3; \theta)] \\
 &= \mathbb{E}_{z_3 \sim p(z_3; \theta_{\text{alt}})} [(1 + z_3) \ln \theta + (2 - z_3) \ln(1 - \theta)] \\
 &= (1 + \mathbb{E}_{z_3 \sim p(z_3; \theta_{\text{alt}})} [z_3]) \ln \theta + (2 - \mathbb{E}_{z_3 \sim p(z_3; \theta_{\text{alt}})} [z_3]) \ln(1 - \theta) \\
 &= (1 + 0.7) \ln \theta + (2 - 0.7) \ln(1 - \theta) \\
 &= 1.7 \cdot \ln \theta + 1.3 \cdot \ln(1 - \theta).
 \end{aligned}$$

Schritt 3: Der M-Schritt (Maximierung).

Wir maximieren nun $Q(\theta, \theta_{\text{alt}})$ bezüglich θ , um θ_{neu} zu erhalten. Dazu bilden wir die Ableitung nach θ und setzen diese gleich Null. Es ist

$$\frac{\partial}{\partial \theta} Q(\theta, \theta_{\text{alt}}) = \frac{1.7}{\theta} - \frac{1.3}{1 - \theta} \stackrel{!}{=} 0.$$

Durch Auflösen nach θ erhalten wir $\theta_{\text{neu}} = \frac{1.7}{3} \approx 0.567$. Führt man noch weitere Iterationen aus, so konvergiert das Verfahren bei $\theta^* = 0.5$.

Interpretation: Wir haben einen Erfolg und einen Misserfolg beobachtet. Der nicht beobachtete Wurf geht zusätzlich mit dem Erwartungswert von 0.7 ein, sodass wir den neuen Parameter erhalten, indem wir die Gesamtanzahl der Köpfe (1.7) durch die Anzahl der Würfe (3) teilen.

5 Probabilistische PCA (PPCA)

Lösung zu Aufgabe 6.1

Es gilt

$$\begin{aligned}
 \Sigma_{xx} &= \mathbb{E}[(x - \mathbb{E}[x])(x - \mathbb{E}[x])^\top] \\
 &= \mathbb{E}[(Wz + \mu + \varepsilon - \mu)(Wz + \mu + \varepsilon - \mu)^\top] \\
 &= \mathbb{E}[(Wz + \varepsilon)(Wz + \varepsilon)^\top] \\
 &= \mathbb{E}[Wz z^\top W^\top + Wz \varepsilon^\top + \varepsilon z^\top W^\top + \varepsilon \varepsilon^\top] \\
 &= \mathbb{E}[Wz z^\top W^\top] + \mathbb{E}[\varepsilon \varepsilon^\top] \\
 &= WW^\top + \sigma^2 I.
 \end{aligned}$$

Lösung zu Aufgabe 6.3

Für die Kovarianz des Posteriors errechnet man

$$\begin{aligned}
 \Sigma_{z|x} &= \Sigma_{zz} - \Sigma_{zx} \Sigma_{xx}^{-1} \Sigma_{xz} \\
 &= I - W^\top C^{-1} W \\
 &= I - M^{-1} W^\top W \\
 &= I - M^{-1} (M - \sigma^2 I) \\
 &= I - M^{-1} M + \sigma^2 M^{-1} \\
 &= \sigma^2 M^{-1}.
 \end{aligned}$$

Lösung zu Aufgabe 6.5

Für die Ableitung nach σ^2 betrachten wir die Zielfunktion $f(\sigma^2)$, wobei wir das Ergebnis $\mu = \bar{x}$ wieder direkt einsetzen

$$f(\sigma^2) = - \sum_{n=1}^N \left\{ \frac{M}{2} \ln(2\pi\sigma^2) + \frac{1}{2\sigma^2} \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 - \frac{1}{\sigma^2} \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) + \frac{1}{2\sigma^2} \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \right\}$$

Wir bilden zunächst die partiellen Ableitungen der einzelnen Terme innerhalb der äußeren Klammer nach der Variablen σ^2 :

$$\begin{aligned} \frac{\partial}{\partial \sigma^2} \left(\frac{M}{2} \ln(2\pi\sigma^2) \right) &= \frac{M}{2\sigma^2} \\ \frac{\partial}{\partial \sigma^2} \left(\frac{1}{2\sigma^2} \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 \right) &= -\frac{1}{2(\sigma^2)^2} \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 \\ \frac{\partial}{\partial \sigma^2} \left(-\frac{1}{\sigma^2} \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) \right) &= \frac{1}{(\sigma^2)^2} \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) \\ \frac{\partial}{\partial \sigma^2} \left(\frac{1}{2\sigma^2} \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \right) &= -\frac{1}{2(\sigma^2)^2} \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \end{aligned}$$

Das Einsetzen der abgeleiteten Terme zurück in die Summe liefert

$$\begin{aligned} \frac{\partial}{\partial \sigma^2} f(\sigma^2) &= - \sum_{n=1}^N \left\{ \frac{M}{2\sigma^2} - \frac{1}{2(\sigma^2)^2} \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 + \frac{1}{(\sigma^2)^2} \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) - \frac{1}{2(\sigma^2)^2} \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \right\} \\ &= -\frac{NM}{2\sigma^2} - \sum_{n=1}^N \left\{ -\frac{1}{2(\sigma^2)^2} \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 + \frac{1}{(\sigma^2)^2} \mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) - \frac{1}{2(\sigma^2)^2} \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \right\}. \end{aligned}$$

Indem wir nun den gemeinsamen Faktor $\frac{1}{2(\sigma^2)^2}$ aus dem verbleibenden Summenausdruck ausklammern, drehen sich aufgrund des Minuszeichens vor der Summe alle Vorzeichen

im Inneren um. Damit ergibt sich die gesuchte Identität:

$$\begin{aligned} \frac{\partial}{\partial \sigma^2} f(\sigma^2) = & -\frac{NM}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{n=1}^N \left\{ \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 - 2\mathbb{E}[\mathbf{z}_n]^\top \mathbf{W}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) \right. \\ & \left. + \text{trace}(\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \mathbf{W}^\top \mathbf{W}) \right\}. \end{aligned}$$